


Enterprise AI Platform

GPU-Infrastruktur, Model Serving und Betrieb
einer KI-Plattform im Unternehmen

KV-CACHE · EINE SEQUENZ, SECHS BLÖCKE



Enterprise AI Platform

Lab Guide – GPU-Infrastruktur, Model Serving und Betrieb

Inhalt

Über dieses Buch	1
Über den Autor	5
TEIL I	
Grundlagen der LLM-Inferenz für Infrastruktur-Engineers	
1 Die Enterprise AI Platform im Überblick	9
1.1 Was diese Rolle verantwortet	9
1.2 Abgrenzung zu benachbarten Rollen	10
1.3 Warum diese Rolle gerade jetzt entsteht	11
1.4 Die vier Reifegrade einer KI-Plattform	12
1.5 Die Stack-Landkarte	13
1.6 Ein Request auf dem Weg durch die Plattform	14
1.7 Bekannte Bausteine, veränderte Eigenschaften	16
1.8 Die fünf Bruchstellen	17
1.9 Was eine KI-Plattform kostet	19
1.10 Typische Fehlannahmen beim Einstieg	20
1.11 Das Umfeld: Wer sonst beteiligt ist	21
1.12 Der Aufbau dieses Buches	22
1.13 Interviewfragen	23
1.14 Zusammenfassung	24
2 LLM-Inferenz aus Infrastruktursicht	27
2.1 Der Lebenszyklus einer Anfrage	27
2.2 Token	28
2.3 Prefill: rechenbegrenzt	29
2.4 Decode: bandbreitenbegrenzt	30
2.5 Der KV-Cache	31
2.6 Die VRAM-Bilanz	32
2.7 Kennzahlen	33
2.8 Batching — der zentrale Hebel	34
2.9 Prefill und Decode konkurrieren um dieselbe GPU	35
2.10 Gemeinsame Präfixe: der unterschätzte Hebel	37
2.11 Ausgabelänge und Sampling aus Betriebssicht	38
2.12 Einbettungs-Inferenz: dieselbe Hardware, andere Lastform	39
2.13 Kontextlänge und ihr Preis	40
2.14 Von der Nutzerzahl zur GPU-Zahl	40
2.15 Warum Messwerte streuen	42
2.16 Lab: Inferenz messbar machen	42
2.17 Betrieb und Troubleshooting	44
2.18 Interviewfragen	44
2.19 Zusammenfassung	46
3 Modellformate, Quantisierung und VRAM-Planung	47
3.1 Wie ein Modell auf der Festplatte aussieht	47
3.2 Zahlenformate	48
3.3 Was Quantisierung tatsächlich tut	49
3.4 Die Verfahren im Vergleich	50
3.5 Qualitätsverlust methodisch prüfen	52
3.6 Die vollständige VRAM-Bilanz	53
3.7 Modellauswahl für die Plattform	54
3.8 Entscheidungsmatrix	56
3.9 Zwei Sonderfälle, welche die Bilanz verändern	57
3.10 Rechenblatt: VRAM-Bilanz aufstellen	59
3.11 Lab: ein Modell in drei Formaten	59

3.12	Betrieb: Herkunft und Bereitstellung von Modellen	61
3.13	Betrieb und Troubleshooting	62
3.14	Interviewfragen	62
3.15	Referenztablette gängiger Modelle	64
3.16	Zusammenfassung	65

TEIL II

GPU-Infrastruktur

4	GPU-Hardware und der NVIDIA-Software-Stack	69
4.1	Was an einer GPU zählt	69
4.2	Consumer- oder Rechenzentrumskarte	71
4.3	Topologie: PCIe, NVLink und NUMA	71
4.4	Der Software-Stack	73
4.5	Lab: GPU-Passthrough unter Proxmox	74
4.6	Die Landkarte der GPU-Aufteilung	77
4.7	Treibervarianten: proprietär oder offen	77
4.8	Treiber und Container Toolkit in der VM	78
4.9	Betriebsthemen	80
4.10	Stack-Verifikation in einem Durchgang	83
4.11	Betrieb und Troubleshooting	85
4.12	Interviewfragen	85
4.13	Zusammenfassung	87
5	GPUs unter Kubernetes	89
5.1	Warum Kubernetes GPUs nicht von selbst kennt	89
5.2	Der NVIDIA GPU Operator	90
5.3	RKE2: was anders ist	91
5.4	Lab: GPU Operator auf RKE2 ausrollen	93
5.5	Scheduling: GPU-Knoten sauber trennen	95
5.6	Heterogene Cluster: mehrere GPU-Typen	97
5.7	Kontingente für Teams	98
5.8	Wartung und Knotengesundheit	99
5.9	Ausblick: Dynamic Resource Allocation	103
5.10	Den Operator selbst betreiben	104
5.11	Betrieb und Troubleshooting	105
5.12	Interviewfragen	106
5.13	Zusammenfassung	108
6	GPU-Sharing und Multi-Tenancy	109
6.1	Was Isolation bedeutet	109
6.2	Time-Slicing	110
6.3	Lab: Time-Slicing und seine Grenze	111
6.4	MPS — Multi-Process Service	113
6.5	MIG — Multi-Instance GPU	114
6.6	Die Vergleichsmatrix	116
6.7	Ein Entscheidungsbaum	117
6.8	Der Fall, für den Time-Slicing gebaut ist	117
6.9	Kostenzuordnung bei geteilten Karten	119
6.10	Wenn Time-Slicing nicht mehr trägt	119
6.11	Multi-Tenancy in der Praxis	120
6.12	Zwei Wege außerhalb des NVIDIA-Stacks	121
6.13	Beobachtbarkeit bei geteilten GPUs	122
6.14	Durchgerechnet: acht Karten für fünf Teams	123
6.15	Den aktiven Sharing-Modus erkennen	124
6.16	Betrieb und Troubleshooting	126
6.17	Interviewfragen	126
6.18	Zusammenfassung	127

TEIL III

Model Serving

7	vLLM: Architektur und Interna	131
7.1	Warum ein einfacher Generierungsaufwurf nicht genügt	131
7.2	PagedAttention	132
7.3	Der Scheduler	133
7.4	Chunked Prefill	136
7.5	Prefix Caching	137
7.6	Speculative Decoding	137
7.7	Die Engine-Architektur	139
7.8	Der Weg einer Anfrage durch die Engine	139
7.9	Strukturierte Ausgaben erzwingen	140
7.10	Aufmerksamkeitskernel und Kompilierung	142
7.11	Scheduler-Politik	143
7.12	Lab: dem Scheduler bei der Arbeit zusehen	144
7.13	Mehrere Antwortvarianten und geteilte Blöcke	145
7.14	Was vLLM nicht gut kann	146
7.15	Lab: geführtes Sampling messen	146
7.16	Betrieb und Troubleshooting	147
7.17	Interviewfragen	148
7.18	Zusammenfassung	149
8	vLLM in Produktion	151
8.1	Die Schnittstelle	151
8.2	Engine-Argumente: Referenz	152
8.3	Die vier Parameter, die voneinander abhängen	154
8.4	Mehrere Adapter auf einem Basismodell	155
8.5	Deployment auf Kubernetes	156
8.6	Modelle in den Cluster bringen	158
8.7	Mehrere Repliken	159
8.8	Absicherung des Deployments	160
8.9	Konfiguration versionieren	161
8.10	Pod-Größe berechnen	162
8.11	Benchmarking	162
8.12	Lab: deployen, tunen, messen	163
8.13	Einbettungsmodelle betreiben	164
8.14	Ein Modellwechsel in Produktion	165
8.15	Logs richtig einstellen	166
8.16	Betrieb und Troubleshooting	168
8.17	Interviewfragen	168
8.18	Zusammenfassung	169
9	Distributed Inference	171
9.1	Die Entscheidungskette	171
9.2	Tensor Parallelism	172
9.3	Was die Kommunikation kostet	174
9.4	Pipeline Parallelism	175
9.5	Data Parallelism	176
9.6	Konfiguration	177
9.7	Die VRAM-Bilanz bei Tensor Parallelism	178
9.8	Netzwerkanforderungen bei mehreren Knoten	179
9.9	Expert Parallelism	180
9.10	Wie viele GPUs für wie viele Nutzer	180
9.11	Multi-Node mit Ray	181
9.12	Beobachtbarkeit bei verteiltem Serving	182
9.13	Prefill/Decode-Disaggregation	183
9.14	Wann verteiltes Serving schadet	184
9.15	Optionales Lab auf gemieteter Hardware	184

9.16	Die Entscheidung in einer Tabelle	185
9.17	Der Weg von einer GPU zu mehreren	186
9.18	Betrieb und Troubleshooting	187
9.19	Interviewfragen	187
9.20	Zusammenfassung	188
10	KServe und das Serving-Ökosystem	191
10.1	Warum eine Abstraktion darüber	191
10.2	Die Architektur	192
10.3	Der InferenceService	193
10.4	Modellbezug	195
10.5	Autoscaling für Sprachmodelle	195
10.6	Canary-Rollouts	197
10.7	Cache-bewusste Weiterleitung	198
10.8	Das Serving-Ökosystem	199
10.9	Weitere Bestandteile	200
10.10	Beobachtbarkeit	201
10.11	Weiterleitung nach dem Kubernetes-Standard	201
10.12	Vom Deployment zu KServe	202
10.13	Stapelverarbeitung	203
10.14	Auslastung über mehrere Dienste	205
10.15	Lab: InferenceService mit Canary	205
10.16	Betrieb und Troubleshooting	207
10.17	Interviewfragen	207
10.18	Zusammenfassung	209

TEIL IV

Der Enterprise-Layer

11	AI Gateway mit LiteLLM	213
11.1	Warum ein Gateway	213
11.2	Architektur	214
11.3	Virtual Keys, Teams und Budgets	216
11.4	Routing und Ausfallsicherheit	217
11.5	Protokollierung und die Prompt-Frage	219
11.6	Antwort-Caching	219
11.7	Eigene Modelle bepreisen	220
11.8	Anbieterfunktionen weiterreichen	221
11.9	Streaming durch das Gateway	222
11.10	Guardrails im Anfragepfad	223
11.11	Anwendungsteams anbinden	224
11.12	Bestehende Zugänge ablösen	225
11.13	Das Gateway als kritischste Komponente	226
11.14	Lab: Gateway einrichten	227
11.15	Betrieb und Troubleshooting	229
11.16	Interviewfragen	229
11.17	Zusammenfassung	231
12	Identity, Autorisierung und Secrets	233
12.1	Drei Fragen, drei Mechanismen	233
12.2	Keycloak: die beiden Wege	234
12.3	Ansprüche im Gateway auswerten	235
12.4	Maschinenidentität ohne Geheimnis	236
12.5	OpenBao	237
12.6	Der Weg eines Provider-Schlüssels	238
12.7	Rotation ohne Ausfall	239
12.8	Wer fragt eigentlich? Das Delegationsproblem	241
12.9	Nachvollziehbarkeit	242
12.10	Zugänge beenden	243

12.11	Notfallzugang	243
12.12	Ein Rechtemodell für die Plattform	244
12.13	Bestandsaufnahme: alle Geheimnisse der Plattform	244
12.14	Vertraulichkeit auf dem Netzwerkpfad	245
12.15	Keycloak-Konfiguration als Code	246
12.16	Lab: Die Kette schließen	246
12.17	Betrieb und Troubleshooting	247
12.18	Interviewfragen	248
12.19	Zusammenfassung	249
13	AI Security, Governance und Compliance	251
13.1	Das Bedrohungsmodell	251
13.2	Prompt Injection und Handlungsvollmacht	252
13.3	Datenklassifikation	253
13.4	Erkennung personenbezogener Daten	254
13.5	Modell-Allowlist nach Datenklasse	255
13.6	Egress-Kontrolle	256
13.7	Mandantentrennung	257
13.8	Risiken der Wissensbasis	258
13.9	Falsche Antworten als Betriebsrisiko	258
13.10	Wer entscheidet was	259
13.11	Protokollierung, Aufbewahrung und Auskunft	259
13.12	Betreiberpflichten aus der KI-Regulierung	260
13.13	Die Ausgabe ist ungeprüfte Eingabe	261
13.14	Der Systemprompt ist kein Geheimnis	262
13.15	Herkunft und Lieferkette	263
13.16	Prüfplan vor der Inbetriebnahme	263
13.17	Wenn etwas passiert	264
13.18	Lab: Klassifikation und Egress durchsetzen	264
13.19	Betrieb und Troubleshooting	266
13.20	Interviewfragen	266
13.21	Zusammenfassung	268

TEIL V

Betrieb

14	Observability und FinOps	271
14.1	Drei Ebenen, drei Fragen	271
14.2	GPU-Metriken: die Auslastungsfalle	272
14.3	Serving-Metriken vollständig	273
14.4	Drei Dashboards	274
14.5	SLOs für Inferenz	274
14.6	Tracing	276
14.7	Das Kostenmodell	276
14.8	Gateway-Metriken	277
14.9	Logs	278
14.10	Aufbewahrung und Kardinalität	279
14.11	Kapazitätstrend	279
14.12	Der Monatsbericht	280
14.13	Diagnose: „Es ist langsam“	281
14.14	Die Break-even-Rechnung	282
14.15	Dashboard-Referenz	283
14.16	Lab: Von der Metrik zur Kostenaussage	284
14.17	Betrieb und Troubleshooting	285
14.18	Interviewfragen	285
14.19	Zusammenfassung	287
15	RAG-Infrastruktur betreiben	289
15.1	Die Strecke aus Betreibersicht	290

15.2	Kapazität berechnen	290
15.3	Die Datenbanken	291
15.4	Indexverfahren	292
15.5	Ingestion	293
15.6	Neuaufbau ohne Ausfall	294
15.7	Berechtigungen im Abruf	295
15.8	Löschen und Auskunft	296
15.9	Der Abruf im Detail	297
15.10	Parser und Vorverarbeitung	298
15.11	Mehrere Bestände	299
15.12	Betrieb der Datenbank	300
15.13	Das Einbettungsmodell als Plattformscheidung	301
15.14	Qualität messen, ohne Data Scientist zu sein	302
15.15	Zusammenspiel mit dem Gateway	302
15.16	Lab: Eine Abrufstrecke betreiben	303
15.17	Betrieb und Troubleshooting	304
15.18	Interviewfragen	305
15.19	Zusammenfassung	306
16	Model Lifecycle, GitOps und Delivery	309
16.1	Das Grundproblem	309
16.2	Modelle als Artefakte	310
16.3	Die Delivery-Kette	311
16.4	Umgebungen	311
16.5	Promotion und Rollback	312
16.6	Was ArgoCD nicht kann	313
16.7	Der Modellkatalog	314
16.8	Das Referenz-Repository	314
16.9	Was Modellpflege bedeutet	316
16.10	Wiederanlauf	316
16.11	Container-Images für Inferenz	318
16.12	Ein Rollout-Plan für die ganze Plattform	319
16.13	Lab: Ein Modellwechsel über GitOps	320
16.14	Betrieb und Troubleshooting	321
16.15	Interviewfragen	322
16.16	Zusammenfassung	323
TEIL VI		
Synthese		
17	Referenzarchitekturen und Kapazitätsplanung	327
17.1	Die Größe bestimmt fast alles	327
17.2	Klein: unter 100 Nutzer	328
17.3	Mittel: einige hundert Nutzer	329
17.4	Groß: mehrere tausend Nutzer	330
17.5	Die drei Architekturen im Kostenvergleich	331
17.6	Wann welche Stufe	332
17.7	Betriebsmodelle	332
17.8	Was ein Plattformteam können muss	333
17.9	Von der Nutzerzahl zur Hardware	333
17.10	Drei Anwendungsfälle durchgerechnet	334
17.11	Hybrid und mehrere Standorte	336
17.12	Die vollständige Referenzarchitektur	337
17.13	Die Senior-Aufgabe	338
17.14	Was am häufigsten falsch gemacht wird	339
17.15	Was bleibt, wenn sich die Werkzeuge ändern	339
17.16	Zusammenfassung	340
A	Interview- und Whiteboard-Training	343

A.1	Phase 1: LLM- und Inferenz-Grundlagen	343
A.2	Phase 2: GPU-Infrastruktur	346
A.3	Phase 3: vLLM	348
A.4	Phase 4: Kubernetes und KServe	350
A.5	Phase 5: AI Gateway	352
A.6	Phase 6: Security	353
A.7	Phase 7: Die Systemdesign-Aufgabe	354
A.8	Zwei weitere Systemdesign-Aufgaben	356
A.9	Whiteboard-Skizzen	357
A.10	Vertiefungsfragen	362
A.11	Fragen, die Sie selbst stellen sollten	365
A.12	Was nach dem Fachlichen kommt	366
A.13	Selbsteinschätzung	366
B	Referenz-Repository	369
B.1	Vollständige Struktur	370
B.2	Der Modellkatalog	372
B.3	Die Teamdefinition	372
B.4	Umgebungswerte	373
B.5	Was nicht ins Repository gehört	373
C	Kommando- und Konfigurationsreferenz	375
C.1	nvidia-smi	375
C.2	Xid-Codes	376
C.3	Kubernetes für GPUs	376
C.4	vLLM: Engine-Argumente	376
C.5	vLLM: Änderungen nach 0.8.x	377
C.6	DCGM-Metriken	378
C.7	LiteLLM	378
C.8	Formeln	379
C.9	Faustregeln	379
D	Glossar	381
	Sachregister	385
	Zum Schluss	387

Über dieses Buch

0.1 Für wen dieses Buch geschrieben ist

Dieses Buch richtet sich an alle, die eine unternehmensweite KI-Plattform bauen und betreiben – und die dafür Produktionserfahrung mit Kubernetes, GitOps, Identity-Providern, Secret-Verwaltung und Monitoring mitbringen.

Diese Aufgabe stellt sich derzeit in sehr vielen Organisationen gleichzeitig, und sie stellt sich meistens ungeplant. Entwickler benutzen längst ChatGPT und Claude, oft über private Accounts. Fachabteilungen haben Proof-of-Concepts gebaut, die niemand betreibt. Der Datenschutzbeauftragte hat Fragen. Der Einkauf hat eine Rechnung gesehen, die niemand einem Team zuordnen kann. Und irgendwo steht ein Server mit zwei GPUs, für den es keinen Betriebsprozess gibt.

Wer diese Situation in eine betreibbare Plattform überführen soll, braucht ein anderes Wissen als der Data Scientist, der Modelle auswählt, und ein anderes als der Anwendungsentwickler, der gegen eine API programmiert. Gebraucht wird Wissen über GPUs im Cluster, über die Mechanik von Inferenz-Servern, über Zugriffskontrolle auf Modelle, über Kostenzuordnung – und über die Frage, welche Daten welches Modell erreichen dürfen. Genau dieses Wissen versammelt dieses Buch.

0.2 Was dieses Buch nicht ist

Das ist wichtig genug für einen eigenen Abschnitt, denn es bestimmt, was auf den folgenden Seiten steht – und vor allem, was nicht.

Dies ist kein Kubernetes-Buch. Es wird nicht erklärt, was ein Pod, ein Deployment, ein Service oder ein Namespace ist. Es wird nicht erklärt, wie der Scheduler grundsätzlich arbeitet, wie Ingress funktioniert oder wie man ein Helm-Chart schreibt. Wo dieses Buch über Kubernetes spricht, geht es ausschließlich um das, was für GPU- und Inferenz-Workloads anders ist als für gewöhnliche Anwendungen – und das ist eine ganze Menge.

Dies ist kein DevOps-Grundlagenbuch. CI/CD, GitOps, Infrastructure as Code, Container, Registries, Netzwerksegmentierung und Observability werden als bekannt vorausgesetzt. Sie tauchen auf, aber immer in ihrer AI-spezifischen Ausprägung: ArgoCD nicht als Werkzeug erklärt, sondern in der Frage, wie man ein 16 Gigabyte großes Modellartefakt sinnvoll durch eine GitOps-Pipeline bewegt.

Dies ist kein Machine-Learning-Buch. Sie werden hier nicht lernen, wie ein Transformer funktioniert, wie Attention mathematisch definiert ist, wie man ein Modell trainiert oder feintunt. Die Innenansicht des Modells interessiert nur so weit, wie sie Betriebsentscheidungen bestimmt – und das ist überraschend weit: Ohne ein Verständnis davon, warum der KV-Cache linear mit der Kontextlänge wächst, kann man keine GPU-Kapazität planen. Aber die Grenze verläuft klar bei der Frage: Beeinflusst dieses Wissen eine Entscheidung, die ein Plattformbetreiber trifft?

Dies ist kein Tutorial. Ein Tutorial führt Sie einmal von Anfang bis Ende und ist danach verbraucht. Dieses Buch ist als Nachschlagewerk angelegt. Die meisten Kapitel sind so gebaut, dass man gezielt hineinspringen kann: Konzept, Referenz, Lab, Betrieb und Troubleshooting, Entscheidungsmatrix, Interviewfragen. Kapitel 1 und 17 ordnen ein und enthalten kein Lab; Kapitel 9 behandelt ein Thema, das sich im Referenz-Lab nicht ausführen lässt und deshalb als Konzept mit Konfigurationsreferenz erscheint. Sie werden es beim ersten Mal vielleicht linear lesen. Nützlich wird es beim zwölften Mal, wenn Sie um 23 Uhr nachschlagen, warum ein Pod mit `nvidia.com/gpu: 1` im Status Pending hängt.

0.3 Was vorausgesetzt wird

Bereich	Erwartetes Niveau
Linux	Sicher auf der Kommandozeile, systemd, Kernelmodule, Paketverwaltung
Container	Images bauen, Registries, Runtimes, Volumes, Netzwerkmodi
Kubernetes	Produktionserfahrung: Workloads, Scheduling, RBAC, Storage, Netzwerk
GitOps / CI-CD	ArgoCD oder Flux im Einsatz, Pipeline-Design
Identity	OIDC-Grundlagen, ein IdP wie Keycloak im Betrieb
Observability	Prometheus, Grafana, Logs und Traces im Alltag
Netzwerk und Security	TLS, NetworkPolicies, Egress-Kontrolle, Secret-Handling
Python	Lesen und anpassen — nicht entwickeln
Machine Learning	Nichts. Wird an den nötigen Stellen aufgebaut.

Wer bei mehreren dieser Zeilen unsicher ist, sollte diese Lücken zuerst schließen. Dieses Buch baut darauf auf und wiederholt es nicht.

0.4 Das Referenz-Lab

Alle praktischen Übungen in diesem Buch beziehen sich auf eine konkrete, bewusst kleine Umgebung. Das ist eine Entscheidung gegen Beliebigkeit: Anleitungen, die auf jeder denkbaren Plattform funktionieren sollen, funktionieren am Ende auf keiner richtig, weil sie genau die Reibungspunkte weglassen, an denen man tatsächlich scheitert.

Komponente	Ausprägung im Referenz-Lab
Virtualisierung	Proxmox VE, mehrere virtuelle Maschinen auf einem Host
GPU	Eine NVIDIA-GPU der RTX-Klasse mit 24 GiB VRAM, per VFIO an eine VM durchgereicht
Kubernetes	RKE2, mehrere Knoten, GPU auf genau einem Worker
Modelle	Llama 3.1 8B und Qwen 2.5 in 0.5B bis 32B, verschiedene Quantisierungen

Diese Umgebung ist keine Notlösung, sondern in einem Punkt sogar realistischer als ein Cloud-Cluster mit acht H100: Sie zwingt zu Entscheidungen. 24 GiB VRAM sind schnell voll. Eine GPU lässt sich nicht beliebig auf Teams verteilen. Genau diese

Knappheit ist es, die Plattformarbeit ausmacht — und wer sie im Kleinen beherrscht, kann sie im Großen begründen.

Wo die Hardware an ihre Grenze stößt, sagt dieses Buch das ausdrücklich. Tensor Parallelism über mehrere GPUs etwa lässt sich mit einer Karte nicht ausführen. Solche Themen werden dann als Konzept mit vollständiger Konfigurationsreferenz behandelt und ausdrücklich als nicht im Lab durchführbar gekennzeichnet. Was Sie hier nicht finden werden, ist ein Lab, das im Buch funktioniert und auf Ihrer Hardware nicht.

0.5 Konventionen

Wiederkehrende Elemente strukturieren jedes Kapitel. Sie erkennen sie an ihrer Farbe und Marke.

LAB So sieht ein Lab aus

Ziel: Was am Ende funktionieren soll

Praktische Übungen im Referenz-Lab. Immer mit erwarteter Ausgabe, damit Sie erkennen, ob es funktioniert hat — und woran Sie merken, dass es das nicht hat.

MERKE

Kernaussagen, die den Rest eines Abschnitts tragen. Wenn Sie ein Kapitel nur überfliegen, lesen Sie diese Kästen.

ACHTUNG

Fallstricke mit realen Konsequenzen: Datenverlust, Ausfall, Kostenexplosion oder eine Sicherheitslücke. Diese Kästen entstehen fast immer aus Fehlern, die jemand schon gemacht hat.

INTERVIEWFRAGE

Und so sieht eine Interviewfrage aus.

Am Ende jedes Kapitels stehen Fragen auf Senior-Niveau, jeweils mit dem, was eine schwache, eine gute und eine wirklich überzeugende Antwort ausmacht.

Zusätzlich trägt jedes Kapitel am Anfang einen Versionsstempel. Er nennt die Softwarestände, gegen die geschrieben und geprüft wurde:

GESCHRIEBEN GEGEN

Kubernetes 1.31 · RKE2 v1.31.x · vLLM 0.8.x

Das ist kein Zierrat. Der hier beschriebene Werkzeugkasten verändert sich schnell — vLLM veröffentlicht regelmäßig Releases mit neuen Engine-Argumenten, KServe verschiebt API-Felder, der GPU Operator ändert Standardwerte. Ein Nachschlagewerk ohne Versionsangabe altert unbemerkt und wird dadurch gefährlich. Mit

Versionsangabe altert es sichtbar und bleibt benutzbar, weil Sie wissen, wogegen Sie prüfen müssen.

0.6 Lesepfade

Es gibt drei sinnvolle Wege durch dieses Buch.

Der Aufbau Pfad Sie sollen eine Plattform bauen. Lesen Sie linear. Die Reihenfolge der Kapitel entspricht der Reihenfolge, in der die Schichten aufeinander aufbauen: erst verstehen, was Inferenz kostet, dann GPUs verfügbar machen, dann Modelle servieren, dann Zugriff und Governance, zuletzt Betrieb.

Der Interview Pfad Sie bereiten sich auf Gespräche vor. Lesen Sie die Abschnitte *Worum es geht* und *Merke* jedes Kapitels, dann geschlossen Anhang A, und gehen Sie von dort gezielt in die Kapitel zurück, deren Fragen Sie nicht souverän beantworten konnten.

Der Nachschlage Pfad Sie haben ein konkretes Problem. Nutzen Sie Inhaltsverzeichnis und Index, springen Sie in den Troubleshooting-Teil des betreffenden Kapitels – jedes der Kapitel 2 bis 16 hat einen; die einordnenden Kapitel 1 und 17 nicht. Wo zusätzlich ein eigener Referenzabschnitt existiert, ist er im Inhaltsverzeichnis als solcher benannt. Diese Abschnitte sind so geschrieben, dass sie ohne den Rest des Kapitels funktionieren.

0.7 Eine Anmerkung zur Haltbarkeit

Ein Buch über eine Technologie, die sich im Monatsrhythmus bewegt, hat ein offensichtliches Problem. Dieses Buch geht damit so um, dass es zwei Ebenen klar trennt. Die eine Ebene sind Konzepte: Warum Prefill und Decode grundsätzlich verschiedene Workloads sind. Warum der KV-Cache das eigentliche Kapazitätsproblem ist. Warum ein AI-Gateway die richtige Stelle für Governance ist. Warum GPU-Auslastung die zentrale FinOps-Kennzahl ist. Diese Ebene ist stabil. Sie war vor drei Jahren richtig und wird es in drei Jahren sein.

Die andere Ebene sind konkrete Flags, Feldnamen und Versionsstände. Diese Ebene veraltet, und zwar schnell. Sie ist deshalb konsequent in Referenzabschnitte und Versionsstempel ausgelagert, statt im Fließtext verstreut zu sein. Wenn ein Kommando nicht mehr stimmt, finden Sie es an einer klar markierten Stelle – und der Gedanke drumherum trägt weiter.

Wer nur Kommandos lernt, muss dieses Buch in einem Jahr wegwerfen. Wer die Konzepte versteht, kann die Kommandos in der jeweils aktuellen Dokumentation nachschlagen und richtig einordnen. Das zweite ist das Ziel.

Über den Autor

An dieser Stelle steht in Fachbüchern gewöhnlich eine Seite über den Verfasser. Darauf wird hier verzichtet. Wer ein Buch über Plattformarbeit schreibt, sollte sich an der Arbeit messen lassen und nicht an der Beschreibung seiner selbst.

Wer trotzdem wissen möchte, wer hinter diesen Kapiteln steht, findet das an den folgenden Stellen – und zwar belastbarer, als eine Biografie es sein könnte.

Der Autor arbeitet freiberuflich und unterstützt Organisationen beim Aufbau und Betrieb der hier beschriebenen Plattformen – von der Architektur über die Umsetzung bis zur Übergabe an den Betrieb, ebenso bei der Begutachtung bestehender Installationen und in Schulungen zum Stoff dieser Kapitel. Anfragen dazu sind willkommen, genauso wie Fragen zum Buch, Korrekturen und Hinweise auf Fehler: Ein Nachschlagewerk wird durch Widerspruch besser, nicht durch Zustimmung.

KONTAKT UND ARBEIT

Web	thomaszachmann.de
Firma	nyrvex.com
Code	gitlab.com/thomaszachmann
E-Mail	thomas@zachmann.work

TEIL I

Grundlagen der LLM-Inferenz für Infrastruktur-Engineers

Bevor eine GPU im Cluster steckt, muss klar sein, was auf ihr eigentlich passiert. Dieser Teil erklärt LLM-Inferenz aus der Perspektive dessen, der sie betreiben muss — nicht aus der Perspektive dessen, der Modelle trainiert.

Die Enterprise AI Platform im Überblick

ZIEL	Die Rolle des Enterprise AI Platform Engineers präzise fassen: Verantwortung, Abgrenzung zu benachbarten Rollen, und die Frage, welcher Teil des vorhandenen Platform-Wissens trägt und welcher nicht.
SETZT VORAUS	Produktionserfahrung mit Kubernetes und Platform Engineering. Kein Vorwissen über GPUs, Modelle oder Inferenz.
DANACH KANNST DU	Die vollständige Stack-Landkarte dieses Buches erklären, die fünf strukturellen Unterschiede zu klassischer Plattformarbeit benennen und einordnen, welche Kapitel für ein konkretes Vorhaben relevant sind.

GESCHRIEBEN GEGEN

Stand September 2026

Dieses Kapitel enthält keine Konfiguration und kein Lab. Es baut die Landkarte, auf die sich alle folgenden Kapitel beziehen. Wer ungeduldig ist und sofort GPUs in einen Cluster bringen will, kann bei Kapitel 4 einsteigen und hierher zurückkehren, sobald die Frage auftaucht, warum die Plattform eigentlich so geschnitten ist, wie sie geschnitten ist.

1.1 Was diese Rolle verantwortet

Die Rolle des Enterprise AI Platform Engineers umfasst Aufbau und Betrieb der Infrastruktur, auf der KI-Modelle in einer Organisation genutzt werden. Sie verantwortet nicht, welches Modell gut antwortet, sondern dass Modelle überhaupt verfügbar sind, dass sie kontrolliert genutzt werden, dass die Nutzung bezahlbar bleibt und dass sie nachweisbar den Regeln des Unternehmens folgt.

Das lässt sich auf vier Fragen zuspitzen. Wer eine KI-Plattform betreibt, muss sie jederzeit beantworten können:

1. **Auf welcher Hardware läuft welches Modell – und wer teilt sich diese Hardware?** Das ist eine Kapazitäts- und Isolationsfrage, und sie ist bei GPUs deutlich härter als bei CPU und RAM.
2. **Wie kommt ein Modell reproduzierbar in Produktion und wieder heraus?** Das ist eine Delivery-Frage, aber mit Artefakten von zweistelliger Gigabyte-Größe und Startzeiten in Minuten statt Sekunden.
3. **Wer darf welches Modell mit welchen Daten benutzen?** Das ist eine Identity-, Autorisierungs- und Governance-Frage – und der Punkt, an dem eine KI-Plattform sich am deutlichsten von einer gewöhnlichen Plattform unterscheidet.

4. **Was kostet der Betrieb, und wem wird er zugerechnet?** Das ist eine FinOps-Frage, die anders als bei klassischen Workloads nicht monatlich, sondern pro Anfrage entsteht und pro Anfrage messbar ist.

MERKE

Die Rolle ist keine Erweiterung der Data-Science-Rolle nach unten, sondern eine Erweiterung der Platform-Engineering-Rolle nach oben. Der fachliche Kern bleibt Infrastruktur: Ressourcen bereitstellen, Zugriff kontrollieren, Betrieb sichern, Kosten zuordnen. Neu ist die Art der Ressource — und die Tatsache, dass der Inhalt eines Requests plötzlich ein Compliance-Gegenstand ist.

1.2 Abgrenzung zu benachbarten Rollen

Der Begriff „AI Engineer“ wird derzeit für sehr verschiedene Tätigkeiten verwendet. Für die eigene Positionierung — gegenüber Arbeitgebern wie gegenüber Kunden — lohnt es sich, die Unterschiede scharf zu ziehen.

Rolle	Verantwortet	Typische Frage
Data Scientist	Modellauswahl, Evaluation, Datenqualität, fachliche Ergebnisse	Ist die Antwort richtig genug für den Anwendungsfall?
ML Engineer	Training, Fine-Tuning, Feature-Pipelines, Experimentverfolgung	Wie wird aus Daten ein besseres Modell?
AI Engineer / LLM App Developer	Anwendung gegen Modell-APIs, Prompting, Agenten, RAG-Logik	Wie baue ich ein Produkt auf einem Modell?
MLOps Engineer	Der Weg vom Training zum Deployment, Model Registry, Reproduzierbarkeit	Wie kommt ein trainiertes Modell zuverlässig in Betrieb?
AI Platform Engineer	Laufzeitplattform: GPUs, Serving, Gateway, Identity, Governance, Observability, Kosten	Wie betreibe ich Modelle für die ganze Organisation — sicher, verfügbar und bezahlbar?

Die Grenze zum MLOps Engineer ist in der Praxis unscharf und in kleineren Organisationen oft dieselbe Person. Der Unterschied in der Betonung ist trotzdem real: MLOps denkt vom Modellartefakt her, Platform Engineering von der Laufzeitumgebung und ihren Nutzern her. Dieses Buch nimmt durchgehend die zweite Perspektive ein.

MERKE

Für die eigene Positionierung ist die entscheidende Aussage nicht „ich kann auch KI“, sondern: **Ich baue und betreibe die Plattform, auf der KI im Unternehmen läuft.** Das ist eine Infrastrukturaussage, und sie ist gegenüber einem Data Scientist nicht schwächer, sondern komplementär.

1.3 Warum diese Rolle gerade jetzt entsteht

Rollen entstehen nicht aus Technologie allein, sondern aus Druck. Bei KI-Infrastruktur lässt sich dieser Druck auf vier Treiber zurückführen, die in fast jeder größeren Organisation gleichzeitig wirken.

1.3.1 Kontrollverlust durch Schatten-KI

Die verbreitetste Ausgangslage ist keine Plattform, sondern deren Abwesenheit. Mitarbeiter nutzen öffentliche Chat-Oberflächen mit privaten oder team-eigenen Zugängen. Was dabei passiert, ist aus Sicht der Informationssicherheit unangenehm einfach:



Schatten-KI: der unkontrollierte Pfad, den eine Plattform ersetzen muss

Das Problem ist nicht der Modellanbieter — viele Anbieter erfüllen im Enterprise-Tarif hohe Standards. Das Problem ist, dass die Organisation über den Vorgang nichts weiß. Es gibt keinen Nachweis, welche Daten das Haus verlassen haben, keine Möglichkeit, den Zugang zu entziehen, und keine Grundlage für eine Auskunft gegenüber Kunden oder Aufsichtsbehörden.

Eine Plattform löst das nicht dadurch, dass sie verbietet. Sie löst es dadurch, dass sie den kontrollierten Weg bequemer macht als den unkontrollierten. Das ist eine Infrastrukturaufgabe.

1.3.2 Kosten, die niemandem gehören

KI-Nutzung erzeugt Kosten pro Anfrage. Das ist ein struktureller Unterschied zu fast allen anderen Workloads einer Plattform. Ein Kubernetes-Cluster kostet einen Betrag pro Monat, weitgehend unabhängig davon, wie intensiv er genutzt wird. Ein Modellzugang kostet proportional zur Nutzung — und zwar in einer Größenordnung, die überrascht, sobald mehrere hundert Entwickler ihn ernsthaft verwenden.

Ohne Plattform landet diese Rechnung als eine Summe im Einkauf, ohne Zuordnung zu Team, Anwendung oder Zweck. Damit ist sie weder steuerbar noch verhandelbar. Der Wunsch nach Kostenzuordnung ist in der Praxis häufig der Auslöser, der ein AI-Gateway-Projekt überhaupt bewilligt bekommt — öfter als Sicherheitsargumente.

1.3.3 Datensouveränität und Regulierung

Für einen Teil der Daten ist die Frage nicht, ob der Anbieter vertrauenswürdig ist, sondern ob die Daten das Haus überhaupt verlassen dürfen. Gesundheitsdaten, Personalvorgänge, laufende Verfahren, sicherheitsrelevante Konstruktionsdaten, Quellcode mit Wettbewerbsrelevanz: Für diese Kategorien gibt es Anforderungen, die kein Vertrag mit einem externen Anbieter auflöst.

Daraus folgt fast zwangsläufig eine hybride Architektur — externe Modelle für unkritische Aufgaben, lokal betriebene Modelle für den Rest — und damit die Notwendigkeit, eigene GPUs zu betreiben. Genau an dieser Stelle wird aus einer Beschaffungsfrage eine Plattformfrage.

1.3.4 Abhängigkeit von einzelnen Anbietern

Der vierte Treiber ist betrieblicher Natur. Wenn eine wachsende Zahl interner Anwendungen direkt gegen die API eines einzigen Anbieters programmiert ist, hat die Organisation ein Verfügbarkeits- und ein Verhandlungsproblem zugleich. Ein Ausfall trifft alles gleichzeitig; ein Preis- oder Modellwechsel erzwingt Änderungen in jeder Anwendung.

Die Antwort darauf ist eine Abstraktionsschicht zwischen Anwendung und Anbieter. Das ist kein neues Muster — es ist dasselbe Argument, mit dem man einen Reverse Proxy, einen Message Broker oder einen Service Mesh einführt. Nur heißt es hier AI Gateway.

1.4 Die vier Reifegrade einer KI-Plattform

Organisationen kommen nicht in einem Schritt zu einer Plattform. In der Praxis lassen sich vier Stufen unterscheiden, und es lohnt sich, die eigene Organisation ehrlich einzuordnen — weil jede Stufe eine andere nächste Maßnahme nahelegt.

Stufe 0 — Schatten-KI Es gibt keine Plattform. Nutzung findet statt, aber unsichtbar, über private oder team-eigene Zugänge. Es existiert kein Inventar, kein Audit-Log, keine Kostenzuordnung. Charakteristisch ist, dass niemand die Frage beantworten kann, wie viele Menschen im Haus KI tatsächlich nutzen.

Stufe 1 — Zentraler Zugang Ein AI-Gateway bündelt den Zugriff. Identität, Kontingente und Protokollierung existieren, die Modelle laufen aber vollständig bei externen Anbietern. Das ist der Punkt, an dem Sichtbarkeit entsteht — und damit erstmals belastbare Zahlen für alle weiteren Entscheidungen.

Stufe 2 — Hybrid Zusätzlich laufen eigene Modelle auf eigenen GPUs. Das Gateway entscheidet, welche Anfrage wohin geht. Ab hier braucht die Organisation den vollen GPU- und Serving-Stack — und damit die Rolle, um die es in diesem Buch geht.

Stufe 3 — Plattform mit Governance Mehrere Teams nutzen die Plattform als Selbstbedienungsangebot. Es gibt Mandantentrennung, Modell-Allowlists nach Datenklassifikation, Chargeback, SLOs und einen definierten Weg, wie ein neues Modell in Betrieb geht. Das ist der Zielzustand, den dieses Buch beschreibt.

Diese Einordnung ist auch ein gutes Gesprächsinstrument im Kundenkontakt: Sie macht aus einer diffusen Anfrage („wir wollen was mit KI machen“) eine konkrete Ausgangslage.


Stufe	Sichtbarkeit	Typischer Aufwand	Zentrales Risiko
0 – Schatten-KI	keine	–	Datenabfluss, keine Nachweisbarkeit
1 – Gateway	vollständig für externe Nutzung	Wochen	Gateway wird zum Single Point of Failure
2 – Hybrid	zusätzlich eigene Infrastruktur	Monate	Schlechte GPU-Auslastung macht es teuer
3 – Governance	inklusive Datenklassifikation und Kosten je Team	fortlaufend	Komplexität überfordert das Betriebsteam

MERKE

Die Reihenfolge ist nicht beliebig. Wer bei Stufe 0 sofort GPUs beschafft, kauft Hardware ohne Nutzungsdaten und hat gute Chancen, sie falsch zu dimensionieren. Der Weg über Stufe 1 liefert genau die Zahlen, mit denen sich die Beschaffung anschließend begründen und richtig auslegen lässt.

1.5 Die Stack-Landkarte

Alles Weitere in diesem Buch ordnet sich in das folgende Bild ein. Es ist die Zielarchitektur, auf die die Kapitel schrittweise hinarbeiten.



Die Zielarchitektur einer Enterprise AI Plattform

Die entscheidende Beobachtung an diesem Bild ist ihre Verteilung: Der überwiegende Teil besteht aus Bausteinen, die ein erfahrener Platform Engineer bereits betreibt. Kubernetes, Identity, Secrets, Netzwerk, Monitoring, Registry, GitOps — das sind keine KI-Themen. Wirklich neu sind vier Kästen: der GPU-Stack, der Inferenz-Server, die Serving-Abstraktion darüber und das AI-Gateway davor.


MERKE

Ungefähr zwei Drittel einer Enterprise AI Plattform sind klassisches Platform Engineering. Das ist die eigentliche gute Nachricht: Der neue Teil ist schmal und tief, nicht breit und flach — und er lässt sich auf vier Bausteine und fünf strukturelle Unterschiede zurückführen.

1.6 Ein Request auf dem Weg durch die Plattform

Die Schichtgrafik zeigt, was es gibt. Sie zeigt nicht, was passiert. Der folgende Durchgang verfolgt eine einzelne Anfrage von der Anwendung bis zur GPU und

zurück – und benennt bei jedem Schritt, welches Kapitel ihn behandelt. Wer diesen Ablauf frei erzählen kann, hat die Architektur verstanden.



Nr.	Station	Was hier entschieden wird	Kapitel
1	Authentifizierung am Gateway	Ist das Token gültig? Gehört es zu einem Nutzer oder einer Maschine? Aus welchem Team?	12
2	Kontingentprüfung	Ist das Budget des Teams erschöpft? Werden Anfragen pro Minute oder Token pro Minute überschritten?	11
3	Inhaltsbewertung	Enthält der Prompt personenbezogene Daten oder als vertraulich klassifizierte Inhalte?	13
4	Modellauswahl	Welche Modelle darf dieser Nutzer mit dieser Datenklasse verwenden? Extern oder lokal? Was ist die Ausweichoption bei Ausfall?	11, 13
5a	KServe	Auf welche Modellversion wird geleitet? Existiert eine laufende Instanz oder muss erst eine starten?	10
5b	vLLM-Scheduler	Wird die Anfrage sofort verarbeitet oder eingereiht? Passt sie in den aktuellen Batch? Reicht der freie KV-Cache?	7

Nr.	Station	Was hier entschieden wird	Kapitel
5c	GPU	Prefill verarbeitet den gesamten Prompt auf einmal, Decode erzeugt danach Token für Token.	2
6	Verbrauchsbuchung	Wie viele Token wurden verbraucht, was kostet das, und welchem Team wird es zugerechnet?	11, 14
7	Protokollierung	Was wird gespeichert — und was ausdrücklich nicht?	13, 14

An diesem Ablauf lassen sich drei Dinge ablesen, die für den Rest des Buches wichtig sind.

Erstens trifft das Gateway die meisten Entscheidungen, obwohl es technisch die einfachste Komponente ist. Es ist die einzige Stelle, an der Identität, Inhalt, Kosten und Zielmodell gleichzeitig bekannt sind. Deshalb ist es der natürliche Ort für Governance — und deshalb ist es zugleich die Komponente, deren Ausfall alles stoppt.

Zweitens verlaufen die interessanten Fehlerfälle nicht am Ende, sondern in der Mitte. Eine Anfrage kann am Kontingent scheitern, an der Datenklassifikation, an einem Anbietersausfall, an einem erschöpften KV-Cache oder an einer Instanz, die noch lädt. Jeder dieser Fälle braucht ein eigenes Verhalten und eine eigene Fehlermeldung. Kapitel 11 behandelt, welche davon der Anwendung gegenüber wie signalisiert werden.

Drittens entstehen die aussagekräftigsten Metriken an den Rändern: am Gateway die Kosten- und Nutzungsdaten, an der GPU die Auslastungsdaten. Erst zusammengeführt ergeben sie ein Bild — etwa die Kosten je tausend Token im Eigenbetrieb, die sich nur bilden lassen, wenn Verbrauchszahlen aus dem Gateway und Auslastungszahlen aus DCGM zusammengebracht werden. Kapitel 14 zeigt, wie.

Diese Erzählung eignet sich gut als Einstieg in ein Architekturgespräch: Sie ist konkret genug, um Rückfragen zu provozieren, und vollständig genug, um jede Komponente unterzubringen.

1.7 Bekannte Bausteine, veränderte Eigenschaften

Die folgende Tabelle ist der praktische Kern dieses Kapitels. Sie stellt vertrauten Plattformkomponenten ihr Gegenstück auf einer KI-Plattform gegenüber und benennt, was daran anders ist.

Klassisch	Auf einer KI-Plattform	Der Unterschied
CPU- und Memory-Requests	nvidia.com/gpu als Extended Resource	Nicht teilbar, nicht überbuchbar, keine Limits im üblichen Sinn. Eine GPU gehört einem Pod — oder wird über MIG, Time-Slicing oder MPS geteilt, mit sehr unterschiedlichen Isolationsgarantien.
Node Pools und Taints	GPU-Node-Pools	Konzeptionell identisch. Neu ist die Label-Vielfalt aus der GPU Feature Discovery und die Notwendigkeit, GPU-Typen im Scheduling zu unterscheiden.
Container-Images	Modellartefakte	Zehn bis über hundert Gigabyte, nicht im Image, sondern aus Object Storage oder Hugging Face geladen. Startzeit

Klassisch	Auf einer KI-Plattform	Der Unterschied
		in Minuten. Caching wird zum Deployment-Thema.
Horizontal Pod Autoscaler	KServe-Autoscaling	CPU-Auslastung ist als Signal weitgehend wertlos. Maßgeblich sind Queue-Tiefe, KV-Cache-Belegung und Time to First Token.
Ingress und Reverse Proxy	AI Gateway	Zusätzlich Token-Zählung, Budgets, Modell-Routing, Provider-Fallback und Kostenzuordnung — auf Ebene des Anfrageinhalts, nicht nur des Transports.
OIDC und RBAC	Identität für Modellzugriff	Autorisiert wird nicht nur der Endpunkt, sondern die Kombination aus Nutzer, Modell und Datenklassifikation.
Vault-Secrets	Provider-API-Keys	Gleiche Mechanik, höhere Brisanz: Ein durchgereicherter Produktions-Key ist unmittelbar in Geld konvertierbar.
Prometheus-Metriken	DCGM und vLLM-Metriken	Gleicher Stack, andere Kennzahlen. Auslastung schlägt Verfügbarkeit als Leitmetrik.
Blue-Green und Canary	Modell-Rollouts	Gleiche Muster, aber teuer: Zwei Modellversionen parallel bedeuten doppelten VRAM-Bedarf, nicht doppelten RAM-Bedarf.
GitOps mit ArgoCD	Modell-Delivery	Das Manifest liegt in Git, das Artefakt nicht. Die Referenz auf die Modellversion wird zum kritischen, versionierten Bindeglied.

1.8 Die fünf Bruchstellen

Wo diese Analogien enden, beginnt das eigentlich Neue. Es sind fünf strukturelle Unterschiede, und sie erklären fast jede Entscheidung, die in den folgenden Kapiteln getroffen wird.

1.8.1 GPUs sind nicht fungibel

Kubernetes behandelt CPU und Speicher als teilbare, überbuchbare Größen. Ein Node mit 16 Kernen kann Pods mit zusammen 40 angeforderten Kernen tragen, solange sie nicht gleichzeitig Vollgas geben. Bei GPUs gilt nichts davon. Eine GPU wird über das Device Plugin als ganzzahlige, exklusive Ressource vergeben. Es gibt keine „halbe GPU“ im Standardmodell, und es gibt keine Überbuchung, die der Scheduler auffangen könnte.

Geteilt werden kann trotzdem — über MIG, Time-Slicing oder MPS — aber diese Verfahren sind grundverschieden in dem, was sie garantieren. Time-Slicing etwa teilt Rechenzeit, aber **nicht** Speicher: Zwei Pods auf derselben Karte können sich gegenseitig in den Out-of-Memory-Zustand treiben. Wer das nicht weiß, baut eine Multi-Tenancy, die im Lasttest funktioniert und in Produktion nicht. Kapitel 6 behandelt das im Detail.

Ausführlich in Kapitel 6, inklusive der Frage, welches Verfahren welche Isolationszusage tatsächlich einhält.

1.8.2 Modelle sind große, langsame Artefakte

Ein typischer Anwendungscontainer ist einige hundert Megabyte groß und in Sekunden gestartet. Ein Modell im Format safetensors mit acht Milliarden Parametern in 16-Bit-Präzision belegt rund 16 Gigabyte und muss vollständig in den GPU-Speicher geladen werden, bevor die erste Anfrage beantwortet werden kann.

Das verändert Betriebsannahmen, die sonst selbstverständlich sind. Scale-to-Zero ist attraktiv, weil eine ungenutzte GPU teuer ist — aber der Kaltstart kostet Minuten, nicht Millisekunden. Rolling Updates brauchen kurzzeitig Kapazität für zwei Modellversionen. Ein Node-Ausfall ist keine Sache von Sekunden mehr. Kapitel 8 und 10 behandeln die Konsequenzen.

1.8.3 Auslastung ist die Leitmetrik, nicht Verfügbarkeit

Bei klassischen Diensten optimiert man auf Verfügbarkeit und akzeptiert dafür Überkapazität. Ein Webserver bei 15 Prozent CPU-Last ist kein Problem, sondern Reserve.

Bei GPUs ist genau das ein Problem. Eine Karte, die zu 15 Prozent ausgelastet ist, verbrennt den Großteil ihres Anschaffungs- oder Mietpreises ohne Gegenwert. GPU-Auslastung ist deshalb keine reine Betriebskennzahl, sondern die zentrale wirtschaftliche Größe der gesamten Plattform — und der Grund, warum Batching, Sharing und Scheduling in diesem Buch so viel Raum einnehmen.

ACHTUNG Ein häufiger Fehlschluss

Hohe GPU-Auslastung im Sinne von `nvidia-smi` bedeutet nicht automatisch hohen Durchsatz. Der angezeigte Wert misst, ob überhaupt Kernel ausgeführt werden — nicht, wie effizient. Ein Inferenz-Server mit schlechtem Batching kann 100 Prozent anzeigen und trotzdem einen Bruchteil des möglichen Durchsatzes liefern. Kapitel 14 behandelt, welche Metriken tatsächlich aussagekräftig sind.

1.8.4 Kosten entstehen pro Anfrage

Klassische Plattformkosten sind Fixkosten mit monatlicher Granularität. KI-Kosten sind variable Kosten mit Anfrage-Granularität — und sie sind, anders als fast alles andere im Betrieb, exakt einer Person, einem Team und einer Anwendung zuzuordnen.

Das ist Chance und Verpflichtung zugleich. Die Chance: Eine Plattform kann echtes Chargeback leisten und damit Verbrauch steuern. Die Verpflichtung: Sobald diese Zuordnung technisch möglich ist, wird sie erwartet. Ein AI-Gateway ohne Kostenzuordnung gilt in Enterprise-Kontexten als unvollständig. Kapitel 11 und 14 behandeln beides.

1.8.5 Der Anfrageinhalt ist der Compliance-Gegenstand

Dies ist die tiefgreifendste Bruchstelle. Bei einer gewöhnlichen Plattform ist der Inhalt eines Requests für den Betreiber uninteressant; er transportiert, was Anwendungen senden, und Sicherheit bedeutet Transportsicherheit und Zugriffskontrolle.

Bei einer KI-Plattform ist der Inhalt selbst das Risiko. Ob ein Prompt Personendaten, Quellcode oder Vertragsdetails enthält, entscheidet darüber, welches Modell ihn verarbeiten darf. Damit entstehen Anforderungen, die es in klassischer Plattformarbeit

Die Ladezeit ist der Grund, warum Scale-to-Zero bei LLMs eine deutlich härtere Entscheidung ist als bei gewöhnlichen Diensten. Siehe Kapitel 10.

so nicht gibt: Inhaltsklassifikation im Anfragepfad, Modell-Allowlisting nach Datenkategorie, Egress-Kontrolle auf Anwendungsebene, und die unangenehme Frage, ob Prompts überhaupt protokolliert werden dürfen – und wie lange.

MERKE

Wer die fünf Bruchstellen erklären kann, hat den konzeptionellen Kern dieser Rolle verstanden. Alles Übrige sind Werkzeuge, die sich austauschen lassen. Diese fünf Punkte bleiben, auch wenn vLLM, KServe und LiteLLM in einigen Jahren anders heißen.

1.9 Was eine KI-Plattform kostet

Kaum eine Frage entscheidet häufiger über ein Plattformvorhaben als diese – und kaum eine wird häufiger mit Zahlen beantwortet, deren Herkunft niemand prüfen kann. Deshalb steht hier die Rechenmethode im Vordergrund, nicht das Ergebnis.

ACHTUNG Zu den Zahlen in diesem Abschnitt

Die folgenden Werte sind Beispielannahmen zur Veranschaulichung der Methode, keine aktuellen Marktpreise. Anbieterpreise, Hardwarekosten und Stromtarife ändern sich laufend. Ersetzen Sie jede Zeile durch Ihre eigenen Werte – das Verfahren bleibt gültig, die Zahlen nicht.

1.9.1 Die Bedarfsrechnung

Der Ausgangspunkt ist nie die Hardware, sondern das Nutzungsvolumen. Es lässt sich aus vier Größen ableiten:

Größe	Annahme	Woher sie kommt
Nutzer gesamt	500	Organisation
davon täglich aktiv	40 %	Erfahrungswert, stark schwankend
Anfragen je aktivem Nutzer und Tag	30	Aus Gateway-Logs, sonst geschätzt
Arbeitstage je Monat	20	Kalender
Input-Token je Anfrage	1 500	Aus Gateway-Logs; Systemprompt und Kontext dominieren
Output-Token je Anfrage	400	Aus Gateway-Logs

Daraus folgt: 200 aktive Nutzer, 120 000 Anfragen pro Monat, rund 180 Millionen Input-Token und 48 Millionen Output-Token.

1.9.2 Variante A – ausschließlich externe Modelle

Bei angenommenen 3 US-Dollar je Million Input-Token und 15 US-Dollar je Million Output-Token ergibt das rund 540 Dollar für Eingabe und 720 Dollar für Ausgabe, zusammen etwa 1 260 Dollar im Monat. Dazu kommt der Betrieb des Gateways, der auf gewöhnlichen CPU-Knoten läuft und im Vergleich kaum ins Gewicht fällt.

Die entscheidende Eigenschaft dieser Variante: Die Kosten sind vollständig variabel. Sie verdoppeln sich, wenn die Nutzung sich verdoppelt – und sie fallen auf null, wenn niemand die Plattform nutzt.

Die Input-Token dominieren fast immer die Menge, die Output-Token fast immer die Kosten – Ausgabe ist bei praktisch allen Anbietern deutlich teurer als Eingabe.

1.9.3 Variante B – eigene Inferenz

Hier entstehen im Wesentlichen Fixkosten. Eine beispielhafte Rechnung für einen GPU-Server mit zwei Beschleunigerkarten:

Position	Betrag im Monat	Grundlage
Hardware-Abschreibung	rund 700 €	25 000 € auf 36 Monate
Strom	rund 180 €	ca. 1 kW dauerhaft, 0,25 €/kWh
Rechenzentrumsfläche und Netz	rund 100 €	interne Verrechnung
Betriebsaufwand	rund 1 500 €	etwa 0,2 Vollzeitäquivalente
Summe	rund 2 480 €	

Die Kapazität einer solchen Maschine liegt um Größenordnungen über dem oben errechneten Bedarf. Genau darin liegt der Kern des Problems: Die Fixkosten fallen an, ob die GPUs zu 5 Prozent oder zu 80 Prozent ausgelastet sind.

1.9.4 Der Vergleich und was er wirklich sagt

Bei 120 000 Anfragen im Monat ist die externe Variante deutlich günstiger. Der Gleichstand liegt – unter diesen Annahmen – bei etwa der vierfachen Nutzung, also rund einer halben Million Anfragen im Monat. Darüber hinaus gewinnt der Eigenbetrieb, und zwar zunehmend deutlich, weil die Hardware noch sehr viel mehr Last tragen könnte. Kapitel 14.14 führt diese Rechnung vollständig und beziffert den Gleichstand über die GPU-Auslastung.

MERKE

Eigenbetrieb rechnet sich nicht ab einer bestimmten Nutzerzahl, sondern ab einer bestimmten **Auslastung**. Eine GPU, die zu einem Fünftel genutzt wird, ist die teuerste Variante von allen – teurer als jede Cloud-API. Das ist der wirtschaftliche Grund, warum Batching, Sharing und Scheduling in diesem Buch so viel Raum einnehmen.

Und die eigentliche Pointe: In vielen Organisationen ist die Kostenrechnung gar nicht der Grund für den Eigenbetrieb. Der Grund ist die Datenklassifikation – für einen Teil der Anfragen gibt es die externe Option schlicht nicht. Die Kostenrechnung entscheidet dann nicht mehr über das Ob, sondern nur noch über die Dimensionierung.

1.10 Typische Fehlannahmen beim Einstieg

Die folgenden Muster begegnen einem in fast jedem Projekt. Sie sind hier gesammelt, weil sie fast alle aus derselben Quelle stammen: aus der Übertragung von Annahmen, die bei klassischen Workloads richtig sind und bei Inferenz nicht mehr gelten.

„**Wir kaufen erst mal GPUs und schauen dann weiter.**“ Hardware ohne Nutzungsdaten wird fast immer falsch dimensioniert – meist zu groß in der Anzahl und zu klein im VRAM je Karte. Der VRAM je Karte bestimmt, welche Modelle überhaupt laufen; die Anzahl bestimmt nur den Durchsatz. Die Reihenfolge lautet: erst messen, dann beschaffen.

„**Das Modell ist zu groß, wir brauchen mehr GPUs.**“ Häufig stimmt das nicht. Zwischen „passt nicht“ und „mehr Hardware“ liegen Quantisierung, kleinere

Modellvarianten und eine bewusst begrenzte Kontextlänge. Kapitel 3 behandelt diese Kette systematisch.

„**Autoscaling regelt das schon.**“ Bei Inferenz skaliert nicht die Anwendung, sondern das Modell – und dessen Start dauert Minuten. Autoscaling ohne Wärmereserve erzeugt genau dann Ausfälle, wenn Last entsteht.

„**Wir loggen einfach alles mit.**“ Prompts können personenbezogene Daten, Quellcode und Geschäftsgeheimnisse enthalten. Vollständiges Logging ist deshalb keine Observability-Entscheidung, sondern eine datenschutzrechtliche. Sie gehört vor die Inbetriebnahme, nicht danach.

„**Ein Gateway ist doch nur ein Proxy.**“ Funktional ja, betrieblich nein. Sobald alle KI-Nutzung darüber läuft, ist es die kritischste Komponente der Plattform – mit entsprechenden Anforderungen an Hochverfügbarkeit, Zustandshaltung und Wartungsfenster.

„**GPU-Auslastung bei 100 Prozent heißt, wir sind am Limit.**“ Der Wert sagt nur, dass Rechenkerne beschäftigt sind, nicht wie effizient. Ein Server mit schlechtem Batching erreicht 100 Prozent bei einem Bruchteil des möglichen Durchsatzes.

„**Die Data Scientists sagen uns schon, was sie brauchen.**“ Sie nennen typischerweise Modellnamen, nicht Ressourcenprofile. Die Übersetzung von „wir wollen dieses Modell“ in VRAM-Bedarf, Kontextgrenze, erwarteten Durchsatz und Latenzziel ist genau die Aufgabe dieser Rolle.

1.11 Das Umfeld: Wer sonst beteiligt ist

Eine KI-Plattform berührt mehr Rollen als eine gewöhnliche Plattform. Wer diese Schnittstellen früh klärt, spart sich später Eskalationen.

Rolle	Braucht von der Plattform	Liefert an die Plattform
Anwendungsteams	Stabile, dokumentierte Endpunkte; Kontingente, die zur Anwendung passen	Lastprofile, Latenzanforderungen, Datenklassifikation
Data Science	Modelle deployen können; reproduzierbare Umgebungen	Modellauswahl, Ressourcenprofile, Qualitätskriterien
Informationssicherheit	Audit-Logs, Zugriffsnachweise, Egress-Kontrolle	Klassifikationsschema, Freigabekriterien
Datenschutz	Auskunft über Speicherung und Verarbeitung von Prompts	Aufbewahrungsfristen, Zweckbindung, Löschregeln
Einkauf und Controlling	Kosten je Team und Anwendung	Budgets, Anbieterverträge
Betrieb und On-Call	Runbooks, aussagekräftige Alarmer, klare Eskalation	Betriebszeiten, Reaktionszeiten

Auffällig ist die vierte Zeile. In klassischer Plattformarbeit ist der Datenschutz selten ein täglicher Gesprächspartner. Bei einer KI-Plattform ist er es, weil der Inhalt jeder Anfrage potenziell personenbezogen ist. Wer diese Abstimmung als Teil des Plattformdesigns begreift und nicht als nachgelagerte Freigabe, baut die Plattform anders – und richtiger.

Die Zeile „Datenschutz“ wird am häufigsten übersehen und verursacht am häufigsten späte Verzögerungen – meist genau dann, wenn die Plattform produktiv gehen soll.

1.12 Der Aufbau dieses Buches

Aus den Bruchstellen ergibt sich eine natürliche Reihenfolge. Man kann keinen Inferenz-Server sinnvoll tunen, ohne zu wissen, wofür der Speicher draufgeht. Man kann kein Gateway sinnvoll planen, ohne zu wissen, was hinter ihm steht.

Kapitel	Thema	Beantwortet die Frage
2–3	Inferenz und Speicher	Was passiert auf der GPU, und was kostet es an VRAM?
4–6	GPU-Infrastruktur	Wie wird eine GPU zu einer planbaren Cluster-Ressource?
7–10	Model Serving	Wie wird aus einer GPU ein belastbarer Modell-Endpunkt?
11–13	Enterprise-Layer	Wer darf was, mit welchen Daten, zu welchen Kosten?
14–16	Betrieb	Wie hält man das im Alltag am Laufen und liefert Änderungen aus?
17	Synthese	Wie sieht die Gesamtarchitektur in drei Größenordnungen aus?

Diese Reihenfolge entspricht bewusst nicht der Reihenfolge, in der die Komponenten im Architekturbild von oben nach unten stehen. Sie folgt der Reihenfolge, in der man sie verstehen muss: von der Hardware nach oben, weil jede höhere Schicht Annahmen über die darunterliegende trifft.

1.12.1 Was im Referenz-Lab lauffähig ist

Weil das Referenz-Lab mit einer einzelnen GPU arbeitet, ist ein Teil der Themen praktisch durchführbar und ein Teil nicht. Diese Grenze wird in jedem Kapitel ausdrücklich benannt; hier die Übersicht:

Thema	Im Lab	Anmerkung
GPU-Passthrough, Treiber-Stack	ja	Kapitel 4, vollständig
GPU Operator auf RKE2	ja	Kapitel 5, inklusive der RKE2-Besonderheiten
Node-Pool-Trennung, Scheduling	ja	Kapitel 5, durch die Topologie sogar realistisch
Time-Slicing, MPS	ja	Kapitel 6
MIG	nein	Auf RTX-Karten nicht verfügbar; als Konzept und Referenz behandelt
vLLM, Tuning, Benchmarking	ja	Kapitel 7–8, Kern des Buches
Tensor / Pipeline Parallelism	nein	Benötigt mehrere GPUs; optionales Cloud-Lab
KServe, Canary, Autoscaling	ja	Kapitel 10
LiteLLM, Keycloak, OpenBao	ja	Kapitel 11–13, CPU-Workloads
Observability-Stack	ja	Kapitel 14
RAG-Strecke mit Vektor-DB	ja	Kapitel 15, Einbettungsmodell neben dem LLM
GitOps-Delivery	ja	Kapitel 16

1.13 Interviewfragen

INTERVIEWFRAGE

Wie grenzen Sie Ihre Rolle von der eines ML Engineers ab?

Schwach ist jede Antwort, die Zuständigkeiten aufzählt, ohne den Schnitt zu begründen.

Gut ist die Unterscheidung nach Artefakt und Laufzeit: Der ML Engineer verantwortet, wie ein Modell entsteht und besser wird; der Platform Engineer verantwortet die Umgebung, in der es für die Organisation nutzbar ist.

Senior wird die Antwort durch die Schnittstelle zwischen beiden Rollen: das Modellartefakt mit seiner Version, seinen Ressourcenanforderungen und seinem Freigabestatus. Wer beschreiben kann, wie diese Übergabe konkret aussieht — Registry, Versionsreferenz im GitOps-Repo, Ressourcenprofil, Freigabe — zeigt, dass er Organisationen und nicht nur Technik denkt.

INTERVIEWFRAGE

Zwei Drittel einer AI-Plattform sind angeblich klassisches Platform Engineering. Was ist dann das dritte Drittel?

Gut ist die Aufzählung der vier neuen Bausteine: GPU-Stack, Inferenz-Server, Serving-Abstraktion, AI-Gateway.

Senior ist die Ergänzung, dass es nicht nur um neue Komponenten geht, sondern um veränderte Eigenschaften bekannter Komponenten: nicht teilbare Ressourcen, sehr große Artefakte, Auslastung statt Verfügbarkeit als Leitmetrik, nutzungsproportionale Kosten und Anfrageinhalte als Compliance-Gegenstand. Wer die fünf Bruchstellen benennt, hat die Frage vollständig beantwortet.

INTERVIEWFRAGE

Ein Vorstand fragt, warum die Firma eigene GPUs betreiben soll, wenn es OpenAI gibt. Was antworten Sie?

Schwach ist eine reine Kostenrechnung — sie geht bei moderatem Volumen fast immer gegen den Eigenbetrieb aus.

Gut ist die Trennung nach Datenklassifikation: Für einen Teil der Daten ist die externe Verarbeitung schlicht keine Option, unabhängig vom Preis.

Senior ist die hybride Antwort mit einer Bedingung: Externe Modelle für den Großteil der Anwendungsfälle, lokale Modelle für die regulierte Minderheit — verbunden durch ein Gateway, das die Entscheidung datengetrieben trifft, statt sie den Anwendungen zu überlassen. Dazu die ehrliche Angabe, ab welchem Auslastungsgrad sich eigene Hardware rechnet, und die Feststellung, dass eine schlecht ausgelastete GPU die teuerste Variante von allen ist.

INTERVIEWFRAGE

Was ist die wichtigste Kennzahl einer AI-Plattform?

Schwach ist „Verfügbarkeit“ — die Antwort aus dem klassischen Betrieb.

Gut ist GPU-Auslastung, mit dem wirtschaftlichen Argument dahinter.

Senior ist die Einschränkung: Auslastung im Sinne von `nvidia-smi` misst nur, ob Kernel laufen, nicht wie effizient. Aussagekräftig ist die Kombination aus Durchsatz in Tokens pro Sekunde, Time to First Token unter Last, KV-Cache-Belegung und Warteschlangentiefe — und für die Geschäftsseite die Kosten pro tausend Tokens im Vergleich zum Marktpreis.

INTERVIEWFRAGE

Wo würden Sie in einer Organisation ohne KI-Plattform zuerst ansetzen?

Gut ist das AI-Gateway: Es schafft sofort Sichtbarkeit, Zugriffskontrolle und Kostenzuordnung, ohne dass eine einzige GPU beschafft werden muss.

Senior ist die Begründung der Reihenfolge — Sichtbarkeit vor Kontrolle, Kontrolle vor Eigenbetrieb — ergänzt um den politischen Punkt: Das Gateway ist die Komponente, die sich am schnellsten rechtfertigen lässt, weil sie ein Problem löst, das das Management bereits als Problem erkannt hat. Eigene GPUs kommen später und mit belastbaren Nutzungsdaten aus dem Gateway als Begründung.

1.14 Zusammenfassung

- Der Enterprise AI Platform Engineer verantwortet die Laufzeitumgebung für KI im Unternehmen: Hardware, Serving, Zugriff, Governance, Betrieb und Kosten — nicht die fachliche Qualität der Modellantworten.
- Die Rolle steht dem Platform Engineering nahe, nicht der Data-Science-Rolle. Etwa zwei Drittel des benötigten Wissens deckt ab, wer Kubernetes produktiv betreibt.
- Vier Treiber erzeugen den Bedarf: Kontrollverlust durch Schatten-KI, nicht zuordenbare Kosten, Datensouveränität und Anbieterabhängigkeit.
- Wirklich neu sind vier Bausteine — GPU-Stack, Inferenz-Server, Serving-Abs-traktion, AI-Gateway — und fünf strukturelle Bruchstellen: GPUs sind nicht fungibel, Modelle sind große und langsame Artefakte, Auslastung schlägt Verfügbarkeit, Kosten entstehen pro Anfrage, und der Anfrageinhalt selbst ist der Compliance-Gegenstand.
- Der Aufbau des Buches verläuft von unten nach oben: Inferenz verstehen, GPUs verfügbar machen, Modelle servieren, Zugriff und Governance regeln, Betrieb sichern.

Quellen und Weiterlesen

- NVIDIA: *GPU Operator Documentation* — Referenz für den vollständigen GPU-Stack unter Kubernetes. Grundlage für Kapitel 5 und 6.
- vLLM: *Documentation* — Architektur, Engine-Argumente und verteiltes Serving. Grundlage für Kapitel 7 bis 9.
- KServe: *Documentation* — InferenceService, Serving Runtimes und Autoscaling. Grundlage für Kapitel 10.

- LiteLLM: *Proxy Documentation* — Gateway-Funktionen, Virtual Keys und Budgets. Grundlage für Kapitel 11.
- Europäische Union: *Verordnung über künstliche Intelligenz (EU AI Act)* — relevant für die Betreiberpflichten in Kapitel 13.

LLM-Inferenz aus Infrastruktursicht

ZIEL	Verstehen, was auf der GPU passiert, wenn ein Prompt eintrifft – und zwar so weit, dass sich daraus Speicherbedarf, Durchsatz und Latenz vorher berechnen lassen statt hinterher gemessen zu werden.
SETZT VORAUS	Kapitel 1. Kein Wissen über neuronale Netze.
DANACH KANNST DU	Den KV-Cache-Bedarf eines Modells aus seiner Konfigurationsdatei berechnen, die Decode-Geschwindigkeit aus der Speicherbandbreite abschätzen, TTFT und Durchsatz sauber auseinanderhalten und begründen, warum Batching der zentrale Hebel jeder Inferenz-Plattform ist.

GESCHRIEBEN GEGEN


vLLM 0.8.x · Referenz-GPU RTX, 24 GiB · Stand September 2026

Dieses Kapitel ist die Grundlage für alles Weitere. Wer die hier entwickelten Rechnungen beherrscht, kann eine GPU-Beschaffung begründen, ein Kapazitätsproblem diagnostizieren und in einem Interview jede Frage zur Dimensionierung beantworten. Wer sie überspringt, wird in Kapitel 8 vLLM-Parameter setzen, ohne zu wissen, warum.

Ausdrücklich nicht behandelt wird, wie ein Transformer funktioniert. Von der Modellarchitektur interessiert hier ausschließlich das, was Speicher belegt und Zeit kostet.

2.1 Der Lebenszyklus einer Anfrage

Aus Betriebssicht zerfällt jede Inferenz-Anfrage in fünf Abschnitte. Drei davon sind vernachlässigbar, zwei bestimmen alles.

**MERKE**

Die gesamte Betriebsmechanik von LLM-Inferenz folgt aus einer einzigen Tatsache: **Prefill und Decode sind zwei grundverschiedene Arten von Arbeit.** Prefill ist rechenbegrenzt und lässt sich parallelisieren. Decode ist speicherbandbreitenbegrenzt und ist prinzipiell sequenziell. Fast jede Optimierung in diesem Buch adressiert entweder das eine oder das andere – selten beides.

2.2 Token

2.2.1 Was ein Token ist

Ein Modell verarbeitet keinen Text, sondern Ganzzahlen. Der Tokenizer zerlegt Text in Einheiten aus dem Vokabular des Modells – typischerweise 32 000 bis 200 000 Einträge – und bildet sie auf IDs ab. Diese Einheiten sind keine Wörter, sondern häufige Zeichenfolgen: ganze kurze Wörter, Wortstämme, Endungen, Satzzeichen, Leerzeichen.

Für den Plattformbetrieb ist daran genau eine Eigenschaft wichtig: **Die Zahl der Token ist nicht proportional zur Zahl der Wörter, und das Verhältnis hängt von der Sprache ab.**

Inhalt	Token je Wort	Konsequenz
Englischer Fließtext	ca. 1,3	Referenzfall, auf den Anbieter ihre Preise auslegen
Deutscher Fließtext	ca. 1,8 bis 2,2	Komposita und Umlaute zerfallen in mehrere Token

Inhalt	Token je Wort	Konsequenz
Quellcode	ca. 2 bis 3	Bezeichner, Einrückung und Sonderzeichen
JSON und XML	ca. 3 und mehr	Strukturzeichen dominieren
Tabellen und Zahlen	stark schwankend	Ziffernfolgen werden oft einzeln zerlegt

Deutsch kostet also bei gleicher Aussage grob die anderthalb- bis zweifache Tokenmenge gegenüber Englisch. Wer eine Kostenschätzung aus englischsprachigen Benchmarkzahlen ableitet und auf einen deutschsprachigen Anwendungsfall überträgt, unterschätzt systematisch.

Diese Zeile wird in Kostenrechnungen fast immer übersehen: Dieselbe Anwendung ist auf Deutsch spürbar teurer als auf Englisch – allein durch die Tokenisierung.

2.2.2 Input- und Output-Token

Die Trennung ist keine Preisfindungslaune der Anbieter, sondern spiegelt die technische Realität. Input-Token werden im Prefill verarbeitet – alle gemeinsam, in einem hochparallelen Durchlauf. Output-Token entstehen im Decode – einzeln, nacheinander, jedes mit einem vollständigen Durchlauf durch sämtliche Modellgewichte.

Ein Output-Token kostet deshalb ein Vielfaches dessen, was ein Input-Token kostet. Bei externen Anbietern schlägt sich das in Preisen nieder, die für Ausgabe typischerweise drei- bis fünfmal höher liegen. Im Eigenbetrieb schlägt es sich darin nieder, dass die Ausgabelänge über den Durchsatz der gesamten Plattform entscheidet.

MERKE

Für Kapazitätsplanung gilt die Faustregel: Die Zahl der Input-Token bestimmt den **Speicherbedarf** – über den KV-Cache. Die Zahl der Output-Token bestimmt die **Zeit** – über den Decode. Zwei verschiedene Engpässe, zwei verschiedene Stellschrauben.

2.3 Prefill: rechenbegrenzt

Im Prefill verarbeitet die GPU sämtliche Prompt-Token in einem Durchgang. Weil alle Eingabetoken bereits bekannt sind, lässt sich die Berechnung vollständig parallelisieren – genau das, wofür eine GPU gebaut ist. Die Auslastung der Rechenwerke erreicht hier realistisch hohe Werte.

Der Rechenaufwand lässt sich gut abschätzen. Ein Vorwärtsdurchlauf durch ein Modell mit P Parametern kostet näherungsweise $2P$ Gleitkommaoperationen je Token – eine Multiplikation und eine Addition je Parameter. Für einen Prompt mit T Token also:

$$\text{FLOPs}_{\text{Prefill}} \approx 2 \cdot P \cdot T$$

Für ein Modell mit 8 Milliarden Parametern und einem Prompt von 2 000 Token sind das rund 32 Billionen Operationen. Eine GPU der Referenzklasse leistet in der Praxis – nicht im Datenblatt – grob 80 bis 120 Billionen Operationen je Sekunde in 16-Bit-Präzision. Der Prefill dauert damit etwa 0,3 Sekunden.

Diese Zahl ist die Untergrenze der Time to First Token. Alles, was zusätzlich anfällt – Warteschlange, Tokenization, Netzwerk – kommt obendrauf.

Die Näherung ignoriert den Aufwand der Attention selbst, der quadratisch mit der Sequenzlänge wächst. Bis in den Bereich einiger tausend Token dominieren die Matrixmultiplikationen der Gewichte, und die Näherung trägt gut.

MERKE

Prefill-Zeit wächst **linear** mit der Promptlänge. Ein zehnmal längerer Prompt bedeutet eine etwa zehnmal längere Wartezeit bis zum ersten Token. Das ist der Grund, warum Anwendungen mit sehr großem Kontext — etwa RAG mit vielen eingebetteten Dokumenten — ein spürbares Latenzproblem haben, das sich nicht durch mehr Speicher lösen lässt.

2.4 Decode: bandbreitenbegrenzt

Der Decode erzeugt ein Token nach dem anderen. Jedes neue Token benötigt das vorhergehende — die Schritte lassen sich nicht parallelisieren.

Entscheidend ist, was bei jedem einzelnen Schritt passiert: Die GPU muss **sämtliche Modellgewichte** aus dem Videospeicher in die Rechenwerke laden, um genau ein Token zu erzeugen. Der Rechenaufwand dafür ist winzig — rund $2P$ Operationen — aber die Datenmenge ist die volle Modellgröße.

Damit ist nicht die Rechenleistung der Engpass, sondern die Speicherbandbreite. Und daraus folgt eine der nützlichsten Abschätzungen dieses Buches:

$$\text{Token je Sekunde} \approx \frac{\text{Speicherbandbreite}}{\text{Modellgröße im Speicher}}$$

Modell und Format	Größe	Rechnerisch	Realistisch gemessen
Llama 3.1 8B, FP16	ca. 15 GiB	ca. 63 T/s	ca. 50–60 T/s
Llama 3.1 8B, AWQ 4-Bit	ca. 5,7 GiB	ca. 175 T/s	ca. 110–140 T/s
Qwen 2.5 14B, AWQ 4-Bit	ca. 9,5 GiB	ca. 105 T/s	ca. 70–90 T/s
Qwen 2.5 32B, AWQ 4-Bit	ca. 19,5 GiB	ca. 51 T/s	ca. 30–45 T/s

Grundlage ist eine Speicherbandbreite von rund 1 000 GB/s, wie sie Karten der Referenzklasse bieten. Die gemessenen Werte liegen darunter, weil neben den Gewichten auch der KV-Cache gelesen werden muss und die Bandbreite nie vollständig ausgereizt wird. Als Abschätzung für die Planung ist die Rechnung trotzdem erstaunlich belastbar.

MERKE

Bei einer einzelnen Anfrage bestimmt die **Speicherbandbreite** geteilt durch die **Modellgröße** die Ausgabegeschwindigkeit. Eine schnellere GPU mit gleicher Bandbreite bringt im Decode praktisch nichts. Quantisierung hingegen wirkt unmittelbar, weil sie den Divisor verkleinert — sie ist damit nicht nur eine Speicher-, sondern vor allem eine Geschwindigkeitsmaßnahme.

ACHTUNG Der häufigste Denkfehler bei der GPU-Auswahl

Datenblätter betonen Rechenleistung in TFLOPS. Für den Decode — also für die gefühlte Antwortgeschwindigkeit — ist diese Zahl weitgehend irrelevant. Vergleichen Sie Speicherbandbreite und VRAM-Kapazität. Eine Karte mit doppelter Rechenleistung, aber gleicher Bandbreite liefert bei einzelnen Anfragen nahezu identische Token-Raten.

2.5 Der KV-Cache

2.5.1 Warum es ihn gibt

Bei jedem Decode-Schritt müsste das Modell prinzipiell die Beziehung des neuen Tokens zu **allen** vorhergehenden Token berechnen. Diese Zwischenergebnisse — Key- und Value-Vektoren — hängen aber nur von den bereits verarbeiteten Token ab und ändern sich nicht mehr. Sie werden deshalb einmal berechnet und aufbewahrt: im KV-Cache.

Ohne ihn müsste bei jedem neuen Token die gesamte bisherige Sequenz neu verarbeitet werden. Der Aufwand für eine Antwort wüchse quadratisch statt linear mit ihrer Länge. Der KV-Cache tauscht also Rechenzeit gegen Speicher — und dieser Speicher ist das zentrale Kapazitätsproblem jeder Inferenz-Plattform.

2.5.2 Die Formel

MERKE KV-Cache-Bedarf

$$\text{Bytes je Token} = 2 \cdot L \cdot H_{\text{kv}} \cdot D \cdot B$$

mit L = Zahl der Schichten, H_{kv} = Zahl der Key-Value-Köpfe, D = Dimension je Kopf, B = Bytes je Wert (2 bei FP16 oder BF16). Der Faktor 2 steht für Key **und** Value.

Alle vier Größen lassen sich aus der Datei `config.json` des Modells ablesen — hier der für die Rechnung maßgebliche Ausschnitt:

```
{
  "num_hidden_layers": 32,
  "num_key_value_heads": 8,
  "num_attention_heads": 32,
  "hidden_size": 4096,
  "torch_dtype": "bfloat16",
  "max_position_embeddings": 131072
}
```

Die Zuordnung zu den Symbolen der Formel:

Symbol	Feld in <code>config.json</code>	Wert im Beispiel
L	<code>num_hidden_layers</code>	32
H_{kv}	<code>num_key_value_heads</code>	8
D	<code>hidden_size</code> geteilt durch <code>num_attention_heads</code>	$4096 / 32 = 128$
B	<code>torch_dtype</code> — BF16 sind 2 Byte	2

Damit ergibt sich für Llama 3.1 8B:

$$2 \cdot 32 \cdot 8 \cdot 128 \cdot 2 \text{ Byte} = 131.072 \text{ Byte} = 128 \text{ KiB je Token}$$

2.5.3 Warum Grouped-Query Attention so viel ausmacht

In der Formel steht H_{kv} , nicht die Zahl der Attention-Köpfe. Bei älteren Modellen waren beide gleich. Moderne Modelle verwenden **Grouped-Query Attention**: mehrere Query-Köpfe teilen sich ein Key-Value-Paar.

Praktische Merkhilfe: 128 KiB je Token bedeutet, dass 8 192 Token genau 1 GiB belegen. Für Llama 3.1 8B lässt sich der KV-Bedarf damit im Kopf rechnen.

Llama 3.1 8B hat 32 Attention-Köpfe, aber nur 8 KV-Köpfe. Ohne diese Optimierung läge der Bedarf bei 512 KiB je Token statt bei 128 — viermal so viel. Der gesamte nutzbare Kontext eines Servers würde sich vierteln.

Modell	L	H_{kv}	D	je Token	je 8 192 Token
Qwen 2.5 0.5B	24	2	64	12 KiB	0,09 GiB
Qwen 2.5 7B	28	4	128	56 KiB	0,44 GiB
Llama 3.1 8B	32	8	128	128 KiB	1,00 GiB
Qwen 2.5 14B	48	8	128	192 KiB	1,50 GiB
Qwen 2.5 32B	64	8	128	256 KiB	2,00 GiB
Llama 3.1 70B	80	8	128	320 KiB	2,50 GiB

Bemerkenswert an dieser Tabelle ist, dass der KV-Bedarf **nicht** proportional zur Parameterzahl wächst. Llama 3.1 70B hat knapp neunmal so viele Parameter wie das 8B-Modell, aber nur den 2,5-fachen KV-Bedarf je Token. Große Modelle sind bei den Gewichten teuer und beim Kontext vergleichsweise günstig — kleine Modelle umgekehrt.

ACHTUNG Der KV-Cache gehört der Sequenz, nicht der Anfrage

Der Bedarf richtet sich nach der **gesamten** Sequenzlänge, also Prompt plus bereits erzeugte Ausgabe. Eine Anfrage mit 30 000 Token Kontext belegt bei Llama 3.1 8B rund 3,7 GiB — dauerhaft, bis sie abgeschlossen ist. Wenige solcher Anfragen können den Cache eines Servers vollständig belegen und alle anderen blockieren.

2.6 Die VRAM-Bilanz

Der Videospeicher einer GPU teilt sich auf vier Posten auf. Nur einer davon ist variabel, und genau darum geht es beim Dimensionieren.

24 GiB VRAM × --gpu-memory-utilization 0.90		
vom Server beansprucht:	ca. 21,6 GiB	
CUDA-Kontext, Framework, Puffer	ca. 0,8 GiB	fix
Aktivierungen des laufenden Batches	ca. 0,5 GiB	fast fix
MODELLGEWICHTE Llama 3.1 8B in FP16	ca. 15,0 GiB	fix, aber durch Quanti- sierung wählbar
KV-CACHE = 43 000 Token bei 128 KiB je Token	ca. 5,3 GiB	der Rest

VRAM-Aufteilung: Der KV-Cache bekommt, was übrig bleibt.

Der KV-Cache ist der Restposten. Er bestimmt, wie viele Anfragen gleichzeitig bearbeitet werden können und wie lang ihr Kontext sein darf — und damit den gesamten Durchsatz.

2.6.1 Eine Rechnung, die man führen können muss

Angenommen, ein Dienst soll 20 gleichzeitige Anfragen mit je 4 000 Token Kontext bedienen. Der KV-Bedarf beträgt:

$$20 \cdot 4.000 \cdot 128 \text{ KiB} = 10.240.000 \text{ KiB} \approx 9,8 \text{ GiB}$$

Bei 5,3 GiB verfügbarem Cache passt das nicht. Es gibt vier Auswege, und alle vier haben Nebenwirkungen:

Option	Geeignet, wenn	Ungeeignet, wenn
Quantisierung des Modells	Gewichte auf 4 Bit reduzieren: rund 9 GiB mehr Cache, also über 100 000 Token Budget. Der wirkksamste Hebel.	Wenn die Antwortqualität nachweislich leidet – was fachlich geprüft werden muss, nicht technisch.
Kontextlänge begrenzen	Wenn der Anwendungsfall mit 2 000 Token auskommt. Halbiert den Bedarf sofort.	Wenn die Anwendung lange Dokumente verarbeiten muss.
Weniger Gleichzeitigkeit	Wenn Anfragen warten dürfen. Der Durchsatz bleibt erhalten, die Wartezeit steigt.	Wenn Latenzzusagen gelten oder die Warteschlange unbegrenzt wächst.
Kleineres Modell	Qwen 2.5 7B braucht 56 statt 128 KiB je Token und lässt mehr Platz für Gewichte.	Wenn die Aufgabe die Fähigkeiten des größeren Modells wirklich benötigt.
KV-Cache quantisieren	FP8 für den Cache halbiert dessen Bedarf. Vergleichsweise geringe Qualitätswirkung.	Wenn die eingesetzte Version das für dieses Modell nicht unterstützt.

MERKE

„Mehr GPUs“ steht bewusst nicht in dieser Liste. Eine zweite Karte verdoppelt zwar den Speicher, aber Tensor Parallelism kostet Kommunikation und lohnt sich erst, wenn das Modell selbst nicht mehr passt. Bei einem Kapazitätsproblem im KV-Cache sind Quantisierung und Kontextbegrenzung fast immer die besseren Antworten. Kapitel 9 behandelt, wann die Ausnahme gilt.

2.7 Kennzahlen

Ohne saubere Begriffe ist jede Diskussion über Inferenz-Leistung wertlos. Diese fünf Größen müssen sitzen.

Kennzahl	Bedeutung	Wovon sie abhängt
TTFT	Time to First Token: von der Annahme bis zum ersten ausgegebenen Token	Warteschlange + Promptlänge + Rechenleistung
TPOT / ITL	Time per Output Token bzw. Inter-Token Latency: Abstand zwischen zwei Ausgabtoken	Speicherbandbreite, Modellgröße, Batchgröße
E2E-Latenz	Gesamtdauer bis zur vollständigen Antwort	TTFT + TPOT × Ausgabelänge
Durchsatz	Summe der Ausgabtoken je Sekunde über alle Anfragen	Batchgröße, KV-Cache-Größe

Kennzahl	Bedeutung	Wovon sie abhängt
Goodput	Anteil der Anfragen, die eine Latenz-zusage tatsächlich einhalten	alles Vorstehende gemeinsam

Der Zusammenhang ist einfach und wird trotzdem ständig verwechselt:

$$\text{E2E-Latenz} = \text{TTFT} + \text{TPOT} \cdot (\text{Ausgabedaten} - 1)$$

Bei 0,3 Sekunden TTFT, 20 Millisekunden je Token und 500 Ausgabedaten ergibt das rund 10,3 Sekunden. Die Wahrnehmung des Nutzers hängt allerdings kaum an diesem Wert, sondern fast vollständig an TTFT und TPOT – weil moderne Oberflächen die Antwort strömend darstellen. Eine Antwort, die nach 0,3 Sekunden beginnt und flüssig weiterläuft, wirkt schnell, auch wenn sie zehn Sekunden dauert.

MERKE

Für Latenzzusagen gegenüber Anwendungsteams sind **TTFT** und **TPOT** die richtigen Größen, nicht die Gesamtdauer. Die Gesamtdauer hängt von der Ausgabedatenlänge ab, und die bestimmt die Anwendung, nicht die Plattform. Ein SLO auf E2E-Latenz ist deshalb ein SLO, das die Plattform nicht kontrollieren kann.

Goodput ist die ehrlichste Kennzahl. Ein Server kann seinen Durchsatz verdoppeln, indem er die Batchgröße erhöht – und dabei jede Latenzzusage reißen. Der Durchsatz sieht dann hervorragend aus, der Goodput fällt auf null.

2.8 Batching – der zentrale Hebel

2.8.1 Warum es überhaupt funktioniert

Im Decode wird bei jedem Schritt das gesamte Modell aus dem Speicher gelesen. Dieser Lesevorgang ist derselbe, unabhängig davon, ob ein Token für eine Anfrage oder für dreißig Anfragen gleichzeitig berechnet wird. Die Bandbreitenkosten fallen einmal an, die Rechenkosten steigen linear – und Rechenleistung ist im Decode reichlich vorhanden.

Daraus folgt der wichtigste Effekt der gesamten Inferenz-Optimierung: **Der Durchsatz steigt fast linear mit der Batchgröße, während die Latenz der einzelnen Anfrage nahezu konstant bleibt** – bis eine der beiden Grenzen erreicht ist.

Batch	Token/s je Anfrage	Token/s gesamt	Begrenzender Faktor
1	ca. 55	ca. 55	Speicherbandbreite
4	ca. 53	ca. 212	Speicherbandbreite
16	ca. 48	ca. 768	Speicherbandbreite
32	ca. 42	ca. 1 344	Übergang zu Rechenlast
64	ca. 30	ca. 1 920	Rechenlast und KV-Cache
96	–	–	KV-Cache erschöpft, Anfragen werden eingereiht

Die Zahlen sind Größenordnungen für ein 8B-Modell auf der Referenzhardware, keine Messwerte – das Lab am Ende dieses Kapitels erzeugt Ihre eigenen. Das Muster ist jedoch allgemein: Der Gesamtdurchsatz steigt zunächst fast proportional, dann abgeschwächt, und bricht schließlich ab, wenn der KV-Cache voll ist.


MERKE

Ein Inferenz-Server ohne wirksames Batching verschenkt eine Größenordnung an Durchsatz. Das ist der eigentliche Grund, warum ein spezialisierter Server wie vLLM einem einfachen Skript mit Hugging Face Transformers derart überlegen ist – nicht bessere Kernel, sondern bessere Auslastung. Kapitel 7 zeigt, wie das im Detail funktioniert.

2.8.2 Statisches, dynamisches und kontinuierliches Batching

Verfahren	Arbeitsweise	Problem
Statisch	Ein fester Batch wird gebildet, gemeinsam verarbeitet, gemeinsam beendet.	Alle warten auf die längste Antwort. Frei werdende Plätze bleiben ungenutzt.
Dynamisch	Der Server wartet ein kurzes Fenster, um mehrere Anfragen zu sammeln.	Besser, aber der Batch bleibt bis zum Ende starr. Zusätzliche Wartezeit für die erste Anfrage.
Kontinuierlich	Nach jedem Decode-Schritt verlassen fertige Anfragen den Batch und neue rücken nach.	Erfordert Speicherverwaltung auf Blockebene – genau das leistet PagedAttention.

Der Unterschied ist erheblich. Bei statischem Batching bestimmt die längste Antwort im Batch die Belegung aller Plätze. Wenn eine Anfrage 1 000 Token erzeugt und neunzehn andere je 50, sind neunzehn Plätze über 95 Prozent der Zeit ungenutzt.



Statisches gegenüber kontinuierlichem Batching. Grau markiert ungenutzte Plätze.

2.9 Prefill und Decode konkurrieren um dieselbe GPU


Bisher wurden beide Phasen getrennt betrachtet. Im laufenden Betrieb finden sie gleichzeitig statt – auf derselben Karte, mit denselben Rechenwerken. Daraus entsteht der Effekt, der in Produktion die meisten unerklärlichen Latenzspitzen verursacht.

2.9.1 Das Problem: eine lange Anfrage blockiert alle anderen

Ein Server bearbeitet gerade dreißig Anfragen im Decode. Jeder Schritt dauert wenige Millisekunden, die Ausgabe läuft für alle flüssig. Nun trifft eine neue Anfrage mit einem Prompt von 20 000 Token ein.

Der Prefill dafür ist ein einzelner, großer, unteilbarer Rechenauftrag. Solange er läuft, kommt kein Decode-Schritt zum Zug. Bei rund 0,3 Sekunden für 2 000 Token dauert

der Prefill für 20 000 Token grob drei Sekunden – und für drei Sekunden steht die Ausgabe **aller dreißig** laufenden Anfragen still.



Head-of-Line-Blocking: ein großer Prefill hält alle Decodes an.

In den Metriken sieht das so aus: TPOT springt kurzzeitig auf ein Vielfaches, ohne dass Auslastung oder Speicherbelegung auffällig wären. Wer nur Mittelwerte betrachtet, sieht davon nichts – erst das 95. oder 99. Perzentil macht den Effekt sichtbar.

MERKE

Deshalb sind Mittelwerte bei Inferenz-Latenz irreführend. Ein Server kann eine hervorragende mittlere TPOT haben und trotzdem regelmäßig sekundenlange Aussetzer produzieren. Latenz-SLOs für Inferenz gehören auf Perzentile, nicht auf Mittelwerte. Kapitel 14 behandelt die passenden Histogramme.

2.9.2 Die Gegenmaßnahmen

Maßnahme	Wirkung	Preis
Chunked Prefill	Der Prefill wird in Teilstücke zerlegt; zwischen den Stücken laufen Decode-Schritte weiter. Die Blockade verschwindet.	Der Prefill selbst dauert etwas länger, TTFT der neuen Anfrage steigt leicht.
Promptlänge begrenzen	Verhindert das Problem an der Wurzel.	Schränkt Anwendungsfälle ein; muss im Gateway durchgesetzt werden.
Getrennte Instanzen nach Lastprofil	Anwendungen mit langen Prompts erhalten eigene Endpunkte; interaktive Nutzung bleibt unbeeinflusst.	Mehr Instanzen, schlechtere Gesamtauslastung.
Prefill/Decode-Disaggregation	Prefill und Decode laufen auf verschiedenen GPUs; der KV-Cache wird übertragen. Beide Phasen lassen sich unabhängig skalieren.	Deutlich höhere Komplexität; lohnt erst bei großen Installationen. Kapitel 9.

Chunked Prefill ist in aktuellen Versionen der gängigen Server verfügbar und in vielen Fällen bereits voreingestellt. Es ist die erste Maßnahme, die man prüfen sollte, wenn TPOT-Ausreißer auftreten.

2.9.3 Der Sonderfall: gemischte Lastprofile

Der Konflikt verschärft sich, wenn sehr verschiedene Anwendungsfälle denselben Endpunkt benutzen:

Anwendungsfall	Prompt	Ausgabe	Charakter
Chat-Assistent	kurz	mittel	decode-dominiert, latenz-empfindlich
RAG mit Dokumenten	sehr lang	mittel	prefill-dominiert
Klassifikation	mittel	sehr kurz	prefill-dominiert, Massenbetrieb
Codegenerierung	lang	lang	beides, hoher KV-Bedarf
Zusammenfassung	sehr lang	kurz	nahezu reiner Prefill

Ein einzelner Endpunkt, der alle fünf Profile bedient, wird für keines davon gut konfiguriert sein. Die Trennung nach Lastprofil – über eigene Instanzen mit eigenen Parametern, geroutet vom Gateway – ist eine der wirksamsten Architekturentscheidungen einer reifen Plattform.

MERKE

Bevor Sie einen Inferenz-Endpunkt dimensionieren, klären Sie das Lastprofil: Wie lang ist der Prompt, wie lang die Antwort, wie viele Anfragen gleichzeitig, und wie empfindlich ist die Anwendung gegenüber Latenz? Ohne diese vier Angaben ist jede Konfiguration geraten.

Diese Tabelle ist ein guter Gesprächseinstieg mit Anwendungsteams. Die Frage „wie lang sind eure Prompts und eure Antworten?“ liefert mehr für die Dimensionierung als jede Angabe zur Nutzerzahl.

2.10 Gemeinsame Präfixe: der unterschätzte Hebel

In Unternehmensanwendungen sehen Anfragen einander sehr ähnlich. Fast jede trägt denselben Systemprompt: Rollenbeschreibung, Verhaltensregeln, Ausgabeformat, Werkzeugdefinitionen. In der Praxis sind das häufig 500 bis 2 000 Token – vor jeder einzelnen Nutzerfrage.

Ohne Gegenmaßnahme berechnet der Server diesen identischen Anfang bei **jeder** Anfrage neu. Bei einem Systemprompt von 1 500 Token und einer Nutzerfrage von 200 Token entfallen fast neun Zehntel der gesamten Prefill-Arbeit auf immer denselben Text.

Prefix Caching löst das: Die berechneten Key-Value-Blöcke des gemeinsamen Anfangs bleiben im Cache und werden von nachfolgenden Anfragen wiederverwendet. Der Prefill beginnt erst dort, wo sich die Anfragen tatsächlich unterscheiden.



Ohne und mit Prefix Caching bei gleichem Systemprompt

Die Wirkung ist erheblich: Bei den genannten Zahlen sinkt die Prefill-Arbeit ab der zweiten Anfrage um rund 88 Prozent, und TTFT fällt entsprechend.

MERKE Die Reihenfolge im Prompt entscheidet

Wiederverwendet werden kann nur ein **gemeinsamer Anfang**. Sobald sich zwei Anfragen an irgendeiner Stelle unterscheiden, ist ab dort nichts mehr wiederverwendbar. Daraus folgt eine Regel, die Plattformbetreiber an ihre Anwendungsteams weitergeben sollten:

Statisches zuerst, Variables zuletzt. Systemprompt, Werkzeugdefinitionen und Formatvorgaben an den Anfang; abgerufene Dokumente, Nutzerdaten und die eigentliche Frage ans Ende. Ein Zeitstempel oder ein Nutzernamen am Prompt-Anfang macht Prefix Caching vollständig wirkungslos – ein Fehler, der in RAG-Anwendungen häufig vorkommt und dessen Ursache selten gesucht wird.

Der Preis ist Speicher: Zwischengespeicherte Präfixe belegen Blöcke im KV-Cache, die sonst für laufende Anfragen zur Verfügung stünden. Bei wenigen, häufig genutzten Systemprompts ist das Geschäft klar vorteilhaft. Bei sehr vielen unterschiedlichen Präfixen verdrängt der Cache sich selbst und der Nutzen verschwindet. Kapitel 7 behandelt die Verdrängungsstrategie im Detail.

2.11 Ausgabelänge und Sampling aus Betriebssicht

Die Parameter, mit denen Anwendungen die Ausgabe steuern, sehen wie fachliche Einstellungen aus. Aus Plattformsicht sind mehrere davon unmittelbar kapazitätsrelevant.

Parameter	Fachliche Wirkung	Betriebliche Wirkung
max_tokens	Begrenzt die Antwortlänge	Die wirksamste Kostenbremse überhaupt. Ohne Obergrenze kann eine einzelne Anfrage einen Batchplatz beliebig lange belegen.
temperature	Steuert die Zufälligkeit der Auswahl	Kaum Rechenwirkung. Bei 0 sind Ergebnisse reproduzierbar – wichtig für Tests und für Antwort-Caching.
top_p, top_k	Begrenzen den Kandidatenraum	Vernachlässigbar.

Parameter	Fachliche Wirkung	Betriebliche Wirkung
n	Erzeugt mehrere Antwortvarianten	Vervielfacht die Decode-Arbeit unmittelbar. $n = 4$ bedeutet vierfachen Aufwand.
stop	Beendet die Ausgabe an definierten Zeichenfolgen	Spart Decode-Zeit, wenn sauber gesetzt — oft mehr als jede Serveroptimierung.
stream	Liefert Token einzeln aus	Ändert nichts an der Rechenlast, aber alles an der wahrgenommenen Geschwindigkeit.

ACHTUNG Eine fehlende Obergrenze ist ein Kapazitätsrisiko

Ein Client ohne `max_tokens` kann eine Antwort erzeugen, die bis zur Kontextgrenze läuft. Bei 4 096 Token Kontext sind das im ungünstigsten Fall über 4 000 Decode-Schritte für eine einzige Anfrage — bei gleichzeitiger dauerhafter Belegung eines Batchplatzes und des zugehörigen KV-Speichers. Eine serverseitige Obergrenze im Gateway gehört zu den ersten Schutzmaßnahmen jeder Plattform. Kapitel 11 zeigt, wie.

2.12 Einbettungs-Inferenz: dieselbe Hardware, andere Lastform

Für RAG-Anwendungen wird neben dem Sprachmodell ein Einbettungsmodell betrieben. Es verdient hier einen eigenen Abschnitt, weil sein Lastprofil in fast jeder Hinsicht anders aussieht — und weil es sich häufig dieselbe GPU mit dem Sprachmodell teilen muss.

Eigenschaft	Sprachmodell	Einbettungsmodell
Phasen	Prefill und Decode	nur Prefill
KV-Cache	wächst mit jeder Antwort	entfällt vollständig
Engpass	Speicherbandbreite im Decode	Rechenleistung
Typische Größe	5 bis 20 GiB	unter 1 GiB
Batching	kontinuierlich, komplex	einfach, sehr wirksam
Antwortzeit	Sekunden	Millisekunden

Weil kein Decode stattfindet und kein KV-Cache anfällt, skaliert Einbettungs-Inferenz deutlich freundlicher: Große Batches sind unproblematisch, und der Durchsatz liegt um Größenordnungen höher — Tausende kurzer Texte je Sekunde sind erreichbar.

Die betriebliche Konsequenz ist der gemeinsame Speicher. Ein Einbettungsmodell mit knapp 1 GiB nimmt dem Sprachmodell rund 8 000 Token KV-Cache weg. Das ist verschmerzbar, aber es muss in der Bilanz auftauchen — und es spricht dafür, Einbettungsdienste auf einem CPU-Node zu betreiben, wenn die Latenzanforderung es zulässt.

In RAG-Systemen entsteht der Engpass fast nie beim Embedding der Anfrage, sondern bei der einmaligen Verarbeitung des Dokumentenbestands. Kapitel 15 behandelt diese Ingestion-Last getrennt vom Abfragebetrieb.

2.13 Kontextlänge und ihr Preis

Modelle geben eine maximale Kontextlänge an — Llama 3.1 etwa 131 072 Token. Diese Zahl ist eine Eigenschaft des Modells, keine Betriebszusage. Was ein Server tatsächlich anbieten kann, ergibt sich aus seinem KV-Cache.

Bei 5,3 GiB Cache und 128 KiB je Token liegt das gesamte Token-Budget bei rund 43 000 Token — über **alle** gleichzeitigen Anfragen zusammen. Der volle Modellkontext von 131 072 Token passt also nicht einmal für eine einzige Anfrage.

ACHTUNG Der klassische erste Fehler beim vLLM-Start

Ohne gesetzte Kontextgrenze versucht vLLM, die deklarierte Maximallänge des Modells zu bedienen, stellt fest, dass der KV-Cache dafür nicht ausreicht, und bricht ab. Die Meldung nennt sinngemäß die maximale Sequenzlänge des Modells und die Zahl der Token, die tatsächlich in den Cache passen, und schlägt vor, `--max-model-len` zu senken oder `--gpu-memory-utilization` zu erhöhen. Der genaue Wortlaut ändert sich zwischen Versionen; das Muster bleibt.

Die richtige Reaktion ist nicht, blind an `--gpu-memory-utilization` zu drehen, sondern die Kontextgrenze bewusst am Anwendungsfall auszurichten. Kapitel 8 behandelt beide Parameter im Detail.

Kontextlänge ist damit eine **Kapazitätsentscheidung**, keine Konfigurationsformalität. Sie bestimmt unmittelbar, wie viele Anfragen gleichzeitig laufen können:

$$\text{Gleichzeitige Anfragen} \approx \frac{\text{KV-Cache in KiB}}{\text{Kontextlänge} \cdot \text{KiB je Token}}$$

Kontextgrenze	Gleichzeitige Anfragen	Geeignet für
2 048 Token	ca. 21	Chat, kurze Aufgaben, Klassifikation
4 096 Token	ca. 10	Allgemeiner Betrieb
8 192 Token	ca. 5	RAG mit wenigen Dokumenten
32 768 Token	ca. 1	Lange Dokumente — praktisch Einzelbetrieb

2.14 Von der Nutzerzahl zur GPU-Zahl

Damit sind alle Bausteine beisammen, um die Frage zu beantworten, die in jedem Plattformgespräch früher oder später gestellt wird: **Wie viele GPUs brauchen wir?** Die Rechnung verläuft in fünf Schritten.

2.14.1 Schritt 1 – Anfragerate

Aus der Nutzungsannahme wird eine Rate. Für die 200 aktiven Nutzer aus Kapitel 1 mit je 30 Anfragen über einen Arbeitstag von acht Stunden:

$$\frac{200 \cdot 30}{8 \cdot 3600 \text{ s}} \approx 0,21 \text{ Anfragen je Sekunde}$$

Nutzung verteilt sich jedoch nicht gleichmäßig. Ein Spitzenfaktor von 3 bis 5 gegenüber dem Tagesmittel ist bei interaktiver Nutzung realistisch — Vormittage und die Zeit nach Besprechungen dominieren. Mit Faktor 3:

$$\text{Spitzenlast} \approx 0,63 \text{ Anfragen je Sekunde}$$

2.14.2 Schritt 2 – Tokenbedarf

Bei 400 Ausgabetoken je Anfrage:

$$0,63 \cdot 400 \approx 250 \text{ Ausgabetoken je Sekunde}$$

Das ist die Größe, die eine GPU liefern muss – nicht die Anfragerate.

2.14.3 Schritt 3 – Durchsatz je GPU

Aus dem Batching-Abschnitt: Ein 8B-Modell liefert auf der Referenzhardware bei mittlerer Batchgröße grob 1 000 bis 1 400 Ausgabetoken je Sekunde. Rechnerisch reicht eine einzelne Karte für den Bedarf mehrfach aus.

2.14.4 Schritt 4 – Gegenprobe am KV-Cache

Der Durchsatz allein genügt nicht; die Anfragen müssen auch gleichzeitig in den Speicher passen. Nach dem Gesetz von Little gilt für die Zahl gleichzeitig im System befindlicher Anfragen:

$$\text{Anfragen im System} = \text{Rate} \cdot \text{Verweildauer}$$

Bei 0,63 Anfragen je Sekunde und einer mittleren Bearbeitungsdauer von 8 Sekunden sind das rund 5 gleichzeitige Anfragen. Bei 4 096 Token Kontext und 128 KiB je Token:

$$5 \cdot 4.096 \cdot 128 \text{ KiB} \approx 2,5 \text{ GiB}$$

Das passt komfortabel in die verfügbaren 5,3 GiB. Der KV-Cache ist hier nicht der Engpass.

2.14.5 Schritt 5 – Reserve und Verfügbarkeit

Die rechnerisch ausreichende Kapazität ist nicht die zu beschaffende Kapazität. Drei Aufschläge kommen hinzu:

Aufschlag	Faktor	Begründung
Wachstum	1,5 bis 2	Nutzung wächst nach Einführung regelmäßig stärker als geplant
Rollout-Reserve	+1 Instanz	Bei Modellwechseln laufen kurzzeitig zwei Versionen parallel
Ausfallreserve	+1 Knoten	Ohne zweiten GPU-Knoten ist Wartung nur mit Ausfall möglich

MERKE

Das Ergebnis dieser Rechnung ist fast immer, dass die **Kapazität** für den geplanten Bedarf mit erstaunlich wenig Hardware erreicht wird – und dass die tatsächliche Beschaffung von **Verfügbarkeit** und **Modellgröße** bestimmt wird, nicht von der Nutzerzahl. Wer eine Plattform mit zwei GPU-Knoten plant, tut das für Wartbarkeit und Ausfallsicherheit, nicht wegen des Durchsatzes.

ACHTUNG Wo diese Rechnung kippt

Sie gilt für interaktive Nutzung mit kurzen Antworten. Zwei Fälle brechen sie: **Stapelverarbeitung** – etwa das Klassifizieren von Millionen Dokumenten – erzeugt Dauerlast ohne Spitzen und wird durch den reinen Durchsatz begrenzt. **Agentische**

Anwendungen erzeugen je Nutzeraktion zehn bis hundert Modellaufrufe statt einem; hier ist der Multiplikator zwischen Nutzerhandlung und Anfragerate die entscheidende und meist unbekannte Größe.

2.15 Warum Messwerte streuen

Wer die Rechnungen dieses Kapitels an der eigenen Hardware überprüft, wird abweichende Zahlen sehen. Das ist normal. Die folgenden Ursachen erklären fast jede Abweichung und sollten bei jeder Messung ausgeschlossen werden.

Kein Warmlauf Die ersten Anfragen nach dem Start sind deutlich langsamer – Kernel werden übersetzt, Caches füllen sich, Ausführungsgraphen entstehen. Verwerfen Sie die ersten Durchläufe grundsätzlich.

Unterschiedliche Tokenisierung „100 Token“ bedeuten bei zwei Modellen unterschiedlich viel Text. Vergleiche zwischen Modellen müssen über Token laufen, nicht über Zeichen oder Wörter.

Schwankende Ausgabelänge Bei temperature größer null erzeugt dasselbe Prompt unterschiedlich lange Antworten. Für Messungen temperature auf 0 setzen und max_tokens fest vorgeben, sonst misst man die Ausgabelänge und nicht die Geschwindigkeit.

Prefix Caching wirkt unbemerkt Der zweite Durchlauf desselben Prompts ist drastisch schneller. Für Prefill-Messungen müssen die Prompts sich unterscheiden.

Thermische Begrenzung Consumer-Karten drosseln unter Dauerlast. Ein Lauf über zehn Minuten liefert andere Werte als ein Lauf über zehn Sekunden. Beobachten Sie Taktfrequenz und Temperatur mit.

Fremdlast auf derselben Karte Ein vergessener Prozess belegt Speicher und Rechenzeit. Vor jeder Messung den Belegungszustand prüfen.

MERKE

Eine Messung ohne festgehaltene Randbedingungen – Modell, Quantisierung, Kontextgrenze, Batchgröße, Promptlänge, Ausgabelänge, Serverversion – ist nicht reproduzierbar und damit wertlos. Das gilt besonders für Zahlen, die später zur Begründung einer Beschaffung dienen sollen.

2.16 Lab: Inferenz messbar machen

LAB Die Theorie an der eigenen GPU überprüfen

Ziel: Prefill- und Decode-Verhalten trennen, die Bandbreitenformel überprüfen und den Batching-Effekt sichtbar machen.

Voraussetzung: GPU-Node erreichbar, Python-Umgebung mit vLLM. Der vollständige Cluster-Betrieb folgt in Kapitel 8 – hier genügt ein direkter Start auf dem GPU-Host.

Schritt 1 – Server starten. Bewusst mit begrenzter Kontextlänge, damit der Start gelingt:

```
vllm serve Qwen/Qwen2.5-7B-Instruct \
  --max-model-len 4096 \
  --gpu-memory-utilization 0.90 \
  --port 8000
```

Erwartete Ausgabe: In der Startmeldung nennt vLLM die Größe des KV-Caches in Token oder GiB. Notieren Sie diesen Wert — er ist die Grundlage aller folgenden Rechnungen. Rechnen Sie ihn gegen die Formel aus Abschnitt 2.5 nach: Qwen 2.5 7B belegt 56 KiB je Token.

Schritt 2 – Decode-Rate bei einer einzelnen Anfrage. Eine Anfrage mit kurzem Prompt und langer Ausgabe isoliert den Decode:

```
curl -s http://localhost:8000/v1/completions \
  -H 'Content-Type: application/json' \
  -d '{"model": "Qwen/Qwen2.5-7B-Instruct",
    "prompt": "Zaehle von 1 bis 200.",
    "max_tokens": 300, "temperature": 0}' \
  | jq .usage
```

Messen Sie die Wanduhrzeit mit `time`. Teilen Sie die erzeugten Token durch die Dauer. **Erwartung:** Der Wert sollte in der Größenordnung von Bandbreite geteilt durch Modellgröße liegen — bei einem 7B-Modell in FP16 also grob 60 bis 70 Token je Sekunde.

Schritt 3 – Prefill sichtbar machen. Wiederholen Sie den Aufruf mit einem sehr langen Prompt und `"max_tokens": 1`. Damit entfällt der Decode fast vollständig, und die gemessene Zeit ist im Wesentlichen der Prefill. Steigern Sie die Promptlänge in Stufen — etwa 256, 1 024 und 3 072 Token — und tragen Sie die Zeiten auf. **Erwartung:** ein annähernd linearer Verlauf.

Schritt 4 – Batching-Effekt. Senden Sie 1, 4, 16 und 32 Anfragen gleichzeitig, jeweils mit identischer Ausgabelänge:

```
M=Qwen/Qwen2.5-7B-Instruct
LAST='{ "model": "'$M'", "prompt": "Erzaehle eine Geschichte.", '
LAST=$LAST'"max_tokens":200,"temperature":0}'

for n in 1 4 16 32; do
  start=$(date +%s.%N)
  for i in $(seq 1 $n); do
    curl -s http://localhost:8000/v1/completions \
      -H 'Content-Type: application/json' \
      -d "$LAST" >/dev/null &
  done
  wait
  d=$(echo "$(date +%s.%N) - $start" | bc)
  echo "n=$n  ${d}s  $(echo "$n*200/$d" | bc) Token/s"
done
```

Erwartung: Der Gesamtdurchsatz steigt deutlich, während die Dauer der einzelnen Anfrage nur mäßig zunimmt. Genau das ist der Batching-Effekt aus Abschnitt 2.8.

Schritt 5 – Metriken lesen. Während einer Lastphase:

```
curl -s http://localhost:8000/metrics | grep -E \
'num_requests_|gpu_cache_usage|time_to_first_token'
```

Beobachten Sie, wie die Zahl wartender Anfragen und die KV-Cache-Belegung mit der Gleichzeitigkeit steigen. Diese beiden Werte sind die wichtigsten Signale für Autoscaling – Kapitel 10 und 14 bauen darauf auf.

Ergebnis: Sie haben die drei zentralen Behauptungen dieses Kapitels an der eigenen Hardware überprüft: Prefill wächst linear mit der Promptlänge, Decode ist an die Bandbreite gebunden, und Batching erhöht den Durchsatz, ohne die Einzellatenz entsprechend zu verschlechtern.

2.17 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Server startet nicht, Meldung zur maximalen Sequenzlänge	Deklariert Modellkontext passt nicht in den verfügbaren KV-Cache	Modellgröße und <code>max_position_embeddings</code> gegen freien VRAM rechnen	<code>--max-model-len</code> am Anwendungsfall ausrichten; quantisiertes Modell erwägen
Antworten sind sehr langsam, GPU-Auslastung niedrig	Kein wirksames Batching; Anfragen laufen nacheinander	<code>num_requests_running</code> prüfen – steht dauerhaft bei 1	Gleichzeitigkeit erhöhen; prüfen, ob der Client serialisiert
Durchsatz bricht bei steigender Last ein	KV-Cache erschöpft, Anfragen werden verdrängt und neu berechnet	<code>gpu_cache_usage_percent</code> nahe 1,0 bei wachsender Warteschlange	Kontextgrenze senken, Modell quantisieren oder Gleichzeitigkeit begrenzen
TTFT hoch, TPOT normal	Lange Prompts oder Wartezeit in der Warteschlange	TTFT gegen Promptlänge auftragen; <code>num_requests_waiting</code> prüfen	Chunked Prefill aktivieren; Kapazität erhöhen; Prompts kürzen
TPOT hoch, TTFT normal	Batch zu groß oder Modell für die Bandbreite zu groß	Token je Sekunde gegen Bandbreite geteilt durch Modellgröße prüfen	Quantisieren; maximale Batchgröße begrenzen
Speicherfehler erst unter Last, nicht beim Start	Gewichte passen, aber KV-Cache und Aktivierungen wachsen mit der Gleichzeitigkeit	Belegung während eines Lasttests beobachten	<code>--gpu-memory-utilization</code> und <code>--max-num-seqs</code> aufeinander abstimmen

2.18 Interviewfragen

INTERVIEWFRAGE

Ein Modell braucht 40 GB VRAM. Sie haben eine Karte mit 24 GB. Was tun Sie?

Schwach ist „mehr GPUs“ als erste und einzige Antwort.

Gut ist die geordnete Liste: Quantisierung, kleinere Modellvariante, Kontextlänge begrenzen, mehrere GPUs mit Tensor Parallelism, im Notfall CPU-Offloading.

Senior wird die Antwort durch die Reihenfolge und ihre Begründung: Quantisierung zuerst, weil sie sowohl Speicher spart als auch den Decode beschleunigt – die Modellgröße steht im Nenner der Bandbreitenformel. Tensor Parallelism zuletzt, weil es Kommunikationsaufwand einführt und erst lohnt, wenn die Gewichte selbst nicht passen. CPU-Offloading nur als Notlösung, weil PCIe-Bandbreite um mehr als eine Größenordnung unter der HBM-Bandbreite liegt. Dazu die Rückfrage, ob 40 GB die Gewichte allein meinen oder den KV-Cache einschließen – das ändert die Antwort vollständig.

INTERVIEWFRAGE

Warum braucht ein LLM so viel GPU-Speicher?

Gut ist die Aufteilung in Gewichte und KV-Cache.

Senior ist die vollständige Bilanz – Gewichte, KV-Cache, Aktivierungen, CUDA-Kontext – mit der Feststellung, dass die Gewichte fix sind und der KV-Cache der variable Rest, der Gleichzeitigkeit und Kontextlänge bestimmt. Wer die Formel $2LH_{kv}DB$ nennen und an einem Modell vorrechnen kann, hebt sich deutlich ab.

INTERVIEWFRAGE

Was ist der Unterschied zwischen Prefill und Decode, und warum sollte mich das interessieren?

Gut ist: Prefill verarbeitet den Prompt parallel, Decode erzeugt Token sequenziell.

Senior ist die betriebliche Konsequenz: Prefill ist rechenbegrenzt und bestimmt TTFT, Decode ist bandbreitenbegrenzt und bestimmt TPOT. Daraus folgt, dass ein Latenzproblem je nach Ausprägung völlig verschiedene Ursachen hat – und dass beide Phasen um dieselbe GPU konkurrieren. Wer Chunked Prefill oder Prefill/Decode-Disaggregation als Antwort darauf nennt, zeigt, dass er die aktuelle Entwicklung kennt.

INTERVIEWFRAGE

Wie viele gleichzeitige Nutzer schafft eine GPU?

Schwach ist jede konkrete Zahl ohne Rückfrage.

Gut ist die Feststellung, dass es auf Modell, Quantisierung, Kontextlänge und Ausgabelänge ankommt.

Senior ist die Rechnung vor Ort: KV-Cache geteilt durch Kontextlänge mal Bytes je Token ergibt die Zahl gleichzeitiger Sequenzen; Durchsatz geteilt durch Token je Anfrage ergibt die Zahl der Anfragen je Sekunde. Ergänzt um den Hinweis, dass „gleichzeitige Nutzer“ und „gleichzeitige Anfragen“ nicht dasselbe sind – ein Nutzer im Chat erzeugt vielleicht eine Anfrage pro Minute.

INTERVIEWFRAGE

Warum ist Quantisierung nicht nur eine Speichurmaßnahme?

Gut ist: Sie reduziert die Modellgröße und schafft Platz für den KV-Cache.

Senior ist die zweite Wirkung: Weil der Decode bandbreitenbegrenzt ist und die Modellgröße im Nenner steht, erhöht Quantisierung unmittelbar die Ausgabegeschwindigkeit — ein 4-Bit-Modell ist nicht nur kleiner, sondern etwa zwei- bis dreimal schneller im Decode. Der Preis ist ein Qualitätsverlust, der fachlich zu prüfen ist. Kapitel 3 behandelt beides.

2.19 Zusammenfassung

- Eine Anfrage zerfällt in Prefill und Decode. Prefill ist rechenbegrenzt, wächst linear mit der Promptlänge und bestimmt TTFT. Decode ist bandbreitenbegrenzt, sequenziell und bestimmt TPOT.
- Die Decode-Geschwindigkeit einer einzelnen Anfrage lässt sich als Speicherbandbreite geteilt durch Modellgröße abschätzen. Diese Formel trägt für Planung und Fehlersuche.
- Der KV-Cache benötigt $2LH_{kv}DB$ Bytes je Token. Alle Werte stehen in der `config.json` des Modells. Bei Llama 3.1 8B sind es 128 KiB je Token, also 1 GiB je 8 192 Token.
- Der VRAM teilt sich in Gewichte, KV-Cache, Aktivierungen und Kontext. Die Gewichte sind fix, der KV-Cache ist der Rest — und er bestimmt Gleichzeitigkeit und Kontextlänge.
- Kontextlänge ist eine Kapazitätsentscheidung, keine Formalität. Der deklarierte Modellkontext ist keine Betriebszusage.
- Batching ist der wirksamste Hebel für Durchsatz, weil die Bandbreitenkosten des Gewichteslesens je Decode-Schritt nur einmal anfallen. Kontinuierliches Batching setzt Blockverwaltung des Caches voraus.
- Für Latenzzusagen sind TTFT und TPOT die richtigen Größen. Die Gesamtdauer hängt an der Ausgabelänge, die die Anwendung bestimmt.

Quellen und Weiterlesen

- vLLM: *Documentation — Engine Arguments und Metrics*. Referenz für `max-model-len`, `gpu-memory-utilization` und die im Lab genutzten Kennzahlen.
- Kwon et al.: *Efficient Memory Management for Large Language Model Serving with PagedAttention*. Die Arbeit hinter der Blockverwaltung des KV-Caches; Grundlage für Kapitel 7.
- Ainslie et al.: *GQA — Training Generalized Multi-Query Transformer Models*. Hintergrund zur Reduktion der Key-Value-Köpfe.
- Die `config.json` der eingesetzten Modelle auf Hugging Face — die verlässlichste Quelle für L , H_{kv} und D .

Modellformate, Quantisierung und VRAM-Planung

ZIEL	Aus einem Modellnamen eine belastbare Speicher- und Geschwindigkeitsaussage ableiten — und begründet entscheiden, in welchem Format ein Modell betrieben wird.
SETZT VORAUS	Kapitel 2, insbesondere die KV-Cache-Formel und die Bandbreitenabschätzung.
DANACH KANNST DU	Ein Modell-Repository lesen und seine Größe vorhersagen, die Quantisierungsverfahren unterscheiden und passend auswählen, die vollständige VRAM-Bilanz für eine gegebene Karte aufstellen und den Qualitätsverlust einer Quantisierung methodisch sauber prüfen.

GESCHRIEBEN GEGEN

vLLM 0.8.x · safetensors 0.4.x · Referenz-GPU RTX, 24 GiB, Ampere oder Ada · Stand September 2026

Kapitel 2 hat gezeigt, dass die Modellgröße zweimal wirkt: Sie belegt Speicher, der dem KV-Cache fehlt, und sie steht im Nenner der Bandbreitenformel und bestimmt damit die Decode-Geschwindigkeit. Quantisierung ist der einzige Hebel, der beide Wirkungen gleichzeitig verbessert. Sie ist deshalb keine Randnotiz, sondern die folgenreichste Einzelentscheidung beim Betrieb eines Modells.

3.1 Wie ein Modell auf der Festplatte aussieht

3.1.1 Das Repository-Layout

Ein Modell ist kein Artefakt, sondern ein Verzeichnis. Die Struktur ist bei praktisch allen offenen Modellen identisch:

```
Llama-3.1-8B-Instruct/
├── config.json                Architektur: Schichten, Köpfe, Dimensionen
├── generation_config.json     Vorgaben für Sampling
├── model-00001-of-00004.safetensors Gewichte, in Teildateien aufgeteilt
├── model-00002-of-00004.safetensors
├── model-00003-of-00004.safetensors
├── model-00004-of-00004.safetensors
├── model.safetensors.index.json Zuordnung Tensorname -> Teildatei
├── tokenizer.json             Vokabular und Zerlegungsregeln
├── tokenizer_config.json      Chat-Vorlage, Sondertoken
└── special_tokens_map.json
```

Der übliche Aufbau eines Modell-Repositorys

Für den Betrieb sind drei Dateien wichtig. Die `config.json` liefert alle Werte für die KV-Cache-Formel aus Kapitel 2. Der `tokenizer_config.json` enthält die Chat-Vorlage, die darüber entscheidet, wie Nachrichten in einen Prompt umgesetzt werden — eine häufige Fehlerquelle bei selbst gebauten Clients. Und die Summe der Gewichtsdateien ist die Untergrenze des VRAM-Bedarfs.

Die `index.json` ist praktisch: Sie listet jeden Tensor mit Namen. Daran lässt sich ablesen, welche Teile eines quantisierten Modells noch in voller Präzision vorliegen.

3.1.2 safetensors und warum das eine Sicherheitsfrage ist

Ältere Modelle liefern Gewichte als `.bin` oder `.pt` — das sind Python-Pickle-Dateien. Pickle ist ein Serialisierungsformat, das beim Laden beliebigen Code ausführen kann. Ein manipuliertes Modell aus einer öffentlichen Quelle ist damit ein vollwertiger Angriffsvektor auf den GPU-Knoten.

`safetensors` wurde genau dagegen entworfen: reine Tensordaten mit einem JSON-Kopfbereich, ohne ausführbaren Anteil. Das Format erlaubt zusätzlich speicherabbildendes Laden, was Startzeiten spürbar verkürzt.

ACHTUNG Betriebsregel

Auf Produktionsknoten sollten ausschließlich `safetensors`-Gewichte geladen werden. Wo ein Modell nur als Pickle vorliegt, gehört die Umwandlung in eine kontrollierte Vorstufe — nicht auf den Inferenz-Knoten. Serverseitig lässt sich das erzwingen; Kapitel 13 behandelt die Absicherung des Modellpfads, Kapitel 16 die Frage, wie Modelle überhaupt in die eigene Umgebung gelangen.

3.1.3 Die Größe vorhersagen

Der Speicherbedarf der Gewichte ergibt sich unmittelbar:

$$\text{Bytes} = \text{Parameterzahl} \cdot \text{Bytes je Parameter}$$

Für ein Modell mit 8,03 Milliarden Parametern in 16 Bit sind das rund 16,1 Milliarden Bytes, also etwa 15,0 GiB. Diese Zahl sollte mit der Summe der `safetensors`-Dateien übereinstimmen. Weicht sie deutlich ab, liegt entweder eine andere Präzision vor oder das Modell ist bereits quantisiert.

3.2 Zahlenformate

3.2.1 Die Kandidaten

Format	Bytes	Eigenschaft	Rolle bei Inferenz
FP32	4	Volle Präzision, 8 Exponent- und 23 Mantissenbits	Für Inferenz überdimensioniert; kommt praktisch nicht vor
FP16	2	5 Exponentenbits — begrenzter Wertebereich, Überlaufgefahr	Verbreitet, aber gegenüber BF16 im Nachteil
BF16	2	8 Exponentenbits wie FP32, dafür nur 7 Mantissenbits	Der Standard. Gleicher Wertebereich wie FP32, robuster als FP16
FP8 (E4M3)	1	4 Exponenten-, 3 Mantissenbits	Sehr gutes Verhältnis, aber nur auf neuerer Hardware
INT8	1	Ganzzahlig, benötigt Skalierungsfaktoren	Solide, breit unterstützt

Format	Bytes	Eigenschaft	Rolle bei Inferenz
INT4	0,5	Ganzzahlig, gruppenweise Skalierung	Der Arbeitspunkt für begrenzten VRAM

Die wichtigste Unterscheidung ist die zwischen FP16 und BF16, und sie wird oft missverstanden. Beide belegen zwei Bytes. FP16 verteilt sie auf 5 Exponenten- und 10 Mantissenbits, BF16 auf 8 und 7. BF16 ist also **ungenauer**, deckt aber denselben Wertebereich ab wie FP32. Für neuronale Netze ist das der bessere Kompromiss, weil Überläufe schlimmere Folgen haben als Rundungsfehler.

MERKE

Wenn ein Modell BF16-Gewichte mitbringt, betreiben Sie es in BF16. Die Umwandlung nach FP16 spart nichts – beide belegen zwei Bytes – und kann bei Modellen mit großen Aktivierungswerten zu Ausfällen führen, die als scheinbar zufällige NaN-Ausgaben auftreten.

3.2.2 FP8 und seine Hardwarevoraussetzung

FP8 ist attraktiv: halber Speicher gegenüber BF16 bei sehr geringem Qualitätsverlust, weil das Format seinen Wertebereich behält. Es setzt allerdings Rechenwerke voraus, die FP8 nativ beherrschen.

GPU-Generation	Beispiele	Compute	FP8 nativ
Ampere	A100, RTX 3090	8.0 / 8.6	nein
Ada Lovelace	L40S, L4, RTX 4090	8.9	ja
Hopper	H100, H200	9.0	ja
Blackwell	B200 und Nachfolger	10.0	ja, zusätzlich FP4

ACHTUNG FP8 im Referenz-Lab

Auf einer Karte der Ampere-Generation – etwa einer RTX 3090 – steht FP8 nicht zur Verfügung. Der Server kann ein FP8-Modell zwar unter Umständen laden, indem er es entpackt, verliert dabei aber genau den Vorteil, um den es ging. Auf einer Karte der Ada-Generation – etwa einer RTX 4090 – funktioniert FP8 dagegen vollständig.

Die Labs dieses Kapitels sind deshalb auf AWQ und GPTQ ausgelegt, die auf beiden Generationen laufen. Der FP8-Abschnitt bleibt konzeptionell – er ist für Kundenumgebungen mit H100 oder L40S trotzdem wichtig zu beherrschen.

3.3 Was Quantisierung tatsächlich tut

3.3.1 Das Grundprinzip

Quantisierung bildet einen kontinuierlichen Wertebereich auf wenige diskrete Stufen ab. Bei 4 Bit stehen 16 Stufen zur Verfügung. Damit das funktioniert, wird nicht das ganze Modell auf einmal skaliert, sondern in **Gruppen** – typischerweise 64 oder 128 benachbarte Gewichte. Jede Gruppe erhält einen eigenen Skalierungsfaktor und gegebenenfalls einen Nullpunkt, beides in höherer Präzision.

Daraus folgt, dass „4 Bit“ nie exakt 4 Bit bedeutet:

$$\text{effektive Bits} \approx 4 + \frac{\text{Bits für Skalierung und Nullpunkt}}{\text{Gruppengröße}}$$

Bei einer Gruppengröße von 128 und je 16 Bit für Skalierung und Nullpunkt ergibt das rund 4,25 Bit je Gewicht. Die Gruppengröße ist damit ein direkter Kompromiss: kleinere Gruppen bedeuten bessere Qualität und mehr Speicher.

3.3.2 Warum nicht alles quantisiert wird

Hier liegt eine Beobachtung, die viele Größenrechnungen scheitern lässt. Ein Modell mit 8 Milliarden Parametern müsste bei 4,25 Bit rund 4,0 GiB belegen. Tatsächliche 4-Bit-Modelle dieser Größe liegen bei etwa 5,7 GiB. Die Differenz hat einen Grund: **Einbettungsschicht und Ausgabekopf bleiben in voller Präzision.**

Bei Llama 3.1 8B mit einem Vokabular von 128 256 Einträgen und einer Modelldimension von 4 096 belegt die Einbettungsmatrix rund 525 Millionen Parameter – und der Ausgabekopf noch einmal ebenso viele. Zusammen sind das über eine Milliarde Parameter, die in 16 Bit verbleiben und allein rund 2,0 GiB belegen.

MERKE

Bei modernen Modellen mit großem Vokabular entfällt ein erheblicher Teil des Speicherbedarfs auf Einbettung und Ausgabekopf, die von der Quantisierung ausgenommen bleiben. Die Faustregel „4-Bit-Modell ist ein Viertel so groß“ trifft deshalb nicht zu. Realistisch sind 35 bis 40 Prozent der Originalgröße. Die verlässliche Zahl steht in der Dateigröße des Repositorys – nicht in einer Rechnung.

3.3.3 Gewichte oder auch Aktivierungen

Zwei Ansätze sind zu unterscheiden:

Weight-only Nur die Gewichte werden quantisiert und vor der Berechnung wieder entpackt. Die eigentliche Rechnung läuft in 16 Bit. Speicher und Bandbreite sinken, die Rechenlast steigt sogar leicht.

Weight and Activation Auch die Zwischenergebnisse werden in niedriger Präzision gehalten und gerechnet. Erst dadurch sinkt auch die Rechenlast.

Für Inferenz ist **weight-only** in den meisten Fällen die richtige Wahl – und der Grund steht in Kapitel 2: Der Decode ist bandbreitenbegrenzt, nicht rechenbegrenzt. Wer die Datenmenge reduziert, gewinnt unmittelbar; zusätzliche Rechenlast fällt kaum ins Gewicht.

Im Prefill kehrt sich das um: Dort ist Rechenleistung der Engpass, und weight-only-Quantisierung bringt wenig bis nichts. Bei prefill-dominierten Lastprofilen ist der Gewinn deshalb geringer als erwartet.

3.4 Die Verfahren im Vergleich

Verfahren	Bits	Kalibrierung	Hardware	Einordnung
AWQ	4	nötig	Ampere und neuer	Schützt die wichtigsten Gewichte anhand von Aktivierungsmustern. Sehr gute Qualität, schnelle Kernel. Empfehlung für den Regelfall.

Verfahren	Bits	Kalibrierung	Hardware	Einordnung
GPTQ	3, 4, 8	nötig	Ampere und neuer	Schichtweise Optimierung mit Fehlerausgleich. Vergleichbar gut, sehr verbreitet, viele fertige Modelle verfügbar.
FP8	8	gering	Ada, Hopper und neuer	Geringster Qualitätsverlust, aber nur halbe Ersparnis gegenüber 4 Bit – und Hardwarevoraussetzung.
INT8	8	gering	breit	Robuster Zwischenschritt, wenn 4 Bit zu viel Qualität kostet.
bitsandbytes	4, 8	keine	breit	Quantisiert beim Laden, ohne Vorbereitung. Bequem für Versuche, für Produktion deutlich langsamer.
GGUF	2 bis 8	teils	CPU und GPU	Format der llama.cpp-Familie. Stark für CPU-Betrieb und Einzelplatz, im Kubernetes-Serving unüblich.

3.4.1 Kalibrierungsdaten – der unterschätzte Punkt

AWQ und GPTQ benötigen einen kleinen Datensatz, an dem sie beobachten, welche Gewichte wichtig sind. Üblich sind einige hundert Textausschnitte. Fast alle öffentlich verfügbaren quantisierten Modelle wurden mit **englischsprachigen** Standarddatensätzen kalibriert.

ACHTUNG Für deutschsprachige Anwendungen relevant

Ein mit englischen Daten kalibriertes Modell kann bei deutschsprachigen Eingaben stärker verlieren als die veröffentlichten Benchmark-Zahlen vermuten lassen – und ganz besonders bei fachsprachlichen oder domänenspezifischen Texten.

Das ist kein Grund, auf Quantisierung zu verzichten. Es ist ein Grund, den Qualitätsverlust **an den eigenen Daten** zu prüfen statt an fremden Benchmarks. Der nächste Abschnitt beschreibt, wie.

Wer eigene Kalibrierungsdaten verwendet – etwa echte Prompts aus dem eigenen Anwendungsfall – erzielt regelmäßig bessere Ergebnisse als mit einem fertigen Community-Modell. Der Aufwand liegt bei einigen GPU-Stunden und ist gut investiert, sobald ein Modell dauerhaft im Einsatz sein soll.

3.4.2 Warum das Format die Geschwindigkeit bestimmt

Ein quantisiertes Modell ist nicht automatisch schneller. Entscheidend ist, ob für das konkrete Format optimierte Rechenkerne vorliegen. Fehlen sie, entpackt der Server die Gewichte bei jeder Verwendung – der Speichervorteil bleibt, der

Geschwindigkeitsvorteil verschwindet, und im Extremfall wird es langsamer als das unquantisierte Modell.

MERKE

Prüfen Sie vor der Auswahl eines Formats, ob der eingesetzte Inferenz-Server dafür optimierte Kernel mitbringt – und ob diese auf der vorhandenen GPU-Generation verfügbar sind. Ein Format mit hervorragenden Benchmark-Zahlen auf Hopper kann auf Ampere unbrauchbar sein. Der Startlog des Servers nennt in der Regel, welche Kernel-Implementierung gewählt wurde; dieser Eintrag gehört bei jeder Inbetriebnahme geprüft.

3.5 Qualitätsverlust methodisch prüfen

3.5.1 Warum veröffentlichte Zahlen nicht genügen

Zu jedem quantisierten Modell finden sich Angaben wie „weniger als ein Prozent Verlust“. Diese Zahlen stammen meist aus standardisierten Benchmarks – englischsprachig, faktenlastig, mit kurzen Antworten. Ihre Aussagekraft für eine konkrete Unternehmensanwendung ist gering.

Auch **Perplexity**, die am häufigsten genannte Metrik, ist ein schwaches Signal. Sie misst, wie gut ein Modell einen Referenztext vorhersagt – und korreliert nur mäßig mit der Qualität freier Antworten, mit der Zuverlässigkeit von Formatvorgaben oder mit der Fähigkeit, Werkzeugaufrufe korrekt zu erzeugen.

3.5.2 Der praktische Weg

LAB Qualitätsvergleich mit einem eigenen Prüfsatz

Ziel: Belastbar entscheiden, ob eine Quantisierung für den eigenen Anwendungsfall tragfähig ist.

Schritt 1 – Prüfsatz anlegen. Sammeln Sie 50 bis 100 echte Prompts aus dem Zielanwendungsfall. Echte, keine erfundenen. Wenn noch keine Anwendung existiert, formulieren Sie sie gemeinsam mit dem Fachbereich. Decken Sie dabei ausdrücklich ab: typische Fälle, Randfälle, lange Eingaben und – besonders wichtig – Fälle mit strengen Formatvorgaben wie JSON-Ausgaben oder Werkzeugaufrufen.

Schritt 2 – Referenz erzeugen. Lassen Sie alle Prompts gegen das unquantisierte Modell laufen, mit `temperature` auf 0. Speichern Sie die Antworten.

Schritt 3 – Kandidaten erzeugen. Dasselbe mit jeder Quantisierungsvariante, unter identischen Bedingungen.

Schritt 4 – Auswerten. Drei Ebenen, in dieser Reihenfolge:

- **Maschinell prüfbar:** Ist die JSON-Ausgabe valide? Werden Werkzeugnamen korrekt getroffen? Werden Längenvorgaben eingehalten? Dies ist der härteste und aussagekräftigste Test – Formattreue bricht bei zu aggressiver Quantisierung typischerweise zuerst.
- **Automatisiert vergleichend:** Ein stärkeres Modell bewertet paarweise, welche von zwei Antworten besser ist, ohne zu wissen, welche woher stammt.
- **Menschlich:** Der Fachbereich prüft eine Stichprobe von 20 Fällen. Aufwendig, aber die einzige Instanz, die fachliche Richtigkeit beurteilen kann.

Ergebnis: Eine Entscheidung, die sich gegenüber dem Fachbereich begründen lässt – und ein Prüfsatz, der bei jedem künftigen Modellwechsel wiederverwendet wird. Dieser Prüfsatz ist ein dauerhaftes Plattform-Artefakt und gehört versioniert ins GitOps-Repository, nicht auf einen Laptop.

MERKE

Formattreue bricht vor Sprachqualität. Ein 4-Bit-Modell, das flüssige Texte schreibt, kann bei strukturierten Ausgaben deutlich unzuverlässiger geworden sein. Wenn eine Anwendung auf JSON oder Werkzeugaufrufen aufbaut, ist das der Test, der zuerst laufen muss.

3.6 Die vollständige VRAM-Bilanz

Damit lässt sich die Rechnung aus Kapitel 2 vervollständigen:

$\text{VRAM} = \text{Gewichte} + \text{KV-Cache} + \text{Aktivierungen} + \text{Kontext} + \text{Puffer}$

Der letzte Posten liegt bei etwa 0,8 bis 1,0 GiB, die Aktivierungen bei 0,3 bis 0,8 GiB je nach Batchgröße. Zusammen also rund 1,3 GiB, die vor jeder weiteren Rechnung abzuziehen sind. Zusätzlich reserviert der Server nicht den gesamten Speicher: Der Parameter `--gpu-memory-utilization` – Voreinstellung meist 0,90 – legt fest, welcher Anteil überhaupt beansprucht wird.

3.6.1 Rechenbeispiele für 24 GiB

Nutzbar sind bei 0,90 rund 21,6 GiB, abzüglich 1,3 GiB Grundlast also etwa 20,3 GiB für Gewichte und KV-Cache zusammen.

Modell	Format	Gewichte	KV je Tok.	KV-Budget	Token gesamt
Qwen 2.5 7B	BF16	14,2 GiB	56 KiB	6,1 GiB	ca. 114 000
Qwen 2.5 7B	AWQ 4	5,6 GiB	56 KiB	14,7 GiB	ca. 275 000
Llama 3.1 8B	BF16	15,0 GiB	128 KiB	5,3 GiB	ca. 43 000
Llama 3.1 8B	AWQ 4	5,7 GiB	128 KiB	14,6 GiB	ca. 119 000
Qwen 2.5 14B	AWQ 4	9,9 GiB	192 KiB	10,4 GiB	ca. 56 000
Qwen 2.5 32B	AWQ 4	19,4 GiB	256 KiB	0,9 GiB	ca. 3 600

Die letzte Zeile ist die lehrreichste. Ein 32B-Modell passt formal auf die Karte – aber es bleiben unter 4 000 Token KV-Cache. Das reicht für **eine** Anfrage mit knapp 3 500 Token Kontext, ohne jede Gleichzeitigkeit. Als Demonstration ist das interessant, als Dienst ist es unbrauchbar.

MERKE

„Passt auf die Karte“ und „lässt sich betreiben“ sind zwei verschiedene Aussagen. Die Betriebsfähigkeit entscheidet sich am verbleibenden KV-Cache, nicht an den Gewichten. Eine brauchbare Faustregel: Die Gewichte sollten höchstens zwei Drittel des nutzbaren Speichers belegen.

3.6.2 KV-Cache-Quantisierung

Auch der KV-Cache lässt sich in niedrigerer Präzision halten. Von BF16 auf FP8 halbiert das seinen Bedarf – bei Llama 3.1 8B also von 128 auf 64 KiB je Token, was das Token-Budget verdoppelt.

Der Qualitätseinfluss gilt als gering, weil Key- und Value-Vektoren weniger empfindlich sind als Gewichte. Zwei Einschränkungen sind zu beachten: Die Unterstützung hängt von Serverversion, Modell und Aufmerksamkeitsimplementierung ab, und FP8 für den Cache verlangt – wie bei den Gewichten – entsprechende Hardware. Auf Ampere-Karten steht in der Regel eine INT8-Variante zur Verfügung.

3.7 Modellauswahl für die Plattform

Format und Modell lassen sich nicht getrennt entscheiden. Ein kleineres Modell in höherer Präzision ist häufig die bessere Wahl als ein größeres in aggressiver Quantisierung – und diese Abwägung führt der Plattformbetreiber, nicht der Fachbereich.

3.7.1 Größenklassen und wofür sie taugen

Klasse	BF16	Typische Eignung	Auf 24 GiB
0,5 bis 1,5B	1 bis 3 GiB	Klassifikation, Routing, Extraktion nach festem Schema, Entwurfsmodell für Speculative Decoding. Für freie Dialoge zu schwach.	problemlos, auch mehrere gleichzeitig
3 bis 4B	6 bis 8 GiB	Zusammenfassungen, einfache Assistenzaufgaben, strukturierte Ausgaben.	BF16 möglich
7 bis 9B	14 bis 18 GiB	Das Arbeitspferd. Dialog, RAG, Werkzeugaufrufe, Codehilfe. Für die große Mehrheit der Unternehmensanwendungen ausreichend.	BF16 knapp, 4 Bit komfortabel
12 bis 14B	24 bis 30 GiB	Spürbar besser bei mehrschrittigen Aufgaben und längeren Anweisungsketten.	nur quantisiert
30 bis 34B	60 bis 70 GiB	Anspruchsvolle Analyse, komplexe Anweisungen.	quantisiert, aber ohne nutzbaren KV-Cache
70B und mehr	140 GiB und mehr	Höchste Qualität in der offenen Klasse.	nicht betreibbar – mehrere GPUs nötig

MERKE

Für eine erste Plattform ist die 7-bis-9B-Klasse fast immer der richtige Einstieg. Sie läuft auf einer einzelnen Karte mit brauchbarem KV-Cache, deckt die Mehrheit der Anwendungsfälle ab und lässt genug Reserve, um daneben ein Einbettungsmodell zu betreiben. Der Sprung auf 14B lohnt sich erst, wenn ein konkreter Anwendungsfall nachweislich scheitert – gemessen am Prüfsatz, nicht vermutet.

3.7.2 Vokabular, Sprache und Tokenisierungseffizienz

Kapitel 2 hat gezeigt, dass deutscher Text deutlich mehr Token benötigt als englischer. Wie viel mehr, hängt am Tokenizer – und der ist eine Eigenschaft des Modells.

Modelle mit großem, mehrsprachig trainiertem Vokabular zerlegen deutschen Text effizienter. Der Unterschied ist betrieblich relevant: Zehn Prozent weniger Token je Anfrage bedeuten zehn Prozent weniger Prefill-Arbeit, zehn Prozent weniger KV-Cache und bei externen Modellen zehn Prozent geringere Kosten – dauerhaft, bei jeder Anfrage.

LAB Tokenisierungseffizienz zweier Modelle vergleichen

Ziel: Ein hartes Auswahlkriterium für deutschsprachige Anwendungen gewinnen.

Nehmen Sie einen repräsentativen deutschen Text aus dem eigenen Anwendungsfall – etwa 2 000 Wörter aus einer echten Dokumentation – und zählen Sie die Token je Modell:

```
from transformers import AutoTokenizer

text = open("beispiel_de.txt", encoding="utf-8").read()
woerter = len(text.split())

for name in ["meta-llama/Llama-3.1-8B-Instruct",
            "Qwen/Qwen2.5-7B-Instruct"]:
    tok = AutoTokenizer.from_pretrained(name)
    n = len(tok.encode(text))
    print(f"{name:45s} {n:6d} Token {n/woerter:.2f} je Wort")
```

Erwartung: Werte zwischen 1,7 und 2,3 Token je Wort. Ein Unterschied von 0,2 zwischen zwei Modellen bedeutet rund zehn Prozent Unterschied in Speicherbedarf und Kosten – über die gesamte Laufzeit der Plattform.

Wiederholen Sie den Test mit einem englischen Text derselben Länge. Die Differenz zwischen beiden Sprachen ist der Aufschlag, den Ihre Organisation für Deutsch zahlt.

Ein großes Vokabular hat allerdings einen Preis, der genau an dieser Stelle relevant wird: Die Einbettungsmatrix wächst mit ihm – und sie bleibt bei der Quantisierung unangetastet. Ein Modell mit 152 000 Vokabeleinträgen trägt entsprechend mehr unquantisierten Ballast als eines mit 32 000.

MERKE

Zwischen Tokenisierungseffizienz und Speicherbedarf besteht ein direkter Zielkonflikt. Für deutschsprachige Anwendungen gewinnt in der Regel die Effizienz: Der Aufschlag von ein bis zwei Gigabyte fällt einmal an, die eingesparten Token bei jeder Anfrage.

3.7.3 Weitere Auswahlkriterien

Kriterium	Worauf zu achten ist
Lizenz	Unterscheidet sich erheblich. Manche Modelle schränken kommerzielle Nutzung oder Nutzerzahlen ein. Vor der Auswahl klären, nicht danach.

Kriterium	Worauf zu achten ist
Werkzeugaufrufe	Nicht jedes Modell beherrscht strukturierte Funktionsaufrufe zuverlässig. Wenn die Anwendung darauf baut, ist das ein Ausschlusskriterium — und der erste Testfall im Prüfsatz.
Deklarierte Kontextlänge	Nur eine Obergrenze. Die betrieblich nutzbare Länge ergibt sich aus dem KV-Cache und liegt fast immer deutlich darunter.
Chat-Vorlage	Steht in <code>tokenizer_config.json</code> . Weicht eine eigene Implementierung davon ab, verschlechtert sich die Qualität, ohne dass ein Fehler auftritt.
Verfügbarkeit quantisierter Varianten	Für verbreitete Modelle existieren gepflegte AWQ- und GPTQ-Versionen. Für exotische Modelle muss selbst quantisiert werden.
Modellpflege	Wird das Modell weiterentwickelt? Ein aufgegebenes Modell ist eine Sackgasse, aus der ein Wechsel später teuer wird.

3.7.4 Ein Entscheidungsverfahren

Die Auswahl lässt sich als Abfolge führen. Die Reihenfolge ist wichtig, weil jeder Schritt den Möglichkeitsraum verkleinert:

1. **Anwendungsfall und Lastprofil klären.** Promptlänge, Ausgabelänge, Gleichzeitigkeit, Latenzanforderung — die vier Angaben aus Kapitel 2.
2. **Harte Ausschlusskriterien anwenden.** Lizenz, Sprache, Werkzeugaufrufe.
3. **Kleinste plausible Größenklasse wählen.** Im Zweifel eine Klasse kleiner beginnen.
4. **VRAM-Bilanz aufstellen.** Gewichte plus benötigter KV-Cache gegen die verfügbare Karte.
5. **Format wählen.** BF16, wenn es passt; sonst 4 Bit über AWQ oder GPTQ.
6. **Am Prüfsatz messen.** Formattreue zuerst.
7. **Erst wenn das scheitert:** eine Größenklasse aufwärts — und die Bilanz neu aufstellen.

ACHTUNG Die häufigste Reihenfolgeverwechslung

In der Praxis beginnt die Diskussion fast immer beim Modellnamen: „Wir hätten gern Modell X.“ Damit ist die Reihenfolge umgekehrt, und die Hardwarefrage wird zur Folge einer Auswahl, die niemand am Anwendungsfall geprüft hat. Die Rückfrage nach Prompt- und Ausgabelänge stellt die richtige Reihenfolge her — und ist zugleich die Frage, an der sich zeigt, ob ein Anwendungsfall überhaupt durchdacht ist.

3.8 Entscheidungsmatrix

Option	Geeignet, wenn	Ungeeignet, wenn
BF16 unquantisiert	Das Modell passt bequem und lässt genug KV-Cache. Keine Qualitätsdiskussion nötig, keine Kalibrierungsfrage.	Der KV-Cache wird knapp oder die Decode-Geschwindigkeit reicht nicht.

Option	Geeignet, wenn	Ungeeignet, wenn
FP8	Hardware ab Ada oder Hopper vorhanden und Qualität hat Vorrang vor maximaler Ersparnis. Nahezu verlustfrei.	Auf Ampere-Karten — dort fehlt die native Unterstützung.
AWQ 4 Bit	Der Regelfall bei begrenztem VRAM. Beste Kombination aus Qualität, Kernel-Reife und Modellverfügbarkeit.	Wenn kein passendes Modell verfügbar ist und keine Kapazität zum Selbstquantisieren besteht.
GPTQ 4 Bit	Wenn für das gewünschte Modell nur GPTQ-Varianten existieren. Qualitativ vergleichbar.	Kein systematischer Nachteil — die Wahl folgt der Verfügbarkeit.
INT8	Wenn 4 Bit im eigenen Prüfsatz messbar Qualität kostet, BF16 aber nicht passt.	Wenn 4 Bit die Prüfung besteht — dann ist INT8 unnötig teuer im Speicher.
bitsandbytes	Für schnelle Versuche ohne Vorbereitung.	Im Produktionsbetrieb — deutlich langsamer als vorbereitete Formate.

3.9 Zwei Sonderfälle, welche die Bilanz verändern

3.9.1 Mixture-of-Experts

Bei einem Mixture-of-Experts-Modell — kurz MoE — sind die Feedforward-Schichten nicht einfach vorhanden, sondern mehrfach: Statt eines Blocks existieren etwa acht sogenannte Experten. Ein Router wählt je Token aus, welche zwei davon tatsächlich rechnen.

Für die Bilanz hat das eine unangenehme Asymmetrie zur Folge:

Größe	Verhalten bei MoE
Speicherbedarf der Gewichte	Richtet sich nach der Gesamtzahl der Parameter — alle Experten müssen im VRAM liegen, auch die gerade ungenutzten
Rechenaufwand je Token	Richtet sich nach den aktiven Parametern — also nur den ausgewählten Experten
Gelesene Datenmenge je Decode-Schritt	Bei einer einzelnen Anfrage nur die aktiven Experten; mit wachsender Batchgröße nähert sie sich der Gesamtgröße an

Ein verbreitetes Beispiel dieser Bauart trägt rund 47 Milliarden Parameter insgesamt, aktiviert je Token aber nur etwa 13 Milliarden. In BF16 belegt es damit über 90 GiB Speicher — bei der Rechen- und Bandbreitencharakteristik eines 13B-Modells.

MERKE

MoE liefert die Qualität eines großen Modells bei der Geschwindigkeit eines kleinen — zum Speicherpreis des großen. Für Umgebungen mit reichlich VRAM ist das ein ausgezeichnetes Geschäft. Für eine einzelne 24-GiB-Karte ist es genau die falsche Form: Der knappe Posten ist hier der Speicher, nicht die Rechenleistung.

Ein zweiter Punkt wird häufig übersehen und ist beim Dimensionieren entscheidend. Der Bandbreitenvorteil gilt für eine **einzelne** Anfrage. Sobald mehrere Anfragen gleichzeitig im Batch stehen, wählen ihre Token unterschiedliche Experten – und die GPU muss entsprechend mehr Experten lesen. Bei hoher Gleichzeitigkeit nähert sich die gelesene Datenmenge der Gesamtgröße des Modells an, und der Vorteil schmilzt.

ACHTUNG Benchmark-Zahlen zu MoE-Modellen kritisch lesen

Geschwindigkeitsangaben zu MoE-Modellen stammen häufig aus Messungen mit einer einzigen Anfrage. Genau dort ist der Vorteil am größten. Unter realistischer Serverlast mit dreißig gleichzeitigen Anfragen fällt er deutlich geringer aus. Wer MoE-Modelle bewertet, sollte grundsätzlich unter der Gleichzeitigkeit messen, die im Betrieb erwartet wird.

Neuere MoE-Modelle mit moderater Gesamtgröße und sehr wenigen aktiven Parametern verschieben diese Rechnung. Ein Modell mit rund 30 Milliarden Gesamt- und wenigen Milliarden aktiven Parametern passt in 4-Bit-Quantisierung durchaus auf eine 24-GiB-Karte – allerdings mit demselben Vorbehalt wie in Abschnitt 3.7: Was an KV-Cache übrig bleibt, entscheidet über die Betreibbarkeit. Die Prüfung erfolgt mit derselben Bilanz wie bei jedem anderen Modell.

3.9.2 Entwurfsmodelle für Speculative Decoding

Speculative Decoding beschleunigt den Decode, indem ein kleines, schnelles Entwurfsmodell mehrere Token vorschlägt, die das große Modell anschließend in einem einzigen Durchlauf bestätigt oder verwirft. Kapitel 7 behandelt das Verfahren im Detail; hier interessiert nur die Auswirkung auf die Speicherbilanz.

Das Entwurfsmodell belegt zusätzlichen VRAM – typischerweise 1 bis 2 GiB – und dieser Speicher fehlt dem KV-Cache. Für eine 24-GiB-Karte mit einem 4-Bit-Modell von rund 6 GiB ist das gut verkraftbar; für eine Konfiguration, die ohnehin knapp ist, kippt es die Rechnung.

Posten	Ohne Entwurfsmodell	Mit Entwurfsmodell
Hauptmodell, 4 Bit	5,7 GiB	5,7 GiB
Entwurfsmodell	–	1,2 GiB
KV-Cache Hauptmodell	14,6 GiB	13,2 GiB
Token-Budget	ca. 119 000	ca. 108 000
Decode bei einer Anfrage	Referenz	je nach Trefferquote deutlich höher

Der Gewinn hängt daran, wie oft die Vorschläge des Entwurfsmodells angenommen werden. Bei vorhersagbaren Texten – Code, strukturierten Ausgaben, Wiederholungen aus dem Prompt – ist die Trefferquote hoch und der Gewinn erheblich. Bei freier, kreativer Sprache fällt er gering aus, während der Speicher trotzdem belegt bleibt.

3.9.3 Warum Quantisierung nicht linear beschleunigt

Ein letzter Punkt zur Erwartungshaltung. Nach der Bandbreitenformel aus Kapitel 2 müsste ein Modell, das von 15 auf 5,7 GiB schrumpft, im Decode etwa 2,6-mal so schnell werden. Gemessen werden meist Faktoren zwischen 1,8 und 2,3.

Die Differenz hat drei Ursachen. Erstens müssen 4-Bit-Gewichte vor der Rechnung entpackt werden, was zusätzliche Operationen kostet. Zweitens bleiben Einbettung und Ausgabekopf unquantisiert und werden weiterhin in voller Breite gelesen. Drittens wird neben den Gewichten auch der KV-Cache gelesen, dessen Größe sich nicht verändert hat – und dessen Anteil an der Gesamtlesemenge mit der Kontextlänge wächst.

MERKE

Die Bandbreitenformel ist eine **Obergrenze**, keine Vorhersage. Sie taugt hervorragend, um Größenordnungen abzuschätzen und Messwerte auf Plausibilität zu prüfen. Wer sie als exakte Zusage behandelt, wird enttäuscht – und wer 80 Prozent des rechnerischen Werts erreicht, hat ein gut konfiguriertes System.

3.10 Rechenblatt: VRAM-Bilanz aufstellen

Die folgende Abfolge führt von einer Kartengröße zu einer belastbaren Aussage. Sie ist so angelegt, dass sie sich im Gespräch auf einem Blatt Papier durchführen lässt.

Nr.	Schritt	Beispiel: 24 GiB, Llama 3.1 8B, AWQ
1	Gesamtpeicher der Karte	24,0 GiB
2	mal <code>--gpu-memory-utilization</code>	$\times 0,90 = 21,6 \text{ GiB}$
3	minus Kontext und Puffer	$- 1,0 \text{ GiB} = 20,6 \text{ GiB}$
4	minus Aktivierungen	$- 0,3 \text{ GiB} = 20,3 \text{ GiB}$
5	minus Gewichte (Repository-Größe)	$- 5,7 \text{ GiB} = 14,6 \text{ GiB}$
6	minus Entwurfsmodell, falls vorhanden	$- 0,0 \text{ GiB} = 14,6 \text{ GiB}$
7	ergibt KV-Cache	14,6 GiB
8	geteilt durch Bytes je Token	$\div 128 \text{ KiB} = \text{ca. } 119\,000 \text{ Token}$
9	geteilt durch geplante Kontextlänge	$\div 4\,096 = \text{ca. } 29 \text{ Sequenzen}$
10	Plausibilitätsprüfung nach Little	$\text{Rate} \times \text{Verweildauer} \leq 29?$

Schritt 10 ist der, der am häufigsten fehlt. Eine Konfiguration, die 29 gleichzeitige Sequenzen erlaubt, ist nur dann richtig dimensioniert, wenn die erwartete Last diese Zahl auch ausschöpft – und nicht überschreitet. Beides ist ein Problem: Deutlich weniger bedeutet verschenkten Speicher, deutlich mehr bedeutet wachsende Warteschlangen.

3.11 Lab: ein Modell in drei Formaten

LAB Speicher, Geschwindigkeit und Qualität gegenüberstellen

Ziel: Die Aussagen dieses Kapitels an der eigenen Karte belegen und eine begründete Formatentscheidung treffen.

Schritt 1 – Ausgangsmessung in BF16.

Dieses Rechenblatt beantwortet die meisten Dimensionierungsfragen in einem Vorstellungsgespräch – und in einem Kundengespräch. Es lohnt sich, es auswendig zu können.

```
vllm serve Qwen/Qwen2.5-7B-Instruct \
  --dtype bfloat16 \
  --max-model-len 4096 \
  --gpu-memory-utilization 0.90
```

Notieren Sie aus dem Startlog die Modellgröße und die Größe des KV-Caches. Messen Sie wie in Kapitel 2 die Decode-Rate bei einer einzelnen Anfrage. **Erwartung:** Gewichte um 14 GiB, KV-Budget deutlich über 100 000 Token, Decode in der Größenordnung von 60 bis 70 Token je Sekunde.

Schritt 2 – dasselbe Modell als AWQ.

```
vllm serve Qwen/Qwen2.5-7B-Instruct-AWQ \
  --max-model-len 4096 \
  --gpu-memory-utilization 0.90
```

Erwartung: Gewichte unter 6 GiB, KV-Budget mehr als verdoppelt, Decode-Rate ungefähr doppelt so hoch. Prüfen Sie im Startlog, welche Kernel-Implementierung gewählt wurde – das ist der Unterschied zwischen „kleiner“ und „schneller“.

Schritt 3 – Speicher tatsächlich nachrechnen. Während der Server läuft:

```
nvidia-smi --query-gpu=memory.used,memory.total --format=csv
```

Vergleichen Sie mit der Bilanz aus Abschnitt 3.7. Die Abweichung sollte unter einem Gigabyte liegen. Ist sie größer, fehlt in Ihrer Rechnung ein Posten – meist die Aktivierungen bei großer Batchgröße.

Schritt 4 – Formattreue prüfen. Der wichtigste Test. Senden Sie an beide Varianten dieselbe Aufgabe mit strenger Formatvorgabe:

```
read -r -d '' FRAGE <<'EOF'
Gib genau dieses JSON zurueck, ohne weiteren Text:
{"stadt": "Berlin", "einwohner": 3700000}
EOF

jq -n --arg m "<Modellname>" --arg c "$FRAGE" \
  '{model:$m, temperature:0, max_tokens:100,
   messages:[{role:"user", content:$c}]}' \
| curl -s http://localhost:8000/v1/chat/completions \
  -H 'Content-Type: application/json' --data @-
```

Wiederholen Sie das mit 20 verschiedenen Strukturvorgaben und zählen Sie die validen Ausgaben je Variante. **Erwartung:** Bei einem 7B-Modell in 4 Bit sollte die Formattreue praktisch unverändert bleiben. Sinkt sie merklich, ist das ein Warnsignal für den Produktionseinsatz.

Schritt 5 – Grenzfall. Starten Sie ein 32B-Modell in 4 Bit ohne gesetzte Kontextgrenze und beobachten Sie den Abbruch. Setzen Sie danach --max-model-len 2048 und beobachten Sie, wie klein das KV-Budget bleibt. Das ist die Zeile aus der Tabelle in Abschnitt 3.7, an der eigenen Karte erlebt.

Ergebnis: Eine Messreihe, die Speicher, Geschwindigkeit und Formattreue über drei Varianten vergleicht – die Grundlage für die Formatentscheidung und ein gutes Vorzeigergebnis in Bewerbungsgesprächen.

3.12 Betrieb: Herkunft und Bereitstellung von Modellen

3.12.1 Die Vertrauensfrage

Quantisierte Modelle stammen überwiegend nicht von den ursprünglichen Herausgebern, sondern von Einzelpersonen und Gruppen aus der Community. Sie sind damit Artefakte unbekannter Herkunft, die auf Produktionshardware geladen werden sollen.

Für eine Unternehmensplattform folgt daraus ein Mindestvorgehen:

1. **Quelle festhalten.** Repository, Version und Prüfsumme werden dokumentiert, nicht nur der Modellname.
2. **Format erzwingen.** Ausschließlich safetensors.
3. **Spiegeln.** Modelle werden in den eigenen Objektspeicher oder die eigene Registry übernommen. Kein Produktionsknoten lädt zur Laufzeit aus dem Internet — das ist zugleich eine Verfügbarkeits- und eine Integritätsfrage.
4. **Prüfen.** Der Prüfsatz aus Abschnitt 3.6 läuft vor der Freigabe.
5. **Lizenz klären.** Modelllizenzen unterscheiden sich erheblich und enthalten teils Nutzungsbeschränkungen, die für kommerzielle Anwendung relevant sind.

3.12.2 Ladezeit – der unterschätzte Betriebsfaktor

Ein Modell muss vor der ersten Anfrage vollständig im GPU-Speicher liegen. Wie lange das dauert, entscheidet über Startzeiten, Rollout-Dauer und darüber, ob Scale-to-Zero überhaupt in Frage kommt.

Bezugsquelle	Rate	15 GiB	5,7 GiB
Öffentliches Repository über 1 Gbit/s	ca. 125 MB/s	ca. 2 min	ca. 46 s
Objektspeicher im Rechenzentrum, 10 Gbit/s	ca. 1,2 GB/s	ca. 13 s	ca. 5 s
Lokales NVMe-Volume	ca. 3 GB/s	ca. 5 s	ca. 2 s
Übertragung in den GPU-Speicher	ca. 12 GB/s	ca. 1,3 s	ca. 0,5 s

Das Spiegeln ist auch ein Betriebsargument: Ein Modell, das beim Start aus dem Internet geladen wird, macht jede Skalierung von der Verfügbarkeit eines fremden Dienstes abhängig — und von dessen Übertragungsrate.

Die Zahlen zeigen deutlich, wo der Engpass liegt: nicht bei der GPU, sondern beim Weg dorthin. Zwischen einem Modell aus dem Internet und einem aus dem lokalen Cache liegen zwei Größenordnungen.

MERKE

Daraus folgen drei Betriebsregeln. Erstens: Modelle liegen im eigenen Objektspeicher oder auf einem persistenten Volume, nie ausschließlich im Internet. Zweitens: Der Modell-Cache eines GPU-Knotens ist persistent, sonst lädt jeder Neustart erneut. Drittens: Ein quantisiertes Modell startet nicht nur speicherschonender, sondern auch spürbar schneller — ein Argument, das in der Formatdiskussion regelmäßig fehlt.

Kapitel 8 behandelt die Umsetzung im Deployment, Kapitel 10 die Folgen für Autoscaling und Scale-to-Zero.

3.12.3 Selbst quantisieren

Wenn kein passendes Modell verfügbar ist oder die Kalibrierung an eigene Daten angepasst werden soll, ist die eigene Quantisierung ein überschaubarer Vorgang:

Kalibrierungsdaten zusammenstellen, Verfahren anwenden, Ergebnis prüfen, ins eigene Repository legen.

Der Ressourcenbedarf ist moderat — für ein 7B-Modell in der Größenordnung weniger GPU-Stunden — aber er benötigt genug Speicher, um das **unquantisierte** Modell zu laden. Für Modelle, die in voller Präzision nicht auf die vorhandene Karte passen, ist das Vorgehen entsprechend nicht auf der Zielhardware durchführbar.

3.13 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Quantisiertes Modell ist langsamer als erwartet	Kein optimierter Kernel für Format und GPU-Generation verfügbar	Startlog auf die gewählte Kernel-Implementierung prüfen	Anderes Format wählen, das auf dieser Generation unterstützt wird
Modell belegt mehr Speicher als berechnet	Einbettung und Ausgabekopf sind nicht quantisiert	<code>model.safetensors.index</code> auf unquantisierte Tensoren prüfen	Modell an tatsächlichen Repository-Größe rechnen, nicht mit Parameterzahl mal Bits
NaN oder unsinnige Ausgaben nach Formatwechsel	BF16-Modell in FP16 betrieben, Wertebereich überschritten	<code>torch_dtype</code> in der <code>config.json</code> gegen die Startparameter prüfen	<code>--dtype bfloat16</code> setzen
Ausgabe ist flüssig, aber JSON ist ungültig	Quantisierung zu aggressiv für strukturierte Ausgaben	Formattreue über den Prüfsatz messen, nicht nach Gefühl beurteilen	Auf 8 Bit wechseln oder erzwungenes Ausgabeschema einsetzen
Deutsche Antworten schlechter als englische	Kalibrierung erfolgte mit englischsprachigen Daten	Prüfsatz getrennt nach Sprache auswerten	Mit eigenen deutschsprachigen Daten neu quantisieren
Start dauert sehr lange	Modell wird bei jedem Start neu heruntergeladen	Cache-Verzeichnis und dessen Persistenz prüfen	Modelle spiegeln und über ein persistentes Volume bereitstellen — Kapitel 8 und 16

3.14 Interviewfragen

INTERVIEWFRAGE

Was bedeutet Quantisierung, und welche Formate kennen Sie?

Gut ist die Aufzählung FP32, FP16, BF16, FP8, INT8, INT4 mit Speicherangabe.

Senior ist der Unterschied zwischen FP16 und BF16 — gleicher Speicher, anderer Wertebereich — und die Feststellung, dass FP8 eine Hardwarevoraussetzung ab Ada oder Hopper hat. Dazu die Unterscheidung zwischen weight-only und weight-and-activation und die Begründung, warum weight-only für Inferenz meist genügt: weil der Decode bandbreiten- und nicht rechenbegrenzt ist.

INTERVIEWFRAGE

Wie viel Speicher spart ein 4-Bit-Modell gegenüber BF16?

Schwach ist „ein Viertel“.

Gut ist der Hinweis auf den Zusatzaufwand für Skalierungsfaktoren.

Senior ist die vollständige Erklärung: Gruppenweise Skalierung ergibt etwa 4,25 statt 4 Bit, und Einbettungsschicht sowie Ausgabekopf bleiben unquantisiert. Bei modernen Modellen mit über 128 000 Vokabeleinträgen sind das über eine Milliarde Parameter in voller Präzision. Realistisch bleiben 35 bis 40 Prozent der Originalgröße – und die verlässliche Zahl ist die Repository-Größe.

INTERVIEWFRAGE

Wie stellen Sie fest, ob eine Quantisierung für Ihren Anwendungsfall tragbar ist?

Schwach ist der Verweis auf veröffentlichte Benchmark-Werte oder Perplexity.

Senior ist ein Prüfsatz aus echten Prompts des Anwendungsfalls, gefahren gegen beide Varianten bei `temperature 0`, ausgewertet auf drei Ebenen – maschinell prüfbare Formattreue zuerst, dann vergleichende Bewertung, dann eine menschliche Stichprobe. Ergänzt um zwei Punkte, die Erfahrung zeigen: Formattreue bricht vor Sprachqualität, und öffentliche Modelle sind meist englischsprachig kalibriert, was für deutschsprachige Anwendungen ein eigenes Risiko darstellt.

INTERVIEWFRAGE

Ein 32B-Modell passt formal auf eine 24-GB-Karte. Würden Sie es dort betreiben?

Gut ist „nein, wegen des KV-Caches“.

Senior ist die Rechnung: rund 19,4 GiB für die Gewichte lassen bei 90 Prozent Speichernutzung unter einem Gigabyte für den KV-Cache – etwa 3 600 Token bei 256 KiB je Token. Das genügt für eine einzige Anfrage ohne Gleichzeitigkeit. Als Faustregel: Die Gewichte sollten höchstens zwei Drittel des nutzbaren Speichers belegen. Die Alternative wäre ein kleineres Modell oder zwei Karten mit Tensor Parallelism – wobei das kleinere Modell in fast allen Fällen die wirtschaftlichere Antwort ist.

INTERVIEWFRAGE

Warum laden Sie Modelle nicht direkt von Hugging Face auf den Produktionsknoten?

Gut sind Verfügbarkeit und Startzeit.

Senior ergänzt die Integritätsfrage: Quantisierte Modelle stammen meist von Dritten, und Pickle-basierte Formate können beim Laden Code ausführen. Daraus folgt ein Mindestvorgehen aus Spiegeln in den eigenen Objektspeicher, Erzwingen von `safetensors`, Festhalten von Version und Prüfsumme, Freigabe über einen Prüfsatz und Klärung der Lizenz. Wer zusätzlich erwähnt, dass die Modellversion damit zu einem versionierten Artefakt im GitOps-Repository wird, verbindet das Thema mit der Delivery-Kette.

3.15 Referenztablette gängiger Modelle

Die folgenden Werte stammen aus den `config.json`-Dateien der jeweiligen Modelle. Sie ersparen das Nachschlagen im Alltag – ersetzen es aber nicht bei einem Modell, das tatsächlich in Betrieb gehen soll. Hersteller ändern Konfigurationen zwischen Versionen.

Modell	L	H_{kv}	D	Vokab.	BF16	4 Bit	KV/Tok.
Qwen 2.5 0,5B	24	2	64	152 k	0,9 GiB	0,5 GiB	12 KiB
Qwen 2.5 1,5B	28	2	128	152 k	2,9 GiB	1,3 GiB	28 KiB
Qwen 2.5 3B	36	2	128	152 k	5,8 GiB	2,4 GiB	36 KiB
Qwen 2.5 7B	28	4	128	152 k	14,2 GiB	5,5 GiB	56 KiB
Qwen 2.5 14B	48	8	128	152 k	27,4 GiB	9,9 GiB	192 KiB
Qwen 2.5 32B	64	8	128	152 k	60,5 GiB	19,3 GiB	256 KiB
Llama 3.1 8B	32	8	128	128 k	15,0 GiB	5,7 GiB	128 KiB
Llama 3.1 70B	80	8	128	128 k	131,5 GiB	40,3 GiB	320 KiB

Drei Beobachtungen lohnen den Blick.

Der KV-Bedarf springt zwischen 7B und 14B um mehr als das Dreifache, obwohl die Parameterzahl sich nur verdoppelt. Ursache ist die Zahl der Key-Value-Köpfe, die von 4 auf 8 steigt, bei gleichzeitig mehr Schichten. Wer von einem 7B- auf ein 14B-Modell wechselt, verliert damit weit mehr Kontextkapazität, als die Gewichtsdiﬀerenz vermuten lässt.

Kleine Modelle quantisieren schlechter – im Verhältnis. Bei Qwen 2.5 0,5B liegt die 4-Bit-Variante bei rund 55 Prozent der BF16-Größe, bei 32B nur noch bei 32 Prozent. Der Grund ist die Einbettungsschicht: Bei einem Vokabular von 152 000 Einträgen ist sie absolut gleich groß, macht bei kleinen Modellen aber den Großteil aus.

Ab 14B ist BF16 auf einer 24-GiB-Karte nicht mehr möglich. Die Formatfrage stellt sich dort nicht mehr als Optimierung, sondern als Voraussetzung.

3.15.1 Die Größe selbst abschätzen

Für Modelle, die nicht in der Tabelle stehen, genügt eine zweiteilige Rechnung. Der unquantisierte Anteil sind Einbettung und Ausgabekopf:

$$P_{\text{fix}} = \text{Vokabulargröße} \cdot \text{Modelldimension} \cdot k$$

mit $k = 2$, wenn Einbettung und Ausgabekopf getrennt vorliegen, und $k = 1$, wenn sie sich die Gewichte teilen – erkennbar am Eintrag `tie_word_embeddings` in der `config.json`. Damit gilt:

$$\text{Größe}_{4 \text{ Bit}} \approx P_{\text{fix}} \cdot 2 \text{ Byte} + (P_{\text{gesamt}} - P_{\text{fix}}) \cdot \frac{4,25}{8} \text{ Byte}$$

Für Llama 3.1 8B ergibt das mit einem Vokabular von 128 256, einer Dimension von 4 096 und getrennten Gewichten rund 1,05 Milliarden fixe Parameter, also etwa 1,96 GiB, plus 6,98 Milliarden quantisierte Parameter mit etwa 3,71 GiB – zusammen 5,67 GiB. Die tatsächlichen Repositories liegen bei rund 5,7 GiB.

MERKE

Diese Abschätzung ist gut genug für die Beschaffungsplanung, aber sie ersetzt nicht den Blick auf die tatsächliche Repository-Größe, sobald ein konkretes Modell feststeht. Abweichungen entstehen durch unterschiedliche Gruppengrößen, zusätzlich ausgenommene Schichten und Formatvarianten.

3.16 Zusammenfassung

- Ein Modell ist ein Verzeichnis. `config.json` liefert die Werte für die KV-Cache-Formel, die Summe der Gewichtsdateien die Untergrenze des VRAM-Bedarfs.
- `safetensors` ist gegenüber Pickle-Formaten nicht nur schneller, sondern eine Sicherheitsanforderung: Pickle kann beim Laden Code ausführen.
- BF16 ist der Standard. Der Unterschied zu FP16 liegt nicht im Speicher, sondern im Wertebereich.
- FP8 setzt Hardware ab Ada oder Hopper voraus. Auf Ampere-Karten stehen AWQ, GPTQ und INT8 zur Verfügung.
- 4-Bit-Quantisierung spart keine drei Viertel, sondern etwa 60 Prozent — wegen gruppenweiser Skalierung und weil Einbettung und Ausgabekopf unquantisiert bleiben.
- Weight-only-Quantisierung genügt für Inferenz, weil der Decode bandbreitenbegrenzt ist. Sie wirkt doppelt: mehr KV-Cache und höhere Decode-Geschwindigkeit.
- Ein quantisiertes Modell ist nur dann schneller, wenn optimierte Kernel für Format und GPU-Generation vorliegen. Der Startlog gibt darüber Auskunft.
- Qualität wird am eigenen Prüfsatz gemessen, nicht an fremden Benchmarks. Formattreue bricht vor Sprachqualität, und englische Kalibrierung ist für deutschsprachige Anwendungen ein eigenes Risiko.
- Die Gewichte sollten höchstens zwei Drittel des nutzbaren Speichers belegen. Was darüber hinausgeht, ist demonstrierbar, aber nicht betreibbar.

Quellen und Weiterlesen

- Frantar et al.: *GPTQ — Accurate Post-Training Quantization for Generative Pre-trained Transformers*. Grundlage des Verfahrens.
- Lin et al.: *AWQ — Activation-aware Weight Quantization for LLM Compression and Acceleration*. Grundlage des empfohlenen Regelverfahrens.
- Hugging Face: *safetensors* — Formatspezifikation und Begründung des Sicherheitsmodells.
- vLLM: *Documentation — Quantization*. Welche Formate und Kernel die eingesetzte Version auf welcher GPU-Generation unterstützt. Vor jeder Formatentscheidung gegen die konkrete Version prüfen.
- NVIDIA: *CUDA C++ Programming Guide — Compute Capabilities*. Verbindliche Referenz dafür, welche Generation welche Datentypen nativ beherrscht.

TEIL II

GPU-Infrastruktur

Eine GPU ist erst dann eine Plattform-Ressource, wenn der Cluster sie kennt, planen kann und mehreren Teams zuteilen darf. Dieser Teil führt von der physischen Karte über den Treiber-Stack bis zum planbaren Scheduling unter Kubernetes.

GPU-Hardware und der NVIDIA-Software-Stack

ZIEL	Die GPU als Betriebsmittel verstehen: welche Kennzahlen bei der Auswahl zählen, wie der Software-Stack vom Kernel bis zum Container aufgebaut ist und wie eine GPU in einer virtualisierten Umgebung überhaupt nutzbar wird.
SETZT VORAUS	Kapitel 2 und 3. Linux-Administration, Kernelmodule, Paketverwaltung. Grundverständnis von Virtualisierung.
DANACH KANNST DU	Eine GPU begründet auswählen, den vollständigen Treiber-Stack aufbauen und verifizieren, GPU-Passthrough unter Proxmox einrichten und die typischen Fehlerbilder der Versionskompatibilität diagnostizieren.

GESCHRIEBEN GEGEN

Proxmox VE 8.x · NVIDIA-Treiber 550 und neuer · Container Toolkit 1.16.x · Stand September 2026

Bis hierher war die GPU eine abstrakte Größe mit zwei Eigenschaften: Speicher und Bandbreite. Dieses Kapitel öffnet die Kiste. Es behandelt, was in einer GPU tatsächlich zählt, wie die Softwarekette vom Kernelmodul bis zum Container aussieht — und wie eine Karte, die in einem Server steckt, in einer virtuellen Maschine ankommt.

Der letzte Punkt ist im Referenz-Lab die Voraussetzung für alles Weitere und in Unternehmensumgebungen mit VMware, Nutanix oder Proxmox ein Dauerbrenner.

4.1 Was an einer GPU zählt

4.1.1 Die Bauteile

Bauteil	Funktion	Betriebliche Relevanz
Streaming Multiprocessors	Die Recheneinheiten. Ihre Zahl bestimmt die Rohleistung.	Relevant für Prefill, kaum für Decode
Tensor Cores	Spezialisierte Einheiten für Matrixmultiplikation in reduzierter Präzision. Bestimmen, welche Datentypen nativ unterstützt werden.	Entscheidet über FP8-Fähigkeit — siehe Kapitel 3
VRAM	Der Speicher, in dem Gewichte und KV-Cache liegen.	Die wichtigste Einzelgröße. Bestimmt, welche Modelle überhaupt laufen

Bauteil	Funktion	Betriebliche Relevanz
Speicheranbindung	GDDR bei Consumer- und Workstation-Karten, HBM bei Rechenzentrumsmodellen.	Bestimmt die Bandbreite und damit die Decode-Geschwindigkeit
PCIe-Anbindung	Verbindung zum Host. Generation und Lane-Zahl bestimmen den Durchsatz.	Relevant beim Modell-Laden und bei Multi-GPU-Kommunikation
NVLink	Direktverbindung zwischen GPUs, deutlich schneller als PCIe.	Entscheidend für Tensor Parallelism — Kapitel 9

4.1.2 Die zwei Zahlen, auf die es ankommt

Aus Kapitel 2 und 3 folgt eine erfreulich einfache Auswahlregel. Für Inferenz zählen zwei Größen, und beide stehen selten im Vordergrund der Herstellerkommunikation:

MERKE

VRAM-Kapazität entscheidet, welche Modelle mit welcher Kontextlänge betreibbar sind. **Speicherbandbreite** entscheidet, wie schnell sie antworten.

Rechenleistung in TFLOPS ist die dritte Größe — sie bestimmt den Prefill und ist bei gemischter Last relevant, aber sie ist selten der Engpass. Wer eine GPU für Inferenz auswählt und zuerst auf TFLOPS schaut, optimiert die falsche Achse.

Die folgende Übersicht ordnet gängige Karten ein. Die Werte sind gerundet und dienen dem Größenvergleich — verbindliche Angaben stehen in den Datenblättern des Herstellers.

Karte	VRAM	Speicher	Bandbreite	Compute	Einordnung
RTX 3090	24 GB	GDDR6X	ca. 940 GB/s	8.6	Consumer, kein FP8, kein MIG
RTX 4090	24 GB	GDDR6X	ca. 1 000 GB/s	8.9	Consumer, FP8, kein MIG
L4	24 GB	GDDR6	ca. 300 GB/s	8.9	Sparsam, geringe Bandbreite
L40S	48 GB	GDDR6	ca. 860 GB/s	8.9	Rechenzentrum, kein MIG
A100 80GB	80 GB	HBM2e	ca. 2 000 GB/s	8.0	MIG, NVLink, kein FP8
H100 SXM	80 GB	HBM3	ca. 3 350 GB/s	9.0	MIG, NVLink, FP8

Zwei Beobachtungen sind für die Praxis wichtig. Erstens: Die L4 hat denselben VRAM wie eine RTX 4090, aber weniger als ein Drittel der Bandbreite. Für Decodlastige Workloads ist sie damit deutlich langsamer, obwohl dieselben Modelle darauf passen — ein Unterschied, den eine reine VRAM-Betrachtung nicht sichtbar macht. Zweitens: Der Sprung von GDDR auf HBM bringt den Faktor zwei bis drei bei der Bandbreite. Das ist der eigentliche technische Grund für den Preisunterschied zwischen Consumer- und Rechenzentrumskarten.

Rechnen Sie die Tabelle einmal mit der Bandbreitenformel aus Kapitel 2 durch: Ein 8B-Modell in BF16 liefert auf einer L4 rund 19 Token je Sekunde, auf einer H100 über

200. Dieselben Modelle, völlig verschiedene Anwendungsfälle.

4.2 Consumer- oder Rechenzentrumskarte

Die Frage stellt sich in jedem Homelab und in vielen kleineren Unternehmensumgebungen. Sie ist nicht nur technisch, sondern auch rechtlich und betrieblich.

Aspekt	Consumer (RTX)	Rechenzentrum (L40S, A100, H100)
Preis je GB VRAM	deutlich günstiger	deutlich teurer
ECC-Speicher	nein	ja — korrigiert Bitfehler
MIG	nein	ab A100 verfügbar
NVLink	entfällt bei aktuellen Generationen	vorhanden
Kühlung	aktiv, für Gehäuse mit Luftstrom	meist passiv, benötigt Serverchassis
Formfaktor	zwei bis vier Slots	zwei Slots oder SXM-Modul
Leistungsaufnahme	350 bis 450 W	300 bis 700 W
Dauerlastbetrieb	nicht dafür ausgelegt, drosselt	dafür ausgelegt
vGPU-Unterstützung	nein	ja, lizenzpflichtig
Lizenzlage im Rechenzentrum	einschränkend — siehe unten	unproblematisch

ACHTUNG Die Lizenzfrage bei Consumer-Karten

Die Endnutzer-Lizenzvereinbarung des NVIDIA-Treibers enthält seit Jahren Einschränkungen für den Einsatz von GeForce-Karten in Rechenzentren. Die Formulierungen haben sich mehrfach geändert und sind in Randbereichen auslegungsbedürftig.

Für ein Homelab und für Entwicklungsumgebungen ist das unkritisch. Für eine produktive Unternehmensplattform gehört die Frage vor der Beschaffung geklärt — nicht vom Plattformteam allein, sondern mit der Rechtsabteilung und gegen den zum Beschaffungszeitpunkt gültigen Lizenztext. Dieses Buch gibt dazu bewusst keine Rechtsauskunft.

Für das Referenz-Lab dieses Buches ist die Consumer-Karte die richtige Wahl: Sie liefert 24 GB VRAM zu einem Bruchteil des Preises, und die fehlenden Eigenschaften — ECC, MIG, NVLink — lassen sich als Konzept behandeln, ohne dass die Labs darunter leiden. Für Kundenumgebungen ist die Rechnung fast immer umgekehrt.

4.3 Topologie: PCIe, NVLink und NUMA

4.3.1 Bandbreiten im Vergleich

Verbindung	Bandbreite je Richtung	Rolle
PCIe 3.0 x16	ca. 16 GB/s	Ältere Systeme
PCIe 4.0 x16	ca. 32 GB/s	Verbreiteter Standard
PCIe 5.0 x16	ca. 63 GB/s	Aktuelle Server
NVLink (A100)	ca. 600 GB/s gesamt	GPU-zu-GPU
NVLink (H100)	ca. 900 GB/s gesamt	GPU-zu-GPU
Interner VRAM-Zugriff	900 bis 3 350 GB/s	GPU-intern

Der Unterschied zwischen PCIe und NVLink beträgt eine Größenordnung, der Unterschied zwischen PCIe und internem Speicherzugriff fast zwei. Daraus folgen zwei praktische Regeln.

Erstens: Alles, was über PCIe muss, ist teuer. Das betrifft das Laden von Modellen – Kapitel 3 hat vorgerechnet, dass 15 GiB über PCIe 4.0 rund eine Sekunde brauchen, was gegenüber dem Netzwerktransport vernachlässigbar ist – und vor allem sogenanntes CPU-Offloading, bei dem Teile des Modells im Hauptspeicher liegen. Bei 32 GB/s statt 1 000 GB/s ist der Decode um den Faktor 30 langsamer. CPU-Offloading ist deshalb keine Skalierungsstrategie, sondern eine Notlösung.

Zweitens: Bei Tensor Parallelism kommunizieren die GPUs nach jeder Schicht miteinander. Ohne NVLink läuft diese Kommunikation über PCIe, und die Skalierungseffizienz sinkt spürbar. Kapitel 9 behandelt das quantitativ.

4.3.2 Die Topologie ermitteln

```
nvidia-smi topo -m
```

Die Ausgabe ist eine Matrix, welche die Verbindungsart zwischen je zwei Geräten angibt. Die wichtigsten Kürzel:


Kürzel	Bedeutung
NV#	NVLink mit der angegebenen Zahl an Verbindungen – der beste Fall
PIX	Über einen einzelnen PCIe-Switch – gut
PXB	Über mehrere PCIe-Switches – brauchbar
PHB	Über den Host-Bridge-Controller – langsamer
NODE	Innerhalb desselben NUMA-Knotens, aber über die CPU
SYS	Über die Verbindung zwischen zwei CPU-Sockeln – der schlechteste Fall

MERKE

SYS zwischen zwei GPUs, die gemeinsam ein Modell tragen sollen, ist ein Konfigurationsfehler. Die Kommunikation läuft dann über die Verbindung zwischen den CPU-Sockeln – ein Pfad, der für diesen Zweck nie ausgelegt war. GPUs, die zusammenarbeiten sollen, gehören an denselben Sockel und möglichst an denselben PCIe-Switch. Bei gemieteter Hardware ist `nvidia-smi topo -m` deshalb einer der ersten Befehle nach der Bereitstellung.

4.4 Der Software-Stack

4.4.1 Die Kette



Vom Kernelmodul zum Container – jede Schicht hat eigene Versionsanforderungen.

Die entscheidende Beobachtung: **Der Treiber liegt auf dem Host, die CUDA-Laufzeit im Container.** Das ist der Grund, warum ein GPU-Container keine Treiberinstallation enthält – und warum er trotzdem nicht auf jedem Host läuft.

4.4.2 Die Kompatibilitätsregel

MERKE Die eine Regel, die man kennen muss

Die CUDA-Laufzeit im Container darf **nicht neuer** sein, als der Host-Treiber unterstützt. Umgekehrt ist unproblematisch: Ein alter Container läuft auf einem neuen Treiber.

Innerhalb einer CUDA-Hauptversion – etwa 12.x – gilt zusätzlich Minor-Version-Kompatibilität: Ein Container mit CUDA 12.4 läuft auf jedem Treiber, der CUDA 12.0 unterstützt. Zwischen Hauptversionen gilt das nicht.

Daraus folgt eine Betriebsregel, die viele Probleme vermeidet: **Der Host-Treiber wird großzügig neu gehalten, die Container-Images werden konservativ gewählt.** Ein zu alter Treiber blockiert alle neueren Images gleichzeitig; ein zu altes Image betrifft nur eine Anwendung.

ACHTUNG Das häufigste Fehlerbild

Die

Meldung `CUDA driver version is insufficient for CUDA runtime version` bedeutet genau das: Das Image erwartet mehr, als der Host-Treiber bietet. Die Lösung ist ein Treiber-Update auf dem Host — oder ein älteres Image. Was **nicht** hilft, ist die Installation eines CUDA-Toolkits im Container: Die Laufzeit ist bereits da, es fehlt der Treiber, und der lässt sich aus einem Container heraus nicht ersetzen.

4.4.3 Die Bestandteile im Einzelnen

Kernelmodul `nvidia.ko` und die zugehörigen Module stellen die Gerätedateien bereit. Sie müssen zur laufenden Kernelversion passen und werden bei Kernel-Updates neu gebaut — über DKMS oder als vorkompiliertes Paket.

Driver API `libcuda.so` wird vom Treiberpaket mitgeliefert und trägt dessen Version. Diese Bibliothek ist es, die der Container-Hook vom Host einblendet.

CUDA-Laufzeit und Bibliotheken `libcudart`, `cuBLAS`, `cuDNN`, `NCCL` liegen im Container-Image und werden mit der Anwendung ausgeliefert.

Container Toolkit Registriert eine Runtime bei `containerd` oder Docker, die beim Containerstart Gerätedateien und Treiberbibliotheken einblendet. Ohne dieses Bauteil sieht ein Container keine GPU, auch wenn der Treiber läuft.

Fabric Manager Nur bei Systemen mit NVSwitch — also Servern mit acht SXM-GPUs — erforderlich. Ohne laufenden Fabric Manager schlägt dort die GPU-Initialisierung fehl.

DCGM Der Data Center GPU Manager liefert detaillierte Telemetrie und ist die Grundlage des Monitorings in Kapitel 14.

4.5 Lab: GPU-Passthrough unter Proxmox

Damit eine virtuelle Maschine eine GPU exklusiv nutzen kann, muss der Host die Karte freigeben und über VFIO an die VM durchreichen. Das folgende Vorgehen baut das von null auf.

ACHTUNG Vor dem Start

Die Karte wird dem Host vollständig entzogen. Wenn Proxmox seine Konsolenausgabe über diese GPU ausgibt, brauchen Sie vorher einen anderen Zugang — serielle Konsole, IPMI oder eine zweite Grafikausgabe. Ein misslungener Passthrough kann sonst zu einem System führen, das startet, aber keine Bildausgabe mehr hat.

Planen Sie einen Wartungszeitraum ein: Das Vorgehen erfordert mindestens zwei Neustarts.

LAB GPU an eine virtuelle Maschine durchreichen

Ziel: Die GPU ist in der VM sichtbar und `nvidia-smi` liefert dort Werte.

Schritt 1 – IOMMU im BIOS aktivieren. Bei Intel heißt die Einstellung VT-d, bei AMD AMD-Vi oder IOMMU. Ohne diese Einstellung ist alles Weitere wirkungslos.

Schritt 2 – IOMMU im Kernel aktivieren. Proxmox verwendet je nach Installation systemd-boot oder GRUB. Prüfen Sie zuerst, welcher Fall vorliegt:

```
efibootmgr -v 2>/dev/null | head -3
ls /etc/kernel/cmdline 2>/dev/null 2>&1 \
  && echo "systemd-boot" || echo "GRUB"
```

Bei systemd-boot ergänzen Sie /etc/kernel/cmdline, bei GRUB die Zeile GRUB_CMDLINE_LINUX_DEFAULT in /etc/default/grub um:

```
intel_iommu=on iommu=pt          # bei Intel-CPUs
amd_iommu=on iommu=pt           # bei AMD-CPUs
```

Anschließend die Bootkonfiguration schreiben:

```
proxmox-boot-tool refresh      # systemd-boot
update-grub                    # GRUB
```

Schritt 3 – VFIO-Module laden. In /etc/modules ergänzen:

```
vfio
vfio_iommu_type1
vfio_pci
```

Schritt 4 – Host-Treiber ausschließen. Der Host darf die Karte nicht beanspruchen. In /etc/modprobe.d/blacklist-gpu.conf:

```
blacklist nouveau
blacklist nvidia
blacklist nvidiafb
blacklist nvidia_drm
```

Schritt 5 – Karte an vfio-pci binden. Zuerst die Geräte-IDs ermitteln:

```
lspci -nn | grep -i nvidia
```

Erwartete Ausgabe: zwei Zeilen – die GPU selbst und ihre Audiofunktion, jeweils mit einer ID in eckigen Klammern, etwa [10de:2684] und [10de:22ba]. **Beide** werden benötigt. In /etc/modprobe.d/vfio.conf:

```
options vfio-pci ids=10de:2684,10de:22ba disable_vga=1
```

Schritt 6 – Initramfs schreiben und neu starten.

```
update-initramfs -u -k all
reboot
```

Schritt 7 – Ergebnis prüfen. Nach dem Neustart:

```
dmesg | grep -e DMAR -e IOMMU | head
lspci -nnk | grep -A3 -i nvidia
```

Erwartete Ausgabe: Die IOMMU-Meldungen bestätigen die Aktivierung, und bei der GPU steht `Kernel driver in use: vfio-pci`. Steht dort `nouveau` oder `nvidia`, greift das Blacklisting nicht — prüfen Sie Schritt 4 und ob das `Initramfs` neu geschrieben wurde.

Schritt 8 — IOMMU-Gruppen prüfen. Durchgereicht wird immer eine ganze IOMMU-Gruppe. Enthält sie fremde Geräte, müssen auch diese mitgehen — was in der Praxis oft nicht möglich ist:

```
for g in /sys/kernel/iommu_groups/*/devices/*; do
  n=${g#/iommu_groups/}; n=${n%/*}
  printf 'Gruppe %s: ' "$n"
  lspci -nns "${g##*/}" | cut -c1-70
done | sort -V | grep -i -B2 -A2 nvidia
```

Erwartete Ausgabe: Die GPU und ihre Audiofunktion liegen in einer eigenen Gruppe. Liegen weitere Geräte darin — etwa ein Netzwerkadapter — ist die Hauptplatine der begrenzende Faktor. Behelfslösungen existieren, sind aber mit Vorsicht zu behandeln; die saubere Lösung ist ein anderer PCIe-Steckplatz.

Schritt 9 — VM konfigurieren. Die VM benötigt Maschinentyp `q35` und UEFI-Firmware `OVMF`. In der Konfigurationsdatei unter `/etc/pve/qemu-server/<VMID>.conf`:

```
machine: q35
bios: ovmf
cpu: host
hostpci0: 0000:01:00,pcie=1,x-vga=0
```

Die Angabe der Adresse **ohne** Funktionsnummer reicht alle Funktionen des Geräts durch — also GPU und Audio gemeinsam. `cpu: host` ist wichtig, damit der Gast alle CPU-Eigenschaften sieht.

Schritt 10 — In der VM prüfen.

```
lspci | grep -i nvidia
```

Erwartete Ausgabe: Die Karte erscheint. Ein Treiber ist noch nicht installiert — das ist der nächste Abschnitt.

Ergebnis: Die GPU gehört ausschließlich dieser VM. Der Host sieht sie nicht mehr, und keine andere VM kann sie beanspruchen.

MERKE

Passthrough ist exklusiv. Eine physische GPU kann genau einer VM gehören. Wer mehrere VMs mit GPU-Zugriff braucht, benötigt entweder mehrere Karten oder vGPU — und vGPU setzt eine Rechenzentrumskarte und eine kostenpflichtige Lizenz voraus. Auf Consumer-Hardware ist die Antwort auf „mehrere VMs teilen sich eine GPU“ schlicht: Das geht nicht. Geteilt wird stattdessen **innerhalb** der VM — über Kubernetes und die Verfahren aus Kapitel 6.

4.6 Die Landkarte der GPU-Aufteilung

Passthrough ist nur eines von mehreren Verfahren, eine GPU mehreren Verbrauchern zugänglich zu machen – und sie arbeiten auf ganz verschiedenen Ebenen. Die folgende Übersicht ordnet sie ein und verweist auf das jeweils zuständige Kapitel. Sie ist die Orientierung für alles, was in Teil II folgt.

Verfahren	Ebene	Isolation	Voraussetzung	Kap.
PCI-Passthrough	Hypervisor	Vollständig, aber exklusiv – eine Karte, eine VM	IOMMU, VFIO	4
vGPU	Hypervisor	Stark; zeitgeteilte Aufteilung mit festem Speicheranteil	Rechenzentrums-karte, kostenpflichtige Lizenz	–
MIG	Hardware	Hart – getrennte Speicher- und Rechenpfade	A100, H100 oder neuer	6
Time-Slicing	Treiber	Keine Speicherisolation – Prozesse können sich gegenseitig verdrängen	keine	6
MPS	Treiber	Keine Isolation; erlaubt aber echte Parallelität mehrerer Kontexte	keine	6
Ein Server, viele Anfragen	Anwendung	Mandantentrennung erfolgt im Gateway, nicht auf der GPU	Inferenz-Server mit Batching	7, 11

MERKE

Die letzte Zeile ist die wichtigste und wird am häufigsten übersehen. Für Inferenz-Workloads ist die effizienteste Form der Aufteilung meist gar keine GPU-Partitionierung, sondern **ein einziger Inferenz-Server, der viele Anfragen gleichzeitig bearbeitet**. Continuous Batching aus Kapitel 2 nutzt die Karte besser aus als jede Aufteilung in kleinere Einheiten, weil die Gewichte nur einmal im Speicher liegen und nur einmal je Schritt gelesen werden.

Aufgeteilt wird eine GPU deshalb sinnvollerweise nur dann, wenn **verschiedene Modelle** darauf laufen sollen – oder wenn Isolation zwischen Mandanten technisch erzwungen werden muss. Für „mehrere Teams nutzen dasselbe Modell“ ist die richtige Antwort ein gemeinsamer Server mit Kontingenten im Gateway.

Für das Referenz-Lab bedeutet das konkret: Die Karte gehört per Passthrough der Kubernetes-Worker-VM. Innerhalb dieser VM übernimmt Kubernetes die Zuteilung – Kapitel 5 – und die eigentliche Mehrfachnutzung geschieht im Inferenz-Server durch Batching.

4.7 Treibervarianten: proprietär oder offen

NVIDIA liefert die Kernelmodule inzwischen in zwei Ausführungen aus. Die Wahl ist nicht beliebig.

	Proprietäre Module	Offene Kernelmodule
Verfügbarkeit	alle unterstützten GPUs	ab Turing, also RTX 20 und neuer
Reifegrad	langjährig erprobt	für Rechenzentrumskarten Standard, für Consumer inzwischen ebenfalls empfohlen
Secure Boot	Signierung erforderlich	Signierung erforderlich
Bevorzugt bei	älterer Hardware	aktueller Hardware und neueren Treiberzweigen

Bei aktuellen Treiberzweigen sind die offenen Module für unterstützte Karten die Voreinstellung. Bei Problemen mit einem Zweig lohnt der Wechsel auf die jeweils andere Variante als Diagnoseschritt – er ist schnell durchgeführt und schließt eine ganze Fehlerklasse aus.

4.8 Treiber und Container Toolkit in der VM

4.8.1 Treiberinstallation

Für den Betrieb unter Kubernetes gibt es zwei Wege, und die Wahl hat Folgen für Kapitel 5:

Option	Geeignet, wenn	Ungeeignet, wenn
Treiber auf dem Host der VM installieren	Volle Kontrolle, funktioniert unabhängig von Kubernetes, gut für ein Lab und für Umgebungen mit gepflegtem Konfigurationsmanagement.	Bei vielen Knoten – dann wird die Versionspflege zur Handarbeit.
Treiber über den GPU Operator ausrollen	Bei mehreren GPU-Knoten. Der Operator betreibt den Treiber als Container und pflegt die Version mit.	Wenn bereits ein Host-Treiber installiert ist – beides gleichzeitig führt zu Konflikten.

Für das Referenz-Lab mit einem GPU-Knoten ist der Host-Treiber der einfachere Weg. Kapitel 5 zeigt beide Varianten und wie der GPU Operator zu konfigurieren ist, damit er einen vorhandenen Treiber respektiert.

LAB Treiber installieren und verifizieren

Ziel: nvidia-smi liefert in der VM Werte, und der Treiber überlebt Kernel-Updates.

Schritt 1 – Kernel-Header bereitstellen. Ohne sie kann das Modul nicht gebaut werden:

```
apt update && apt install -y build-essential dkms \
  linux-headers-$(uname -r)
```

Schritt 2 – Treiber installieren. Bevorzugt aus dem Paket-Repository der Distribution oder aus dem CUDA-Repository von NVIDIA – nicht über die `.run`-Datei. Paketierte Treiber lassen sich aktualisieren und entfernen; die `.run`-Variante entzieht sich der Paketverwaltung und erzeugt später Probleme.

Schritt 3 – Secure Boot beachten. Ist Secure Boot in der VM aktiv, muss das DKMS-Modul signiert werden, sonst verweigert der Kernel das Laden. Für ein Lab ist es einfacher, Secure Boot in den VM-Einstellungen zu deaktivieren.

Schritt 4 – Prüfen.

```
nvidia-smi
```

Erwartete Ausgabe: Eine Tabelle mit Treiberversion, unterstützter CUDA-Version, Kartenname, Temperatur, Leistungsaufnahme und Speicherbelegung. Die Zeile `CUDA Version` oben rechts gibt an, welche CUDA-Hauptversion dieser Treiber **maximal** unterstützt – das ist die Obergrenze für alle Container-Images auf diesem Knoten.

Schritt 5 – Persistence Mode aktivieren. Ohne ihn entlädt der Treiber seinen Zustand, sobald kein Prozess die GPU nutzt – was jede Initialisierung um Sekunden verlängert:

```
systemctl enable --now nvidia-persistenced
nvidia-smi -q | grep -i persistence
```

Erwartete Ausgabe: Persistence Mode : Enabled.

Ergebnis: Der Treiber läuft, überlebt über DKMS auch Kernel-Updates, und der Persistence Mode verhindert unnötige Initialisierungszeiten.

4.8.2 Container Toolkit

Der Treiber allein genügt nicht: Ein Container sieht die GPU erst, wenn eine passende Runtime die Gerätedateien und Treiberbibliotheken einblendet.

LAB Container Toolkit einrichten und prüfen

Ziel: Ein Container kann `nvidia-smi` ausführen.

Schritt 1 – Paket installieren. Das Toolkit stammt aus einem eigenen NVIDIA-Repository. Nach der Installation wird die Container-Laufzeit konfiguriert:

```
nvidia-ctl runtime configure --runtime=containerd
systemctl restart containerd
```

Schritt 2 – Prüfen. Mit einem beliebigen CUDA-Basisimage:

```
IMG=docker.io/nvidia/cuda:12.4.1-base-ubuntu22.04
ctr image pull "$IMG"
ctr run --rm --gpus 0 "$IMG" test nvidia-smi
```

Erwartete Ausgabe: Dieselbe Tabelle wie auf dem Host. Erscheint stattdessen `nvidia-smi: command not found` oder eine Meldung über fehlende Bibliotheken, wurde die Runtime nicht korrekt registriert.

Wichtig für Kapitel 5: Unter RKE2 liegen containerd-Socket und Konfiguration an anderen Pfaden als bei einer eigenständigen containerd-Installation, und RKE2 überschreibt seine Konfiguration bei jedem Start aus einer Vorlage. Der hier gezeigte Aufruf konfiguriert die **systemeigene** containerd-Instanz. Für RKE2 gilt ein anderes Vorgehen – Kapitel 5 behandelt es ausführlich.

4.9 Betriebsthemen

4.9.1 Persistence Mode

Ohne aktivierten Persistence Mode gibt der Treiber seinen Zustand frei, sobald der letzte Prozess die GPU freigibt. Die nächste Initialisierung dauert dann mehrere Sekunden. Bei einem dauerhaft laufenden Inferenz-Server fällt das nicht auf; bei kurzlebigen Pods oder bei Scale-to-Zero summiert es sich.

4.9.2 Leistungsaufnahme und thermische Drosselung

Consumer-Karten sind für schubweise Last ausgelegt, nicht für Dauerbetrieb. Unter anhaltender Inferenzlast erreichen sie ihre Temperaturgrenze und senken den Takt – sichtbar als langsam sinkender Durchsatz über Minuten.

```
nvidia-smi -l 5 --format=csv \
  --query-gpu=timestamp,temperature.gpu,clocks.sm,power.draw
```

Eine bewusste Begrenzung der Leistungsaufnahme kann hier stabilisierend wirken:

```
nvidia-smi -pl 300          # Grenze in Watt
```

Der Durchsatzverlust ist oft geringer als erwartet, weil die Karte ohnehin gedrosselt hätte – dafür bleibt die Leistung über die Zeit konstant. Für reproduzierbare Messungen ist das die bessere Betriebsart.

4.9.3 Xid-Meldungen lesen

Fehler auf GPU-Ebene meldet der Treiber als sogenannte Xid-Meldung im Kernel-Log. Diese Meldungen sind das wichtigste Diagnosewerkzeug bei GPU-Problemen – und sie sind zunächst kryptisch:

```
dmesg -T | grep -i xid
journalctl -k --since "1 hour ago" | grep -i xid
```

Beispielausgabe:

```
NVRM: Xid (PCI:0000:01:00): 31, pid=12345, name=python3,
      Ch 00000008, intr 10000000. MMU Fault: ENGINE GRAPHICS ...
```

Die entscheidende Triage-Frage lautet: **Ist das ein Anwendungs- oder ein Hardwarefehler?** Die Nummer beantwortet sie.

Xid	Bedeutung	Ursprung	Reaktion
13	Ausnahme in der Grafik-Engine	Anwendung	Meist unzulässiger Speicherzugriff im Kernel-Code. Anwendung prüfen.
31	Speicherzugriffsfehler	Anwendung	Häufigster Fall. Fehlerhafter Code oder inkompatible Bibliotheksversion.
43	Verarbeitung angehalten	Anwendung	Der Prozess wurde beendet. GPU bleibt in der Regel nutzbar.
45	Vorzeitige Bereinigung	Betrieb	Folgt meist auf ein beendetes Programm. Für sich genommen unkritisch.

Konstanter, etwas niedrigerer Durchsatz ist betrieblich wertvoller als hoher Durchsatz mit Einbrüchen. Kapazitätsplanung rechnet mit dem Dauerwert, nicht mit der Spitze.

Xid	Bedeutung	Ursprung	Reaktion
48	Nicht korrigierbarer ECC-Fehler	Hardware	GPU zurücksetzen. Bei Wiederholung Austausch veranlassen.
63, 64	Speicherseite stillgelegt bzw. Zeile umgeleitet	Hardware	Beobachten. Häufung deutet auf beginnenden Speicherdefekt.
74	NVLink-Fehler	Hardware	Verbindung oder Einbau prüfen. Bei Wiederholung Servicefall.
79	GPU nicht mehr auf dem Bus	Hardware	Schwerwiegend: Stromversorgung, Temperatur, Einbau, PCIe-Steckplatz.
92	Hohe Rate korrigierter ECC-Fehler	Hardware	Frühwarnung. Karte für den Austausch vormerken.
94, 95	Eingegrenzter bzw. nicht eingegrenzter ECC-Fehler	Hardware	Bei 95 ist der Zustand nicht mehr vertrauenswürdig – Knoten aus dem Betrieb nehmen.

MERKE

Die Faustregel für die Triage: Xid 13, 31, 43 und 45 deuten auf die **Anwendung** – ein Neustart des Pods genügt meist. Xid 48, 63, 64, 74, 79, 92, 94 und 95 deuten auf **Hardware** – der Knoten gehört aus dem Scheduling genommen, bevor weitere Workloads darauf landen.

In Kubernetes lässt sich das automatisieren: Kapitel 14 zeigt, wie Xid-Ereignisse aus DCGM als Metrik verfügbar werden und einen Knoten automatisch markieren können.

ACHTUNG Xid 79 ernst nehmen

„GPU has fallen off the bus“ bedeutet, dass die Karte für den Host nicht mehr ansprechbar ist. Häufigste Ursachen sind unzureichende Stromversorgung unter Lastspitzen, Überhitzung und schlechter Sitz im Steckplatz – in dieser Reihenfolge. Bei Consumer-Karten mit 450 Watt Spitzenaufnahme ist das Netzteil der erste Verdächtige, besonders wenn der Fehler nur unter Volllast auftritt.

4.9.4 nvidia-smi als Referenz

Für den Alltag genügen wenige Aufrufe. Sie gehören ins Muskelgedächtnis.

Aufruf	Zweck
<code>nvidia-smi</code>	Überblick: Treiber, CUDA-Obergrenze, Belegung, Prozesse
<code>nvidia-smi -L</code>	Karten mit UUID auflisten – die UUID ist die stabile Kennung
<code>nvidia-smi -q</code>	Vollständiger Zustandsbericht, sehr ausführlich
<code>nvidia-smi -q -d ECC, TEMPERATURE, POWER</code>	Nur die genannten Abschnitte

Aufruf	Zweck
<code>nvidia-smi topo -m</code>	Verbindungstopologie zwischen Karten
<code>nvidia-smi dmon -s pucm</code>	Fortlaufende Kennzahlen im Sekundentakt
<code>nvidia-smi pmon -s um</code>	Kennzahlen je Prozess — welcher Pod belegt was
<code>nvidia-smi -pl <Watt></code>	Leistungsgrenze setzen
<code>nvidia-smi -r -i <Index></code>	Karte zurücksetzen — nur wenn kein Prozess sie nutzt

Für Skripte und Monitoring ist die Abfrageform die richtige, weil sie maschinenlesbar ausgibt:

```
nvidia-smi --format=csv,noheader,nounits --query-gpu=\
index,name,uuid,memory.total,memory.used,utilization.gpu,\
temperature.gpu,power.draw,clocks.sm
```

Die Liste der verfügbaren Felder liefert `nvidia-smi --help-query-gpu`. Sie ist lang und lohnt einen Blick, bevor man ein eigenes Skript schreibt.

Für den Produktionsbetrieb ist `nvidia-smi` allerdings nur der Einstieg. Es liefert Momentaufnahmen, keine Zeitreihen, und einige wichtige Größen — etwa die tatsächliche Auslastung der Rechenwerke im Unterschied zur bloßen Belegung — gibt es nur über DCGM. Kapitel 14 baut darauf auf.

4.9.5 Mehrere Karten in einem Server

Wer über den Ausbau nachdenkt, stößt schnell auf physische Grenzen, die in Beschaffungsgesprächen regelmäßig übersehen werden.

Grenze	Worauf zu achten ist
Steckplätze	Consumer-Karten belegen drei bis vier Slots. Zwei Karten passen selten nebeneinander, ohne den Luftstrom der oberen zu blockieren.
PCIe-Lanes	Übliche Desktop-Plattformen bieten 20 bis 28 nutzbare Lanes. Zwei Karten mit voller x16-Anbindung erfordern eine Server- oder Workstation-Plattform.
Stromversorgung	Zwei Karten mit je 450 W plus System benötigen ein Netzteil deutlich über 1 200 W — und eine Absicherung, die Lastspitzen trägt.
Kühlung	Aktiv gekühlte Karten setzen Wärme im Gehäuse frei. Passiv gekühlte Rechenzentrumskarten benötigen den Luftstrom eines Serverchassis und funktionieren im Desktop-Gehäuse nicht.
Abwärme im Raum	Zwei GPU-Knoten unter Dauerlast erzeugen die Wärme eines kleinen Heizlüfters. Im Büro ist das eine ernstzunehmende Größe.

MERKE

Der Sprung von einer auf zwei GPUs ist selten ein reiner Karteneinkauf. In der Praxis ist er ein Plattformwechsel — anderes Mainboard, anderes Netzteil, anderes Gehäuse. Das ist ein weiteres Argument dafür, die Kapazitätsrechnung aus Kapitel 2 **vor** der Beschaffung zu führen und nicht nachträglich zu erweitern.

4.9.6 ECC

Rechenzentrumskarten erkennen und korrigieren Bitfehler im Speicher. Consumer-Karten nicht. Bei 24 GB Speicher unter Dauerlast sind gelegentliche Bitfehler statistisch nicht ausgeschlossen; sie äußern sich als sporadisch falsche Ausgaben ohne Fehlermeldung.

Für ein Lab ist das hinnehmbar. Für eine Plattform, deren Ausgaben in Geschäftsprozesse einfließen, ist ECC eines der stärksten Argumente für Rechenzentrumshardware — und eines, das in Beschaffungsdiskussionen selten vorgebracht wird.

```
nvidia-smi -q | grep -A3 "Ecc Mode"
nvidia-smi --format=csv \
  --query-gpu=ecc.errors.uncorrected.volatile.total
```

4.10 Stack-Verifikation in einem Durchgang

Bei der Fehlersuche ist die wichtigste Frage: **Auf welcher Schicht bricht es ab?** Das folgende Skript geht die Kette aus Abschnitt 4.4 von unten nach oben durch und meldet die erste Schicht, die fehlt. Es gehört auf jeden GPU-Knoten.

```
#!/usr/bin/env bash
# gpu-check.sh -- prueft den NVIDIA-Stack von unten nach oben
ok() { printf ' \033[32mOK\033[0m  %s\n' "$1"; }
fehlt(){ printf ' \033[31mFEHLT\033[0m %s\n' "$1"; ABBRUCH=1; }

echo "1) PCI-Geraet"
lspci -nn | grep -qi nvidia \
  && ok "GPU auf dem PCI-Bus sichtbar" \
  || fehlt "Keine NVIDIA-GPU -- Passthrough oder Einbau pruefen"

echo "2) Kernelmodul"
lsmod | grep -q '^nvidia ' \
  && ok "nvidia.ko geladen" \
  || fehlt "Kernelmodul nicht geladen -- dkms status pruefen"

echo "3) Geraetdateien"
ls /dev/nvidia0 >/dev/null 2>&1 \
  && ok "/dev/nvidia0 vorhanden" \
  || fehlt "Geraetdateien fehlen -- nvidia-modprobe oder Neustart"

echo "4) Treiber-Werkzeug"
if nvidia-smi >/dev/null 2>&1; then
  ok "nvidia-smi liefert Werte"
  Q="--format=csv,noheader --query-gpu=driver_version"
  DRV=$(nvidia-smi $Q)
  CU=$(nvidia-smi | grep -o 'CUDA Version: [0-9.]*' | cut -d\ -f3)
  echo "    Treiber $DRV, CUDA bis $CU"
else
  fehlt "nvidia-smi schlaegt fehl"
fi

echo "5) Persistence Mode"
nvidia-smi -q 2>/dev/null | grep -q "Persistence Mode *: Enabled" \
```

```

&& ok "aktiv" \
|| echo "  HINWEIS nicht aktiv -- nvidia-persistenced aktivieren"

echo "6) Container Toolkit"
command -v nvidia-ctk >/dev/null \
&& ok "nvidia-ctk installiert" \
|| fehlt "Container Toolkit fehlt"

echo "7) Xid-Meldungen der letzten 24 Stunden"
XID=$(journalctl -k --since "24 hours ago" 2>/dev/null \
| grep -ci "Xid" || true)
[ "${XID:-0}" -eq 0 ] \
&& ok "keine" \
|| echo "  WARNUNG $XID Xid-Meldungen -- siehe Abschnitt 4.9"

exit "${ABBRUCH:-0}"

```

Erwartete Ausgabe auf einem gesunden Knoten: Sieben Zeilen, alle mit OK, dazu Treiberversion und maximal unterstützte CUDA-Version. Die erste Zeile mit FEHLT benennt die Schicht, an der die Kette bricht – und damit den Abschnitt dieses Kapitels, der weiterhilft.

Dieses Skript eignet sich gut als Startprüfung eines DaemonSets oder als Bereitschaftsprüfung, bevor ein Knoten für GPU-Workloads freigegeben wird.

4.10.1 BIOS-Einstellungen, die häufig fehlen

Vier Einstellungen entscheiden über den Erfolg des Passthroughs und werden regelmäßig übersehen:

Einstellung	Wert	Begründung
VT-d bzw. AMD-Vi	an	Voraussetzung für IOMMU – ohne dies gar nichts
Above 4G Decoding	an	GPUs mit 24 GB und mehr benötigen Adressraum oberhalb der 4-GB-Grenze. Fehlt die Einstellung, wird die Karte nicht korrekt initialisiert.
Resizable BAR	an	Erlaubt dem Host Zugriff auf den gesamten VRAM statt auf ein 256-MB-Fenster. Beschleunigt das Laden von Modellen spürbar.
CSM / Legacy Boot	aus	Der Passthrough mit OVMF setzt reines UEFI voraus.

4.10.2 Treiber-Updates im laufenden Betrieb

Ein Treiber-Update erfordert das Entladen der Kernelmodule – und das gelingt nur, wenn kein Prozess die GPU nutzt. In einem Cluster bedeutet das:

1. Knoten für neue Workloads sperren
2. Laufende GPU-Pods verdrängen und abwarten, bis der Speicher frei ist
3. Prüfen, dass kein Prozess mehr hält: `nvidia-smi` darf keine Prozesse zeigen
4. Treiber aktualisieren, Module neu laden oder Knoten neu starten
5. Verifikation über das Skript aus diesem Abschnitt
6. Knoten wieder freigeben

ACHTUNG Warum ein zweiter GPU-Knoten kein Luxus ist

Ohne einen zweiten GPU-Knoten bedeutet jedes Treiber-Update einen vollständigen Ausfall des Inferenz-Dienstes – und Treiber-Updates sind nicht optional, weil sie Sicherheitskorrekturen enthalten und die Obergrenze der nutzbaren CUDA-Version bestimmen.

Das ist dasselbe Argument wie am Ende von Kapitel 2, nur von der anderen Seite: Der zweite Knoten wird nicht für den Durchsatz beschafft, sondern für die Wartbarkeit.

4.11 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
<code>nvidia-smi</code> meldet <code>No devices found</code>	Kernelmodul nicht geladen oder GPU nicht durchgereicht	<code>lsmod grep nvidia</code> und <code>lspci grep -i nvidia</code>	Modul laden; Passthrough-Konfiguration prüfen
Bei der GPU steht <code>Kernel driver in use: nouveau</code>	Blacklisting greift nicht	<code>/etc/modprobe.d/</code> prüfen, <code>Initramfs-Zeitstempel</code> vergleichen	Blacklist ergänzen, <code>update-initramfs -u -k all</code> , neu starten
VM startet nicht mit durchgereicher GPU	IOMMU-Gruppe enthält weitere Geräte	Gruppenzugehörigkeit wie in Schritt 8 des Labs prüfen	Anderer PCIe-Steckplatz; im Zweifel andere Hauptplatine
CUDA driver version is insufficient	Container-Image erwartet neuere CUDA-Version als der Treiber bietet	<code>nvidia-smi</code> zeigt die maximal unterstützte CUDA-Version	Host-Treiber aktualisieren oder älteres Image verwenden
Container sieht keine GPU, Host schon	Container Toolkit nicht oder für die falsche Laufzeit konfiguriert	<code>nvidia-ctk runtime configure --dry-run</code> und Laufzeitkonfiguration prüfen	Toolkit registrieren, Laufzeit neu starten
Nach Kernel-Update ist die GPU verschwunden	DKMS hat das Modul für den neuen Kernel nicht gebaut	<code>dkms status</code> , Vorhandensein der passenden Kernel-Header	Header nachinstallieren, <code>dkms autoinstall</code>
Durchsatz sinkt über Minuten	Thermische Drosselung	Temperatur und Taktfrequenz über die Zeit beobachten	Kühlung verbessern oder Leistungsgrenze bewusst setzen
GPU-Initialisierung dauert Sekunden	Persistence Mode nicht aktiv	<code>nvidia-smi -q grep -i persistence</code>	<code>nvidia-persistenced</code> aktivieren

4.12 Interviewfragen

INTERVIEWFRAGE

Welche Rolle spielen NVIDIA-Treiber, CUDA und Container Toolkit zueinander?

Gut ist die Aufzählung: Treiber auf dem Host, CUDA-Laufzeit im Container, Toolkit als Bindeglied.

Senior ist die Kompatibilitätsregel – die CUDA-Laufzeit im Container darf nicht neuer sein, als der Host-Treiber unterstützt, mit Minor-Version-Kompatibilität innerhalb einer Hauptversion – und die daraus folgende Betriebsregel: Host-Treiber großzügig neu halten, Images konservativ wählen. Wer ergänzt, dass sich der Treiber aus einem Container heraus nicht ersetzen lässt und deshalb ein Toolkit-Fehler nie durch Nachinstallation im Image zu lösen ist, hat die Frage vollständig beantwortet.

INTERVIEWFRAGE

Wie reichen Sie eine GPU an eine virtuelle Maschine durch?

Gut ist die Kette: IOMMU im BIOS, IOMMU im Kernel, VFIO-Module, Host-Treiber ausschließen, Karte an `vfio-pci` binden, VM mit `q35` und `OVMF`.

Senior sind die drei Fallstricke: Die Audiofunktion der Karte muss mitgehen; es wird immer eine ganze IOMMU-Gruppe durchgereicht, weshalb deren Zusammensetzung vorher zu prüfen ist; und Passthrough ist exklusiv – eine Karte gehört genau einer VM. Wer ergänzt, dass die Alternative vGPU eine Rechenzentrumskarte und eine Lizenz voraussetzt, zeigt Beschaffungsbewusstsein.

INTERVIEWFRAGE

Sie sollen GPUs für eine Inferenz-Plattform auswählen. Worauf achten Sie?

Schwach ist eine Antwort, die mit TFLOPS beginnt.

Senior ist die Reihenfolge: VRAM-Kapazität zuerst, weil sie bestimmt, welche Modelle überhaupt laufen; Speicherbandbreite zweitens, weil sie die Decode-Geschwindigkeit bestimmt; Rechenleistung drittens, weil sie nur den Prefill betrifft. Ergänzt um die betrieblichen Kriterien – ECC, MIG-Fähigkeit bei geplantem Mehrmandantenbetrieb, Kühlkonzept, Leistungsaufnahme je Rack – und den Hinweis auf die Lizenzlage bei Consumer-Karten im Rechenzentrum.

INTERVIEWFRAGE

Was sagt Ihnen `nvidia-smi topo -m`?

Gut ist: die Verbindungsart zwischen GPUs.

Senior ist die Konsequenz. `NV#` bedeutet NVLink und ist der beste Fall für Tensor Parallelism; `SYS` bedeutet Kommunikation über die Verbindung zwischen zwei CPU-Sockeln und ist für zusammenarbeitende GPUs ein Konfigurationsfehler. Der Befehl gehört zu den ersten nach der Bereitstellung neuer Hardware – besonders bei gemieteten Instanzen, wo man die physische Anordnung nicht kennt.

INTERVIEWFRAGE

Warum ist CPU-Offloading keine Skalierungsstrategie?

Senior ist die Rechnung: PCIe 4.0 liefert rund 32 GB/s, der GPU-interne Speicherzugriff 900 bis 3 350 GB/s. Weil der Decode bandbreitenbegrenzt ist, wird jede Schicht, die über

PCIe geladen werden muss, um mehr als eine Größenordnung langsamer. Offloading ist eine Notlösung, um ein Modell überhaupt zum Laufen zu bringen — Quantisierung und ein kleineres Modell sind in praktisch jedem Fall die besseren Antworten.

4.13 Zusammenfassung

- Für Inferenz zählen zwei Kennzahlen: VRAM-Kapazität bestimmt, welche Modelle laufen; Speicherbandbreite bestimmt, wie schnell sie antworten. TFLOPS ist die dritte Größe.
- Der Unterschied zwischen GDDR und HBM beträgt den Faktor zwei bis drei bei der Bandbreite und ist der technische Kern des Preisunterschieds zwischen Consumer- und Rechenzentrumskarten.
- Consumer-Karten sind im Lab eine gute Wahl. Für produktive Umgebungen sprechen ECC, MIG-Fähigkeit, Dauerlastauslegung und die Lizenzlage für Rechenzentrumshardware.
- Der Software-Stack verläuft vom Kernelmodul über `libcuda.so` zum Container Toolkit, das dem Container Gerätedateien und Treiberbibliotheken einblendet. Die CUDA-Laufzeit liegt im Image, nicht auf dem Host.
- Kompatibilitätsregel: Die CUDA-Laufzeit im Container darf nicht neuer sein, als der Host-Treiber unterstützt. Host-Treiber neu halten, Images konservativ wählen.
- GPU-Passthrough setzt IOMMU, VFIO und ein sauberes Blacklisting voraus. Durchgereicht wird immer eine vollständige IOMMU-Gruppe, und die Audiofunktion der Karte gehört dazu.
- Passthrough ist exklusiv: eine Karte, eine VM. Geteilt wird erst innerhalb der VM über Kubernetes — Kapitel 6.
- Persistence Mode, bewusste Leistungsgrenzen und die Beobachtung thermischer Drosselung gehören zur Grundkonfiguration jedes GPU-Knotens.

Quellen und Weiterlesen

- NVIDIA: *CUDA Toolkit Documentation — CUDA Compatibility*. Verbindliche Referenz zur Treiber- und Laufzeitkompatibilität.
- NVIDIA: *Container Toolkit Documentation — Installation and Configuration*. Einrichtung für Docker, containerd und CRI-O.
- Proxmox: *PCI(e) Passthrough* im Proxmox VE Administration Guide. Maßgeblich für die Schritte des Labs; Pfade und Werkzeuge ändern sich zwischen Hauptversionen.
- Linux-Kernel-Dokumentation: *VFIO — Virtual Function I/O*. Hintergrund zu IOMMU-Gruppen und Gerätezuordnung.
- NVIDIA: *System Management Interface* — vollständige Referenz zu `nvidia-smi`, inklusive Abfrage- und Konfigurationsoptionen.

GPUs unter Kubernetes

ZIEL	Aus einer GPU, die in einer VM steckt, eine planbare Cluster-Ressource machen — inklusive der Besonderheiten, die RKE2 dabei mitbringt.
SETZT VORAUS	Kapitel 4: Treiber und Container Toolkit laufen in der VM. Kubernetes-Produktionserfahrung.
DANACH KANNST DU	Das Extended-Resource-Modell erklären, den GPU Operator auf RKE2 ausrollen und konfigurieren, GPU-Knoten sauber vom übrigen Cluster trennen, Kontingente je Team setzen und die typischen Fehlerbilder von Pending-Pods bis Treiber-Mismatch diagnostizieren.

GESCHRIEBEN GEGEN

Kubernetes 1.31 · RKE2 v1.31.x · GPU Operator 24.x · Stand September 2026

Kubernetes verwaltet CPU und Speicher seit jeher. GPUs behandelt es grundlegend anders — und das ist keine Nachlässigkeit, sondern folgt aus den Eigenschaften der Hardware. Dieses Kapitel erklärt das Modell, rollt den GPU Operator aus und behandelt die RKE2-Eigenheiten, an denen generische Anleitungen scheitern.

5.1 Warum Kubernetes GPUs nicht von selbst kennt

5.1.1 Drei Arten von Ressourcen

Ressource	Art	Verhalten
CPU	komprimierbar	Überbuchbar. Ein Pod über seinem Request wird gedrosselt, nicht beendet. Bruchteile möglich (500m).
Arbeitsspeicher	nicht komprimierbar	Überbuchbar mit Risiko. Bei Knappheit wird beendet. Bruchteile möglich.
nvidia.com/gpu	erweitert	Nicht überbuchbar, ganzzahlig, exklusiv. Keine Bruchteile, kein Drosseln, keine Verdrängung durch den Kernel.

Erweiterte Ressourcen sind in Kubernetes ein allgemeiner Mechanismus für Hardware, die der Cluster nicht selbst erkennt. Für sie gelten drei Regeln, die man kennen muss:

1. Nur ganzzahlige Werte. `nvidia.com/gpu: 0.5` ist ungültig.
2. Request und Limit müssen gleich sein. Gibt man nur ein Limit an, setzt Kubernetes den Request automatisch gleich — deshalb genügt in der Praxis die Angabe unter `limits`.


3. Keine Überbuchung. Die Summe aller zugeteilten GPUs kann die vorhandene Zahl nie überschreiten.

MERKE

Die dritte Regel hat eine unmittelbare Folge, die viele überrascht: Ein Cluster mit einer GPU kann **genau einen** Pod mit `nvidia.com/gpu: 1` betreiben. Ein zweiter bleibt in Pending, unabhängig davon, wie wenig der erste tatsächlich rechnet. Wer mehrere Pods auf einer Karte braucht, muss eines der Verfahren aus Kapitel 6 einsetzen – oder, besser, die Aufteilung nach oben in den Inferenz-Server verlagern.

5.1.2 Die Device Plugin API

Damit Kubernetes eine GPU überhaupt sieht, muss ein Gerätetreiber-Dienst sie melden. Diese Rolle übernimmt ein Device Plugin – ein DaemonSet, das auf jedem GPU-Knoten läuft und über einen Unix-Socket mit dem Kubelet spricht.



Der Weg einer GPU-Zuteilung vom Kubelet zum Container

Der letzte Schritt schließt den Kreis zu Kapitel 4: Das Device Plugin **entscheidet** über die Zuteilung, aber das Container Toolkit **setzt sie um**. Fehlt das Toolkit, wird ein Pod erfolgreich geplant und findet im Container trotzdem keine GPU – ein Fehlerbild, das regelmäßig in die Irre führt.

5.2 Der NVIDIA GPU Operator

Der GPU Operator bündelt alle Bausteine, die ein GPU-Knoten braucht, in einem einzigen Helm-Chart und pflegt ihre Versionen aufeinander abgestimmt.

Komponente	Aufgabe	Abschaltbar
Node Feature Discovery	Erkennt Hardware und setzt Knoten-Labels	ja
GPU Feature Discovery	Setzt GPU-spezifische Labels: Modell, Speicher, Anzahl	ja
Driver DaemonSet	Baut und lädt den Treiber als Container	ja — siehe unten
Container Toolkit	Registriert die NVIDIA-Runtime bei containerd	ja
Device Plugin	Meldet GPUs als <code>nvidia.com/gpu</code>	nein — Kernbestandteil
DCGM und DCGM Exporter	Telemetrie für Prometheus — Kapitel 14	ja
MIG Manager	Konfiguriert MIG-Profil — Kapitel 6	ja
Validator	Prüft nach dem Ausrollen, ob der Stack funktioniert	nein

5.2.1 Treiber im Container oder auf dem Host

Die folgenreichste Entscheidung beim Einsatz des Operators:

Option	Geeignet, wenn	Ungeeignet, wenn
<code>driver.enabled=true</code> — Treiber im Container	Bei mehreren GPU-Knoten. Der Operator pflegt die Treiberversion mit und rollt sie einheitlich aus. Der Host bleibt schlank.	Wenn bereits ein Host-Treiber installiert ist. Beides gleichzeitig führt zu Konflikten beim Laden der Kernelmodule.
<code>driver.enabled=false</code> — Treiber auf dem Host	Für wenigen Knoten mit gepflegtem Konfigurationsmanagement, und immer dann, wenn der Treiber schon vorhanden ist — etwa nach Kapitel 4.	Bei vielen Knoten. Die Versionspflege wird dann zur Handarbeit.

Für das Referenz-Lab gilt `driver.enabled=false`, weil Kapitel 4 den Treiber bereits in der VM installiert hat. Dasselbe gilt für das Toolkit, sofern es dort schon eingerichtet wurde — allerdings mit einer wichtigen Einschränkung, die der nächste Abschnitt behandelt.

ACHTUNG Der häufigste Fehler beim ersten Ausrollen

Wird der Operator mit aktivem Treiber-Container auf einen Knoten ausgerollt, der bereits einen Host-Treiber hat, versucht der Container die vorhandenen Kernelmodule zu entladen. Das schlägt fehl, solange irgendein Prozess die GPU nutzt, und der Treiber-Pod läuft in eine Neustartschleife. Im Log erscheinen Meldungen über belegte Module.

Die Lösung ist eine Entscheidung, keine Reparatur: entweder Host-Treiber entfernen oder `driver.enabled=false` setzen. Beides gleichzeitig geht nicht.

5.3 RKE2: was anders ist

Hier liegt der Kern dieses Kapitels. RKE2 bringt eine eigene containerd-Instanz mit, an eigenen Pfaden — und generiert deren Konfiguration bei **jedem** Start neu. Anleitungen, die von kubeadm oder einer verwalteten Cloud-Distribution ausgehen,

führen deshalb zu einem Cluster, in dem Pods GPUs zugeteilt bekommen und im Container trotzdem keine sehen.

5.3.1 Die abweichenden Pfade

Was	Bei RKE2
containerd-Socket	/run/k3s/containerd/containerd.sock
Erzeugte Konfiguration	/var/lib/rancher/rke2/agent/etc/containerd/config.toml
Vorlage	dieselbe Datei mit der Endung <code>.tmpl</code>
Standardpfade anderer Distributionen	/run/containerd/containerd.sock und /etc/containerd/config.toml

MERKE Die entscheidende Eigenheit

RKE2 erzeugt `config.toml` bei jedem Start aus der Vorlage `config.toml.tmpl` neu. Jede direkte Änderung an `config.toml` ist nach dem nächsten Neustart verschwunden. Angepasst wird ausschließlich die Vorlage.

Das ist der Punkt, an dem die meisten GPU-Einrichtungen unter RKE2 scheitern – und zwar verzögert: Es funktioniert bis zum nächsten Neustart des Knotens.

5.3.2 Automatische Erkennung

RKE2 nimmt einem in neueren Versionen einen Teil der Arbeit ab: Findet es beim Start eine ausführbare Datei `nvidia-container-runtime` im Suchpfad, trägt es sie selbständig in die containerd-Konfiguration ein und legt eine passende `RuntimeClass` an.

```
kubectrl get runtimeclass
```

Erwartete Ausgabe: Ein Eintrag `nvidia` – gegebenenfalls zusätzlich `nvidia-experimental`. Erscheint nichts, wurde das Container Toolkit entweder nicht installiert oder erst nach dem letzten RKE2-Start.

ACHTUNG Reihenfolge beachten

Die Erkennung findet beim Start des RKE2-Dienstes statt. Wird das Container Toolkit danach installiert, passiert nichts, bis der Dienst neu startet:

```
systemctl restart rke2-server # bzw. rke2-agent
```

5.3.3 Konfiguration des Operators für RKE2

Wird das Toolkit dem Operator überlassen, muss ihm gesagt werden, wo RKE2 seine containerd-Konfiguration erwartet. Diese vier Umgebungsvariablen sind der Kern:

```
toolkit:
  enabled: true
  env:
    - name: CONTAINERD_CONFIG
      value: >-
        /var/lib/rancher/rke2/agent/etc/containerd/config.toml.tmpl
```

```
- name: CONTAINERD_SOCKET
  value: /run/k3s/containerd/containerd.sock
- name: CONTAINERD_RUNTIME_CLASS
  value: nvidia
- name: CONTAINERD_SET_AS_DEFAULT
  value: "true"
```

Beachtenswert ist der erste Wert: Er zeigt auf die **Vorlage**, nicht auf die erzeugte Datei. Genau das ist die Anpassung, die einen Neustart überlebt.

5.3.4 Pod Security Admission

RKE2 wird CIS-gehärtet ausgeliefert und erzwingt Pod-Security-Standards. Die Komponenten des GPU Operators benötigen privilegierte Container — sie laden Kernelmodule und greifen auf Gerätedateien zu. Ohne entsprechende Kennzeichnung des Namensraums werden sie abgewiesen:

```
kubectl create namespace gpu-operator
kubectl label namespace gpu-operator \
  pod-security.kubernetes.io/enforce=privileged
```

CONTAINERD_SET_AS_DEFAULT auf `true` erspart es, in jedem GPU-Pod `runtimeClassName: nvidia` zu setzen. In gemischten Clustern kann es sinnvoller sein, das auf `false` zu lassen und die Klasse explizit anzugeben.

Fehlt dieser Schritt, erscheinen im Ereignisprotokoll Meldungen über verletzte PodSecurity-Regeln — und die DaemonSets bleiben ohne laufende Pods.

5.4 Lab: GPU Operator auf RKE2 ausrollen

LAB Den GPU-Stack im Cluster verfügbar machen

Ziel: Ein Pod mit `nvidia.com/gpu` wird geplant und sieht die GPU tatsächlich.

Voraussetzung: Kapitel 4 abgeschlossen — Treiber und Container Toolkit laufen in der GPU-VM, `nvidia-smi` liefert dort Werte.

Schritt 1 — RuntimeClass prüfen.

```
kubectl get runtimeclass
```

Fehlt der Eintrag `nvidia`, RKE2 auf dem Knoten neu starten und erneut prüfen.

Schritt 2 — Namensraum anlegen und kennzeichnen.

```
kubectl create namespace gpu-operator
kubectl label namespace gpu-operator \
  pod-security.kubernetes.io/enforce=privileged
```

Schritt 3 — Werte-Datei schreiben. Als `gpu-operator-values.yaml`:

```
driver:
  enabled: false           # Treiber liegt auf dem Host
toolkit:
  enabled: false           # Toolkit liegt auf dem Host
devicePlugin:
  enabled: true
dcgmExporter:
  enabled: true             # fuer Kapitel 14
```

```
nfd:
  enabled: true
migManager:
  enabled: false           # keine MIG-faehige Karte
```

Schritt 4 – Ausrollen.

```
helm repo add nvidia https://helm.ngc.nvidia.com/nvidia
helm repo update
helm upgrade --install gpu-operator nvidia/gpu-operator \
  -n gpu-operator \
  -f gpu-operator-values.yaml
```

Schritt 5 – Zustand beobachten.

```
kubectl -n gpu-operator get pods -w
```

Erwartete Ausgabe: Nach einigen Minuten laufen Device Plugin, GFD, DCGM Exporter und die Validator-Pods. Der Validator ist der wichtigste: Er schlägt fehl, wenn irgendein Glied der Kette nicht funktioniert.

Schritt 6 – Kapazität am Knoten prüfen.

```
kubectl get nodes -o custom-columns=\
NAME:.metadata.name,GPU:.status.capacity.nvidia\\.com/gpu
```

Erwartete Ausgabe: Beim GPU-Knoten steht 1, bei allen anderen <none>. Steht dort nichts, meldet das Device Plugin keine Geräte – siehe Troubleshooting.

Schritt 7 – Labels ansehen. Die GPU Feature Discovery beschreibt die Karte:

```
kubectl get node <gpu-node> -o json \
| jq -r '.metadata.labels | to_entries[]
| select(.key|startswith("nvidia.com"))
| "\(.key)=\(.value)"'
```

Erwartete Ausgabe: Unter anderem `nvidia.com/gpu.count`, `nvidia.com/gpu.memory` in Mebibyte, `nvidia.com/gpu.product` mit dem Karten-namen und `nvidia.com/cuda.driver.major`. Diese Labels sind die Grundlage für gezieltes Scheduling.

Schritt 8 – Ende-zu-Ende prüfen.

```
apiVersion: v1
kind: Pod
metadata:
  name: gpu-test
spec:
  restartPolicy: Never
  runtimeClassName: nvidia
  containers:
  - name: test
    image: nvidia/cuda:12.4.1-base-ubuntu22.04
    command: ["nvidia-smi"]
  resources:
```



```
limits:
  nvidia.com/gpu: 1
```

```
kubectl apply -f gpu-test.yaml
kubectl logs gpu-test
```

Erwartete Ausgabe: Die vertraute `nvidia-smi`-Tabelle — diesmal aus einem Pod heraus. Damit ist die Kette von der physischen Karte bis zum Container geschlossen.

Ergebnis: Die GPU ist eine planbare Cluster-Ressource. Ab hier arbeitet man mit Kubernetes-Mitteln, nicht mehr mit Hostwerkzeugen.

5.5 Scheduling: GPU-Knoten sauber trennen

Im Referenz-Lab liegt die GPU auf genau einem Worker. Das ist kein Sonderfall, sondern die Normallage in Unternehmensclustern: wenige teure GPU-Knoten neben vielen gewöhnlichen. Daraus folgt eine Anforderung in beide Richtungen.

MERKE

Zwei getrennte Probleme, zwei getrennte Mechanismen:

GPU-Pods müssen auf GPU-Knoten landen. Das leistet ein `nodeSelector` oder eine `Node-Affinity`.

Gewöhnliche Pods dürfen GPU-Knoten nicht belegen. Das leistet ein `Taint`. Ohne ihn landen beliebige Workloads auf der teuersten Maschine im Cluster und nehmen ihr CPU und Speicher weg — die GPU bleibt frei, aber der Knoten ist voll.

Der zweite Punkt wird häufiger vergessen und ist der teurere Fehler.

LAB GPU-Knoten als eigenen Pool führen

Ziel: Nur GPU-Workloads landen auf dem GPU-Knoten, und sie landen zuverlässig dort.

Schritt 1 — Knoten kennzeichnen und schützen.

```
kubectl label node <gpu-node> node-role/gpu=true
kubectl taint node <gpu-node> \
  nvidia.com/gpu=present:NoSchedule
```

Schritt 2 — Wirkung prüfen. Ein gewöhnlicher Pod ohne Toleranz darf jetzt nicht mehr auf dem Knoten landen:

```
kubectl run test --image=busybox --restart=Never \
  --overrides='{ "spec": { "nodeName": "<gpu-node>" } }' -- sleep 30
kubectl get pod test -o wide
```

Erwartete Ausgabe: Der Pod bleibt in Pending. Unter `kubectl describe pod test` nennt das Ereignisprotokoll den Taint als Grund.

Schritt 3 — GPU-Workload korrekt kennzeichnen.

```
spec:
  runtimeClassName: nvidia
  nodeSelector:
    node-role/gpu: "true"
  tolerations:
    - key: nvidia.com/gpu
      operator: Equal
      value: present
      effect: NoSchedule
  containers:
    - name: inferenz
      resources:
        limits:
          nvidia.com/gpu: 1
```

Schritt 4 – Auf GPU-Typ einschränken. In gemischten Clustern mit verschiedenen Karten wird gezielt ausgewählt:

```
nodeSelector:
  nvidia.com/gpu.product: NVIDIA-GeForce-RTX-4090
```

Oder flexibler über Affinity, wenn mehrere Kartentypen zulässig sind:

```
affinity:
  nodeAffinity:
    requiredDuringSchedulingIgnoredDuringExecution:
      nodeSelectorTerms:
        - matchExpressions:
            - key: nvidia.com/gpu.memory
              operator: Gt
              values: ["20000"]
```

Ergebnis: Der GPU-Knoten ist reserviert, und GPU-Workloads finden ihn zuverlässig. Das ist die Grundlage für alles, was in Kapitel 8 und 10 deployt wird.

5.5.1 Der GPU Operator und der eigene Taint

Ein Detail, das leicht übersehen wird: Auch die DaemonSets des GPU Operators müssen auf dem GPU-Knoten laufen — sonst gibt es dort kein Device Plugin. Sie bringen von Haus aus Toleranzen für `nvidia.com/gpu` mit. Wird ein **anderer** Taint-Schlüssel gewählt, muss er dem Operator bekannt gemacht werden:

```
daemonsets:
  tolerations:
    - key: <eigener-schluesel>
      operator: Exists
      effect: NoSchedule
```

ACHTUNG Das klassische Henne-Ei-Problem

Wird der Taint gesetzt, bevor der Operator ihn toleriert, verschwinden die Operator-Pods vom Knoten — und mit ihnen das Device Plugin. Der Knoten meldet dann

keine GPU mehr, obwohl die Hardware unverändert vorhanden ist. Setzen Sie deshalb entweder den vom Operator bereits tolerierten Schlüssel `nvidia.com/gpu`, oder passen Sie die Toleranzen an, **bevor** Sie den Taint setzen.

5.6 Heterogene Cluster: mehrere GPU-Typen

Sobald ein Cluster wächst, stehen verschiedene Kartentypen nebeneinander — weil nachbeschafft wurde, weil verschiedene Anwendungsfälle verschiedene Karten rechtfertigen, oder weil Cloud-Kapazität zugemietet wird. Damit wird Scheduling zu einer inhaltlichen Frage.

5.6.1 Nach Eigenschaft auswählen, nicht nach Namen

Die naheliegende Lösung — `nodeSelector` auf `nvidia.com/gpu.product` — ist die schlechtere. Sie bindet ein Deployment an ein konkretes Kartenmodell und muss bei jeder Nachbeschaffung angefasst werden.

MERKE

Wählen Sie nach **Eigenschaft**, nicht nach Modellname. Ein Deployment braucht nicht „eine RTX 4090“, sondern „mindestens 20 GiB VRAM“ oder „FP8-fähig“. Diese Anforderungen sind stabil, Modellnamen nicht.

Die GPU Feature Discovery liefert dafür die passenden Labels:

Label	Beispiel	Eignet sich für
<code>nvidia.com/gpu.memory</code>	24564	Speichieranforderung in Mebibyte
<code>nvidia.com/gpu.count</code>	2	Multi-GPU-Workloads
<code>nvidia.com/gpu.product</code>	NVIDIA-L40S	Letzte Wahl — zu spezifisch
<code>nvidia.com/cuda.driver.major</code>	550	Mindest-Treiberversion
<code>nvidia.com/gpu.compute.major</code>	8	Zusammen mit <code>.minor</code> : FP8-Fähigkeit

Eine Anforderung wie „FP8-fähig“ — also Compute Capability 8.9 oder höher aus Kapitel 3 — lässt sich nicht direkt als Vergleich ausdrücken, weil Haupt- und Nebenversion getrennte Labels sind. In der Praxis setzt man deshalb ein eigenes, fachliches Label:

```
kubectl label node <node> plattform/fp8=true
```

Solche selbstvergebenen Fähigkeitslabels sind die robusteste Lösung: Sie beschreiben, was die Plattform zusagt, und entkoppeln Deployments von der Hardwaregeneration.

5.6.2 Modellprofile statt Hardwareprofile

In reifen Plattformen geht man einen Schritt weiter und definiert benannte Profile, die Anwendungsteams anfordern können — ohne dass sie Kartentypen kennen müssen:

Profil	Zusage	Realisiert durch
klein	bis 8B, Kontext 8k	Beliebige Karte ab 20 GiB
gross	bis 32B, Kontext 8k	Karte ab 48 GiB
lang	bis 8B, Kontext 128k	Karte ab 48 GiB, KV-Cache dominiert
schnell	FP8, niedrige Latenz	Ada oder Hopper

Das ist derselbe Gedanke wie bei StorageClasses: Der Nutzer nennt eine Zusage, die Plattform entscheidet, welche Hardware sie erfüllt. Kapitel 17 greift das für die Referenzarchitekturen wieder auf.

5.7 Kontingente für Teams

Ohne Begrenzung kann ein einzelner Namensraum alle GPUs des Clusters belegen. Erweiterte Ressourcen lassen sich wie CPU und Speicher über ResourceQuota begrenzen:

```
apiVersion: v1
kind: ResourceQuota
metadata:
  name: gpu-kontingent
  namespace: team-forschung
spec:
  hard:
    requests.nvidia.com/gpu: "2"
```

Ergänzend verhindert eine LimitRange, dass ein einzelner Pod alles beansprucht:

```
apiVersion: v1
kind: LimitRange
metadata:
  name: gpu-obergrenze
  namespace: team-forschung
spec:
  limits:
    - type: Container
      max:
        nvidia.com/gpu: "1"
```

MERKE

GPU-Kontingente auf Namensraumebene sind grobkörnig: Sie regeln, wie viele **Karten** ein Team belegen darf. Sie regeln nicht, wie viele Anfragen ein Team an einen gemeinsam genutzten Inferenz-Dienst senden darf – das ist eine ganz andere Frage und gehört ins Gateway. Kapitel 11 behandelt sie.

Beide Ebenen werden gebraucht: ResourceQuota für Teams, die **eigene** Modelle betreiben, Gateway-Kontingente für Teams, die einen **gemeinsamen** Dienst nutzen. In reifen Plattformen ist der zweite Fall der häufigere.

5.7.1 Priorität und Verdrängung

Bei knappen GPUs ist die Reihenfolge wichtig. Über PriorityClass lässt sich festlegen, welche Workloads im Zweifel weichen:

```

apiVersion: scheduling.k8s.io/v1
kind: PriorityClass
metadata:
  name: inferenz-produktion
value: 1000000
preemptionPolicy: PreemptLowerPriority
globalDefault: false

```

Ein typisches Muster ist die Trennung in drei Stufen: Produktions-Inferenz verdrängt Entwicklungs-Workloads, und Stapelverarbeitung läuft mit niedrigster Priorität, wenn Kapazität frei ist.

ACHTUNG Verdrängung bei GPU-Workloads ist teuer

Wird ein Inferenz-Pod verdrängt, geht sein gesamter Zustand verloren: Das Modell muss neu geladen werden — Minuten, nicht Sekunden, wie Kapitel 3 vorgerechnet hat. Laufende Anfragen brechen ab, der KV-Cache ist weg.

Verdrängung ist deshalb bei Inferenz-Workloads ein Mittel für den Ausnahmefall, nicht für die Alltagssteuerung. Wer regelmäßig verdrängt, hat ein Kapazitätsproblem, kein Prioritätsproblem.

5.8 Wartung und Knotengesundheit

5.8.1 Einen GPU-Knoten aus dem Betrieb nehmen

Das übliche Vorgehen aus dem Kubernetes-Alltag greift bei Inferenz-Workloads zu kurz, weil das Beenden eines Modell-Pods teuer ist und laufende Anfragen abbricht.

LAB GPU-Knoten geordnet leeren

Ziel: Wartung ohne abgebrochene Anfragen und ohne unnötige Modell-Neuladungen.

Schritt 1 — Knoten sperren. Neue Pods landen nicht mehr dort:

```
kubectl cordon <gpu-node>
```

Schritt 2 — Ersatz hochfahren, bevor verdrängt wird. Bei einem zweiten GPU-Knoten wird die Replikanzahl vorübergehend erhöht, damit die neue Instanz ihr Modell laden kann, während die alte noch bedient:

```

kubectl scale deploy/vllm --replicas=2
kubectl rollout status deploy/vllm --timeout=10m

```

Schritt 3 — Erst danach leeren.

```

kubectl drain <gpu-node> \
  --ignore-daemonsets --delete-emptydir-data \
  --grace-period=120

```

Die Nachfrist ist bewusst großzügig: Sie gibt laufenden Anfragen Zeit, zu Ende zu laufen. Sie wirkt nur, wenn der Pod auch ein passendes `terminationGracePeriodSeconds` gesetzt hat — Kapitel 8 behandelt das.

Schritt 4 – Freigabe prüfen. Auf dem Knoten:

```
nvidia-smi
```

Erwartete Ausgabe: Keine Prozesse in der Prozessliste, Speicherbelegung nahe null. Erst dann lässt sich der Treiber aktualisieren oder der Knoten neu starten.

Schritt 5 – Zurücknehmen.

```
kubectl uncordon <gpu-node>
```

Anschließend die Verifikation aus Kapitel 4 laufen lassen, bevor wieder Last darauf gegeben wird.

ACHTUNG PodDisruptionBudget allein genügt nicht

Ein PodDisruptionBudget verhindert, dass zu viele Repliken gleichzeitig verschwinden — es beschleunigt aber nicht das Hochfahren des Ersatzes. Bei Modellen mit Ladezeiten von Minuten kann ein Budget von `minAvailable: 1` bei nur einer Replik dazu führen, dass `drain` unbegrenzt wartet.

Der verlässliche Weg ist die Reihenfolge aus dem Lab: erst Kapazität schaffen, dann leeren. Bei einer einzelnen GPU im Cluster gibt es diesen Weg nicht — was noch einmal das Argument für den zweiten Knoten aus Kapitel 4 unterstreicht.

5.8.2 Defekte Knoten automatisch erkennen

Kapitel 4 hat gezeigt, dass Xid-Meldungen zwischen Anwendungs- und Hardwarefehlern unterscheiden. Im Cluster sollte diese Unterscheidung Konsequenzen haben, ohne dass jemand Logs liest.

Zwei Bausteine leisten das:

Node Problem Detector Ein DaemonSet, das Kernel-Logs beobachtet und Befunde als `NodeCondition` oder Ereignis in die Kubernetes-API schreibt. Eine passende Regel für Xid-Meldungen lässt sich als Muster hinterlegen.

DCGM-Metriken Der DCGM Exporter liefert unter anderem Zähler für XID-Ereignisse und ECC-Fehler. Daraus lässt sich eine Alarmregel bauen, die einen Knoten markiert. Kapitel 14 zeigt die konkreten Metrikenamen und Regeln.

MERKE

Das Ziel ist eine automatische Absperrung: Meldet ein Knoten einen Hardware-Xid, wird er gesperrt, bevor weitere Inferenz-Pods darauf landen. Ohne diese Automatik wandern Workloads immer wieder auf eine defekte Karte — und die Fehlersuche beginnt bei der Anwendung statt bei der Hardware.

5.8.3 Aufnahmeprüfung für neue GPU-Knoten

Bevor ein Knoten Produktionslast bekommt, sollten neun Punkte erfüllt sein. Diese Liste eignet sich als Vorlage für ein Runbook — Kapitel 16 greift das Thema auf.

1. `nvidia-smi` liefert auf dem Knoten Werte, Treiberversion notiert
2. Persistence Mode aktiv
3. Container Toolkit installiert, `RuntimeClass nvidia` im Cluster vorhanden

4. Bei RKE2: Anpassung liegt in `config.toml.tpl`, nicht in `config.toml`
5. Knoten meldet `nvidia.com/gpu`-Kapazität
6. Labels der GPU Feature Discovery vollständig
7. Taint gesetzt, Operator-DaemonSets laufen trotzdem
8. Testpod mit `nvidia-smi` läuft erfolgreich durch
9. DCGM Exporter liefert Metriken an Prometheus

5.8.4 Kommandoreferenz: GPU-Zustand im Cluster

Aufruf	Zweck
<code>kubectl describe node <n> grep -A5 Capacity</code>	Gemeldete GPU-Kapazität
<code>kubectl get pods -A -o wide grep <n></code>	Was belegt den Knoten
<code>kubectl -n gpu-operator get pods</code>	Zustand der Operator-Komponenten
<code>kubectl -n gpu-operator logs -l app=nvidia-device-plugin-daemonset</code>	Warum keine GPUs gemeldet werden
<code>kubectl get runtimeclass</code>	Ist die NVIDIA-Runtime registriert
<code>kubectl get clusterpolicy -o yaml</code>	Wirksame Operator-Konfiguration

Punkt 4 ist der einzige RKE2-spezifische — und der einzige, der erst beim nächsten Neustart auffällt. Er gehört deshalb ausdrücklich in die Liste.

Für die Frage, welcher Pod welche GPU tatsächlich belegt, hilft ein Blick von beiden Seiten: `nvidia-smi pmon` auf dem Knoten nennt die Prozess-IDs, `kubectl get pods -o wide` die Pods. Der DCGM Exporter verbindet beides und liefert Metriken direkt mit Pod-Bezug — das ist einer der Gründe, ihn auch dann zu betreiben, wenn noch kein vollständiges Monitoring steht.

5.8.5 Was der Validator prüft

Der Validator des GPU Operators ist das nützlichste Diagnosewerkzeug im Cluster, weil er dieselbe Kette wie das Skript aus Kapitel 4 durchläuft — nur von innen.

Stufe	Prüft	Schlägt fehl, wenn
Driver	Kernelmodule geladen, Gerätedateien vorhanden	Treiber fehlt oder passt nicht zum Kernel
Toolkit	NVIDIA-Runtime bei containerd registriert	Konfiguration fehlt — bei RKE2 der häufigste Fall
CUDA	Ein Testcontainer kann CUDA initialisieren	Treiber zu alt für das Testimage
Plugin	Kubelet meldet <code>nvidia.com/gpu</code>	Device Plugin läuft nicht oder findet keine Karte


```
kubectl -n gpu-operator logs -l app=nvidia-operator-validator \
  --all-containers --tail=50
```

Erwartete Ausgabe: Für jede Stufe eine Erfolgsmeldung. Die erste fehlschlagende Stufe benennt die Schicht — und damit den Abschnitt dieses Kapitels oder von Kapitel 4, der weiterhilft.

5.8.6 Was beim Knoten-Neustart passiert

Nach einem Neustart läuft eine Reihenfolge ab, die zu einer wiederkehrenden Fehlerklasse führt: Kubelet meldet sich zurück, bevor Treiber, Toolkit und Device Plugin

einsatzbereit sind. Der Scheduler sieht in diesem Moment noch keine GPU-Kapazität – oder, schlimmer, sie ist bereits gemeldet, während der Stack noch initialisiert.



Die Startreihenfolge nach einem Neustart des GPU-Knotens

MERKE

Zwischen „Knoten ist Ready“ und „Knoten kann GPU-Workloads bedienen“ liegt eine Zeitspanne von einer Minute oder mehr. Ein Inferenz-Pod, der in dieses Fenster fällt, startet mit einer nicht funktionsfähigen GPU und schlägt fehl – oder, unangenehmer, läuft an und findet erst beim ersten CUDA-Aufruf keinen Treiber.

Die saubere Absicherung ist ein Init-Container, der auf die tatsächliche Verfügbarkeit wartet, statt sich auf den Knotenzustand zu verlassen.

```

initContainers:
- name: warte-auf-gpu
  image: nvidia/cuda:12.4.1-base-ubuntu22.04
  command:
  - sh
  - -c
  - |
    for i in $(seq 1 60); do
      nvidia-smi -L && exit 0
      echo "GPU noch nicht bereit ($i)"; sleep 5
    done
    echo "GPU nach 5 Minuten nicht bereit"; exit 1
  resources:
    limits:
      nvidia.com/gpu: 1
  
```

Der Init-Container fordert selbst eine GPU an und prüft sie. Erst wenn das gelingt, startet der eigentliche Inferenz-Container – und beginnt mit dem minutenlangen Laden des Modells, das man nicht zweimal machen möchte.

5.8.7 Den Modell-Cache vorwärmen

Kapitel 3 hat vorgerechnet, dass das Laden eines Modells über das Netz Minuten dauert und von einem lokalen Volume Sekunden. Im Cluster lässt sich das mit einem

DaemonSet umsetzen, das die benötigten Modelle auf jedem GPU-Knoten in ein persistentes Verzeichnis legt, bevor sie gebraucht werden.

Verfahren	Arbeitsweise	Einordnung
hostPath-Cache	Ein Verzeichnis auf dem Knoten wird in alle Modell-Pods gemountet	Einfach, schnell, aber knotengebunden und ohne Zugriffskontrolle
PVC mit ReadOnlyMany	Gemeinsames Volume für alle Knoten	Sauber, erfordert passende Storage-Klasse
Modell im Container-Image	Modell wird ins Image gebacken	Reproduzierbar, aber Images von zweistelliger Gigabyte-Größe
Modell als eigenes Artefakt	Modell wird als OCI-Artefakt bereitgestellt und vom Knoten gecacht	Der Weg, den KServe geht — Kapitel 10

5.8.8 GPU-Auslastung im Cluster ermitteln

Eine Frage, die im Alltag ständig auftaucht: Wie viele GPUs sind überhaupt vergeben? Der folgende Aufruf beantwortet sie ohne Monitoring-Stack:

```
echo "== Kapazitaet =="
kubectl get nodes -o json | jq -r '
  .items[] | select(.status.capacity["nvidia.com/gpu"])
  | "\(.metadata.name)\t\(.status.capacity["nvidia.com/gpu"])" '

echo "== Angefordert =="
kubectl get pods -A -o json | jq -r '
  [ .items[].spec.containers[]?.resources.limits["nvidia.com/gpu"]
    // empty | tonumber ] | add // 0'
```

Für das Referenz-Lab mit einem GPU-Knoten ist der `hostPath-Cache` völlig ausreichend und spart bei jedem Neustart mehrere Minuten.

Erwartete Ausgabe: Die Zahl der vorhandenen und der angeforderten GPUs. Der Abstand zwischen beiden ist die freie Kapazität — allerdings nur in Bezug auf die **Zuteilung**. Wie gut die zugeteilten Karten tatsächlich ausgelastet sind, beantwortet erst DCGM in Kapitel 14. Genau diese Lücke zwischen „vergeben“ und „genutzt“ ist die zentrale FinOps-Frage der Plattform.

5.8.9 Kapazität und Zuteilbarkeit

Ein feiner, aber wichtiger Unterschied: `status.capacity` nennt, was der Knoten **hat**, `status.allocatable` was davon **vergeben werden kann**. Bei CPU und Speicher weichen die Werte ab, weil Kubernetes Reserven für System und Kubelet abzieht. Bei erweiterten Ressourcen sind sie in der Regel gleich — eine GPU lässt sich nicht anteilig reservieren.

Weicht `allocatable` bei GPUs von `capacity` ab, ist das ein Hinweis auf eine als ungesund gemeldete Karte. Das Device Plugin nimmt defekte Geräte aus der Meldung heraus.

5.9 Ausblick: Dynamic Resource Allocation

Das Device-Plugin-Modell hat bekannte Grenzen: Es kennt nur ganze Geräte, keine Eigenschaften, und ein Pod kann nicht ausdrücken, dass er **zwei über NVLink verbundene** GPUs braucht. Genau dafür entsteht mit Dynamic Resource Allocation

ein allgemeineres Modell, das an Storage-Klassen erinnert: Ein Anspruch beschreibt, **was** gebraucht wird, und ein Treiber entscheidet, **welches** Gerät das erfüllt.

Für Produktionsplattformen ist das derzeit noch kein Ersatz, sondern eine Entwicklung, die man beobachten sollte – besonders für Multi-GPU-Szenarien mit Topologianforderungen aus Kapitel 9. Alles in diesem Buch beschriebene Vorgehen bleibt über das Device-Plugin-Modell gültig.

5.10 Den Operator selbst betreiben

Der GPU Operator ist keine Einmalinstallation, sondern eine Komponente mit eigenem Lebenszyklus – und mit der unangenehmen Eigenschaft, dass ein Update Auswirkungen auf die Laufzeitkonfiguration der Knoten hat.

5.10.1 Konfiguration deklarativ halten

Die wirksame Konfiguration liegt in einer ClusterPolicy, die das Helm-Chart erzeugt. Sie lässt sich zwar direkt bearbeiten – aber dann weicht der Clusterzustand von der Werte-Datei ab, und das nächste Helm-Update setzt die Änderung zurück.

```
kubectl get clusterpolicy cluster-policy -o yaml | head -40
```

MERKE

Änderungen gehören ausschließlich in die Werte-Datei des Helm-Charts, und diese gehört ins GitOps-Repository. Die ClusterPolicy ist ein **Ergebnis**, kein Eingabedokument. Wer sie direkt bearbeitet, baut eine Abweichung, die beim nächsten Abgleich verschwindet – meist zum ungünstigsten Zeitpunkt.

Ein passender Ausschnitt für ein ArgoCD-Application-Manifest, das den Operator verwaltet:

```
spec:
  source:
    repoURL: https://helm.ngc.nvidia.com/nvidia
    chart: gpu-operator
    targetRevision: "24.9.2"      # bewusst gebunden
    helm:
      valueFiles: [values.yaml]
  syncPolicy:
    automated:
      selfHeal: true
      prune: false      # DaemonSets nicht loeschen
```

Die Versionsbindung ist hier keine Formalität. Der Operator bringt abgestimmte Versionen von Treiber, Toolkit und Device Plugin mit; ein ungebundenes targetRevision würde bei jedem Abgleich potenziell den Treiber-Stack der GPU-Knoten austauschen.

5.10.2 Was bei einem Operator-Update passiert

ACHTUNG Ein Operator-Update ist ein Knoten-Eingriff

Beim Update werden die DaemonSets neu ausgerollt. Wird dabei das Container Toolkit erneuert, schreibt es die containerd-Konfiguration neu und startet containerd durch – **auf jedem GPU-Knoten**. Alle Container auf diesem Knoten werden dadurch neu gestartet, einschließlich der Inferenz-Pods mit ihren minutenlangen Ladezeiten.

Ein Operator-Update gehört deshalb in ein Wartungsfenster und wird wie ein Knoten-Eingriff behandelt – mit der Reihenfolge aus Abschnitt 5.8: erst Kapazität schaffen, dann eingreifen.

Die Reihenfolge für ein kontrolliertes Update:

1. Freigabenotizen lesen – besonders auf Änderungen an Treiber- und Toolkit-Versionen
2. Auf einem Nicht-Produktionsknoten prüfen, falls vorhanden
3. Ersatzkapazität hochfahren
4. Update ausrollen, Validator abwarten
5. Ende-zu-Ende-Test aus dem Lab in Abschnitt 5.5 wiederholen
6. Erst danach die Ersatzkapazität zurückbauen

5.10.3 Netzwerkanforderungen von GPU-Knoten

Ein Aspekt, der bei der Planung regelmäßig fehlt: GPU-Knoten ziehen ungewöhnlich große Images. Ein CUDA-Basisimage liegt bei mehreren Gigabyte, ein Inferenz-Image mit PyTorch-Abhängigkeiten schnell im zweistelligen Bereich – und das Modell selbst kommt noch dazu.

Artefakt	Größe	Konsequenz
CUDA-Basisimage	2–4 GB	Einmalig je Knoten, danach im Cache
Inferenz-Image mit PyTorch	8–15 GB	Bei jedem Versionswechsel erneut
Modell	5–20 GB	Siehe Modell-Cache in Abschnitt 5.8

MERKE

Ein neuer GPU-Knoten lädt beim ersten Start leicht 30 Gigabyte. Über eine langsame Anbindung oder aus einer entfernten Registry dauert das erheblich – und es passiert genau dann, wenn Kapazität dringend gebraucht wird. Eine Registry im eigenen Rechenzentrum ist deshalb bei GPU-Plattformen kein Komfort, sondern Kapazitätsvorsorge. Kapitel 16 behandelt Harbor in dieser Rolle.

5.11 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Pod bleibt in Pending, Meldung <code>Insufficient nvidia.com/gpu</code>	Alle GPUs sind belegt oder der Knoten meldet keine	<code>kubectl describe node</code> – Abschnitte <code>Capacity</code> und <code>Allocated resources</code>	Belegenden Pod beenden; oder Device Plugin prüfen
Knoten meldet keine	Device Plugin läuft nicht oder findet keine GPU	Logs des Device-Plugin-Pods; <code>nvidia-smi</code> auf dem Knoten	Toleranzen prüfen, Treiber prüfen, Validator-Log lesen

Symptom	Ursache	Diagnose	Behebung
nvidia.com/gpu -Kapazität			
Pod läuft, sieht im Container aber keine GPU	Container Toolkit nicht wirksam oder <code>RuntimeClass</code> fehlt	<code>kubectl get runtimeclass</code> ; containerd-Konfiguration auf dem Knoten	<code>runtimeClassName: nvidia</code> setzen; Toolkit-Konfiguration korrigieren
Funktionierte, bis der Knoten neu gestartet wurde	RKE2 hat <code>config.toml</code> aus der Vorlage neu erzeugt	<code>config.toml</code> auf den NVIDIA-Eintrag prüfen, <code>.tmpl</code> daneben halten	Anpassung in die <code>.tmpl</code> -Datei übernehmen, nicht in die erzeugte Datei
Operator-Pods starten nicht, PodSecurity-Meldungen	Namensraum ist nicht als privilegiert gekennzeichnet	<code>kubectl get events -n gpu-operator</code>	Label <code>pod-security.kubernetes.io/enforce=privileged</code> setzen
Treiber-Pod in Neustartschleife	Host-Treiber vorhanden, Operator will eigenen laden	Log des Treiber-Pods — Meldungen über belegte Module	<code>driver.enabled=false</code> setzen oder Host-Treiber entfernen
Nach Setzen eines Taints verschwindet die GPU-Kapazität	Operator-DaemonSets tolerieren den Taint nicht	<code>kubectl -n gpu-operator get pods -o wide</code> — Knoten fehlt	Toleranz in den Operator-Werten ergänzen
Gewöhnliche Pods belegen den GPU-Knoten	Kein Taint gesetzt	<code>kubectl get pods -A -o wide</code> und nach dem Knoten filtern	Taint setzen und Fremd-Workloads verlagern

5.12 Interviewfragen

INTERVIEWFRAGE

Warum erkennt Kubernetes GPUs nicht automatisch wie CPU und RAM?

Gut ist: GPUs sind erweiterte Ressourcen und benötigen ein Device Plugin.

Senior ist die Begründung aus den Eigenschaften der Hardware: CPU ist komprimierbar und lässt sich drosseln, Speicher lässt sich überbuchen und im Notfall zurückfordern. Eine GPU ist beides nicht — sie wird ganzzahlig und exklusiv vergeben. Deshalb gibt es keine Bruchteile, keine Überbuchung und keine Verdrängung durch den Kernel. Wer ergänzt, dass Request und Limit bei erweiterten Ressourcen zwingend gleich sind, zeigt, dass er das Modell und nicht nur das Werkzeug kennt.

INTERVIEWFRAGE

Was macht der NVIDIA GPU Operator, und was macht das Device Plugin?

Gut ist die Abgrenzung: Das Device Plugin meldet GPUs an das Kubelet, der Operator bündelt und verwaltet den gesamten Stack.

Senior ist die vollständige Liste der Operator-Komponenten – NFD, GFD, Treiber, Toolkit, Device Plugin, DCGM, MIG Manager, Validator – mit der Feststellung, dass Treiber und Toolkit abschaltbar sind und diese Entscheidung von der Knotenzahl abhängt. Dazu die Trennung: Das Device Plugin **entscheidet** über die Zuteilung, das Container Toolkit **setzt sie um**. Fehlt das Toolkit, wird ein Pod erfolgreich geplant und sieht trotzdem keine GPU.

INTERVIEWFRAGE

Sie richten GPUs unter RKE2 ein. Was ist anders als bei kubeadm?

Diese Frage trennt Erfahrung von Anleitungswissen.

Senior nennt drei Punkte. Erstens die abweichenden Pfade: containerd-Socket unter `/run/k3s/`, Konfiguration unter `/var/lib/rancher/rke2/`. Zweitens – und das ist der entscheidende – RKE2 erzeugt `config.toml` bei jedem Start aus einer Vorlage neu; angepasst werden muss deshalb die `.tmpl`-Datei, sonst ist die Änderung nach dem nächsten Neustart weg. Drittens die CIS-Härtung: Der Namensraum des Operators braucht das Label für privilegierte Pods, sonst starten die DaemonSets nicht. Wer ergänzt, dass RKE2 eine vorhandene NVIDIA-Runtime beim Start selbst erkennt und eine `RuntimeClass` anlegt, kennt die Distribution wirklich.

INTERVIEWFRAGE

Wie trennen Sie GPU-Knoten vom übrigen Cluster?

Gut ist: Taints und Tolerations, dazu `nodeSelector`.

Senior ist die Betonung, dass es zwei getrennte Probleme sind – GPU-Pods müssen hinfinden, gewöhnliche Pods müssen ferngehalten werden – und dass der zweite häufiger vergessen wird und teurer ist: Ohne Taint belegen beliebige Workloads CPU und Speicher der teuersten Maschine im Cluster. Ergänzt um die Falle, dass die DaemonSets des Operators den Taint ebenfalls tolerieren müssen, sonst verschwindet mit dem Device Plugin auch die GPU-Kapazität.

INTERVIEWFRAGE

Ein Pod hat eine GPU zugeteilt bekommen, sieht im Container aber keine. Wo suchen Sie?

Senior ist ein geordnetes Vorgehen entlang der Kette aus Kapitel 4: Meldet der Knoten Kapazität? Dann arbeitet das Device Plugin. Läuft der Pod mit der richtigen `RuntimeClass` – oder ist die NVIDIA-Runtime als Standard gesetzt? Ist die containerd-Konfiguration auf dem Knoten tatsächlich angepasst? Bei RKE2 gehört hier die Zusatzfrage dazu, ob der Knoten seit der Anpassung neu gestartet wurde – denn dann ist die Änderung möglicherweise aus der Vorlage überschrieben worden.

5.13 Zusammenfassung

- GPUs sind in Kubernetes erweiterte Ressourcen: ganzzahlig, exklusiv, nicht überbuchbar. Request und Limit sind zwingend gleich.
- Ein Device Plugin meldet die GPUs an das Kubelet und liefert bei der Zuteilung die Angaben, mit denen das Container Toolkit die Karte in den Container einblendet. Beide Bausteine werden gebraucht.
- Der GPU Operator bündelt NFD, GFD, Treiber, Toolkit, Device Plugin, DCGM, MIG Manager und Validator. Treiber und Toolkit sind abschaltbar – bei vorhandenem Host-Treiber müssen sie es sein.
- Unter RKE2 liegen containerd-Socket und Konfiguration an eigenen Pfaden, und die Konfiguration wird bei jedem Start aus einer Vorlage neu erzeugt. Angepasst wird ausschließlich die `.tmpl`-Datei.
- RKE2 ist CIS-gehärtet: Der Namensraum des Operators braucht das Label für privilegierte Pods.
- GPU-Knoten werden in beide Richtungen getrennt: `nodeSelector` führt GPU-Pods hin, ein Taint hält andere fern. Die DaemonSets des Operators müssen den Taint tolerieren.
- `ResourceQuota` begrenzt GPUs je Namensraum. Anfragekontingente für einen gemeinsam genutzten Dienst gehören dagegen ins Gateway – zwei verschiedene Ebenen.
- Verdrängung ist bei Inferenz teuer, weil das Modell neu geladen werden muss. Wer regelmäßig verdrängt, hat ein Kapazitäts-, kein Prioritätsproblem.

Quellen und Weiterlesen

- Kubernetes: *Device Plugins* und *Schedule GPUs* – das zugrunde liegende Modell erweiterter Ressourcen.
- NVIDIA: *GPU Operator Documentation*, insbesondere die Abschnitte zur ClusterPolicy und zu den unterstützten Kubernetes-Distributionen.
- Rancher: *RKE2 Documentation – Advanced Options*, Abschnitt zur containerd-Konfiguration und zur automatischen Erkennung von NVIDIA-Runtimes.
- Kubernetes: *Pod Security Standards* – Hintergrund zur Kennzeichnung des Operator-Namensraums.
- Kubernetes Enhancement Proposal zu *Dynamic Resource Allocation* – der Nachfolger des Device-Plugin-Modells.

GPU-Sharing und Multi-Tenancy

ZIEL

Die drei Verfahren zur Aufteilung einer GPU nach ihren tatsächlichen Isolationszusagen unterscheiden – und entscheiden können, welches für einen gegebenen Mehrmandantenfall trägt.

SETZT VORAUS

Kapitel 5: GPU Operator läuft, Knoten meldet Kapazität.

DANACH KANNST DU

Time-Slicing konfigurieren und seine Grenzen praktisch demonstrieren, MIG und MPS begründet einordnen, und für eine Mehrmandantenanforderung das passende Verfahren auswählen – einschließlich der Fälle, in denen keines davon die Antwort ist.

GESCHRIEBEN GEGEN

GPU Operator 24.x · Kubernetes 1.31 · Referenz-GPU RTX, 24 GiB --- kein MIG · Stand September 2026

Kapitel 5 endete mit einer harten Grenze: Eine GPU gehört genau einem Pod. Für einen Cluster mit wenigen Karten und mehreren Teams ist das unbefriedigend. Dieses Kapitel behandelt die Verfahren, die diese Grenze aufweichen – und die Frage, die dabei entscheidend ist und selten gestellt wird: **Was genau isoliert das Verfahren eigentlich?**

6.1 Was Isolation bedeutet

Bevor die Verfahren einzeln behandelt werden, lohnt eine Präzisierung. „Zwei Teams teilen sich eine GPU“ kann drei sehr verschiedene Dinge bedeuten:

Dimension	Frage	Konsequenz bei fehlender Isolation
Rechenzeit	Kann ein Mandant den anderen ausbremsen?	Unvorhersagbare Latenz, keine Leistungszusage möglich
Speicher	Kann ein Mandant dem anderen VRAM wegnehmen?	Der andere stürzt mit Out-of-Memory ab – ohne eigenes Verschulden
Fehler	Wirkt sich ein Absturz auf den anderen aus?	Ein fehlerhafter Kernel reißt fremde Prozesse mit

MERKE

Die zweite Zeile ist die wichtigste und wird am häufigsten übersehen. Ein Verfahren, das Rechenzeit teilt, aber Speicher nicht isoliert, ist für Mehrmandantenbetrieb ungeeignet – unabhängig davon, wie gut es im Lasttest aussieht. Der Ausfall tritt erst auf, wenn


zwei Mandanten gleichzeitig große Modelle laden, und er trifft den, der zufällig als Zweiter kommt.

6.2 Time-Slicing

6.2.1 Wie es funktioniert

Time-Slicing ist das einfachste Verfahren: Der Treiber schaltet zwischen den Kontexten verschiedener Prozesse um – vergleichbar mit dem Zeitscheibenverfahren eines Betriebssystems für CPUs. Jeder Prozess bekommt abwechselnd die ganze GPU.

Auf Kubernetes-Ebene wird das darüber abgebildet, dass das Device Plugin dieselbe physische Karte **mehrfach** meldet:



Time-Slicing: eine Karte, mehrere gemeldete Ressourcen, ein gemeinsamer Speicher

6.2.2 Konfiguration über den GPU Operator

Die Einstellung erfolgt über eine ConfigMap, auf die die ClusterPolicy verweist:

```

apiVersion: v1
kind: ConfigMap
metadata:
  name: time-slicing
  namespace: gpu-operator
data:
  any: |-
    version: v1
    flags:
      migStrategy: none
    sharing:
      timeSlicing:
        resources:
          - name: nvidia.com/gpu
            replicas: 4
  
```

In den Helm-Werten wird sie aktiviert:

```

devicePlugin:
  config:
  
```



```
name: time-slicing
default: any
```

Der Schlüssel `any` ist ein benannter Satz von Einstellungen. Über Knoten-Labels lassen sich verschiedene Sätze auf verschiedene Knoten anwenden — etwa vier Replikate auf Entwicklungsknoten und keine auf Produktionsknoten.

6.3 Lab: Time-Slicing und seine Grenze

Dieses Lab hat zwei Teile. Der erste zeigt, dass Time-Slicing funktioniert. Der zweite zeigt, warum man ihm nicht trauen darf.

Der Wert `replicas` ist reine Buchführung. Er ändert nichts an der Hardware und schon gar nichts am verfügbaren Speicher — er ändert nur, wie oft Kubernetes dieselbe Karte vergeben darf.

LAB Time-Slicing aktivieren und Speicherisolation prüfen

Ziel: Vier Pods auf einer Karte betreiben — und den Ausfall herbeiführen, der in Produktion irgendwann von selbst kommt.

Schritt 1 — Konfiguration anwenden.

```
kubectl apply -f time-slicing.yaml
helm upgrade gpu-operator nvidia/gpu-operator \
  -n gpu-operator --reuse-values \
  --set devicePlugin.config.name=time-slicing \
  --set devicePlugin.config.default=any
```

Schritt 2 — Wirkung prüfen.

```
kubectl get node <gpu-node> -o jsonpath=\
'{".status.capacity.nvidia\.com/gpu":{"\n"}}'
```

Erwartete Ausgabe: 4 statt vorher 1. Das Label `nvidia.com/gpu.replicas` am Knoten bestätigt die Aufteilung.

Schritt 3 — Vier kleine Pods starten. Jeder belegt wenig Speicher:

```
for i in 1 2 3 4; do
  kubectl run tsl-$i --restart=Never \
    --image=nvidia/cuda:12.4.1-base-ubuntu22.04 \
    --overrides='{"spec":{"runtimeClassName":"nvidia"}}' \
    --limits=nvidia.com/gpu=1 -- nvidia-smi -L
done
kubectl get pods -l run
```

Erwartete Ausgabe: Alle vier Pods laufen durch. Bemerkenswert: Jeder meldet **die-selbe** GPU-UUID. Das ist der Beweis, dass es sich um eine Karte handelt — nicht um vier.

Schritt 4 — Der eigentliche Test. Zwei Pods, die je viel Speicher belegen wollen:

```
apiVersion: v1
kind: Pod
metadata:
  name: speicherfresser
spec:
  restartPolicy: Never
  runtimeClassName: nvidia
```

```
containers:
  - name: t
    image: pytorch/pytorch:2.4.0-cuda12.4-cudnn9-runtime
    command: ["python", "-c"]
    args:
      - |
        import torch, time
        n = 15 * 1024**3 // 2      # ~15 GiB in FP16
        x = torch.empty(n, dtype=torch.float16,
                        device="cuda")
        gib = torch.cuda.memory_allocated() // 2**30
        print("belegt:", gib, "GiB")
        time.sleep(600)
resources:
  limits:
    nvidia.com/gpu: 1
```

Starten Sie diesen Pod zweimal unter verschiedenen Namen.

Erwartete Ausgabe: Der erste Pod meldet die Belegung und läuft. Der zweite bricht ab mit `torch.OutOfMemoryError: CUDA out of memory` – obwohl Kubernetes ihm ordnungsgemäß eine „GPU“ zugeteilt hat und der Pod aus Sicht des Clusters völlig gesund ist.

Ergebnis: Sie haben den Ausfall reproduziert, der in Produktion unvorhersehbar auftritt. Kubernetes hat korrekt geplant, das Device Plugin hat korrekt zugeteilt – und trotzdem stirbt der zweite Mandant an einer Ressource, die niemand begrenzt hat.

Aufräumen:

```
kubectl delete pod -l run --ignore-not-found
kubectl delete pod speicherfresser-1 speicherfresser-2
```

ACHTUNG Die Betriebsregel, die daraus folgt

Time-Slicing ist geeignet für **Entwicklungs- und Testumgebungen**, in denen mehrere kleine Workloads eine Karte teilen und ein gelegentlicher Ausfall hinnehmbar ist. Für Mehrmandantenbetrieb mit Zusagen ist es **ungeeignet**. Wer es dort einsetzt, baut eine Plattform, die im Lasttest funktioniert und in Produktion sporadisch ausfällt – mit einem Fehlerbild, das der Anwendung zugeschrieben wird, obwohl die Plattform die Ursache ist.

6.3.1 Was Time-Slicing zusätzlich kostet

Neben der fehlenden Speicherisolation hat das Verfahren zwei weitere Eigenschaften, die man kennen sollte:


Kontextwechsel kosten Zeit Der Wechsel zwischen Prozessen ist nicht kostenlos. Bei vielen Replikaten und rechenintensiven Kernen sinkt der Gesamtdurchsatz gegenüber einem einzelnen Prozess spürbar.

Keine Ausführungsparallelität Die Prozesse laufen nicht gleichzeitig, sondern abwechselnd. Ein Pod, der die GPU nicht auslastet, verschenkt seine Zeitscheibe – ein anderer kann sie nicht nutzen. Genau hier setzt MPS an.

6.4 MPS – Multi-Process Service

6.4.1 Der Unterschied zu Time-Slicing

MPS lässt mehrere Prozesse ihre Kernel in einem **gemeinsamen** GPU-Kontext ausführen. Damit laufen sie tatsächlich gleichzeitig, statt sich abzuwechseln.



Time-Slicing gegenüber MPS bei drei Prozessen, die die GPU nur teilweise auslasten

Für Workloads, die eine GPU einzeln nicht auslasten – kleine Modelle, kurze Anfragen, Einbettungsdienste – ist der Unterschied erheblich.

6.4.2 Konfiguration und Grenzen

Der GPU Operator unterstützt MPS analog zum Time-Slicing:

```
sharing:
  mps:
    resources:
      - name: nvidia.com/gpu
        replicas: 4
```

MPS bietet zusätzlich die Möglichkeit, den Speicher je Client zu begrenzen. Das schließt die größte Lücke des Time-Slicing – allerdings nicht vollständig:

Eigenschaft	Bewertung
Rechenzeit	Echte Parallelität, bessere Auslastung als Time-Slicing
Speicher	Begrenzbar je Client – deutlich besser als Time-Slicing, aber keine hardwareseitig erzwungene Trennung
Fehlerisolation	Schlechter als Time-Slicing. Ein schwerwiegender Fehler in einem Client kann den gemeinsamen MPS-Server treffen und damit alle Clients
Hardware	Keine besondere Voraussetzung

MERKE

MPS tauscht Fehlerisolation gegen Auslastung. Für vertrauenswürdige Workloads desselben Teams ist das ein gutes Geschäft. Für Mandanten, die einander nicht vertrauen, ist es das falsche Verfahren – ein fehlerhafter Kernel eines Mandanten kann die anderen mitreißen.

6.5 MIG – Multi-Instance GPU

MIG steht auf der Referenzhardware dieses Buches nicht zur Verfügung: Es setzt eine Rechenzentrumskarte ab der A100-Generation voraus. Dieser Abschnitt ist deshalb Konzept und Konfigurationsreferenz – beides braucht man in Interviews und in Kundenumgebungen.

6.5.1 Was MIG tatsächlich tut

MIG teilt die GPU auf **Hardwareebene** auf. Nicht die Zeit wird geteilt, sondern die Bausteine: Rechenwerke, Speicherbereiche, Speichercontroller und Anteile des L2-Caches werden fest zugeordnet.

OHNE MIG	MIT MIG (Beispiel: 3 Instanzen)		
Alle Rechenwerke	SM 1-2	SM 3-4	SM 5-7
Gesamter L2-Cache	L2-Teil	L2-Teil	L2-Teil
Gesamter Speicher	10 GiB	10 GiB	20 GiB
Alle Speichercontroller	eigene	eigene	eigene
ein Prozess bekommt alles	drei Prozesse, echte Trennung Ein Absturz betrifft nur die eigene Instanz.		

MIG teilt die Hardware selbst, nicht deren Nutzung über die Zeit

Daraus folgt die entscheidende Eigenschaft: **MIG ist das einzige Verfahren mit echter Speicher- und Fehlerisolation.** Eine Instanz kann einer anderen weder Speicher wegnehmen noch sie zum Absturz bringen.

6.5.2 Profile und Notation

MIG-Profile werden als <Rechenanteile>g.<Speicher>gb benannt. Die verfügbaren Profile hängen vom Kartenmodell ab:

Profil	Anzahl	Speicher	Typische Nutzung
1g.10gb	bis 7	10 GiB	Kleine Modelle, Einbettungsdienste, Notebooks
2g.20gb	bis 3	20 GiB	Modelle bis etwa 8B quantisiert
3g.40gb	bis 2	40 GiB	Größere Modelle mit brauchbarem KV-Cache
7g.80gb	1	80 GiB	Ganze Karte – entspricht MIG-frei

Die Werte beziehen sich auf eine 80-GiB-Karte. Verbindlich ist immer die Abfrage auf der konkreten Hardware:

```
nvidia-smi mig -lgip    # verfügbare Profile
nvidia-smi mig -lgi     # eingerichtete Instanzen
```

ACHTUNG Der KV-Cache begrenzt auch hier

Ein `1g.10gb`-Profil hat 10 GiB. Nach der Bilanz aus Kapitel 3 bleiben nach einem 4-Bit-Modell von 5,7 GiB und rund 1,3 GiB Grundlast etwa 3 GiB für den KV-Cache – bei 128 KiB je Token also rund 24 000 Token. Das reicht für einige wenige gleichzeitige Anfragen mit moderatem Kontext.

MIG-Profile werden deshalb nicht nach Bauchgefühl gewählt, sondern mit derselben Rechnung wie eine ganze Karte. Ein zu kleines Profil ergibt eine Instanz, die formal läuft und praktisch nichts leistet.

6.5.3 MIG unter Kubernetes

Der GPU Operator bringt einen MIG Manager mit, der die Aufteilung anhand eines Knoten-Labels vornimmt:

```
kubectl label node <node> \
  nvidia.com/mig.config=all-1g.10gb --overwrite
```

Zwei Meldestrategien stehen zur Wahl:

Strategie	Meldung an Kubernetes	Einordnung
single	Alle Instanzen als <code>nvidia.com/gpu</code>	Einfach. Setzt voraus, dass alle Instanzen dasselbe Profil haben.
mixed	Je Profil eine eigene Ressource, etwa <code>nvidia.com/mig-1g.10gb</code>	Erlaubt gemischte Profile. Pods fordern gezielt ein Profil an.

ACHTUNG Umkonfiguration erfordert eine leere GPU

Die MIG-Aufteilung lässt sich nur ändern, wenn **kein** Prozess die Karte nutzt. Der MIG Manager sperrt den Knoten dafür selbständig und leert ihn – was bei laufenden Inferenz-Diensten einen Ausfall bedeutet.

MIG-Profile sind deshalb eine Kapazitätsentscheidung mit langer Halbwertszeit, keine Stellschraube für den Tagesbetrieb. Sie werden bei der Einrichtung festgelegt und selten geändert.

6.5.4 Was man mit MIG verliert

MIG ist nicht kostenlos, und die Nachteile werden in Übersichtsdarstellungen selten genannt:

- Instanzen können **nicht** zusammenarbeiten. Tensor Parallelism über zwei MIG-Instanzen derselben Karte ist nicht möglich – die Direktverbindung zwischen ihnen fehlt.
- Die Aufteilung ist grob. Eine 80-GiB-Karte lässt sich nicht in fünf gleiche Teile zerlegen, sondern nur in die vorgesehenen Profile.
- Ungenutzte Kapazität einer Instanz bleibt ungenutzt. Anders als beim Time-Slicing kann eine leerlaufende Instanz ihre Rechenwerke nicht abgeben.
- Nicht jede Funktion steht in einer MIG-Instanz zur Verfügung.

MERKE

MIG tauscht Auslastung gegen Garantien. Wer sieben Instanzen einrichtet, von denen drei im Leerlauf sind, nutzt die Karte schlechter als ein einzelner Inferenz-Server

mit Continuous Batching. Der Grund für MIG ist deshalb fast nie Effizienz, sondern **Zusicherung** – gegenüber Mandanten, die sich nicht vertrauen, oder gegenüber Anwendungen mit harten Latenzzusagen.


6.6 Die Vergleichsmatrix

	Time-Slicing	MPS	MIG	Ein Server, viele Anfragen
Rechenzeit	zeitgeteilt	echt parallel	fest zugeteilt	gemeinsam, gebatcht
Speicher	keine Trennung	begrenzbar	hart getrennt	ein Prozess, kein Konflikt
Fehlerisolation	teilweise	schwach	vollständig	entfällt
Auslastung	mittel	gut	je nach Beladung	am besten
Hardware	beliebig	beliebig	A100 und neuer	beliebig
Umkonfiguration	Plugin-Neustart	Plugin-Neustart	GPU muss leer sein	entfällt
Verschiedene Modelle	ja	ja	ja	nein – ein Modell
Mandantentrennung	nein	eingeschränkt	ja	im Gateway

Option	Geeignet, wenn	Ungeeignet, wenn
Ein gemeinsamer Inferenz-Server	Mehrere Teams nutzen dasselbe Modell. Der mit Abstand häufigste Fall – und der effizienteste. Trennung erfolgt über Kontingente im Gateway.	Wenn verschiedene Modelle gebraucht werden.
MIG	Verschiedene Modelle und Mandanten, die einander nicht vertrauen, und Hardware ab A100. Der einzige Weg mit echten Zusicherungen.	Auf Consumer-Hardware, oder wenn die Profile nicht zum Speicherbedarf passen.
MPS	Mehrere kleine Workloads desselben Teams, die eine Karte einzeln nicht auslasten – etwa Einbettungsdienste neben einem kleinen Sprachmodell.	Bei Mandanten, die einander nicht vertrauen – die Fehlerisolation trägt nicht.
Time-Slicing	Entwicklungs- und Testumgebungen, Notebooks, Schulungcluster. Überall dort, wo ein gelegentlicher Ausfall hinnehmbar ist.	In jedem Betrieb mit Zusagen. Die fehlende Speichertrennung ist nicht behebbar.
Gar keine Aufteilung	Wenn ein Modell die Karte ohnehin ausfüllt – der Regelfall bei ernsthafter Inferenz. Kapitel 3 hat gezeigt, wie schnell 24 GiB voll sind.	Wenn tatsächlich mehrere kleine, unabhängige Workloads existieren.

6.7 Ein Entscheidungsbaum

Die Auswahl lässt sich auf fünf Fragen zurückführen. Die Reihenfolge ist wichtig: Jede Frage schließt Möglichkeiten aus, und die erste beantwortet die meisten Fälle bereits.



Entscheidungsweg für die Aufteilung einer GPU

6.8 Der Fall, für den Time-Slicing gebaut ist

Time-Slicing wurde in diesem Kapitel kritisch behandelt — aber es hat einen Anwendungsfall, in dem es die richtige Wahl ist und in vielen Organisationen gebraucht wird: den Entwicklungs-, Notebook- oder Schulungscluster.

Dort sind die Bedingungen andere: Die Nutzer gehören derselben Organisation, die Workloads sind klein, und ein gelegentlicher Ausfall kostet Zeit, aber keine Geschäftsprozesse.

LAB Einen Notebook-Cluster mit geteilter GPU einrichten

Ziel: Mehrere Entwickler teilen sich eine Karte, ohne dass ein Einzelner alles belegt.

Schritt 1 — Getrennter Knotensatz. Entwicklungsknoten bekommen ein eigenes Label und einen eigenen Sharing-Satz, damit Produktionsknoten unberührt bleiben:

```
kubectl label node <dev-node> plattform/gpu-profil=geteilt
```

In der ConfigMap wird ein zweiter benannter Satz ergänzt:

```
data:
  keine: |-
    version: v1
    sharing:
      timeSlicing:
        resources: []
  geteilt: |-
    version: v1
    sharing:
      timeSlicing:
        resources:
          - name: nvidia.com/gpu
            replicas: 4
```

Die Zuordnung erfolgt über ein Knoten-Label, das der Operator auswertet:

```
kubectl label node <dev-node> \
  nvidia.com/device-plugin.config=geteilt --overwrite
```

Schritt 2 — Kontingent je Nutzer. Ein Namensraum je Person oder Team, mit einem Kontingent, das die Überbelegung begrenzt:

```
apiVersion: v1
kind: ResourceQuota
metadata:
  name: notebook-kontingent
spec:
  hard:
    requests.nvidia.com/gpu: "1"
    count/pods: "3"
```

Schritt 3 — Speicherdisziplin erzwingen. Weil Time-Slicing keine Speichergrenze kennt, muss sie auf Anwendungsebene kommen. Für PyTorch-Notebooks lässt sich das über eine Umgebungsvariable im Pod-Template vorgeben:

```
env:
  - name: PYTORCH_CUDA_ALLOC_CONF
    value: "max_split_size_mb:512"
  - name: HINWEIS
    value: "Bitte set_per_process_memory_fraction nutzen"
```

Das ist ausdrücklich eine **Vereinbarung**, keine Durchsetzung — ein Nutzer kann sie umgehen. Genau darin liegt der Unterschied zu MIG.

Schritt 4 – Aufräumen automatisieren. Vergessene Notebooks sind in Schulungsclustern die häufigste Ursache belegter GPUs. Ein `activeDeadlineSeconds` im Pod oder ein regelmäßiger Aufräumauftrag verhindert das:

```
spec:
  activeDeadlineSeconds: 28800    # 8 Stunden
```

Ergebnis: Vier Entwickler teilen sich eine Karte. Die Aufteilung ist nicht erzwungen, aber gerahmt – durch Kontingente, Konventionen und automatisches Aufräumen. Für diesen Anwendungsfall genügt das.

MERKE

Der Unterschied zwischen einem Schulungscluster und einer Produktionsplattform ist nicht die Technik, sondern die Frage, wer die Folgen eines Ausfalls trägt. Wo die Nutzer sich kennen und ein Absturz nur den Nachmittag kostet, sind Vereinbarungen ausreichend. Wo Anwendungen mit Zusagen laufen, braucht es Durchsetzung – und die gibt es nur in Hardware.

6.9 Kostenzuordnung bei geteilten Karten

Die Frage taucht spätestens auf, wenn das Controlling nach der Verteilung fragt. Sie hat je nach Verfahren eine andere Antwort.

Verfahren	Zuordnungsschlüssel	Belastbarkeit
Keine Aufteilung	Ganze Karte je Team – trivial	hoch
MIG	Anteil der Instanz an der Karte, etwa 1/7 bei 1g . 10gb	hoch
Time-Slicing	Kein technischer Schlüssel vorhanden	keine – nur über die Anwendungsschicht
MPS	Speicheranteil je Client als Näherung	mittel
Gemeinsamer Server	Token je Team aus dem Gateway	hoch

MERKE

Die letzte Zeile ist die interessanteste. Bei einem gemeinsamen Inferenz-Dienst ist die Kostenzuordnung nicht schwieriger, sondern **genauer** als bei aufgeteilten Karten: Das Gateway zählt Token je Team, und die Kosten der Karte lassen sich exakt darauf verteilen.

Das ist ein weiteres, selten genanntes Argument gegen die Aufteilung: Eine geteilte Karte im Time-Slicing-Betrieb lässt sich überhaupt nicht sauber abrechnen. Kapitel 14 entwickelt das Kostenmodell vollständig.

6.10 Wenn Time-Slicing nicht mehr trägt

Der übliche Weg einer wachsenden Plattform verläuft in drei Stufen, und der Übergang zwischen ihnen ist planbar.

Stufe	Verfahren	Auslöser für den Wechsel	Aufwand
1	Time-Slicing im Entwicklungscluster	Erste produktive Anwendung mit Latenzusage	–
2	Getrennte Karten je Modell	Zu viele Modelle für die vorhandenen Karten	Beschaffung
3	MIG für die aufgeteilten Karten	Mandanten, die einander nicht vertrauen	Hardwarewechsel

Der Übergang von Stufe 1 auf 2 ist der wichtigste und wird oft zu spät vollzogen – meist deshalb, weil das Time-Slicing „bisher funktioniert hat“. Der auslösende Vorfall ist typischerweise genau der aus dem Lab in Abschnitt 6.3: Ein Pod stirbt an Out-of-Memory, ohne dass an ihm etwas falsch ist.

ACHTUNG Der Wechsel ist keine reine Konfigurationsänderung

Von Time-Slicing auf getrennte Karten umzustellen bedeutet, dass die vorher vierfach gemeldete Kapazität auf ein Viertel fällt. Alles, was bisher lief, passt danach nicht mehr gleichzeitig auf den Cluster.

Die Umstellung gehört deshalb mit einer Kapazitätsrechnung nach Kapitel 2 vorbereitet – und nicht als Reaktion auf einen Vorfall am selben Tag durchgeführt.

6.11 Multi-Tenancy in der Praxis

6.11.1 Die Frage hinter der Frage

Wenn ein Team „wir brauchen GPU-Sharing“ sagt, steht dahinter meist eine von drei Anforderungen – und nur eine davon wird tatsächlich durch GPU-Aufteilung gelöst:

Geäußerte Anforderung	Tatsächliches Bedürfnis	Richtige Lösung
„Jedes Team braucht eine eigene GPU“	Zugesicherter Zugriff ohne Warteschlange	Kontingente im Gateway
„Wir wollen unser eigenes Modell betreiben“	Ein anderes Modell als das der Plattform	Eigene Instanz – MIG oder eigene Karte
„Die anderen bremsen uns aus“	Vorhersagbare Latenz	Prioritäten und Kontingente, notfalls MIG

MERKE

Die erste Zeile ist der häufigste Fall und wird am häufigsten falsch beantwortet. Ein Team, das dasselbe Modell nutzt wie alle anderen, braucht keine eigene GPU – es braucht die Zusicherung, dass seine Anfragen bedient werden. Diese Zusicherung gehört ins Gateway, wo sie sich als Anfragen und Token je Minute ausdrücken lässt, statt als Hardware.

Eine GPU je Team ist fast immer die teuerste und schlechteste Antwort: Sie vervielfacht die Hardware und verschlechtert gleichzeitig die Auslastung, weil jede Karte ihr eigenes Modell vorhalten muss.

6.11.2 Der laute Nachbar

Wo geteilt wird, gibt es das Problem des lauten Nachbarn. Bei GPUs hat es eine besondere Ausprägung, weil die Wirkung asymmetrisch ist:

- Ein Mandant mit **vielen kleinen** Anfragen stört kaum — Continuous Batching fängt das auf.
- Ein Mandant mit **sehr langen Prompts** blockiert alle anderen, wie Kapitel 2 am Head-of-Line-Blocking gezeigt hat.
- Ein Mandant mit **sehr langem Kontext** belegt unverhältnismäßig viel KV-Cache und reduziert die mögliche Gleichzeitigkeit für alle.

Die wirksamen Gegenmaßnahmen liegen deshalb nicht auf GPU-Ebene, sondern im Gateway: Obergrenzen für Prompt- und Ausgabelänge, Kontingente je Team, und im Zweifel getrennte Endpunkte für Lastprofile, die sich nicht vertragen. Kapitel 11 setzt das um.

6.12 Zwei Wege außerhalb des NVIDIA-Stacks

Die drei bisher behandelten Verfahren stammen alle von NVIDIA. Zwei weitere Ansätze sind für Plattformbetreiber relevant — der eine, weil er auf einer anderen Schicht ansetzt, der andere, weil er genau die Lücke schließt, die das Lab in Abschnitt 6.3 aufgezeigt hat.

6.12.1 vGPU auf Hypervisor-Ebene


In virtualisierten Umgebungen — VMware, Nutanix, Proxmox — lässt sich eine GPU auch unterhalb von Kubernetes aufteilen. NVIDIA vGPU stellt jeder virtuellen Maschine ein eigenes Profil mit **fest zugewiesenem** Bildspeicher bereit.

Eigenschaft	Bewertung
Speicherisolation	Fest zugewiesen je VM — deutlich besser als Time-Slicing
Rechenzeit	Zeitgeteilt zwischen den VMs
Ebene	Hypervisor — Kubernetes sieht in jeder VM eine „ganze“ GPU
Voraussetzung	Rechenzentrumskarte und kostenpflichtige Lizenz
Passthrough-Vergleich	Passthrough gibt einer VM alles, vGPU teilt auf mehrere auf

Für das Referenz-Lab entfällt vGPU: Consumer-Karten unterstützen es nicht. In Kundenumgebungen mit vorhandener Virtualisierung und Rechenzentrumskarten ist es dagegen eine ernstzunehmende Option — besonders dort, wo die Mandantentrennung ohnehin auf VM-Ebene gezogen wird und nicht auf Namensraumbene.

6.12.2 Speicherbewusstes Sharing über Drittanbieter

Das Lab hat gezeigt, dass Time-Slicing keine Speichergrenze kennt. Genau hier setzen Projekte an, die eine zusätzliche Schicht zwischen Anwendung und CUDA-Treiber legen und Speicheranforderungen dort abfangen.



Speicherbewusstes Sharing durch Abfangen der CUDA-Aufrufe

Solche Lösungen melden zusätzliche Ressourcen an Kubernetes — typischerweise getrennt nach Speicher und Rechenanteil — sodass ein Pod ausdrücken kann, dass er etwa acht Gigabyte VRAM und dreißig Prozent der Rechenleistung braucht.

Vorteil	Preis
Speichergrenzen auf beliebiger Hardware — auch auf Consumer-Karten	Zusätzliche Schicht zwischen Anwendung und Treiber
Feinere Aufteilung als MIG-Profile erlauben	Kompatibilität muss je CUDA- und Treiberversion geprüft werden
Keine Lizenzkosten	Fehlerisolation bleibt schwächer als bei MIG — die Trennung ist nicht in Hardware

ACHTUNG Abwägung für Produktionsplattformen

Eine Abfangbibliothek liegt im kritischen Pfad jedes CUDA-Aufrufs. Das ist eine bewusste Entscheidung: Sie löst ein reales Problem, führt aber eine Komponente ein, die bei jedem Treiber- und CUDA-Update erneut zu prüfen ist — und die bei Fehlern zwischen Anwendung und NVIDIA-Stack steht, also genau dort, wo Fehlersuche ohnehin schwierig ist.

Für Entwicklungs- und Schulungscluster ist der Gewinn meist größer als das Risiko. Für produktive Mandantentrennung mit Zusagen bleibt MIG die belastbarere Antwort — wo die Hardware es hergibt.

6.13 Beobachtbarkeit bei geteilten GPUs

Sobald eine Karte geteilt wird, wird die Frage „wer verbraucht was“ unangenehm. Die üblichen Werkzeuge antworten unterschiedlich gut:

Verfahren	Was messbar ist	Was fehlt
Time-Slicing	Auslastung der Karte insgesamt; Prozesse über <code>nvidia-smi pmon</code>	Keine saubere Zuordnung der Rechenzeit je Pod

Verfahren	Was messbar ist	Was fehlt
MPS	Prozesse und deren Speicherbelegung	Rechenanteil je Client schwer zuzuordnen
MIG	Metriken je Instanz – DCGM meldet getrennt	Nichts Wesentliches – der klare Vorteil

MERKE

MIG ist auch aus Sicht der Beobachtbarkeit das sauberste Verfahren: Jede Instanz erscheint als eigenes Gerät mit eigenen Metriken. Bei Time-Slicing dagegen sieht man eine Karte mit hoher Auslastung und mehreren Prozessen – und kann nicht sagen, welcher Mandant welchen Anteil verursacht hat.

Für Kostenzuordnung hat das unmittelbare Folgen: Bei geteilten Karten ohne MIG lässt sich der Verbrauch nicht auf GPU-Ebene aufteilen. Die Zuordnung muss dann über die Anzahl der Anfragen und der Token im Gateway erfolgen – Kapitel 11 und 14.

6.14 Durchgerechnet: acht Karten für fünf Teams

Die folgende Aufgabe entspricht der Systemdesign-Frage, die in Interviews zu diesem Kapitel gestellt wird. Sie zeigt, dass die Antwort selten „MIG überall“ lautet.

Ausgangslage: Acht Rechenzentrumskarten mit je 80 GiB. Fünf Teams mit unterschiedlichem Bedarf.

Team	Anwendungsfall	Modellbedarf	Charakter
A	Chat-Assistent, 500 Nutzer	großes Standardmodell	interaktiv
B	RAG über interne Dokumente	dasselbe Modell + Embeddings	interaktiv, lange Prompts
C	Codeassistent	eigenes, feinabgestimmtes Modell	interaktiv
D	Forschung, wechselnde Versuche	wechselnd, klein	unvorhersehbar
E	Massenklassifikation nachts	kleines Modell	Stapelverarbeitung

Der erste Schritt ist eine Rückfrage, keine Aufteilung: Teams A und B nutzen dasselbe Modell. Damit brauchen sie keine getrennte Hardware, sondern getrennte Kontingente.

Karten	Aufteilung	Begründung
2	Ungeteilt, je eine Instanz des großen Modells	Teams A und B teilen sich beide Instanzen über das Gateway. Zwei Repliken für Ausfallsicherheit und rollierende Updates – nicht für Durchsatz.
1	MIG 3g . 40gb × 2	Eine Instanz für das Modell von Team C, eine für den Einbettungsdienst von Team B. Verschiedene Modelle, deshalb echte Aufteilung.
1	MIG 1g . 10gb × 7	Forschungsinstanzen für Team D. Kleine, isolierte Umgebungen mit harter

Karten	Aufteilung	Begründung
		Speichertrennung — genau der Fall, für den MIG gebaut ist.
1	Ungeteilt, niedrige Priorität	Stapelverarbeitung für Team E. Läuft nachts; tagsüber steht die Karte als Reserve bereit.
1	Reserve	Ausfall, Wartung, Modellwechsel. Ohne diese Karte ist jedes Treiber-Update ein Ausfall.
2	Erweiterung	Bewusst nicht vorab verplant. Die tatsächliche Auslastung der ersten Monate entscheidet, wohin sie gehen.

MERKE

Drei Beobachtungen an diesem Entwurf, die verallgemeinerbar sind:

Erstens wird nur ein Viertel der Karten überhaupt aufgeteilt. Für die Hauptlast — viele Nutzer, ein Modell — ist der gemeinsame Server die richtige Antwort.

Zweitens ist die Reserve keine Verschwendung, sondern die Voraussetzung dafür, dass Wartung ohne Ausfall möglich ist.

Drittens bleiben zwei Karten unverplant. Eine Plattform, die am ersten Tag zu 100 Prozent verplant ist, hat keinen Spielraum für die Anforderungen, die im zweiten Monat kommen — und sie kommen.

6.15 Den aktiven Sharing-Modus erkennen

In einem gewachsenen Cluster ist nicht immer klar, welches Verfahren auf welchem Knoten aktiv ist — besonders dann, wenn verschiedene Sharing-Sätze über Knoten-Labels zugeordnet wurden. Die GPU Feature Discovery beantwortet das, wenn man weiß, worauf man schaut.

Label	Beispiel	Bedeutung
nvidia.com/gpu.count	4	Gemeldete Geräte — bei Sharing die Replikatzahl
nvidia.com/gpu.replicas	4	Ausdrücklich die Zahl der Replika-te je Karte
nvidia.com/gpu.sharing-strategy	time-slicing	Aktives Verfahren
nvidia.com/gpu.product	...-SHARED	Namenszusatz bei aktivem Sharing
nvidia.com/mig.strategy	mixed	Meldestategie bei MIG
nvidia.com/gpu.memory	24564	Speicher je gemeldetem Gerät in Mebibyte

Der Namenszusatz am Produktlabel ist der zuverlässigste Hinweis: Bei aktivem Sharing hängt die GPU Feature Discovery eine Kennzeichnung an den Produktnamen an. Ein nodeSelector, der auf den unveränderten Produktnamen zielt, greift dann nicht mehr — eine Fehlerquelle, die nach der Aktivierung von Sharing gerne übersehen wird.

```
kubectl get nodes -o json | jq -r '
  .items[]
  | select(.metadata.labels["nvidia.com/gpu.count"])
  | [ .metadata.name,
      .metadata.labels["nvidia.com/gpu.product"],
      .metadata.labels["nvidia.com/gpu.count"],
      (.metadata.labels["nvidia.com/gpu.sharing-strategy"]
       // "keine") ]
  | @tsv'
```

Erwartete Ausgabe: Je GPU-Knoten eine Zeile mit Produktname, gemeldeter Gerätezahl und Verfahren. Ein Knoten mit `-SHARED` im Produktnamen und einer Gerätezahl größer eins teilt seine Karte — unabhängig davon, was in der Dokumentation steht.

ACHTUNG Der Namenszusatz bricht bestehende Selektoren

Ein Deployment mit

```
nodeSelector:
  nvidia.com/gpu.product: NVIDIA-A100-SXM4-80GB
```

findet nach der Aktivierung von Time-Slicing keinen Knoten mehr, weil das Label jetzt einen Zusatz trägt. Der Pod bleibt in Pending, und die Ursache steht nicht im Ereignisprotokoll — dort steht nur, dass kein Knoten passt.

Das ist ein weiteres Argument für die Empfehlung aus Kapitel 5: nach **Eigenschaft** auswählen — etwa über `nvidia.com/gpu.memory` — statt über den Produktnamen.

6.15.1 Gegenprobe auf dem Knoten

Die Cluster-Sicht kann täuschen. Die verbindliche Auskunft gibt die Karte selbst:

```
nvidia-smi -L # gemeldete Geräte und UUIDs
nvidia-smi --query-gpu=uuid,memory.total --format=csv
nvidia-smi mig -lgi 2>/dev/null # MIG-Instanzen, falls vorhanden
```

Erwartete Ausgabe bei Time-Slicing: Genau **eine** physische Karte mit einer UUID — obwohl Kubernetes vier meldet. Genau diese Diskrepanz ist das Wesen des Verfahrens.

Erwartete Ausgabe bei MIG: Mehrere Instanzen mit eigenen UUIDs, jede mit eigenem Speicherwert. Hier entspricht die Cluster-Sicht der Hardware.

MERKE

Eine einzige Frage entlarvt jedes Sharing-Verfahren: **Wie viele UUIDs meldet die Hardware?** Stimmt diese Zahl mit dem überein, was Kubernetes als Kapazität ausweist, liegt echte Aufteilung vor. Weicht sie ab, wird Zeit geteilt — und der Speicher ist gemeinsam.

6.16 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Nach Aktivierung des Time-Slicing meldet der Knoten weiter 1	ConfigMap nicht wirksam oder Device Plugin nicht neu gestartet	<code>kubectl -n gpu-operator get cm</code> und Log des Device-Plugin-Pods	Namen in <code>devicePlugin.config</code> prüfen, Plugin-Pod löschen
Pods stürzen sporadisch mit CUDA OOM ab	Time-Slicing ohne Speicherisolation	<code>nvidia-smi</code> auf dem Knoten – mehrere Prozesse auf einer Karte	Time-Slicing zurücknehmen oder Speicherbedarf je Pod begrenzen
Durchsatz sinkt nach Aktivierung des Sharing	Kontextwechsel bei zu vielen Replikaten	Durchsatz mit und ohne Sharing vergleichen	Replikatzahl senken; für Auslastung besser einen Server mit Batching
MIG-Umkonfiguration bleibt hängen	Ein Prozess belegt noch die GPU	<code>nvidia-smi</code> – Prozessliste; Zustand des MIG-Managers	Knoten leeren, dann erneut versuchen
Pod fordert <code>nvidia.com/mig-lg.10gb</code> an, bleibt Pending	Strategie <code>single</code> statt <code>mixed</code> , oder Profil nicht eingerichtet	<code>kubectl describe node</code> – welche Ressourcenamen gemeldet werden	Strategie auf <code>mixed</code> stellen oder Profil anlegen
MPS-Clients brechen gemeinsam ab	Fehler in einem Client hat den MPS-Server getroffen	Log des MPS-Daemons auf dem Knoten	Für Mandantentrennung MIG einsetzen; MPS ist dafür ungeeignet

6.17 Interviewfragen

INTERVIEWFRAGE

Was ist MIG, und wann würden Sie es einsetzen?

Gut ist: MIG teilt eine GPU in isolierte Instanzen mit eigenem Speicher.

Senior ist die Präzisierung, dass die Trennung auf Hardwareebene erfolgt – eigene Rechenwerke, Speicherbereiche, Speichercontroller und L2-Anteile – und dass MIG deshalb das einzige Verfahren mit echter Speicher- und Fehlerisolation ist. Dazu die Einordnung: MIG tauscht Auslastung gegen Garantien und lohnt sich, wenn Mandanten sich nicht vertrauen oder harte Latenzzusagen gelten. Wer ergänzt, dass Instanzen nicht zusammenarbeiten können und die Umkonfiguration eine leere GPU erfordert, kennt auch die Nachteile.

INTERVIEWFRAGE

Wann würden Sie MIG statt Time-Slicing verwenden?

Diese Frage zielt auf genau einen Punkt.

Senior ist: Sobald **Speicherisolation** gebraucht wird. Time-Slicing teilt Rechenzeit, aber der VRAM bleibt gemeinsam und unbegrenzt – zwei Pods können sich gegenseitig ins Out-of-Memory treiben, obwohl Kubernetes beide ordnungsgemäß geplant hat.

Time-Slicing ist damit für Entwicklung und Test brauchbar und für Mehrmandantenbetrieb mit Zusagen ungeeignet. Wer ergänzt, dass MIG eine Karte ab der A100-Generation voraussetzt und auf Consumer-Hardware schlicht nicht existiert, beantwortet auch die unausgesprochene Anschlussfrage.

INTERVIEWFRAGE

Acht H100 in einem Cluster sollen mehreren Teams zur Verfügung stehen. Wie gehen Sie vor?

Das ist die klassische Systemdesign-Frage zu diesem Kapitel.

Schwach ist, sofort mit MIG zu antworten.

Senior beginnt mit einer Rückfrage: Nutzen die Teams **dasselbe** Modell oder verschiedene? Bei demselben Modell ist die Antwort ein gemeinsamer Inferenz-Dienst mit Kontingenten im Gateway — das nutzt die Hardware am besten, weil die Gewichte nur einmal im Speicher liegen. Erst bei verschiedenen Modellen oder bei erzwungener Mandantentrennung wird MIG das Mittel der Wahl.

Die vollständige Antwort umfasst dann: Node-Pool-Trennung mit Taints, MIG-Profilen passend zu den Modellgrößen gewählt — mit der KV-Cache-Rechnung als Begründung —, ResourceQuota je Namensraum, Kontingente im Gateway, DCGM-Monitoring mit Zuordnung zu Pod und Team, und eine Kostenzuordnung. Wer zusätzlich sagt, dass er zuerst die tatsächliche Auslastung messen würde, bevor er acht Karten in 56 Instanzen zerlegt, denkt wie ein Plattformbetreiber.

INTERVIEWFRAGE

Worin unterscheiden sich MPS und Time-Slicing?

Gut ist: MPS erlaubt echte Parallelität, Time-Slicing wechselt zwischen Prozessen.

Senior ergänzt den unangenehmen Teil: MPS ist bei der **Fehlerisolation schlechter** als Time-Slicing, weil alle Clients einen gemeinsamen Server nutzen und ein schwerwiegender Fehler alle treffen kann. MPS ist damit gut für mehrere Workloads desselben Teams, die eine Karte einzeln nicht auslasten — und falsch für Mandanten, die einander nicht vertrauen.

6.18 Zusammenfassung

- Die Frage bei jedem Sharing-Verfahren lautet: Was genau wird isoliert — Rechenzeit, Speicher oder Fehler? Die drei Verfahren beantworten das völlig verschieden.
- Time-Slicing meldet dieselbe Karte mehrfach und teilt Rechenzeit. Es isoliert **keinen Speicher**. Zwei Pods können sich gegenseitig ins Out-of-Memory treiben, obwohl Kubernetes beide korrekt geplant hat. Geeignet für Entwicklung, ungeeignet für Zusagen.
- MPS erlaubt echte Parallelität und begrenzbaren Speicher je Client, verschlechtert aber die Fehlerisolation gegenüber Time-Slicing.

- MIG teilt die Hardware selbst und ist das einzige Verfahren mit echter Speicher- und Fehlertrennung. Es setzt eine Karte ab der A100-Generation voraus, tauscht Auslastung gegen Garantien, und die Umkonfiguration erfordert eine leere GPU.
- MIG-Profile werden mit derselben VRAM-Bilanz gewählt wie ganze Karten. Ein zu kleines Profil ergibt eine Instanz ohne nutzbaren KV-Cache.
- Der häufigste Fall in Unternehmen wird durch **keines** der Verfahren gelöst: Mehrere Teams, die dasselbe Modell nutzen, brauchen einen gemeinsamen Inferenz-Dienst mit Kontingenten im Gateway – nicht eine eigene GPU je Team.
- Der laute Nachbar wirkt bei GPUs über lange Prompts und langen Kontext. Die Gegenmaßnahmen liegen im Gateway, nicht auf GPU-Ebene.

Quellen und Weiterlesen

- NVIDIA: *Multi-Instance GPU User Guide* – verbindliche Referenz zu Profilen, Einrichtung und Einschränkungen; die verfügbaren Profile sind modellabhängig.
- NVIDIA: *GPU Operator – GPU Sharing* – Konfiguration von Time-Slicing und MPS über ConfigMap und ClusterPolicy.
- NVIDIA: *Multi-Process Service* – Architektur des MPS-Servers und seine Fehlersemantik.
- Kubernetes: *Schedule GPUs* – Abschnitt zu Sharing-Strategien und deren Abbildung auf erweiterte Ressourcen.

TEIL III

Model Serving

Aus einer verfügbaren GPU wird erst dann ein Dienst, wenn ein Server sie auslastet und eine Abstraktion darüber Rollouts, Skalierung und Versionierung übernimmt. Dieser Teil behandelt vLLM als Motor und KServe als Rahmen.

vLLM: Architektur und Interna

ZIEL	Verstehen, wodurch ein spezialisierter Inferenz-Server einem einfachen Generierungsaufwurf um eine Größenordnung überlegen ist — und zwar so genau, dass sich daraus Konfigurationsentscheidungen und Fehlerdiagnosen ableiten lassen.
SETZT VORAUS	Kapitel 2 und 3, insbesondere KV-Cache, Batching und die VRAM-Bilanz.
DANACH KANNST DU	PagedAttention und Continuous Batching erklären, das Verhalten des Schedulers aus den Metriken ablesen, Preemption erkennen und beheben, sowie Prefix Caching, Chunked Prefill und Speculative Decoding begründet einsetzen.

GESCHRIEBEN GEGEN

vLLM 0.8.x, V1-Engine · Stand September 2026

Kapitel 2 hat gezeigt, **dass** Batching der zentrale Hebel ist. Dieses Kapitel zeigt, **wie** ein Server das umsetzt — und warum das schwieriger ist, als es klingt. Wer diese Mechanik kennt, liest die Metriken aus Kapitel 14 anders und stellt die Parameter aus Kapitel 8 begründet ein statt nach Gefühl.

7.1 Warum ein einfacher Generierungsaufwurf nicht genügt

Ein Modell lässt sich mit wenigen Zeilen Python zur Textgenerierung bringen. Für einen Produktionsdienst reicht das aus drei Gründen nicht, und alle drei betreffen den KV-Cache.

7.1.1 Problem 1: Reservierung auf Verdacht

Der KV-Cache einer Sequenz wächst mit jedem erzeugten Token. Ein naiver Server weiß vorher nicht, wie lang die Antwort wird — also reserviert er Speicher für den **schlimmsten** Fall: die maximale Kontextlänge.

Anfrage mit 200 Prompt-Token, Antwort wird 300 Token lang

NAIVE RESERVIERUNG (max_model_len = 4096)



500 Token 3596 Token reserviert und nie benutzt
tatsächlich
genutzt

Nutzungsgrad: rund 12 Prozent.

Bei 24 GiB KV-Cache passen so nur wenige Sequenzen gleichzeitig.

Reservierung auf Verdacht: Der weitaus größte Teil des Speichers bleibt ungenutzt.

7.1.2 Problem 2: Zerstückelung

Selbst wenn man dynamisch nachreserviert, entsteht das klassische Problem zusammenhängender Speicherbereiche: Zwischen freigegebenen Blöcken bleiben Lücken, die zu klein für neue Sequenzen sind. Der Speicher ist frei, aber unbrauchbar.

7.1.3 Problem 3: Starre Batches

Kapitel 2 hat den Unterschied zwischen statischem und kontinuierlichem Batching gezeigt. Ein naiver Server bildet einen Batch, verarbeitet ihn gemeinsam und beendet ihn gemeinsam — alle warten auf die längste Antwort.

MERKE


Die drei Probleme hängen zusammen: Kontinuierliches Batching setzt voraus, dass Sequenzen jederzeit einzeln hinzukommen und wegfallen können. Das erfordert eine Speicherverwaltung, die Blöcke einzeln vergibt und zurücknimmt — ohne Zusammenhangserfordernis und ohne Reservierung auf Verdacht.

Genau das leistet PagedAttention. Sie ist damit nicht eine Optimierung neben anderen, sondern die **Voraussetzung** für alles Weitere.

7.2 PagedAttention

7.2.1 Die Idee

PagedAttention überträgt das Prinzip der virtuellen Speicherverwaltung auf den KV-Cache. Statt einen zusammenhängenden Bereich je Sequenz zu vergeben, wird der Cache in kleine, gleich große **Blöcke** zerlegt — typischerweise 16 Token je Block. Jede Sequenz erhält eine **Blocktabelle**, die ihre logischen Positionen auf physische Blöcke abbildet.



Blocktabelle: logische Sequenzpositionen zeigen auf beliebig verteilte physische Blöcke.

7.2.2 Was das bewirkt

Effekt	Ohne PagedAttention	Mit PagedAttention
Reservierung	auf maximale Kontextlänge	blockweise, nach Bedarf
Verschnitt innerhalb	Rest bis zum Maximum	höchstens 15 Token im letzten Block
Verschnitt zwischen	Lücken unbrauchbarer Größe	entfällt — Blöcke sind gleich groß
Freigabe	ganze Sequenz	einzelne Blöcke
Gemeinsame Nutzung	nicht möglich	Blöcke referenzierbar

Der letzte Punkt ist mehr als ein Nebeneffekt: Weil eine Blocktabelle nur **Verweise** enthält, können zwei Sequenzen denselben physischen Block referenzieren, solange ihr Inhalt identisch ist. Beim Schreiben wird der Block kopiert — dasselbe Verfahren, das Betriebssysteme beim Kopieren von Prozessen verwenden.

Daraus folgen unmittelbar zwei Funktionen, die später eigene Abschnitte bekommen: Prefix Caching — gemeinsame Prompt-Anfänge teilen sich Blöcke — und mehrfache Antwortvarianten, bei denen alle Varianten den gemeinsamen Prompt teilen und nur ihre eigenen Fortsetzungen belegen.


MERKE

Die Blockgröße ist ein Kompromiss, den man selten anfassen muss. Kleinere Blöcke bedeuten weniger Verschnitt, aber größere Blocktabellen und mehr Verwaltungsaufwand. Der Standardwert von 16 Token ist für nahezu alle Fälle richtig.

7.3 Der Scheduler

Der Scheduler entscheidet vor **jedem** Rechenschritt neu, welche Anfragen in diesem Schritt bearbeitet werden. Das ist der Kern des kontinuierlichen Batchings — und die Quelle der meisten Metriken, die man im Betrieb beobachtet.

7.3.1 Die Zustände einer Anfrage



Der Lebenszyklus einer Anfrage im Scheduler

Zwei Metriken bilden das direkt ab und gehören auf jedes Dashboard: `num_requests_running` und `num_requests_waiting`.

7.3.2 Was in einem Schritt passiert

1. **Freigeben:** Blöcke abgeschlossener Anfragen zurückgeben.
2. **Aufnehmen:** Aus der Warteschlange so viele Anfragen aufnehmen, wie Blöcke und Token-Budget zulassen.
3. **Verdrängen:** Reicht der Platz für die laufenden Anfragen nicht mehr, werden einzelne zurückgestellt.
4. **Rechnen:** Ein Vorwärtsdurchlauf für den gesamten Batch – Prefill-Anteile und Decode-Anteile gemeinsam.
5. **Ausgeben:** Erzeugte Token an die wartenden Clients streamen.

MERKE

Der entscheidende Unterschied zum statischen Batching liegt im zweiten und dritten Punkt: Die Zusammensetzung des Batches ändert sich **bei jedem Schritt**. Eine Anfrage, die nach 30 Token fertig ist, gibt ihren Platz sofort frei – und die nächste rückt im selben Schritt nach.

7.3.3 Verdrängung: der wichtigste Betriebsindikator

Wenn der KV-Cache voll läuft, muss der Scheduler laufende Anfragen zurückstellen. Dafür gibt es zwei Verfahren:

Verfahren	Arbeitsweise	Kosten
Neuberechnung	Die KV-Blöcke werden verworfen. Bei der Wiederaufnahme wird der Prefill erneut ausgeführt.	Rechenzeit – linear zur bisherigen Sequenzlänge. Für kurze Sequenzen günstig.

Verfahren	Arbeitsweise	Kosten
Auslagerung	Die Blöcke werden in den Hauptspeicher kopiert und später zurückgeholt.	Übertragung über PCIe — Kapitel 4 hat gezeigt, wie langsam das im Vergleich ist.

Für einzelne Sequenzen ist Neuberechnung meist die günstigere Wahl und die Voreinstellung.

ACHTUNG Verdrängung ist ein Alarmsignal, kein Normalzustand

Jede Verdrängung bedeutet, dass bereits geleistete Arbeit weggeworfen und später wiederholt wird. Ein System, das dauerhaft verdrängt, arbeitet einen erheblichen Teil seiner Zeit doppelt — bei gleichzeitig steigender Latenz für die betroffenen Anfragen.

Die Metrik dafür ist `num_preemptions_total`. Sie sollte im Normalbetrieb bei null liegen oder nur bei Lastspitzen ansteigen. Ein stetig wachsender Wert bedeutet: Der KV-Cache ist zu klein für die anliegende Last. Die Antwort darauf steht in Kapitel 3 — Kontextgrenze senken, Modell quantisieren oder Gleichzeitigkeit begrenzen.

7.3.4 Der KV-Cache-Manager

Die Blockverwaltung ist eine eigene Komponente, und zwei ihrer Eigenschaften erklären Verhalten, das sonst rätselhaft bleibt.

Das Wasserzeichen. Der Manager hält einen kleinen Anteil der Blöcke frei, statt bis zum letzten Block zu vergeben. Der Grund ist, dass jede laufende Sequenz im nächsten Schritt einen weiteren Block anfordern könnte. Ohne Reserve müsste bei jedem Schritt verdrängt werden. Praktisch bedeutet das: `gpu_cache_usage_perc` erreicht im gesunden Betrieb nie exakt 1,0 — ein Wert dauerhaft knapp darunter ist bereits die Sättigung.

Aufnahme nur bei gesichertem Bedarf. Eine wartende Anfrage wird erst aufgenommen, wenn die Blöcke für ihren gesamten Prompt verfügbar sind. Eine einzelne Anfrage mit sehr langem Prompt kann deshalb warten, während kürzere Anfragen an ihr vorbeiziehen — obwohl sie früher eingetroffen ist.

MERKE

Daraus folgt ein Effekt, der im Betrieb als Fehler gemeldet wird: Unter Last werden lange Anfragen systematisch benachteiligt. Das ist kein Fehler, sondern die Konsequenz daraus, dass sie mehr Speicher am Stück benötigen.

Wenn lange Anfragen eine Zusage brauchen, gehören sie auf einen eigenen Endpunkt mit eigenem Speicherbudget — wieder die Trennung nach Lastprofil aus Kapitel 2.

Die Größe des Caches selbst ergibt sich aus der Speicherprofilierung beim Start und lässt sich im Log ablesen. Sie in Token umzurechnen ist die Probe auf die Bilanz aus Kapitel 3:

```
kubectl logs deploy/vllm | grep -i -E \
'kv cache|blocks|memory profiling'
```

Erwartete Ausgabe: Eine Zeile mit der Zahl der GPU-Blöcke. Multipliziert mit der Blockgröße ergibt das die Zahl der Token — und geteilt durch die geplante Kontext-


länge die Zahl gleichzeitiger Sequenzen. Weicht dieser Wert deutlich von Ihrer Rechnung ab, stimmt eine Annahme nicht: meist die Modellgröße oder ein zusätzlich belegter Posten wie ein Entwurfsmodell.

7.4 Chunked Prefill

Kapitel 2 hat das Head-of-Line-Blocking beschrieben: Ein großer Prefill hält alle laufenden Decodes an. Chunked Prefill ist die Antwort darauf.

7.4.1 Das Token-Budget

Der Scheduler arbeitet mit einem Budget an Token je Schritt – gesteuert über `max-num-batched-tokens`. Ein Prefill, der dieses Budget überschreitet, wird in Stücke zerlegt. In jeden Schritt fließen dann sowohl ein Prefill-Stück als auch die Decode-Schritte der laufenden Anfragen.



Ein Schritt mit gemischtem Batch: Decodes und ein Prefill-Stück teilen sich das Budget.

7.4.2 Die Stellschraube

`max-num-batched-tokens` ist damit ein direkter Regler für den Ausgleich zwischen zwei Zielen:

Wert	Wirkung auf TTFT	Wirkung auf TPOT
klein (z. B. 512)	Höher – Prefills brauchen mehr Schritte	Sehr gleichmäßig – Decodes werden kaum gestört
groß (z. B. 8192)	Niedriger – Prefills sind schnell durch	Ausreißer – große Prefill-Stücke verzögern Decodes

MERKE

Für interaktive Dienste mit Latenzzusagen ist ein moderates Budget die bessere Wahl: Gleichmäßige Ausgabe wird von Nutzern als schneller wahrgenommen als eine niedrige Durchschnittslatenz mit Aussetzern. Für Stapelverarbeitung, wo nur der Durchsatz zählt, gilt das Umgekehrte.

Dies ist einer der wenigen Parameter, bei denen das **Lastprofil** die Einstellung bestimmt – ein weiteres Argument für getrennte Endpunkte je Profil, wie in Kapitel 2 begründet.

7.5 Prefix Caching

7.5.1 Wie Wiederverwendung erkannt wird

Kapitel 2 hat den Nutzen beschrieben. Die Umsetzung ist elegant: Für jeden vollständig gefüllten Block wird ein Streuwert berechnet, der die Token dieses Blocks **und** den Streuwert des Vorgängerblocks einbezieht. Zwei Sequenzen mit identischem Anfang erzeugen damit zwangsläufig identische Streuwerte – bis zu der Stelle, an der sie sich unterscheiden.

```
Anfrage 1: [Systemprompt.....][.....][Frage A.....]
Bloecke:   B1      B2      B3      B4      B5      B6

Streuwerte: h1 = H(          Token von B1)
             h2 = H(h1,      Token von B2)
             h3 = H(h2,      Token von B3)   ...

Anfrage 2: [Systemprompt.....][.....][Frage B.....]
Bloecke:   B1      B2      B3      B4      B5'   B6'

             h1, h2, h3, h4 → TREFFER, Bloecke wiederverwendet
             h5' abweichend → ab hier neu berechnen

Ergebnis: Der Prefill beginnt erst bei Block 5.
```

Kettenweise Streuwerte: Der Treffer endet exakt dort, wo die Prompts sich unterscheiden.

7.5.2 Betriebliche Folgen

Eigenschaft	Konsequenz
Nur vollständige Blöcke werden zwischengespeichert	Bei 16 Token je Block ist ein Systemprompt von 1 500 Token gut abgedeckt
Der Cache belegt Blöcke	Zwischengespeicherte Präfixe konkurrieren mit laufenden Anfragen um denselben Speicher
Verdrängung nach Alter	Selten genutzte Präfixe fallen heraus, wenn Platz gebraucht wird
Treffer nur bei identischem Anfang	Die Regel aus Kapitel 2: Statisches zuerst, Variables zuletzt

Die Wirksamkeit lässt sich messen. Die Metriken `prefix_cache_queries_total` und `prefix_cache_hits_total` ergeben eine Trefferquote, die im Betrieb aussagekräftiger ist als jede Vermutung über die Prompt-Struktur der Anwendungen.

7.6 Speculative Decoding

7.6.1 Die Idee

Der Decode ist bandbreitenbegrenzt: Ein Durchlauf durch alle Gewichte erzeugt genau ein Token, und die Rechenwerke langweilen sich dabei. Speculative Decoding nutzt diese freie Rechenkapazität.

Ein kleines, schnelles **Entwurfsmodell** schlägt mehrere Token auf einmal vor. Das große Modell prüft alle Vorschläge in **einem** Durchlauf und übernimmt sie, bis zum ersten Fehler.

Eine niedrige Trefferquote bei einer Anwendung mit festem Systemprompt ist fast immer ein Hinweis auf variable Inhalte am Prompt-Anfang – Zeitstempel, Sitzungskennungen, Nutzernamen.

OHNE	MIT ENTWURFSMODELL
gross: T1	Entwurf: T1 T2 T3 T4 (schnell)
gross: T2	gross: pruefe alle vier
gross: T3	→ T1 ok
gross: T4	→ T2 ok
4 Durchläufe des grossen Modells	→ T3 ok
	→ T4 falsch, verworfen
	1 Durchlauf des grossen Modells ergibt 3 gueltige Token

Ein Durchlauf des großen Modells bestätigt mehrere Token auf einmal.

7.6.2 Wovon der Gewinn abhängt

Entscheidend ist die **Annahmequote**: Wie viele der vorgeschlagenen Token werden übernommen? Sie hängt vollständig vom Inhalt ab:

Inhalt	Quote	Grund
Code, strukturierte Ausgaben	hoch	Stark vorhersagbar, viele feste Muster
Wiederholungen aus dem Prompt	sehr hoch	Der Text steht bereits da
Fachtexte mit fester Form	mittel	Teilweise vorhersagbar
Freie, kreative Sprache	niedrig	Wenig vorhersagbar

ACHTUNG Der Gewinn ist nicht kostenlos

Das Entwurfsmodell belegt VRAM — Kapitel 3 hat es in der Bilanz berücksichtigt — und seine eigenen Durchläufe kosten Zeit. Bei niedriger Annahmequote kann Speculative Decoding den Durchsatz sogar **senken**.


Zusätzlich gilt: Der Gewinn ist am größten bei **einzelnen** Anfragen und schrumpft mit steigender Batchgröße — weil bei vollem Batch die Rechenwerke ohnehin ausgelastet sind und keine freie Kapazität mehr bereitsteht. Für einen Server unter hoher Last bringt es entsprechend weniger als die Benchmark-Zahlen vermuten lassen.

Messen Sie die Annahmequote am eigenen Verkehr, bevor Sie es aktivieren.

Neben einem eigenständigen Entwurfsmodell existieren Verfahren, die ohne zweites Modell auskommen — etwa die Suche nach wiederkehrenden Zeichenfolgen im Prompt, was bei Zusammenfassungen und Codebearbeitung erstaunlich gut funktioniert und keinen zusätzlichen Speicher kostet.

7.7 Die Engine-Architektur

7.7.1 Die Bausteine



Aufbau der Engine: Frontend, Kern und Ausführung sind getrennt.

Die Trennung zwischen Schnittstelle und Kern in eigene Prozesse ist eine wichtige Eigenschaft: Tokenisierung, HTTP-Verarbeitung und Antwortaufbereitung laufen in Python und würden sonst den Scheduler blockieren. Für den Betrieb bedeutet das, dass ein vLLM-Prozess mehrere CPU-Kerne benötigt — eine Ressourcenangabe, die bei GPU-Pods gerne zu knapp bemessen wird.

MERKE

Ein vLLM-Pod braucht neben der GPU auch CPU und Hauptspeicher: mehrere Kerne für Tokenisierung und Antwortaufbereitung, und Hauptspeicher mindestens in der Größenordnung des Modells, weil die Gewichte beim Laden zunächst dort landen.

Ein Pod mit `nvidia.com/gpu: 1`, aber `cpu: 500m` ist eine häufige Fehlkonfiguration. Sie äußert sich als unerklärlich hohe Latenz bei niedriger GPU-Auslastung. Kapitel 8 behandelt die Ressourcenangaben vollständig.

7.8 Der Weg einer Anfrage durch die Engine

Die einzelnen Mechanismen zusammengesetzt ergeben den folgenden Ablauf. Er ist die detaillierte Fassung des Überblicks aus Kapitel 2 und eignet sich gut, um im Gespräch zu zeigen, dass man den Server verstanden hat.

Nr.	Station	Was dort geschieht
1	HTTP-Schnittstelle	Anfrage validieren, Chat-Vorlage aus <code>tokenizer_config.json</code> anwenden, Sampling-Parameter prüfen

Nr.	Station	Was dort geschieht
2	Tokenisierung	Text wird zur Token-Folge. Läuft auf der CPU — bei knappem CPU-Kontingent hier der erste Engpass
3	Aufnahme in die Warteschlange	Die Anfrage geht in den Zustand <code>waiting</code>
4	Prefix-Prüfung	Streuwerte der Blöcke berechnen und mit dem Cache abgleichen; getroffene Blöcke werden referenziert statt berechnet
5	Aufnahme in den Batch	Der Scheduler prüft, ob genügend freie Blöcke und Token-Budget vorhanden sind
6	Prefill	Verbleibende Prompt-Token verarbeiten, gegebenenfalls in Stücken; KV-Blöcke füllen
7	Decode-Schleife	Je Schritt ein Token. Nach jedem Schritt entscheidet der Scheduler neu über die Batch-Zusammensetzung
8	Sampling	Aus den Ausgabewerten wird ein Token gewählt — siehe nächster Abschnitt
9	Ausgabe	Token zurück an die Schnittstelle, dort Detokenisierung und Auslieferung
10	Abschluss	Blöcke freigeben — Präfixblöcke bleiben gegebenenfalls im Cache

Zwei Stellen verdienen genaueres Hinsehen, weil dort Entscheidungen getroffen werden, die im Betrieb Folgen haben: Schritt 8 — das Sampling — und die Frage, wie der Vorwärtsthroughlauf in Schritt 6 und 7 überhaupt ausgeführt wird.

7.9 Strukturierte Ausgaben erzwingen

7.9.1 Das Problem

Kapitel 3 hat gezeigt, dass Formattreue bei aggressiver Quantisierung als Erstes bricht: Ein Modell schreibt weiterhin flüssige Texte, erzeugt aber gelegentlich ungültiges JSON oder einen falsch benannten Werkzeugaufruf. Für eine Anwendung, die auf strukturierten Ausgaben aufbaut, ist das ein Betriebsproblem — und es lässt sich nicht durch bessere Prompts lösen, sondern nur abmildern.

7.9.2 Die Lösung liegt im Sampling

Beim Sampling wählt der Server aus einer Bewertung aller Vokabeleinträge das nächste Token. Genau an dieser Stelle lässt sich eingreifen: Token, die zu einem ungültigen Ergebnis führen würden, werden vorher ausgeschlossen.

Bisher erzeugt: {"stadt": "Berlin"

Zulaessig nach dem Schema an dieser Stelle:

, (weitere Eigenschaft folgt)
} (Objekt schliessen)

Bewertung aller Vokabeleintraege

" , "	0.51	→	zulaessig
" } "	0.22	→	zulaessig
" " "	0.14	→	AUSGESCHLOSSEN
"und"	0.08	→	AUSGESCHLOSSEN
...		→	AUSGESCHLOSSEN



Auswahl nur aus den zulaessigen Token

Das Modell KANN kein ungueltiges JSON erzeugen.

Geführtes Sampling: unzulässige Token werden vor der Auswahl ausgeschlossen.

Die Zulässigkeit ergibt sich aus einem Zustandsautomaten, der aus dem gewünschten Schema – einem JSON-Schema, einer regulären Ausdrucksform oder einer Grammatik – erzeugt wird. Er verfolgt mit, an welcher Stelle der Struktur die Ausgabe gerade steht, und liefert für jeden Schritt die Menge der erlaubten Token.

MERKE

Das ist ein struktureller Unterschied zu jeder Prompt-Formulierung: Geführtes Sampling macht ungültige Ausgaben nicht **unwahrscheinlich**, sondern **unmöglich**. Für Plattformen, die Werkzeugaufrufe oder maschinell weiterverarbeitete Ausgaben bereitstellen, ist es deshalb keine Zusatzfunktion, sondern eine Betriebsanforderung.

Es entschärft zugleich die Quantisierungsfrage aus Kapitel 3 erheblich: Wenn das Format ohnehin erzwungen wird, verliert der Formattreue-Test seine Härte – und ein aggressiver quantisiertes Modell wird vertretbar.

7.9.3 Was es kostet

Aspekt	Bewertung
Rechenaufwand	Die Zulässigkeitsmaske muss je Schritt bestimmt werden. Moderne Umsetzungen berechnen sie weitgehend vorab und sind kaum spürbar
Erste Anfrage je Schema	Der Automat wird erzeugt und zwischengespeichert – die erste Anfrage mit einem neuen Schema ist langsamer
Inhaltliche Qualität	Die Struktur ist garantiert, der Inhalt nicht. Ein Modell kann schemakonform Unsinn schreiben
Batching	Verschiedene Schemata im selben Batch sind möglich, kosten aber mehr Verwaltungsaufwand

ACHTUNG Struktur ist nicht Richtigkeit

Geführtes Sampling garantiert, dass die Ausgabe dem Schema entspricht. Es garantiert nicht, dass die Werte darin stimmen. Eine Anwendung, die auf erzwungenes JSON vertraut und die Werte ungeprüft weiterverarbeitet, hat das Problem nur verschoben – von der Formatprüfung zur inhaltlichen Prüfung, die weiterhin nötig bleibt.

7.10 Aufmerksamkeitskernel und Kompilierung

7.10.1 Der Kernel bestimmt die Leistung

Der Vorwärtsthroughput besteht im Kern aus der Aufmerksamkeitsberechnung, und dafür existieren verschiedene, hochoptimierte Implementierungen. Welche zum Einsatz kommt, hängt von GPU-Generation, Datentyp, Kontextlänge und den aktiven Funktionen ab – und die Unterschiede sind erheblich.

Der Server wählt beim Start selbständig aus und nennt seine Wahl im Log. Dieser Eintrag gehört bei jeder Inbetriebnahme geprüft:

```
kubectl logs deploy/vllm | grep -i -E \
  'attention|backend' | head -5
```

MERKE

Fällt der Server auf eine allgemeine Rückfallimplementierung zurück, ist das ein Leistungsproblem, das sich nicht im Fehlerlog zeigt – nur in der Latenz. Typische Ursachen sind eine nicht unterstützte Kombination aus Datentyp und GPU-Generation oder eine Funktion, die der bevorzugte Kernel nicht beherrscht. Der Startlog nennt in der Regel auch den Grund.

7.10.2 Warum die ersten Anfragen langsam sind

Beim Start führt der Server mehrere vorbereitende Schritte aus, die zusammen deutlich länger dauern als das reine Laden der Gewichte:

Schritt	Zweck
Gewichte laden	Aus Objektspeicher oder lokalem Cache in den GPU-Speicher
Speicherprofilierung	Ein Probelauf ermittelt, wie viel Speicher für Aktivierungen gebraucht wird – daraus ergibt sich die Größe des KV-Cache
Kompilierung	Rechenpfade werden für die konkrete Konfiguration übersetzt
Ausführungsgraphen	Für typische Batchgrößen werden Aufrufabfolgen vorab aufgezeichnet, um Startkosten je Schritt zu sparen
Aufwärmen	Probelaufe füllen Zwischenspeicher

Die Speicherprofilierung erklärt eine Beobachtung, die zunächst verwirrt: Die Größe des KV-Cache steht erst **nach** dem Start fest und hängt von `max-num-seqs` und `max-num-batched-tokens` ab – nicht nur von `gpu-memory-utilization`. Wer die Batchgrenzen erhöht, verkleinert damit den KV-Cache.

ACHTUNG Startzeit gegen Laufzeitleistung

Die Aufzeichnung von Ausführungsgraphen kostet beim Start Zeit und Speicher, spart im Betrieb aber Aufwand je Schritt — besonders bei kleinen Batches, wo dieser Aufwand relativ am stärksten wiegt.

Ein Abschalten verkürzt den Start spürbar und ist für Fehlersuche und kurze Testläufe sinnvoll. In Produktion gehört es eingeschaltet: Die Startzeit fällt einmal an, der Aufwand je Schritt bei jeder Anfrage. Kapitel 8 behandelt die zugehörigen Parameter, Kapitel 10 die Folgen für Scale-to-Zero.

7.10.3 Ressourcen jenseits der GPU

Aus dem Startablauf folgen konkrete Anforderungen, die in Pod-Definitionen regelmäßig fehlen:

Ressource	Größenordnung	Wofür
CPU	4 bis 8 Kerne	Tokenisierung, HTTP, Ausgabeaufbereitung, Kompilierung
Hauptspeicher	1 bis 1,5 × Modellgröße	Gewichte werden beim Laden zunächst hier abgelegt
Gemeinsamer Speicher	mehrere Gigabyte	Kommunikation zwischen den Prozessen der Engine
Kurzlebiger Speicher	Modellgröße	Zwischenspeicher, sofern nicht auf einem eigenen Volume

7.11 Scheduler-Politik

Standardmäßig arbeitet der Scheduler nach dem Prinzip „wer zuerst kommt, mahlt zuerst“. Für eine Plattform mit verschiedenen Anwendungsfällen ist das nicht immer richtig — eine interaktive Anfrage sollte nicht hinter einem Stapelauftrag warten.

Politik	Verhalten	Geeignet für
Ankunftsreihenfolge	Faire, vorhersagbare Bedienung	Gleichartige Last, einfacher Betrieb
Priorität	Höher priorisierte Anfragen werden vorgezogen und können niedriger priorisierte verdrängen	Gemischte Last mit unterschiedlichen Zusagen

Der gemeinsame Speicher — in Kubernetes über ein

Medium:

`emptyDir` mit `Memory` — ist eine der häufigsten Ursachen für Abstürze beim Start, die wie ein GPU-Problem aussehen.

MERKE

Prioritäten im Inferenz-Server sind ein feineres Werkzeug als Kontingente im Gateway, aber ein gröberes als getrennte Endpunkte. Die Reihenfolge der Mittel lautet:

Erstens getrennte Endpunkte für unvereinbare Lastprofile — wie in Kapitel 2 begründet. Zweitens Kontingente im Gateway für die Mengensteuerung je Team — Kapitel 11. Drittens Prioritäten im Server für die Feinsteuerung innerhalb eines Endpunkts.

Wer mit dem dritten Mittel beginnt, löst meist ein Problem, das an der falschen Stelle entstanden ist.

7.12 Lab: dem Scheduler bei der Arbeit zusehen

LAB Batching, Prefix Caching und Verdrängung sichtbar machen

Ziel: Die drei zentralen Mechanismen dieses Kapitels an den eigenen Metriken belegen.

Schritt 1 – Server mit knappem Cache starten. Die Kontextgrenze wird bewusst so gesetzt, dass Verdrängung provozierbar ist:

```
vllm serve Qwen/Qwen2.5-7B-Instruct \
  --max-model-len 8192 \
  --max-num-seqs 64 \
  --gpu-memory-utilization 0.85 \
  --port 8000
```

Schritt 2 – Ruhezustand festhalten.

```
curl -s localhost:8000/metrics | grep -E \
  '^vllm:(num_requests|gpu_cache_usage|num_preempt)'
```

Erwartete Ausgabe: Laufende und wartende Anfragen bei 0, Cache-Belegung bei 0, Verdrängungen bei 0.

Schritt 3 – Prefix Caching messen. Zuerst zwanzig Anfragen mit identischem, langem Systemprompt und unterschiedlicher Frage:

```
SYS=$(python3 -c "print('Du bist ein Assistent. ' * 80)")
for i in $(seq 1 20); do
  jq -n --arg s "$SYS" --arg f "Frage Nummer $i?" \
    '{model:"Qwen/Qwen2.5-7B-Instruct", max_tokens:20,
      temperature:0,
      messages:[{role:"system",content:$s},
                 {role:"user",content:$f}]}' \
  | curl -s localhost:8000/v1/chat/completions \
    -H 'Content-Type: application/json' --data @- \
    >/dev/null
done
curl -s localhost:8000/metrics | grep prefix_cache
```

Erwartete Ausgabe: Die Trefferquote liegt deutlich über null – der Systemprompt wird ab der zweiten Anfrage wiederverwendet.

Schritt 4 – Gegenprobe. Dasselbe, aber mit einer laufenden Nummer **am Anfang** des Systemprompts. Erwartung: Die Trefferquote bricht ein, weil sich bereits der erste Block unterscheidet. Das ist die Regel „Statisches zuerst“ als Messwert.

Schritt 5 – Verdrängung provozieren. Viele gleichzeitige Anfragen mit langem Kontext und langer Ausgabe:

```
for i in $(seq 1 60); do
  jq -n '{model:"Qwen/Qwen2.5-7B-Instruct",
        prompt:"Schreibe einen langen Text.",
        max_tokens:2000, temperature:0}' \
  | curl -s localhost:8000/v1/completions \
    -H 'Content-Type: application/json' --data @- \
```

```
>/dev/null &
done
```

Währenddessen im zweiten Terminal beobachten:

```
while true; do
  curl -s localhost:8000/metrics | grep -E \
    '^vllm:(num_requests_(running|waiting)|gpu_cache|num_pre)' \
    | grep -v '#'
  echo "---"; sleep 2
done
```

Erwartete Ausgabe: Die Cache-Belegung steigt gegen 1,0, die Zahl wartender Anfragen wächst, und num_preemptions_total beginnt zu zählen. Genau dieses Bild bedeutet in Produktion: Der KV-Cache ist zu klein für die anliegende Last.

Ergebnis: Sie haben die drei Kernmechanismen an eigenen Zahlen gesehen — und kennen die Metriken, an denen Kapitel 14 das Monitoring aufhängt.

7.13 Mehrere Antwortvarianten und geteilte Blöcke

Fordert eine Anfrage mehrere Varianten derselben Antwort an, zeigt sich die Blockverwaltung von ihrer stärksten Seite. Alle Varianten teilen sich denselben Prompt — und damit dieselben physischen Blöcke.

Prompt: 1000 Token

Vier Varianten zu je 200 Token

NAIV

MIT GETEILTEN BLOECKEN

Variante 1 [1000][200]
 Variante 2 [1000][200]
 Variante 3 [1000][200]
 Variante 4 [1000][200]

gemeinsam [1000]

```
graph TD
  A["[1000]"] --> B["[200]"]
  A --> C["[200]"]
  A --> D["[200]"]
  A --> E["[200]"]
```

Belegt: 4800 Token

Belegt: 1800 Token

Vier Antwortvarianten teilen sich den Prompt und belegen nur ihre eigenen Fortsetzungen.

Beim Schreiben wird ein geteilter Block kopiert — notwendig nur für den Block, in dem die Varianten sich erstmals unterscheiden. Der Speichergewinn beträgt bei langen Prompts und kurzen Antworten leicht den Faktor drei.

MERKE

Der Rechenaufwand steigt trotzdem linear: Vier Varianten bedeuten vier Decode-Ströme. Geteilte Blöcke sparen **Speicher**, nicht **Zeit**. Der Parameter `n` bleibt damit die kapazitätsrelevante Angabe aus Kapitel 2 — er vervielfacht die Decode-Arbeit.

7.14 Was vLLM nicht gut kann

Ein Nachschlagewerk sollte auch die Grenzen benennen. vLLM ist auf einen bestimmten Arbeitspunkt optimiert — viele gleichzeitige Anfragen an ein Modell auf einer oder wenigen GPUs — und außerhalb davon gibt es bessere Werkzeuge.

Fall	Warum es schlecht passt	Besser geeignet
Einzelanfragen ohne Gleichzeitigkeit	Der gesamte Vorteil stammt aus Batching. Bei einer Anfrage zur Zeit bleibt nur der Startaufwand	Schlankere Server, siehe Kapitel 10
Betrieb ohne GPU	CPU-Ausführung ist möglich, aber nicht der Zweck	llama.cpp und verwandte Projekte
Sehr kleine Modelle	Der Verwaltungsaufwand überwiegt den Nutzen	Direkte Ausführung im Anwendungsprozess
Training und Feinabstimmung	Ausdrücklich nicht der Aufgabenbereich	Die üblichen Trainingsbibliotheken
Extrem lange Kontexte auf einer Karte	Der KV-Cache dominiert und lässt keine Gleichzeitigkeit zu — Kapitel 3	Mehrere GPUs, Kapitel 9

MERKE

Die erste Zeile ist für Plattformbetreiber die wichtigste. Ein Dienst mit wenigen Anfragen je Minute rechtfertigt keinen dedizierten Inferenz-Server — weder technisch noch wirtschaftlich. Solche Anwendungsfälle gehören auf einen **gemeinsamen** Endpunkt mit anderen, damit das Batching überhaupt greifen kann. Kapitel 11 zeigt, wie das Gateway das leistet, ohne dass die Anwendungen davon wissen müssen.

7.15 Lab: geführtes Sampling messen

Dieses Lab schließt die Frage aus Kapitel 3, ob Quantisierung die Formattreue zerstört.

LAB Strukturzwang gegen Prompt-Formulierung

Ziel: Belegen, dass geführtes Sampling gültige Struktur garantiert — und was es kostet.

Schritt 1 — Ohne Zwang. Zwanzig Anfragen, die per Prompt um JSON bitten:

```
SCHEMA='{ "type": "object",
  "properties": { "stadt": { "type": "string" },
                  "einwohner": { "type": "integer" } },
  "required": [ "stadt", "einwohner" ] }'
```

```
ok=0
for i in $(seq 1 20); do
  A=$(jq -n '{model:"Qwen/Qwen2.5-7B-Instruct",
    temperature:0.7, max_tokens:80,
    messages:[{role:"user",
      content:"Nenne eine deutsche Stadt als JSON mit
        den Feldern stadt und einwohner."}]}' \
    | curl -s localhost:8000/v1/chat/completions \
```

```
-H 'Content-Type: application/json' --data @- \
| jq -r '.choices[0].message.content')
echo "$A" | jq . >/dev/null 2>&1 && ok=$((ok+1))
done
echo "gueltig ohne Zwang: $ok von 20"
```

Erwartete Ausgabe: Meist zwischen 14 und 20 — je nach Modell, Quantisierung und Temperatur. Typische Fehler sind einleitende Sätze vor dem JSON oder abschließende Erläuterungen.

Schritt 2 — Mit Zwang. Dieselbe Schleife, aber mit Schemaangabe:

```
| jq -n --argjson s "$SCHEMA" \
'{"model": "Qwen/Qwen2.5-7B-Instruct",
  temperature: 0.7, max_tokens: 80,
  response_format: {type: "json_schema",
    json_schema: {name: "stadt", schema: $s}},
  messages: [{role: "user",
    content: "Nenne eine deutsche Stadt."}]}'
```

Erwartete Ausgabe: 20 von 20. Nicht „fast immer“, sondern immer — ungültige Token sind ausgeschlossen.

Schritt 3 — Die Kosten messen. Vergleichen Sie TTFT und Gesamtdauer beider Varianten. Achten Sie besonders auf die **erste** Anfrage mit einem neuen Schema:

```
curl -s localhost:8000/metrics \
| grep -E 'time_to_first_token.*sum|_count' | head
```

Erwartete Ausgabe: Die erste Anfrage je Schema ist spürbar langsamer, weil der Zustandsautomat erzeugt wird. Danach ist der Unterschied gering.

Schritt 4 — Der eigentliche Erkenntnisgewinn. Wiederholen Sie Schritt 1 und 2 mit einer 4-Bit-Variante desselben Modells. Ohne Zwang sinkt die Quote messbar — mit Zwang bleibt sie bei 20 von 20.

Ergebnis: Geführtes Sampling verschiebt die Formattreue von einer Modelleigenschaft zu einer Servereigenschaft. Das ist der Grund, warum eine Plattform es zentral bereitstellen sollte, statt es jedem Anwendungsteam zu überlassen.

7.16 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
num_preemptions_total wächst stetig	Kontext-Cache zu klein für die Last	Cache-Belegung und Warteschlangenlänge über die Zeit	Kontextgrenze senken, quantisieren, max-num-seqs begrenzen
TTFT springt gelegentlich stark an	Head-of-Line-Blocking durch lange Prompts	TTFT-Perzentile gegen Promptlänge halten	Chunked Prefill prüfen, max-num-batched-tokens senken
Prefix-Cache-Trefferquote nahe null	Variable Inhalte am Prompt-Anfang	Rohe Prompts zweier Anfragen vergleichen	Anwendungsteam auf „Statisches zuerst“ hinweisen

Symptom	Ursache	Diagnose	Behebung
Hohe Latenz bei niedriger GPU-Auslastung	CPU-Mangel im Pod – Tokenisierung und Ausgabe blockieren	CPU-Auslastung des Pods gegen sein Limit halten	CPU-Anforderung erhöhen; mehrere Kerne vorsehen
Durchsatz sinkt nach Aktivierung von Speculative Decoding	Niedrige Annahmequote oder hohe Batchgröße	Annahmequote in den Metriken prüfen	Abschalten oder Verfahren ohne Entwurfsmodell nutzen
Server verarbeitet nur wenige Anfragen gleichzeitig	max-num-seqs zu niedrig oder Cache erschöpft	num_requests_running gegen den konfigurierten Wert	Grenze anheben, sofern der KV-Cache es hergibt

7.17 Interviewfragen

INTERVIEWFRAGE

Was ist PagedAttention, und welches Problem löst sie?

Gut ist: Sie verwaltet den KV-Cache in Blöcken statt zusammenhängend.

Senior ist die vollständige Herleitung: Ohne sie muss ein Server auf die maximale Kontextlänge reservieren, weil die Antwortlänge unbekannt ist – was den größten Teil des Speichers ungenutzt lässt. Blockweise Vergabe beseitigt sowohl den Verschnitt innerhalb einer Sequenz als auch die Zerstückelung zwischen Sequenzen. Der eigentliche Durchbruch ist aber, dass Blöcke **referenziert** statt kopiert werden können – daraus folgen Prefix Caching und mehrfache Antwortvarianten. Wer die Analogie zur virtuellen Speicherverwaltung nennt, hat das Konzept verstanden.

INTERVIEWFRAGE

Was ist Continuous Batching, und warum ist es besser als dynamisches Batching?

Gut ist: Anfragen kommen und gehen einzeln statt als starrer Batch.

Senior ist die Präzisierung, dass die Entscheidung **je Rechenschritt** fällt, nicht je Batch – und die Rechnung dahinter: Bei statischem Batching bestimmt die längste Antwort die Belegung aller Plätze. Erzeugt eine Anfrage 1 000 Token und neunzehn andere je 50, sind neunzehn Plätze über 95 Prozent der Zeit ungenutzt. Wer ergänzt, dass Continuous Batching eine blockweise Speicherverwaltung **voraussetzt**, verbindet die beiden Konzepte richtig.

INTERVIEWFRAGE

Ihr vLLM-Server verdrängt ständig Anfragen. Was tun Sie?

Senior ist ein geordnetes Vorgehen. Zuerst die Diagnose: num_preemptions_total steigt, gpu_cache_usage_perc liegt nahe 1,0, die Warteschlange wächst – das Zusammenspiel dieser drei Werte belegt einen zu kleinen KV-Cache.

Dann die Abhilfe in der Reihenfolge ihrer Wirksamkeit: max-model-len am tatsächlichen Bedarf ausrichten, Modell quantisieren – was nach Kapitel 3 doppelt wirkt –,

`max-num-seqs` begrenzen, um die Warteschlange statt den Cache überlaufen zu lassen, und erst zuletzt mehr Hardware. Wer erwähnt, dass Verdrängung bedeutet, bereits geleistete Arbeit wegzuerwerfen, erklärt auch, warum das kein tragfähiger Dauerzustand ist.

INTERVIEWFRAGE

Wann bringt Speculative Decoding etwas, und wann nicht?

Senior ist die zweifache Abhängigkeit. Erstens vom Inhalt: hohe Annahmequote bei Code und strukturierten Ausgaben, niedrige bei freier Sprache. Zweitens — und das wird meist übersehen — von der Last: Der Gewinn stammt aus ungenutzter Rechenkapazität im Decode. Bei voller Batchgröße gibt es diese nicht mehr, und der Vorteil schmilzt. Dazu die Speicherkosten des Entwurfsmodells und der Hinweis, dass die Annahmequote am eigenen Verkehr zu messen ist, bevor man es aktiviert.

INTERVIEWFRAGE

Warum verwendet man nicht einfach Hugging Face Transformers als Produktionsserver?

Schwach ist „vLLM ist schneller“.

Senior nennt die drei strukturellen Gründe: Reservierung auf die maximale Kontextlänge statt nach Bedarf, keine blockweise Speicherverwaltung und damit Zerstückelung, und starre Batches, bei denen alle auf die längste Antwort warten. Das Ergebnis ist eine Größenordnung Unterschied im Durchsatz — nicht durch schnellere Kernel, sondern durch bessere Auslastung. Wer ergänzt, dass die Transformers-Bibliothek für Forschung und Feinabstimmung gebaut wurde und dort weiterhin das richtige Werkzeug ist, argumentiert fair.

7.18 Zusammenfassung

- Ein spezialisierter Inferenz-Server löst drei Probleme, die alle den KV-Cache betreffen: Reservierung auf Verdacht, Zerstückelung und starre Batches.
- PagedAttention verwaltet den KV-Cache blockweise nach dem Vorbild virtueller Speicherverwaltung. Verschnitt entsteht nur im letzten Block einer Sequenz.
- Weil Blocktabellen nur Verweise enthalten, können Sequenzen Blöcke teilen. Daraus folgen Prefix Caching und mehrfache Antwortvarianten.
- Der Scheduler entscheidet je Rechenschritt neu über die Zusammensetzung des Batches. `num_requests_running` und `num_requests_waiting` bilden das direkt ab.
- Verdrängung wirft geleistete Arbeit weg. `num_preemptions_total` ist deshalb ein Alarmsignal, kein Normalwert.
- Chunked Prefill zerlegt große Prefills anhand eines Token-Budgets und beendet damit das Head-of-Line-Blocking. `max-num-batched-tokens` ist der Regler zwischen TTFT und gleichmäßiger Ausgabe.
- Prefix Caching erkennt Wiederverwendung über kettenweise Streuwerte je Block. Der Treffer endet dort, wo sich die Prompts unterscheiden — daher „Statisches zuerst“.

- Speculative Decoding nutzt freie Rechenkapazität im Decode. Der Gewinn hängt von der Annahmequote ab und schrumpft mit steigender Batchgröße.
- Ein vLLM-Pod braucht neben der GPU mehrere CPU-Kerne und ausreichend Hauptspeicher. Zu knappe CPU äußert sich als hohe Latenz bei niedriger GPU-Auslastung.

Quellen und Weiterlesen

- Kwon et al.: *Efficient Memory Management for Large Language Model Serving with PagedAttention* — die Arbeit hinter dem Verfahren, mit den Messungen zum Verschnitt.
- vLLM: *Documentation* — *Design* und *Optimization and Tuning*. Aufbau der Engine, Scheduler-Verhalten, Chunked Prefill und Prefix Caching.
- vLLM: *Documentation* — *Metrics*. Vollständige Liste der im Lab genutzten Kennzahlen; Namen und Umfang ändern sich zwischen Versionen.
- Leviathan et al.: *Fast Inference from Transformers via Speculative Decoding* — Grundlage des Verfahrens und der Annahmequote.

vLLM in Produktion

ZIEL	Einen vLLM-Dienst auf Kubernetes betreiben, seine Parameter begründet setzen und seine Leistung reproduzierbar messen.
SETZT VORAUS	Kapitel 5 – GPU-Knoten im Cluster – und Kapitel 7 – Verständnis des Schedulers und der Speicherverwaltung.
DANACH KANNST DU	Die Engine-Argumente und ihre Wechselwirkungen beherrschen, ein vollständiges Deployment mit Sonden, Volumes und Ressourcenangaben schreiben, mehrere LoRA-Adapter auf einem Basismodell bereitstellen und eine belastbare Messreihe erzeugen.

GESCHRIEBEN GEGEN

vLLM 0.8.x · Kubernetes 1.31 · RKE2 v1.31.x · Stand September 2026

Kapitel 7 hat erklärt, wie die Engine arbeitet. Dieses Kapitel setzt sie in Betrieb – mit dem Anspruch, dass am Ende jede gesetzte Option begründbar ist. Die Parameterreferenz in Abschnitt 8.3 ist bewusst als Nachschlageabschnitt angelegt.

8.1 Die Schnittstelle

8.1.1 Endpunkte

vLLM stellt eine OpenAI-kompatible Schnittstelle bereit. Das ist der Grund, warum sich bestehende Anwendungen und das Gateway aus Kapitel 11 ohne Anpassung dagegen betreiben lassen.

Endpunkt	Zweck	Auth nötig
/v1/chat/completions	Dialogformat mit Rollen – der Regelfall	ja
/v1/completions	Reine Textfortsetzung ohne Chat-Vorlage	ja
/v1/embeddings	Einbettungen, sofern ein passendes Modell geladen ist	ja
/v1/models	Welche Modelle und Adapter bereitstehen	ja
/tokenize, /detokenize	Token zählen ohne Inferenz – nützlich fürs Gateway	ja
/health	Lebenszeichen für Sonden	nein
/metrics	Prometheus-Kennzahlen – Kapitel 14	nein

MERKE

/health und /metrics sind bewusst nicht durch den API-Schlüssel geschützt. Das ist richtig so – Sonden und Prometheus sollen keine Zugangsdaten brauchen. Es bedeutet

aber, dass diese Pfade nicht nach außen erreichbar sein dürfen: `/metrics` gibt Auskunft über Auslastung und Modellnamen. Die Absicherung erfolgt über `NetworkPolicies`, nicht über den Server – Kapitel 13.

8.1.2 Der Modellname als Schnittstelle

Anwendungen sprechen ein Modell über seinen Namen an. Standardmäßig ist das der Repository-Pfad – unhandlich und an eine konkrete Herkunft gebunden. Mit `--served-model-name` lässt sich ein stabiler, fachlicher Name vergeben:

```
vllm serve /modelle/qwen2.5-7b-awq \
  --served-model-name unternehmen-chat-v1
```

MERKE

Das ist eine unterschätzte Architekturentscheidung. Ein fachlicher Name entkoppelt die Anwendung vom konkreten Modell: Ein Wechsel des Modells oder der Quantisierung wird dann zur Plattformänderung, nicht zur Anwendungsänderung. In Verbindung mit dem Gateway aus Kapitel 11 ist das die Grundlage für Modellwechsel ohne Beteiligung der Anwendungsteams.

8.1.3 Chat-Vorlage und Werkzeugaufrufe

Die Chat-Vorlage in `tokenizer_config.json` bestimmt, wie Rollen und Nachrichten in einen Prompt umgesetzt werden. Sie wird automatisch verwendet. Eine eigene Vorlage lässt sich über `--chat-template` vorgeben – was man nur tun sollte, wenn man weiß, warum.

Für Werkzeugaufrufe braucht der Server zusätzlich einen Auswerter, der die modell-spezifische Ausgabeform in das OpenAI-Format übersetzt:

```
vllm serve <modell> \
  --enable-auto-tool-choice \
  --tool-call-parser hermes
```

Der passende Auswerter hängt vom Modell ab; die Dokumentation nennt die unterstützten Kombinationen. Ohne ihn liefert das Modell Werkzeugaufrufe als Text im Antwortkörper – und die Anwendung sieht keine strukturierten Aufrufe.

8.2 Engine-Argumente: Referenz

Die folgenden Tabellen sind zum Nachschlagen gedacht. Verbindlich ist immer `vllm serve --help` der eingesetzten Version; Namen und Voreinstellungen ändern sich. Welche Argumente sich seit dem hier geprüften Stand 0.8.x geändert haben, steht gesammelt in Anhang C.5.

8.2.1 Modell und Format

Argument	Vorgabe	Wirkung
<code>--model</code>	–	Pfad oder Repository-Kennung
<code>--served-model-name</code>	Modellpfad	Fachlicher Name für Clients

Argument	Vorgabe	Wirkung
<code>--revision</code>	main	Version festnageln — in Produktion immer setzen
<code>--dtype</code>	auto	auto folgt der <code>config.json</code> ; siehe Kapitel 3
<code>--quantization</code>	erkannt	Nur setzen, wenn die Erkennung fehlschlägt
<code>--kv-cache-dtype</code>	auto	fp8 halbiert den KV-Bedarf — Hardwarefrage
<code>--trust-remote-code</code>	aus	Führt Code aus dem Repository aus. Nur bei geprüften Quellen
<code>--download-dir</code>	Cache	Wohin Modelle geladen werden — persistent halten

8.2.2 Speicher und Kontext

Argument	Vorgabe	Wirkung
<code>--gpu-memory-utilization</code>	0.9	Anteil des VRAM, den der Server beansprucht
<code>--max-model-len</code>	Modell	Obergrenze für Prompt plus Ausgabe je Anfrage
<code>--swap-space</code>	4	Hauptspeicher in GiB für ausgelagerte Blöcke
<code>--num-gpu-blocks-override</code>	–	Blockzahl erzwingen — nur zur Fehlersuche

8.2.3 Batching und Durchsatz

Argument	Vorgabe	Wirkung
<code>--max-num-seqs</code>	versch.	Wie viele Sequenzen gleichzeitig im Batch
<code>--max-num-batched-tokens</code>	versch.	Token-Budget je Schritt — Kapitel 7
<code>--enable-prefix-caching</code>	meist an	Wiederverwendung gemeinsamer Präfixe
<code>--enable-chunked-prefill</code>	meist an	Lange Prefills zerlegen
<code>--enforce-eager</code>	aus	Ausführungsgraphen abschalten — kürzerer Start, höherer Aufwand je Schritt

8.2.4 Verteilung und Server

Argument	Vorgabe	Wirkung
<code>--tensor-parallel-size</code>	1	GPUs je Modellkopie — Kapitel 9
<code>--pipeline-parallel-size</code>	1	Schichtaufteilung über Knoten — Kapitel 9
<code>--host, --port</code>	8000	Bindung
<code>--api-key</code>	–	Einfacher Schlüssel; echte Authentifizierung im Gateway
<code>--disable-log-requests</code>	aus	In Produktion setzen — sonst landen Prompts im Containerlog
<code>--max-logprobs</code>	20	Begrenzt zurückgegebene Wahrscheinlichkeiten


ACHTUNG Zwei Argumente mit Datenschutzbezug

--disable-log-requests verhindert, dass Prompts und Antworten im Containerlog erscheinen. Ohne diese Option landen personenbezogene Daten und Geschäftsgeheimnisse in der Log-Pipeline — und damit in Loki, in Backups und in der Aufbewahrung.

--trust-remote-code führt Python-Code aus dem Modell-Repository auf dem GPU-Knoten aus. Es ist für manche Modellarchitekturen nötig, aber es ist eine Vertrauensentscheidung im Sinne von Kapitel 3. Beide Optionen gehören in die Sicherheitsprüfung vor der Inbetriebnahme — Kapitel 13.

8.3 Die vier Parameter, die voneinander abhängen

Der häufigste Konfigurationsfehler entsteht daraus, dass vier Angaben unabhängig aussehen und es nicht sind.



Die Abhängigkeitskette der Speicherparameter

MERKE

Zwei Wirkungen, die überraschen:

Höhere Batchgrenzen verkleinern den KV-Cache. --max-num-seqs und --max-num-batched-tokens bestimmen, wie viel Speicher für Aktivierungen zurückgelegt wird. Wer sie erhöht, nimmt dem KV-Cache Platz weg — und kann damit die Gleichzeitigkeit **senken**, obwohl er sie erhöhen wollte.

--max-num-seqs ohne passenden KV-Cache ist wirkungslos. Steht die Grenze bei 256, reicht der Cache aber nur für 20 Sequenzen mit der konfigurierten Kontextlänge, dann bleiben es 20. Die höhere Zahl erzeugt lediglich eine längere Warteschlange.

8.3.1 Ein Einstellvorgang

Die Reihenfolge ist entscheidend. Jeder Schritt setzt den vorigen voraus.

1. **Kontextlänge aus dem Anwendungsfall bestimmen.** Nicht aus dem Modell. Was brauchen die Prompts tatsächlich, mit Reserve?
2. **Modell und Format wählen** nach der Bilanz aus Kapitel 3.
3. **--gpu-memory-utilization setzen.** 0,90 als Ausgangswert; 0,95 nur, wenn nichts anderes auf der Karte läuft und Messungen zeigen, dass es stabil bleibt.
4. **Starten und den KV-Cache im Log ablesen.** Gegen die eigene Rechnung prüfen.
5. **Gleichzeitigkeit berechnen:** Token-Budget geteilt durch Kontextlänge.
6. **--max-num-seqs auf diesen Wert setzen** — nicht höher. Alles darüber verlängert nur die Warteschlange.
7. **--max-num-batched-tokens nach Lastprofil wählen.** Niedrig für gleichmäßige Ausgabe, hoch für Durchsatz — Kapitel 7.
8. **Unter realistischer Last messen** und prüfen, ob Verdrängungen auftreten. Wenn ja, zurück zu Schritt 1.

8.4 Mehrere Adapter auf einem Basismodell

8.4.1 Warum das für Plattformen wichtig ist

Feinabgestimmte Modelle entstehen in Unternehmen meist als **Adapter**: Statt alle Gewichte zu ändern, werden kleine Zusatzmatrizen gelernt, die zur Laufzeit hinzugerechnet werden. Ein solcher Adapter ist wenige zehn bis wenige hundert Megabyte groß — gegenüber Gigabyte für ein vollständiges Modell.

Für den Plattformbetrieb ist das ein erheblicher Unterschied:

	Vollständige Modelle	Basismodell mit Adaptern
VRAM bei fünf Varianten	5 × Modellgröße	1 × Modellgröße + 5 kleine Adapter
Auf einer 24-GiB-Karte	nicht möglich	problemlos
Neue Variante bereitstellen	neues Deployment	Adapter nachladen
Batching über Varianten	getrennte Batches	gemeinsamer Batch möglich

MERKE

Die letzte Zeile ist der eigentliche Gewinn: Anfragen an verschiedene Adapter können im **selben** Batch verarbeitet werden, weil die Basisgewichte gemeinsam sind. Fünf Fachbereiche mit je eigener Feinabstimmung teilen sich damit eine GPU — und die Auslastung bleibt hoch.

Das ist der Fall, in dem „mehrere Modelle auf einer Karte“ tatsächlich funktioniert — im Unterschied zu den Aufteilungsverfahren aus Kapitel 6.

Schritt 8 ist der, den man nicht überspringen darf. Alle vorherigen Schritte sind Rechnungen; erst die Messung zeigt, ob die Annahmen stimmen.

8.4.2 Konfiguration

```
vllm serve <basismodell> \
  --enable-lora \
  --max-loras 4 \
  --max-lora-rank 32 \
  --lora-modules \
```

```
recht=/adapter/recht \
technik=/adapter/technik
```

Die Anwendung wählt den Adapter über den Modellnamen:

```
{"model": "recht", "messages": [...]}
```

Argument	Bedeutung
--max-loras	Wie viele Adapter gleichzeitig im GPU-Speicher gehalten werden
--max-cpu-loras	Wie viele im Hauptspeicher vorgehalten werden
--max-lora-rank	Obergrenze für den Rang — bestimmt den Speicherbedarf

Übersteigt die Zahl angeforderter Adapter --max-loras, tauscht der Server sie aus — was Zeit kostet. Bei vielen Adaptern mit wechselnder Nutzung lohnt sich ein höherer Wert; er kostet allerdings VRAM, der dem KV-Cache fehlt.

8.5 Deployment auf Kubernetes

Das folgende Manifest enthält alle Bestandteile, die in der Praxis gebraucht werden. Die begleitenden Anmerkungen erklären, warum jeder davon nötig ist.

```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: vllm-chat
spec:
  replicas: 1
  selector:
    matchLabels: {app: vllm-chat}
  template:
    metadata:
      labels: {app: vllm-chat}
    spec:
      runtimeClassName: nvidia
      nodeSelector:
        node-role/gpu: "true"
      tolerations:
        - key: nvidia.com/gpu
          operator: Equal
          value: present
          effect: NoSchedule
      terminationGracePeriodSeconds: 120
      containers:
        - name: vllm
          image: vllm/vllm-openai:v0.8.5
          args:
            - --model=/modelle/qwen2.5-7b-awq
            - --served-model-name=unternehmen-chat-v1
            - --max-model-len=8192
            - --max-num-seqs=24
```

```

- --gpu-memory-utilization=0.90
- --disable-log-requests
ports:
- containerPort: 8000
resources:
  limits:
    nvidia.com/gpu: 1
    cpu: "8"
    memory: 32Gi
  requests:
    cpu: "4"
    memory: 24Gi
volumeMounts:
- {name: modelle, mountPath: /modelle, readOnly: true}
- {name: shm, mountPath: /dev/shm}
startupProbe:
  httpGet: {path: /health, port: 8000}
  periodSeconds: 10
  failureThreshold: 60
readinessProbe:
  httpGet: {path: /health, port: 8000}
  periodSeconds: 5
livenessProbe:
  httpGet: {path: /health, port: 8000}
  periodSeconds: 30
  failureThreshold: 5
volumes:
- name: modelle
  persistentVolumeClaim: {claimName: modell-cache}
- name: shm
  emptyDir: {medium: Memory, sizeLimit: 8Gi}

```

8.5.1 Warum jeder Bestandteil nötig ist

Bestandteil	Begründung
startupProbe mit hoher Fehlerrate	Das Laden des Modells und die Kompilierung dauern Minuten. Ohne eigene Startsonde würde die Lebendsonde den Container vorzeitig neu starten — in einer Endlosschleife
readinessProbe getrennt	Ein Pod, der noch lädt, darf keinen Verkehr bekommen. Erst wenn /health antwortet, nimmt der Service ihn auf
livenessProbe mit Toleranz	Unter Volllast kann /health kurz verzögert antworten. Eine zu strenge Sonde beendet einen gesunden Server mitten unter Last
Nachfrist von 120 Sekunden	terminationGracePeriodSeconds: Laufende Anfragen sollen zu Ende laufen. Ohne diese Angabe werden sie nach 30 Sekunden abgeschnitten — Kapitel 5 hat das beim Leeren von Knoten behandelt
/dev/shm als Speichervolume	Die Prozesse der Engine kommunizieren darüber. Die Vorgabe von 64 MiB genügt nicht und äußert sich als Absturz beim Start
CPU-Anforderung von 4 bis 8	Tokenisierung, HTTP und Ausgabeauffbereitung — siehe Kapitel 7

Bestandteil	Begründung
Hauptspeicher über Modellgröße	Gewichte werden beim Laden zunächst dort abgelegt
Modell-Volume readOnly	Der Server verändert Modelle nicht. Schreibrechte wären unnötiges Risiko

ACHTUNG Die häufigste Fehlkonfiguration

Fehlt die `startupProbe`, greift die `livenessProbe` sofort. Bei einem Modell mit drei Minuten Ladezeit und einer Lebendsonde mit 30 Sekunden Toleranz wird der Container getötet, bevor er je bereit war — und startet neu, lädt wieder, wird wieder getötet.

Im Ereignisprotokoll sieht das nach einem Absturz aus. Tatsächlich hat der Server nie einen Fehler gemacht.

8.5.2 Abschalten ohne Abbrüche

Beim Beenden soll der Server keine neuen Anfragen mehr annehmen, laufende aber zu Ende führen. Kubernetes unterstützt das, wenn zwei Dinge zusammenpassen: Der Pod wird aus dem Service entfernt, **bevor** das Beendigungssignal wirkt, und die Nachfrist ist lang genug.

Bei langen Antworten — 2 000 Ausgabetoken sind schnell 40 Sekunden — ist die Standardnachfrist von 30 Sekunden zu kurz. 120 Sekunden sind ein brauchbarer Ausgangswert; er sollte über der längsten erwarteten Antwortdauer liegen.

8.6 Modelle in den Cluster bringen

Kapitel 3 hat vorgerechnet, dass der Weg zum Modell den Start dominiert — zwei Minuten aus dem Internet gegen fünf Sekunden vom lokalen Volume. Für das Deployment folgen daraus drei brauchbare Muster.

Muster	Aufbau	Einordnung
PVC mit ReadOnlyMany	Ein Volume, das alle Modell-Pods einhängen. Befüllt durch einen einmaligen Auftrag	Der Regelfall. Setzt eine Storage-Klasse mit Mehrfachzugriff voraus
Knotenlokaler Cache	<code>hostPath</code> je GPU-Knoten, befüllt durch ein DaemonSet	Schnellste Ladezeit. Knotengebunden, keine Zugriffskontrolle
Init-Container lädt	Jeder Pod holt sein Modell beim Start aus dem Objektspeicher	Sauber getrennt, aber jeder Neustart kostet die volle Ladezeit

Ein Init-Container, der aus dem eigenen Objektspeicher lädt und dabei die Prüfsumme verifiziert, verbindet Nachvollziehbarkeit mit vertretbarer Ladezeit:

```
initContainers:
- name: modell-holen
  image: amazon/aws-cli:2.17.0
  command: ["sh", "-c"]
  args:
  - |
    set -e
```



```

test -f /modelle/fertig && exit 0
aws s3 sync "$QUELLE" /modelle/ \
  --endpoint-url "$ENDPUNKT"
touch /modelle/fertig
env:
- name: QUELLE
  value: s3://modelle/qwen2.5-7b-awq
- name: ENDPUNKT
  value: http://minio.storage.svc:9000
volumeMounts:
- {name: modelle, mountPath: /modelle}

```

MERKE

Die Markierungsdatei ist wichtig: Ohne sie lädt jeder Neustart erneut. Mit ihr wird das Volume einmal befüllt und danach nur noch geprüft. Für Modellwechsel wird die Markierung gelöscht – oder, besser, ein Verzeichnis je Modellversion verwendet, was zugleich Rollbacks ermöglicht. Kapitel 16 behandelt das als Teil der Delivery-Kette.

8.7 Mehrere Repliken

8.7.1 Warum die Lastverteilung hier anders funktioniert

Bei gewöhnlichen Diensten ist die Verteilung von Anfragen auf Repliken eine gelöste Frage: Ein Service verteilt sie, und weil die Repliken zustandslos sind, ist es gleichgültig, welche antwortet.

Bei Inferenz-Servern stimmt die Annahme der Zustandslosigkeit nicht. Jede Replik hat ihren **eigenen** Prefix-Cache. Und der ist zustandsbehaftet im wörtlichen Sinne: Er enthält genau die Präfixe, die diese Replik bereits gesehen hat.

MEHRSTUFIGER DIALOG, drei Anfragen derselben Sitzung

REIHUM VERTEILT

Runde 1 → Replik A
berechnet alles
Runde 2 → Replik B
kennt nichts
berechnet ALLES neu
Runde 3 → Replik C
kennt nichts
berechnet ALLES neu

Prefill-Arbeit wächst
mit jeder Runde quadratisch

SITZUNGSBEZOGEN

Runde 1 → Replik A
berechnet alles
Runde 2 → Replik A
Verlauf im Cache
nur die neue Frage
Runde 3 → Replik A
nur die neue Frage

Prefill-Arbeit bleibt klein

Bei mehrstufigen Dialogen entscheidet die Zuordnung über die Trefferquote.

MERKE

Bei mehrstufigen Dialogen wächst der Prompt mit jeder Runde, weil der bisherige Verlauf mitgeschickt wird. Landet jede Runde auf einer anderen Replik, wird der

gesamte Verlauf jedes Mal neu berechnet. Bei zehn Runden bedeutet das ein Vielfaches der nötigen Arbeit.

Die Gegenmaßnahme ist eine Zuordnung, die zusammengehörige Anfragen auf dieselbe Replik führt. Kubernetes bietet dafür `sessionAffinity` auf IP-Basis — was hinter einem Gateway nicht greift, weil dann alle Anfragen von derselben Adresse kommen. Die belastbare Lösung liegt im Gateway oder in einer cache-bewussten Weiterleitung; Kapitel 10 und 11 behandeln beide.

8.7.2 Repliken sind keine Skalierung des KV-Cache

Ein zweiter Punkt, der oft falsch angenommen wird: Zwei Repliken verdoppeln den Durchsatz, aber sie verdoppeln **nicht** die mögliche Kontextlänge einer einzelnen Anfrage. Jede Replik hat ihren eigenen, gleich großen KV-Cache. Eine Anfrage, die auf einer Replik nicht passt, passt auch auf zwei nicht.

Ziel	Richtiges Mittel
Mehr gleichzeitige Anfragen	Mehr Repliken
Längerer Kontext je Anfrage	Größerer KV-Cache — quantisieren, Kapitel 3
Größeres Modell	Mehrere GPUs je Replik — Kapitel 9
Ausfallsicherheit	Mehr Repliken auf verschiedenen Knoten

Für den letzten Punkt gehört eine Verteilungsregel ins Manifest, sonst landen beide Repliken auf demselben Knoten:

```
topologySpreadConstraints:
- maxSkew: 1
  topologyKey: kubernetes.io/hostname
  whenUnsatisfiable: DoNotSchedule
  labelSelector:
    matchLabels: {app: vllm-chat}
```

8.8 Absicherung des Deployments

Die offiziellen Inferenz-Images sind auf Funktion optimiert, nicht auf Härtung. Für eine Unternehmensplattform gehören einige Angaben ergänzt — mit einer Einschränkung, die man kennen muss.

```
securityContext:
  runAsNonRoot: true
  runAsUser: 1000
  allowPrivilegeEscalation: false
  capabilities:
    drop: ["ALL"]
  seccompProfile:
    type: RuntimeDefault
```

ACHTUNG Nicht jedes Image trägt das

Viele Inferenz-Images laufen als `root` und schreiben in Verzeichnisse, die einem unprivilegierten Nutzer nicht gehören — etwa den Modell-Cache oder Kompilierungsverzeichnisse. `runAsNonRoot` führt dann zu einem Absturz beim Start.

Der gangbare Weg ist, die betroffenen Pfade über Umgebungsvariablen auf beschreibbare Volumes umzulenken und das Ergebnis zu prüfen — nicht, die Härting wegzulassen. Ein `readOnlyRootFilesystem` mit gezielten `emptyDir`-Volumes für Cache und temporäre Dateien ist erreichbar, erfordert aber einen Durchlauf mit Fehlersuche.

Wo das nicht gelingt, gehört das Ergebnis dokumentiert: Ein Inferenz-Pod mit Root-Rechten auf einem GPU-Knoten ist eine bewusste Restrisiko-Entscheidung, keine Nachlässigkeit. Kapitel 13 ordnet sie in das Bedrohungsmodell ein.

Ergänzend gehören `NetworkPolicies` dazu: Der Inferenz-Dienst soll nur vom Gateway erreichbar sein und selbst nur den Objektspeicher erreichen dürfen. Kapitel 13 entwickelt das vollständig.

8.9 Konfiguration versionieren

Die Engine-Argumente sind die eigentliche Konfiguration des Dienstes — und sie gehören damit unter Versionskontrolle, nicht in ein `kubectl edit`.

Ablageort	Bewertung
Direkt in <code>args</code>	Sichtbar im Manifest, gut nachvollziehbar. Der Regelfall
<code>ConfigMap</code>	Änderungen ohne Manifestwechsel — aber ohne Neustart wirkungslos, was Verwirrung stiftet
Helm-Werte	Der praktikable Weg bei mehreren Umgebungen

MERKE

Eine Änderung an den Engine-Argumenten wirkt erst beim Neustart des Pods — der das Modell neu lädt und die Kompilierung wiederholt. Sie ist damit betrieblich eine Neuausrollung, keine Konfigurationsanpassung.

Daraus folgt: Parametertuning gehört nicht in den laufenden Produktionsbetrieb, sondern in eine Messreihe wie in Abschnitt 8.8. Wer in Produktion an `--max-num-seqs` dreht, erzeugt bei jedem Versuch einen Neustart mit minutenlanger Nichtverfügbarkeit.

Ein Ausschnitt, der die Argumente aus Helm-Werten erzeugt und dabei die Modellversion festnagelt:

```
args:
  - --model=/modelle/{{ .Values.modell.pfad }}
  - --served-model-name={{ .Values.modell.name }}
  - --revision={{ .Values.modell.revision }}
  - --max-model-len={{ .Values.engine.kontext }}
  - --max-num-seqs={{ .Values.engine.sequenzen }}
  - --gpu-memory-utilization={{ .Values.engine.speicher }}
  - --disable-log-requests
```

8.10 Pod-Größe berechnen

Zum Nachschlagen die Ressourcenangaben für die Modellklassen aus Kapitel 3. Die Werte sind Ausgangspunkte, keine Messwerte.

Modell und Format	GPU	CPU	RAM	/dev/shm
0,5B bis 3B, BF16	1	2–4	8 Gi	2 Gi
7B bis 8B, 4 Bit	1	4–8	24 Gi	8 Gi
7B bis 8B, BF16	1	4–8	32 Gi	8 Gi
14B, 4 Bit	1	4–8	32 Gi	8 Gi
32B, 4 Bit	1	8	48 Gi	8 Gi

Die Faustregel für den Hauptspeicher lautet: mindestens das Anderthalbfache der Modellgröße auf der Platte, weil die Gewichte beim Laden zunächst dort landen. Die CPU-Angabe steigt mit der Zahl gleichzeitiger Anfragen, weil Tokenisierung und Ausgabeaufbereitung dort stattfinden.

Prüfen Sie die Werte im Betrieb nach:

`kubecttl top pod` gegen die gesetzten Anforderungen. Zu großzügige Anforderungen blockieren auf einem GPU-Knoten Kapazität, die andere Pods brauchen könnten.

8.11 Benchmarking

8.11.1 Warum Methodik hier alles ist

Kapitel 2 hat die Fehlerquellen genannt: fehlender Warmlauf, schwankende Ausgabelängen, unbemerkt wirkendes Prefix Caching, thermische Drosselung. Eine Messung ohne festgehaltene Randbedingungen ist wertlos — besonders dann, wenn sie später eine Beschaffung begründen soll.

8.11.2 Das mitgelieferte Werkzeug

```
vllm bench serve \
  --backend openai-chat \
  --base-url http://localhost:8000 \
  --model unternehmen-chat-v1 \
  --dataset-name random \
  --random-input-len 1024 \
  --random-output-len 256 \
  --num-prompts 200 \
  --request-rate 4
```

Der Parameter `--request-rate` ist der wichtigste: Er bestimmt, ob Sie **Durchsatz unter Sättigung** messen — alle Anfragen auf einmal — oder **Latenz bei realistischer Last**. Beides ist sinnvoll, aber es sind verschiedene Messungen mit verschiedenen Aussagen.

Messart	Vorgehen	Beantwortet
Sättigung	Alle Anfragen sofort	Wie viel schafft der Server maximal
Feste Rate	Anfragen gleichmäßig verteilt	Hält der Server die Latenzzusage bei dieser Last
Rampe	Rate schrittweise erhöhen	Ab welcher Last bricht die Zusage

MERKE

Für Kapazitätsplanung ist die **Rampe** die aussagekräftigste Messung: Sie liefert genau den Punkt, an dem die Latenzzusage reißt — und das ist die Zahl, mit der man dimensioniert. Die Sättigungsmessung liefert eine größere, schönere Zahl, die im Betrieb nie erreicht wird, weil dort niemand mehr die Zusage einhält.

8.11.3 Was zu einer Messung gehört

Ohne diese Angaben ist ein Ergebnis nicht reproduzierbar und sollte nicht weitergegeben werden:

Angabe	Beispiel
Modell, Format, Version	Qwen 2.5 7B, AWQ, feste Revision
Server- und Treiberversion	vLLM 0.8.5, Treiber 550.x
Hardware	RTX-Klasse, 24 GiB, PCIe 4.0
Engine-Argumente	vollständig, nicht nur die veränderten
Lastprofil	1 024 Eingabe-, 256 Ausgabetoken, Rate 4/s, 200 Anfragen
Prefix Caching	aktiv oder nicht — verändert das Ergebnis erheblich
Warmlauf	Zahl verworfener Anfragen
Ergebnisse	TTFT und TPOT als Median und 95. Perzentil, Durchschnitt

ACHTUNG Mittelwerte allein sind unbrauchbar

Kapitel 7 hat gezeigt, dass Verdrängung und Head-of-Line-Blocking einzelne Anfragen stark verzögern, ohne den Mittelwert zu verschieben. Eine Messung, die nur Mittelwerte berichtet, verbirgt genau die Probleme, die im Betrieb auffallen. Perzentile gehören in jedes Ergebnis.

8.12 Lab: deployen, tunen, messen

LAB Von der Rechnung zur belegten Konfiguration

Ziel: Einen produktionsnahen vLLM-Dienst betreiben und seine Konfiguration mit Messwerten begründen.

Schritt 1 — Modell bereitstellen. Das Modell liegt auf einem persistenten Volume, nicht im Internet — Kapitel 3:

```
kubectl apply -f modell-cache-pvc.yaml
kubectl run lader --rm -it --restart=Never \
  --image=python:3.11-slim \
  --overrides='{ "spec": { "volumes": [ { "name": "m",
    "persistentVolumeClaim": { "claimName": "modell-cache" } } ],
    "containers": [ { "name": "lader", "image": "python:3.11-slim",
    "volumeMounts": [ { "name": "m", "mountPath": "/modelle" } ],
    "stdin": true, "tty": true } ] } }' -- bash
```

Im Container das Modell in /modelle ablegen.

Schritt 2 – Deployment ausrollen. Manifest aus Abschnitt 8.6 anwenden:

```
kubectl apply -f vllm-chat.yaml
kubectl rollout status deploy/vllm-chat --timeout=15m
```

Erwartete Ausgabe: Der Rollout dauert mehrere Minuten. Wenn die Startsonde greift, bleibt der Pod in Running ohne Ready – genau so soll es sein.

Schritt 3 – KV-Cache gegen die Rechnung prüfen.

```
kubectl logs deploy/vllm-chat | grep -i -E \
'kv cache|gpu blocks'
```

Rechnen Sie das Ergebnis nach: Blöcke mal 16 Token, geteilt durch die Kontextlänge ergibt die mögliche Gleichzeitigkeit. Stimmt sie mit `--max-num-seqs` überein?

Schritt 4 – Rampe fahren. Drei Messungen mit steigender Rate:

```
for r in 2 4 8; do
  echo "== Rate $r =="
  vllm bench serve --backend openai-chat \
    --base-url http://vllm-chat:8000 \
    --model unternehmen-chat-v1 \
    --dataset-name random \
    --random-input-len 1024 --random-output-len 256 \
    --num-prompts 200 --request-rate "$r"
done
```

Erwartete Ausgabe: Bei niedriger Rate bleiben TTFT und TPOT stabil. Ab einer bestimmten Rate steigt zuerst das 95. Perzentil der TTFT, dann der Median. Dieser Punkt ist die belastbare Kapazität des Dienstes.

Schritt 5 – Gegenprobe in den Metriken. Während der höchsten Rate:

```
kubectl exec deploy/vllm-chat -- \
  sh -c 'curl -s localhost:8000/metrics' \
  | grep -E 'num_requests_waiting|num_preemptions'
```

Steigen wartende Anfragen und Verdrängungen, ist die Sättigung erreicht – und die Ursache liegt beim KV-Cache, nicht bei der Rechenleistung.

Schritt 6 – Eine Größe ändern, erneut messen. Senken Sie `--max-model-len` auf 4096 und wiederholen Sie Schritt 3 bis 5. **Erwartung:** Doppeltes Token-Budget, höhere mögliche Gleichzeitigkeit, die Sättigung tritt später ein.

Ergebnis: Eine Konfiguration, die sich mit Zahlen begründen lässt – und eine Messreihe, die als Grundlage für die Kapazitätsplanung in Kapitel 17 dient.

8.13 Einbettungsmodelle betreiben

Für die RAG-Strecke aus Kapitel 15 wird neben dem Sprachmodell ein Einbettungsdienst gebraucht. Derselbe Server kann das – mit einer anderen Aufgabenstellung und deutlich anderem Betriebsverhalten.

```
vllm serve BAAI/bge-m3 \
  --task embed \
```

```
--served-model-name einbettung-v1 \  
--max-model-len 512
```

Die Unterschiede zum Sprachmodell wurden in Kapitel 2 hergeleitet und werden hier betrieblich konkret:

	Sprachmodell	Einbettungsmodell
Endpunkt	/v1/chat/completions	/v1/embeddings
KV-Cache	dominiert den Speicher	entfällt – kein Decode
--max-model-len	Kapazitätsentscheidung	Länge des längsten Abschnitts
Antwortzeit	Sekunden	Millisekunden
Sinnvolle Batchgröße	durch KV-Cache begrenzt	sehr groß
GPU nötig?	ja	bei moderater Last oft nicht

MERKE

Die letzte Zeile ist die betrieblich wichtigste. Ein Einbettungsmodell unter einem Gigabyte läuft auf CPU-Knoten mit vertretbarer Latenz – und nimmt dem Sprachmodell dann keinen VRAM weg. Kapitel 2 hatte vorgerechnet, dass ein Gigabyte rund 8 000 Token KV-Cache kostet.

Die Entscheidung fällt an der Ingestion-Last, nicht am Abfragebetrieb: Das einmalige Einlesen eines großen Dokumentenbestands profitiert erheblich von der GPU, der laufende Abfragebetrieb selten. Ein sinnvolles Muster ist deshalb ein dauerhafter CPU-Dienst für Abfragen und ein zeitweiliger GPU-Auftrag für die Ingestion. Kapitel 15 setzt das um.

8.14 Ein Modellwechsel in Produktion

Der Wechsel auf eine neue Modellversion ist die häufigste Änderung im Betrieb – und auf einem Cluster mit einem GPU-Knoten die unangenehmste.

8.14.1 Warum es hier nicht wie sonst geht

Ein gewöhnliches Rolling Update startet den neuen Pod, wartet auf Bereitschaft und beendet danach den alten. Das setzt voraus, dass beide **gleichzeitig** laufen können. Bei `nvidia.com/gpu: 1` und einer Karte ist das ausgeschlossen: Der neue Pod bleibt in Pending, bis der alte weg ist – und `maxSurge` läuft ins Leere.

Ausgangslage	Möglich	Ausfallzeit
Eine GPU im Cluster	Nur Neustart: alt beenden, neu starten	Volle Ladezeit – Minuten
Zwei GPUs	Rolling Update mit <code>maxSurge: 1</code>	keine
Zwei GPUs, Canary	Beide Versionen parallel, Verkehr schrittweise umlenken	keine – Kapitel 10

ACHTUNG Die Strategie muss zur Hardware passen

Die Standardstrategie `RollingUpdate` mit `maxSurge: 1` führt bei einer einzelnen GPU zu einem Deployment, das hängt: Der neue Pod wartet auf eine GPU, die der alte hält, und der alte wird erst beendet, wenn der neue bereit ist.

Auf einem Ein-GPU-Cluster ist deshalb `strategy: Recreate` die **ehrlichere** Einstellung: Sie erzeugt eine kurze, planbare Nichtverfügbarkeit statt eines blockierten Rollouts.

```
spec:
  strategy:
    type: Recreate          # bei genau einer GPU
```

8.14.2 Der Ablauf mit zwei Knoten

1. Neue Modellversion auf das Volume legen — in ein **eigenes** Verzeichnis, nicht über die alte schreiben
2. Manifest mit neuem Pfad und neuer `--revision` ausrollen
3. Bereitschaft abwarten; die Startsonde deckt die Ladezeit ab
4. Prüfsatz aus Kapitel 3 gegen den neuen Endpunkt fahren
5. Erst nach bestandener Prüfung den Verkehr vollständig umlenken
6. Alte Version noch einige Tage vorhalten — ein Rollback ist dann eine Manifeständerung statt eines erneuten Ladevorgangs

MERKE

Getrennte Verzeichnisse je Modellversion sind die Voraussetzung für schnelle Rollbacks. Wer die alte Version überschreibt, kann nur über einen erneuten Ladevorgang zurück — und der dauert genau dann Minuten, wenn es eilt.

8.15 Logs richtig einstellen

Die Protokollierung eines Inferenz-Dienstes hat zwei Seiten: Sie ist unverzichtbar für die Fehlersuche und zugleich der wahrscheinlichste Ort, an dem vertrauliche Inhalte ungewollt landen.

8.15.1 Was der Server protokolliert

Kategorie	Inhalt	In Produktion
Start	Modell, Argumente, KV-Cache-Größe, gewählte Kernel	behalten — die wichtigste Quelle für Nachvollziehbarkeit
Durchsatz	Regelmäßige Zusammenfassung: laufende und wartende Anfragen, Cache-Belegung	behalten
Anfragen	Prompt, Sampling-Parameter, teils die Antwort	abschalten — <code>--disable-log-requests</code>
Fehler	Ausnahmen, abgebrochene Verbindungen	behalten

Die Startmeldungen verdienen besondere Aufmerksamkeit: Sie enthalten die Zahl der KV-Blöcke, die gewählte Kernel-Implementierung und die wirksamen Argumente. Bei jeder Störung ist das die erste Stelle, an der man nachsieht — und bei jeder Inbetriebnahme die Stelle, an der man die eigene Rechnung prüft.

ACHTUNG Prompts im Log sind ein Datenschutzvorfall

Ohne `--disable-log-requests` erscheinen Anfrageinhalte im Containerlog. Von dort wandern sie in die Log-Pipeline, nach Loki, in dessen Aufbewahrung und in Backups. Damit liegen personenbezogene Daten und Geschäftsgeheimnisse an einem Ort, für den weder eine Zweckbindung noch eine Löschfrist definiert wurde.

In Fassungen nach 0.8.x ist diese Voreinstellung umgekehrt — siehe Anhang C.5. Die Regel bleibt, der Handgriff ändert sich.

Das ist keine theoretische Sorge: Es ist der häufigste Weg, auf dem Prompt-Inhalte eine Organisation unbeabsichtigt durchqueren. Die Option gehört in jede Produktionskonfiguration — und die Protokollierung von Anfragen gehört an die einzige Stelle, an der sie kontrolliert stattfinden kann: das Gateway, mit ausdrücklich festgelegter Aufbewahrung. Kapitel 11 und 13 behandeln das.

8.15.2 Die Durchsatzmeldung lesen

In regelmäßigen Abständen gibt der Server eine Zusammenfassung aus. Sie enthält genau die Größen aus Kapitel 7 und ist bei der Fehlersuche oft schneller zur Hand als ein Dashboard:

```
kubectl logs deploy/vllm-chat --tail=20 \
| grep -i -E 'running|waiting|cache usage'
```

Erwartete Ausgabe: Zeilen mit der Zahl laufender und wartender Anfragen sowie der Cache-Belegung. Drei Muster sind aussagekräftig:

Beobachtung	Bedeutung
Laufend niedrig, wartend null, Cache niedrig	Der Dienst langweilt sich — oder der Client serialisiert seine Anfragen
Laufend hoch, wartend null, Cache mittel	Der gesunde Arbeitspunkt
Laufend am Maximum, wartend steigend, Cache nahe voll	Sättigung — die Kapazitätsgrenze aus Abschnitt 8.9 ist erreicht

8.15.3 Protokollierung im Cluster

Die Ausführlichkeit lässt sich über eine Umgebungsvariable steuern. Für den Normalbetrieb genügt die Standardstufe; für die Fehlersuche liefert eine höhere Stufe deutlich mehr Details — allerdings in einer Menge, die man nicht dauerhaft aufbewahren will.

```
env:
- name: VLLM_LOGGING_LEVEL
  value: INFO # DEBUG nur zur Fehlersuche
```

MERKE

Eine erhöhte Protokollstufe ist eine vorübergehende Maßnahme, keine Einstellung. Sie erzeugt bei einem ausgelasteten Dienst schnell Gigabyte je Stunde — und da eine Änderung der Umgebungsvariablen ohnehin einen Neustart erfordert, verliert man dabei genau den Zustand, den man untersuchen wollte.

Für Störungen, die sich nicht reproduzieren lassen, sind die Metriken aus Kapitel 14 das bessere Werkzeug: Sie liegen dauerhaft vor, ohne Inhalte zu speichern.

8.16 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Pod startet endlos neu, ohne je Ready zu werden	Lebenssonde greift während des Modellladens	Ereignisprotokoll – <code>Liveness probe failed</code> vor dem ersten Erfolg	<code>startupProbe</code> mit hoher <code>failureThreshold</code> ergänzen
Absturz beim Start, Meldung zu gemeinsamem Speicher	<code>/dev/shm</code> zu klein – Vorgabe 64 MiB	<code>df -h /dev/shm</code> im Container	<code>emptyDir</code> mit <code>medium: Memory</code> einhängen
Server startet nicht, Meldung zur Sequenzlänge	Kontextgrenze passt nicht in den KV-Cache – Kapitel 3	Modellgröße gegen verfügbaren Speicher rechnen	<code>--max-model-len</code> senken oder quantisiertes Modell
Hohe Latenz, GPU-Auslastung niedrig	CPU-Mangel im Pod	CPU-Auslastung gegen das Limit halten	CPU-Anforderung auf 4 bis 8 Kerne erhöhen
Anfragen brechen bei Rollouts ab	Nachfrist zu kurz	Antwortdauer gegen <code>terminationGracePeriodSeconds</code>	Nachfrist über die <code>terminationGracePeriodSeconds</code> setzte Antwortdauer setzen
Prompts erscheinen im Log	<code>--disable-log-requests</code> nicht gesetzt	<code>kubectl logs</code> auf Anfrageinhalte prüfen	Option setzen und Log-Aufbewahrung prüfen – Kapitel 13
Adapter wird nicht gefunden	Nicht in <code>--lora-modules</code> registriert oder Pfad falsch	<code>/v1/models</code> abfragen	Adapter registrieren oder zur Laufzeit nachladen
Erste Anfragen nach dem Start sehr langsam	Kompilierung und Aufzeichnung der Ausführungsgraphen	Zeitverlauf der ersten Anfragen	Normal – Warmlauf in die Bereitschaftsprüfung aufnehmen

8.17 Interviewfragen

INTERVIEWFRAGE

Wie stellen Sie `gpu-memory-utilization` und `max-model-len` ein?

Schwach ist, an `--gpu-memory-utilization` zu drehen, bis der Server startet.

Senior ist die Reihenfolge: Kontextlänge zuerst, und zwar aus dem Anwendungsfall – nicht aus dem Modell. Dann Modell und Format nach der VRAM-Bilanz. Dann `--gpu-memory-utilization` auf 0,90, starten, den tatsächlichen KV-Cache im Log gegen die eigene Rechnung prüfen. Daraus die mögliche Gleichzeitigkeit berechnen und `--max-num-seqs` darauf setzen – nicht höher, weil das nur die Warteschlange

verlängert. Wer ergänzt, dass höhere Batchgrenzen den KV-Cache **verkleinern**, kennt die unangenehme Wechselwirkung.

INTERVIEWFRAGE

Wie deployen Sie vLLM auf Kubernetes?

Gut ist ein Deployment mit GPU-Limit und Service.

Senior nennt die Bestandteile, die in der Praxis fehlen und Ausfälle verursachen: `startupProbe` wegen der minutenlangen Ladezeit – ohne sie tötet die Lebendsonde den Container in einer Endlosschleife –, `/dev/shm` als Speichervolume, CPU-Anforderung von mehreren Kernen, Hauptspeicher über Modellgröße, `terminationGracePeriodSeconds` über der längsten Antwortdauer, `runtimeClassName` und Toleranz für den GPU-Taint, und das Modell auf einem persistenten Volume statt aus dem Internet.

INTERVIEWFRAGE

Fünf Fachbereiche wollen je ein eigenes feinabgestimmtes Modell. Wie lösen Sie das?

Schwach sind fünf Deployments mit fünf Modellen.

Senior ist Multi-LoRA: ein Basismodell, fünf Adapter. Die Begründung liefert die Rechnung – fünf vollständige Modelle passen auf keine 24-GiB-Karte, ein Basismodell plus fünf Adapter problemlos. Der eigentliche Gewinn ist aber das gemeinsame Batching: Anfragen an verschiedene Adapter laufen im selben Batch, weil die Basisgewichte geteilt sind. Wer ergänzt, dass die Adapter über den Modellnamen adressiert werden und sich damit sauber ins Gateway einfügen, denkt die Plattform mit.

INTERVIEWFRAGE

Wie messen Sie die Kapazität eines Inferenz-Dienstes?

Schwach ist eine Sättigungsmessung mit einer großen Durchsatzzahl.

Senior ist die Rampe: Die Anfragerate wird schrittweise erhöht, bis das 95. Perzentil der TTFT die Zusage reißt. Dieser Punkt ist die belastbare Kapazität – die Sättigungszahl wird im Betrieb nie erreicht, weil dort niemand mehr die Zusage einhält. Dazu die Randbedingungen, ohne die eine Messung nicht reproduzierbar ist: Modell, Format, Version, Engine-Argumente, Lastprofil, Prefix-Caching-Zustand und Warmlauf.

8.18 Zusammenfassung

- Die OpenAI-kompatible Schnittstelle macht vLLM ohne Anpassung für bestehende Anwendungen und für das Gateway nutzbar. `--served-model-name` entkoppelt den fachlichen Namen vom konkreten Modell.
- `/health` und `/metrics` sind absichtlich ungeschützt und müssen über Network-Policies abgesichert werden.
- Vier Parameter hängen voneinander ab: `--gpu-memory-utilization`, `--max-model-len`, `--max-num-seqs` und `--max-num-batched-tokens`. Höhere

- Batchgrenzen verkleinern den KV-Cache; eine zu hohe Sequenzgrenze verlängert nur die Warteschlange.
- Der Einstellvorgang beginnt bei der Kontextlänge aus dem Anwendungsfall und endet bei einer Messung unter realistischer Last.
 - `--disable-log-requests` gehört in Produktion gesetzt, sonst landen Prompts in der Log-Pipeline. `--trust-remote-code` ist eine Vertrauensentscheidung.
 - Multi-LoRA erlaubt viele feinabgestimmte Varianten auf einem Basismodell – mit gemeinsamem Batching über die Varianten hinweg.
 - Ein produktionsfähiges Deployment braucht `startupProbe`, ausreichend `/dev/shm`, mehrere CPU-Kerne, Hauptspeicher über Modellgröße und eine Nachfrist über der längsten Antwortdauer.
 - Für die Kapazitätsplanung ist die Rampenmessung die richtige: Sie liefert den Punkt, an dem die Latenzzusage reißt. Ergebnisse ohne Perzentile und ohne Randbedingungen sind wertlos.

Quellen und Weiterlesen

- vLLM: *Documentation — Engine Arguments*. Verbindliche Referenz; Namen und Voreinstellungen ändern sich zwischen Versionen.
- vLLM: *Documentation — OpenAI-Compatible Server*. Endpunkte, Werkzeugauswerter, Chat-Vorlagen.
- vLLM: *Documentation — LoRA Adapters*. Konfiguration und Grenzen des Adapterbetriebs.
- vLLM: *Documentation — Benchmarks*. Das mitgelieferte Messwerkzeug und seine Parameter.
- Kubernetes: *Configure Liveness, Readiness and Startup Probes* — warum die Startsonde bei langen Ladezeiten unverzichtbar ist.

Distributed Inference

ZIEL	Entscheiden können, wann ein Modell auf mehrere GPUs verteilt werden muss — und wann das ein Fehler wäre. Die Verfahren, ihre Kommunikationskosten und ihre Konfiguration beherrschen.
SETZT VORAUS	Kapitel 3 — VRAM-Bilanz —, Kapitel 4 — Topologie und Bandbreiten — und Kapitel 7 — Aufbau der Engine.
DANACH KANNST DU	Tensor, Pipeline und Data Parallelism unterscheiden und begründet auswählen, den Kommunikationsaufwand abschätzen, eine Multi-GPU-Konfiguration schreiben und die Grenzen des Verfahrens benennen.

GESCHRIEBEN GEGEN

vLLM 0.8.x · Ray 2.4x · Stand September 2026

ACHTUNG Dieses Kapitel hat kein Lab

Das Referenz-Lab hat eine GPU. Tensor und Pipeline Parallelism lassen sich damit nicht ausführen — eine Simulation gibt es nicht.

Das Kapitel ist deshalb als Konzept- und Referenzkapitel angelegt. Es enthält die vollständige Konfiguration, die Rechnungen zur Dimensionierung und die Entscheidungskriterien — alles, was man für ein Interview und für eine Kundenumgebung mit mehreren GPUs braucht. Am Ende steht ein optionales Lab auf gemieteter Hardware für wenige Euro, falls Sie es tatsächlich messen möchten.

9.1 Die Entscheidungskette

Bevor die Verfahren behandelt werden, die wichtigste Frage: **Wann braucht man überhaupt mehr als eine GPU?** Es gibt genau drei Gründe, und nur einer davon erzwingt verteiltes Serving.


Grund	Situation	Antwort
Durchsatz	Eine GPU schafft die Anfragerate nicht	Mehr Repliken — jede mit eigenem Modell. Kein verteiltes Serving
Ausfallsicherheit	Wartung soll ohne Ausfall möglich sein	Mehr Repliken auf verschiedenen Knoten
Modellgröße	Die Gewichte passen nicht auf eine Karte	Verteiltes Serving — hier führt kein Weg vorbei

MERKE

Zwei von drei Gründen werden durch schlichte Vervielfachung gelöst, nicht durch Verteilung. Verteiltes Serving ist ausschließlich die Antwort auf ein **Kapazitätsproblem des einzelnen Modells** — und selbst dann erst, nachdem die Alternativen aus Kapitel 3 geprüft wurden.

9.1.1 Die Leiter

Die Reihenfolge, in der man vorgeht, ist festgelegt — jede Stufe ist teurer als die vorige:




Die Entscheidungsleiter. Jede Stufe kostet mehr als die darunter.

9.2 Tensor Parallelism

9.2.1 Die Idee

Tensor Parallelism zerlegt die **Gewichtsmatrizen** selbst. Jede GPU hält einen Teil jeder Schicht und rechnet an denselben Token mit — nur eben an einem Ausschnitt. Bei der Aufmerksamkeit ist die Aufteilung natürlich: Die Köpfe werden auf die GPUs verteilt. Bei den Feedforward-Schichten wird die erste Matrix spaltenweise und die zweite zeilenweise zerlegt, sodass sich die Teilergebnisse am Ende aufsummieren lassen.



Tensor Parallelism über vier GPUs: Jede rechnet an jeder Schicht mit.

9.2.2 Was gewonnen wird

Größe	Eine GPU	TP = 4
Gewichte je GPU	volle Modellgröße	ein Viertel
KV-Cache je GPU	voller Bedarf	ein Viertel — die Köpfe sind verteilt
Nutzbarer Speicher insgesamt	24 GiB	96 GiB
Rechenleistung	einfach	annähernd vierfach
Speicherbandbreite	einfach	annähernd vierfach

Die letzte Zeile erklärt, warum Tensor Parallelism auch die Latenz verbessert und nicht nur den Speicher: Nach der Bandbreitenformel aus Kapitel 2 liest jede GPU nur ihren Anteil der Gewichte — die Decode-Geschwindigkeit steigt entsprechend.

9.2.3 Die Einschränkungen

Einschränkung	Bedeutung
Teilbarkeit	Die Zahl der Aufmerksamkeitsköpfe muss durch die TP-Größe teilbar sein. Bei 64 Köpfen sind 2, 4 und 8 möglich, 3 oder 5 nicht
Key-Value-Köpfe	Bei Grouped-Query Attention begrenzt deren Zahl die sinnvolle Aufteilung — bei 8 KV-Köpfen ist TP über 8 hinaus nicht mehr wirksam
Gleiche Hardware	Alle beteiligten GPUs müssen identisch sein. Die langsamste bestimmt das Tempo

Einschränkung	Bedeutung
Ein Server	TP setzt schnelle Direktverbindungen voraus und ist über Knotengrenzen hinweg unwirtschaftlich
Alles oder nichts	Fällt eine GPU aus, ist die gesamte Modellkopie weg

MERKE

Die letzte Zeile ist betrieblich die folgenreichste: Tensor Parallelism vergrößert die Fehlerdomäne. Vier GPUs mit vier unabhängigen Modellkopien überstehen den Ausfall einer Karte mit 25 Prozent Kapazitätsverlust. Vier GPUs mit einer TP-4-Kopie verlieren bei demselben Ausfall **alles**.

Das ist ein Argument, das in Verfügbarkeitsbetrachtungen regelmäßig fehlt — und ein weiterer Grund, verteiltes Serving nur einzusetzen, wenn das Modell es erzwingt.

9.3 Was die Kommunikation kostet

9.3.1 Die Rechnung

Bei jeder Sammeloperation tauschen die GPUs Aktivierungen aus. Die Datenmenge je Operation und Token entspricht der Modelldimension:

Bytes je Token und Sammeloperation $\approx$ Modelldimension $\cdot$ Bytes je Wert

Für ein Modell mit einer Dimension von 8 192 in BF16 sind das rund 16 KiB je Token.

Bei 80 Schichten mit je zwei Sammeloperationen und einer Batchgröße von 32:

$$80 \cdot 2 \cdot 32 \cdot 16 \text{ KiB} \approx 82 \text{ MiB je Rechenschritt}$$

Bei zwanzig Rechenschritten je Sekunde ergibt das rund 1,6 GiB/s — eine Menge, die selbst PCIe bewältigt.

9.3.2 Warum die Bandbreite trotzdem nicht das Problem ist

Die eigentliche Kostenquelle ist nicht das Volumen, sondern die **Anzahl** der Synchronisationspunkte. 160 Sammeloperationen je Rechenschritt bedeuten 160-mal, dass alle GPUs aufeinander warten müssen.

Verbindung	Latenz	160 Punkte	Anteil an einem 20-ms-Schritt
NVLink	ca. 2 μ s	ca. 0,3 ms	rund 2 %
PCIe 4.0 im selben Sockel	ca. 8 μ s	ca. 1,3 ms	rund 6 %
PCIe über zwei Sockel	ca. 20 μ s	ca. 3,2 ms	rund 16 %
Ethernet 25 GbE	ca. 50 μ s	ca. 8 ms	rund 40 %

Die Werte sind Größenordnungen zur Veranschaulichung. Das Muster ist jedoch belastbar und erklärt drei Faustregeln:

MERKE

Erstens: Tensor Parallelism gehört in **einen** Server. Über Netzwerk verliert man den größten Teil des Gewinns.

Zweitens: NVLink ist für TP kein Komfort, sondern der Unterschied zwischen zwei und sechs Prozent Zusatzaufwand. Das ist der technische Grund, warum Rechenzentrumsplattformen mit NVLink gebaut werden.

Drittens: `nvidia-smi topo -m` aus Kapitel 4 ist vor jedem TP-Einsatz zu prüfen. Zwei GPUs mit der Kennzeichnung `SYS` – Kommunikation über die Verbindung zwischen den CPU-Sockeln – sind für Tensor Parallelism die schlechteste denkbare Anordnung.

9.3.3 Skalierungseffizienz

Der Zusatzaufwand wächst mit der Zahl der GPUs. Grobe Erwartungswerte bei guter Anbindung:

TP	mit NVLink	über PCIe	Anmerkung
2	ca. 1,8×	ca. 1,6×	Fast immer lohnend, wenn das Modell es braucht
4	ca. 3,3×	ca. 2,5×	Guter Arbeitspunkt
8	ca. 5,5×	ca. 3,5×	Deutlich abnehmender Ertrag
16	–	–	Über Knotengrenzen: dann Pipeline Parallelism

9.4 Pipeline Parallelism

9.4.1 Die Idee

Pipeline Parallelism teilt nicht die Matrizen, sondern die **Schichten**. GPU 0 rechnet die Schichten 0 bis 19, GPU 1 die Schichten 20 bis 39 und so weiter. Zwischen den Stufen wird nur das Zwischenergebnis weitergereicht – eine Punkt-zu-Punkt-Übertragung von wenigen Kilobyte statt einer Sammeloperation über alle Beteiligten.

Diese Zahlen gelten für den Durchsatz. Bei der **Latenz** einer einzelnen Anfrage ist der Gewinn oft größer, weil dort die Bandbreite je GPU voll durchschlägt und die Batchgröße klein ist.


TENSOR PARALLELISM	PIPELINE PARALLELISM
Jede GPU: alle Schichten, ein Teil jeder Matrix	Jede GPU: einige Schichten, alle Matrizen
GPU 0 ┌ Schicht 0 (1/4) ┐ GPU 1 ┌ Schicht 0 (1/4) ┐ GPU 2 ┌ Schicht 0 (1/4) ┐ GPU 3 ┌ Schicht 0 (1/4) ┐ ALL-REDUCE ... je Schicht	GPU 0 ┌ Schichten 0-19 ┐ GPU 1 ┌ Schichten 20-39 ┐ GPU 2 ┌ Schichten 40-59 ┐ GPU 3 ┌ Schichten 60-79 ┐ send/recv ... je Stufengrenze
160 Sammeloperationen je Rechenschritt	3 Punkt-zu-Punkt-Übertragungen je Rechenschritt

Pipeline Parallelism: Schichten statt Matrizen aufgeteilt.

Der Kommunikationsaufwand ist damit um Größenordnungen geringer – weshalb Pipeline Parallelism das Verfahren der Wahl über Knotengrenzen hinweg ist.

9.4.2 Der Preis: die Blase

Dafür entsteht ein anderes Problem. Solange GPU 0 an einem Token rechnet, haben GPU 1 bis 3 nichts zu tun. Erst wenn das Zwischenergebnis weitergereicht ist, arbeitet die nächste Stufe – und GPU 0 wartet.



Die Pipeline-Blase: ohne genügend gleichzeitige Anfragen steht der Großteil still.

MERKE

Pipeline Parallelism braucht **viele gleichzeitige Anfragen**, um die Blase zu füllen. Bei niedriger Last ist die Auslastung so schlecht wie der Kehrwert der Stufenzahl – bei vier Stufen also 25 Prozent.

Daraus folgt eine klare Zuordnung: Tensor Parallelism verbessert die **Latenz** auch bei einzelnen Anfragen. Pipeline Parallelism verbessert nur den **Durchsatz**, und das auch nur unter Last. Wer eine Latenzzusage einhalten muss, wählt TP; wer Kapazität für viele Nutzer braucht und über Knoten verteilen muss, PP.

9.4.3 Die Kombination

Bei sehr großen Modellen werden beide Verfahren kombiniert: Tensor Parallelism **innerhalb** eines Servers, Pipeline Parallelism **zwischen** Servern.

Aufbau	Einstellung	Bedeutung
1 Server, 4 GPUs	TP=4, PP=1	Alle vier über NVLink
2 Server à 4 GPUs	TP=4, PP=2	TP im Server, PP über Ethernet
4 Server à 8 GPUs	TP=8, PP=4	32 GPUs für sehr große Modelle

Die Regel ist einfach: **TP bis zur Knotengrenze, PP darüber hinaus**. Die Zahl der GPUs je Modellkopie ist das Produkt aus beiden.

9.5 Data Parallelism

Der Vollständigkeit halber: Data Parallelism bedeutet, dass mehrere unabhängige Kopien desselben Modells laufen und Anfragen darauf verteilt werden. Das ist kein verteiltes Serving im engeren Sinne – es ist das, was Kubernetes mit Repliken ohnehin tut, und was Kapitel 8 behandelt hat.

Es verdient hier trotzdem eine Erwähnung, weil es in Interviews als **Kontrastfolie** gebraucht wird:

	Data	Tensor	Pipeline
Löst	Durchsatz	Modellgröße, Latenz	Modellgröße über Knoten
Kommunikation	keine	sehr hoch	gering
Fehlerdomäne	eine Replik	alle GPUs	alle Knoten

	Data	Tensor	Pipeline
Speicher je GPU	volles Modell	Anteil	Anteil
Komplexität	gering	mittel	hoch

MERKE

Wenn ein Modell auf eine GPU passt, ist Data Parallelism in praktisch jeder Hinsicht überlegen: keine Kommunikation, kleine Fehlerdomäne, einfacher Betrieb, lineare Skalierung. Die anderen Verfahren existieren nur, weil manche Modelle nicht passen.

9.6 Konfiguration

9.6.1 In vLLM

```
vllm serve meta-llama/Llama-3.1-70B-Instruct \
  --tensor-parallel-size 4 \
  --max-model-len 8192 \
  --gpu-memory-utilization 0.90
```

Für mehrere Knoten kommt ein verteilter Ausführungsrahmen hinzu:

```
vllm serve <modell> \
  --tensor-parallel-size 8 \
  --pipeline-parallel-size 2 \
  --distributed-executor-backend ray
```

Argument	Hinweis
--tensor-parallel-size	Muss die Zahl der Aufmerksamkeitsköpfe teilen
--pipeline-parallel-size	Zahl der Stufen; Produkt mit TP ergibt die GPU-Zahl
--distributed-executor-backend	mp innerhalb eines Knotens, ray darüber hinaus
VLLM_HOST_IP	Bei mehreren Netzwerkkarten die richtige Adresse festlegen
NCCL_SOCKET_IFNAME	Welche Schnittstelle die Sammeloperationen nutzen
NCCL_DEBUG	INFO bei Verbindungsproblemen — sehr ausführlich

9.6.2 In Kubernetes

Ein Modell über mehrere Knoten zu verteilen bricht mit einer Grundannahme von Deployments: Die Pods sind nicht mehr austauschbar, sondern bilden gemeinsam **eine** Instanz. Ein einzelner Pod ist ohne die anderen nutzlos.

Muster	Aufbau	Einordnung
Ein Pod, mehrere GPUs	nvidia.com/gpu: 4 in einem Container	Der einfache Fall. Innerhalb eines Knotens immer so
StatefulSet mit Headless Service	Stabile Namen, Pods finden einander	Funktioniert, aber die Semantik passt nicht
LeaderWorkerSet	Eigene Ressourcenart für Gruppen aus Anführer und Arbeitern	Der passende Ansatz für Multi-Node-Inferenz

MERKE

Solange alle GPUs in einem Knoten stecken, ist verteiltes Serving in Kubernetes unspektakulär: ein Pod, der mehrere GPUs anfordert. Erst über Knotengrenzen hinweg wird es zu einem eigenen Problem – mit Anforderungen an gemeinsamen Start, gemeinsames Beenden und gegenseitige Auffindbarkeit, die ein gewöhnliches Deployment nicht erfüllt.

Für den einfachen Fall genügt eine Änderung am Manifest aus Kapitel 8:

```
resources:
  limits:
    nvidia.com/gpu: 4
    cpu: "16"
    memory: 96Gi
  args:
    - --tensor-parallel-size=4
```

Die CPU- und Speicherangaben steigen mit: Jede GPU bekommt einen eigenen Arbeitsprozess, und die Gewichte werden beim Laden im Hauptspeicher zwischengelagert.

9.7 Die VRAM-Bilanz bei Tensor Parallelism

Die Rechnung aus Kapitel 3 gilt unverändert – sie wird nur je GPU geführt. Sowohl die Gewichte als auch der KV-Cache teilen sich auf, weil mit den Aufmerksamkeitsköpfen auch deren Key-Value-Anteile verteilt werden.

$$\text{Gewichte je GPU} = \frac{\text{Modellgröße}}{\text{TP}} \quad \text{KV je GPU und Token} = \frac{\text{Bytes je Token}}{\text{TP}}$$

9.7.1 Durchgerechnet: ein 70B-Modell

Für ein Modell mit 70,6 Milliarden Parametern in BF16 – 131,5 GiB – auf Karten mit 80 GiB, bei 0,90 Speichernutzung und 1,5 GiB Grundlast, also 70,5 GiB nutzbar je Karte:

TP	Gewichte/GPU	KV/GPU	KV gesamt	Token-Budget
1	131,5 GiB	–	–	passt nicht
2	65,8 GiB	4,7 GiB	9,4 GiB	ca. 30 000
4	32,9 GiB	37,6 GiB	150 GiB	ca. 492 000
8	16,4 GiB	54,1 GiB	433 GiB	ca. 1 420 000

Die Zeile für TP = 2 ist die lehrreiche. Das Modell **passt** – aber es bleiben 30 000 Token KV-Cache. Bei 8 192 Token Kontext sind das knapp vier gleichzeitige Sequenzen. Zwei teure Karten, und der Dienst bedient vier Nutzer.

MERKE

Es ist dieselbe Lektion wie beim 32B-Modell auf 24 GiB in Kapitel 3, nur eine Größenordnung höher: „Passt“ und „ist betreibbar“ sind verschiedene Aussagen. Die

Faustregel gilt unverändert — die Gewichte sollten höchstens zwei Drittel des nutzbaren Speichers belegen.

Für ein 70B-Modell in BF16 bedeutet das $TP = 4$ als Untergrenze. Mit 4-Bit-Quantisierung — rund 40 GiB — genügt dagegen bereits eine einzelne Karte mit 80 GiB, und zwar mit rund 30 GiB KV-Cache. Auch hier wirkt Quantisierung doppelt: Sie spart nicht nur Speicher, sie erspart unter Umständen das gesamte verteilte Serving.

9.7.2 Quantisierung und Verteilung zusammen

Beide Verfahren lassen sich kombinieren und wirken multiplikativ auf den Speicherbedarf. Die Reihenfolge der Prüfung bleibt die aus der Entscheidungsleiter: zuerst quantisieren, dann verteilen. Wer umgekehrt vorgeht, beschafft Hardware für ein Problem, das eine Formatentscheidung gelöst hätte.

9.8 Netzwerkanforderungen bei mehreren Knoten

Die beiden Verfahren stellen völlig verschiedene Anforderungen — und das entscheidet, welches über Knotengrenzen hinweg überhaupt in Frage kommt.

	Tensor Parallelism	Pipeline Parallelism
Übertragung je Schritt	ca. 82 MiB bei einem 70B-Modell und Batch 32	ca. 0,5 MiB je Stufengrenze
Bandbreitenbedarf	ca. 1,6 GiB/s — entspricht rund 13 Gbit/s	wenige zehn MiB/s
Synchronisationspunkte	160 je Rechenschritt	wenige je Rechenschritt
Latenzempfindlichkeit	sehr hoch	gering
Mindestanforderung	NVLink; über Netzwerk 100 GbE mit RDMA — und dann noch verlustbehaftet	10 GbE genügt

MERKE

Die Bandbreite ist bei Tensor Parallelism nicht das Problem — 13 Gbit/s liefert jedes moderne Netz. Das Problem ist die Latenz, multipliziert mit 160 Synchronisationspunkten je Rechenschritt. Selbst bei 50 Mikrosekunden Umlaufzeit ergeben sich acht Millisekunden reine Wartezeit — bei einem Rechenschritt von 20 Millisekunden.

Deshalb gilt kompromisslos: **Tensor Parallelism bleibt im Knoten.** Über Knotengrenzen wird Pipeline Parallelism eingesetzt, dessen Kommunikationsmuster dafür geeignet ist.

9.8.1 Was das für die Beschaffung bedeutet

Ein Server mit acht über NVLink verbundenen GPUs ist für große Modelle etwas anderes als acht Server mit je einer GPU — auch wenn die Summe der Rechenleistung dieselbe ist. Die zweite Anordnung kann Modelle, die 300 GiB Gewichte tragen, praktisch nicht bedienen.

Diese Unterscheidung gehört in jede Beschaffungsdiskussion. „Acht GPUs“ ist keine ausreichende Spezifikation — die Frage ist, ob sie zusammenarbeiten können.

9.9 Expert Parallelism

Kapitel 3 hat Mixture-of-Experts-Modelle behandelt: Alle Experten müssen im Speicher liegen, aber je Token rechnen nur wenige. Bei sehr großen MoE-Modellen kommt ein eigenes Verteilungsverfahren hinzu.

Bei Expert Parallelism werden die **Experten** auf die GPUs verteilt. Jedes Token wird an diejenigen GPUs geschickt, die seine ausgewählten Experten halten – und das Ergebnis zurück. Das erzeugt ein anderes Kommunikationsmuster als Tensor Parallelism: keine Sammeloperation über alle, sondern einen gezielten Austausch zwischen wechselnden Teilmengen.

Eigenschaft	Bewertung
Speicher	Verteilt die Experten und damit den größten Teil der Gewichte
Kommunikation	Austausch aller mit allen – Volumen hängt von der Routenverteilung ab
Lastverteilung	Ungleichmäßig – werden bestimmte Experten häufiger gewählt, sind deren GPUs überlastet
Einsatzbereich	Sehr große MoE-Modelle in großen Installationen

MERKE

Für Plattformen der hier behandelten Größenordnung ist Expert Parallelism nicht relevant. Man sollte es benennen können – die ungleichmäßige Lastverteilung ist sein charakteristisches Problem – aber es ist Technik für Betreiber mit Dutzenden von Knoten.

9.10 Wie viele GPUs für wie viele Nutzer

Die Kapazitätsrechnung aus Kapitel 2 lässt sich auf große Modelle übertragen. Ein durchgerechnetes Beispiel für ein 70B-Modell.

Ausgangslage: 500 Nutzer, davon 40 Prozent täglich aktiv, 30 Anfragen je Person und Tag, Spitzenfaktor 3, 400 Ausgabetoken je Anfrage.

Nr.	Schritt	Ergebnis
1	Anfragerate in der Spitze	ca. 0,63 je Sekunde
2	Benötigte Ausgabetoken	ca. 250 je Sekunde
3	Durchsatz einer TP-4-Kopie in 4 Bit	ca. 600 bis 900 Token/s
4	Rechnerisch nötige Kopien	eine
5	Gegenprobe KV-Cache nach Little	5 Anfragen zu 8 192 Token, 320 KiB je Token: 12,5 GiB – unkritisch
6	Rollout- und Ausfallreserve	zweite Kopie
7	Ergebnis	2 Kopien à 4 GPUs = 8 GPUs

MERKE


Auch hier bestimmt nicht der Durchsatz die Beschaffung, sondern die Verfügbarkeit: Eine Kopie würde die Last tragen, aber jedes Treiber-Update und jeder Modellwechsel wäre ein vollständiger Ausfall. Die zweite Kopie verdoppelt die Hardware und ist trotzdem die richtige Entscheidung.

Der Vergleich mit einem 8B-Modell ist ernüchternd: Dieselbe Nutzerzahl wäre dort mit zwei Karten bedient. Der Aufpreis für das größere Modell beträgt den Faktor vier – und ob er sich lohnt, beantwortet der Prüfsatz aus Kapitel 3, nicht das Bauchgefühl.

9.11 Multi-Node mit Ray

Über Knotengrenzen hinweg braucht vLLM einen Rahmen, der die Prozesse auf mehreren Maschinen startet und miteinander verbindet. Dafür wird Ray eingesetzt.

9.11.1 Aufbau



Ray-Cluster für ein über zwei Knoten verteiltes Modell

Der zweite Punkt ist betrieblich wichtig: Der Dienst hat **einen** Endpunkt, auch wenn er über mehrere Knoten läuft. Ein Service, der auf beide Pods zeigt, wäre falsch – die Hälfte der Anfragen liefe ins Leere.

9.11.2 Betriebliche Eigenheiten

Eigenschaft	Konsequenz
Alle Knoten brauchen dasselbe Modell	Ein gemeinsames Volume oder identische lokale Kopien
Alle Knoten brauchen dieselbe Version	Von vLLM, CUDA und Treiber. Abweichungen äußern sich als Hängenbleiben
Der Start ist gekoppelt	Fehlt ein Arbeiter, startet der gesamte Dienst nicht
Der Ausfall eines Knotens beendet alles	Es gibt keine Teilverfügbarkeit
Ports müssen erreichbar sein	Ray und NCCL nutzen dynamische Ports – NetworkPolicies entsprechend fassen

ACHTUNG Die häufigste Störung bei Multi-Node-Inferenz

Der Dienst bleibt beim Start ohne Fehlermeldung stehen. Ursache ist fast immer, dass NCCL die falsche Netzwerkschnittstelle wählt – etwa ein Verwaltungsnetz statt des schnellen Datenpfads – oder dass die Knoten einander unter der gemeldeten Adresse nicht erreichen.

```
export NCCL_SOCKET_IFNAME=eth1
export NCCL_DEBUG=INFO
export VLLM_HOST_IP=10.0.1.11
```

Ohne NCCL_DEBUG=INFO gibt es dazu keine Diagnose – der Prozess wartet einfach. Diese Variable gehört bei jeder Erstinbetriebnahme gesetzt und danach wieder entfernt.

9.11.3 Startzeit

Bei verteiltem Serving addieren sich mehrere Verzögerungen:

Schritt	Anmerkung
Ray-Cluster bilden	Alle Arbeiter müssen sich melden
Modell laden	Läuft parallel – jede GPU lädt ihren Anteil
Sammeloperationen einrichten	NCCL baut die Verbindungen auf
Speicherprofilierung	Auf allen GPUs, muss übereinstimmen
Kompilierung	Auf allen GPUs

MERKE

Das parallele Laden ist die gute Nachricht: Ein 70B-Modell über acht GPUs lädt nicht achtmal so lange, sondern jede Karte holt ihren Achtel-Anteil. Die schlechte Nachricht sind die Synchronisationsschritte davor und danach.

Für Kubernetes bedeutet das eine noch großzügigere `startupProbe` als in Kapitel 8 – zehn Minuten sind bei großen Modellen keine Übertreibung. Für Scale-to-Zero bedeutet es, dass es praktisch ausscheidet: Ein Kaltstart von mehreren Minuten ist keine Grundlage für bedarfsgesteuerte Skalierung. Kapitel 10 greift das auf.

9.12 Beobachtbarkeit bei verteiltem Serving

Ein verteiltes Modell erzeugt Metriken an mehreren Stellen, und nicht alle sind gleich aussagekräftig.

Quelle	Aussage	Auswertung
vLLM-Metriken	Anfragen, Warteschlange, KV-Cache – nur auf dem Anführer	Die maßgebliche Quelle
DCGM je GPU	Auslastung, Speicher, Temperatur je Karte	Alle Karten zusammen betrachten
NCCL	Kommunikationszeiten – nur bei erhöhter Protokollierung	Zur Fehlersuche

MERKE

Die Anfrage-Metriken liegen nur beim Prozess mit dem HTTP-Endpunkt vor – die Arbeiterknoten liefern keine. Ein ServiceMonitor, der alle Pods abfragt, findet auf den Arbeitern nichts und meldet Ausfälle. Die Abfrage gehört gezielt auf den Anführer gerichtet.

Umgekehrt gilt für die GPU-Metriken: Sie müssen über **alle** beteiligten Karten betrachtet werden. Eine ungleiche Auslastung zwischen den Karten einer TP-Gruppe ist ein Warnzeichen – bei Tensor Parallelism sollten alle nahezu gleich ausgelastet sein. Weicht eine ab, liegt meist ein Topologie- oder Taktproblem vor.


Bei Pipeline Parallelism ist ungleiche Auslastung dagegen **normal** und sogar diagnostisch nützlich: Die Blase aus Abschnitt 9.5 wird als Auslastungsgefälle zwischen den Stufen sichtbar. Sinkt die Auslastung von Stufe zu Stufe deutlich, fehlt es an gleichzeitigen Anfragen.

9.13 Prefill/Decode-Disaggregation

9.13.1 Die Idee

Kapitel 2 hat gezeigt, dass Prefill und Decode grundverschiedene Workloads sind: rechenbegrenzt gegen bandbreitenbegrenzt. Kapitel 7 hat gezeigt, dass sie sich auf derselben GPU gegenseitig stören.

Die konsequente Antwort ist, sie auf **verschiedene** GPUs zu legen: Eine Gruppe von Instanzen führt nur Prefills aus, eine andere nur Decodes. Der KV-Cache wird zwischen ihnen übertragen.



Getrennte Pools für Prefill und Decode.

9.13.2 Wann es sich lohnt

Bedingung	Begründung
Sehr viele Anfragen	Der Zusatzaufwand der Übertragung muss sich amortisieren
Stark unterschiedliche Prompt- und Ausgabelängen	Genau dann stören sich die Phasen am meisten
Schnelle Verbindung zwischen den Pools	Der KV-Cache eines langen Prompts ist Gigabyte groß
Betriebsteam mit Kapazität	Zwei Pools, ein Übertragungspfad, mehr Fehlerquellen

MERKE

Disaggregation ist Technik für große Installationen. Für eine Plattform mit einer Handvoll GPUs ist Chunked Prefill aus Kapitel 7 die richtige Antwort auf dasselbe Problem – mit einem Bruchteil der Komplexität.

Man sollte das Verfahren trotzdem erklären können: Es ist derzeit eines der meistdiskutierten Themen im Bereich Inferenz-Infrastruktur und taucht in Interviews auf Senior-Ebene regelmäßig auf.

9.14 Wann verteiltes Serving schadet

Ein Abschnitt, den Übersichtsdarstellungen auslassen. Verteiltes Serving hat vier Kosten, die vor der Entscheidung auf dem Tisch liegen sollten.

Kosten	Bedeutung
Vergrößerte Fehlerdomäne	Eine ausgefallene GPU nimmt die gesamte Modellkopie mit. Bei vier unabhängigen Repliken wäre es ein Viertel der Kapazität
Startzeit	Alle beteiligten Prozesse müssen laden und sich synchronisieren. Aus Minuten werden leicht mehrere Minuten – mit Folgen für Rollouts und Scale-to-Zero
Schwierigere Fehlersuche	Ein Fehler in den Sammeloperationen äußert sich als Hängenbleiben ohne Meldung. Die Diagnose erfordert NCCL-Protokollierung und Kenntnis der Topologie
Starre Hardwarebindung	Alle GPUs müssen identisch und topologisch günstig angeordnet sein. Nachbeschaffung und heterogene Cluster werden schwierig

ACHTUNG Die Frage, die man zuerst stellen sollte

Bevor ein Modell verteilt wird: **Braucht die Anwendung wirklich dieses Modell?**

Der Sprung von einem 8B- auf ein 70B-Modell vervielfacht die Hardwarekosten, die Betriebskomplexität und die Ausfallwahrscheinlichkeit. Ob er die Antwortqualität für den konkreten Anwendungsfall entsprechend verbessert, lässt sich mit dem Prüfsatz aus Kapitel 3 **messen** – und die Antwort lautet häufiger „nein“, als man erwartet.

Diese Frage zu stellen ist Teil der Rolle. Sie zu übergehen und stattdessen acht GPUs zu beschaffen ist der teuerste Weg, ein Qualitätsproblem nicht zu lösen.

9.15 Optionales Lab auf gemieteter Hardware

Wer die Skalierung tatsächlich messen möchte, kommt mit geringem Aufwand aus.

LAB Skalierungseffizienz auf zwei GPUs messen

Ziel: Den Gewinn von Tensor Parallelism am eigenen Messwert belegen statt an einer Tabelle.

Voraussetzung: Eine Instanz mit zwei identischen GPUs bei einem Anbieter mit Stundenabrechnung. Die Größenordnung liegt bei ein bis drei Euro für eine Stunde – ausreichend für diese Messreihe.

Schritt 1 – Topologie prüfen. Vor allem anderen:

```
nvidia-smi topo -m
```

Erwartete Ausgabe: Zwischen den beiden GPUs sollte NV# oder mindestens PIX stehen. Bei SYS ist die Instanz für diese Messung ungeeignet – Kapitel 4.

Schritt 2 – Referenz auf einer GPU. Ein Modell wählen, das auf eine Karte passt:

```
CUDA_VISIBLE_DEVICES=0 vllm serve <modell> \
  --tensor-parallel-size 1 --max-model-len 4096 &
vllm bench serve --backend openai-chat \
  --model <modell> --dataset-name random \
  --random-input-len 1024 --random-output-len 256 \
  --num-prompts 100
```

Notieren Sie Durchsatz, TTFT und TPOT.

Schritt 3 – Dasselbe mit TP = 2.

```
vllm serve <modell> --tensor-parallel-size 2 \
  --max-model-len 4096 &
```

Messung wiederholen.

Erwartete Ausgabe: Der Durchsatz steigt um den Faktor 1,6 bis 1,8 – nicht 2,0. Die Differenz ist der Kommunikationsaufwand. Die Verbesserung bei TPOT fällt oft deutlicher aus als beim Durchsatz, weil dort die verdoppelte Bandbreite je Modellkopie voll durchschlägt.

Schritt 4 – Den Aufwand sichtbar machen. Mit gesetzter NCCL-Protokollierung noch einmal starten:

```
NCCL_DEBUG=INFO vllm serve <modell> \
  --tensor-parallel-size 2 2>&1 | grep -i -E \
  'NVLS|Ring|channel|via'
```

Erwartete Ausgabe: NCCL nennt den gewählten Übertragungspfad. Steht dort SHM oder P2P statt NVLink, läuft die Kommunikation über einen langsameren Weg – und das erklärt eine schlechte Skalierung.

Schritt 5 – Instanz beenden. Nicht vergessen.

Ergebnis: Ein eigener Messwert für die Skalierungseffizienz – und die Erfahrung, dass sie deutlich unter dem Faktor der GPU-Zahl liegt.

9.16 Die Entscheidung in einer Tabelle

Zum Nachschlagen die Zusammenfassung aller Verfahren gegeneinander.

	Repliken	Tensor P.	Pipeline P.	Disaggregation
Löst	Durchsatz	Modell zu groß, Latenz	Modell zu groß über Knoten	Phasenkonflikt
Kommunikation	keine	sehr hoch	gering	KV-Übertragung
Ort	beliebig	ein Knoten	über Knoten	getrennte Pools
Fehlerdomäne	eine Replik	alle GPUs	alle Knoten	ein Pool

	Repliken	Tensor P.	Pipeline P.	Disaggregation
Startzeit	normal	erhöht	deutlich erhöht	erhöht
Scale-to-Zero	möglich	schwierig	praktisch nein	nein
Betriebsaufwand	gering	mittel	hoch	hoch
Ab welcher Größe	immer	Modell passt nicht	Modell passt nicht in einen Knoten	große Installationen

MERKE

Die Zeile „Fehlerdomäne“ ist die, die in Architekturdiskussionen am häufigsten fehlt – und die bei einer Verfügbarkeitsbetrachtung den Ausschlag gibt. Vier GPUs als vier Repliken verkraften einen Kartenausfall mit einem Viertel Kapazitätsverlust. Dieselben vier GPUs als eine TP-4-Kopie verlieren alles.

Wer verteiltes Serving einsetzt, braucht deshalb **zwei** Kopien – und damit die doppelte Hardware. Diese Verdopplung gehört in die Wirtschaftlichkeitsrechnung, bevor die Entscheidung fällt.

9.17 Der Weg von einer GPU zu mehreren

Falls die Entscheidung für verteiltes Serving fällt, ist die folgende Reihenfolge sinnvoll. Sie vermeidet, dass zwei Änderungen gleichzeitig untersucht werden müssen.

1. **Ausgangsmessung festhalten.** Durchsatz, TTFT und TPOT des bisherigen Betriebs mit der Methodik aus Kapitel 8. Ohne diesen Bezugswert lässt sich später nicht beurteilen, ob die Verteilung etwas gebracht hat.
2. **Topologie prüfen.** `nvidia-smi topo -m`. Bei SYS zwischen den vorgesehenen Karten zuerst die Hardware klären – alles andere ist verlorene Zeit.
3. **TP-Größe aus der Kopfzahl ableiten.** Sie muss `num_attention_heads` teilen und sollte `num_key_value_heads` nicht überschreiten.
4. **VRAM-Bilanz je GPU führen.** Nach Abschnitt 9.6, mit der Zwei-Drittel-Regel.
5. **Auf einem Knoten starten**, ohne Kubernetes, mit `NCCL_DEBUG=INFO`. Erst wenn das läuft, folgt das Manifest.
6. **Messen und mit Schritt 1 vergleichen.** Liegt die Skalierungseffizienz deutlich unter den Erwartungswerten aus Abschnitt 9.4, liegt es fast immer an der Topologie.
7. **Zweite Kopie einplanen.** Ohne sie ist jede Wartung ein Ausfall.
8. **Erst dann über Knotengrenzen gehen** – und dann mit Pipeline Parallelism, nicht mit Tensor Parallelism.

Schritt 5 wird gern übersprungen. Ein direkt in Kubernetes gestartetes verteiltes Modell, das hängt, ist erheblich mühsamer zu diagnostizieren als dasselbe Problem auf der Kommandozeile.

ACHTUNG Zwei Änderungen auf einmal

Ein häufiger Fehler ist, gleichzeitig auf ein größeres Modell **und** auf verteiltes Serving umzustellen. Wenn danach die Latenz schlechter ist, lässt sich nicht mehr trennen, woran es liegt – am größeren Modell, an der Kommunikation oder an einer ungünstigen Topologie.

Die saubere Reihenfolge ist: erst das größere Modell auf ausreichend großer Hardware fachlich prüfen, dann die Verteilung technisch einführen und messen.

9.18 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Start bleibt ohne Meldung hängen	Sammeloperationen finden einander nicht	NCCL_DEBUG=INFO setzen, Ausgabe prüfen	NCCL_SOCKET_IFNAME und VLLM_HOST_IP festlegen
Server startet nicht, Meldung zur Teilbarkeit	TP-Größe teilt die Kopfzahl nicht	num_attention_heads in der config.json	TP-Größe auf einen Teiler setzen
Skalierung deutlich schlechter als erwartet	Ungünstige Topologie — Kommunikation über CPU-Sockel	nvidia-smi topo -m ; NCCL-Protokoll auf den Pfad prüfen	GPUs umstecken oder Instanz wechseln
Eine GPU fällt aus, der ganze Dienst ist weg	Erwartetes Verhalten bei Tensor Parallelism	–	Zweite Modellkopie auf anderer Hardware vorsehen
Bei Pipeline Parallelism niedrige Auslastung	Zu wenige gleichzeitige Anfragen — die Blase	Auslastung der einzelnen GPUs vergleichen	Mehr Last bündeln oder auf Tensor Parallelism wechseln
Speicherfehler trotz ausreichender GPU-Zahl	Hauptspeicher des Knotens erschöpft beim Laden	Speicherverbrauch während des Starts beobachten	Hauptspeicheranforderung erhöhen — mehrere Prozesse laden parallel

9.19 Interviewfragen

INTERVIEWFRAGE

Was bedeutet Tensor Parallelism, und wann brauchen Sie es?

Gut ist: Die Gewichtsmatrizen werden auf mehrere GPUs aufgeteilt, die gemeinsam an denselben Token rechnen.

Senior ist die Einordnung in die Entscheidungskette: Tensor Parallelism ist die Antwort darauf, dass ein Modell nicht auf eine Karte passt — **nachdem** Quantisierung, Kontextbegrenzung und ein kleineres Modell geprüft wurden. Es verbessert neben dem Speicher auch die Latenz, weil jede GPU nur ihren Anteil der Gewichte liest. Der Preis sind zwei Sammeloperationen je Schicht und eine vergrößerte Fehlerdomäne — eine ausgefallene Karte nimmt die gesamte Modellkopie mit.

INTERVIEWFRAGE

Wann Tensor Parallelism, wann Pipeline Parallelism?

Senior ist die Zuordnung nach Kommunikationsmuster: TP erzeugt zwei Sammeloperationen je Schicht — bei 80 Schichten also 160 Synchronisationspunkte je Rechenschritt

– und gehört deshalb in einen Server mit NVLink. PP erzeugt nur eine Punkt-zu-Punkt-Übertragung je Stufengrenze und ist damit über Knoten hinweg brauchbar.

Der zweite Unterschied ist die Wirkung: TP verbessert die Latenz auch bei einzelnen Anfragen, PP nur den Durchsatz unter Last – weil ohne genügend gleichzeitige Anfragen die Pipeline-Blase entsteht und die Auslastung auf den Kehrwert der Stufenzahl fällt. Die Regel lautet: TP bis zur Knotengrenze, PP darüber.

INTERVIEWFRAGE

Sie skalieren von einer auf vier GPUs. Was erwarten Sie beim Durchsatz?

Schwach ist „viermal so viel“.

Senior ist die Rückfrage nach dem Ziel: Bei einem Modell, das auf eine Karte passt, wären vier unabhängige Repliken die richtige Antwort – und die skalieren tatsächlich nahezu linear. Bei Tensor Parallelism sind realistisch 3,0 bis 3,3 mit NVLink und deutlich weniger über PCIe. Die Differenz ist der Kommunikationsaufwand, und der wird von der **Anzahl** der Synchronisationspunkte bestimmt, nicht vom Datenvolumen.

INTERVIEWFRAGE

Was ist Prefill/Decode-Disaggregation?

Gut ist: Prefill und Decode laufen auf verschiedenen GPUs.

Senior ist die Begründung aus Kapitel 2 – rechenbegrenzt gegen bandbreitenbegrenzt – und aus Kapitel 7 – sie stören sich auf derselben Karte. Getrennte Pools lassen sich unabhängig skalieren und beenden das Head-of-Line-Blocking. Der Preis ist die Übertragung des KV-Cache, der bei langen Prompts Gigabyte groß ist. Wer ergänzt, dass Chunked Prefill für kleinere Installationen dasselbe Problem mit einem Bruchteil der Komplexität löst, zeigt Augenmaß.

9.20 Zusammenfassung

- Nur **ein** Grund erzwingt verteiltes Serving: Das Modell passt nicht auf eine GPU. Durchsatz und Ausfallsicherheit werden durch mehr Repliken gelöst.
- Die Entscheidungsleiter lautet: quantisieren, Kontext begrenzen, kleineres Modell – erst dann Tensor Parallelism, dann zusätzlich Pipeline Parallelism.
- Tensor Parallelism teilt die Matrizen und erzeugt zwei Sammeloperationen je Schicht. Es senkt Speicherbedarf und Latenz je GPU, gehört aber in einen Server.
- Nicht das Datenvolumen ist teuer, sondern die Anzahl der Synchronisationspunkte. Das ist der Grund, warum NVLink für TP entscheidend ist und Ethernet ungeeignet.
- Pipeline Parallelism teilt die Schichten, kommuniziert sparsam und funktioniert über Knotengrenzen – braucht aber viele gleichzeitige Anfragen, sonst entsteht die Blase.
- TP bis zur Knotengrenze, PP darüber hinaus. Die GPU-Zahl je Modellkopie ist das Produkt.
- Verteiltes Serving vergrößert die Fehlerdomäne: Eine ausgefallene GPU nimmt die gesamte Modellkopie mit.

- Prefill/Decode-Disaggregation trennt die beiden Phasen auf eigene Pools. Für kleinere Installationen ist Chunked Prefill die einfachere Antwort auf dasselbe Problem.
- Die Frage vor allen anderen bleibt: Braucht die Anwendung wirklich dieses Modell? Der Prüfsatz aus Kapitel 3 beantwortet sie messbar.

Quellen und Weiterlesen

- Shoeybi et al.: *Megatron-LM — Training Multi-Billion Parameter Language Models Using Model Parallelism*. Die Grundlage der Matrixaufteilung.
- vLLM: *Documentation — Distributed Inference and Serving*. Konfiguration von TP und PP, Ray-Anbindung, Multi-Node-Aufbau.
- NVIDIA: *NCCL Documentation* — Umgebungsvariablen, Pfadauswahl und Fehlersuche bei Sammeloperationen.
- Kubernetes SIG Apps: *LeaderWorkerSet* — Ressourcenart für Gruppen aus Anführer und Arbeitern, passend für Multi-Node-Inferenz.

KServe und das Serving-Ökosystem

ZIEL	Model Serving als Kubernetes-Primitive begreifen: Versionierung, Rollout, Skalierung und Modellbezug deklarativ statt handgeschrieben — und begründet entscheiden, welcher Inferenz-Server für welchen Fall der richtige ist.
SETZT VORAUS	Kapitel 8 — ein handgeschriebenes vLLM-Deployment — und Kapitel 7 — die Metriken, an denen Skalierung hängt.
DANACH KANNST DU	Einen <code>InferenceService</code> schreiben und betreiben, Modellbezug aus Objektspeicher und Volume einrichten, Autoscaling an den richtigen Signalen aufhängen, Canary-Rollouts fahren und die verfügbaren Inferenz-Server einordnen.

GESCHRIEBEN GEGEN

KServe 0.14.x · Kubernetes 1.31 · vLLM 0.8.x · Stand September 2026

Kapitel 8 hat ein vollständiges Deployment gezeigt — mit Sonden, Volumes, Ressourcenangaben und einer Rollout-Strategie, die zur Hardware passt. Es funktioniert. Die Frage dieses Kapitels ist, was passiert, wenn daraus zwanzig Deployments werden.

10.1 Warum eine Abstraktion darüber

10.1.1 Was ein Deployment nicht leistet

Anforderung	Mit Deployment und Service
Modell aus dem Objektspeicher beziehen	Eigener Init-Container je Dienst — Kapitel 8
Zwei Modellversionen parallel mit Verkehrsaufteilung	Zwei Deployments, ein eigener Verteiler, manuelle Gewichtung
Skalierung nach Warteschlangenlänge	Eigene HPA mit externem Metrikadapter
Auf null herunterskalieren	Nicht vorgesehen
Einheitliche Konfiguration über zwanzig Modelle	Zwanzig Manifeste, die auseinanderlaufen
Modellversion als Teil der Auslieferung	Konvention statt Mechanismus

Jede dieser Anforderungen lässt sich einzeln lösen. Zusammen ergeben sie eine Plattformaufgabe — und genau die übernimmt KServe.


MERKE

Der Nutzen entsteht nicht beim ersten Modell, sondern beim fünften. Für einen einzelnen Inferenz-Dienst ist ein handgeschriebenes Deployment einfacher und durchschaubarer. Sobald mehrere Teams eigene Modelle bereitstellen sollen, kehrt sich das um: Dann braucht es eine Ressourcenart, die ein Anwendungsteam ausfüllen kann, ohne den gesamten Betriebsstack zu verstehen.

Das ist derselbe Gedanke wie bei den Modellprofilen aus Kapitel 5 – eine Zusage anfordern, statt Infrastruktur zu beschreiben.

10.2 Die Architektur

10.2.1 Zwei Ressourcenarten



ServingRuntime beschreibt das Wie, InferenceService das Was.

Die Trennung ist der eigentliche Gewinn: Das Plattformteam legt einmal fest, wie ein vLLM-Container gestartet wird – mit welchen Sonden, welchen Ressourcen, welchen Sicherheitseinstellungen. Anwendungsteams beschreiben danach nur noch, **welches** Modell sie bereitstellen wollen.

10.2.2 Betriebsarten

KServe kann seine Ressourcen auf zwei Wegen umsetzen, und die Wahl hat Folgen:

Betriebsart	Aufbau	Einordnung
RawDeployment	Gewöhnliches Deployment mit HPA	Der Regelfall für LLM-Serving. Wenig zusätzliche Bausteine, vertrautes Verhalten
Serverless	Knative Serving mit eigener Skalierung und Verkehrssteuerung	Bietet Scale-to-Zero und feine Verkehrsaufteilung – setzt Knative im Cluster voraus

```

metadata:
  annotations:
    serving.kserve.io/deploymentMode: RawDeployment
  
```

MERKE

Für Sprachmodelle ist RawDeployment in den meisten Fällen die bessere Wahl. Der Hauptvorteil der Serverless-Betriebsart — Herunterskalieren auf null — ist bei Ladezeiten von Minuten nur eingeschränkt nutzbar, wie Abschnitt 10.6 zeigt. Der Preis ist dagegen real: Knative bringt einen eigenen Netzwerkpfad und eigene Fehlerquellen mit. Wer Scale-to-Zero tatsächlich braucht — etwa für selten genutzte Modelle in einer Entwicklungsumgebung — ist mit Serverless richtig. Für einen produktiven Chat-Dienst mit dauerhafter Last nicht.

10.3 Der InferenceService

10.3.1 Ein vollständiges Beispiel

```
apiVersion: serving.kserve.io/v1beta1
kind: InferenceService
metadata:
  name: chat-v1
  annotations:
    serving.kserve.io/deploymentMode: RawDeployment
spec:
  predictor:
    minReplicas: 1
    maxReplicas: 3
    runtimeClassName: nvidia
    nodeSelector:
      node-role/gpu: "true"
    tolerations:
      - key: nvidia.com/gpu
        operator: Equal
        value: present
        effect: NoSchedule
  model:
    modelFormat: {name: vllm}
    storageUri: s3://modelle/qwen2.5-7b-awq
    args:
      - --served-model-name=unternehmen-chat-v1
      - --max-model-len=8192
      - --max-num-seqs=24
      - --disable-log-requests
    resources:
      limits:
        nvidia.com/gpu: "1"
        cpu: "8"
        memory: 32Gi
      requests:
        cpu: "4"
        memory: 24Gi
```

Was hier **nicht** steht, ist der Gewinn: kein Container-Image, keine Sonden, kein Init-Container für den Modellbezug, kein Service, keine Rollout-Strategie. All das kommt aus der ServingRuntime.

10.3.2 Die ServingRuntime

```
apiVersion: serving.kserve.io/v1alpha1
kind: ClusterServingRuntime
metadata:
  name: vllm-runtime
spec:
  supportedModelFormats:
    - name: vllm
      autoSelect: true
  protocolVersions: [v2, v1]
  containers:
    - name: kserve-container
      image: vllm/vllm-openai:v0.8.5
      command:
        - python
        - -m
        - vllm.entrypoints.openai.api_server
      args:
        - --model=/mnt/models
        - --port=8080
      ports:
        - containerPort: 8080
          protocol: TCP
      startupProbe:
        httpGet: {path: /health, port: 8080}
        periodSeconds: 10
        failureThreshold: 60
      volumeMounts:
        - {name: shm, mountPath: /dev/shm}
  volumes:
    - name: shm
      emptyDir: {medium: Memory, sizeLimit: 8Gi}
```

Der Pfad /mnt/models ist die Verabredung: Dorthin legt der Storage-Initializer das Modell, unabhängig davon, woher es kam.

MERKE

Die ClusterServingRuntime ist der Ort, an dem die Erkenntnisse aus Kapitel 8 einmal festgeschrieben werden — Startsonde mit hoher Fehlerzahl, gemeinsamer Speicher, Ressourcenvorgaben. Danach profitiert jeder InferenceService davon, ohne dass irgendjemand sie noch einmal recherchieren muss.

Das ist der Kern von Plattformarbeit: eine schwierige Entscheidung einmal richtig treffen und sie dann verfügbar machen.

10.4 Modellbezug

10.4.1 Die Herkunftsangaben

Schema	Bedeutung	Einordnung
pvc://	Volume im Cluster	Schnellster Start. Kein Kopiervorgang, wenn das Volume gemeinsam nutzbar ist
s3://	Objektspeicher	Der Regelfall. Zugangsdaten über ein Secret
hf://	Hugging Face	Für Versuche brauchbar, in Produktion nicht — Kapitel 3
oci://	Modell als OCI-Artefakt	Nutzt die Registry und deren Zwischenspeicher auf dem Knoten
https://	Einzelne Datei	Nur für kleine Artefakte sinnvoll

10.4.2 Der Storage-Initializer und seine Kosten

Bei allen Schemata außer pvc:// läuft ein Init-Container, der das Modell in den Pod kopiert. Das bedeutet: **Jeder Pod-Start kopiert das vollständige Modell.**

Bezugsweg	15 GiB	Wirkung auf den Start
pvc:// mit ReadOnlyMany	0 s	Nur eingehängt, nicht kopiert
s3:// im Rechenzentrum	ca. 15 s	Vertretbar
oci:// mit Knoten-Cache	ca. 5 s	Nach dem ersten Pod je Knoten
hf:// über das Internet	ca. 2 min	Nicht produktionsstauglich

MERKE

Für Modelle, die auf mehreren Repliken laufen, ist pvc:// mit gemeinsam nutzbarem Volume der klar beste Weg: Es entfällt nicht nur der Kopiervorgang, sondern auch der Speicherplatz je Pod. Bei einem 15-GiB-Modell und drei Repliken spart das 30 GiB kurzlebigen Speicher auf dem Knoten.

Das OCI-Verfahren ist interessant, wo eine Registry ohnehin betrieben wird: Das Modell wird zum versionierten Artefakt neben den Container-Images, und der Knoten-Cache wirkt wie bei jedem anderen Image. Kapitel 16 greift das in der Delivery-Kette auf.

10.5 Autoscaling für Sprachmodelle

10.5.1 Warum die üblichen Signale versagen

Die Standardeinstellung einer HPA ist die CPU-Auslastung. Für einen Inferenz-Dienst ist sie das denkbar schlechteste Signal.

Signal	Warum es nicht funktioniert
CPU-Auslastung	Die Arbeit findet auf der GPU statt. Ein voll ausgelasteter Server kann bei 20 Prozent CPU liegen — und ein leerlaufender bei 40, weil Tokenisierung und HTTP dort laufen

Signal	Warum es nicht funktioniert
Speicherauslastung	Der Server belegt beim Start seinen gesamten Anteil und behält ihn. Der Wert ist konstant und trägt keine Information
GPU-Auslastung	Besser, aber trügerisch: Sie zeigt, dass Kernel laufen, nicht ob der Server überlastet ist – Kapitel 1 und 14
Anfragen je Sekunde	Brauchbar als Näherung, ignoriert aber die Verarbeitungsdauer: 10 kurze und 10 sehr lange Anfragen bedeuten völlig verschiedene Last

10.5.2 Die richtigen Signale

Kapitel 7 hat sie bereits geliefert. Sie stammen aus dem Scheduler, weil dort die tatsächliche Überlastung entsteht:

Metrik	Aussage	Als Skalierungssignal
num_requests_waiting	Anfragen, die nicht bearbeitet werden können	Das beste Signal. Größer null heißt: zu wenig Kapazität
gpu_cache_usage_perc	Belegung des KV-Cache	Guter Frühindikator – steigt vor der Warteschlange
num_preemptions_total	Verdrängungen	Alarm, nicht Skalierungssignal – hier ist es bereits zu spät
TTFT-Perzentil	Wahrgenommene Latenz	Direkt an der Zusage, aber träge
Gleichzeitigkeit	Anfragen im System	Einfach und robust; Knative nutzt sie

10.5.3 Umsetzung mit KEDA

```
apiVersion: keda.sh/v1alpha1
kind: ScaledObject
metadata:
  name: chat-v1-skalierung
spec:
  scaleTargetRef:
    name: chat-v1-predictor
  minReplicaCount: 1
  maxReplicaCount: 3
  cooldownPeriod: 600
  triggers:
    - type: prometheus
      metadata:
        serverAddress: http://prometheus.monitoring:9090
        threshold: "2"
        query: |
          sum(vllm:num_requests_waiting{service="chat-v1"})
```

ACHTUNG Die Abkühlzeit ist der wichtigste Parameter

`cooldownPeriod` von 600 Sekunden sieht großzügig aus und ist es nicht. Eine Replik herunterzufahren und später wieder hochzufahren kostet die volle Ladezeit. Bei schwankender Last mit kurzer Abkühlzeit entsteht ein Pendeln, bei dem der Dienst mehr Zeit mit Laden als mit Antworten verbringt.

Die Regel lautet: Die Abkühlzeit sollte ein Vielfaches der Ladezeit betragen. Bei drei Minuten Ladezeit sind zehn Minuten ein sinnvoller Ausgangswert.

10.5.4 Scale-to-Zero: die Rechnung

Eine ungenutzte GPU ist teuer — Kapitel 1 hat das als zentrale wirtschaftliche Größe benannt. Das Herunterskalieren auf null ist deshalb verlockend. Ob es sich lohnt, ist eine Rechnung:

Größe	Beispielwert
Kaltstart	3 Minuten — Modell laden, kompilieren, aufwärmen
Erste Anfrage nach Ruhephase	wartet diese 3 Minuten
Kosten einer laufenden Karte	rund 3 € je Stunde im Eigenbetrieb
Ersparnis bei 12 Stunden Ruhe	rund 36 € je Tag
Preis	Jede erste Anfrage nach Ruhe dauert 3 Minuten

MERKE

Scale-to-Zero ist geeignet für Entwicklungsumgebungen, Stapelverarbeitung und selten genutzte Fachmodelle — überall dort, wo drei Minuten Wartezeit hinnehmbar sind. Für interaktive Dienste ist es ungeeignet. Die Alternative heißt **Warmhaltung mit reduzierter Kapazität**: nachts eine Replik statt drei. Das spart zwei Drittel der Kosten, ohne dass ein Nutzer je drei Minuten wartet. Für die meisten Unternehmensplattformen ist das die richtige Antwort.

10.6 Canary-Rollouts

10.6.1 Verkehrsaufteilung deklarativ

Ein Modellwechsel lässt sich mit einer Zeile schrittweise fahren:

```
spec:
  predictor:
    canaryTrafficPercent: 10
    model:
      storageUri: s3://modelle/qwen2.5-7b-awq-v2
```

KServe hält dann beide Versionen vor und leitet zehn Prozent des Verkehrs auf die neue.

ACHTUNG Canary braucht doppelte GPU-Kapazität

Zwei Modellversionen gleichzeitig bedeuten zwei belegte GPUs — nicht zwei belegte Prozesse. Auf einem Cluster mit einer Karte ist Canary schlicht nicht möglich; der neue Pod bleibt in Pending, wie Kapitel 8 für Rolling Updates gezeigt hat.

Das ist die konkrete, in Hardware messbare Konsequenz der Aussage aus Kapitel 4: Der zweite GPU-Knoten wird nicht für den Durchsatz beschafft, sondern für die Wartbarkeit – und Canary-Rollouts sind ein Teil davon.

10.6.2 Der Ablauf

1. Neue Version mit `canaryTrafficPercent: 0` ausrollen – sie startet, lädt, wird bereit, bekommt aber keinen Verkehr
2. Prüfsatz aus Kapitel 3 direkt gegen die neue Version fahren
3. Auf 10 Prozent erhöhen, Fehlerrate und Latenzperzentile beobachten
4. Schrittweise auf 50, dann 100 Prozent
5. Alte Version einige Tage vorhalten – ein Rollback ist dann eine Zahlenänderung

MERKE


Der zweite Schritt ist der, der den Unterschied macht. Ein Canary-Rollout misst **technische** Kennzahlen: Fehler, Latenz, Durchsatz. Er misst nicht, ob die Antworten besser oder schlechter geworden sind – und genau das ist bei einem Modellwechsel die entscheidende Frage.

Deshalb gehört der fachliche Prüfsatz **vor** die Verkehrsaufteilung. Ein Modell, das technisch einwandfrei läuft und fachlich schlechter antwortet, fällt in keiner Metrik auf.

10.7 Cache-bewusste Weiterleitung

Kapitel 8 hat das Problem beschrieben: Bei mehreren Repliken hat jede ihren eigenen Prefix-Cache. Landet ein mehrstufiger Dialog reihum auf verschiedenen Repliken, wird der Verlauf jedes Mal neu berechnet.

Die Lösung ist eine Weiterleitung, die den Cache-Zustand berücksichtigt – statt gleichmäßig zu verteilen.



Cache-bewusste Weiterleitung: Anfragen folgen ihren Präfixen.

MERKE

Die Abwägung ist der eigentliche Punkt: Eine reine Cache-Zuordnung würde alle Anfragen mit demselben Systemprompt auf eine Replik lenken und die anderen leer laufen lassen. Eine brauchbare Weiterleitung wägt Cache-Treffer gegen Auslastung ab. Für Plattformen mit wenigen Repliken ist der Gewinn begrenzt. Er wird erheblich, sobald mehrstufige Dialoge über viele Repliken laufen — also genau dann, wenn die Plattform wächst.

10.8 Das Serving-Ökosystem

vLLM ist nicht die einzige Wahl. Die folgende Übersicht ordnet die Alternativen ein — nicht als Rangliste, sondern nach Einsatzbereich.

Server	Stärke	Einschränkung
vLLM	Breite Modellunterstützung, ausgereiftes Batching, OpenAI-Schnittstelle, große Verbreitung	Kein Spitzenreiter bei reiner Einzelanfrage-Latenz
SGLang	Sehr gute Leistung, besonders bei strukturierten Ausgaben und agentischen Abläufen mit vielen gemeinsamen Präfixen	Kleinere Verbreitung, Ökosystem im Aufbau
TensorRT-LLM	Höchste Leistung auf NVIDIA-Hardware	Modell muss je GPU-Typ und Konfiguration übersetzt werden — unflexibel bei Modellwechseln
TGI	Enge Anbindung an das Hugging-Face-Ökosystem, einfacher Einstieg	Weniger Stellschrauben als vLLM
Triton	Mehrere Frameworks und Modelle in einem Server; oft Unterbau für TensorRT-LLM	Erheblicher Konfigurationsaufwand
Ray Serve	Zusammensetzen mehrerer Modelle und Vor-/Nachverarbeitung in Python	Für reines LLM-Serving mehr Aufwand als Nutzen
Ollama	Sehr bequem für Einzelplatz und Entwicklung	Kein Mehrmandanten-Serving, kein Batching auf Produktionsniveau
llama.cpp	CPU-Betrieb, breite Quantisierungsvarianten, geringe Anforderungen	Auf GPU deutlich langsamer als spezialisierte Server

Option	Geeignet, wenn	Ungeeignet, wenn
vLLM	Der Regelfall für Unternehmensplattformen: breite Modellunterstützung, gute Leistung, große Verbreitung und damit verfügbares Wissen im Markt	Wenn die letzten zehn Prozent Leistung entscheidend sind und das Modell selten wechselt
SGLang	Bei sehr vielen gemeinsamen Präfixen — agentische Abläufe, strukturierte Ausgaben	Wenn Verbreitung und verfügbares Wissen im Team wichtiger sind als Spitzenleistung

Option	Geeignet, wenn	Ungeeignet, wenn
TensorRT-LLM	Wenn maximale Leistung auf festgelegter Hardware zählt und Modellwechsel selten sind	In einer Plattform mit häufigen Modellwechseln — der Übersetzungsschritt wird zur Belastung
llama.cpp oder Ollama	Entwicklungsumgebungen, Einzelplatz, CPU-Betrieb, Randgeräte	Für Mehrmandanten-Serving mit Zusagen

MERKE

Die Auswahl sollte nicht allein an Benchmark-Zahlen hängen. Für eine Unternehmensplattform zählen drei weitere Kriterien mindestens ebenso viel: **Modellunterstützung** — läuft das Modell, das der Fachbereich will —, **Betriebsreife** — gibt es Metriken, Sonden, Dokumentation — und **Marktverbreitung** — findet man Menschen, die es kennen.

Ein zehn Prozent schnellerer Server, den im Haus niemand betreiben kann, ist die teurere Wahl.

10.9 Weitere Bestandteile

10.9.1 Vor- und Nachverarbeitung

Neben dem eigentlichen Modell kennt KServe eine vorgelagerte Komponente für Umformungen — etwa um ein internes Anfrageformat in das des Modells zu übersetzen oder Antworten nachzubearbeiten.

ACHTUNG Für LLM-Plattformen selten die richtige Stelle

Bei klassischen Modellen ist eine Vorverarbeitung sinnvoll: Bilder skalieren, Merkmale normalisieren. Bei Sprachmodellen wird sie regelmäßig für Dinge verwendet, die woanders hingehören — Prompt-Vorlagen, Filterung, Protokollierung.

Diese Aufgaben gehören ins Gateway, weil sie **modellübergreifend** gelten und dort zentral verwaltet werden. Eine Vorverarbeitung je InferenceService führt dazu, dass dieselbe Regel an zwanzig Stellen gepflegt wird — und an neunzehn davon veraltet.

10.9.2 Viele kleine Modelle

Für Plattformen mit sehr vielen kleinen Modellen — klassische Klassifikatoren, nicht Sprachmodelle — gibt es eine Betriebsart, die Modelle nach Bedarf in gemeinsam genutzte Server lädt und wieder verdrängt. Bei Sprachmodellen ist sie nicht die richtige Antwort: Die Ladezeiten machen das Nachladen unpraktikabel.

MERKE

Für viele **Varianten** eines Sprachmodells ist Multi-LoRA aus Kapitel 8 die passende Lösung: ein Basismodell, viele Adapter, gemeinsames Batching. Für viele **verschiedene** Sprachmodelle gibt es keine gute Antwort außer mehr GPUs — die Gewichte müssen resident sein.

Diese Unterscheidung ist in Architekturgesprächen wertvoll: „Wir brauchen zwanzig Modelle“ bedeutet fast immer zwanzig Varianten, und die sind mit einer Karte machbar.

10.10 Beobachtbarkeit

Ein InferenceService erzeugt Metriken auf zwei Ebenen, die man auseinanderhalten muss:

Quelle	Inhalt	Verwendung
vLLM /metrics	Warteschlange, KV-Cache, TTFT, Verdrängungen — Kapitel 7	Die maßgebliche Quelle für Skalierung und Diagnose
KServe-Controller	Zustand der Ressourcen, Rollout-Fortschritt	Für Alarme auf nicht bereitete Dienste
DCGM je GPU	Auslastung, Speicher, Temperatur — Kapitel 4	Zuordnung zur Hardware


Damit Prometheus die Server-Metriken einsammelt, braucht es einen Monitor, der den richtigen Port trifft:

```
apiVersion: monitoring.coreos.com/v1
kind: ServiceMonitor
metadata:
  name: kserve-vllm
spec:
  selector:
    matchLabels:
      serving.kserve.io/inferenceservice: chat-v1
  endpoints:
    - port: http
      path: /metrics
      interval: 15s
```

10.11 Weiterleitung nach dem Kubernetes-Standard

Cache-bewusste Weiterleitung war lange eine Eigenentwicklung jeder Plattform. Inzwischen entsteht dafür eine Erweiterung der Kubernetes-Gateway-API, die speziell auf Inferenz-Workloads zugeschnitten ist.

Der Port heißt in der von KServe erzeugten Service-Definition nicht wie im Container. Prüfen Sie ihn mit `kubectl get svc -o yaml`, bevor Sie den Monitor schreiben — ein falscher Portname ist die häufigste Ursache für fehlende Metriken.



Weiterleitung mit Kenntnis des Server-Zustands statt blinder Verteilung

MERKE

Der Unterschied zu einem gewöhnlichen Lastverteiler ist, dass die Auswahl den **inneren Zustand** der Server einbezieht – Warteschlange, Cache-Belegung, geladene Adapter. Genau diese Informationen liefern die Metriken aus Kapitel 7.

Für Plattformen mit wenigen Repliken lohnt der Aufwand noch nicht. Man sollte die Entwicklung aber kennen: Sie ist die Antwort auf das Replik-Problem aus Kapitel 8 und wird die Schnittstelle zwischen Gateway und Serving in den nächsten Jahren prägen.

10.12 Vom Deployment zu KServe

Wer wie in Kapitel 8 begonnen hat, steht irgendwann vor der Umstellung. Die folgende Reihenfolge vermeidet, dass dabei Wissen verloren geht.

1. **Bestehendes Deployment dokumentieren.** Alle Argumente, Sonden, Ressourcen und Volumes – besonders die, deren Grund man vergessen hat.
2. **ClusterServingRuntime daraus ableiten.** Alles Wiederverwendbare wandert dorthin: Image, Sonden, gemeinsamer Speicher, Sicherheitseinstellungen.
3. **Modellspezifisches im InferenceService belassen.** Kontextlänge, Sequenzgrenze, Modellname.
4. **Parallel betreiben.** Der neue Dienst bekommt einen eigenen Namen und noch keinen Verkehr.
5. **Vergleichen.** KV-Cache-Größe, TTFT und Durchsatz beider Varianten unter derselben Last – mit der Methodik aus Kapitel 8.
6. **Umschalten** über das Gateway, nicht über einen Service-Namen. So bleibt der Rückweg offen.
7. **Altes Deployment entfernen,** wenn eine Woche ohne Auffälligkeit vergangen ist.

ACHTUNG Ein Unterschied, der auffällt

Ein über KServe betriebener Dienst kann eine **andere** KV-Cache-Größe haben als das handgeschriebene Deployment – weil die Runtime andere Ressourcenvorgaben setzt oder weil `--gpu-memory-utilization` anders vorbelegt ist.

Schritt 5 ist deshalb kein Formalismus. Ein unbemerkt kleinerer KV-Cache äußert sich nicht beim Start, sondern erst unter Last als Verdrängung – Tage später, wenn niemand mehr an die Umstellung denkt.

10.13 Stapelverarbeitung

Nicht jede Inferenz ist interaktiv. Das Klassifizieren eines Dokumentenbestands, das Erzeugen von Einbettungen für die RAG-Ingestion oder das nächtliche Zusammenfassen von Berichten sind Aufgaben mit völlig anderem Profil – und sie gehören nicht auf denselben Endpunkt wie der Chat-Dienst.

10.13.1 Warum getrennt

Eigenschaft	Interaktiv	Stapelbetrieb
Latenzzusage	streng	keine
Lastverlauf	schwankend mit Spitzen	konstant, planbar
Optimierungsziel	TTFT und gleichmäßige Ausgabe	Durchsatz
<code>max-num-batched-tokens</code>	moderat	hoch – Kapitel 7
Priorität	hoch	niedrig, verdrängbar
Scale-to-Zero	ungeeignet	ideal

Die dritte und vierte Zeile machen deutlich, warum ein gemeinsamer Endpunkt beiden schadet: Die Einstellungen, die den Durchsatz maximieren, sind genau die, die Latenzausreißer erzeugen.

MERKE

Stapelverarbeitung ist der Anwendungsfall, für den Scale-to-Zero tatsächlich gebaut ist. Eine GPU, die nachts vier Stunden rechnet und tagsüber schläft, kostet ein Sechstel einer dauerhaft laufenden – und die drei Minuten Kaltstart fallen bei einem vierstündigen Lauf nicht ins Gewicht.

Zusammen mit den Prioritätsklassen aus Kapitel 5 ergibt sich ein wirtschaftliches Muster: Stapelaufträge laufen mit niedriger Priorität auf derselben Hardware und weichen, sobald interaktive Last kommt.

10.13.2 Das Muster

Ein Stapelauftrag ist kein Dienst, sondern ein Job – er startet, arbeitet die Liste ab und endet.

```
apiVersion: batch/v1
kind: Job
metadata:
```

```

name: einbettungen-ingestion
spec:
  backoffLimit: 2
  template:
    spec:
      restartPolicy: Never
      priorityClassName: stapel-niedrig
      runtimeClassName: nvidia
      nodeSelector:
        node-role/gpu: "true"
      tolerations:
        - key: nvidia.com/gpu
          operator: Equal
          value: present
          effect: NoSchedule
    containers:
      - name: lauf
        image: registry.intern/ingestion:1.4.0
        resources:
          limits:
            nvidia.com/gpu: 1
            cpu: "8"
            memory: 32Gi

```

ACHTUNG Ein Job blockiert die GPU vollständig

Solange der Auftrag läuft, ist die Karte belegt – auch wenn er nur zu dreißig Prozent auslastet. Kubernetes vergibt GPUs ganzzahlig und exklusiv, wie Kapitel 5 gezeigt hat. Daraus folgt eine Betriebsregel: Stapelaufträge gehören auf eine Karte, die dafür vorgesehen ist – oder sie laufen mit niedriger Priorität und werden verdrängt. Was nicht funktioniert, ist die Hoffnung, sie würden sich „schon vertragen“.

10.13.3 Offline-Verarbeitung ohne Server

Für reine Stapelverarbeitung ist ein HTTP-Server unnötiger Aufwand. vLLM lässt sich direkt in einem Skript verwenden, was den Netzwerkweg und die Serialisierung erspart:

```

from vllm import LLM, SamplingParams

llm = LLM(model="/modelle/qwen2.5-7b-awq",
          max_model_len=4096,
          gpu_memory_utilization=0.92)

params = SamplingParams(temperature=0, max_tokens=256)

with open("/daten/eingabe.txt") as f:
    prompts = [z.strip() for z in f if z.strip()]

# Der gesamte Stapel wird intern gebatcht
ausgaben = llm.generate(prompts, params)

with open("/daten/ausgabe.jsonl", "w") as f:

```

```
for a in ausgaben:
    f.write(a.outputs[0].text.replace("\n", " ") + "\n")
```

MERKE

Der Aufruf mit einer vollständigen Liste ist der wesentliche Punkt: Der Scheduler bekommt alle Anfragen auf einmal und kann optimal batchen. Ein Skript, das die Prompts einzeln in einer Schleife an einen HTTP-Endpunkt schickt und auf jede Antwort wartet, erreicht einen Bruchteil des Durchsatzes – weil es genau das Batching verhindert, um dessentwillen der Server existiert.

Das ist der häufigste Leistungsfehler bei Stapelverarbeitung, und er liegt nicht in der Infrastruktur, sondern im Aufrufmuster.

Ein höheres `gpu-memory-utilization` ist hier vertretbar, weil keine anderen Prozesse auf der Karte laufen – und ein höheres Token-Budget je Schritt ebenfalls, weil es keine Latenzzusage gibt, die durch große Prefill-Stücke verletzt würde.

10.14 Auslastung über mehrere Dienste

Sobald mehrere `InferenceService` im Cluster laufen, stellt sich die Frage nach der Gesamtauslastung. Sie ist der Übergang zu Teil V.

```
kubectl get isvc -A -o custom-columns=\
'NS:.metadata.namespace,NAME:.metadata.name,\
READY:.status.conditions[?(@.type=="Ready")].status,\
URL:.status.url'
```

Aussagekräftiger ist die Gegenüberstellung von zugeteilter und genutzter Kapazität:

Frage	Quelle	Kapitel
Wie viele GPUs sind vergeben?	Summe der Limits aller Pods	5
Wie ausgelastet sind sie?	DCGM je Karte	14
Wie viele Anfragen kommen an?	vLLM-Metriken je Dienst	7
Wer verursacht sie?	Nur das Gateway weiß das	11

MERKE

Die letzte Zeile ist der Grund, warum Teil IV auf Teil III folgt. Die Serving-Schicht weiß, **wie viel** Arbeit anfällt. Sie weiß nicht, **wer** sie verursacht – diese Information existiert nur an der Stelle, an der die Identität bekannt ist. Ohne Gateway lässt sich weder zuordnen noch begrenzen noch abrechnen.

10.15 Lab: InferenceService mit Canary

LAB Model Serving deklarativ betreiben

Ziel: Ein Modell über KServe bereitstellen und einen Versionswechsel schrittweise fahren.

Voraussetzung: KServe im Cluster, Betriebsart RawDeployment, Modell im Objektspeicher oder auf einem Volume.

Schritt 1 – Runtime anlegen. Die ClusterServingRuntime aus Abschnitt 10.3 anwenden. Sie wird einmal je Cluster gebraucht:

```
kubectl apply -f vllm-runtime.yaml
kubectl get clusterservingruntime
```

Schritt 2 – InferenceService ausrollen.

```
kubectl apply -f chat-v1.yaml
kubectl get isvc chat-v1 -w
```

Erwartete Ausgabe: Die Spalte READY wechselt nach einigen Minuten auf True, und URL nennt den Endpunkt. Bleibt sie auf False, gibt kubectl describe isvc chat-v1 den Grund.

Schritt 3 – Endpunkt prüfen.

```
kubectl port-forward svc/chat-v1-predictor 8080:80 &
curl -s localhost:8080/v1/models | jq -r '.data[].id'
```

Erwartete Ausgabe: Der über --served-model-name vergebene Name.

Schritt 4 – Skalierung an das richtige Signal hängen. ScaledObject aus Abschnitt 10.5 anwenden und unter Last beobachten:

```
kubectl get scaledobject,hpa
ISVC=serving.kserve.io/inferenceservice
kubectl get pods -l "$ISVC=chat-v1" -w
```

Erzeugen Sie Last wie in Kapitel 8. **Erwartung:** Sobald num_requests_waiting den Schwellwert überschreitet, wird eine zweite Replik gestartet – und braucht die volle Ladezeit, bevor sie hilft. Genau deshalb ist die Warteschlange ein Frühindikator und keine Notbremse.

Schritt 5 – Canary starten. Neue Version ohne Verkehr:

```
NEU=s3://modelle/qwen2.5-7b-awq-v2
jq -n --arg u "$NEU" '{spec:{predictor:{
  canaryTrafficPercent:0,
  model:{storageUri:$u}}}}' > patch.json
kubectl patch isvc chat-v1 --type=merge \
  --patch-file patch.json
```

Schritt 6 – Fachlich prüfen, dann Verkehr geben. Prüfsatz gegen die neue Revision fahren. Erst danach:

```
for p in 10 50 100; do
  jq -n --argjson p "$p" \
    '{spec:{predictor:{canaryTrafficPercent:$p}}}' \
    > patch.json
  kubectl patch isvc chat-v1 --type=merge \
```



```
--patch-file patch.json
sleep 300
kubectl get isvc chat-v1 \
  -o jsonpath='{.status.components.predictor.traffic}'
echo
done
```

Erwartete Ausgabe: Die Verkehrsaufteilung verschiebt sich schrittweise. Beobachten Sie dabei Fehlerrate und TTFT-Perzentile beider Revisionen getrennt.

Ergebnis: Ein Modellwechsel ohne Ausfall und mit Rückfallmöglichkeit – und die Erfahrung, dass die technische Absicherung die fachliche Prüfung nicht ersetzt.

10.16 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
InferenceService bleibt READY=False	Runtime nicht gefunden oder Modellformat passt nicht	<code>kubectl describe isvc</code> – Bedingungen am Ende	<code>modelFormat</code> gegen <code>supportedModelFormats</code> prüfen
Storage-Initializer schlägt fehl	Zugangsdaten oder Pfad falsch	Log des Init-Containers	Secret und Dienstkonto prüfen; Pfad gegen den Objektspeicher halten
Pod startet, aber Sonde schlägt fehl	Startsonde in der Runtime zu streng – Kapitel 8	Zeit bis zur ersten erfolgreichen Sonde	<code>failureThreshold</code> in der <code>ClusterServingRuntime</code> erhöhen
Skalierung reagiert nicht	Metrik nicht verfügbar oder Abfrage liefert nichts	Abfrage direkt gegen Prometheus ausführen	Beschriftungen im Abfrageausdruck korrigieren
Skalierung pendelt	Abkühlzeit zu kurz gegenüber der Ladezeit	Zeitverlauf der Replikatzahl	<code>cooldownPeriod</code> auf ein Vielfaches der Ladezeit setzen
Canary-Pod bleibt Pending	Keine freie GPU für die zweite Version	<code>kubectl describe pod</code> <code>Insufficient</code> – <code>nvidia.com/gpu</code>	Zweiten GPU-Knoten bereitstellen; ohne ihn kein Canary
Nach dem Rollout ist die Latenz schlechter	Andere Modellgröße oder anderes Format	KV-Cache-Größe beider Revisionen im Log vergleichen	Engine-Argumente an das neue Modell anpassen

10.17 Interviewfragen

INTERVIEWFRAGE

Was ist ein KServe InferenceService, und was gewinnen Sie damit?

Gut ist: eine Ressourcenart, die ein Modell deklarativ bereitstellt.

Senior ist die Trennung: Die `ServingRuntime` beschreibt, **wie** ein Server gestartet wird – gepflegt vom Plattformteam –, der `InferenceService` beschreibt, **welches**

Modell bereitgestellt wird – geschrieben vom Anwendungsteam. Dazu die ehrliche Einordnung: Für einen einzelnen Dienst ist ein handgeschriebenes Deployment einfacher. Der Nutzen entsteht ab dem fünften Modell, wenn Modellbezug, Rollout und Skalierung nicht mehr zwanzigmal einzeln gelöst werden sollen.

INTERVIEWFRAGE

Warum ist CPU-basiertes Autoscaling bei LLMs unzureichend?

Gut ist: Die Arbeit findet auf der GPU statt.

Senior ist die Aufzählung der Alternativen mit ihrer jeweiligen Schwäche – Speicher- auslastung ist konstant, GPU-Auslastung zeigt nur, dass Kernel laufen, Anfragen je Sekunde ignorieren die Verarbeitungsdauer – und die richtige Antwort: die Warteschlangenlänge des Schedulers als Hauptsignal, die KV-Cache-Belegung als Frühindikator. Wer ergänzt, dass Verdrängungen kein Skalierungssignal sind, weil es dann bereits zu spät ist, kennt die Metriken aus Kapitel 7 wirklich.

INTERVIEWFRAGE

Wie funktioniert Scale-to-Zero bei LLMs – und würden Sie es einsetzen?

Senior ist eine Rechnung statt einer Meinung: Der Kaltstart kostet die volle Ladezeit von mehreren Minuten. Damit ist Scale-to-Zero geeignet für Entwicklung, Stapelbetrieb und selten genutzte Fachmodelle – und ungeeignet für interaktive Dienste. Die Alternative ist Warmhaltung mit reduzierter Kapazität: nachts eine Replik statt drei, was zwei Drittel spart, ohne dass jemand drei Minuten wartet.

INTERVIEWFRAGE

Wie führen Sie einen Modellwechsel in Produktion durch?

Gut ist Canary mit schrittweiser Verkehrsaufteilung.

Senior ist die Reihenfolge und ihre Begründung: Neue Version zuerst mit null Prozent Verkehr starten, dann den **fachlichen** Prüfsatz aus Kapitel 3 dagegen fahren, und erst danach Verkehr geben. Der Grund: Ein Canary misst Fehler, Latenz und Durchsatz – er misst nicht, ob die Antworten schlechter geworden sind. Genau das ist bei einem Modellwechsel aber die entscheidende Frage. Wer ergänzt, dass Canary doppelte GPU-Kapazität voraussetzt und auf einem Ein-Karten-Cluster nicht möglich ist, verbindet es mit der Hardware.

INTERVIEWFRAGE

vLLM, SGLang, TensorRT-LLM, Triton – wie wählen Sie aus?

Senior ist eine Auswahl nach Einsatzbereich statt nach Benchmark: TensorRT-LLM bei maximaler Leistung auf festgelegter Hardware, mit dem Preis eines Übersetzungsschritts je Modell und GPU-Typ. SGLang bei vielen gemeinsamen Präfixen. Triton,

wenn mehrere Frameworks in einem Server laufen sollen. vLLM als Regelfall wegen Modellbreite, Betriebsreife und Verbreitung.

Der überzeugende Zusatz ist das dritte Kriterium: Marktverbreitung. Ein zehn Prozent schnellerer Server, den im Haus niemand betreiben kann, ist die teurere Wahl.

10.18 Zusammenfassung

- KServe trennt *ServingRuntime* — wie ein Server gestartet wird, gepflegt vom Plattformteam — von *InferenceService* — welches Modell bereitgestellt wird, geschrieben vom Anwendungsteam.
- Der Nutzen entsteht ab dem fünften Modell. Für einen einzelnen Dienst ist ein handgeschriebenes Deployment einfacher.
- *RawDeployment* ist für LLM-Serving in den meisten Fällen die bessere Betriebsart. Serverless lohnt nur, wenn Scale-to-Zero tatsächlich gebraucht wird.
- *pvc://* ist der schnellste Modellbezug, weil nichts kopiert wird. *hf://* gehört nicht in Produktion.
- CPU, Speicher und GPU-Auslastung sind schlechte Skalierungssignale. Die Warteschlangenlänge des Schedulers ist das beste, die KV-Cache-Belegung der beste Frühindikator.
- Die Abkühlzeit der Skalierung muss ein Vielfaches der Ladezeit betragen, sonst pendelt der Dienst.
- Scale-to-Zero kostet die volle Ladezeit bei der ersten Anfrage. Für interaktive Dienste ist Warmhaltung mit reduzierter Kapazität die bessere Antwort.
- Canary braucht doppelte GPU-Kapazität — auf einem Cluster mit einer Karte ist es nicht möglich.
- Vor der Verkehrsaufteilung steht der fachliche Prüfsatz. Ein Canary misst technische Kennzahlen, nicht Antwortqualität.
- Bei der Serverauswahl zählen neben der Leistung Modellunterstützung, Betriebsreife und Marktverbreitung.

Quellen und Weiterlesen

- KServe: *Documentation* — *InferenceService* und *Serving Runtimes*. Aufbau der Ressourcenarten und unterstützte Modellformate.
- KServe: *Documentation* — *Storage Containers* und die unterstützten Herkunftsschemata einschließlich OCI-Artefakten.
- KEDA: *Documentation* — *Prometheus Scaler*. Skalierung anhand eigener Metriken.
- Knative: *Serving* — *Autoscaling*. Gleichzeitigkeitsbasierte Skalierung und Scale-to-Zero.
- Die Dokumentationen von SGLang, TensorRT-LLM, TGI und Triton — für die Auswahlentscheidung jeweils gegen die aktuelle Modellunterstützung prüfen.

TEIL IV

Der Enterprise-Layer

Bis hierher ist die Plattform technisch funktionsfähig. Was fehlt, ist alles, was sie in einem Unternehmen betreibbar macht: Wer darf was, mit welchen Daten, zu welchen Kosten – und wie lässt sich das nachweisen.

AI Gateway mit LiteLLM

ZIEL	Die Schicht bauen, an der Identität, Inhalt, Kosten und Zielmodell gleichzeitig bekannt sind – und die deshalb der einzige sinnvolle Ort für Governance ist.
SETZT VORAUS	Ein erreichbarer Inferenz-Endpunkt aus Kapitel 8 oder 10.
DANACH KANNST DU	Ein Gateway konfigurieren und betreiben, Virtual Keys mit Budgets und Kontingenten je Team vergeben, Routing und Fallback einrichten, die Protokollierungsfrage entscheiden und das Gateway hochverfügbar auslegen.


GESCHRIEBEN GEGEN

LiteLLM 1.6x · PostgreSQL 16 · Redis 7 · Stand September 2026

Zehn Kapitel haben auf diese Komponente verwiesen. Kontingente statt eigener GPUs, Kostenzuordnung über Token, kontrollierte Protokollierung, Modellnamen als Entkopplung, getrennte Endpunkte je Lastprofil – all das wurde ins Gateway verschoben. Dieses Kapitel löst die Versprechen ein.

11.1 Warum ein Gateway

11.1.1 Die vier Aufgaben




MERKE

Der Inferenz-Server aus Teil III weiß, **wie viel** Arbeit anfällt. Er weiß nicht, **wer** sie verursacht – ein API-Schlüssel je Anwendung wäre das Äußerste, und selbst der sagt nichts über Budgets oder Datenklassifikation.

Die Anwendung wiederum kennt ihren Nutzer, aber nicht die Kosten, nicht die Modell-Allowlist und nicht die Verfügbarkeit der Anbieter. Nur das Gateway sieht alles gleichzeitig. Das ist kein Architekturgeschmack, sondern eine Eigenschaft der Informationsverteilung.

11.1.2 Was ohne Gateway nicht geht

Anforderung	Ohne Gateway
Kosten je Team	Eine Sammelrechnung ohne Zuordnung – Kapitel 1
Kontingente je Team	Nur über getrennte Hardware – Kapitel 6
Modellwechsel ohne Anwendungsänderung	Jede Anwendung muss angepasst werden
Ausweichen bei Anbieterausfall	Jede Anwendung braucht eigene Logik
Kontrollierte Protokollierung	Prompts liegen im Containerlog – Kapitel 8
Datenklassifikation im Anfragepfad	Findet nicht statt
Einheitliche Schnittstelle über Anbieter	Jede Anwendung spricht jeden Anbieter

11.2 Architektur**11.2.1 Die Bestandteile**

Der Proxy ist zustandslos; der Zustand liegt in Datenbank und Cache.

Die Trennung ist wichtig für den Betrieb: Der Proxy selbst hält keinen Zustand und lässt sich beliebig vervielfachen. Datenbank und Cache tragen den Zustand – und sind damit die Komponenten, deren Verfügbarkeit über die der Plattform entscheidet.

11.2.2 Die Konfiguration

```
model_list:
  # Eigenes Modell -- Kapitel 8
  - model_name: unternehmen-chat
    litellm_params:
      model: openai/unternehmen-chat-v1
      api_base: http://chat-v1-predictor.serving:80/v1
      api_key: os.environ/VLLM_KEY
      rpm: 600

  # Zweite Replik desselben Modells
  - model_name: unternehmen-chat
    litellm_params:
      model: openai/unternehmen-chat-v1
      api_base: http://chat-v2-predictor.serving:80/v1
      api_key: os.environ/VLLM_KEY
      rpm: 600

  # Externer Anbieter
  - model_name: extern-gross
    litellm_params:
      model: azure/gpt-4o
      api_base: os.environ/AZURE_BASE
      api_key: os.environ/AZURE_KEY

router_settings:
  routing_strategy: least-busy
  redis_host: os.environ/REDIS_HOST
  fallbacks:
    - unternehmen-chat: [extern-gross]

litellm_settings:
  drop_params: true
  set_verbose: false

general_settings:
  database_url: os.environ/DATABASE_URL
  master_key: os.environ/MASTER_KEY
```

MERKE

Zwei Einträge mit demselben `model_name` bilden eine **Gruppe**: Das Gateway verteilt Anfragen darauf und nimmt eine ausgefallene Replik aus der Verteilung. Damit übernimmt es die Rolle, die in Kapitel 10 dem Service zufiel – allerdings mit Kenntnis von Fehlerraten und Auslastung.

`model_name` ist zugleich der fachliche Name, den Anwendungen verwenden. Zusammen mit `--served-model-name` aus Kapitel 8 entsteht damit eine zweifache Entkopplung: Die Anwendung kennt weder das Modell noch dessen Standort.

11.3 Virtual Keys, Teams und Budgets

11.3.1 Die Hierarchie

Ebene	Zweck	Typische Einstellung
Organisation	Oberste Klammer, etwa ein Geschäftsbereich	Gesamtbudget
Team	Kostenstelle, Abteilung	Monatsbudget, erlaubte Modelle
Schlüssel	Eine Anwendung oder ein Zugang	Ratenbegrenzung, Gültigkeitsdauer
Endnutzer	Person hinter der Anfrage	Verbrauchszuordnung, Obergrenze

Die unterste Ebene ist die, die am häufigsten fehlt und am meisten bringt: Wenn die Anwendung den Endnutzer mitschickt, lässt sich der Verbrauch bis auf die Person zurückführen — ohne dass für jede Person ein eigener Schlüssel existieren müsste.

11.3.2 Einen Schlüssel ausstellen

```
curl -s http://gateway/key/generate \
-H "Authorization: Bearer $MASTER_KEY" \
-H 'Content-Type: application/json' \
-d '{
  "team_id": "team-recht",
  "key_alias": "vertragsassistent-prod",
  "models": ["unternehmen-chat"],
  "max_budget": 200,
  "budget_duration": "30d",
  "rpm_limit": 120,
  "tpm_limit": 200000,
  "duration": "90d"
}' | jq -r .key
```

Feld	Wirkung
models	Allowlist. Anfragen an andere Modelle werden abgelehnt — die technische Umsetzung der Datenklassifikation aus Kapitel 13
max_budget	Obergrenze in Währungseinheiten für den Zeitraum
budget_duration	Zurücksetzung des Verbrauchs
rpm_limit, tpm_limit	Anfragen bzw. Token je Minute
duration	Ablauf des Schlüssels — erzwingt Rotation
key_alias	Sprechender Name; der Schlüssel selbst wird nur einmal angezeigt

ACHTUNG Gültigkeitsdauer ist keine Schikane

Ein Schlüssel ohne `duration` lebt ewig — und landet erfahrungsgemäß in Konfigurationsdateien, Notizen und Chatverläufen. Eine Gültigkeit von 90 Tagen erzwingt eine Rotation und macht damit aus einem dauerhaften Risiko ein befristetes.

Voraussetzung ist, dass die Rotation automatisiert ist. Kapitel 12 zeigt, wie Schlüssel aus OpenBao bezogen und erneuert werden, ohne dass jemand sie von Hand kopiert.

11.3.3 Kontingente gegen GPU-Zuteilung

Kapitel 6 hat die Behauptung aufgestellt, dass „jedes Team braucht eine eigene GPU“ fast immer die falsche Antwort ist. Hier ist die richtige:

	Eigene GPU je Team	Kontingent im Gateway
Zusicherung	Hardware, exklusiv	Anfragen und Token je Minute
Auslastung	je Team einzeln — meist schlecht	gemeinsam — gut
Kosten	vervielfacht	geteilt
Änderung	Beschaffung	ein API-Aufruf
Granularität	ganze Karten	je Anwendung und Person
Nachweisbarkeit	keine	vollständig

MERKE

Ein Kontingent ist die **bessere** Zusicherung, nicht die schwächere: Es ist feiner, sofort änderbar, nachweisbar — und es verschwendet keine Hardware. Der einzige Fall, in dem eine eigene GPU nötig bleibt, ist ein eigenes **Modell** — und dafür gibt es Multi-LoRA aus Kapitel 8.

11.4 Routing und Ausfallsicherheit

11.4.1 Verteilungsstrategien

Strategie	Arbeitsweise	Geeignet für
Zufällig	Gleichmäßige Verteilung	Gleichartige Repliken
Nach Auslastung	Bevorzugt die Replik mit den wenigsten offenen Anfragen	Der Regelfall bei eigenen Modellen
Nach Latenz	Bevorzugt die zuletzt schnellste	Gemischte Hardware
Nach Verbrauch	Verteilt anhand von Ratenbegrenzungen der Anbieter	Mehrere externe Konten

11.4.2 Fallback-Ketten

Der Fall, für den Kapitel 1 das Gateway begründet hat: Ein Anbieter fällt aus.

```
router_settings:
  fallbacks:
    - unternehmen-chat: [unternehmen-chat-klein, extern-gross]
  context_window_fallbacks:
    - unternehmen-chat: [unternehmen-chat-lang]
  num_retries: 2
  request_timeout: 120
  allowed_fails: 3
  cooldown_time: 60
```

Einstellung	Bedeutung
fallbacks	Ausweichmodelle, wenn das primäre fehlschlägt

Einstellung	Bedeutung
context_window_fallbacks	Ausweichen, wenn der Prompt zu lang ist — statt Fehler ein Modell mit größerem Kontext
num_retries	Wiederholungen vor dem Ausweichen
allowed_fails	Fehlerzahl, ab der ein Ziel ausgesetzt wird
cooldown_time	Wie lange ein Ziel ausgesetzt bleibt

Die zweite Zeile ist eine unterschätzte Funktion. Kapitel 2 hat gezeigt, dass die Kontextlänge eine Kapazitätsentscheidung ist — und dass ein zu langer Prompt abgewiesen wird. Statt der Anwendung einen Fehler zu liefern, kann das Gateway auf einen Endpunkt mit größerem Kontext ausweichen. Das ist genau die Trennung nach Lastprofil aus Kapitel 2, nur automatisch.

ACHTUNG Fallback über die Datengrenze hinweg

Eine Fallback-Kette, die von einem **lokalen** auf ein **externes** Modell ausweicht, verlässt möglicherweise die zulässige Datenkategorie — und zwar genau dann, wenn niemand hinsieht, nämlich während einer Störung.

Fallbacks müssen deshalb innerhalb derselben Datenklasse bleiben. Für Anfragen, die das Haus nicht verlassen dürfen, lautet die richtige Reaktion auf einen Ausfall: **ablehnen**, nicht ausweichen. Kapitel 13 macht daraus eine durchgesetzte Regel.

11.4.3 Was die Anwendung merken soll

Situation	Antwort	Begründung
Budget erschöpft	429	Wiederholbar, sobald der Zeitraum wechselt
Ratenbegrenzung erreicht	429 mit Retry-After	Die Anwendung kann warten
Modell nicht erlaubt	403	Wiederholen hilft nicht
Alle Ziele ausgefallen	503	Vorübergehend
Prompt zu lang, kein Ausweichziel	400	Die Anwendung muss kürzen
Datenklasse verbietet das Ziel	403 mit Begründung	Kapitel 13

MERKE

Diese Zuordnung gehört in die Schnittstellenbeschreibung der Plattform. Anwendungsteams müssen wissen, welche Fehler wiederholbar sind und welche nicht — sonst bauen sie entweder gar keine Behandlung ein oder wiederholen auch dann, wenn es nie funktionieren wird. Beides erzeugt Last, die niemand gebrauchen kann.

11.5 Protokollierung und die Prompt-Frage

11.5.1 Die Entscheidung

Kapitel 8 hat Prompts aus dem Containerlog verbannt. Damit ist die Frage nicht beantwortet, sondern verschoben — an die Stelle, an der sie kontrolliert beantwortet werden kann.

Umfang	Was gespeichert wird	Einordnung
Nur Kennzahlen	Zeitpunkt, Team, Modell, Tokenzahl, Kosten, Dauer, Statuscode	Der Regelfall. Genügt für Abrechnung, Kapazitätsplanung und Betrieb
Zusätzlich Metadaten	Anwendung, Endnutzer, Datenklasse	Für Nachweispflichten meist erforderlich
Vollständige Inhalte	Prompt und Antwort im Klartext	Nur mit ausdrücklicher Rechtsgrundlage, kurzer Frist und Zugriffsbeschränkung

MERKE

Die erste Zeile deckt praktisch alle Betriebsbedürfnisse ab. Kostenzuordnung, Kapazitätsplanung, Fehlersuche auf Systemebene und Nachweis der Nutzung funktionieren vollständig ohne Prompt-Inhalte.

Inhalte werden fast immer aus einem anderen Grund gewünscht: um die **Qualität** der Antworten zu untersuchen. Das ist ein berechtigtes Anliegen — aber es ist eine Auswertung mit eigenem Zweck, eigener Rechtsgrundlage und eigener Aufbewahrung, und es gehört nicht in das allgemeine Betriebsprotokoll.

11.5.2 Umsetzung

```
litellm_settings:
  success_callback: ["prometheus", "otel"]
  failure_callback: ["prometheus", "otel"]
  turn_off_message_logging: true
```

Die letzte Zeile ist die entscheidende: Sie sorgt dafür, dass die Rückmeldungen nur Kennzahlen enthalten, keine Inhalte. Wo Inhalte tatsächlich benötigt werden, geschieht das über einen getrennten Pfad mit eigener Aufbewahrungsregel — nicht durch Abschalten dieser Einstellung.

11.6 Antwort-Caching

Identische Anfragen müssen nicht zweimal gerechnet werden. Für Anwendungen mit wiederkehrenden Fragen — Hilfetexte, Klassifikationen, Formatumwandlungen — ist das eine erhebliche Ersparnis.

```
litellm_settings:
  cache: true
  cache_params:
    type: redis
    ttl: 3600
```

Prüfen Sie das nach der Inbetriebnahme nach: eine Testanfrage mit einem erkennbaren Inhalt senden und anschließend in Logs, Metriken und Traces danach suchen. Diese Prüfung gehört in die Abnahme.

Art	Trefferbedingung	Einordnung
Exakt	Identische Anfrage, identische Parameter	Sicher und vorhersagbar. Der Regelfall
Semantisch	Ähnliche Anfrage nach Einbetungsvergleich	Verlockend, aber riskant — siehe unten

ACHTUNG Semantisches Caching liefert falsche Antworten

Ein semantischer Cache liefert die Antwort auf eine **ähnliche** Frage. Der Unterschied zwischen „Wie kündige ich den Vertrag?“ und „Wie kündige ich den Vertrag **vorzeitig**?“ ist für eine Ähnlichkeitsmessung klein und fachlich entscheidend.

Bei Anfragen mit Personenbezug kommt hinzu: Zwei Nutzer mit ähnlicher Frage, aber unterschiedlichem Kontext könnten die Antwort des jeweils anderen erhalten.

Wenn semantisches Caching eingesetzt wird, dann mit hoher Ähnlichkeitsschwelle, je Mandant getrennt und ausschließlich für Anfragen ohne Personenbezug. Für den allgemeinen Betrieb ist exaktes Caching die richtige Wahl.

11.7 Eigene Modelle bepreisen

Für externe Anbieter kennt das Gateway die Preise und rechnet den Verbrauch in Geld um. Für ein selbst betriebenes Modell weiß es nichts — und zeigt Kosten von null an. Damit funktioniert die Kostenzuordnung genau für den Teil nicht, der die Hardware verursacht.

11.7.1 Vom Serverpreis zum Tokenpreis

Kapitel 1 hat einen GPU-Server mit rund 2 480 € im Monat berechnet — Abschreibung, Strom, Fläche, Betrieb. Diese Zahl lässt sich in einen Tokenpreis umrechnen.

Nr.	Schritt	Beispiel
1	Kosten der Karte je Monat	2 480 €
2	Betriebsstunden je Monat	730
3	Kosten je Stunde	3,40 €
4	Durchsatz bei realistischer Auslastung	800 Ausgabetoken/s
5	Ausgabetoken je Stunde bei 40 % Auslastung	ca. 1,15 Mio.
6	Kosten je Million Ausgabetoken	ca. 2,95 €
7	Eingabetoken nach Prefill-Anteil	rund ein Zehntel davon

MERKE

Schritt 5 ist der wichtige: Der Tokenpreis hängt von der **Auslastung** ab, nicht vom Anschaffungspreis. Dieselbe Karte kostet bei 80 Prozent Auslastung die Hälfte je Token wie bei 40 Prozent. Damit wird die Aussage aus Kapitel 1 — Auslastung ist die zentrale wirtschaftliche Größe — zu einer Zahl, die im Verbrauchsprotokoll auftaucht.

Der Wert gehört regelmäßig aktualisiert. Eine jährlich gepflegte Zahl genügt; eine Zahl von null führt dazu, dass Eigenbetrieb in jeder Auswertung kostenlos erscheint und Cloud-Nutzung teuer — die Grundlage für falsche Entscheidungen.

11.7.2 Konfiguration

```
model_list:
- model_name: unternehmen-chat
  litellm_params:
    model: openai/unternehmen-chat-v1
    api_base: http://chat-v1-predictor.serving:80/v1
    api_key: os.environ/VLLM_KEY
    # Preise in Waehrungseinheiten je Token
    input_cost_per_token: 0.0000003
    output_cost_per_token: 0.00000295
```

Damit erscheinen eigene und externe Modelle in derselben Auswertung mit vergleichbaren Zahlen – und die Frage „lohnt sich der Eigenbetrieb?“ aus Kapitel 1 lässt sich mit echten Daten statt mit Annahmen beantworten. Kapitel 14 baut die Auswertung darauf auf.

11.8 Anbieterfunktionen weiterreichen

Ein Gateway, das nur einfachen Text durchreicht, ist für moderne Anwendungen zu wenig. Werkzeugaufrufe, strukturierte Ausgaben und multimodale Eingaben müssen unverändert ankommen.

Funktion	Anmerkung	Kapitel
Werkzeugaufrufe	Setzt einen passenden Auswerter im Inferenz-Server voraus	8
Strukturierte Ausgaben	<code>response_format</code> mit Schema wird durchgereicht	7
Bilder in der Eingabe	Nur bei Modellen, die das können	–
Einbettungen	Eigener Endpunkt, eigene Modelle	8, 15
Wahrscheinlichkeiten	Vom Server begrenzt	8

ACHTUNG Stillschweigend verworfene Parameter

Die Einstellung `drop_params: true` sorgt dafür, dass Parameter, die ein Ziel nicht kennt, entfernt werden statt einen Fehler auszulösen. Das erhöht die Kompatibilität über verschiedene Anbieter hinweg – und es kann dazu führen, dass eine Anwendung ohne Fehlermeldung etwas anderes bekommt, als sie angefordert hat.

Besonders unangenehm ist das bei `response_format`: Wird es verworfen, liefert das Modell freien Text statt des erzwungenen Schemas – und die Anwendung scheitert erst beim Auswerten. Wo strukturierte Ausgaben verbindlich sind, sollte `drop_params` für dieses Ziel abgeschaltet sein, damit ein Fehler sichtbar wird.

11.8.1 Der Modellkatalog

Anwendungsteams müssen wissen, was sie nutzen dürfen. Die Abfrage liefert genau die Modelle, die der jeweilige Schlüssel erreichen darf:

```
curl -s localhost:4000/v1/models \
-H "Authorization: Bearer $TEAM_KEY" \
| jq -r '.data[].id'
```

MERKE

Diese gefilterte Auskunft ist ein unterschätzter Baustein der Selbstbedienung: Ein Team sieht nur, was ihm zusteht, und braucht keine Dokumentation, die veraltet. Für den Katalog der Plattform – welche Modelle es gibt, wofür sie gedacht sind, welche Datenklasse sie verarbeiten dürfen – braucht es allerdings eine gepflegte Beschreibung daneben. Kapitel 13 verbindet beides mit der Datenklassifikation.

11.9 Streaming durch das Gateway

Praktisch jede Chat-Anwendung nutzt strömende Ausgabe – Kapitel 2 hat gezeigt, warum: Eine Antwort, die nach 0,3 Sekunden beginnt, wirkt schnell, auch wenn sie zehn Sekunden dauert. Für das Gateway bringt das drei Besonderheiten mit sich, die in der Praxis regelmäßig übersehen werden.

11.9.1 Pufferung bricht das Streaming

Ein Ingress oder Reverse Proxy, der Antworten puffert, sammelt die gesamte Ausgabe und liefert sie am Ende auf einmal aus. Technisch funktioniert das – die Anwendung erhält gültige Daten. Für den Nutzer verschwindet aber genau der Vorteil: Statt nach 0,3 Sekunden erscheint die Antwort nach zehn.

OHNE PUFFERUNG

t=0,3s "Die"
t=0,4s "Antwort"
t=0,5s "beginnt"
...
t=10s Ende

Gefuehlte Wartezeit: 0,3 Sekunden

MIT PUFFERUNG

t=0,3s (nichts)
t=0,4s (nichts)
...
t=10s "Die Antwort beginnt ..."

Gefuehlte Wartezeit: 10 Sekunden

Pufferung macht aus strömender Ausgabe eine späte Komplettlieferrung.

ACHTUNG Der Fehler ist unsichtbar

Es erscheint keine Fehlermeldung, kein Alarm schlägt an, und die Metriken sehen unverändert aus – TTFT wird serverseitig gemessen und bleibt niedrig. Auffallen kann es nur den Nutzern.

Für die gängigen Ingress-Umsetzungen bedeutet das eine ausdrückliche Abschaltung der Pufferung auf den betroffenen Pfaden, oft über eine Annotation. Prüfen Sie es nach der Inbetriebnahme **aus Nutzersicht**: eine strömende Anfrage stellen und beobachten, ob Token einzeln eintreffen.

```
curl -N -s localhost:4000/v1/chat/completions \
-H "Authorization: Bearer $KEY" \
-H 'Content-Type: application/json' \
-d '{"model": "unternehmen-chat", "stream": true,
  "messages": [{"role": "user",
    "content": "Zaehle langsam bis zwanzig."}]}'
```

Die Option `-N` schaltet die Pufferung von `curl` selbst ab. Erscheinen die Fragmente einzeln, ist der Pfad in Ordnung.

11.9.2 Verbrauch wird erst am Ende bekannt

Bei einer gewöhnlichen Anfrage kennt das Gateway die Tokenzahl mit der Antwort. Bei strömender Ausgabe kommt sie – wenn überhaupt – erst mit dem letzten Fragment.

```
{"stream": true, "stream_options": {"include_usage": true}}
```

Ohne diese Angabe liefern viele Anbieter keine Verbrauchsangabe, und das Gateway muss schätzen. Für die Kostenzuordnung ist das ein Unterschied, der auffällt.

MERKE

Daraus folgt eine Grenze der Budgetdurchsetzung: Das Gateway kann eine **laufende** strömende Anfrage nicht anhand ihrer Kosten abrechnen, weil es sie erst am Ende kennt. Ein Team kann sein Budget deshalb innerhalb einer einzelnen Anfrage überschreiten.

In der Praxis ist das unkritisch, solange `max_tokens` serverseitig begrenzt ist – Kapitel 2 hat das als wirksamste Kostenbremse benannt. Ohne diese Begrenzung ist die Überschreitung nach oben offen.

Die Anweisung an Anwendungsteams lautet deshalb: `stream_options` mitsenden, damit die Zuordnung stimmt – und die Plattform setzt unabhängig davon eine Obergrenze für die Ausgabelänge durch.

11.9.3 Zeitüberschreitungen


Eine strömende Antwort hält die Verbindung offen, solange sie dauert. Voreingestellte Zeitgrenzen von Ingress, Service Mesh oder Lastverteiler liegen häufig bei 30 oder 60 Sekunden – und schneiden lange Antworten mittendrin ab.

Stelle	Vorgabe	Empfehlung
Ingress-Lesezeit	oft 60 s	mindestens 300 s auf den Inferenzpfaden
Service Mesh	oft 15 s	entsprechend erhöhen oder Pfad ausnehmen
<code>request_timeout</code> im Gateway	–	über der längsten erwarteten Antwort
Client	oft 30 s	Anwendungsteams ausdrücklich informieren

11.10 Guardrails im Anfragepfad

Das Gateway bietet Einhängpunkte vor und nach der Modellanfrage. Dort lassen sich Prüfungen einsetzen, die Kapitel 13 im Detail behandelt – Erkennung personenbezogener Daten, Datenklassifikation, Filterung.

Dieses Problem zeigt sich typischerweise erst in Produktion – bei genau den langen Antworten, die im Test nie vorkamen.



Einhängepunkte für Prüfungen im Anfragepfad

MERKE

Der wichtige Punkt für dieses Kapitel ist die **Stelle**, nicht das Verfahren: Weil das Gateway die Datenklasse bestimmt **bevor** es das Ziel wählt, kann es die Entscheidung „diese Anfrage darf das Haus nicht verlassen“ tatsächlich durchsetzen — statt sie nur zu protokollieren.

Jede Prüfung im Anfragepfad kostet Latenz. Kapitel 13 behandelt, welche sich lohnt und welche man besser asynchron ausführt.

11.11 Anwendungsteams anbinden

Eine Plattform, deren Nutzung ein Ticket erfordert, wird umgangen. Der Zugang gehört deshalb so einfach, dass der kontrollierte Weg bequemer ist als der unkontrollierte — das Argument aus Kapitel 1.

11.11.1 Was ein Team bekommt

Element	Inhalt
Endpunkt	Eine URL — OpenAI-kompatibel, damit jede Bibliothek funktioniert
Schlüssel	Aus dem Secret-Speicher bezogen, nicht per Nachricht verschickt — Kapitel 12
Modellnamen	Fachliche Namen, keine Repository-Pfade
Kontingente	Budget, Anfragen und Token je Minute — schriftlich zugesagt
Fehlerverhalten	Die Zuordnung aus Abschnitt 11.5
Pflichtfelder	user für die Zuordnung, max_tokens als Obergrenze

11.11.2 Die Selbstbedienungsstrecke

```
# 1. Team anlegen (Plattformteam, aus GitOps)
# 2. Schluessel erzeugen und in OpenBao ablegen
# 3. Team liest ihn ueber sein Dienstkonto
```

MERKE

Die Schlüsselerzeugung gehört automatisiert und der Schlüssel in den Secret-Speicher – nicht in eine Chat-Nachricht. Kapitel 12 zeigt den vollständigen Weg. Ein Schlüssel, der einmal per Nachricht verschickt wurde, ist dauerhaft in einem Nachrichtenverlauf gespeichert und praktisch nicht mehr zurückzuholen.

11.11.3 Eine Beispielanbindung

Für Anwendungsteams reicht meist ein kurzer Hinweis: Die vorhandene Bibliothek funktioniert, es ändern sich nur zwei Werte.

```
from openai import OpenAI

client = OpenAI(
    base_url="https://ai.intern.example/v1", # statt Anbieter
    api_key=os.environ["PLATTFORM_KEY"],    # statt Anbieterkey
)

antwort = client.chat.completions.create(
    model="unternehmen-chat", # fachlicher Name
    user="m.mueller",        # Pflicht: Zuordnung
    max_tokens=800,          # Pflicht: Obergrenze
    messages=[{"role": "user", "content": frage}],
    stream=True,
    stream_options={"include_usage": True},
)
```

11.12 Bestehende Zugänge ablösen

In den meisten Organisationen existieren bereits direkte Anbieter-Zugänge – die Ausgangslage aus Kapitel 1. Der Übergang lässt sich ohne Bruch gestalten.

1. **Gateway bereitstellen**, zunächst nur mit den Modellen, die bereits genutzt werden.
2. **Bestehende Anbieterschlüssel ins Gateway verlagern**. Sie liegen danach nur noch dort – Kapitel 12.
3. **Ein freiwilliges Team umstellen** und Erfahrungen sammeln.
4. **Sichtbarkeit herstellen**: Nach einigen Wochen zeigen die Verbrauchsdaten erstmals, wer wie viel nutzt. Diese Zahlen sind das stärkste Argument gegenüber der Leitung.
5. **Frist für die Umstellung setzen**, mit Unterstützungsangebot.
6. **Direkte Zugänge abschalten**. Erst wenn die Schlüssel im Gateway liegen, ist das überhaupt durchsetzbar – vorher könnte jedes Team einfach eigene beschaffen.

ACHTUNG Die Reihenfolge ist entscheidend

Wer direkte Zugänge abschaltet, bevor das Gateway läuft und bequem nutzbar ist, erzeugt Widerstand und treibt die Nutzung in private Accounts — also genau in die Schatten-KI aus Kapitel 1, nur schlechter kontrollierbar.

Der zweite Schritt ist der wirksame: Sobald die Anbieterschlüssel ausschließlich im Gateway liegen, ist der kontrollierte Weg der einzige. Alles davor ist Überzeugungsarbeit, alles danach ist Durchsetzung.

11.13 Das Gateway als kritischste Komponente

11.13.1 Die unbequeme Wahrheit

Ein Gateway, das jede KI-Anfrage der Organisation bearbeitet, ist die Komponente, deren Ausfall alles stoppt — auch die eigenen Modelle, die weiterlaufen würden.

Ausfall	Wirkung	Gegenmaßnahme
Eine Proxy-Replik	keine	Mehrere Repliken, verteilt auf Knoten
Alle Proxy-Repliken	Totalausfall	Ausreichende Repliken, PodDisruptionBudget
PostgreSQL	Keine Schlüsselprüfung mehr — Totalausfall	Hochverfügbar auslegen; Verhalten bei Ausfall festlegen
Redis	Ratenbegrenzung und Cache fallen aus	Betrieb ohne Redis muss möglich bleiben
Ein Inferenz-Ziel	Ausweichen über Fallback	Bereits gelöst

MERKE

Die dritte Zeile ist die kritischste und wird oft übersehen: Ohne Datenbank kann das Gateway keine Schlüssel prüfen. Ein Datenbankausfall legt damit die gesamte KI-Nutzung lahm — obwohl alle Modelle laufen.

Die Datenbank des Gateways gehört deshalb in dieselbe Verfügbarkeitsklasse wie die Plattform selbst. Für viele Organisationen bedeutet das: die vorhandene, betreute Datenbankinfrastruktur nutzen statt einer beiläufig mitausgerollten Instanz im selben Namensraum.

11.13.2 Auslegung

```
replicas: 3
resources:
  requests: {cpu: "1", memory: 2Gi}
  limits:   {cpu: "2", memory: 4Gi}
topologySpreadConstraints:
- maxSkew: 1
  topologyKey: kubernetes.io/hostname
  whenUnsatisfiable: DoNotSchedule
  labelSelector:
    matchLabels: {app: gateway}
```

Der Proxy läuft auf gewöhnlichen CPU-Knoten — er rechnet nicht, er vermittelt. Drei Repliken auf verschiedenen Knoten sind ein sinnvoller Ausgangspunkt.

11.13.3 Das Latenzbudget

Ein Gateway fügt jeder Anfrage Zeit hinzu. Das ist vertretbar, muss aber bekannt sein:

Schritt	Größenordnung	Anmerkung
Schlüsselprüfung	< 1 ms	Aus dem Zwischenspeicher
Kontingentsprüfung	1–3 ms	Redis-Zugriff
Routing-Entscheidung	< 1 ms	Im Speicher
Netzwerk zum Ziel	1–5 ms	Im selben Cluster
Summe	3–10 ms	Gegen Sekunden Inferenzzeit

MERKE

Wenige Millisekunden gegen mehrere Sekunden Antwortzeit sind vernachlässigbar — das Gateway ist kein Latenzproblem. Es wird eines, wenn Datenbank oder Cache langsam antworten. Beide gehören deshalb überwacht, und zwar mit Perzentilen: Ein Redis mit gelegentlich 200 Millisekunden Antwortzeit fällt im Mittelwert nicht auf und verschlechtert trotzdem jede zwanzigste Anfrage spürbar.

11.14 Lab: Gateway einrichten

LAB Vom offenen Endpunkt zur kontrollierten Plattform

Ziel: Zugriff, Kontingente, Kostenzuordnung und Ausweichverhalten an einem echten Aufbau nachvollziehen.

Voraussetzung: Ein Inferenz-Endpunkt aus Kapitel 8 oder 10, PostgreSQL und Redis im Cluster.

Schritt 1 — Konfiguration ablegen und ausrollen.

```
kubectl create secret generic gateway-geheim \
  --from-literal=MASTER_KEY="$(openssl rand -hex 24)" \
  --from-literal=DATABASE_URL="$DB_URL" \
  --from-literal=REDIS_HOST=redis.data.svc
kubectl create configmap gateway-config \
  --from-file=config.yaml
kubectl apply -f gateway-deployment.yaml
```

Schritt 2 — Erreichbarkeit prüfen.

```
kubectl port-forward svc/gateway 4000:4000 &
curl -s localhost:4000/health/readiness | jq .
```

Erwartete Ausgabe: Ein Bereitschaftsstatus sowie die Zahl der erreichbaren Ziele. Meldet das Gateway null gesunde Ziele, stimmt `api_base` in der Konfiguration nicht.

Schritt 3 — Team und Schlüssel anlegen.

```
M="Authorization: Bearer $MASTER_KEY"
curl -s localhost:4000/team/new -H "$M" \
  -H 'Content-Type: application/json' \
  -d '{"team_alias": "team-recht", "max_budget": 500,
      "budget_duration": "30d"}' | jq -r .team_id
```

Danach den Schlüssel wie in Abschnitt 11.4 erzeugen.

Schritt 4 – Anfrage über das Gateway.

```
curl -s localhost:4000/v1/chat/completions \
  -H "Authorization: Bearer $TEAM_KEY" \
  -H 'Content-Type: application/json' \
  -d '{"model": "unternehmen-chat", "user": "m.mueller",
      "messages": [{"role": "user", "content": "Hallo"}]}' \
  | jq '{modell: .model, verbrauch: .usage}'
```

Erwartete Ausgabe: Antwort und Tokenzahlen. Beachten Sie das Feld user — es ist die Grundlage der Zuordnung bis auf die Person.

Schritt 5 – Verbrauch abfragen.

```
curl -s "localhost:4000/spend/logs" -H "$M" \
  | jq -r '.[ ] | [.user, .model, .spend] | @tsv' | tail
```

Erwartete Ausgabe: Je Anfrage eine Zeile mit Nutzer, Modell und Kosten. Genau diese Daten fehlten in Kapitel 1 und Kapitel 6.

Schritt 6 – Allowlist prüfen. Eine Anfrage an ein nicht freigegebenes Modell:

```
curl -s -o /dev/null -w '%{http_code}\n' \
  localhost:4000/v1/chat/completions \
  -H "Authorization: Bearer $TEAM_KEY" \
  -H 'Content-Type: application/json' \
  -d '{"model": "extern-gross",
      "messages": [{"role": "user", "content": "Test"}]}'
```

Erwartete Ausgabe: 401 oder 403 — die Anfrage erreicht den Anbieter nicht.

Schritt 7 – Ratenbegrenzung auslösen.

```
for i in $(seq 1 200); do
  curl -s -o /dev/null -w '%{http_code} ' \
    localhost:4000/v1/chat/completions \
    -H "Authorization: Bearer $TEAM_KEY" \
    -H 'Content-Type: application/json' \
    -d '{"model": "unternehmen-chat", "max_tokens": 5,
        "messages": [{"role": "user", "content": "hi"}]}' &
done; wait; echo
```

Erwartete Ausgabe: Zunächst 200, dann zunehmend 429. Das Kontingent greift.

Schritt 8 – Ausweichen erzwingen. Skalieren Sie das primäre Ziel auf null:

```
kubectl scale deploy/chat-v1-predictor --replicas=0
```

Anfrage wiederholen. **Erwartung:** Nach kurzer Verzögerung antwortet das Ausweichziel. Im Antwortfeld `model` steht ein anderer Wert als angefordert — die Anwendung merkt vom Ausfall nichts außer der leicht erhöhten Latenz.

Ergebnis: Zugriffskontrolle, Kontingente, Kostenzuordnung und Ausfallsicherheit — ohne dass eine Anwendung angepasst wurde. Damit ist die Reifestufe 1 aus Kapitel 1 erreicht.

11.15 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Alle Anfragen scheitern mit Authentifizierungsfehler	Datenbank nicht erreichbar — Schlüssel nicht prüfbar	<code>/health/readiness</code> ; Verbindung zur Datenbank	Datenbank wiederherstellen; Verfügbarkeit erhöhen
Kontingente greifen nicht bei mehreren Repliken	Redis fehlt — jede Replik zählt für sich	<code>redis_host</code> in <code>router_settings</code> prüfen	Redis konfigurieren; ohne ihn keine clusterweite Begrenzung
Anfragen gehen an ein ausgefallenes Ziel	<code>allowed_fails</code> zu hoch oder <code>cooldown_time</code> abgelaufen	Zielzustände über <code>/health</code> abfragen	Schwellwerte senken
Kosten werden nicht zugeordnet	Anwendung sendet kein <code>user_feld</code>	Verbrauchsprotokoll auf leere Nutzerfelder prüfen	Anwendungsteams auf das Feld verpflichten — Teil der Schnittstelle
Prompts erscheinen in Traces	<code>turn_off_message_logging</code> nicht gesetzt	<code>Testing</code> mit Erkennungsmerkmal, dann suchen	Einstellung setzen und Abnahmeprüfung ergänzen
Latenz durch das Gateway auffällig	Langsame Antworten von Redis oder Datenbank	Perzentile der Abhängigkeiten prüfen	Ressourcen erhöhen; Netzwerkpfad prüfen
Anwendung erhält Antworten eines anderen Modells	Fallback hat gegriffen — meist gewollt	Feld <code>model</code> in der Antwort auswerten	Falls unerwünscht: Fallback-Kette einschränken

11.16 Interviewfragen

INTERVIEWFRAGE

Warum sollen Anwendungen nicht direkt gegen die Anbieter-API programmieren?

Gut sind Kostenkontrolle und Ausfallsicherheit.

Senior ist die Begründung aus der Informationsverteilung: Nur an einer zentralen Stelle sind Identität, Inhalt, Kosten und erlaubtes Zielmodell **gleichzeitig** bekannt. Die Anwendung kennt ihren Nutzer, aber nicht die Budgets; der Inferenz-Server kennt die Last, aber nicht den Verursacher. Daraus folgt, dass Governance nur im Gateway stattfinden kann — und dass Kostenzuordnung, Modell-Allowlists und Datenklassifikation dieselbe Stelle brauchen.

INTERVIEWFRAGE

Wie ordnen Sie Kosten einzelnen Teams zu?

Gut ist: über Virtual Keys je Team.

Senior ist die vollständige Hierarchie — Organisation, Team, Schlüssel, Endnutzer — mit dem Hinweis, dass das Feld für den Endnutzer die Zuordnung bis auf die Person ermöglicht, ohne dass jede Person einen eigenen Schlüssel braucht. Dazu die Feststellung, dass dieses Feld von der Anwendung kommen muss und deshalb Teil der verbindlichen Schnittstellenbeschreibung ist — sonst fehlt es genau bei den Teams, die man am dringendsten zuordnen möchte.

INTERVIEWFRAGE

Was passiert, wenn Ihr Anbieter ausfällt?

Gut ist: Fallback auf ein anderes Modell.

Senior ergänzt die Grenze: Fallbacks müssen innerhalb derselben **Datenklasse** bleiben. Eine Kette, die von einem lokalen auf ein externes Modell ausweicht, verletzt im Störfall möglicherweise genau die Regel, wegen der das lokale Modell betrieben wird — und zwar unbemerkt. Für schützenswerte Anfragen lautet die richtige Reaktion auf einen Ausfall: ablehnen, nicht ausweichen.

INTERVIEWFRAGE

Das Gateway ist ein Single Point of Failure. Wie gehen Sie damit um?

Gut ist: mehrere Repliken.

Senior ist die Analyse nach Abhängigkeiten: Der Proxy selbst ist zustandslos und leicht zu vervielfachen. Kritisch sind die Datenbank — ohne sie keine Schlüsselprüfung und damit Totalausfall, obwohl alle Modelle laufen — und Redis, ohne den Kontingente nicht mehr cluster-weit greifen. Die Datenbank gehört deshalb in dieselbe Verfügbarkeitsklasse wie die Plattform. Wer ergänzt, dass das Latenzbudget des Gateways bei wenigen Millisekunden liegt und damit kein Problem darstellt, hat die Bedenken vollständig eingeordnet.

INTERVIEWFRAGE

Sollen Prompts protokolliert werden?

Schwach ist ein einfaches Ja oder Nein.

Senior ist die Abstufung: Kennzahlen — Zeitpunkt, Team, Modell, Token, Kosten, Status — genügen für Abrechnung, Kapazitätsplanung und Betrieb vollständig. Inhalte werden meist gewünscht, um Antwortqualität zu untersuchen; das ist ein eigener Zweck mit eigener Rechtsgrundlage, eigener Frist und eigenem Zugriffsschutz und gehört nicht ins Betriebsprotokoll. Wer ergänzt, dass die Einstellung nach der Inbetriebnahme mit einer Testanfrage überprüft gehört, denkt an die Abnahme.

11.17 Zusammenfassung

- Das Gateway ist die einzige Stelle, an der Identität, Inhalt, Kosten und Zielmodell gleichzeitig bekannt sind. Governance kann deshalb nur dort stattfinden.
- Der Proxy ist zustandslos; der Zustand liegt in Datenbank und Cache. Diese beiden bestimmen die Verfügbarkeit der gesamten Plattform.
- Mehrere Einträge mit demselben Namen bilden eine Gruppe — das Gateway übernimmt damit Lastverteilung und Ausfallerkennung mit Kenntnis von Fehlerraten.
- Die Schlüsselhierarchie reicht von der Organisation bis zum Endnutzer. Das Nutzerfeld ermöglicht Zuordnung bis auf die Person und gehört in die Schnittstellenbeschreibung.
- Ein Kontingent ist die bessere Zusicherung als eine eigene GPU: feiner, sofort änderbar, nachweisbar — und ohne Hardwareverschwendung.
- Fallbacks müssen innerhalb derselben Datenklasse bleiben. Für schützenswerte Anfragen lautet die richtige Reaktion auf einen Ausfall: ablehnen.
- Für den Betrieb genügen Kennzahlen ohne Prompt-Inhalte. Inhaltsauswertung ist ein eigener Zweck mit eigener Grundlage.
- Exaktes Caching ist sicher, semantisches Caching kann fachlich falsche Antworten liefern und bei Personenbezug fremde Antworten.
- Ohne Datenbank keine Schlüsselprüfung und damit Totalausfall — die Datenbank gehört in dieselbe Verfügbarkeitsklasse wie die Plattform.

Quellen und Weiterlesen

- LiteLLM: *Proxy Documentation — Configuration*. Aufbau von `model_list`, `router_settings` und `general_settings`.
- LiteLLM: *Virtual Keys, Teams and Budgets*. Schlüsselhierarchie, Kontingente und Verbrauchsverfolgung.
- LiteLLM: *Routing, Fallbacks and Retries*. Verteilungsstrategien und Ausweichverhalten.
- LiteLLM: *Logging and Observability*. Rückmeldungen an Prometheus, OpenTelemetry und externe Ziele — einschließlich der Einstellungen zur Inhaltsunterdrückung.

Identity, Autorisierung und Secrets

ZIEL

SETZT VORAUS

DANACH KANNST DU

Klären, wer auf die Plattform zugreifen darf, woran das geprüft wird – und wie die Zugangsdaten dorthin gelangen, ohne dass ein Mensch sie je sieht.

Kapitel 11 – ein laufendes Gateway. OIDC-Grundlagen und Kubernetes-RBAC werden vorausgesetzt.

Nutzer- und Maschinenzugänge über OIDC einrichten, Ansprüche aus dem Token auf Teams und Kontingente abbilden, Provider-Schlüssel aus einem Secret-Speicher beziehen und ohne Ausfall rotieren.

GESCHRIEBEN GEGEN

Keycloak 26.x · OpenBao 2.x · LiteLLM 1.6x · External Secrets 0.10.x · Stand September 2026

Kapitel 11 hat zweimal auf dieses Kapitel verwiesen: Schlüssel gehören in den Secret-Speicher, nicht in eine Nachricht – und erst wenn die Anbieterschlüssel ausschließlich im Gateway liegen, ist Durchsetzung möglich. Beides wird hier eingelöst. Was hier **nicht** erklärt wird, sind OIDC-Grundlagen und Kubernetes-RBAC. Es geht um ihre Anwendung auf eine KI-Plattform – und um die Stellen, an denen sie sich anders verhält als bei gewöhnlichen Diensten.

12.1 Drei Fragen, drei Mechanismen

Frage	Mechanismus	Auf dieser Plattform
Wer bist du?	Authentifizierung	OIDC über Keycloak – Menschen und Maschinen
Was darfst du?	Autorisierung	Ansprüche aus dem Token, abgebildet auf Team, Kontingent und Modell-Allowlist
Womit greifst du zu?	Secret-Verwaltung	OpenBao – Provider-Schlüssel, Datenbankzugänge, Gateway-Schlüssel

Die dritte Zeile ist die, die bei KI-Plattformen besonders wiegt. Ein Provider-Schlüssel ist unmittelbar in Geld konvertierbar – Kapitel 1 hat das als Unterschied zu gewöhnlichen Zugangsdaten benannt. Wer ihn hat, kann auf Kosten der Organisation beliebig viele Anfragen stellen, ohne Kontingent und ohne Zuordnung.

12.1.1 Zwei Arten von Aufrufern

MERKE

Eine KI-Plattform hat zwei grundverschiedene Nutzergruppen, und sie brauchen verschiedene Verfahren:

Menschen — Entwickler in einer Oberfläche, Fachbereiche in einem Chat-Werkzeug. Sie melden sich interaktiv an, ihre Sitzung ist kurzlebig, und ihre Identität ist im Verzeichnisdienst gepflegt.

Maschinen — Anwendungen, Aufträge, Automatisierungen. Sie haben keinen Browser, ihre Identität stammt aus der Laufzeitumgebung, und sie laufen unbeaufsichtigt.

Die häufigste Fehlkonstruktion ist, für Anwendungen einen persönlichen Zugang zu verwenden — der Zugang eines Mitarbeiters, der irgendwann das Unternehmen verlässt.

12.2 Keycloak: die beiden Wege

12.2.1 Für Menschen

Der übliche Weg mit Weiterleitung zum Anmeldedialog und Rückgabe eines Codes, der gegen Token getauscht wird. Für die Plattform ist daran nur eines wichtig: Was im Token steht.

```
{
  "sub": "8f3c...",
  "preferred_username": "m.mueller",
  "email": "m.mueller@example.com",
  "groups": ["/abteilungen/recht"],
  "realm_access": {"roles": ["ai-nutzer"]},
  "ai_team": "team-recht",
  "ai_datenklasse": "intern",
  "exp": 1756...
}
```

Die letzten beiden Felder sind nicht standardmäßig vorhanden — sie werden über Abbildungsregeln aus Gruppenzugehörigkeiten erzeugt. Genau darin liegt die Plattformarbeit: aus dem, was der Verzeichnisdienst ohnehin pflegt, die Angaben zu gewinnen, die das Gateway braucht.

MERKE

Die Gruppenzugehörigkeit im Verzeichnisdienst ist die **Quelle der Wahrheit** — nicht eine Liste im Gateway. Wechselt jemand die Abteilung, ändert sich sein Team beim nächsten Token automatisch. Eine gepflegte Zuordnungstabelle im Gateway wäre eine zweite Wahrheit, die auseinanderläuft.

12.2.2 Für Maschinen

Anwendungen holen sich ihr Token direkt, mit einer Kennung und einem Geheimnis:


```
curl -s "$KC/realms/plattform/protocol/openid-connect/token" \
  -d grant_type=client_credentials \
  -d client_id=vertragsassistent \
  -d client_secret="$CLIENT_SECRET" \
  | jq -r .access_token
```

Das verschiebt das Problem allerdings nur: Woher kommt `CLIENT_SECRET`? Die Antwort steht in Abschnitt 12.5 – und die bessere Antwort in Abschnitt 12.4.

12.3 Ansprüche im Gateway auswerten

12.3.1 Zwei Verfahren

Verfahren	Arbeitsweise	Einordnung
Virtual Keys	Das Gateway vergibt eigene Schlüssel – Kapitel 11	Einfach, unabhängig vom Verzeichnisdienst. Rotation muss organisiert werden
OIDC-Token	Die Anwendung schickt ein Token vom Verzeichnisdienst; das Gateway prüft die Signatur und liest Ansprüche	Kein eigener Schlüssel nötig. Team und Rechte kommen aus dem Verzeichnisdienst



Token-Prüfung im Gateway: Die Signatur wird gegen den öffentlichen Schlüssel geprüft.

```
general_settings:
  enable_jwt_auth: true
  litellm_jwtauth:
    team_id_jwt_field: "ai_team"
    user_id_jwt_field: "sub"
    admin_jwt_scope: "ai-admin"
    public_key_ttl: 3600
```

MERKE

Der letzte Punkt im Diagramm ist betrieblich wichtig: Die Prüfung erfolgt lokal gegen zwischengespeicherte öffentliche Schlüssel. Das Gateway ist damit **nicht** bei jeder Anfrage von Keycloak abhängig – ein Keycloak-Ausfall unterbricht nur die Ausgabe **neuer** Token, nicht den laufenden Betrieb.

Das ist ein deutlicher Unterschied zur Datenbank aus Kapitel 11, ohne die gar nichts geht. Wer Verfügbarkeitsklassen festlegt, sollte den Unterschied kennen.

12.3.2 Wann welches Verfahren

Option	Geeignet, wenn	Ungeeignet, wenn
Virtual Keys	Anwendungen außerhalb des Clusters, Werkzeuge von Drittanbietern, schneller Einstieg. Auch: wenn feingranulare Budgets je Anwendung gebraucht werden	Wenn Rechte sich häufig ändern – dann läuft die Zuordnung im Gateway der Realität hinterher
OIDC-Token	Menschen und Anwendungen, deren Rechte aus dem Verzeichnisdienst kommen. Kein Geheimnis, das rotiert werden muss	Wenn kein Verzeichnisdienst verfügbar ist oder die Anwendung kein OIDC spricht

In der Praxis läuft beides nebeneinander: Menschen über OIDC, Anwendungen im Cluster über Workload-Identität, externe Werkzeuge über Virtual Keys mit begrenzter Gültigkeit.

12.4 Maschinenidentität ohne Geheimnis

Der beste Weg mit einem Geheimnis ist der ohne. In Kubernetes gibt es ihn.

12.4.1 Projizierte Dienstkonto-Token

Ein Pod kann sich ein kurzlebiges, an eine Zielgruppe gebundenes Token ausstellen lassen, das das Kubelet automatisch erneuert:

```
volumes:
- name: plattform-token
  projected:
    sources:
    - serviceAccountToken:
        path: token
        audience: ai-plattform
        expirationSeconds: 3600
```

Eigenschaft	Bedeutung
Kurzlebig	Eine Stunde; wird automatisch erneuert
Zielgruppengebunden	Nur für den benannten Empfänger gültig – ein gestohlenes Token nützt anderswo nichts
An den Pod gebunden	Endet mit dem Pod
Kein Geheimnis im Manifest	Nichts, was rotiert oder verwahrt werden müsste

MERKE

Ein projiziertes Dienstkonto-Token ist einem statischen Geheimnis in jeder Hinsicht überlegen: kurzlebig, zielgerichtet, automatisch erneuert, nirgendwo abgelegt. Wo eine Anwendung im selben Cluster läuft, ist das der richtige Weg – und er erspart die gesamte Rotationsfrage.

Voraussetzung ist, dass das Gateway diese Token akzeptiert. Kubernetes stellt dafür einen eigenen Aussteller-Endpunkt bereit, der wie jeder andere OIDC-Aussteller eingebunden werden kann.

12.5 OpenBao

Für alles, was sich nicht auf diese Weise lösen lässt — Provider-Schlüssel, Datenbankzugänge, Zugangsdaten zu Systemen außerhalb des Clusters — braucht es einen Secret-Speicher.

12.5.1 Die Bausteine

Baustein	Aufgabe
Anmeldeverfahren	Wie sich ein Aufrufer ausweist — für uns: Kubernetes-Dienstkonten
Richtlinien	Wer auf welchen Pfad zugreifen darf
Secret-Engines	Wie Geheimnisse verwaltet werden — statisch oder dynamisch erzeugt
Versiegelung	Der Speicher startet verschlossen und muss entsiegelt werden

ACHTUNG Die Versiegelung ist ein Betriebsthema

Nach einem Neustart ist der Speicher verschlossen und liefert keine Geheimnisse — bis jemand oder etwas ihn entsiegelt. Ohne automatische Entsiegelung bedeutet ein Knotenausfall am Wochenende, dass die Plattform steht, bis ein Mensch Schlüsselteile eingibt.

Für den produktiven Betrieb gehört eine automatische Entsiegelung eingerichtet — über ein Hardware-Sicherheitsmodul oder einen Cloud-Schlüsseldienst. Das verlagert das Vertrauen, beseitigt es aber nicht: Wer den Entsiegelungsschlüssel kontrolliert, kontrolliert den Speicher.

12.5.2 Kubernetes-Anmeldung

Ein Pod weist sich mit seinem Dienstkonto-Token aus; OpenBao prüft es gegen die Kubernetes-API und gibt ein eigenes, kurzlebiges Token zurück.

```
bao auth enable kubernetes

bao write auth/kubernetes/config \
  kubernetes_host="https://kubernetes.default.svc"

bao write auth/kubernetes/role/gateway \
  bound_service_account_names=gateway \
  bound_service_account_namespaces=ai-plattform \
  policies=gateway-lesen \
  ttl=1h
```

Die Richtlinie erlaubt genau das Nötige:

```
path "kv/data/ai/provider/*" {
  capabilities = ["read"]
}
```

MERKE

Die Bindung an Dienstkonto **und** Namensraum ist der Kern: Nur ein Pod, der mit diesem Dienstkonto in diesem Namensraum läuft, erhält Zugriff. Ein Angreifer mit Cluster-Zugriff bräuchte die Berechtigung, genau dort einen Pod zu starten – was wiederum über Kubernetes-RBAC eingeschränkt ist.

Das ist der Grund, warum GPU-Knoten mit privilegierten Containern aus Kapitel 5 und 8 ein eigenes Risiko darstellen und in Kapitel 13 noch einmal auftauchen.

12.5.3 Geheimnisse in den Pod bringen


Verfahren	Arbeitsweise	Einordnung
Beiwagen-Agent	Ein Zusatzcontainer holt Geheimnisse und legt sie als Datei ab	Erneuert automatisch. Ein Container mehr je Pod
CSI-Treiber	Geheimnisse werden als Volume eingehängt	Kein Kubernetes-Secret nötig – sauber, aber ein weiterer Baustein
External Secrets	Ein Operator erzeugt aus einer Ressource ein Kubernetes-Secret	Der pragmatischste Weg. Passt zu GitOps, Anwendungen bleiben unverändert

```
apiVersion: external-secrets.io/v1beta1
kind: ExternalSecret
metadata:
  name: provider-schluessel
  namespace: ai-plattform
spec:
  refreshInterval: 1h
  secretStoreRef:
    name: openbao
    kind: SecretStore
  target:
    name: gateway-provider
  data:
    - secretKey: AZURE_KEY
      remoteRef:
        key: ai/provider/azure
        property: api_key
```

Der entscheidende Punkt: Im Git-Repository steht nur der **Verweis**, nie das Geheimnis. Das Manifest kann bedenkenlos versioniert und geprüft werden.

12.6 Der Weg eines Provider-Schlüssels

Die Frage aus Kapitel 11 – wie kommt ein Schlüssel zum Gateway, ohne dass ihn jemand verschickt – lässt sich jetzt vollständig beantworten.



Von der Beschaffung bis zum laufenden Pod, ohne Zwischenstation auf einem Laptop


MERKE

Damit ist die Frage aus Kapitel 1 beantwortet: **Wie verhindert man, dass Entwickler Produktionsschlüssel sehen?** Nicht durch Vertrauen und nicht durch eine Richtlinie, sondern dadurch, dass es keinen Weg gibt, an dem sie vorbeikommen — die Anwendungen sprechen mit dem Gateway, und nur das Gateway kennt den Anbieterschlüssel. Der Nebeneffekt ist mindestens ebenso wertvoll: Weil kein Team einen eigenen Zugang hat, kann auch keines am Gateway vorbei arbeiten. Kontrolle entsteht hier aus der Architektur, nicht aus Anweisungen.

12.7 Rotation ohne Ausfall

12.7.1 Das Grundmuster

Ein Schlüssel lässt sich nicht atomar austauschen: Zwischen „neuer Schlüssel angelegt“ und „alle Verbraucher nutzen ihn“ vergeht Zeit. Die Lösung ist eine Überlappungsphase.



Überlappende Gültigkeit statt hartem Wechsel

1. Neuen Schlüssel beim Anbieter anlegen — der alte bleibt gültig
2. In OpenBao unter demselben Pfad ablegen, neue Version
3. Warten, bis alle Verbraucher aktualisiert haben — mindestens ein Aktualisierungsintervall
4. Prüfen, dass keine Anfragen mehr mit dem alten Schlüssel laufen
5. Alten Schlüssel beim Anbieter widerrufen

ACHTUNG Schritt 4 wird gern übersprungen

Ohne Prüfung wird der alte Schlüssel widerrufen, während irgendein Pod ihn noch hält — typischerweise einer, der seit Wochen läuft und nichts neu geladen hat. Der Ausfall tritt dann nicht sofort auf, sondern beim nächsten Zugriff dieses Pods, und niemand bringt ihn mit der Rotation in Verbindung.

Die Prüfung erfolgt am besten beim Anbieter selbst, wenn dieser die Nutzung je Schlüssel ausweist — oder durch einen erzwungenen Neustart der Verbraucher vor dem Widerruf.

12.7.2 Dynamische Zugangsdaten

Für Systeme, die es unterstützen — allen voran Datenbanken — geht es besser: OpenBao erzeugt bei jeder Anfrage einen **neuen** Zugang mit begrenzter Gültigkeit.

```
bao read database/creds/gateway
# username: v-kubernetes-gateway-x7f2...
# password: Ala-...
# lease_duration: 3600
```

MERKE


Damit entfällt Rotation als Vorgang: Es gibt keinen dauerhaften Zugang, der veralten könnte. Für die Gateway-Datenbank aus Kapitel 11 ist das die richtige Betriebsart — und ein gutes Argument gegenüber der Sicherheitsabteilung.

Für Anbieterschlüssel funktioniert es nicht: Die Anbieter stellen keine Schnittstelle bereit, über die sich Schlüssel bedarfsweise erzeugen ließen. Dort bleibt es beim Überlappungsmuster.

12.8 Wer fragt eigentlich? Das Delegationsproblem

Eine Anwendung hat eine eigene Identität. Sie handelt aber im Auftrag eines Menschen – und der bestimmt, welche Daten im Spiel sind. Das ist bei KI-Plattformen keine Feinheit, sondern der Kern der Autorisierung.

12.8.1 Warum es hier besonders wiegt



Bei einem gewöhnlichen Dienst wäre das verkraftbar – die Anwendung setzt ihre eigenen Regeln durch. Bei einer KI-Plattform nicht: Ob eine Anfrage ein externes Modell erreichen darf, hängt an den **Daten**, und welche Daten eine Person berührt, hängt an ihrer Rolle. Kapitel 13 baut darauf auf.

12.8.2 Drei Wege, den Nutzer mitzuteilen

Weg	Arbeitsweise	Belastbarkeit
Feld in der Anfrage	Die Anwendung schreibt eine Kennung ins user-Feld – Kapitel 11	Ungeprüft. Die Anwendung könnte beliebiges eintragen
Token durchreichen	Die Anwendung sendet das Token des Nutzers weiter	Geprüft. Setzt voraus, dass die Anwendung im Anmeldeweg liegt
Token-Austausch	Die Anwendung tauscht das Nutzer-Token gegen ein nachgelagertes ein, das beide Identitäten trägt	Geprüft und nachvollziehbar. Aufwendiger einzurichten

MERKE

Die entscheidende Unterscheidung: **Für die Kostenzuordnung genügt ein ungeprüftes Feld. Für eine Autorisierungsentscheidung nicht.**

Wenn die Plattform anhand des Nutzers entscheidet, ob eine Anfrage das Haus verlassen darf, muss die Nutzeridentität überprüfbar sein. Ein Feld, das die Anwendung frei setzen kann, ist dafür wertlos – eine fehlerhafte oder kompromittierte Anwendung könnte jede Einschränkung umgehen, indem sie einen anderen Namen einträgt.

Praktisch bedeutet das: Das user-Feld für Abrechnung und Statistik, das Nutzer-Token für alles, was eine Entscheidung auslöst.

12.8.3 Der pragmatische Mittelweg

Nicht jede Anwendung kann ein Nutzer-Token weiterreichen — Stapelaufträge und Hintergrundprozesse haben keinen angemeldeten Nutzer. Ein tragfähiges Modell arbeitet deshalb mit zwei Stufen:

Anwendungsart	Identität	Zulässige Datenklasse
Interaktiv, Nutzer-Token	Nutzer und Anwendung	Nach der Rolle des Nutzers — feingranular
Interaktiv, nur user-Feld	Anwendung, Nutzer nur zur Zuordnung	Nach der engsten Klasse, die die Anwendung bedienen darf
Hintergrund ohne Nutzer	nur Anwendung	Fest der Anwendung zugewiesen

Die mittlere Zeile ist der Kompromiss: Wenn die Nutzeridentität nicht überprüfbar ist, gilt für alle Anfragen dieser Anwendung die strengste in Frage kommende Regel. Das ist weniger komfortabel, aber es ist sicher — und es schafft für Anwendungsteams einen sichtbaren Anreiz, das Token durchzureichen.

12.9 Nachvollziehbarkeit

Wer wann was getan hat, lässt sich nicht aus einer Quelle beantworten. Vier Systeme liefern Teilstücke, und man sollte wissen, welches welche Frage beantwortet.

Quelle	Beantwortet	Typische Aufbewahrung
Keycloak-Ereignisse	Wer hat sich wann angemeldet, welche Zugänge wurden vergeben	90 Tage
OpenBao-Prüfprotokoll	Wer hat welches Geheimnis wann gelesen	Lang — oft Jahre, Sicherheitsanforderung
Gateway-Verbrauchsprotokoll	Wer hat welches Modell wie oft genutzt, mit welchen Kosten — Kapitel 11	Nach Abrechnungszeitraum, oft 12–24 Monate
Kubernetes-Prüfprotokoll	Wer hat welche Ressource geändert	30–90 Tage

MERKE

Die zweite Zeile verdient besondere Aufmerksamkeit. Das Prüfprotokoll des Secret-Speichers ist die einzige Stelle, an der sich nachweisen lässt, dass ein Anbieterschlüssel **nicht** von Menschen gelesen wurde. Für Prüfungen und für die Aufklärung nach einem Vorfall ist das die wertvollste Aufzeichnung der gesamten Plattform — und sie fällt aus, wenn der Speicher sie nicht schreiben kann.

OpenBao verweigert im Zweifel den Dienst, wenn das Prüfprotokoll nicht schreibbar ist. Das ist beabsichtigt und will im Betrieb bedacht sein: Ein volles Dateisystem legt den Secret-Speicher lahm — und damit die Plattform.

Wichtig ist außerdem, was in diesen Protokollen **nicht** steht: Keines davon enthält Prompt-Inhalte. Die Frage „was hat jemand gefragt“ ist bewusst nicht beantwortbar, solange nicht ausdrücklich eine Inhaltsprotokollierung eingerichtet wurde — Kapitel 11.

12.10 Zugänge beenden

Der Vorgang, der am seltensten geübt und am häufigsten unvollständig ist.

Was	Maßnahme	Automatisch?
Nutzerzugang	Deaktivierung im Verzeichnisdienst — wirkt beim nächsten Token	ja
Laufende Sitzungen	Bestehende Token bleiben bis zum Ablauf gültig	nein — Ablaufzeit begrenzen
Virtual Keys der Person	Widerruf im Gateway	meist nicht
Schlüssel in Anwendungen	Rotation, falls die Person sie kannte	nein
Zugriff auf den Secret-Speicher	Richtlinienzuordnung entfernen	ja, über Gruppen

ACHTUNG Die dritte Zeile ist die Lücke

Ein Virtual Key ist an keinen Verzeichniseintrag gebunden. Er lebt weiter, wenn die Person das Unternehmen verlässt — und er funktioniert weiter, weil das Gateway ihn nicht mit dem Verzeichnisdienst abgleicht.

Zwei Gegenmaßnahmen, die zusammen wirken: Erstens die Gültigkeitsdauer aus Kapitel 11 — ein Schlüssel mit 90 Tagen Laufzeit erlischt von selbst. Zweitens eine regelmäßige Gegenüberstellung der Schlüsselinhaber mit dem Verzeichnisdienst; ein monatlicher Bericht genügt.

Der beste Weg bleibt, persönliche Schlüssel gar nicht erst zu vergeben und Menschen ausschließlich über OIDC anzubinden. Dann greift die Deaktivierung im Verzeichnisdienst automatisch.

12.11 Notfallzugang

Jede Absicherung braucht einen Weg für den Fall, dass sie im Weg steht — und der Weg muss selbst kontrolliert sein.

Anforderung	Umsetzung
Getrennter Zugang	Ein eigenes Konto, das nicht im Alltag benutzt wird
Nicht vom Verzeichnisdienst abhängig	Sonst hilft es bei dessen Ausfall nicht
Nachweisbar	Jede Nutzung erzeugt einen Alarm, nicht nur einen Protokolleintrag
Aufgeteilt	Zugangsdaten so verwahrt, dass zwei Personen nötig sind
Geübt	Ein Notfallzugang, der nie erprobt wurde, funktioniert im Ernstfall nicht

MERKE

Die dritte Zeile ist die, die den Unterschied macht: Ein Notfallzugang, dessen Nutzung nur protokolliert wird, fällt niemandem auf. Ein Notfallzugang, dessen Nutzung sofort eine Benachrichtigung auslöst, wird nicht beiläufig verwendet — und genau das ist der Zweck.

Bei OpenBao sind die Entsiegelungsschlüssel der klassische Fall: Sie gehören aufgeteilt, getrennt verwahrt und ihre Verwendung gehört gemeldet.

12.12 Ein Rechtemodell für die Plattform

Die Frage, wer was darf, betrifft nicht nur Modellzugriff, sondern auch die Verwaltung der Plattform selbst.

Rolle	Darf	Darf nicht
Plattform-Administration	Modelle bereitstellen, Runtimes pflegen, Teams anlegen, Budgets festlegen	Prompt-Inhalte einsehen – getrennter Zugang mit eigener Begründung
Team-Verantwortung	Schlüssel für das eigene Team erzeugen und widerrufen, eigenen Verbrauch einsehen, Budget innerhalb des Rahmens verteilen	Budget des Teams erhöhen, andere Teams einsehen
Entwicklung	Modelle über das Gateway nutzen, eigenen Verbrauch einsehen	Schlüssel erzeugen, fremden Verbrauch einsehen
Revision	Alle Verbrauchsdaten und Protokolle lesen, Konfiguration einsehen	Ändern – lesender Zugriff genügt
Datenschutz	Aufbewahrungsfristen prüfen, Auskunft über gespeicherte Daten erhalten	Inhalte einsehen ohne Anlass

MERKE

Die erste Zeile enthält die Trennung, die am häufigsten fehlt: **Plattformadministration bedeutet nicht Einsicht in Inhalte**. Wer Modelle betreibt, braucht Zugriff auf Konfiguration und Kennzahlen – nicht auf das, was Menschen in Prompts schreiben.

Diese Trennung technisch abzubilden ist Aufwand. Sie zu unterlassen bedeutet, dass jede Person mit Betriebszugang faktisch alle Prompts lesen kann – und das ist eine Aussage, die man gegenüber Betriebsrat und Datenschutz nicht treffen möchte.

12.13 Bestandsaufnahme: alle Geheimnisse der Plattform

Eine Übersicht, die es in jedem Plattformprojekt geben sollte und selten gibt. Sie beantwortet die Frage, die bei jeder Prüfung gestellt wird: **Welche Geheimnisse gibt es, wo liegen sie, wer darf sie lesen, und wie werden sie erneuert?**

Geheimnis	Ablage	Leser	Erneuerung
Anbieterschlüssel (OpenAI, Azure)	OpenBao	nur Gateway	Überlappung, halbjährlich
Gateway-Hauptschlüssel	OpenBao	Administration	Selten – Ereignis-getrieben
Gateway-Datenbankzugang	OpenBao, dynamisch	Gateway	automatisch je Sitzung
Virtual Keys der Teams	Gateway-Datenbank	ausstellendes Team	Ablauf nach 90 Tagen

Geheimnis	Ablage	Leser	Erneuerung
Keycloak-Client-Geheimnisse	OpenBao	jeweilige Anwendung	Überlappung, jährlich
Zugang zum Modell-Objektspeicher	OpenBao	Storage-Initializer, Ingestion	Überlappung
Registry-Zugangsdaten	OpenBao	Kubelet über Pull-Secret	jährlich
Interner Schlüssel zum Inferenz-Server	OpenBao	Gateway	Überlappung
OpenBao-Entsiegelung	Sicherheitsmodul oder Schlüssel-dienst	Notfall, aufgeteilt	nur bei Personalwechsel

MERKE

Zwei Zeilen sind bemerkenswert. Die **dritte** zeigt den Zielzustand: Ein dynamisch erzeugter Zugang muss nie rotiert werden, weil er von vornherein befristet ist. Wo immer ein System das unterstützt, ist es die richtige Betriebsart.

Die **vierte** ist die einzige, die nicht in OpenBao liegt – die Virtual Keys entstehen im Gateway und leben in dessen Datenbank. Das ist vertretbar, weil sie befristet und eng begrenzt sind, aber es bedeutet, dass die Gateway-Datenbank Geheimnisse enthält und entsprechend zu behandeln ist: verschlüsselt, gesichert, mit beschränktem Zugriff.

12.14 Vertraulichkeit auf dem Netzwerkpfad

Identität beantwortet, **wer** spricht. Auf dem Weg dorthin bleibt die Frage, ob jemand mithören oder sich dazwischenschalten kann.

Strecke	Risiko	Maßnahme
Client zum Gateway	Prompts im Klartext	TLS – am Ingress terminiert
Gateway zum Inferenz-Server	Innerhalb des Clusters oft unverschlüsselt	mTLS über ein Service Mesh oder TLS am Dienst
Gateway zum Anbieter	Verlässt das Haus	TLS, plus Egress-Kontrolle – Kapitel 13
Gateway zur Datenbank	Schlüssel und Verbrauchsdaten	TLS erzwingen
Zum Objektspeicher	Modelle	TLS; Integrität über Prüfsummen – Kapitel 3

ACHTUNG Die zweite Zeile wird regelmäßig übersehen

Zwischen Gateway und Inferenz-Server fließen die vollständigen Prompts – also genau die Inhalte, die in Kapitel 11 aus den Protokollen verbannt wurden. Innerhalb eines Clusters läuft dieser Verkehr standardmäßig unverschlüsselt.

In vielen Organisationen ist das akzeptiert, weil das Cluster-Netz als vertrauenswürdig gilt. Sobald aber Mandantentrennung gefordert ist oder das Cluster mehrere Schutzbedarfsklassen bedient, trägt diese Annahme nicht mehr. Dann ist mTLS zwischen den

Komponenten keine Zusatzhärtung, sondern Voraussetzung — und es gehört gemeinsam mit den NetworkPolicies aus Kapitel 13 geplant.

12.15 Keycloak-Konfiguration als Code

Realms, Clients, Abbildungsregeln und Rollen von Hand in einer Oberfläche zu pflegen funktioniert bis zur ersten Wiederherstellung. Danach fehlt die Hälfte, und niemand weiß, welche Einstellung absichtlich war.

Ansatz	Einordnung
Realm-Export als Datei	Einfach, aber unübersichtlich und schwer zu prüfen — ein Export enthält sehr viel Erzeugtes
Abgleichwerkzeug	Eine gepflegte Beschreibung wird gegen den Ist-Zustand abgeglichen. Gut prüfbar
Operator mit eigenen Ressourcen	Realms und Clients als Kubernetes-Ressourcen — passt am besten zu GitOps

MERKE

Für dieses Buch ist der Punkt nicht das Werkzeug, sondern die Anforderung: Die Zuordnung von Gruppen zu Ansprüchen — und damit zu Teams, Kontingenten und Datenklassen — ist eine **sicherheitsrelevante Konfiguration**. Sie gehört versioniert, geprüft und wiederherstellbar, genau wie die NetworkPolicies aus Kapitel 13.

Eine Abbildungsregel, die jemand vor einem Jahr in einer Oberfläche angelegt hat und die nirgends dokumentiert ist, entscheidet darüber, welche Daten ein Modell erreichen dürfen. Das ist keine Kleinigkeit.

Die Geheimnisse aus dieser Konfiguration — Client-Geheimnisse insbesondere — gehören dabei **nicht** ins Repository, sondern folgen dem Weg aus Abschnitt 12.6: Sie werden erzeugt, direkt in OpenBao abgelegt und von dort bezogen.

12.16 Lab: Die Kette schließen

LAB Von der Anmeldung bis zum Anbieterschlüssel

Ziel: Eine Anfrage durchläuft Keycloak, das Gateway und einen Schlüssel aus OpenBao — ohne dass ein Geheimnis in einem Manifest steht.

Voraussetzung: Keycloak und OpenBao im Cluster, Gateway aus Kapitel 11.

Schritt 1 — Client in Keycloak anlegen. Ein vertraulicher Client mit Maschinenzugang, dazu eine Abbildungsregel, die die Gruppenzugehörigkeit in den Anspruch `ai_team` schreibt.

Schritt 2 — Token holen und ansehen.

```
TOK=$(curl -s "$KC/realms/plattform/protocol/\
openid-connect/token" \
-d grant_type=client_credentials \
-d client_id=vertragsassistent \
```



```
-d client_secret="$SECRET" | jq -r .access_token)

echo "$TOK" | cut -d. -f2 | base64 -d 2>/dev/null | jq .
```

Erwartete Ausgabe: Der mittlere Teil des Tokens enthält die Ansprüche. Prüfen Sie, ob `ai_team` gesetzt ist — fehlt es, greift die Abbildungsregel nicht.

Schritt 3 – Gateway auf Token-Prüfung umstellen. Konfiguration aus Abschnitt 12.3 anwenden und neu ausrollen.

Schritt 4 – Anfrage mit Token statt Schlüssel.

```
curl -s localhost:4000/v1/chat/completions \
-H "Authorization: Bearer $TOK" \
-H 'Content-Type: application/json' \
-d '{"model": "unternehmen-chat",
  "messages": [{"role": "user", "content": "Hallo"}]}' \
| jq -r '.choices[0].message.content'
```

Erwartete Ausgabe: Eine Antwort. Das Kontingent des Teams greift, ohne dass jemals ein Gateway-Schlüssel vergeben wurde.

Schritt 5 – Ablauf prüfen. Warten Sie, bis das Token abgelaufen ist, und wiederholen Sie die Anfrage. **Erwartung:** 401. Das ist der Beweis, dass die Gültigkeit tatsächlich geprüft wird.

Schritt 6 – Anbieterschlüssel aus OpenBao.

```
bao kv put kv/ai/provider/azure api_key="$ECHTER_KEY"
kubectl apply -f externalsecret-provider.yaml
kubectl get secret gateway-provider \
-o jsonpath='{.data}' | jq 'keys'
```

Erwartete Ausgabe: Der Schlüsselname erscheint — der Wert bleibt bewusst ungeprüft. Es besteht kein Grund, ihn anzuzeigen.

Schritt 7 – Rotation üben. Neue Version in OpenBao ablegen und beobachten, wann das Kubernetes-Secret nachzieht:

```
bao kv put kv/ai/provider/azure api_key="$NEUER_KEY"
kubectl get externalsecret provider-schluesel \
-o jsonpath='{.status.refreshTime}'; echo
```

Erwartete Ausgabe: Nach spätestens einem Aktualisierungsintervall ist der neue Wert da. Genau diese Zeitspanne ist die Untergrenze der Überlappungsphase aus Abschnitt 12.7.

Ergebnis: Identität aus dem Verzeichnisdienst, Autorisierung aus Ansprüchen, Geheimnisse aus dem Speicher — und kein Geheimnis in einem versionierten Manifest.

12.17 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Gateway lehnt gültiges Token ab	Empfänger oder Aussteller stimmen nicht	Ansprüche aud und iss gegen die Konfiguration halten	Erwarteten Empfänger im Gateway korrigieren

Symptom	Ursache	Diagnose	Behebung
Anspruch <code>ai_team</code> fehlt im Token	Abbildungsregel nicht aktiv oder falschem Client zugeordnet	Token entschlüsseln und Ansprüche prüfen	Regel im Client-Scope ergänzen
Nach Keycloak-Neustart schlagen alle Anfragen fehl	Signaturschlüssel wurden neu erzeugt	Ausgabe des JWKS-Endpunkts vergleichen	Zwischenspeicher leeren; Schlüsselrotation planvoll durchführen
Pod erhält kein Geheimnis aus OpenBao	Dienstkonto oder Namensraum passen nicht zur Rolle	Prüfprotokoll von OpenBao	Bindung der Rolle korrigieren
Nach Neustart liefert OpenBao nichts	Speicher ist versiegelt	Statusabfrage	Automatische Entsiegelung einrichten
Anfragen scheitern nach der Rotation	Alter Schlüssel widerrufen, bevor alle aktualisiert hatten	Zeitpunkt der letzten Aktualisierung gegen den Widerruf	Alten Schlüssel reaktivieren, Überlappung verlängern
Anwendung nutzt weiterhin einen Anbieterschlüssel direkt	Alter Zugang existiert noch	Nutzungsstatistik beim Anbieter je Schlüssel	Schlüssel widerrufen – Kapitel 11, Reihenfolge beachten

12.18 Interviewfragen

INTERVIEWFRAGE

Wie authentifiziert sich ein Benutzer gegenüber der AI-Plattform, und wie eine Anwendung?

Gut ist die Unterscheidung: Menschen über den interaktiven Anmeldeweg, Anwendungen über Maschinenzugänge.

Senior ist der dritte Weg: Anwendungen **im Cluster** brauchen überhaupt kein Geheimnis, sondern verwenden ein projiziertes Dienstkonto-Token – kurzlebig, an eine Zielgruppe gebunden, automatisch erneuert. Damit entfällt die gesamte Rotationsfrage für diese Klasse von Aufrufern. Wer ergänzt, dass ein persönlicher Zugang für eine Anwendung die häufigste Fehlkonstruktion ist, hat auch den organisatorischen Teil gesehen.

INTERVIEWFRAGE

Wo liegen die OpenAI- oder Anthropic-Schlüssel, und wie verhindern Sie, dass Entwickler sie sehen?

Gut ist: in einem Secret-Speicher.

Senior ist der vollständige Weg: Der Schlüssel wird bei der Beschaffung direkt in OpenBao abgelegt, eine Richtlinie erlaubt nur der Gateway-Rolle den Lesezugriff, der Bezug erfolgt über ein an Dienstkonto und Namensraum gebundenes Verfahren, und im Git-Repository steht nur ein Verweis.

Der entscheidende Punkt ist aber die Architektur: Entwickler sehen den Schlüssel nicht, weil es keinen Weg gibt, an dem sie vorbeikommen — die Anwendungen sprechen ausschließlich mit dem Gateway. Kontrolle entsteht aus dem Aufbau, nicht aus einer Anweisung.

INTERVIEWFRAGE

Wie rotieren Sie Provider-Secrets ohne Ausfall?

Senior ist das Überlappungsmuster in fünf Schritten — neuen Schlüssel anlegen, im Speicher ablegen, warten bis alle Verbraucher aktualisiert haben, **prüfen** dass der alte nicht mehr benutzt wird, erst dann widerrufen — mit der Betonung auf Schritt 4, der am häufigsten übersprungen wird und dessen Ausfall zeitversetzt auftritt.

Der Zusatz, der Erfahrung zeigt: Für Datenbanken geht es besser — dynamisch erzeugte Zugänge mit begrenzter Gültigkeit machen Rotation als Vorgang überflüssig. Für Anbieterschlüssel geht das nicht, weil die Anbieter keine entsprechende Schnittstelle bereitstellen.

INTERVIEWFRAGE

Welche Rollen braucht eine AI-Plattform?

Senior nennt fünf — Plattformadministration, Team-Verantwortung, Entwicklung, Revision, Datenschutz — und betont die Trennung, die am häufigsten fehlt: Plattformadministration bedeutet **nicht** Einsicht in Prompt-Inhalte. Wer Modelle betreibt, braucht Konfiguration und Kennzahlen, nicht das, was Menschen schreiben.

Wer ergänzt, dass diese Trennung technisch aufwendig ist und ihr Fehlen bedeutet, dass jede Person mit Betriebszugang alle Prompts lesen kann, hat verstanden, warum es sich trotzdem lohnt.

INTERVIEWFRAGE

Was passiert mit Ihrer Plattform, wenn Keycloak ausfällt?

Senior ist die Differenzierung: Das Gateway prüft Token **lokal** gegen zwischengespeicherte öffentliche Schlüssel und fragt Keycloak nicht bei jeder Anfrage. Ein Ausfall verhindert deshalb nur die Ausgabe **neuer** Token — bestehende Sitzungen laufen weiter, bis sie ablaufen.

Das ist ein deutlicher Unterschied zur Gateway-Datenbank, ohne die keine Schlüsselprüfung möglich ist und damit sofort alles steht. Wer beide Komponenten richtig in Verfügbarkeitsklassen einordnet, zeigt Betriebsdenken.

12.19 Zusammenfassung

- Drei Fragen, drei Mechanismen: Authentifizierung über OIDC, Autorisierung über Ansprüche im Token, Zugangsdaten aus einem Secret-Speicher.
- Menschen und Maschinen brauchen verschiedene Verfahren. Ein persönlicher Zugang für eine Anwendung ist die häufigste Fehlkonstruktion.

- Die Gruppenzugehörigkeit im Verzeichnisdienst ist die Quelle der Wahrheit. Eine Zuordnungstabelle im Gateway wäre eine zweite, die auseinanderläuft.
- Das Gateway prüft Token lokal gegen zwischengespeicherte Schlüssel — ein Keycloak-Ausfall unterbricht nur die Ausgabe neuer Token.
- Für Anwendungen im Cluster ist ein projiziertes Dienstkonto-Token der beste Weg: kurzlebig, zielgruppengebunden, automatisch erneuert, ohne abgelegtes Geheimnis.
- OpenBao bindet Zugriff an Dienstkonto **und** Namensraum. Die Versiegelung nach einem Neustart ist ein Betriebsthema, das automatisiert gehört.
- Der Weg eines Anbieterschlüssels führt von der Beschaffung direkt in den Speicher. Genau eine Person sieht ihn, genau einmal.
- Rotation erfolgt über eine Überlappungsphase. Der geprüfte Übergang vor dem Widerruf ist der Schritt, dessen Auslassen zeitversetzt Ausfälle erzeugt.
- Für Datenbanken machen dynamisch erzeugte Zugänge Rotation überflüssig. Für Anbieterschlüssel geht das nicht.
- Plattformadministration bedeutet nicht Einsicht in Prompt-Inhalte. Diese Trennung gehört technisch abgebildet.

Quellen und Weiterlesen

- Keycloak: *Server Administration Guide* — Realms, Clients, Protokoll-Mapper und Gruppenabbildung.
- OpenID Connect Core — die Grundlage der Ansprüche und ihrer Prüfung.
- Kubernetes: *Service Account Token Volume Projection* — kurzlebige, zielgruppengebundene Token ohne abgelegtes Geheimnis.
- OpenBao: *Kubernetes Auth Method* und *KV Secrets Engine* — Anmeldung über Dienstkonten und Ablage statischer Geheimnisse.
- External Secrets Operator: *Documentation* — Abgleich zwischen Secret-Speicher und Kubernetes-Secrets in einer GitOps-Kette.

AI Security, Governance und Compliance

ZIEL

SETZT VORAUS

DANACH KANNST DU

Ein belastbares Bedrohungsmodell für eine KI-Plattform aufstellen – und ehrlich trennen, was Infrastruktur dagegen leisten kann und was nicht.
Kapitel 11 und 12 – Gateway, Identität und Secrets.
Datenklassifikation im Anfragepfad durchsetzen, Egress kontrollieren, Mandanten trennen, die Protokollierungsfrage rechtssicher entscheiden und die technischen Betreiberpflichten aus der KI-Regulierung umsetzen.

GESCHRIEBEN GEGEN
Kubernetes 1.31 · LiteLLM 1.6x · Stand September 2026

ACHTUNG Keine Rechtsberatung

Dieses Kapitel behandelt die **technische** Umsetzung von Anforderungen, die aus Datenschutz und KI-Regulierung folgen. Die Bewertung, welche Pflichten für eine konkrete Organisation und einen konkreten Anwendungsfall gelten, ist eine juristische Frage und gehört zur Rechtsabteilung oder zum Datenschutzbeauftragten.
Die Rechtslage entwickelt sich fort. Prüfen Sie sie zum Zeitpunkt der Umsetzung – nicht gegen dieses Buch.

13.1 Das Bedrohungsmodell

13.1.1 Was hier anders ist

Kapitel 1 hat es als fünfte Bruchstelle benannt: Bei einer KI-Plattform ist der **Inhalt** einer Anfrage der Compliance-Gegenstand. Daraus folgen Bedrohungen, die es bei gewöhnlichen Plattformen so nicht gibt.

Bedrohung	Was passieren kann	Was Infrastruktur leisten kann
Datenabfluss über Prompts	Vertrauliche Inhalte erreichen ein externes Modell	Viel – Klassifikation, Allowlist, Egress-Kontrolle
Prompt Injection	Eingeschleuste Anweisungen verändern das Verhalten	Wenig – aber die Schadensreichweite lässt sich begrenzen
Übermäßige Handlungsvollmacht	Ein Modell mit Werkzeugzugriff führt schädliche Aktionen aus	Viel – Rechte der Werkzeuge, Bestätigungspflicht
Preisgabe im Ausgabe-pfad	Das Modell gibt Systemprompt oder fremde Daten aus	Mittel – Ausgabeprüfung, Mandamententrennung

Bedrohung	Was passieren kann	Was Infrastruktur leisten kann
Herkunft von Modellen	Manipuliertes Modell auf dem GPU-Knoten	Viel – Kapitel 3: Safetensors, Spiegelung, Prüfsummen
Unbegrenzter Verbrauch	Kostenexplosion, Verdrängung anderer Nutzer	Viel – Kontingente und Obergrenzen aus Kapitel 11
Vergiftung der Wissensbasis	Manipulierte Dokumente beeinflussen RAG-Antworten	Mittel – Quellenkontrolle bei der Ingestion, Kapitel 15

MERKE

Die zweite Zeile ist die unbequeme. **Prompt Injection lässt sich mit Infrastrukturmitteln nicht lösen** – weil ein Sprachmodell nicht zwischen Anweisung und Inhalt unterscheidet. Jede Filterung ist ein Wettlauf, den der Angreifer gewinnen kann, weil natürliche Sprache unbegrenzt viele Umschreibungen erlaubt.


Was Infrastruktur leisten kann, ist die **Schadensreichweite** zu begrenzen: Was kann ein erfolgreich manipuliertes Modell überhaupt anrichten? Diese Frage ist beantwortbar – und sie ist die eigentliche Sicherheitsfrage einer KI-Plattform.

13.2 Prompt Injection und Handlungsvollmacht

13.2.1 Zwei Formen

Form	Herkunft	Erkennbarkeit
Direkt	Der Nutzer selbst schreibt die manipulierende Anweisung	Der Nutzer greift sein eigenes Konto an – meist begrenzt schädlich
Indirekt	Die Anweisung steckt in Inhalten, die das Modell verarbeitet – Dokumente, Webseiten, E-Mails	Der gefährliche Fall – der Nutzer weiß nichts davon

13.2.2 Warum der zweite Fall gefährlich ist



Indirekte Injektion: die Anweisung kommt aus dem verarbeiteten Inhalt.

MERKE

Ohne Werkzeugzugriff endet der Angriff mit einer merkwürdigen Antwort – ärgerlich, aber begrenzt. **Mit** Werkzeugzugriff wird daraus eine Handlung im Namen des Nutzers, mit dessen Rechten.

Die Gefahr entsteht also nicht aus dem Modell, sondern aus der Kombination: fremde Inhalte im Kontext, plus Werkzeuge mit Wirkung, plus die Rechte des Nutzers. Wer eine dieser drei Zutaten entfernt, entschärft den Angriff.

13.2.3 Was Infrastruktur beitragen kann

Maßnahme	Wirkung
Werkzeuge nach dem Grundsatz der geringsten Rechte	Ein Werkzeug, das nur lesen kann, kann nichts versenden. Die wirksamste Maßnahme überhaupt
Trennung lesender und schreibender Werkzeuge	Anwendungen, die fremde Inhalte verarbeiten, bekommen keine schreibenden Werkzeuge
Bestätigung durch den Menschen	Wirkungsvolle Aktionen erfordern eine ausdrückliche Freigabe
Egress-Kontrolle	Selbst wenn das Modell Daten senden will – es erreicht kein fremdes Ziel
Kontingente	Begrenzen den Schaden eines automatisierten Missbrauchs – Kapitel 11
Protokollierung der Werkzeugaufrufe	Macht den Vorfall im Nachhinein rekonstruierbar

ACHTUNG Was Filterung nicht leistet

Eingabefilter, die nach Formulierungen wie „ignoriere vorige Anweisungen“ suchen, erzeugen ein Sicherheitsgefühl ohne Sicherheit. Sie erkennen bekannte Muster und scheitern an Umschreibungen, anderen Sprachen, Kodierungen und Verschleierungen.

Sie sind nicht wertlos – sie halten Gelegenheitsversuche ab und liefern Erkennungssignale. Aber sie dürfen keine Maßnahme ersetzen, die tatsächlich trägt. Wer Werkzeugrechte mit dem Argument großzügig vergibt, dass ein Filter davor steht, hat die Reihenfolge vertauscht.

13.3 Datenklassifikation**13.3.1 Klassen definieren**

Die Klassifikation ist keine technische, sondern eine organisatorische Festlegung. Die Plattform setzt sie durch.

Klasse	Inhalte	Zulässige Ziele
Öffentlich	Bereits veröffentlichte Informationen	alle Modelle
Intern	Allgemeine Unternehmensinformationen, unkritischer Code	Externe Anbieter mit Verarbeitungsvertrag
Vertraulich	Kundendaten, Verträge, Personalvorgänge, wettbewerbsrelevanter Code	Nur lokale Modelle

Klasse	Inhalte	Zulässige Ziele
Streng vertraulich	Gesundheitsdaten, laufende Verfahren, Sicherheitsdaten	Nur lokale Modelle, zusätzlich eingeschränkter Nutzerkreis

13.3.2 Wie eine Anfrage ihre Klasse bekommt

Quelle	Arbeitsweise	Belastbarkeit
Anwendung	Die Anwendung ist einer Klasse fest zugeordnet	Der Regelfall. Einfach, vorhersagbar, prüfbar
Nutzerrolle	Aus dem Anspruch im Token – Kapitel 12	Gut, wenn die Nutzeridentität überprüfbar ist
Inhaltsprüfung	Der Prompt wird untersucht	Zusätzliche Absicherung, nicht alleinige Grundlage

MERKE

Die erste Zeile ist die tragfähigste und wird oft übersehen: Eine Anwendung, die Personalvorgänge verarbeitet, ist **immer** vertraulich – unabhängig davon, was im einzelnen Prompt steht. Diese Zuordnung ist einmal zu treffen, leicht zu prüfen und nicht zu umgehen.

Inhaltsprüfung ist eine sinnvolle Ergänzung, um Fehler zu fangen – etwa wenn jemand eine Kundennummer in einen als intern eingestuften Assistenten kopiert. Sie taugt aber nicht als alleinige Grundlage, weil sie fehlbar ist und die Fehler beide Richtungen haben.

13.4 Erkennung personenbezogener Daten

13.4.1 Die Verfahren

Verfahren	Erkennt	Latenz	Schwäche
Mustererkennung	Formatierte Daten: IBAN, Kreditkarten, Ausweisnummern	< 5 ms	Erkennt nur, was ein festes Format hat
Namensmodell	Namen, Orte, Organisationen im Text	20–80 ms	Fehlerbehaftet, sprachabhängig
Sprachmodell	Kontextabhängige Zusammenhänge	100 ms bis Sekunden	Zu langsam für den Anfragepfad, teuer

MERKE

Die Latenzspalte entscheidet über den Einsatzort. Mustererkennung kostet nichts und gehört in den Anfragepfad. Ein Namensmodell ist grenzwertig – 80 Millisekunden gegen eine TTFT von 300 sind ein Viertel mehr Wartezeit. Ein Sprachmodell als Prüfer gehört **nicht** in den synchronen Pfad.

Der praktikable Aufbau ist zweistufig: schnelle Prüfung synchron mit Blockierwirkung, gründliche Prüfung asynchron mit Alarmwirkung. Die zweite verhindert nichts, aber sie deckt auf – und das ist mehr, als eine gar nicht stattfindende Prüfung leistet.

13.4.2 Maskieren oder ablehnen

Option	Geeignet, wenn	Ungeeignet, wenn
Ablehnen	Bei streng vertraulichen Klassen und bei eindeutigen Treffern. Der Nutzer erfährt, warum, und kann die Anfrage anpassen	Bei hoher Fehlalarmrate – dann wird die Plattform als unbrauchbar empfunden und umgangen
Maskieren	Wenn die Anfrage auch ohne die Daten sinnvoll ist – etwa eine Formulierungshilfe	Wenn die Daten für die Aufgabe gebraucht werden. Dann liefert das Modell Unsinn, und niemand versteht warum
Umleiten	Meist die beste Antwort: Die Anfrage geht an ein lokales Modell statt an einen externen Anbieter	Wenn kein lokales Modell verfügbar ist


ACHTUNG Fehlalarme treiben Nutzer zurück in die Schatten-KI

Eine Erkennung, die zu oft grundlos blockiert, erzeugt genau das Verhalten, gegen das die Plattform gebaut wurde: Menschen weichen auf private Zugänge aus – Kapitel 1.

Deshalb ist Umleiten dem Ablehnen fast immer vorzuziehen. Der Nutzer bekommt eine Antwort, die Daten bleiben im Haus, und niemand hat einen Grund, einen anderen Weg zu suchen. Das ist Sicherheit, die funktioniert, weil sie nicht im Weg steht.

13.5 Modell-Allowlist nach Datenklasse

Die Mechanik steht seit Kapitel 11 bereit. Hier wird sie zusammengesetzt.



Die Entscheidungskette im Gateway

Umgesetzt wird das über die Schlüssel- beziehungsweise Team-Allowlist aus Kapitel 11:

```
curl -s http://gateway/team/update -H "$M" \
-H 'Content-Type: application/json' \
-d '{"team_id":"team-personal",
    "models":["lokal-chat","lokal-lang"],
    "metadata":{"datenklasse":"vertraulich"}}'
```

MERKE

Der entscheidende Punkt ist die **Reihenfolge**: Die Klasse wird bestimmt, bevor das Ziel gewählt wird. Damit ist die Regel „diese Daten verlassen das Haus nicht“ durchgesetzt und nicht nur protokolliert — die Aussage aus Kapitel 11.

Eine Fallback-Kette darf diese Reihenfolge nicht unterlaufen. Kapitel 11 hat davor gewarnt: Ein Ausweichen von einem lokalen auf ein externes Modell während einer Störung verletzt genau die Regel, wegen der das lokale Modell existiert.

13.6 Egress-Kontrolle

13.6.1 Warum sie hier besonders zählt

Bei gewöhnlichen Anwendungen ist ausgehender Verkehr ein Nebenthema. Bei einer KI-Plattform ist er der Weg, auf dem Daten das Haus verlassen — und die Modellanbieter sind erreichbare Ziele im Internet.

```
apiVersion: networking.k8s.io/v1
kind: NetworkPolicy
metadata:
  name: inferenz-kein-egress
  namespace: serving
spec:
  podSelector:
    matchLabels: {komponente: inferenz}
  policyTypes: [Egress]
  egress:
    # Nur DNS
    - to:
        - namespaceSelector:
            matchLabels: {kubernetes.io/metadata.name: kube-system}
    ports:
        - {protocol: UDP, port: 53}
    # Nur der Objektspeicher fuer Modelle
    - to:
        - podSelector:
            matchLabels: {app: minio}
    ports:
        - {protocol: TCP, port: 9000}
```

MERKE

Der Inferenz-Server braucht **keinen** Internetzugang. Er lädt Modelle aus dem eigenen Objektspeicher — Kapitel 3 und 8 — und beantwortet Anfragen. Eine Egress-Regel, die

ihm alles außer DNS und Objektspeicher verbietet, kostet nichts und schließt eine ganze Angriffsklasse aus.

Das Gateway dagegen **muss** nach außen. Genau deshalb ist es die einzige Komponente, deren ausgehender Verkehr sorgfältig eingegrenzt gehört.

13.6.2 Der Egress-Pfad des Gateways

Maßnahme	Wirkung
NetworkPolicy mit Zielbeschränkung	Nur definierte Ziele erreichbar — in Kubernetes allerdings meist nur auf IP-Ebene
Ausgehender Proxy mit Namensliste	Erlaubt Beschränkung auf Domännennamen, was bei Anbietern mit wechselnden Adressen der praktikable Weg ist
Protokollierung am Proxy	Unabhängiger Nachweis, welche Ziele tatsächlich kontaktiert wurden
Verbot direkter Zugriffe	Kein anderer Pod darf Anbieter erreichen — sonst ist das Gateway umgehbar

Die letzte Zeile ist die, die den Aufbau trägt: Wenn beliebige Pods externe Modelle erreichen können, ist die gesamte Governance eine Empfehlung. Ein grundsätzliches Egress-Verbot mit gezielten Ausnahmen ist deshalb die Voraussetzung, nicht die Kür.

13.7 Mandantentrennung

Wie weit Mandanten getrennt werden, ist eine Abwägung zwischen Zusicherung und Kosten.

Ebene	Trennung durch	Verbleibendes Risiko
Kontingent im Gateway	Budgets, Ratenbegrenzung, Allowlist	Gemeinsames Modell — Prefix-Cache und Batch geteilt
Eigener Namensraum	RBAC, NetworkPolicies, Kontingente	Gemeinsame Knoten und GPUs
Eigene Knoten	Physische Trennung der Rechenknoten	Gemeinsame Steuerungsebene
Eigener Cluster	Vollständig getrennte Umgebung	Nur noch gemeinsame Netzinfrastruktur

MERKE

Die erste Zeile verdient eine ehrliche Betrachtung: Wenn zwei Mandanten dasselbe Modell nutzen, teilen sie sich den Prefix-Cache und die Batches. Eine Anfrage von Mandant A und eine von Mandant B werden im selben Rechenschritt verarbeitet.

Ein Datenabfluss zwischen ihnen ist dadurch nicht zu erwarten — die Sequenzen sind getrennt, und die Blöcke werden nur bei identischem Inhalt geteilt. Aber die Aussage „vollständig getrennt“ wäre falsch, und in einer Prüfung sollte man das offen sagen können. Wo echte Trennung gefordert ist, führt der Weg über getrennte Instanzen — und damit zurück zu Kapitel 6.

13.8 Risiken der Wissensbasis

RAG-Systeme bringen eigene Angriffsflächen mit. Kapitel 15 behandelt den Betrieb; hier die sicherheitsrelevanten Punkte, die beim Entwurf entschieden werden müssen.

Risiko	Wie es entsteht	Maßnahme
Vergiftete Dokumente	Ein Dokument mit eingeschleusten Anweisungen gelangt in den Bestand und wird später in den Kontext geladen	Quellen kontrollieren, Ingestion nur aus freigegebenen Ablagen
Berechtigungsübergreif	Der Bestand enthält Dokumente, die der fragende Nutzer nicht sehen dürfte	Berechtigungen bei der Suche durchsetzen , nicht erst bei der Anzeige
Mandantenvermischung	Ein gemeinsamer Index liefert Treffer aus fremden Beständen	Trennung im Index; Filterung als Pflicht, nicht als Option
Löschlücke	Ein gelöscht Dokument bleibt als Einbettung im Index	Löschpfad über alle abgeleiteten Bestände — Abschnitt 13.9

MERKE

Die zweite Zeile ist der häufigste und folgenreichste Fehler. Wird ein Dokumentenbestand ohne Berechtigungsfilter eingebettet, kann jeder Nutzer über eine geschickte Frage Inhalte erfahren, für die er keine Freigabe hat — ohne dass irgendein Zugriffssystem verletzt wurde. Das Modell fasst brav zusammen, was ihm vorgelegt wurde.

Die Berechtigung muss deshalb **bei der Suche** wirken: Der Abruf liefert nur Abschnitte aus Dokumenten, die der fragende Nutzer sehen darf. Alles andere ist zu spät.

13.9 Falsche Antworten als Betriebsrisiko

Nicht jedes Risiko ist ein Angriff. Ein Modell kann überzeugend formulierte, sachlich falsche Antworten geben — und in einem Geschäftsprozess ist das ein realer Schaden.

Maßnahme	Wirkung und Grenze
Antworten belegen	Quellenangaben aus dem Abruf — der Nutzer kann prüfen. Wirkt nur, wenn er es auch tut
Auf den Bestand einschränken	Anweisung, nur aus den gelieferten Dokumenten zu antworten. Verringert Erfindungen, verhindert sie nicht
Ausgabe kennzeichnen	Der Nutzer weiß, dass eine KI geantwortet hat — Betreiberpflicht aus Abschnitt 13.10
Menschliche Freigabe	Bei folgenreichen Entscheidungen. Die einzige Maßnahme, die zuverlässig trägt
Anwendungsfall begrenzen	Kein automatisiertes Handeln dort, wo Fehler teuer sind

MERKE

Aus Plattformsicht ist die wichtigste Erkenntnis: Antwortqualität lässt sich nicht technisch garantieren. Was die Plattform leisten kann, ist die **Einordnung** — durch Kennzeichnung, Quellenangaben und die Durchsetzung menschlicher Freigaben, wo es darauf ankommt.

Der Rest ist eine Frage des Anwendungsfalls und gehört zur Freigabeentscheidung, nicht zur Infrastruktur. Genau deshalb braucht es einen Freigabeprozess.

13.10 Wer entscheidet was

Eine Plattform ohne Freigabeprozess führt dazu, dass jede Erweiterung entweder unbemerkt geschieht oder in einer Endlosdiskussion endet. Die folgende Aufteilung hat sich bewährt.

Vorgang	Entscheidet	Beteiligt
Neues Modell aufnehmen	Plattformteam	Datenschutz – wegen Anbieter und Vertragslage
Datenklasse eines Modells festlegen	Datenschutz und Sicherheit	Plattformteam als Umsetzer
Neue Anwendung anbinden	Plattformteam	Fachbereich, Datenschutz bei personenbezogenen Daten
Datenklasse einer Anwendung	Fachbereich, geprüft von Datenschutz	Plattformteam setzt um
Budget erhöhen	Kostenstellenverantwortung	Plattformteam meldet Verbrauch
Werkzeug mit Schreibwirkung freigeben	Sicherheit	Fachbereich begründet, Plattformteam setzt Rechte
Inhaltsprotokollierung aktivieren	Datenschutz	Betriebsrat, sofern Beschäftigten Daten betroffen

MERKE

Zwei Zeilen sind es, an denen ein Plattformteam **nicht** allein entscheiden sollte: die Datenklasse eines Modells und die Freigabe schreibender Werkzeuge. Beide bestimmen die Schadensreichweite, und beide sind keine technischen Fragen.

Umgekehrt sollte das Plattformteam bei allem anderen entscheidungsfähig bleiben. Ein Prozess, der für jede Modellaufnahme ein Gremium einberuft, wird umgangen – und dann landet man wieder bei Kapitel 1.

Praktisch lässt sich das schlank halten: eine Aufnahmeliste je Modell mit Anbieter, Vertragslage, zulässiger Datenklasse und Freigabedatum. Sie liegt im GitOps-Repository neben der Gateway-Konfiguration, und eine Änderung durchläuft dieselbe Prüfung wie jede andere Änderung – Kapitel 16.

13.11 Protokollierung, Aufbewahrung und Auskunft

13.11.1 Die Entscheidung schriftlich fassen

Kapitel 11 hat die technische Seite behandelt. Hier die Fragen, die vor der Inbetriebnahme beantwortet und dokumentiert sein müssen:

Frage	Warum sie gestellt werden muss
Welche Daten werden gespeichert?	Grundlage jeder weiteren Antwort. Kennzahlen, Metadaten, Inhalte – Kapitel 11

Frage	Warum sie gestellt werden muss
Zu welchem Zweck?	Abrechnung, Betrieb und Qualitätsuntersuchung sind verschiedene Zwecke mit verschiedenen Grundlagen
Wie lange?	Je Zweck eine eigene Frist. Ohne Frist gilt faktisch „für immer“
Wer darf zugreifen?	Die Trennung aus Kapitel 12: Betrieb ist nicht Inhalts-einsicht
Wie wird gelöscht?	Muss technisch umsetzbar sein – auch aus Sicherungen
Wie wird Auskunft erteilt?	Auf Anfrage muss auffindbar sein, was zu einer Person gespeichert ist

ACHTUNG Die vorletzte Zeile ist die schwierigste

Eine Löschpflicht erstreckt sich auch auf Sicherungen und auf abgeleitete Bestände – etwa eine Vektordatenbank, in die Dokumente eingebettet wurden. Ein Löschvorgang, der die Originaldokumente entfernt und die Einbettungen stehen lässt, ist unvollständig.

Kapitel 15 behandelt das für RAG-Bestände. Es ist einer der Punkte, an denen eine KI-Plattform Anforderungen erzeugt, die vorher niemand auf dem Zettel hatte – und die im Nachhinein sehr aufwendig zu erfüllen sind. Sie gehören ins Design.

13.11.2 Externe Anbieter

Wo Daten an externe Modellanbieter gehen, kommen weitere Fragen hinzu: ob ein Verarbeitungsvertrag besteht, wo verarbeitet wird, ob Eingaben zum Training verwendet werden und wie lange der Anbieter sie vorhält.

MERKE

Für die Plattform folgt daraus eine technische Konsequenz: Die Zuordnung **Modell** → **Anbieter** → **vertragliche Grundlage** gehört gepflegt und mit der Datenklassifikation verknüpft. Ein neues Modell in der Konfiguration ist damit kein rein technischer Vorgang – es ist eine Freigabe, die eine Prüfung voraussetzt.

Praktisch bedeutet das: Der Modellkatalog aus Kapitel 11 bekommt eine Spalte für die zulässige Datenklasse, und deren Pflege ist an einen Freigabeprozess gebunden.

13.12 Betreiberpflichten aus der KI-Regulierung

Die europäische KI-Verordnung unterscheidet Rollen. Für die hier behandelte Plattform ist in der Regel die Rolle des **Betreibers** einschlägig – nicht die des Modellanbieters. Welche Pflichten konkret gelten, hängt vom Anwendungsfall ab und ist juristisch zu klären.

Technisch vorbereiten lässt sich Folgendes, unabhängig von der Einstufung:

Anforderung	Technische Umsetzung	Kapitel
Nachvollziehbarkeit der Nutzung	Verbrauchsprotokoll je Nutzer, Team und Modell	11

Anforderung	Technische Umsetzung	Kapitel
Menschliche Aufsicht	Bestätigungspflicht bei wirkungsvollen Aktionen; keine unbeaufsichtigte Automatik bei folgenreichen Entscheidungen	13
Transparenz gegenüber Nutzern	Kennzeichnung in der Oberfläche, dass eine KI antwortet	Anwendung
Aufzeichnung der Systemvorgänge	Protokolle mit definierter Frist — Kapitel 12	12
Beschreibung der eingesetzten Modelle	Gepflegter Katalog: Modell, Anbieter, Zweck, Datenklasse	11
Überwachung im Betrieb	Kennzahlen und Alarmer — Kapitel 14	14
Kompetenz der Anwender	Schulung und Nutzungshinweise — organisatorisch	–

MERKE

Bemerkenswert an dieser Tabelle ist, dass fast alles bereits gebaut wurde. Eine Plattform, die Kapitel 11 bis 14 umsetzt, erfüllt den technischen Teil der Betreiberpflichten weitgehend — weil dieselben Mechanismen gebraucht werden, die auch Kostenkontrolle und Betrieb ermöglichen.

Was fehlt, ist meist die **Dokumentation**: Der Nachweis, dass es so ist. Ein Modellkatalog mit Zweck und Datenklasse, eine beschriebene Aufbewahrung und eine Aufstellung der Kontrollen sind schnell erstellt, wenn die Technik steht — und sehr mühsam, wenn sie nachträglich rekonstruiert werden muss.

13.13 Die Ausgabe ist ungeprüfte Eingabe

Ein Punkt, der bei Sicherheitsbetrachtungen regelmäßig fehlt: Was ein Modell erzeugt, ist aus Sicht des verarbeitenden Systems **nicht vertrauenswürdiger** als eine Eingabe aus dem Internet — besonders dann, wenn der Prompt fremde Inhalte enthielt.

13.13.1 Der Abfluss über die Darstellung

Der bekannteste Fall braucht keinen Werkzeugzugriff und funktioniert allein durch das Rendern der Antwort.

- 1 Manipuliertes Dokument gelangt in den Kontext
 - 2 Modell wird angewiesen, am Ende auszugeben:
``
 - 3 Anwendung stellt die Antwort als Markdown dar
 - 4 Der BROWSER lädt das Bild
 und überträgt dabei die Daten in der Adresse
- Kein Werkzeug beteiligt.
 Kein Netzwerkzugriff der Plattform.
 Der Abfluss geschieht im Browser des Nutzers.

Datenabfluss ohne Werkzeuge: Der Browser holt das Bild und trägt die Daten mit.

MERKE

Dieser Weg ist besonders unangenehm, weil er die gesamte Egress-Kontrolle aus Abschnitt 13.6 umgeht: Nicht die Plattform sendet die Daten, sondern der Browser des Nutzers – und der darf ins Internet.

Die Gegenmaßnahme liegt deshalb nicht in der Infrastruktur, sondern in der Anwendung: Externe Bild- und Verweisziele in Modellantworten gehören unterdrückt oder auf eine Positivliste beschränkt. Das ist eine Anforderung, die das Plattformteam an Anwendungsteams weitergeben muss – sie steht in keiner Infrastrukturdokumentation.

13.13.2 Weitere Verarbeitungspfade

Verarbeitung	Risiko	Maßnahme
Als HTML dargestellt	Eingeschleustes Skript	Bereinigung wie bei jeder Nutzereingabe
Als Markdown dargestellt	Abfluss über Bilder und Verweise	Externe Ziele unterdrücken
Als Datenbankabfrage ausgeführt	Manipulierte Abfrage	Niemals direkt ausführen; Parameter binden
Als Befehl ausgeführt	Beliebige Codeausführung	Nicht tun. Wenn doch: streng eingegrenzte Umgebung
Als Dateiname verwendet	Pfadwechsel	Zeichen einschränken, Pfad auflösen und prüfen
Als Werkzeugargument	Aufruf mit fremden Werten	Schema erzwingen – Kapitel 7 – und Werte prüfen

MERKE

Die letzte Zeile verbindet zwei Kapitel: Geführtes Sampling aus Kapitel 7 stellt sicher, dass ein Werkzeugaufwurf **strukturell** gültig ist. Es stellt nicht sicher, dass die **Werte** zulässig sind. Ein Modell kann schemakonform eine Kontonummer aufrufen, die dem Nutzer nicht gehört.

Die Prüfung der Werte gehört in das Werkzeug selbst – mit den Rechten des Nutzers, nicht mit denen der Anwendung. Das ist derselbe Grundsatz wie bei jeder API, wird bei Werkzeugen für Sprachmodelle aber erstaunlich oft vergessen.

13.14 Der Systemprompt ist kein Geheimnis

Systemprompts enthalten häufig Dinge, die dort nicht hingehören: interne Bezeichnungen, Regeln, gelegentlich sogar Zugangsdaten oder Adressen interner Systeme.

ACHTUNG Systemprompts gelangen an die Oberfläche

Es gibt keine zuverlässige Methode, ein Modell daran zu hindern, seinen Systemprompt preiszugeben. Anweisungen wie „gib diese Regeln niemals aus“ wirken gegen Gelegenheitsversuche und nicht gegen gezielte.

Behandeln Sie den Systemprompt deshalb als **veröffentlichungsfähig**. Was dort nicht stehen darf: Zugangsdaten, interne Adressen, Namen von Personen, Regeln, deren Kenntnis ihre Umgehung erlaubt.

Umgekehrt gilt: Wenn eine Zugriffsbeschränkung nur im Systemprompt steht, ist sie keine Beschränkung. Sie gehört ins Werkzeug oder ins Gateway.

13.15 Herkunft und Lieferkette

Kapitel 3 hat die Frage für Modelle behandelt. Eine KI-Plattform hat allerdings drei Lieferketten, und alle drei gehören betrachtet.

Kette	Risiko	Maßnahme
Modelle	Manipulierte Gewichte, Code beim Laden	Nur <code>safetensors</code> , spiegeln, Prüfsummen — Kapitel 3
Container-Images	Manipulierte oder verwundbare Images	Eigene Registry, Signaturprüfung, Schwachstellenprüfung — Kapitel 16
Python-Abhängigkeiten	Die größte Angriffsfläche — Inferenz-Images bringen hunderte Pakete mit	Feste Versionen, Herkunftsnachweis, regelmäßige Prüfung

MERKE

Die dritte Zeile wird unterschätzt. Ein Inferenz-Image enthält typischerweise mehrere hundert Python-Pakete — und läuft nach Kapitel 8 möglicherweise mit erweiterten Rechten auf einem Knoten mit GPU-Zugriff.

Zwei Maßnahmen wiegen hier am schwersten: Images aus der eigenen Registry beziehen und regelmäßig gegen bekannte Schwachstellen prüfen — und den Inferenz-Pod so weit wie möglich einschränken, wie in Kapitel 8 beschrieben. Wo `runAsNonRoot` nicht erreichbar ist, gehört das als Restrisiko dokumentiert.

13.16 Prüfplan vor der Inbetriebnahme

Die folgende Liste eignet sich als Abnahmekriterium. Jeder Punkt ist prüfbar, nicht nur behauptbar.

Nr.	Prüfpunkt	Nachweis
1	Kein Pod erreicht externe Modellanbieter außer dem Gateway	Testabruf aus fremdem Namensraum
2	Der Inferenz-Server hat keinen Internetzugang	Testabruf aus dem Pod
3	Prompts erscheinen nicht in Logs, Metriken oder Traces	Testanfrage mit Erkennungsmerkmal, dann suchen
4	Die Modell-Allowlist greift je Team	Anfrage an unzulässiges Modell
5	Anbieterschlüssel liegen nur im Secret-Speicher	Suche im Repository und in Manifesten
6	Schlüssel haben eine Gültigkeitsdauer	Auflistung der Schlüssel mit Ablaufdatum

Nr.	Prüfpunkt	Nachweis
7	Aufbewahrungsfristen sind gesetzt und wirksam	Alter des ältesten Datensatzes je Ablage
8	Betriebszugang erlaubt keine Inhaltseinsicht	Rechteprüfung mit einem Betriebskonto
9	Werkzeuge haben minimale Rechte	Durchsicht der Werkzeugdefinitionen
10	Modellkatalog mit Zweck und Datenklasse ist gepflegt	Vorhandensein und Aktualität

Diese Liste einmal vollständig durchzugehen dauert einen halben Tag. Sie nachträglich zu erfüllen, wenn eine Prüfung sie einfordert, dauert Wochen.

13.17 Wenn etwas passiert

Ein Vorfall auf einer KI-Plattform unterscheidet sich von einem gewöhnlichen Sicherheitsvorfall in einem Punkt: Die entscheidende Frage lautet nicht nur „wer hatte Zugriff“, sondern **„welche Inhalte waren betroffen“**.

Nr.	Schritt	Womit
1	Umfang eingrenzen: Zeitraum, Team, Modell	Verbrauchsprotokoll des Gateways – Kapitel 11
2	Ziele bestimmen: Welche Anbieter wurden erreicht	Protokoll des Egress-Proxy
3	Betroffene Personen ermitteln	Nutzerfeld im Verbrauchsprotokoll
4	Inhalte beurteilen	Meist nicht möglich – und das ist beabsichtigt
5	Zugänge sperren	Schlüssel widerrufen, Team-Allowlist einschränken
6	Schlüssel rotieren	Verfahren aus Kapitel 12

MERKE

Schritt 4 ist der Punkt, an dem die Entscheidung aus Kapitel 11 spürbar wird: Wer Inhalte nicht speichert, kann im Vorfall nicht sagen, **was** konkret abgeflossen ist – nur, welche Anwendung, welcher Nutzer, welches Modell und welcher Umfang betroffen war.

Das ist ein bewusster Zielkonflikt, und er sollte vorher entschieden und dokumentiert sein. Beides ist vertretbar; unvertretbar ist, ihn erst im Vorfall zu bemerken.

In der Praxis genügt die Eingrenzung über Anwendung und Datenklasse meist: Wenn bekannt ist, dass eine als vertraulich eingestufte Anwendung betroffen war, folgt daraus die Meldepflicht – unabhängig davon, welcher Satz genau übertragen wurde.

13.18 Lab: Klassifikation und Egress durchsetzen

LAB Die Regel technisch erzwingen, nicht nur festlegen

Ziel: Belegen, dass vertrauliche Anfragen das Haus nicht verlassen können – auch dann nicht, wenn es jemand versucht.

Voraussetzung: Gateway aus Kapitel 11 mit einem lokalen und einem externen Modell.

Schritt 1 – Zwei Teams mit unterschiedlicher Klasse anlegen.

```
M="Authorization: Bearer $MASTER_KEY"
for T in "intern:extern-gross,lokal-chat" \
    "vertraulich:lokal-chat"; do
    N=${T%*:.*}; MODELLE=${T##*:}
    jq -n --arg n "team-$N" --arg m "$MODELLE" \
        '{team_alias:$n, models:($m|split(","))}' \
    | curl -s http://gateway/team/new -H "$M" \
        -H 'Content-Type: application/json' --data @-
done
```

Schritt 2 – Prüfen, dass die Allowlist greift. Mit dem Schlüssel des vertraulichen Teams das externe Modell anfordern:

```
curl -s -o /dev/null -w '%{http_code}\n' \
    http://gateway/v1/chat/completions \
    -H "Authorization: Bearer $KEY_VERTRAULICH" \
    -H 'Content-Type: application/json' \
    -d '{"model": "extern-gross",
        "messages": [{"role": "user", "content": "Test"}]}'
```

Erwartete Ausgabe: 401 oder 403. Die Anfrage erreicht den Anbieter nicht.

Schritt 3 – Egress grundsätzlich verbieten. Für den Serving-Namensraum die Regel aus Abschnitt 13.6 anwenden, dann prüfen:

```
kubectl -n serving exec deploy/chat-v1-predictor -- \
    timeout 5 curl -s -o /dev/null -w '%{http_code}\n' \
    https://api.openai.com/v1/models || echo "blockiert"
```

Erwartete Ausgabe: blockiert oder eine Zeitüberschreitung. Der Inferenz-Server hat keinen Weg nach draußen.

Schritt 4 – Die Umgehung ausschließen. Ein beliebiger Pod in einem anderen Namensraum darf ebenfalls nicht direkt zum Anbieter:

```
kubectl run test --rm -it --restart=Never \
    --image=curlimages/curl -- \
    timeout 5 curl -s -o /dev/null -w '%{http_code}\n' \
    https://api.openai.com/v1/models || echo "blockiert"
```

Erwartete Ausgabe: blockiert. Ist es das nicht, ist das Gateway umgehbar – und damit die gesamte Governance eine Empfehlung.

Schritt 5 – Umleitung statt Ablehnung. Konfigurieren Sie für das vertrauliche Team eine Zuordnung, die Anfragen an extern-gross auf lokal-chat umleitet, statt sie abzulehnen. Prüfen Sie, dass die Antwort kommt und das Feld `model` das lokale Modell nennt.

Erwartung: Der Nutzer bekommt eine Antwort. Die Daten bleiben im Haus. Niemand hat einen Grund, einen anderen Weg zu suchen – die Aussage aus Abschnitt 13.4.

Ergebnis: Die Datenklassifikation ist durchgesetzt, nicht empfohlen – und zwar an zwei Stellen unabhängig voneinander: im Gateway und im Netzwerk.

13.19 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Anfragen werden unerwartet abgelehnt	Allowlist des Teams zu eng oder Klasse falsch zugeordnet	Antwortkörper des Gateways; Team-Konfiguration abfragen	Zuordnung korrigieren; Umleitung statt Ablehnung erwägen
Erkennung schlägt bei harmlosen Texten an	Muster zu weit gefasst – etwa Zahlenfolgen als Kartennummern	Treffer stichprobenartig prüfen	Muster verschärfen; Prüfsummen verlangen, wo möglich
Latenz nach Aktivierung der Prüfung deutlich höher	Aufwendiges Verfahren im synchronen Pfad	TTFT vor und nach der Aktivierung vergleichen	Zweistufig aufbauen: schnell synchron, gründlich asynchron
Inferenz-Pod startet nicht mehr nach Egress-Regel	Modellbezug oder DNS blockiert	Log des Storage-Initializers	Objektspeicher und DNS ausdrücklich erlauben
Ein Pod erreicht weiterhin externe Anbieter	Kein grundsätzliches Egress-Verbot, nur gezielte Regeln	Testabruf aus einem beliebigen Namensraum	Grundregel „alles verbieten“ einführen, dann Ausnahmen
Löschanfrage lässt sich nicht vollständig erfüllen	Abgeleitete Bestände nicht berücksichtigt	Alle Ablagen aufzählen: Protokolle, Vektordatenbank, Sicherungen	Löschpfad je Ablage definieren – gehört ins Design, Kapitel 15

13.20 Interviewfragen

INTERVIEWFRAGE

Wie verhindern Sie, dass vertrauliche Daten externe Modelle erreichen?

Gut ist eine Modell-Allowlist je Team.

Senior ist die Kombination aus zwei unabhängigen Ebenen: die Allowlist im Gateway, die auf der Datenklasse beruht – und ein grundsätzliches Egress-Verbot im Netzwerk, das sicherstellt, dass niemand am Gateway vorbei kommt. Ohne die zweite Ebene ist die erste eine Empfehlung.

Dazu die Feststellung, dass die Klasse **vor** der Zielwahl bestimmt wird und dass Fall-back-Ketten diese Reihenfolge nicht unterlaufen dürfen – ein Ausweichen von lokal nach extern während einer Störung verletzt genau die Regel, wegen der lokal betrieben wird.

INTERVIEWFRAGE

Was ist Prompt Injection, und was können Sie als Plattformbetreiber dagegen tun?

Schwach ist „mit Filtern verhindern“.

Senior beginnt mit der ehrlichen Aussage: Prompt Injection ist mit Infrastrukturmitteln **nicht** lösbar, weil ein Sprachmodell Anweisung und Inhalt nicht unterscheidet. Filterung erkennt bekannte Muster und scheitert an Umschreibungen.

Was möglich ist, ist die Begrenzung der Schadensreichweite: Werkzeuge mit möglichst geringen Rechten, Trennung lesender und schreibender Werkzeuge, Bestätigung durch Menschen bei wirkungsvollen Aktionen, Egress-Kontrolle, Kontingente, Protokollierung der Werkzeugaufrufe. Wer betont, dass die Gefahr aus der **Kombination** von fremden Inhalten, Werkzeugen und Nutzerrechten entsteht, hat das Modell verstanden.

INTERVIEWFRAGE

Dürfen Sie Prompts speichern?

Senior ist die Zerlegung: Für Abrechnung, Kapazitätsplanung und Betrieb genügen Kennzahlen ohne Inhalte vollständig. Inhalte werden meist zur Untersuchung der Antwortqualität gewünscht — das ist ein eigener Zweck mit eigener Rechtsgrundlage, eigener Frist und eigenem Zugriffsschutz.

Die technische Antwort lautet deshalb: Inhalte im Betriebsprotokoll abschalten, Qualitätsuntersuchung als getrennten Pfad mit ausdrücklicher Grundlage. Wer ergänzt, dass Löschpflichten sich auch auf Sicherungen und abgeleitete Bestände wie Vektordatenbanken erstrecken, hat den unangenehmen Teil bedacht.

INTERVIEWFRAGE

Wie trennen Sie Mandanten auf einer gemeinsamen Plattform?

Senior ist die Staffelung mit ehrlicher Benennung des Restrisikos: Kontingente im Gateway trennen Verbrauch und Zugriff, aber die Mandanten teilen sich Modell, Prefix-Cache und Batches. Getrennte Namensräume trennen zusätzlich Rechte und Netzwerk, aber nicht die Hardware. Getrennte Knoten trennen die Hardware, getrennte Cluster alles.

Der überzeugende Zusatz ist, das Restrisiko der ersten Stufe offen zu benennen, statt „vollständig getrennt“ zu behaupten — und zu sagen, ab welcher Anforderung man auf die nächste Stufe wechseln würde.

INTERVIEWFRAGE

Welche Pflichten hat ein Plattformbetreiber nach der KI-Verordnung?

Gut ist der Hinweis, dass die Einstufung vom Anwendungsfall abhängt und juristisch zu klären ist.

Senior ist die technische Vorbereitung, unabhängig von der Einstufung: Verbrauchs- und Systemprotokolle mit definierten Fristen, menschliche Aufsicht bei wirkungsvollen Aktionen, Kennzeichnung gegenüber Nutzern, ein gepflegter Modellkatalog mit Zweck und Datenklasse, Überwachung im Betrieb.

Die überzeugende Beobachtung: Eine Plattform mit Gateway, Identität und Monitoring erfüllt den technischen Teil weitgehend — weil dieselben Mechanismen für Kostenkontrolle gebraucht werden. Was meist fehlt, ist die Dokumentation.

13.21 Zusammenfassung

- Bei einer KI-Plattform ist der Anfrageinhalt der Compliance-Gegenstand. Daraus folgen Bedrohungen, die es sonst nicht gibt.
- Prompt Injection ist mit Infrastrukturmitteln nicht lösbar. Begrenzbar ist die Schadensreichweite — über Werkzeugrechte, Bestätigungspflichten, Egress und Kontingente.
- Die Gefahr entsteht aus der Kombination: fremde Inhalte im Kontext, Werkzeuge mit Wirkung, Rechte des Nutzers. Eine dieser Zutaten zu entfernen entschärft den Angriff.
- Die tragfähigste Datenklassifikation ist die Zuordnung der **Anwendung** zu einer Klasse. Inhaltsprüfung ist Ergänzung, nicht Grundlage.
- Mustererkennung gehört in den synchronen Pfad, aufwendige Verfahren nicht. Zweistufig: schnell blockierend, gründlich alarmierend.
- Umleiten ist dem Ablehnen fast immer vorzuziehen — Fehlalarme treiben Nutzer zurück in die Schatten-KI.
- Die Klasse wird bestimmt, bevor das Ziel gewählt wird. Fallback-Ketten dürfen diese Reihenfolge nicht unterlaufen.
- Der Inferenz-Server braucht keinen Internetzugang. Ein grundsätzliches Egress-Verbot mit gezielten Ausnahmen ist Voraussetzung, nicht Kür — sonst ist das Gateway umgehbar.
- Mandantentrennung ist gestaffelt. Bei gemeinsamem Modell werden Prefix-Cache und Batches geteilt; „vollständig getrennt“ wäre falsch.
- Löschpflichten erstrecken sich auf Sicherungen und abgeleitete Bestände. Das gehört ins Design.
- Eine Plattform mit Gateway, Identität und Monitoring erfüllt den technischen Teil der Betreiberpflichten weitgehend. Was fehlt, ist meist die Dokumentation.

Quellen und Weiterlesen

- OWASP: *Top 10 for Large Language Model Applications* — ein brauchbares Raster für das Bedrohungsmodell; Nummerierung und Bezeichnungen ändern sich zwischen Auflagen.
- NIST: *AI Risk Management Framework* — Struktur für Risikobetrachtung und Kontrollen.
- Europäische Union: *Verordnung über künstliche Intelligenz* — Rollen, Einstufungen und Pflichten; die Anwendbarkeit ist je Anwendungsfall zu prüfen.
- Datenschutz-Grundverordnung — insbesondere die Vorschriften zu Auftragsverarbeitung, Auskunft, Löschung und technischen Maßnahmen.
- Kubernetes: *Network Policies* — Grundlage der Egress-Kontrolle; die Umsetzung hängt von der eingesetzten Netzwerklösung ab.

TEIL V

Betrieb

*Eine Plattform ist nicht fertig, wenn sie läuft, sondern wenn sie sich betreiben, messen, abrechnen und weiterentwickeln lässt.
Dieser Teil behandelt, was den Dauerbetrieb ausmacht.*

Observability und FinOps

ZIEL

Sehen, was die Plattform tut – auf drei Ebenen, mit den richtigen Kennzahlen – und daraus Kosten je Team und die Break-even-Rechnung aus Kapitel 1 ableiten.

SETZT VORAUS

Kapitel 7 – die Scheduler-Metriken –, Kapitel 11 – das Verbrauchsprotokoll – und ein laufender Prometheus-Stack.

DANACH KANNST DU

DCGM- und vLLM-Metriken richtig interpretieren, Dashboards für drei Zielgruppen bauen, sinnvolle SLOs für Inferenz formulieren, Alarme ohne Rauschen einrichten und eine belastbare Kostenauswertung je Team erzeugen.

GESCHRIEBEN GEGEN

DCGM Exporter 3.3.x · Prometheus 2.5x · vLLM 0.8.x · Stand September 2026

Der Monitoring-Stack selbst wird vorausgesetzt – Prometheus, Grafana, Loki und Tempo sind klassische Plattformerarbeit. Dieses Kapitel behandelt, welche Kennzahlen bei KI-Infrastruktur zählen und wie sie zu lesen sind.

14.1 Drei Ebenen, drei Fragen

Ebene	Beantwortet	Fragt danach
Infrastruktur	Ist die Hardware gesund und ausgelastet?	Betrieb, Kapazitätsplanung
Serving	Bedient der Dienst die Last innerhalb der Zusage?	Betrieb, Anwendungsteams
Geschäft	Wer nutzt wie viel, und was kostet es?	Controlling, Fachbereiche, Leitung

MERKE

Die Trennung ist mehr als Ordnung: Die drei Ebenen haben verschiedene Zielgruppen, verschiedene Auflösungen und verschiedene Aufbewahrungsfristen. Ein Dashboard, das alle drei mischt, ist für niemanden brauchbar.

Die Verbindung entsteht an genau zwei Stellen: Die GPU-Auslastung aus Ebene 1 und die Tokenzahlen aus Ebene 2 ergeben zusammen den Preis je Token – die Zahl, mit der Ebene 3 arbeitet. Ohne beide Quellen bleibt die Kostenrechnung eine Schätzung.

14.2 GPU-Metriken: die Auslastungsfalle

14.2.1 Was DCGM liefert

Der DCGM Exporter läuft als Teil des GPU Operators aus Kapitel 5. Wichtig ist die Zuordnung zu Pods — ohne sie sieht man nur, dass **eine** Karte ausgelastet ist, nicht wodurch.

Metrik	Bedeutung	Einordnung
DCGM_FI_DEV_GPU_UTIL	Anteil der Zeit, in der überhaupt Kernel laufen	Die Falle — siehe unten
DCGM_FI_PROF_PIPE_TENSOR_ACTIVE	Auslastung der Tensor-Recheneinheiten	Aussagekräftig für Prefill
DCGM_FI_PROF_DRAM_ACTIVE	Auslastung der Speicherbandbreite	Die wichtigste Zahl für Decode
DCGM_FI_DEV_FB_USED	Belegter Videospeicher in MiB	Bilanz aus Kapitel 3
DCGM_FI_DEV_GPU_TEMP	Temperatur	Drosselung erkennen — Kapitel 4
DCGM_FI_DEV_POWER_USAGE	Leistungsaufnahme	Kostenrechnung und Drosselung
DCGM_FI_DEV_SM_CLOCK	Taktfrequenz	Fällt bei Drosselung ab
DCGM_FI_DEV_XID_ERRORS	Hardwarefehler — Kapitel 4	Alarm, kein Dashboard

14.2.2 Warum 100 Prozent nichts bedeuten

Kapitel 1 hat es angekündigt, hier die Auflösung: Die verbreitete Auslastungszahl misst, ob **überhaupt** Kernel ausgeführt werden — nicht, wie viel dabei geschieht.

```
FALL A -- gut ausgelastet, Decode

GPU_UTIL          100 %  "es laufen Kernel"
DRAM_ACTIVE       85 %   Speicherbandbreite fast voll
PIPE_TENSOR_ACTIVE 12 %   wenig Rechenlast -- normal im Decode

→ Der Server arbeitet am Limit. Mehr geht nicht.

FALL B -- schlecht ausgelastet, gleiche Anzeige

GPU_UTIL          100 %  "es laufen Kernel"
DRAM_ACTIVE       15 %   Bandbreite kaum genutzt
PIPE_TENSOR_ACTIVE  4 %   fast keine Rechenlast

→ Viele winzige Kernel, kein Batching.
   Der Durchsatz liegt bei einem Bruchteil des Moeglichen.
```

Dieselbe Auslastungszahl, völlig verschiedene Arbeit

MERKE

Für Inferenz ist DCGM_FI_PROF_DRAM_ACTIVE die aussagekräftigste Kennzahl. Sie folgt direkt aus Kapitel 2: Der Decode ist bandbreitenbegrenzt — also ist eine hohe Bandbreitenauslastung der Beweis, dass die Karte tatsächlich arbeitet.

Die einfache Auslastungszahl gehört trotzdem auf das Dashboard — aber als **Anwesenheitsanzeige**, nicht als Leistungsmaß. Wer Kapazitätsentscheidungen darauf stützt, trifft sie auf falscher Grundlage.

14.2.3 Zuordnung zu Pods

```
# Speicherbelegung je Pod
DCGM_FI_DEV_FB_USED{exported_namespace="serving"}
  * on(gpu, instance) group_left(exported_pod)
    DCGM_FI_DEV_FB_USED

# Einfacher, wenn die Kubernetes-Zuordnung aktiv ist:
sum by (exported_pod) (DCGM_FI_DEV_FB_USED)
```

Der GPU Operator aktiviert diese Zuordnung standardmäßig. Fehlen die Pod-Beschriftungen, läuft der Exporter ohne Anbindung an das Kubelet — ein häufiger Fehler bei handgebaute Installationen und der Grund, warum sich Verbrauch dann nicht zurechnen lässt.

14.3 Serving-Metriken vollständig

Die Kennzahlen aus Kapitel 7, hier als Referenz mit ihrer Bedeutung für den Betrieb.

Metrik	Bedeutung	Verwendung
num_requests_running	Anfragen im Batch	Auslastung
num_requests_waiting	Anfragen in der Warteschlange	Skalierung und Alarm
gpu_cache_usage_perc	KV-Cache-Belegung	Frühindikator
num_preemptions_total	Verdrängungen	Alarm
prompt_tokens_total	Eingabetoken kumuliert	Kosten
generation_tokens_total	Ausgabetoken kumuliert	Kosten und Durchsatz
time_to_first_token_seconds	TTFT als Histogramm	SLO
time_per_output_token_seconds	TPOT als Histogramm	SLO
e2e_request_latency_seconds	Gesamtdauer	Diagnose, nicht SLO — Kapitel 2
request_queue_time_seconds	Wartezeit vor der Bearbeitung	Diagnose
prefix_cache_hits_total	Treffer im Präfix-Cache	Wirksamkeit — Kapitel 7
request_success_total	Abgeschlossene Anfragen	Verfügbarkeit

14.3.1 Abgeleitete Größen

```
# Durchsatz in Ausgabetoken je Sekunde
sum(rate(vllm:generation_tokens_total[5m]))

# TTFT, 95. Perzentil
histogram_quantile(0.95,
  sum by (le, model_name) (
    rate(vllm:time_to_first_token_seconds_bucket[5m])))
```

```
# Trefferquote des Praefix-Caches
sum(rate(vllm:prefix_cache_hits_total[15m]))
  / sum(rate(vllm:prefix_cache_queries_total[15m]))

# Verdraengungen je Minute -- sollte 0 sein
sum(rate(vllm:num_preemptions_total[5m])) * 60
```

MERKE

Die dritte Abfrage ist die, die am meisten über die **Anwendungen** verrät. Eine Trefferquote nahe null bei einem Dienst mit festem Systemprompt bedeutet, dass irgendetwas Variables am Prompt-Anfang steht – Kapitel 7. Diese Zahl ist damit ein Werkzeug für das Gespräch mit Anwendungsteams, nicht nur eine Betriebskennzahl.

14.4 Drei Dashboards

Dashboard	Zielgruppe	Inhalt
Hardware	Betrieb	Je GPU: Bandbreiten- und Rechenauslastung, Speicher, Temperatur, Takt, Leistungsaufnahme, Xid-Ereignisse
Dienste	Betrieb, Anwendungsteams	Je Modell: laufende und wartende Anfragen, KV-Cache, TTFT- und TPOT-Perzentile, Durchsatz, Fehlerrate, Verdrängungen, Cache-Trefferquote
Nutzung und Kosten	Controlling, Leitung	Je Team: Anfragen, Token, Kosten, Budgetausschöpfung, Modellverteilung, Trend

ACHTUNG Perzentile, keine Mittelwerte

Kapitel 7 hat gezeigt, dass Verdrängung und Head-of-Line-Blocking einzelne Anfragen stark verzögern, ohne den Mittelwert zu bewegen. Ein Dashboard mit Durchschnittslatenzen zeigt genau die Probleme nicht, über die sich Nutzer beschweren.

Auf das Dienste-Dashboard gehören TTFT und TPOT als 50., 95. und 99. Perzentil. Der Abstand zwischen dem 50. und dem 99. ist dabei die interessanteste Größe: Wächst er, während der Median stabil bleibt, arbeitet der Server an der Sättigungsgrenze.

14.5 SLOs für Inferenz

14.5.1 Was sich zusagen lässt

Kapitel 2 hat die Grundlage gelegt: Die Gesamtdauer hängt an der Ausgabelänge, und die bestimmt die Anwendung. Ein SLO auf die Gesamtdauer wäre eine Zusage über etwas, das die Plattform nicht kontrolliert.

Kennzahl	Beispielzusage	Begründung
Verfügbarkeit	99,5 % der Anfragen ohne Serverfehler	Klassisch, aber allein unzureichend
TTFT	95. Perzentil unter 1,5 s	Von der Plattform kontrollierbar; prägt die Wahrnehmung
TPOT	95. Perzentil unter 60 ms	Bestimmt, ob die Ausgabe flüssig wirkt
Goodput	98 % der Anfragen halten TTFT und TPOT ein	Die ehrlichste Zusage – verbindet beides

MERKE

Goodput ist die Kennzahl, die sich nicht schönrechnen lässt. Ein Server kann seinen Durchsatz verdoppeln, indem er die Batchgröße erhöht – und dabei jede Latenzzusage reißen. Durchsatz und Verfügbarkeit sähen dann hervorragend aus, Goodput fiel ab.

Eine Plattform, die Goodput als Leitkennzahl führt, kann nicht in die Falle laufen, Durchsatz auf Kosten der Nutzererfahrung zu optimieren.

14.5.2 Alarme, die nicht rauschen

Alarm	Bedingung	Bedeutung
Dienst nicht bereit	Kein Pod bereit für 5 min	Ausfall
Verdrängungen	Rate über 0 für 10 min	KV-Cache zu klein – Kapitel 7
Warteschlange wächst	Wartende Anfragen über 10 für 10 min	Sättigung
TTFT-Budget verbraucht	Fehlerbudget-Verbrauchsrate über Schwelle	Latenzzusage in Gefahr
KV-Cache dauerhaft voll	Belegung über 0,95 für 15 min	Kapazitätsgrenze
GPU-Hardwarefehler	Xid-Zähler steigt	Knoten sperren – Kapitel 4 und 5
Budget fast erschöpft	Team über 80 % des Monatsbudgets	Rechtzeitig informieren
Prefix-Trefferquote eingebrochen	Abfall über 50 % gegenüber Vorwoche	Anwendung hat den Prompt-Aufbau geändert

ACHTUNG Nicht auf GPU-Auslastung alarmieren


Eine hohe Auslastungszahl ist bei Inferenz der Normalzustand und kein Alarmgrund – eine niedrige übrigens auch nicht, denn sie kann bedeuten, dass gerade wenig Last anliegt.

Alarmiert wird auf **Wirkung**: Verdrängungen, wachsende Warteschlange, verletzte Latenzzusage, Hardwarefehler. Alles andere erzeugt Meldungen, auf die niemand reagieren kann.

Die letzte Zeile ist ungewöhnlich für einen Alarm, aber wertvoll: Sie meldet eine **Anwendungsänderung** mit Kostenfolge, bevor sie in der Rechnung auffällt.

14.6 Tracing

Ein Trace über die gesamte Kette beantwortet die Frage, wo die Zeit hingeht – die einzige Diagnose, die bei verteilten Aufbauten wirklich trägt.



Ein Trace über Gateway, Serving und Modell

MERKE

Ein Trace darf **keine Prompt-Inhalte** enthalten – Kapitel 11 und 13. Was hineingeht: Modellname, Team, Tokenzahlen, Dauer je Abschnitt, Statuscode. Was nicht hineingeht: Nachrichten, Werkzeugargumente, abgerufene Dokumente.

Das ist ein häufiger Fehler, weil Tracing-Bibliotheken hilfreich sein wollen und Nutzlasten von sich aus aufzeichnen. Die Prüfung aus Kapitel 13 – Testanfrage mit Erkennungsmerkmal, dann in Traces suchen – gehört ausdrücklich dazu.

Bei hohem Anfragevolumen ist vollständiges Tracing zu teuer. Eine niedrige Abtastrate für den Normalfall, kombiniert mit vollständiger Aufzeichnung fehlgeschlagener und besonders langsamer Anfragen, liefert den Nutzen ohne die Kosten.

14.7 Das Kostenmodell

14.7.1 Die vollständige Rechnung

Kapitel 11 hat den Tokenpreis abgeleitet. Hier die Gegenüberstellung, die Kapitel 1 angekündigt hat.

Größe	Eigenbetrieb	Extern	Anmerkung
Kosten je Karte und Monat	2 480 €	–	Kapitel 1
Auslastung	40 %	–	Die Stellschraube
Ausgabefolgen je Monat	ca. 840 Mio.	–	bei 800 T/s und 40 %
Kosten je Mio. Ausgabe-folgen	ca. 2,95 €	ca. 14 €	Beispielpreise
Kosten je Mio. Eingabefolgen	ca. 0,30 €	ca. 2,80 €	Beispielpreise

MERKE

Bei 40 Prozent Auslastung ist der Eigenbetrieb je Token rund viermal günstiger als der externe Bezug. Das klingt eindeutig – und ist es nicht, weil die Rechnung eine Voraussetzung hat: **dass die Auslastung erreicht wird.**

Bei 10 Prozent Auslastung steigt der Preis auf rund 12 € je Million und der Vorteil verschwindet. Bei 5 Prozent ist der Eigenbetrieb teurer als jede Cloud-API.

Damit ist die Aussage aus Kapitel 1 vollständig begründet: Eigenbetrieb rechnet sich nicht ab einer bestimmten Nutzerzahl, sondern ab einer bestimmten **Auslastung** – und genau deshalb ist sie die zentrale wirtschaftliche Kennzahl der Plattform.

14.7.2 Die Auslastung messen

```
# Anteil der Zeit mit nennenswerter Bandbreitenauslastung
avg_over_time(
  (DCGM_FI_PROF_DRAM_ACTIVE > bool 0.3)[7d:5m])

# Tatsächlich erzeugte Token je Woche
sum(increase(vllm:generation_tokens_total[7d]))

# Kosten je Million Ausgabetoken, gerechnet
(2480 / 4.35) # Kosten je Woche
/ (sum(increase(vllm:generation_tokens_total[7d])) / 1e6)
```

Die dritte Abfrage liefert den Wert, der in die Gateway-Konfiguration aus Kapitel 11 gehört – und der sich damit selbst korrigiert, sobald die Nutzung wächst.

14.7.3 Zuordnung oder Verrechnung

Option	Geeignet, wenn	Ungeeignet, wenn
Nur ausweisen	Als Einstieg. Teams sehen ihren Verbrauch, ohne dass Geld fließt. Erzeugt Bewusstsein ohne Konflikte	Wenn die Nutzung so stark wächst, dass niemand steuert
Verrechnen	Wenn Budgets tatsächlich steuern sollen. Setzt belastbare Zahlen und akzeptierte Preise voraus	Solange die Zahlen noch schwanken oder der Tokenpreis nicht gepflegt wird

Diese Zahl einmal im Quartal nachzurechnen genügt. Sie sinkt bei wachsender Nutzung – was ein gutes Argument gegenüber der Leitung ist.

MERKE

Fast alle Plattformen beginnen mit dem Ausweisen und wechseln nach ein bis zwei Quartalen zur Verrechnung. Das ist die richtige Reihenfolge: Zuerst müssen die Zahlen stimmen und unstrittig sein, sonst wird über die Messung diskutiert statt über den Verbrauch.

Der Wechsel gelingt leichter, wenn von Anfang an dieselben Zahlen ausgewiesen werden, die später verrechnet werden – inklusive des Preises für eigene Modelle.

14.8 Gateway-Metriken

Das Gateway liefert die Ebene, die dem Serving fehlt: Wer verursacht die Last. Seine Kennzahlen ergänzen die aus Abschnitt 14.3 um die Zuordnung.

Kennzahl	Bedeutung	Verwendung
Anfragen je Team und Modell	Verteilung der Nutzung	Kosten, Kapazität
Token je Team	Eingabe und Ausgabe getrennt	Grundlage der Verrechnung
Kosten je Team	Aus Tokenzahl und hinterlegtem Preis — Kapitel 11	Verrechnung
Ausgeschöpftes Budget	Anteil am Zeitraum	Frühwarnung
Abgelehnte Anfragen	Nach Grund: Kontingent, Allowlist, Fehler	Sehr aussagekräftig — siehe unten
Ausweichvorgänge	Wie oft ein Fallback griff	Anbieterqualität
Latenz je Ziel	Antwortzeit der Anbieter	Routing-Entscheidungen

MERKE

Die Zeile mit den abgelehnten Anfragen verdient einen eigenen Blick auf dem Dashboard, nach Grund aufgeschlüsselt:

Viele Ablehnungen wegen **Kontingent** bedeuten, dass ein Team mehr braucht — oder fehlerhaft wiederholt. Ablehnungen wegen **Allowlist** bedeuten, dass eine Anwendung ein Modell anspricht, das sie nicht darf — entweder ein Konfigurationsfehler oder ein Versuch, die Datenklassifikation zu umgehen. Beides gehört gesehen, nicht nur gezählt.

14.9 Logs

Nach den Einschränkungen aus Kapitel 11 und 13 bleibt die Frage, was überhaupt in die Log-Pipeline gehört.

Quelle	Behalten	Nicht behalten
Inferenz-Server	Startmeldungen mit KV-Cache-Größe und Kernelwahl, Durchsatzzusammenfassungen, Fehler	Anfrageinhalte — Kapitel 8
Gateway	Statuscodes, Ablehnungsgründe, Ausweichvorgänge, Fehler	Prompts und Antworten — Kapitel 11
GPU Operator	Treiber- und Validator-Meldungen	–
Kubernetes	Ereignisse zu GPU-Pods	–

MERKE

Die Startmeldungen des Inferenz-Servers sind die wertvollsten Logzeilen der gesamten Plattform: Sie enthalten die wirksamen Argumente, die KV-Cache-Größe und die gewählte Kernel-Implementierung. Bei jeder Störung ist das die erste Frage — lief der Dienst überhaupt mit der Konfiguration, die man annimmt?

Deshalb lohnt es sich, sie ausdrücklich zu erfassen und länger aufzubewahren als den laufenden Betrieb: Sie fallen selten an und beantworten viel.

14.10 Aufbewahrung und Kardinalität

Metriken einer KI-Plattform haben zwei Eigenschaften, die den Speicherbedarf treiben: viele Beschriftungen und die Versuchung, den Nutzerbezug hineinzunehmen.

ACHTUNG Nutzerkennungen gehören nicht in Metrikbeschriftungen

Eine Beschriftung mit der Nutzerkennung erzeugt eine eigene Zeitreihe je Person und Metrik. Bei 500 Nutzern, zehn Metriken und drei weiteren Beschriftungen entstehen schnell Hunderttausende Zeitreihen – mit entsprechendem Speicher- und Abfrageaufwand.

Der Nutzerbezug gehört in die **Verbrauchsdaten** des Gateways, die als Ereignisse vorliegen und sich dort beliebig auswerten lassen. Metriken bleiben auf Team- und Modellebene.

Dasselbe gilt für Modellnamen bei Multi-LoRA aus Kapitel 8: Fünfzig Adapter als Beschriftung sind vertretbar, fünftausend nicht.

Datenart	Frist	Begründung
Rohe Metriken	15–30 Tage	Reicht für Störungsanalyse
Verdichtete Metriken	13–24 Monate	Kapazitätstrend und Jahresvergleich
Verbrauchsdaten	Abrechnungszeitraum plus Aufbewahrung	Kapitel 13
Traces	3–7 Tage	Nur für aktuelle Analysen
Startmeldungen	90 Tage	Nachvollziehbarkeit von Konfigurationsständen

Für die zweite Zeile genügen wenige verdichtete Zeitreihen, die stündlich berechnet werden:

```
groups:
- name: ai-plattform-verdichtet
  interval: 1h
  rules:
    - record: plattform:ausgabetoken:rate1h
      expr: sum by (model_name) (
        rate(vllm:generation_tokens_total[1h]))
    - record: plattform:gpu_bandbreite:avg1h
      expr: avg by (gpu, node) (
        avg_over_time(DCGM_FI_PROF_DRAM_ACTIVE[1h]))
```

14.11 Kapazitätstrend

Die Frage „wann brauchen wir die nächste GPU?“ lässt sich beantworten, wenn die verdichteten Zeitreihen vorliegen.

Nr.	Schritt	Quelle
1	Ausgabetoken je Woche über die letzten Monate	verdichtete Zeitreihe
2	Wachstumsrate bestimmen	linearer oder exponentieller Verlauf

Nr.	Schritt	Quelle
3	Aktuelle Spitzenauslastung ermitteln	Bandbreitenauslastung, 95. Perzentil
4	Schwelle festlegen, ab der die Zusage reißt	Rampenmessung aus Kapitel 8
5	Zeitpunkt hochrechnen	Wachstum gegen Schwelle
6	Beschaffungsvorlauf abziehen	oft drei bis sechs Monate

MERKE

Schritt 6 wird regelmäßig vergessen und ist der teuerste Fehler. Wenn die Rechnung ergibt, dass die Kapazität in fünf Monaten nicht mehr reicht, und die Beschaffung sechs Monate dauert, ist die Entscheidung **bereits überfällig**.

Ein Kapazitätsbericht, der nur den aktuellen Stand zeigt, kommt für diese Entscheidung zu spät. Er muss die Hochrechnung enthalten – und den Vorlauf.

ACHTUNG Wachstum ist bei KI-Plattformen selten linear

Nach der Einführung wächst die Nutzung typischerweise sprunghaft: Ein Fachbereich bindet eine Anwendung an, und die Last verdoppelt sich innerhalb einer Woche.

Eine Hochrechnung aus dem bisherigen Verlauf greift deshalb zu kurz. Ergänzen Sie sie um die geplanten Anbindungen aus dem Freigabeprozess in Kapitel 13 – dort ist bekannt, welche Anwendungen als Nächstes kommen. Diese Information ist für die Kapazitätsplanung wertvoller als jede Kurvenanpassung.

14.12 Der Monatsbericht

Ein wiederkehrender Bericht ist das Werkzeug, mit dem eine Plattform ihre Existenz begründet. Er sollte auf eine Seite passen.

Abschnitt	Inhalt	Zielgruppe
Nutzung	Anfragen und Token gesamt, Verlauf, Top-Teams, Modellverteilung	Leitung, Fachbereiche
Kosten	Gesamtkosten, Aufteilung eigen und extern, Kosten je Million Token, Trend	Controlling
Zusagen	Verfügbarkeit, TTFT- und TPOT-Perzentile, Goodput, Zwischenfälle	Betrieb, Anwendungsteams
Kapazität	Auslastung, Hochrechnung, empfohlene Maßnahme mit Zeitpunkt	Leitung
Governance	Neue Modelle und Anwendungen, Ablehnungen nach Grund, offene Punkte	Sicherheit, Datenschutz

MERKE


Der wirksamste Abschnitt ist der zweite – und zwar nicht wegen der Gesamtsumme, sondern wegen der **Kosten je Million Token im Zeitverlauf**. Wenn diese Zahl

sinkt, während die Nutzung steigt, zeigt der Bericht Skaleneffekte. Das ist das stärkste Argument für weitere Investitionen, und es ergibt sich unmittelbar aus der Auslastungsrechnung in Abschnitt 14.8.

Umgekehrt ist eine steigende Zahl bei sinkender Nutzung das Signal, Kapazität zurückzubauen — eine Entscheidung, die ohne diese Auswertung niemand trifft.

14.13 Diagnose: „Es ist langsam“

Die häufigste Meldung — und die unspezifischste. Mit den Kennzahlen dieses Kapitels lässt sie sich in wenigen Schritten eingrenzen. Die folgende Abfolge deckt praktisch alle Fälle ab.



Diagnosepfad bei Latenzbeschwerden

MERKE

Der letzte Zweig ist der, der am häufigsten zutrifft und am seltensten zuerst geprüft wird. Wenn TTFT und TPOT serverseitig gut aussehen, die Nutzer aber warten, liegt es meist an der Pufferung im Ingress aus Kapitel 11 — ein Fehler, der keine Metrik bewegt und keine Meldung erzeugt.

Deshalb gehört zur Diagnose immer eine Messung **aus Nutzersicht**, nicht nur aus dem Cluster heraus.

14.14 Die Break-even-Rechnung

Die Frage aus Kapitel 1 — lohnt sich Eigenbetrieb? — lässt sich jetzt vollständig beantworten. Die Antwort ist eine Kurve, kein Wert.

Auslastung	Token/Monat	Preis je Mio.	Gegenüber extern (14 €)
5 %	ca. 105 Mio.	ca. 23,60 €	deutlich teurer
10 %	ca. 210 Mio.	ca. 11,80 €	etwa gleich
20 %	ca. 420 Mio.	ca. 5,90 €	rund halb so teuer
40 %	ca. 840 Mio.	ca. 2,95 €	rund ein Fünftel
70 %	ca. 1 470 Mio.	ca. 1,69 €	rund ein Achtel

Grundlage sind die 2 480 € je Monat aus Kapitel 1 und ein Durchsatz von 800 Ausgabetoken je Sekunde.

MERKE

Der Gleichstand liegt bei rund **zehn Prozent Auslastung** — also bei etwa 210 Millionen Ausgabetoken im Monat. Nach der Rechnung aus Kapitel 2 entspricht das grob 500 000 Anfragen mit je 400 Ausgabetoken, also rund 17 000 Anfragen am Tag.

Für eine Organisation mit einigen hundert aktiven Nutzern ist das erreichbar, aber nicht selbstverständlich. Genau hier liegt die ehrliche Antwort auf die Vorstandsfrage aus Kapitel 1: Unterhalb dieser Schwelle ist der Eigenbetrieb **nicht** wirtschaftlich begründbar — er ist dann durch Datenklassifikation begründet, und das ist ein anderes Argument.

ACHTUNG Was die Tabelle nicht enthält

Drei Posten fehlen bewusst, weil sie stark von der Organisation abhängen und die Rechnung sonst scheingenau würde:

Die **Ausfallreserve** — eine zweite Karte für Wartung, wie Kapitel 4 und 9 begründet haben — verdoppelt die Fixkosten, ohne den Durchsatz zu verdoppeln. Der **Einführungsaufwand** für Aufbau und Einarbeitung fällt einmalig an, aber erheblich. Und die **Kosten des Nichtstuns** — entgangener Nutzen, wenn ein Anwendungsfall wegen Datenschutzgründen gar nicht umgesetzt werden kann — tauchen in keiner Rechnung auf und sind oft der eigentliche Grund für die Investition.

Nennen Sie diese drei Posten, wenn Sie die Rechnung präsentieren. Eine Kalkulation, die ihre eigenen Grenzen benennt, ist glaubwürdiger als eine, die eine Zahl behauptet.

14.15 Dashboard-Referenz

Zum Nachbauen die wesentlichen Abfragen je Dashboard.

14.15.1 Hardware

```
# Bandbreitenauslastung je GPU
avg by (gpu, Hostname) (DCGM_FI_PROF_DRAM_ACTIVE)

# Speicherbelegung gegen Kapazität
sum by (gpu) (DCGM_FI_DEV_FB_USED)
/ sum by (gpu) (DCGM_FI_DEV_FB_TOTAL)

# Drosselung erkennen: Takt gegen Temperatur
avg by (gpu) (DCGM_FI_DEV_SM_CLOCK)
avg by (gpu) (DCGM_FI_DEV_GPU_TEMP)

# Hardwarefehler -- gehoert auf Alarm, nicht ins Panel
increase(DCGM_FI_DEV_XID_ERRORS[1h])
```

14.15.2 Dienste

```
# Auslastung des Batches
sum by (model_name) (vllm:num_requests_running)
sum by (model_name) (vllm:num_requests_waiting)

# KV-Cache
avg by (model_name) (vllm:gpu_cache_usage_perc)

# TTFT: Median und 99. Perzentil nebeneinander
histogram_quantile(0.50, sum by (le, model_name) (
  rate(vllm:time_to_first_token_seconds_bucket[5m])))
histogram_quantile(0.99, sum by (le, model_name) (
  rate(vllm:time_to_first_token_seconds_bucket[5m])))

# Goodput: Anteil unter beiden Schwellen
sum(rate(vllm:time_to_first_token_seconds_bucket{le="1.5"}[5m]))
/ sum(rate(vllm:time_to_first_token_seconds_count[5m]))
```

14.15.3 Nutzung und Kosten

Diese Auswertungen stammen aus den Verbrauchsdaten des Gateways, nicht aus Prometheus – sie brauchen den Nutzerbezug, der nach Abschnitt 14.7 nicht in Metriken gehört.

Auswertung	Grundlage
Token je Team und Monat	Summe über die Verbrauchsdaten
Kosten je Team	Token mal hinterlegter Preis – Kapitel 11
Budgetausschöpfung	Kosten gegen <code>max_budget</code>
Modellverteilung je Team	Gruppierung nach Modell
Kosten je Anfrage im Zeitverlauf	Gesamtkosten geteilt durch Anfragen
Anteil eigen gegen extern	Gruppierung nach Zielart

Die vorletzte Zeile ist eine gute Frühwarnung: Steigen die Kosten je Anfrage, ohne dass sich die Preise geändert haben, werden die Prompts länger – meist durch eine Änderung an einer Anwendung.

14.16 Lab: Von der Metrik zur Kostenaussage

LAB Die Kette Hardware, Dienst, Kosten schließen

Ziel: Aus DCGM- und vLLM-Metriken einen belastbaren Preis je Million Token ableiten — und die Auslastungsfälle selbst sehen.

Voraussetzung: GPU Operator mit DCGM Exporter, vLLM-Dienst, Prometheus.

Schritt 1 — Metriken prüfen.

```
kubectl -n gpu-operator port-forward \
  svc/nvidia-dcgm-exporter 9400:9400 &
curl -s localhost:9400/metrics \
  | grep -E 'DRAM_ACTIVE|GPU_UTIL|FB_USED' | head
```

Erwartete Ausgabe: Werte mit Beschriftungen für Pod und Namensraum. Fehlen die Pod-Beschriftungen, ist die Kubernetes-Zuordnung nicht aktiv — siehe Abschnitt 14.2.

Schritt 2 — Die Falle sichtbar machen. Senden Sie einzelne Anfragen nacheinander, ohne Gleichzeitigkeit:

```
for i in $(seq 1 20); do
  curl -s localhost:8000/v1/completions \
    -H 'Content-Type: application/json' \
    -d '{"model": "unternehmen-chat-v1", "max_tokens": 100,
      "prompt": "Erzaehle etwas.", "temperature": 0}' \
    >/dev/null
done
```

Beobachten Sie dabei beide Werte. **Erwartung:** Die einfache Auslastungszahl liegt hoch, die Bandbreitenauslastung deutlich niedriger — weil ohne Batching wenig Arbeit je Kernel anfällt.

Schritt 3 — Gegenprobe mit Last. Dieselbe Zahl Anfragen, aber gleichzeitig:

```
for i in $(seq 1 20); do
  curl -s localhost:8000/v1/completions \
    -H 'Content-Type: application/json' \
    -d '{"model": "unternehmen-chat-v1", "max_tokens": 100,
      "prompt": "Erzaehle etwas.", "temperature": 0}' \
    >/dev/null &
done; wait
```

Erwartung: Die Bandbreitenauslastung steigt deutlich, die einfache Auslastungszahl kaum — sie war schon hoch. Genau das ist der Unterschied aus Abschnitt 14.2.

Schritt 4 — Durchsatz messen.

```
sum(rate(vllm:generation_tokens_total[5m]))
```

Schritt 5 — Preis ableiten. Setzen Sie Ihre eigenen Kartenkosten ein und rechnen Sie den Wert für eine Woche. Vergleichen Sie ihn mit dem Preis eines externen Anbieters für ein vergleichbares Modell.

Schritt 6 — Ins Gateway eintragen. Den ermittelten Wert als `output_cost_per_token` konfigurieren — Kapitel 11 — und anschließend prüfen, dass im Verbrauchsprotokoll Kosten ungleich null erscheinen:

```
curl -s localhost:4000/spend/logs -H "$M" \
  | jq -r '.[.] | [.model, .spend] | @tsv' | tail -5
```

Ergebnis: Eine Kostenaussage, die auf gemessenen Werten beruht – und die Erfahrung, wie stark sie von der Auslastung abhängt.

14.17 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
DCGM-Metriken ohne Pod-Be-schriftung	Kubernetes-Zu-ordnung im Ex-orter nicht aktiv	Rohausgabe des Ex-porters ansehen	Zuordnung in der Ope-rator-Konfiguration ak-tivieren
vLLM-Metriken fehlen in Prome-theus	ServiceMonitor trifft den Port nicht – Kapitel 10	Portnamen im erzeug-ten Service prüfen	Monitor korrigieren
Latenz laut Dash-board gut, Nutzer beschwerten sich	Mittelwerte statt Perzentilen	99. Perzentil gegen den Median hal-ten	Dashboard auf Perzenti-le umstellen
Alarmer feuern ständig ohne Handlungsbedarf	Alarm auf Auslas-tung statt auf Wirkung	Alarmregeln durchse-hen	Auf Verdrängungen, Warteschlange und Feh-lerbudget umstellen
Kosten je Team sind null	Preise für eigene Modelle nicht ge-setzt – Kapitel 11	Verbrauchsprotokoll ansehen	output_cost_per_token konfigurieren
Prompt-Inhalte tauchen in Traces auf	Bibliothek zeich-net Nutzlasten auf	Testanfrage mit Er-kennungsmerkmal, dann suchen	Aufzeichnung von Nutzlasten abschalten – Kapitel 13
Metrikdaten wachsen unkon-trolliert	Hohe Kardinalität durch Nutzerken-nungen als Be-schriftung	Zahl der Zeitreihen je Metrik prüfen	Nutzerbezug in die Ver-brauchsdaten, nicht in Metriken

14.18 Interviewfragen

INTERVIEWFRAGE

Was ist die wichtigste Kennzahl einer AI-Plattform?

Schwach ist „Verfügbarkeit“ – die Antwort aus dem klassischen Betrieb.

Gut ist GPU-Auslastung mit dem wirtschaftlichen Argument.

Senior ist die Präzisierung: Die verbreitete Auslastungszahl misst nur, ob überhaupt Kernel laufen. Für Inferenz ist die **Bandbreitenauslastung** die aussagekräftige Größe, weil der Decode bandbreitenbegrenzt ist. Ein Server ohne wirksames Batching zeigt 100 Prozent Auslastung bei 15 Prozent Bandbreitennutzung – und liefert einen Bruchteil des möglichen Durchsatzes.

Für die Geschäftsseite ist die Leitkennzahl der Preis je Million Token, und der ergibt sich aus Auslastung und Durchsatz.

INTERVIEWFRAGE

Welche SLOs würden Sie für einen Inferenz-Dienst definieren?

Senior ist die Begründung, warum die Gesamtdauer **kein** SLO sein kann: Sie hängt an der Ausgabelänge, und die bestimmt die Anwendung. Zusagbar sind TTFT und TPOT als Perzentile, dazu Verfügbarkeit.

Der überzeugende Zusatz ist Goodput — der Anteil der Anfragen, die beide Latenzgrenzen einhalten. Diese Kennzahl lässt sich nicht schönrechnen: Ein Server kann seinen Durchsatz durch größere Batches verdoppeln und dabei jede Zusage reißen. Durchsatz und Verfügbarkeit sähen gut aus, Goodput fiel ab.

INTERVIEWFRAGE

Wie ordnen Sie GPU-Kosten einzelnen Teams zu?

Senior ist der vollständige Weg: Kartenkosten je Monat, geteilt durch die tatsächlich erzeugten Token in diesem Zeitraum, ergibt einen Preis je Million Token. Dieser Wert wird im Gateway hinterlegt, das je Anfrage Team, Nutzer und Tokenzahl kennt — damit erscheinen eigene und externe Modelle in derselben Auswertung.

Der entscheidende Punkt ist die Abhängigkeit von der Auslastung: Bei 40 Prozent liegt der Preis rund viermal unter dem externen Bezug, bei 5 Prozent darüber. Wer das benennt, erklärt zugleich, warum Auslastung die zentrale wirtschaftliche Kennzahl ist.

INTERVIEWFRAGE

Ihr Dashboard zeigt 100 Prozent GPU-Auslastung. Ist das gut?

Senior ist die Rückfrage nach den anderen beiden Werten: Bandbreitenauslastung und Tensor-Auslastung. Bei hoher Bandbreitennutzung arbeitet der Server im Decode am Limit — das ist der gesunde Zustand. Bei niedriger Bandbreitennutzung laufen viele kleine Kernel ohne wirksames Batching, und der Durchsatz liegt weit unter dem Möglichen.

Ergänzend: Auf Auslastung wird nicht alarmiert. Alarmiert wird auf Wirkung — Verdrängungen, wachsende Warteschlange, verletzte Latenzusage, Hardwarefehler.

INTERVIEWFRAGE

Was gehört in einen Trace, und was nicht?

Senior ist die klare Trennung: Hinein gehören Modellname, Team, Tokenzahlen, Dauer je Abschnitt und Statuscode. Nicht hinein gehören Nachrichten, Werkzeugargumente und abgerufene Dokumente — aus denselben Gründen wie bei den Logs in Kapitel 11.

Der praktische Zusatz: Tracing-Bibliotheken zeichnen Nutzlasten häufig von sich aus auf. Die Prüfung gehört deshalb in die Abnahme — eine Testanfrage mit Erkennungsmerkmal senden und anschließend in Logs, Metriken und Traces danach suchen.

14.19 Zusammenfassung

- Drei Ebenen mit drei Zielgruppen: Infrastruktur, Serving, Geschäft. Ein Dashboard, das sie mischt, ist für niemanden brauchbar.
- Die verbreitete GPU-Auslastungszahl misst nur, ob Kernel laufen. Für Inferenz ist die Bandbreitenauslastung die aussagekräftige Größe – weil der Decode bandbreitenbegrenzt ist.
- Ohne Pod-Zuordnung der DCGM-Metriken lässt sich Verbrauch nicht zurechnen.
- Latenz gehört als Perzentil auf das Dashboard. Der Abstand zwischen dem 50. und dem 99. zeigt an, ob der Server an der Sättigungsgrenze arbeitet.
- Ein SLO auf die Gesamtdauer ist eine Zusage über etwas, das die Plattform nicht kontrolliert. Zusagbar sind TTFT, TPOT und Goodput.
- Goodput lässt sich nicht durch größere Batches schönrechnen – deshalb ist es die ehrlichste Leitkennzahl.
- Alarmiert wird auf Wirkung, nicht auf Auslastung: Verdrängungen, Warteschlange, Fehlerbudget, Hardwarefehler.
- Traces enthalten keine Inhalte. Tracing-Bibliotheken zeichnen Nutzlasten von sich aus auf – die Prüfung gehört in die Abnahme.
- Der Preis je Million Token folgt aus Kartenkosten geteilt durch erzeugte Token. Bei 40 Prozent Auslastung liegt er weit unter dem externen Bezug, bei 5 Prozent darüber.
- Erst ausweisen, dann verrechnen. Zuerst müssen die Zahlen unstrittig sein.

Quellen und Weiterlesen

- NVIDIA: *DCGM Exporter – Metrics Reference*. Vollständige Liste der Feldkennungen und ihrer Bedeutung; die Profiling-Metriken sind gesondert zu aktivieren.
- vLLM: *Documentation – Metrics*. Namen und Umfang ändern sich zwischen Versionen.
- Google: *Site Reliability Engineering* – Kapitel zu SLOs, Fehlerbudgets und Alarmierung nach Verbrauchsrate.
- Prometheus: *Querying – Histograms and Quantiles*. Grundlage der Perzentilbildung aus Histogrammen.
- FinOps Foundation: *Framework* – Begriffe und Vorgehen für Ausweisung und Verrechnung.

RAG-Infrastruktur betreiben

ZIEL	Eine Abrufstrecke als Plattformdienst betreiben — mit Blick auf Kapazität, Berechtigungen, Lösbarkeit und Wiederherstellung, nicht auf Antwortqualität.
SETZT VORAUS	Kapitel 8 — Einbettungsmodelle betreiben — und Kapitel 13 — Berechtigungen und Löschpflichten.
DANACH KANNST DU	Eine Vektordatenbank begründet auswählen und betreiben, Index- und Speicherbedarf berechnen, Ingestion und Neuaufbau ohne Ausfall fahren, Berechtigungen im Abruf durchsetzen und Löschungen vollständig umsetzen.

GESCHRIEBEN GEGEN

Qdrant 1.12.x · pgvector 0.8.x · Milvus 2.5.x · Stand September 2026

Dieses Kapitel behandelt RAG als **Infrastrukturaufgabe**. Fragen der Antwortqualität — welche Zerlegung fachlich sinnvoll ist, welches Abrufverfahren die besten Treffer liefert — gehören zum Anwendungsteam. Was der Plattformbetreiber verantwortet, ist die Betreibbarkeit: Kapazität, Verfügbarkeit, Berechtigungen, Datenschutz und Wiederherstellbarkeit.

15.1 Die Strecke aus Betreibersicht



Zwei getrennte Strecken mit völlig verschiedenem Lastprofil

MERKE

Die beiden Strecken teilen sich fast nichts außer der Datenbank. Ingestion ist ein Stapelauftrag mit hoher, planbarer Last — Kapitel 10 hat das Muster behandelt. Die Abfrage ist ein latenzkritischer Dauerdienst mit geringer Rechenlast.

Sie getrennt zu dimensionieren und zu betreiben ist die wichtigste Entscheidung dieses Kapitels. Wer beides in denselben Dienst legt, hat einen Abfragedienst, der während jeder Ingestion langsam wird.

15.2 Kapazität berechnen

Bevor eine Datenbank ausgewählt wird, muss die Größenordnung feststehen. Die Rechnung ist einfach und wird selten geführt.

Nr.	Größe	Beispiel
1	Dokumente	50 000
2	Durchschnittliche Länge	8 Seiten, ca. 4 000 Token
3	Abschnittsgröße	512 Token, 20 % Überlappung
4	Abschnitte je Dokument	ca. 10
5	Vektoren insgesamt	ca. 500 000
6	Dimension des Einbettungsmodells	1 024
7	Rohgröße je Vektor	1 024 × 4 Byte = 4 KiB
8	Rohdaten gesamt	ca. 2,0 GiB
9	Indexaufschlag	Faktor 1,5 bis 2 — siehe Abschnitt 15.4
10	Nutzlast: Text und Metadaten	ca. 1,5 GiB
11	Gesamtbedarf im Arbeitsspeicher	ca. 5 bis 6 GiB

MERKE

Für die allermeisten Unternehmensbestände ist das Ergebnis überraschend klein. Eine halbe Million Abschnitte passen mit Index in wenige Gigabyte — also in den Arbeitsspeicher eines gewöhnlichen Knotens.

Daraus folgt eine Aussage, die viele Architekturdiskussionen abkürzt: **Unterhalb einiger Millionen Vektoren ist die Wahl der Datenbank keine Kapazitätsfrage.** Sie ist eine Frage des Betriebsaufwands, der Berechtigungsmodelle und dessen, was das Team bereits betreibt.

15.2.1 Wann es doch groß wird

Fall	Vektoren	Konsequenz
Abteilungswissen	< 1 Mio.	Jede Lösung genügt; pgvector naheliegend
Unternehmensweite Dokumentation	1–20 Mio.	Spezialisierte Datenbank sinnvoll
Alle E-Mails und Chats	> 100 Mio.	Eigenes Vorhaben mit eigener Planung
Quellcode aller Repositorys	10–100 Mio.	Feine Zerlegung treibt die Zahl

15.3 Die Datenbanken

Die Auswahl folgt nicht dem Benchmark, sondern dem Betriebsaufwand — wie schon bei den Inferenz-Servern in Kapitel 10.

Lösung	Stärke	Einschränkung
pgvector	Erweiterung für PostgreSQL. Nutzt vorhandenen Betrieb: Sicherung, Hochverfügbarkeit, Berechtigungen, Transaktionen. Vektoren und Metadaten in einer Datenbank	Bei sehr vielen Vektoren langsamer als spezialisierte Lösungen

Lösung	Stärke	Einschränkung
Qdrant	Auf Vektorsuche ausgelegt, gute Filterung, einfacher Betrieb, brauchbare Kubernetes-Unterstützung	Ein weiteres System mit eigener Sicherung und eigenem Betriebswissen
Milvus	Für sehr große Bestände ausgelegt, Rechnen und Speichern getrennt skalierbar	Deutlich mehr bewegliche Teile – lohnt erst bei entsprechender Größe
OpenSearch	Wenn bereits im Haus. Verbindet Volltext- und Vektorsuche in einem System	Vektorsuche ist nicht der Hauptzweck; Speicherbedarf hoch

Option	Geeignet, wenn	Ungeeignet, wenn
pgvector	Der Regelfall unterhalb weniger Millionen Vektoren – besonders wenn PostgreSQL ohnehin betrieben wird. Ein System weniger im Betrieb	Bei zweistelligen Millionenzahlen oder sehr hohen Abfrageraten
Qdrant	Wenn Vektorsuche zentral ist, viel gefiltert wird und die Bestände wachsen	Wenn PostgreSQL genügt – dann ist es unnötiger Betriebsaufwand
OpenSearch	Wenn es bereits produktiv läuft und hybride Suche gebraucht wird	Als Neueinführung allein für Vektorsuche
Milvus	Bei zweistelligen Millionen bis Milliarden Vektoren	Für Bestände, die in den Arbeitsspeicher eines Knotens passen

MERKE

Die verbreitete Annahme, eine spezialisierte Vektordatenbank sei immer die bessere Wahl, hält der Betriebsprüfung selten stand. Eine PostgreSQL-Instanz, die das Team seit Jahren betreibt – mit erprobter Sicherung, Wiederherstellung, Hochverfügbarkeit und Rechtemodell – ist einem neuen System überlegen, solange die Kapazität reicht.

Der entscheidende Vorteil ist die **Transaktionalität**: Dokument, Abschnitte, Berechtigungen und Vektoren liegen in einer Datenbank und lassen sich gemeinsam ändern und löschen. Genau das macht die Anforderungen aus Abschnitt 15.8 erheblich einfacher.

15.4 Indexverfahren

15.4.1 Die Verfahren

Verfahren	Arbeitsweise	Speicher	Einordnung
Vollständig	Vergleicht mit allen Vektoren	nur Rohdaten	Exakt. Bis einige zehntausend Vektoren völlig ausreichend
HNSW	Mehrschichtiger Nachbarschaftsgraph	+50 bis 100 %	Der Regelfall. Schnell, gute Trefferqualität
IVF	Aufteilung in Zellen, Suche in wenigen	+10 bis 20 %	Speichersparend, dafür ungenauer
Mit Kompression	Vektoren verkleinert gespeichert	–75 % und mehr	Bei sehr großen Beständen; kostet Genauigkeit

MERKE

Der Aufschlag bei HNSW wird bei der Dimensionierung regelmäßig vergessen: Der Index ist kein Beiwerk, sondern belegt so viel wie die Vektoren selbst noch einmal zur Hälfte oder ganz. In der Rechnung aus Abschnitt 15.2 steckt er im Faktor der neunten Zeile.

Unterhalb einiger zehntausend Vektoren ist die vollständige Suche schnell genug – und hat den Vorteil, exakt zu sein und keinen Index zu benötigen, der beim Schreiben gepflegt werden muss.

15.4.2 Die Stellschrauben

Parameter	Wirkt auf	Abwägung
Nachbarschaftsgrad	Verbindungen je Knoten	Höher: bessere Treffer, mehr Speicher, langsamerer Aufbau
Aufbautiefe	Sorgfalt beim Einfügen	Höher: bessere Struktur, deutlich langsamerer Aufbau
Suchtiefe	Kandidaten je Abfrage	Zur Laufzeit änderbar – der wichtigste Regler

Die dritte Zeile ist betrieblich die wertvollste: Sie lässt sich je Abfrage setzen. Damit kann dieselbe Datenbank eine schnelle, ungefähre Suche für interaktive Anfragen und eine gründliche für Stapelauswertungen bedienen – ohne zweiten Index.

15.5 Ingestion

15.5.1 Als Stapelauftrag

Kapitel 10 hat das Muster behandelt: Ingestion ist ein Job, kein Dienst.

Eigenschaft	Umsetzung
Läuft selten	Zeitgesteuert oder ereignisgetrieben
Braucht viel Rechenleistung	GPU sinnvoll – Kapitel 8
Ist unterbrechbar	Fortschritt festhalten, Wiederaufnahme ermöglichen
Darf den Abfragebetrieb nicht stören	Eigene Instanz, niedrige Priorität
Ist reproduzierbar	Gleiche Eingabe, gleiches Ergebnis – Modell und Zerlegung festnageln

15.5.2 Was mitgeschrieben werden muss

Hier entscheidet sich, ob die Anforderungen aus Kapitel 13 später erfüllbar sind. Jeder Abschnitt braucht:

Feld	Zweck	Ohne dieses Feld
Dokumentkennung	Zuordnung zum Original	Löschung unmöglich
Version oder Prüfsumme	Änderungserkennung	Jede Ingestion verarbeitet alles neu
Berechtigungen	Filter im Abruf – Kapitel 13	Berechtigungsübergreif
Mandant	Trennung	Vermischung
Datenklasse	Zielmodellwahl – Kapitel 13	Klassifikation greift nicht

Feld	Zweck	Ohne dieses Feld
Quelle und Zeitpunkt	Nachvollziehbarkeit, Belege in der Antwort	Antworten ohne Beleg
Modellversion der Einbettung	Erkennen, was neu eingebettet werden muss	Blinder Neuaufbau

ACHTUNG Berechtigungen nachzurüsten ist sehr aufwendig

Wer einen Bestand ohne Berechtigungsfelder einbettet, muss zum Nachrüsten alles neu verarbeiten — inklusive der Einbettungskosten. Bei 500 000 Abschnitten sind das mehrere GPU-Stunden.

Schlimmer ist die Zwischenzeit: Bis zum Neuaufbau liefert das System Treffer ohne Berechtigungsprüfung. Das ist der Fall aus Kapitel 13 — jeder Nutzer kann über eine geschickte Frage Inhalte erfahren, für die er keine Freigabe hat.

Diese Felder gehören deshalb ins erste Design, nicht in die zweite Ausbaustufe.

15.5.3 Änderungserkennung

Ein vollständiger Neuaufbau bei jeder Ausführung ist bei wachsenden Beständen nicht tragfähig. Über Prüfsummen je Dokument lässt sich der Aufwand auf das Nötige begrenzen:

```
for dok in quelle.auflisten():
    pruef = sha256(dok.inhalt).hexdigest()
    vorhanden = db.pruefsumme(dok.id)

    if vorhanden == pruef:
        continue                # unverändert
    if vorhanden is not None:
        db.abschnitte_loeschen(dok.id)  # erst weg,
        db.abschnitte_schreiben(        # dann neu
            dok.id, zerlegen_und_einbetten(dok), pruef)

# Zum Schluss: was in der Quelle fehlt, muss weg
for id in db.dokumente() - quelle.ids():
    db.abschnitte_loeschen(id)
```

MERKE

Die letzte Schleife ist die, die am häufigsten fehlt — und sie ist die datenschutzrelevante: Ein in der Quelle gelöscht Dokument bleibt sonst dauerhaft im Index und taucht weiter in Antworten auf.

Das ist genau die Löschlücke aus Kapitel 13. Sie entsteht nicht durch böse Absicht, sondern dadurch, dass eine Ingestion naheliegenderweise nur das verarbeitet, was da ist.

15.6 Neuaufbau ohne Ausfall

Ein Wechsel des Einbettungsmodells macht den gesamten Bestand ungültig: Vektoren verschiedener Modelle sind nicht vergleichbar. Das ist kein Randfall, sondern

passiert bei jedem Modellwechsel – und der ist so wahrscheinlich wie bei Sprachmodellen.

```
AUSGANGSLAGE
Anwendung → Alias "wissen" → Sammlung wissen_v1 (Modell A)

1 Zweite Sammlung anlegen
  Anwendung → Alias → wissen_v1
                        wissen_v2 (Modell B, leer)

2 Neu einbetten -- laeuft Stunden, stoert nichts
  Anwendung → Alias → wissen_v1 (bedient weiter)
                        wissen_v2 (fuellt sich)

3 Pruefen: Vollstaendigkeit, Stichprobe der Trefferqualitaet

4 Alias umschalten -- ein Vorgang, ohne Ausfall
  Anwendung → Alias → wissen_v2
                        wissen_v1 (bleibt vorerst)

5 Nach einigen Tagen: wissen_v1 loeschen
```

Neuaufbau über eine zweite Sammlung mit Umschaltung

MERKE

Das Muster ist dasselbe wie beim Modellwechsel in Kapitel 8 und beim Canary in Kapitel 10: parallel aufbauen, prüfen, umschalten, alte Version vorhalten. Voraussetzung ist, dass die Anwendung über einen **Alias** zugreift und nicht über den Sammlungsnamen. Diese Indirektion kostet beim Aufbau nichts und ist später nicht mehr nachzurüsten – ohne sie bedeutet jeder Modellwechsel eine Anwendungsänderung.

Der Speicherbedarf verdoppelt sich während des Übergangs. Bei den Größenordnungen aus Abschnitt 15.2 ist das unkritisch; bei sehr großen Beständen gehört es eingeplant.

15.7 Berechtigungen im Abruf

Kapitel 13 hat den Fehler benannt. Hier die Umsetzung.

15.7.1 Filtern statt nachbearbeiten

FALSCH

Suche: 10 beste Treffer
ueber ALLE Abschnitte



Danach filtern



Vielleicht 3 uebrig --
und 7 Plaetze verschenkt

Schlimmer: Wer den Filter
vergisst, liefert alles.

RICHTIG

Suche: 10 beste Treffer
MIT Filter auf die Gruppen
des fragenden Nutzers



10 zulaessige Treffer

Der Filter gehört in die Suche, nicht dahinter

Zwei Probleme mit der linken Variante: Die Trefferliste wird kürzer als angefordert — und wenn der nachgelagerte Filter irgendwo fehlt, gelangen unzulässige Inhalte ins Sprachmodell. Ein Fehler, der keine Ausnahme auslöst.

```
-- pgvector: Filter und Suche in einer Abfrage
SELECT id, text, dokument_id
FROM abschnitte
WHERE mandant = $1
      AND leseberechtigt && $2::text[] -- Gruppen des Nutzers
ORDER BY einbettung <=> $3
LIMIT 10;
```

MERKE

Bei pgvector ist das eine gewöhnliche Bedingung — und die Datenbank kann sie mit der Vektorsuche gemeinsam planen. Das ist der praktische Vorteil, Vektoren und Metadaten in einem System zu halten.

Spezialisierte Vektordatenbanken bieten dafür eigene Filtermechanismen. Wichtig ist bei allen dasselbe: Der Filter muss **während** der Suche wirken, nicht danach. Prüfen Sie das — manche Umsetzungen filtern nachgelagert und liefern dann weniger Treffer als angefordert.

15.7.2 Die Gruppen des Nutzers

Sie stammen aus dem Token — Kapitel 12. Damit schließt sich die Kette: Die Anmeldung liefert die Gruppenzugehörigkeit, das Gateway reicht sie durch, der Abruf filtert danach.

Wo die Nutzeridentität nicht überprüfbar ist — der Fall aus Kapitel 12 —, gilt auch hier die engste Regel: Die Anwendung bekommt nur Zugriff auf einen Bestand, den **alle** ihre Nutzer sehen dürfen.

15.8 Löschen und Auskunft

Kapitel 13 hat die Löschlücke benannt. Ein RAG-System hat mehrere Ablagen, und eine Löschung muss alle erreichen.

Ablage	Was dort liegt	Löschpfad
Quellsystem	Originaldokument	Außerhalb der Plattform
Vektordatenbank	Abschnitte, Einbettungen, Metadaten	Über die Dokumentkennung
Zwischenablage der Ingestion	Extrahierter Text	Frist setzen oder nach Lauf löschen
Antwort-Cache	Antworten mit zitierten Inhalten — Kapitel 11	Wird oft vergessen
Sicherungen	Alles Vorstehende	Nach Ablauf der Sicherheitsfrist

ACHTUNG Der Antwort-Cache ist die unauffälligste Ablage

Eine zwischengespeicherte Antwort kann wörtliche Auszüge aus einem Dokument enthalten, das später gelöscht wurde. Sie wird weiter ausgeliefert, bis die Frist abläuft – und taucht in keiner Löschbetrachtung auf, weil niemand den Cache für einen Datenspeicher hält.

Zwei Maßnahmen: eine kurze Gültigkeit für Antworten aus RAG-Anwendungen, und die Möglichkeit, den Cache bei einer Löschung gezielt zu leeren. Beides ist einfach, wenn man vorher daran denkt.

15.8.1 Auskunft

Auf die Frage, welche Daten zu einer Person gespeichert sind, muss ein RAG-System antworten können. Praktisch heißt das:

1. Abschnitte finden, die auf ein Dokument mit Personenbezug verweisen – über die Metadaten, nicht über eine Volltextsuche in den Einbettungen
2. Verbrauchsdaten des Gateways nach Nutzerkennung durchsuchen – Kapitel 11
3. Zwischenablagen und Cache prüfen

MERKE

Der erste Punkt setzt voraus, dass der Personenbezug in den Metadaten geführt wird – etwa über die Dokumentkennung, die im Quellsystem auflösbar ist. Ohne diese Verbindung ist die Auskunft nur über eine vollständige Durchsicht möglich, und das ist bei einer halben Million Abschnitten nicht praktikabel.

Wieder gilt: Es ist eine Entwurfsentscheidung, keine Betriebsaufgabe.

15.9 Der Abruf im Detail

15.9.1 Was Latenz kostet

Die Abfragestrecke fügt der Antwortzeit etwas hinzu, bevor das Sprachmodell überhaupt beginnt. Kapitel 2 hat gezeigt, dass TTFT die Wahrnehmung prägt – also lohnt die Aufschlüsselung.

Schritt	Dauer	Anmerkung
Einbettung der Frage	10–40 ms	Auf CPU; kurzer Text, kleines Modell
Vektorsuche	5–50 ms	Abhängig davon, ob der Index im Speicher liegt
Nachbewertung	50–300 ms	Optional – der teuerste Posten
Prompt zusammensetzen	< 5 ms	Reine Textarbeit
Summe vor dem Modell	20–400 ms	Kommt vollständig zur TTFT hinzu
Prefill mit Kontext	+200–600 ms	Der Abruf verlängert den Prompt erheblich

MERKE

Die letzte Zeile wird bei der Latenzbetrachtung meist übersehen: Der Abruf fügt nicht nur seine eigene Zeit hinzu, sondern verlängert den Prompt um mehrere tausend Token – und Prefill wächst linear mit der Promptlänge, wie Kapitel 2 gezeigt hat.

Eine RAG-Anfrage mit fünf Abschnitten zu je 512 Token trägt rund 2 500 zusätzliche Token. Das ist der Grund, warum RAG-Anwendungen spürbar träger wirken als reine Chat-Anwendungen – und warum Prefix Caching aus Kapitel 7 hier besonders wertvoll ist, sofern die abgerufenen Abschnitte **hinter** dem Systemprompt stehen.

15.9.2 Nachbewertung: lohnt sie sich?

Ein Nachbewertungsmodell ordnet die gefundenen Abschnitte neu, indem es Frage und Abschnitt gemeinsam betrachtet statt nur ihre Vektoren zu vergleichen. Fachlich bringt das messbar bessere Treffer – betrieblich ist es ein weiterer Dienst.

Aspekt	Bewertung
Zusätzliche Latenz	50 bis 300 ms je Anfrage, abhängig von Modell und Trefferzahl
Zusätzliche Hardware	Ein weiteres Modell – auf CPU langsam, auf GPU nimmt es Speicher vom Sprachmodell
Wirkung	Erlaubt, weniger Abschnitte in den Prompt zu geben – was Prefill spart
Betriebsaufwand	Ein Dienst mehr mit eigenem Rollout und eigenen Metriken

MERKE

Die dritte Zeile enthält die Abwägung: Nachbewertung kostet Zeit vorne und spart Zeit hinten, weil weniger Kontext ins Modell geht. Bei langen Abschnitten und großzügiger Trefferzahl kann sie sich in der Gesamtlatenz sogar auszahlen.

Aus Plattformsicht gilt: Sie ist eine Entscheidung des Anwendungsteams, aber die Plattform sollte sie als **gemeinsamen Dienst** anbieten – nicht jedes Team ein eigenes Modell betreiben lassen. Sonst entstehen fünf schlecht ausgelastete Instanzen, wo eine genügt. Dasselbe Argument wie beim Sprachmodell in Kapitel 6.

15.9.3 Hybride Suche

Vektorsuche findet inhaltlich Ähnliches und versagt bei exakten Zeichenfolgen – Artikelnummern, Fehlercodes, Eigennamen. Volltextsuche kann das, findet aber nichts sinnverwandtes. Eine Kombination beider ist deshalb bei technischen Beständen oft deutlich besser als jede einzelne.

Umsetzung	Aufbau	Einordnung
In einem System	PostgreSQL mit Volltext und pg-vector; OpenSearch mit beidem	Einfacher Betrieb – eine Datenbank, eine Sicherung
Zwei Systeme	Vektordatenbank plus Suchmaschine, Ergebnisse zusammengeführt	Mehr Betriebsaufwand, dafür je Teil das bessere Werkzeug

Für die Auswahl aus Abschnitt 15.3 ist das ein zusätzliches Argument: Wenn hybride Suche absehbar gebraucht wird, spricht es für ein System, das beides kann.

15.10 Parser und Vorverarbeitung

Der unscheinbarste Teil der Strecke und der mit den meisten Betriebsproblemen. Er verarbeitet Dateien unbekannter Herkunft – und ist damit eine Angriffsfläche im Sinne von Kapitel 13.

Format	Typische Probleme	Betriebsfolge
PDF	Mehrspaltig, Tabellen, gescannte Seiten ohne Text	Der aufwendigste Fall; Texterkennung braucht eigene Rechenzeit
Office	Eingebettete Objekte, Änderungsverfolgung, Kommentare	Kommentare können Vertrauliches enthalten
HTML	Navigation und Werbung im Text	Ohne Bereinigung viel Rauschen im Index
Bilder	Kein Text vorhanden	Entweder Texterkennung oder auslassen

ACHTUNG Zwei Fallen im Parser

Sicherheit: Parser für komplexe Formate haben regelmäßig Schwachstellen, und sie verarbeiten Dateien, die Nutzer hochladen. Die Ingestion gehört deshalb in eine eingeschränkte Umgebung: eigener Namensraum, kein Netzwerkzugang außer zur Quelle und zur Datenbank, kein privilegierter Container, begrenzte Ressourcen. Es ist derselbe Grundsatz wie bei den Werkzeugen in Kapitel 13.

Datenschutz: Office-Dokumente enthalten häufig Kommentare, gelöschte Textteile aus der Änderungsverfolgung und Metadaten mit Personennamen. Wer ein Dokument einbettet, bettet das mit ein – und liefert es später möglicherweise in einer Antwort aus. Die Bereinigung gehört in den Parser, nicht in die Hoffnung.

15.10.1 Zerlegung als Betriebsparameter

Die fachliche Frage, wie zerlegt wird, gehört zum Anwendungsteam. Zwei Auswirkungen sind jedoch betrieblich:

Entscheidung	Betriebliche Folge
Abschnittsgröße	Bestimmt die Vektorzahl – und damit Speicher und Kosten aus Abschnitt 15.2
Überlappung	20 Prozent Überlappung bedeuten 20 Prozent mehr Vektoren
Zerlegungsverfahren	Ändert sich es, muss der gesamte Bestand neu aufgebaut werden – wie beim Modellwechsel

MERKE

Die dritte Zeile verdient einen Hinweis an Anwendungsteams: Eine Änderung an der Zerlegung ist genauso teuer wie ein Modellwechsel. Beide Parameter gehören deshalb zusammen mit der Modellversion in die Metadaten – Abschnitt 15.5 – damit erkennbar bleibt, welcher Bestand mit welchen Einstellungen entstanden ist.

15.11 Mehrere Bestände

In der Praxis bleibt es selten bei einem Bestand. Verschiedene Fachbereiche haben eigene Quellen, eigene Berechtigungen und eigene Aktualisierungszyklen.

Aufbau	Vorgehen	Einordnung
Ein Bestand, Filterung	Alles in einer Sammlung, getrennt über Metadaten	Einfach, aber jede Abfrage durchsucht alles
Bestand je Bereich	Getrennte Sammlungen	Der Regelfall. Klare Trennung, eigene Aktualisierung, unabhängiger Neuaufbau
Bestand je Mandant	Bei echter Mandantentrennung	Nötig, wenn Trennung nachweisbar sein muss – Kapitel 13

MERKE

Getrennte Bestände je Fachbereich sind meist die richtige Wahl – nicht aus Leistungsgründen, sondern aus Betriebsgründen: Ein Neuaufbau betrifft nur einen Bereich, eine fehlerhafte Ingestion beschädigt nicht alles, und Berechtigungen sind gröber und damit robuster.

Der Preis ist, dass eine bereichsübergreifende Frage mehrere Bestände abfragen muss. Das ist lösbar – und deutlich einfacher, als eine vermischte Sammlung nachträglich zu trennen.

15.12 Betrieb der Datenbank

Thema	Anforderung	Anmerkung
Sicherung	Konsistente Momentaufnahme	Bei pgvector Teil der bestehenden Sicherung – ein starkes Argument
Wiederherstellung	Geübt, nicht nur eingerichtet	Der Neuaufbau aus den Quellen ist die zweite Absicherung
Hochverfügbarkeit	Je nach Anspruch	Bei RAG oft geringer als beim Gateway – Ausfall bedeutet schlechtere Antworten, nicht Stillstand
Speicher	Arbeitsspeicher entscheidet	Ein Index, der nicht hineinpasst, macht die Suche um Größenordnungen langsamer
Überwachung	Latenz, Trefferzahl, Indexgröße	Kapitel 14

MERKE

Die dritte Zeile ist eine hilfreiche Einordnung: Fällt die Vektordatenbank aus, kann eine gut gebaute Anwendung ohne Abruf antworten – schlechter, aber sie antwortet. Fällt das Gateway aus, geht gar nichts.

Das rechtfertigt einen geringeren Aufwand für Hochverfügbarkeit – vorausgesetzt, die Anwendung fängt den Ausfall ab, statt einen Fehler zu liefern. Diese Anforderung gehört in die Schnittstellenbeschreibung.

15.12.1 Kennzahlen

Kennzahl	Aussage	Alarmwert
Suchlatenz, 95. Perzentil	Antwortzeit der Datenbank	Über 200 ms — prüfen, ob der Index in den Speicher passt
Trefferzahl je Abfrage	Liefert der Filter zu wenig	Häufig unter dem Angeforderten — Berechtigungen prüfen
Indexgröße	Wachstum des Bestands	Nähert sich dem Arbeitsspeicher
Ingestion-Dauer	Aufwand je Lauf	Überschreitet das Zeitfenster
Alter des ältesten Dokuments	Aktualität des Bestands	Überschreitet die zugesagte Frische

Die letzte Zeile ist eine Kennzahl, die es sonst kaum gibt und die hier wichtig ist: Ein RAG-System liefert stillschweigend veraltete Antworten, wenn die Ingestion nicht läuft. Es gibt keinen Fehler — nur schlechtere Antworten.

15.13 Das Einbettungsmodell als Plattformscheidung

Kapitel 8 hat gezeigt, wie ein Einbettungsdienst betrieben wird. Welches Modell darin läuft, ist eine Entscheidung mit ungewöhnlich langer Bindung — und sie gehört deshalb zur Plattform, nicht zum einzelnen Anwendungsteam.

Kriterium	Betriebliche Bedeutung
Dimension	Bestimmt den Speicherbedarf unmittelbar — 1 024 gegen 384 Dimensionen sind Faktor 2,7 — Abschnitt 15.2
Mehrsprachigkeit	Bei deutschsprachigen Beständen entscheidend. Rein englische Modelle liefern erkennbar schlechtere Treffer
Maximale Eingabelänge	Begrenzt die Abschnittsgröße nach oben
Größe des Modells	Unter 1 GiB läuft es auf CPU — Kapitel 8
Pflegezustand	Ein aufgegebenes Modell bedeutet später einen vollständigen Neuaufbau

MERKE

Die Dimension ist der Parameter mit der größten Hebelwirkung und wird am wenigsten beachtet: Ein Modell mit 384 Dimensionen belegt weniger als die Hälfte des Speichers eines Modells mit 1 024 — bei einer halben Million Abschnitte also rund 1,5 statt 4 GiB inklusive Index.

Ob die höhere Dimension bessere Treffer liefert, ist fachlich zu prüfen — und zwar am eigenen Bestand, mit demselben Vorgehen wie beim Prüfsatz aus Kapitel 3. Die Annahme „größer ist besser“ trägt bei Einbettungsmodellen weniger weit als bei Sprachmodellen.

Weil ein Wechsel den vollständigen Neuaufbau nach Abschnitt 15.6 erzwingt, gilt: Die Auswahl gehört einmal sorgfältig getroffen und danach lange beibehalten. Eine Plattform, die für alle Bestände dasselbe Einbettungsmodell verwendet, spart sich

außerdem einen zweiten Dienst – und die Frage, welcher Bestand mit welchem Modell entstanden ist.

15.14 Qualität messen, ohne Data Scientist zu sein

Der Plattformbetreiber verantwortet nicht die Antwortqualität. Er sollte aber merken, wenn sie sich verschlechtert – besonders nach einem Neuaufbau oder Modellwechsel.

Messung	Wie	Aussage
Prüffragen	20 bis 50 Fragen mit bekannten Zieldokumenten	Der praktikable Weg – vor und nach jeder Änderung
Trefferrang	Auf welchem Platz erscheint das erwartete Dokument	Verschlechtert sich messbar bei falscher Konfiguration
Leere Trefferlisten	Anteil der Abfragen ohne Treffer	Deutet auf zu enge Filter oder falsche Einbettung
Nutzerrückmeldung	Bewertung in der Anwendung	Träge, aber die einzige fachliche Wahrheit

MERKE

Ein Satz von Prüffragen mit erwarteten Zieldokumenten ist das Gegenstück zum Prüfsatz aus Kapitel 3 – und ebenso wertvoll. Er wird einmal gemeinsam mit dem Fachbereich erstellt, liegt versioniert im Repository und läuft vor jeder Umschaltung nach Abschnitt 15.6.

Er ersetzt keine fachliche Bewertung. Er beantwortet aber die Frage, die ein Plattformbetreiber beantworten können muss: **Ist es nach meiner Änderung schlechter geworden?**

```
treffer = 0
for frage, erwartet in pruefsatz:
    ergebnis = suche(frage, limit=5)
    ids = [t.dokument_id for t in ergebnis]
    if erwartet in ids:
        treffer += 1

print(f"Zieldokument unter den ersten 5: "
      f"{treffer}/{len(pruefsatz)}")
```

Erwartete Ausgabe: Ein Wert, der vor und nach einer Änderung vergleichbar ist. Ein Einbruch nach einem Neuaufbau bedeutet, dass etwas mit Modell, Zerlegung oder Index nicht stimmt – und zwar bevor Nutzer es bemerken.

15.15 Zusammenspiel mit dem Gateway

Eine RAG-Anwendung stellt zwei verschiedene Anfragen an die Plattform, und sie sollten getrennt behandelt werden.

Anfrageart	Ziel	Kontingent und Kosten
Einbettung der Frage	Einbettungsdienst	Sehr günstig, hohe Rate zulässig

Anfrageart	Ziel	Kontingent und Kosten
Einbettung bei Ingestion	Einbettungsdienst	Große Mengen — eigenes Kontingent, sonst verdrängt es den Abfragebetrieb
Antwortgenerierung	Sprachmodell	Teuer, Hauptanteil der Kosten

MERKE

Die mittlere Zeile ist der praktische Fallstrick: Eine Ingestion mit einer Million Abschnitten erzeugt eine Million Einbettungsanfragen. Ohne eigenes Kontingent verbraucht sie das Budget des Teams und blockiert dessen Abfragebetrieb — mitten in einem Vorgang, den niemand beobachtet, weil er nachts läuft.

Die Lösung ist ein getrennter Schlüssel für die Ingestion, mit eigenem Kontingent und eigener Kostenstelle. Damit wird zugleich sichtbar, was der Aufbau eines Bestands tatsächlich kostet — eine Zahl, die sonst niemand kennt.

Für die Kostenrechnung aus Kapitel 14 bedeutet das: Der einmalige Aufbau eines Bestands ist ein **Investitionsposten**, kein laufender Betrieb. Er gehört getrennt ausgewiesen, sonst verzerrt er den Monatsvergleich in dem Monat, in dem er anfällt.

15.16 Lab: Eine Abrufstrecke betreiben

LAB Von der Ingestion bis zur gefilterten Suche

Ziel: Eine vollständige Strecke aufbauen und die beiden Anforderungen aus Kapitel 13 — Berechtigungsfilter und Lösbarkeit — praktisch prüfen.

Voraussetzung: PostgreSQL mit pgvector, Einbettungsdienst aus Kapitel 8.

Schritt 1 — Schema anlegen. Mit allen Feldern aus Abschnitt 15.5:

```
CREATE EXTENSION IF NOT EXISTS vector;

CREATE TABLE abschnitte (
  id                bigserial PRIMARY KEY,
  dokument_id       text NOT NULL,
  pruefsumme        text NOT NULL,
  mandant           text NOT NULL,
  leseberechtigt    text[] NOT NULL,
  datenklasse       text NOT NULL,
  quelle            text,
  modellversion     text NOT NULL,
  text              text NOT NULL,
  einbettung        vector(1024) NOT NULL
);

CREATE INDEX ON abschnitte
  USING hnsu (einbettung vector_cosine_ops);
CREATE INDEX ON abschnitte (dokument_id);
CREATE INDEX ON abschnitte (mandant);
```

Schritt 2 – Testbestand einbetten. Zwei Dokumentgruppen mit unterschiedlichen Berechtigungen – etwa ["alle"] und ["recht"].

Schritt 3 – Ohne Filter suchen. Zur Veranschaulichung des Fehlers aus Kapitel 13:

```
SELECT dokument_id, leseberechtigt, text
FROM abschnitte
ORDER BY einbettung <=> $1 LIMIT 5;
```

Erwartete Ausgabe: Treffer aus **beiden** Gruppen. Genau so gelangen Inhalte ins Sprachmodell, für die der Nutzer keine Freigabe hat.

Schritt 4 – Mit Filter suchen. Dieselbe Abfrage mit der Bedingung aus Abschnitt 15.7 und den Gruppen {alle}.

Erwartete Ausgabe: Nur Treffer der zulässigen Gruppe – und weiterhin fünf, weil der Filter **in** der Suche wirkt.

Schritt 5 – Indexgröße prüfen.

```
SELECT pg_size_pretty(pg_relation_size('abschnitte')) AS daten,
       pg_size_pretty(pg_indexes_size('abschnitte')) AS index;
```

Vergleichen Sie mit der Rechnung aus Abschnitt 15.2. **Erwartung:** Der Index liegt in der Größenordnung der Daten.

Schritt 6 – Löschen und nachweisen.

```
DELETE FROM abschnitte WHERE dokument_id = 'dok-042';
SELECT count(*) FROM abschnitte WHERE dokument_id = 'dok-042';
```

Erwartete Ausgabe: 0. Prüfen Sie anschließend, ob eine zuvor gestellte Frage zu diesem Dokument noch aus dem Antwort-Cache beantwortet wird – der Punkt aus Abschnitt 15.8.

Schritt 7 – Neuaufbau üben. Legen Sie eine zweite Tabelle mit einem anderen Einbettungsmodell an, füllen Sie sie, und schalten Sie über eine Ansicht um. Die Anwendung merkt nichts.

Ergebnis: Eine Strecke, die filtert, löscht und ohne Ausfall umgebaut werden kann. Antwortqualität ist damit noch nicht bewertet – das bleibt Aufgabe des Anwendungsteams.

15.17 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Suche plötzlich um Größenordnungen langsamer	Index passt nicht mehr in den Arbeitsspeicher	Indexgröße gegen verfügbaren Speicher	Speicher erhöhen oder Vektoren komprimieren
Weniger Treffer als angefordert	Filter wirkt nachgelagert statt in der Suche	Abfrageplan ansehen	Filter in die Suchbedingung ziehen
Nutzer sieht fremde Inhalte	Berechtigungsfilter fehlt oder Metadaten unvollständig	Stichprobe: Abfrage ohne Filter gegen eine mit	Filter erzwingen; fehlende Felder nachtragen – aufwendig

Symptom	Ursache	Diagnose	Behebung
Antworten beziehen sich auf gelöschte Dokumente	Löschung nicht bis in den Index durchgereicht	Dokumentkennung im Index suchen	Abgleichschleife aus Abschnitt 15.5 ergänzen
Ingestion läuft immer länger	Keine Änderungserkennung — alles wird neu verarbeitet	Verhältnis verarbeiteter zu geänderten Dokumenten	Prüfsummenvergleich einführen
Trefferqualität nach Modellwechsel schlechter	Bestand teilweise mit altem Modell eingebettet	Modellversionen im Bestand zählen	Vollständig neu aufbauen — Abschnitt 15.6
Abfragedienst wird während der Ingestion langsam	Beide Strecken auf derselben Instanz	Zeitliche Korrelation prüfen	Ingestion trennen und mit niedriger Priorität fahren

15.18 Interviewfragen

INTERVIEWFRAGE

Beschreiben Sie eine RAG-Pipeline aus Betreibersicht.

Gut ist die Kette: Dokument, Parser, Zerlegung, Einbettung, Vektordatenbank, Abruf, Prompt, Modell.

Senior ist die Trennung in **zwei** Strecken mit gegensätzlichem Lastprofil: Ingestion als seltener Stapelauftrag mit hoher, planbarer Last — GPU sinnvoll — und Abfrage als latenzkritischer Dauerdienst mit geringer Last, für den ein CPU-Knoten meist genügt. Wer beides zusammenlegt, hat einen Abfragedienst, der während jeder Ingestion langsam wird.

INTERVIEWFRAGE

Welche Vektordatenbank würden Sie wählen?

Schwach ist eine Nennung ohne Rückfrage.

Senior beginnt mit der Kapazitätsrechnung: 50 000 Dokumente ergeben rund eine halbe Million Abschnitte und mit Index etwa fünf Gigabyte — das passt in den Arbeitsspeicher eines gewöhnlichen Knotens. Unterhalb einiger Millionen Vektoren ist die Wahl damit keine Kapazitätsfrage.

Daraus folgt die Empfehlung: pgvector, wenn PostgreSQL ohnehin betrieben wird — ein System weniger, erprobte Sicherung, und Vektoren, Metadaten und Berechtigungen in einer Transaktion. Spezialisierte Datenbanken lohnen bei größeren Beständen, hoher Abfragerate oder aufwendiger Filterung.

INTERVIEWFRAGE

Wie verhindern Sie, dass ein Nutzer über RAG Inhalte erfährt, die er nicht sehen darf?

Senior ist die klare Aussage: Der Berechtigungsfilter muss **in** der Suche wirken, nicht danach. Nachgelagertes Filtern liefert zu wenige Treffer – und wenn es irgendwo vergessen wird, gelangen unzulässige Inhalte ins Modell, ohne dass ein Fehler auftritt. Voraussetzung ist, dass die Berechtigungen bei der Ingestion je Abschnitt mitgeschrieben werden. Wer das nachrüsten muss, verarbeitet den gesamten Bestand neu – und liefert bis dahin ungefilterte Treffer. Die Gruppen des Nutzers stammen aus dem Token, womit sich die Kette zu Kapitel 12 schließt.

INTERVIEWFRAGE

Sie wechseln das Einbettungsmodell. Was passiert?

Senior ist: Der gesamte Bestand wird ungültig, weil Vektoren verschiedener Modelle nicht vergleichbar sind. Der Ablauf ist derselbe wie bei jedem Rollout in diesem Buch: zweite Sammlung anlegen, parallel neu einbetten – was Stunden dauert und den Betrieb nicht stört –, Vollständigkeit und Trefferqualität prüfen, Alias umschalten, alte Sammlung einige Tage vorhalten.

Voraussetzung ist der Zugriff über einen Alias statt über den Sammlungsnamen. Diese Indirektion kostet beim Aufbau nichts und ist später nicht nachzurüsten.

INTERVIEWFRAGE

Ein Dokument muss gelöscht werden. Wo überall?

Senior zählt alle Ablagen auf: Quellsystem, Vektordatenbank über die Dokumentkennung, Zwischenablage der Ingestion, Sicherungen nach Ablauf ihrer Frist – und den Antwort-Cache des Gateways, der am häufigsten vergessen wird, weil ihn niemand für einen Datenspeicher hält.

Dazu die Ergänzung, dass eine Ingestion ohne Abgleichschleife gelöschte Dokumente gar nicht bemerkt: Sie verarbeitet, was da ist, und lässt im Index stehen, was verschwunden ist.

15.19 Zusammenfassung

- RAG besteht aus zwei Strecken mit gegensätzlichem Lastprofil. Sie gehören getrennt dimensioniert und betrieben.
- Die Kapazitätsrechnung führt bei üblichen Unternehmensbeständen auf wenige Gigabyte. Unterhalb einiger Millionen Vektoren ist die Datenbankwahl keine Kapazitätsfrage.
- pgvector ist der Regelfall, wenn PostgreSQL ohnehin betrieben wird: erprobte Sicherung, ein System weniger – und Vektoren, Metadaten und Berechtigungen in einer Transaktion.
- Der HNSW-Index belegt zusätzlich 50 bis 100 Prozent der Vektorgröße. Die Suchtiefe ist zur Laufzeit änderbar und damit die wichtigste Stellschraube.
- Bei der Ingestion müssen Berechtigungen, Mandant, Datenklasse, Prüfsumme und Modellversion je Abschnitt mitgeschrieben werden. Nachrüsten bedeutet vollständige Neuverarbeitung.

- Die Abgleichschleife für gelöschte Quelldokumente fehlt am häufigsten – und sie ist die datenschutzrelevante.
- Ein Modellwechsel macht den Bestand ungültig. Der Neuaufbau läuft über eine zweite Sammlung mit Aliasumschaltung; die Anwendung muss über den Alias zugreifen.
- Der Berechtigungsfilter gehört in die Suche, nicht dahinter. Nachgelagertes Filtern liefert zu wenige Treffer und schlägt bei Auslassung stillschweigend fehl.
- Löschungen müssen alle Ablagen erreichen – einschließlich des Antwort-Caches.
- Der Ausfall der Vektordatenbank bedeutet schlechtere Antworten, nicht Stillstand – vorausgesetzt, die Anwendung fängt ihn ab.

Quellen und Weiterlesen

- pgvector: *Documentation* – Indexverfahren, Operatoren und Zusammenspiel mit gewöhnlichen Bedingungen.
- Qdrant: *Documentation* – *Filtering* und *Collections*. Filterung während der Suche, Alias-Verwaltung.
- Malkov und Yashunin: *Efficient and robust approximate nearest neighbor search using Hierarchical Navigable Small World graphs* – Grundlage des HNSW-Verfahrens.
- OpenSearch und Milvus: jeweilige Dokumentation – für die Auswahlentscheidung gegen die eigene Bestandsgröße und die vorhandene Betriebslandschaft prüfen.

Model Lifecycle, GitOps und Delivery

ZIEL	Eine Modellversion reproduzierbar in Produktion bringen — und wieder heraus. Dazu die Frage beantworten, was bei einem Totalverlust wiederherzustellen ist und in welcher Reihenfolge.
SETZT VORAUS	Kapitel 8 und 10 — Deployment und InferenceService — sowie Kapitel 12 — Secrets in einer GitOps-Kette.
DANACH KANNST DU	Modelle als versionierte Artefakte führen, eine Delivery-Kette von der Freigabe bis zur Produktion bauen, Umgebungen sauber trennen, Rollbacks in Minuten statt Stunden fahren und einen belastbaren Wiederanlaufplan aufstellen.

GESCHRIEBEN GEGEN

ArgoCD 2.13.x · Harbor 2.11.x · Kubernetes 1.31 · Stand September 2026

GitOps als Verfahren wird vorausgesetzt — es ist klassische Plattformarbeit. Neu ist, was passiert, wenn das auszuliefernde Artefakt zwanzig Gigabyte groß ist, Minuten zum Laden braucht und sich nicht sinnvoll in ein Repository legen lässt.

16.1 Das Grundproblem

ANWENDUNG		MODELL
Groesse	wenige hundert MB	5 bis 200 GB
Herkunft	selbst gebaut	Dritte -- Kapitel 3
Aenderung	taeglich	selten
Start	Sekunden	Minuten
Im Git	Quellcode ja	Gewichte nein
Rollback	Image-Tag zurueck	Modell neu laden?
Pruefung	Testsuite	fachlicher Pruefsatz
Gemeinsam ist nur eines: Beide brauchen eine VERSION, die im Git steht.		

Zwei Artefakte mit gegensätzlichen Eigenschaften

MERKE

Die letzte Zeile ist der Ausweg. Das Modell selbst gehört nicht ins Repository — seine **Referenz** schon: Pfad, Version, Prüfsumme. Damit wird der Modellwechsel zu einer gewöhnlichen, geprüften und nachvollziehbaren Änderung an einer Textdatei — und die Delivery-Kette funktioniert wie bei jeder anderen Komponente.

Alles Weitere in diesem Kapitel folgt aus dieser Trennung: Artefakt im Speicher, Referenz im Git.

16.2 Modelle als Artefakte

16.2.1 Wo sie liegen

Ablage	Eignung	Einordnung
Objektspeicher	Der Regelfall. Versionierte Pfade, günstig, gut zu sichern	Braucht eine eigene Zugriffskontrolle
Registry als OCI-Artefakt	Modell neben den Images	Nutzt vorhandene Signatur- und Cache-Mechanik – Kapitel 10
Persistentes Volume	Schnellster Zugriff	Keine Versionierung von sich aus
Externes Repository	Nur als Quelle	Nicht als Produktionsablage – Kapitel 3

16.2.2 Die Ordnung im Speicher

```
s3://modelle/
├─ qwen2.5-7b-instruct/
│   └─ awq-2026-03-15/           Format und Aufnahmedatum
│       └─ config.json
│       └─ model-*.safetensors
│       └─ MANIFEST.json       Herkunft, Prüfsummen, Freigabe
├─ awq-2026-08-02/
├─ bge-m3/
└─ fp16-2026-01-20/
```


MERKE

Zwei Regeln machen den Unterschied. Erstens: **Ein Verzeichnis je Version, niemals überschreiben.** Kapitel 8 hat begründet, warum – ohne getrennte Verzeichnisse ist ein Rollback ein erneuter Ladevorgang von Minuten, genau dann, wenn es eilt.

Zweitens: Ein Beschreibungsdokument je Version, das Herkunft, Prüfsummen, verwendete Quantisierung und Freigabestand festhält. Es ist die Antwort auf die Frage aus Kapitel 3 – woher stammt dieses Modell – und auf die aus Kapitel 13 – wer hat es freigegeben.

```
{
  "modell": "Qwen/Qwen2.5-7B-Instruct-AWQ",
  "quelle": "huggingface",
  "revision": "alb2c3d4",
  "aufgenommen": "2026-03-15",
  "pruefsummen": {"model-00001.safetensors": "sha256:..."},
  "quantisierung": {"verfahren": "awq", "bits": 4},
  "datenklasse": "vertraulich",
  "freigabe": {"datum": "2026-03-18",
               "durch": "plattform+datenschutz"},
  "pruefsatz": {"formattreue": "20/20", "stichprobe": "bestanden"}
}
```


16.3 Die Delivery-Kette



Vom externen Repository bis in die Produktion

MERKE

Schritt 3 ist der, der eine KI-Plattform von einer gewöhnlichen unterscheidet. Bei einer Anwendung entscheidet eine Testsuite über die Freigabe — sie ist automatisiert und eindeutig. Bei einem Modell entscheidet ein **fachlicher** Prüfsatz, dessen Bewertung teilweise menschlich ist.

Das bedeutet nicht, dass die Kette manuell sein muss: Die maschinell prüfbaren Teile — Formattreue, Antwortzeiten, Trefferrang bei RAG — laufen automatisch. Aber die Freigabe ist ein Vorgang mit einer Person, und das gehört im Ablauf abgebildet.

16.4 Umgebungen

16.4.1 Was sich unterscheidet

	dev	stage	prod
GPU	geteilt, Time-Slicing — Kapitel 6	eine Karte	dedizierte Knoten
Modell	klein, schnell	wie prod	freigegeben
Repliken	1	1	2 oder mehr
Kontingente	eng	wie prod	je Team
Daten	Testdaten	anonymisiert	echt
Zugriff	Team	Team	nur über Gateway

ACHTUNG Die Zeile mit den Daten ist die kritische

Eine Vorproduktionsumgebung mit echten Daten ist eine Produktionsumgebung mit schwächerem Schutz. Das gilt bei KI-Plattformen besonders, weil dort echte Prompts verarbeitet werden – mit allem, was Nutzer hineinschreiben.

Wenn zum Testen realistische Daten nötig sind, gehören sie anonymisiert. Wenn das fachlich nicht geht, muss die Umgebung dieselben Schutzmaßnahmen tragen wie die Produktion – einschließlich Egress-Kontrolle und Protokollierungsregeln aus Kapitel 13.

16.4.2 Trennung von Konfiguration

Die Modellversion unterscheidet sich zwischen Umgebungen, die Struktur nicht. Eine Aufteilung in Basis und Umgebungsüberlagerung bildet das ab:

```
gitops/
├─ basis/
│   ├── inferencesevice.yaml
│   ├── gateway.yaml
│   └── kustomization.yaml
└─ umgebungen/
    ├── dev/
    │   ├── kustomization.yaml
    │   ├── werte.yaml          modell.version: awq-2026-08-02
    ├── stage/
    └── prod/
        ├── werte.yaml          modell.version: awq-2026-03-15
```

MERKE

Die beiden Zeilen am Ende zeigen den Normalzustand einer gepflegten Plattform: Produktion läuft auf einer älteren, geprüften Version, während in der Entwicklung bereits die nächste getestet wird. Der Unterschied ist **sichtbar** und **eine Zeile groß** – das ist der eigentliche Gewinn.

16.5 Promotion und Rollback**16.5.1 Der Weg nach vorne**

1. Neue Version aufnehmen und prüfen – Schritte 1 bis 3 aus Abschnitt 16.3
2. In dev referenzieren, Abgleich abwarten
3. Automatisierte Prüfungen laufen lassen: Startet der Dienst? Stimmt die KV-Cache-Größe? Besteht der Formattest?
4. In stage referenzieren, Prüfsatz vollständig fahren, Lastmessung nach Kapitel 8
5. In prod referenzieren – mit Canary nach Kapitel 10, sofern Kapazität vorhanden
6. Alte Version mindestens zwei Wochen vorhalten

16.5.2 Der Weg zurück

Fall	Maßnahme	Dauer
Modell antwortet schlechter	Version in <code>werte.yaml</code> zurücksetzen	Minuten – sofern das Verzeichnis noch existiert

Schritt 3 lässt sich vollständig automatisieren und fängt die Mehrzahl der Fehler – meist Konfigurationsfehler, die nichts mit dem Modell zu tun haben.

Fall	Maßnahme	Dauer
Dienst startet nicht	Dasselbe	Minuten
Canary läuft noch	Verkehrsanteil auf null – Kapitel 10	Sekunden
Konfigurationsfehler	Änderung zurücknehmen	Minuten
Modellverzeichnis gelöscht	Erneut aus der Quelle laden	Stunden – der vermeidbare Fall

MERKE

Die letzte Zeile ist der Grund für die Aufbewahrungsregel. Ein Rollback ist genau so lange eine Zeilenänderung, wie das alte Verzeichnis existiert. Wer aufräumt, verwandelt einen Minutenvorgang in einen Stundenvorgang – und zwar in dem Moment, in dem es eilt.

Zwei Wochen Vorhaltezeit kosten bei den Größenordnungen aus Kapitel 3 wenige zehn Gigabyte Objektspeicher. Das ist die günstigste Versicherung der ganzen Plattform.

16.6 Was ArgoCD nicht kann

Ein GitOps-Werkzeug gleicht den **Sollzustand** mit dem **Istzustand** ab. Bei Modellen stößt das an eine Grenze, die man kennen sollte.

Erwartung	Realität
Abgleich bedeutet, das Modell ist aktuell	Der Abgleich prüft das Manifest , nicht den Inhalt des Objektspeichers
Eine Änderung wird sofort wirksam	Der Pod startet neu und lädt Minuten – Kapitel 8
Abweichung wird erkannt	Ein von Hand ausgetauschtes Modell unter demselben Pfad bleibt unbemerkt

ACHTUNG Der unsichtbare Modellwechsel

Wird ein Modellverzeichnis im Objektspeicher überschrieben, ohne dass sich die Referenz ändert, bemerkt das Werkzeug nichts – der Sollzustand ist unverändert. Beim nächsten Neustart lädt der Dienst ein anderes Modell als zuvor, und niemand weiß davon.

Zwei Gegenmaßnahmen: Modellverzeichnisse werden **nie** überschrieben – die Regel aus Abschnitt 16.2 – und der Schreibzugriff auf den Modellspeicher ist auf den Aufnahmevorgang beschränkt. Die Inferenz-Knoten lesen nur, wie Kapitel 8 im Manifest festgelegt hat.

16.6.1 Prüfsummen als Absicherung

Wo der Aufwand vertretbar ist, prüft ein Init-Container die Prüfsummen aus dem Beschreibungsdokument, bevor der Dienst startet:

```
cd /modelle
jq -r '.pruefsummen | to_entries[]
  | "\(.value|sub("sha256:");")" \(.key)"' \
```

```
MANIFEST.json > /tmp/summen  
sha256sum -c /tmp/summen || exit 1
```

Das kostet bei großen Modellen einige Sekunden und schließt eine Fehlerklasse aus, die sonst erst durch merkwürdige Antworten auffällt.

16.7 Der Modellkatalog

Kapitel 13 hat ihn gefordert. Er lässt sich als Datei im Repository führen und ist damit selbst versioniert und geprüft.

```
modelle:  
- name: unternehmen-chat  
  pfad: qwen2.5-7b-instruct/awq-2026-03-15  
  zweck: Allgemeiner Assistent, Dialog und Zusammenfassung  
  datenklasse: vertraulich  
  ziel: lokal  
  freigabe: 2026-03-18  
  kontext: 8192  
  verantwortlich: plattformteam  
  
- name: extern-gross  
  zweck: Komplexe Analysen ohne schutzwuerdige Daten  
  datenklasse: intern  
  ziel: azure  
  vertrag: AVV-2025-114  
  freigabe: 2025-11-02
```

MERKE

Diese Datei erfüllt drei Zwecke gleichzeitig: Sie erzeugt die Gateway-Konfiguration aus Kapitel 11, sie ist der Nachweis für die Betreiberpflichten aus Kapitel 13, und sie ist die Dokumentation für Anwendungsteams.

Der Gewinn liegt darin, dass eine Änderung daran denselben Weg nimmt wie jede andere Änderung: Vorschlag, Prüfung, Zustimmung, Abgleich. Damit ist die Freigabe eines Modells nachvollziehbar, ohne dass ein eigener Vorgang dafür gebaut werden muss.

16.8 Das Referenz-Repository

Die Struktur, auf die dieses Buch hinarbeitet. Sie ist bewusst flach gehalten — jede Ebene mehr kostet Übersicht.

enterprise-ai-platform/		
└─ infrastruktur/	Was unterhalb von Kubernetes liegt	
└─ terraform/	Knoten, Netze, Objektspeicher	
└─ ansible/	Treiber, Container Toolkit (Kap. 4)	
└─ plattform/	Cluster-Komponenten	
└─ gpu-operator/	ClusterPolicy	(Kap. 5)
└─ kserve/	ClusterServingRuntime	(Kap. 10)
└─ keycloak/	Realm, Clients, Mapper	(Kap. 12)
└─ openbao/	Policies, Auth-Rollen	(Kap. 12)
└─ monitoring/	Regeln, Dashboards	(Kap. 14)
└─ netzwerk/	NetworkPolicies	(Kap. 13)
└─ dienste/	Was die Plattform anbietet	
└─ gateway/	LiteLLM-Konfiguration	(Kap. 11)
└─ inferenz/	InferenceServices	(Kap. 10)
└─ einbettung/	Einbettungsdienst	(Kap. 8)
└─ rag/	Ingestion, Vektor-DB	(Kap. 15)
└─ katalog/		
└─ modelle.yaml	Zweck, Datenklasse, Freigabe	(Kap. 13)
└─ teams.yaml	Kontingente, Allowlists	(Kap. 11)
└─ umgebungen/		
└─ dev/ stage/ prod/	nur Werte, keine Struktur	
└─ pruefsaetze/	Fachliche Pruefung	
└─ formattreue/	(Kap. 3)	
└─ abruf/	(Kap. 15)	
└─ doku/		
└─ architektur.md		
└─ runbooks/	Wiederanlauf, Rotation, Wartung	
└─ entscheidungen/	Warum es so ist, wie es ist	

Repository-Struktur einer Enterprise AI Plattform

MERKE

Zwei Verzeichnisse sind ungewöhnlich und wichtig.

katalog/ enthält keine Kubernetes-Manifeste, sondern die fachliche Wahrheit über Modelle und Teams. Daraus werden Gateway-Konfiguration und Nachweise erzeugt – Kapitel 13 hat begründet, warum das eine versionierte Datei sein sollte.

pruefsaetze/ enthält die fachlichen Prüfungen aus Kapitel 3 und 15. Sie sind Plattform-Artefakte mit langer Lebensdauer und gehören nicht auf einen Laptop.

16.8.1 Entscheidungen dokumentieren

Das Verzeichnis `doku/entscheidungen/` verdient einen eigenen Hinweis. Eine KI-Plattform trifft eine Reihe von Entscheidungen, deren Begründung nach einem Jahr niemand mehr kennt:

Entscheidung	Wird später gefragt
Warum dieses Modell	Wenn ein besseres erscheint – Kapitel 3
Warum diese Quantisierung	Wenn die Qualität diskutiert wird
Warum diese Kontextgrenze	Wenn eine Anwendung mehr braucht – Kapitel 2
Warum keine Inhaltsprotokollierung	Bei jeder Prüfung – Kapitel 11 und 13

Die letzte Zeile ist die, die man am dringendsten belegen können muss: Der zweite Knoten sieht wie Reserve aus und ist die Voraussetzung für Wartung ohne Ausfall.

Entscheidung	Wird später gefragt
Warum diese Vektordatenbank	Wenn jemand eine andere vorschlägt — Kapitel 15
Warum zwei GPU-Knoten	Wenn gespart werden soll — Kapitel 4 und 9

Ein kurzer Eintrag je Entscheidung — Sachlage, Alternativen, Wahl, Begründung — genügt. Er kostet zwanzig Minuten und erspart später eine Diskussion, die ohne ihn sachlich nicht mehr führbar ist.

16.9 Was Modellpflege bedeutet

Ein häufiges Missverständnis bei Plattformvorhaben: Nach dem Aufbau sei die Arbeit getan. Tatsächlich entsteht ein wiederkehrender Aufwand, der eingeplant gehört.

Aufgabe	Rhythmus	Aufwand
Modellversionen prüfen und aufnehmen	quartalsweise	Tage — inkl. Prüfsatz
Inferenz-Server aktualisieren	quartalsweise	Tage — Kapazitätsgrenzen können sich ändern
Treiber und GPU Operator	halbjährlich	Tage — Wartungsfenster, Kapitel 5
Secrets rotieren	halbjährlich	Stunden — Kapitel 12
Prüfsätze erweitern	laufend	Stunden — mit dem Fachbereich
Vektorbestände neu aufbauen	bei Modellwechsel	Tage — Kapitel 15
Kostenpreis nachrechnen	quartalsweise	Stunden — Kapitel 14
Katalog und Nachweise pflegen	laufend	Stunden

MERKE

In Summe ist das ein erheblicher Anteil einer Stelle — und zwar dauerhaft, nicht nur im Aufbau. Das gehört in die Planung, weil sonst genau diese Arbeiten liegen bleiben: Sie sind nicht dringend, bis sie es plötzlich sind.

Der zweite Punkt der Tabelle ist der unterschätzte: Ein Update des Inferenz-Servers kann Voreinstellungen ändern — etwa beim Token-Budget oder beim Chunked Prefill — und damit die gemessenen Kapazitätsgrenzen aus Kapitel 8 verschieben. Nach jedem Update gehört die Rampenmessung wiederholt.

16.10 Wiederanlauf

Die Frage, die selten gestellt und noch seltener geübt wird: Was ist zu tun, wenn der Cluster verloren ist?

16.10.1 Was wiederhergestellt werden muss

Bestandteil	Quelle	Dauer	Ohne ihn
Cluster	Infrastruktur als Code	Stunden	nichts geht
Plattformkonfiguration	Git	Minuten	nichts geht

Bestandteil	Quelle	Dauer	Ohne ihn
Secrets	OpenBao-Sicherung	Minuten	nichts geht – Kapitel 12
Gateway-Datenbank	Sicherung	Minuten	keine Schlüssel, kein Verbrauch
Modelle	Objektspeicher	Stunden	Dienste starten nicht
Vektorbestand	Sicherung oder Neuaufbau	Stunden bis Tage	schlechtere Antworten – Kapitel 15
Metriken	Sicherung	–	Historie fehlt, Betrieb läuft

MERKE

Die dritte Zeile ist die kritischste und wird bei Wiederanlaufplänen am häufigsten vergessen: Ohne die Sicherung des Secret-Speichers – und ohne die Entsiegelungsschlüssel aus Kapitel 12 – ist der Wiederanlauf nicht möglich. Alle Zugangsdaten müssten neu beschafft werden, von der Anbieter-API bis zur Datenbank.

Diese Sicherung gehört an einen Ort, der **unabhängig** vom Cluster ist. Eine Sicherung des Secret-Speichers, die im selben Cluster liegt, ist keine.

16.10.2 Die Reihenfolge

1. Cluster aufbauen, Netzwerk und Speicher
2. Secret-Speicher wiederherstellen und entsiegeln
3. Plattformkomponenten über GitOps ausrollen – ohne Modelle
4. Objektspeicher wiederherstellen oder Modelle neu beschaffen
5. Inferenz-Dienste starten, Verifikation aus Kapitel 5
6. Gateway mit Datenbank hochfahren
7. Zugang für Anwendungen freigeben
8. Vektorbestände wiederherstellen oder neu aufbauen

MERKE

Der achte Schritt steht bewusst am Ende: Eine RAG-Anwendung ohne Bestand antwortet schlechter, aber sie antwortet – die Einordnung aus Kapitel 15. Damit ist die Plattform nach Schritt 7 wieder nutzbar, und der aufwendigste Teil läuft im Hintergrund.

Diese Reihenfolge zu kennen ist der Unterschied zwischen sechs Stunden und zwei Tagen Ausfall.

16.10.3 Was geübt gehört

Übung	Häufigkeit	Prüft
Rollback einer Modellversion	je Rollout	Ist das alte Verzeichnis da
Wiederherstellung der Gateway-Datenbank	halbjährlich	Sicherung brauchbar
Entsiegelung aus der Sicherung	halbjährlich	Der kritischste Punkt

Übung	Häufigkeit	Prüft
Neuaufbau eines Vektorbestands	jährlich	Ingestion reproduzierbar
Vollständiger Wiederanlauf	jährlich	Reihenfolge und Zeitbedarf

16.11 Container-Images für Inferenz

Neben den Modellen wird ein zweites Artefakt ausgeliefert: das Image des Inferenz-Servers. Es hat eigene Eigenschaften, die es von gewöhnlichen Anwendungs-Images unterscheiden.

Eigenschaft	Folge für die Auslieferung
8 bis 15 GB groß	Erster Abruf je Knoten dauert — Kapitel 5
Hunderte Abhängigkeiten	Größte Angriffsfläche der Plattform — Kapitel 13
Selten geändert	Aber jede Änderung betrifft alle Modelle gleichzeitig
An CUDA-Version gebunden	Kompatibilität zum Treiber — Kapitel 4

16.11.1 Eigenes Image oder fremdes

Option	Geeignet, wenn	Ungeeignet, wenn
Offizielles Image direkt verwenden	Schneller Einstieg, keine eigene Bauinfrastruktur. Für Entwicklungsumgebungen richtig	In Produktion — kein Schwachstellennachweis, keine Kontrolle über den Inhalt
Gespiegelt in die eigene Registry	Der Regelfall. Verfügbarkeit gesichert, Schwachstellenprüfung möglich, Herkunft dokumentiert	Wenn Anpassungen nötig sind
Eigenes Image auf offizieller Grundlage	Wenn zusätzliche Werkzeuge oder Einstellungen gebraucht werden	Wenn nichts anzupassen ist — unnötiger Pflegeaufwand

MERKE

Das Spiegeln in die eigene Registry ist derselbe Gedanke wie bei Modellen aus Kapitel 3: Kein Produktionsknoten lädt aus dem Internet. Der Unterschied ist, dass eine Registry ohnehin betrieben wird — der zusätzliche Aufwand beschränkt sich auf einen Spiegelvorgang.

Der Gewinn ist doppelt: Verfügbarkeit — Kapitel 5 hat vorgerechnet, dass ein neuer GPU-Knoten leicht 30 Gigabyte lädt — und die Schwachstellenprüfung, die auf einem fremden Image nicht durchführbar ist.

16.11.2 Versionsbindung

```
# Falsch: bewegliches Ziel
image: vllm/vllm-openai:latest

# Richtig: unveränderliche Referenz
image: registry.intern/vllm-openai@sha256:3f2a...
```

ACHTUNG Warum die Prüfsumme und nicht der Versionstag

Ein Versionstag kann auf ein anderes Image umgehängt werden — versehentlich oder absichtlich. Die Prüfsumme ist unveränderlich und beschreibt genau einen Inhalt.

Bei Inferenz-Images wiegt das schwerer als bei Anwendungen: Ein unbemerkt getauschtes Image bedeutet möglicherweise eine andere Serverversion mit anderem Verhalten bei Batching und Speicherverwaltung — und damit andere Kapazitätsgrenzen, ohne dass sich eine Konfiguration geändert hätte.

16.12 Ein Rollout-Plan für die ganze Plattform

Was in diesem Buch entstanden ist, wird nicht an einem Tag gebaut. Die folgende Reihenfolge folgt den Abhängigkeiten und liefert nach jedem Schritt etwas Nutzbares.

Stufe	Was entsteht	Dauer	Kapitel
1	Gateway vor externen Anbietern — Sichtbarkeit und Kontingente	Wochen	11, 12
2	Identität und Secrets vollständig	Wochen	12
3	GPU-Knoten, Treiber, Operator	Wochen	4, 5
4	Erstes eigenes Modell im Betrieb	Wochen	3, 7, 8
5	Monitoring und Kostenzuordnung	Wochen	14
6	Governance und Egress-Kontrolle	Wochen	13
7	Serving-Abstraktion und GitOps-Kette	Monate	10, 16
8	RAG-Strecke	Monate	15

MERKE

Die Reihenfolge ist bewusst nicht die des Buches. Sie folgt dem Nutzen: Stufe 1 löst das dringendste Problem aus Kapitel 1 — Kontrollverlust und fehlende Zuordnung — und braucht **keine einzige GPU**. Sie liefert zugleich die Nutzungsdaten, mit denen sich die Beschaffung für Stufe 3 begründen lässt.

Wer umgekehrt beginnt — erst GPUs beschaffen, dann überlegen — kauft Hardware ohne Datengrundlage. Das ist der erste Punkt aus der Liste typischer Fehlannahmen in Kapitel 1, und er ist der teuerste.

16.12.1 Was in jeder Stufe gleich bleibt

Grundsatz	Bedeutung
Alles über GitOps	Auch die erste Stufe — nachträglich umzustellen ist teurer
Secrets von Anfang an im Speicher	Kapitel 12; nachträgliches Einsammeln verstreuter Schlüssel ist mühsam

Grundsatz	Bedeutung
Metriken ab dem ersten Tag	Ohne Ausgangswerte lässt sich später nichts vergleichen
Modellkatalog ab dem ersten Modell	Er wächst mit; nachträglich rekonstruieren ist Archäologie
Prüfsätze ab dem ersten Anwendungsfall	Kapitel 3 und 15; sie sind bei jedem Wechsel wieder nötig

16.13 Lab: Ein Modellwechsel über GitOps

LAB Eine Modellversion ausliefern und zurücknehmen

Ziel: Den vollständigen Weg gehen — Aufnahme, Referenz, Abgleich, Prüfung, Rollback — und dabei messen, wie lange jeder Schritt dauert.

Voraussetzung: ArgoCD, Objektspeicher, InferenceService aus Kapitel 10.

Schritt 1 — Version aufnehmen.

```
V="awq-$(date +%Y-%m-%d)"
Z="s3://modelle/qwen2.5-7b-instruct/$V"
aws s3 sync ./modell/ "$Z/" --endpoint-url "$EP"
```

Schritt 2 — Beschreibung erzeugen.

```
sha256sum ./modell/*.safetensors \
  | jq -Rn '[inputs | split(" ")
    | {(.[]): ("sha256:" + .[0])}] | add' \
  > pruefsummen.json
jq --slurpfile p pruefsummen.json \
  '.pruefsummen = $p[0]' vorlage.json > MANIFEST.json
aws s3 cp MANIFEST.json "$Z/" --endpoint-url "$EP"
```

Schritt 3 — In dev referenzieren.

```
cd gitops
yq -i ".modell.version = \"$V\"" umgebungen/dev/werte.yaml
git commit -am "Modellversion $V in dev"
git push
```

Schritt 4 — Abgleich beobachten und Zeit messen.

```
time kubectl wait --for=condition=Ready \
  isvc/chat-dev --timeout=20m
```

Erwartete Ausgabe: Mehrere Minuten. Das ist die Zahl, die in jede Rollout-Planung gehört — und die begründet, warum Canary aus Kapitel 10 nicht auf einer einzelnen Karte funktioniert.

Schritt 5 — Automatisiert prüfen.

```
kubectl logs deploy/chat-dev-predictor \
  | grep -i "kv cache"
curl -s http://chat-dev/v1/models | jq -r '.data[].id'
```

Vergleichen Sie die KV-Cache-Größe mit der vorherigen Version. Weicht sie deutlich ab, hat sich etwas an Modell oder Konfiguration geändert — die Warnung aus Kapitel 10.

Schritt 6 — Rollback üben.

```
git revert --no-edit HEAD
git push
time kubectl wait --for=condition=Ready \
  isvc/chat-dev --timeout=20m
```

Erwartete Ausgabe: Dieselbe Größenordnung wie beim Ausrollen — weil das alte Modell neu geladen werden muss. Auf einem Knoten mit lokalem Cache aus Kapitel 5 geht es deutlich schneller.

Schritt 7 — Den teuren Fall zeigen. Löschen Sie das alte Verzeichnis im Objektspeicher und versuchen Sie den Rollback erneut.

Erwartung: Der Storage-Initializer scheitert. Genau deshalb gilt die Aufbewahrungsregel aus Abschnitt 16.5.

Ergebnis: Ein Modellwechsel, der nachvollziehbar, prüfbar und in Minuten umkehrbar ist — und gemessene Zahlen für die Rollout-Planung.

16.14 Betrieb und Troubleshooting

Symptom	Ursache	Diagnose	Behebung
Abgleich zeigt Erfolg, altes Modell läuft weiter	Pod wurde nicht neu gestartet — nur die Referenz änderte sich	Startzeitpunkt des Pods gegen den Zeitpunkt der Änderung	Neustart auslösen; Änderung an den Pod-Vorlagen binden
Storage-Initializer findet das Modell nicht	Pfad falsch oder Verzeichnis gelöscht	Objektspeicher auflisten	Pfad korrigieren; Aufbewahrungsregel einführen
Prüfsummenprüfung schlägt fehl	Unvollständige Übertragung oder verändertes Verzeichnis	Übertragung wiederholen und erneut prüfen	Aufnahme wiederholen; Schreibzugriff einschränken
Rollback dauert Stunden statt Minuten	Altes Verzeichnis gelöscht	Objektspeicher prüfen	Vorhaltezeit festlegen — Abschnitt 16.5
Umgebungen laufen auseinander	Konfiguration je Umgebung dupliziert statt überlagert	Unterschiede zwischen den Umgebungsdateien ansehen	Auf Basis und Überlagerung umstellen
Nach dem Wiederanlauf fehlen alle Zugangsdaten	Sicherung des Secret-Speichers fehlte oder lag im selben Cluster	–	Sicherung extern ablegen; Entsiegelung üben — Kapitel 12
Modell im Katalog, aber nicht im Gateway	Katalog wird nicht zur Konfigurationserzeugung genutzt	Katalogeintrag gegen die Gateway-Konfiguration	Erzeugung aus dem Katalog automatisieren

16.15 Interviewfragen

INTERVIEWFRAGE

Wie liefern Sie ein Modell über GitOps aus, wenn es 20 GB groß ist?

Senior ist die Trennung: Das Artefakt liegt im Objektspeicher oder in der Registry, im Git steht nur die **Referenz** — Pfad, Version, Prüfsumme. Damit wird der Modellwechsel zu einer gewöhnlichen, geprüften Änderung an einer Textdatei.

Dazu die Regel, die daraus folgt: ein Verzeichnis je Version, niemals überschreiben. Ein Rollback ist genau so lange eine Zeilenänderung, wie das alte Verzeichnis existiert — sonst wird aus Minuten ein Stundenvorgang, und zwar dann, wenn es eilt.

INTERVIEWFRAGE

Wie versionieren Sie Modelle, und wie machen Sie einen Rollback?

Gut ist: versionierte Pfade und Zurücksetzen der Referenz.

Senior ergänzt das Beschreibungsdokument je Version — Herkunft, Revision, Prüfsummen, Quantisierung, Datenklasse, Freigabe, Prüfsatzergebnis. Es beantwortet die Frage nach der Herkunft aus Kapitel 3 und die nach der Freigabe aus Kapitel 13.

Beim Rollback ist die ehrliche Zahl wichtig: Er dauert so lange wie das Laden des Modells, also Minuten. Nur ein laufender Canary lässt sich in Sekunden zurücknehmen — was ein weiteres Argument dafür ist, ihn zu fahren, wo Kapazität vorhanden ist.

INTERVIEWFRAGE

Was ist bei einem Modell-Rollout anders als bei einer Anwendung?

Senior nennt drei Unterschiede. **Erstens** die Prüfung: Bei einer Anwendung entscheidet eine Testsuite, bei einem Modell ein fachlicher Prüfsatz mit teilweise menschlicher Bewertung. **Zweitens** die Dauer: Minuten statt Sekunden, was Canary und Rollback verteuert. **Drittens** die Kapazität: Zwei Modellversionen parallel bedeuten zwei belegte GPUs — auf einem Cluster mit einer Karte ist Canary nicht möglich.

Wer ergänzt, dass ein Canary technische Kennzahlen misst und nicht die Antwortqualität, verbindet es mit Kapitel 10.

INTERVIEWFRAGE

Ihr Cluster ist vollständig verloren. Was tun Sie?

Senior ist die Reihenfolge mit Begründung: Cluster, Secret-Speicher, Plattform über GitOps, Modelle, Inferenz, Gateway, Freigabe für Anwendungen — und **zuletzt** die Vektorbestände, weil eine RAG-Anwendung ohne Bestand schlechter, aber überhaupt antwortet.

Der kritische Punkt ist der zweite Schritt: Ohne die Sicherung des Secret-Speichers und die Entsiegelungsschlüssel ist der Wiederanlauf nicht möglich — alle Zugangsdaten müssten neu beschafft werden. Diese Sicherung gehört an einen Ort außerhalb des Clusters, und die Entsiegelung gehört geübt.

INTERVIEWFRAGE

Wie stellen Sie sicher, dass in Produktion das Modell läuft, das Sie erwarten?

Senior nennt die Lücke: Ein GitOps-Werkzeug gleicht das Manifest ab, nicht den Inhalt des Objektspeichers. Ein von Hand überschriebenes Modellverzeichnis unter demselben Pfad bleibt unbemerkt — beim nächsten Neustart lädt der Dienst etwas anderes.

Drei Maßnahmen: Verzeichnisse nie überschreiben, Schreibzugriff auf den Aufnahmevorgang beschränken, und Prüfsummen aus dem Beschreibungsdokument vor dem Start verifizieren. Wer zusätzlich nennt, dass die KV-Cache-Größe im Startlog eine gute Kontrollgröße ist, verbindet es mit Kapitel 8.

16.16 Zusammenfassung

- Das Modell gehört nicht ins Repository, seine Referenz schon. Damit wird der Modellwechsel zu einer gewöhnlichen, geprüften Änderung.
- Ein Verzeichnis je Version, niemals überschreiben. Ein Beschreibungsdokument hält Herkunft, Prüfsummen, Quantisierung, Datenklasse und Freigabe fest.
- Die Delivery-Kette unterscheidet sich an einer Stelle von der einer Anwendung: Über die Freigabe entscheidet ein fachlicher Prüfsatz, nicht nur eine Testsuite.
- Umgebungen unterscheiden sich in Modellversion, Kapazität und Daten — die Struktur bleibt gleich. Vorproduktion mit echten Daten ist Produktion mit schwächerem Schutz.
- Ein Rollback ist eine Zeilenänderung, solange das alte Verzeichnis existiert. Zwei Wochen Vorhaltezeit sind die günstigste Versicherung der Plattform.
- GitOps gleicht das Manifest ab, nicht den Objektspeicher. Ein überschriebenes Modellverzeichnis bleibt unbemerkt — deshalb Schreibschutz und Prüfsummen.
- Der Modellkatalog erzeugt die Gateway-Konfiguration, belegt die Betreiberpflichten und dokumentiert für Anwendungsteams — aus einer versionierten Datei.
- Beim Wiederanlauf ist der Secret-Speicher der kritische Punkt. Seine Sicherung gehört außerhalb des Clusters, die Entsiegelung gehört geübt.
- Vektorbestände kommen zuletzt: Die Plattform ist vorher wieder nutzbar.

Quellen und Weiterlesen

- Argo CD: *Documentation — Declarative Setup und Sync Options*. Abgleichverhalten und Umgang mit Ressourcen, die nicht verwaltet werden sollen.
- Kustomize: *Documentation — Bases and Overlays*. Trennung gemeinsamer Struktur von umgebungsspezifischen Werten.
- Harbor: *Documentation — Registry als Ablage, Signaturprüfung und Schwachstellenprüfung von Artefakten*.
- OCI: *Artifacts Specification* — Grundlage für Modelle als Registry-Artefakte.
- OpenBao: *Documentation — Backup and Restore*. Sicherung des Speichers und der Entsiegelungsschlüssel.

TEIL VI

Synthese

Sechzehn Kapitel haben die Bausteine entwickelt. Dieser Teil setzt sie zusammen – in drei Größenordnungen, mit durchgerechneter Kapazität und in der Form, in der sie am Whiteboard gebraucht werden.

Referenzarchitekturen und Kapazitätsplanung

ZIEL

SETZT VORAUS

DANACH KANNST DU

Alles Vorangegangene zu drei durchgerechneten Architekturen zusammenführen – und die Systemdesign-Aufgabe beantworten können, die in Interviews auf Senior-Ebene gestellt wird.

Die Kapitel 1 bis 16.

Für eine gegebene Organisationsgröße eine Architektur entwerfen, den Hardwarebedarf begründen, die Entwicklungsstufen benennen und jede Entscheidung verteidigen.

GESCHRIEBEN GEGEN

Stand September 2026

Dieses Kapitel enthält nichts Neues. Es setzt zusammen, was in sechzehn Kapiteln entstanden ist – in der Form, in der es am Whiteboard gebraucht wird.

17.1 Die Größe bestimmt fast alles

	Klein 50 Nutzer	Mittel 500 Nutzer	Groß 5 000 Nutzer
Anfragen je Tag	ca. 600	ca. 6 000	ca. 60 000
Spitzenrate	< 0,1/s	ca. 0,6/s	ca. 6/s
Ausgabetoken/s in der Spitze	ca. 25	ca. 250	ca. 2 500
GPUs rechnerisch	–	1	3–4
GPUs tatsächlich	0	2	8–10
Gateway-Repliken	2	3	4–6
Betriebsaufwand	0,2 Stellen	0,5 Stellen	1,5–2 Stellen


MERKE

Die beiden GPU-Zeilen sind die wichtigste Aussage dieses Kapitels. Der rechnerische Bedarf ist überraschend klein – eine einzelne Karte trägt 500 Nutzer. Die tatsächliche Beschaffung wird durch etwas anderes bestimmt: **Verfügbarkeit und Modellgröße**.

Die zweite Karte im mittleren Fall dient nicht dem Durchsatz. Sie ermöglicht Treiber-Updates ohne Ausfall – Kapitel 4 –, Canary-Rollouts – Kapitel 10 – und Wartung ohne Nichtverfügbarkeit – Kapitel 5. Wer sie einspart, spart an der Betreibbarkeit, nicht an der Kapazität.

17.2 Klein: unter 100 Nutzer

17.2.1 Die Architektur



Kleine Architektur: Gateway ohne eigene GPUs

Entscheidung	Begründung
Keine eigenen GPUs	Bei dieser Nutzung liegt der Eigenbetrieb weit unter der Break-even-Auslastung von rund zehn Prozent – Kapitel 14
Gateway trotzdem	Sichtbarkeit, Kontingente und Kostenzuordnung sind unabhängig von der Größe nötig – Kapitel 1
Keine Serving-Abstraktion	KServe lohnt ab dem fünften Modell – Kapitel 10
Zwei Gateway-Repliken	Das Gateway ist der einzige kritische Pfad – Kapitel 11


MERKE

Diese Architektur ist in wenigen Wochen aufgebaut und löst das Problem aus Kapitel 1 vollständig: Schatten-KI verschwindet, Kosten werden zuordenbar, Datenklassifikation wird durchsetzbar.

Wenn schutzwürdige Daten verarbeitet werden müssen und dafür kein externes Modell in Frage kommt, ändert sich die Rechnung: Dann wird eine GPU beschafft – nicht aus wirtschaftlichen, sondern aus rechtlichen Gründen. Kapitel 14 hat diesen Unterschied benannt.

17.3 Mittel: einige hundert Nutzer

17.3.1 Die Architektur



Mittlere Architektur: hybrid, mit zwei GPU-Knoten

17.3.2 Die Entscheidungen

Entscheidung	Begründung	Kapitel
Zwei GPU-Knoten	Wartung, Rollout und Canary ohne Ausfall – nicht Durchsatz	4, 10
Ein Modell der 7-bis-9B-Klasse	Deckt die Mehrheit der Anwendungsfälle; passt quantisiert mit brauchbarem KV-Cache	3
4-Bit-Quantisierung	Wirkt doppelt: mehr KV-Cache und schnellerer Decode	3
Kein Tensor Parallelism	Das Modell passt auf eine Karte – Repliken sind überlegen	9
KServe	Ab hier lohnt die Abstraktion: mehrere Modelle, Canary, Rollouts	10
Embedding auf CPU	Spart VRAM, der dem Sprachmodell fehlen würde	8
pgvector	Bestandsgröße unkritisch; ein System weniger im Betrieb	15
Hybrid	Externe Modelle für unkritische Klassen – günstiger und leistungsfähiger	13, 14

MERKE

Diese Architektur ist der Zielzustand, den die meisten Organisationen brauchen – und auf den dieses Buch durchgehend hinarbeitet. Sie ist mit dem Referenz-Lab aus dem Vorwort weitgehend nachbaubar; es fehlt im Wesentlichen der zweite GPU-Knoten.


Bemerkenswert ist, was **nicht** darin vorkommt: kein verteiltes Serving, keine MIG-Partitionierung, keine spezialisierte Vektordatenbank, kein Prefill/Decode-Splitting. Alle vier sind Technik für größere Installationen und würden hier nur Komplexität hinzufügen.

17.4 Groß: mehrere tausend Nutzer

17.4.1 Was sich ändert

Bereich	Neu gegenüber mittel	Kapitel
Modelle	Mehrere Größen nebeneinander: klein für Klassifikation, mittel für Dialog, groß für Analyse	3, 10
GPU-Aufteilung	MIG für kleinere Modelle und Mandanten mit Zusicherung	6
Verteiltes Serving	Nur, wenn ein Modell nicht auf eine Karte passt	9
Weiterleitung	Cache-bewusst, weil viele Repliken	8, 10
Lastprofile	Getrennte Endpunkte für Chat, RAG und Stapelbetrieb	2, 7
Mandanten	Getrennte Namensräume, teils getrennte Knoten	13
Vektorbestände	Getrennt je Fachbereich; spezialisierte Datenbank denkbar	15
Betrieb	Eigenes Team, Rufbereitschaft, geübter Wiederanlauf	16

17.4.2 Die Architektur



Große Architektur: getrennte Pools nach Lastprofil

MERKE

Die Trennung nach Lastprofil ist die wichtigste Entscheidung dieser Größenordnung – und sie folgt unmittelbar aus Kapitel 2 und 7: Ein einzelner Endpunkt, der lange

RAG-Prompts und kurze Chat-Anfragen bedient, ist für keines von beidem richtig konfiguriert, und die langen Prompts verzögern die kurzen.

Getrennte Pools kosten Auslastung — jeder braucht seine eigene Reserve. Sie sind trotzdem richtig, weil die Alternative bedeutet, Latenzzusagen für alle zu verletzen, sobald ein Nutzer ein langes Dokument einreicht.

17.5 Die drei Architekturen im Kostenvergleich

Die Zahlen folgen den Rechnungen aus Kapitel 1, 11 und 14. Sie sind Beispielwerte, deren Größenordnung stimmt — die eigenen Werte gehören eingesetzt.

Position je Monat	Klein	Mittel	Groß
Externe Modellnutzung	ca. 400 €	ca. 900 €	ca. 4 000 €
GPU-Hardware, abgeschrieben	–	ca. 1 400 €	ca. 5 600 €
Strom und Rechenzentrum	–	ca. 560 €	ca. 2 240 €
CPU-Knoten für Plattformdienste	ca. 150 €	ca. 300 €	ca. 700 €
Betriebsaufwand	ca. 1 600 €	ca. 4 000 €	ca. 14 000 €
Summe	ca. 2 150 €	ca. 7 160 €	ca. 26 540 €
Anfragen je Monat	ca. 12 000	ca. 120 000	ca. 1,2 Mio.
Kosten je 1 000 Anfragen	ca. 179 €	ca. 60 €	ca. 22 €

MERKE

Die letzte Zeile ist die aussagekräftigste und wird selten gebildet: Die Kosten je Anfrage sinken mit der Größe erheblich — und zwar nicht wegen der Hardware, sondern wegen des **Betriebsaufwands**. Er ist in allen drei Fällen der größte Posten und wächst deutlich langsamer als die Nutzung.

Daraus folgt eine Aussage für Architekturgespräche: Eine KI-Plattform ist ein Vorhaben mit ausgeprägten Skaleneffekten. Zwei getrennte Plattformen für zwei Geschäftsbereiche kosten deutlich mehr als eine gemeinsame — und das ist ein Argument, das man früh vorbringen sollte, weil solche Trennungen später schwer rückgängig zu machen sind.

ACHTUNG Der Betriebsaufwand wird regelmäßig unterschätzt

In allen drei Spalten ist er der größte Einzelposten — deutlich vor der Hardware. Wer eine Plattform mit Hardwarekosten begründet und den Betrieb als „machen wir nebenbei“ einplant, unterschätzt das Vorhaben um den Faktor zwei bis drei.

Kapitel 16 hat die wiederkehrenden Aufgaben aufgeführt: Modellversionen, Serverupdates, Treiber, Rotation, Prüfsätze, Neuaufbauten, Katalogpflege. Sie sind nicht dringend — bis sie es plötzlich sind.

17.6 Wann welche Stufe

Die Architekturen sind keine Kategorien, sondern Stationen. Die folgenden Auslöser zeigen an, dass ein Wechsel ansteht.

Übergang	Auslöser	Was zu tun ist
Klein → Mittel	Eine schutzwürdige Datenklasse braucht ein lokales Modell – oder die externe Nutzung übersteigt dauerhaft die Break-even-Schwelle aus Kapitel 14	GPU-Knoten aufbauen, Serving einführen. Das Gateway bleibt unverändert
Mittel → Groß	Ein zweiter Anwendungsfall mit unvereinbarem Lastprofil – meist RAG neben Chat	Pools trennen, Endpunkte je Profil. Kein Architekturbruch
Innerhalb Groß	Mandanten mit Zusicherungsbedarf; Modelle, die nicht auf eine Karte passen	MIG – Kapitel 6 – beziehungsweise verteiltes Serving – Kapitel 9

MERKE

Bemerkenswert ist, dass keiner dieser Übergänge einen Umbau erfordert. Das Gateway bleibt dasselbe, die Identität bleibt dieselbe, GitOps und Monitoring bleiben. Ergänzt wird jeweils eine Schicht darunter.

Das ist kein Zufall, sondern folgt aus der Reihenfolge in Kapitel 16: Wer oben beginnt – beim Gateway – baut nach unten weiter. Wer unten beginnt – bei den GPUs – muss die Zugriffsschicht nachträglich einziehen, während bereits Anwendungen direkt auf die Modelle zugreifen.

17.7 Betriebsmodelle

Wer die Plattform betreibt, ist eine Entscheidung mit Folgen für die Architektur.

Modell	Aufbau	Einordnung
Zentrales Plattformteam	Ein Team betreibt alles, Fachbereiche sind Nutzer	Der Regelfall. Klare Verantwortung, gute Auslastung
Selbstbedienung	Fachbereiche stellen eigene Modelle über KServe bereit	Setzt Reife voraus – Kapitel 10; Governance muss erzwungen sein, nicht vereinbart
Verteilt	Jeder Bereich betreibt eigene GPUs	Schlechte Auslastung, vervielfachter Aufwand. Meist historisch gewachsen

ACHTUNG Selbstbedienung ohne Durchsetzung

Fachbereiche eigene Modelle bereitstellen zu lassen ist attraktiv – es entlastet das Plattformteam und beschleunigt die Fachbereiche. Es funktioniert aber nur, wenn die Governance aus Kapitel 13 **technisch erzwungen** ist: Egress-Verbot, Allowlists, Ressourcenkontingente, Freigabe für schreibende Werkzeuge.

Ohne diese Durchsetzung entsteht eine Plattform, auf der jeder alles darf – und die damit genau die Kontrolle verliert, wegen der sie gebaut wurde. Selbstbedienung ist eine **Folge** funktionierender Governance, nicht ihr Ersatz.

17.8 Was ein Plattformteam können muss

Die Rolle aus Kapitel 1, jetzt mit dem, was sechzehn Kapitel dazu ergeben haben.

Fähigkeit	Konkret	Kapitel
Kapazität rechnen	Von Nutzerzahl zu GPU-Zahl, mit KV-Cache-Gegenprobe	2, 17
Modelle bewerten	VRAM-Bilanz, Quantisierung, Prüfsatz	3
GPU-Stack betreiben	Treiber, Operator, Passthrough, Xid-Diagnose	4, 5
Inferenz tunen	Parameter begründen statt raten, Rampe messen	7, 8
Serving abstrahieren	Runtimes pflegen, Rollouts fahren	10
Zugriff regeln	OIDC, Ansprüche, Kontingente, Secrets	11, 12
Governance durchsetzen	Klassifikation, Egress, Nachweise	13
Messen und abrechnen	Die richtigen Kennzahlen, Kosten je Token	14
Ausliefern	GitOps mit großen Artefakten, Rollback in Minuten	16
Erklären	Entscheidungen gegenüber Leitung und Fachbereich begründen	alle

MERKE

Die letzte Zeile ist die, die den Unterschied macht und in keiner Stellenausschreibung steht. Die meisten Entscheidungen dieses Buches – der zweite GPU-Knoten, die fehlende Inhaltsprotokollierung, das kleinere Modell, die getrennten Pools – müssen gegenüber Menschen begründet werden, die die Technik nicht kennen.

Wer die Rechnungen führen kann, hat dafür Argumente statt Meinungen. Genau das war der Anspruch dieses Buches: nicht zu sagen, was man tun soll, sondern warum – so, dass man es weitergeben kann.

17.9 Von der Nutzerzahl zur Hardware

Die Rechnung aus Kapitel 2, hier als geschlossene Abfolge zum Nachvollziehen.

Nr.	Schritt	Formel	Beispiel
1	Aktive Nutzer	$\text{Nutzer} \times \text{Quote}$	$500 \times 0,4 = 200$
2	Anfragen je Tag	$\text{aktiv} \times \text{Anfragen}$	$200 \times 30 = 6\,000$
3	Mittlere Rate	$\div \text{Arbeitszeit}$	$6\,000 / 28\,800\text{ s} \approx 0,21/\text{s}$
4	Spitzenrate	$\times \text{Spitzenfaktor}$	$\times 3 \approx 0,63/\text{s}$
5	Ausgabefolgen/s	$\times \text{Ausgabefolgen}$	$\times 400 \approx 250/\text{s}$

Nr.	Schritt	Formel	Beispiel
6	Nötige Repliken	$\div$ Durchsatz je GPU	$250 / 900 \rightarrow 1$
7	Gleichzeitige Anfragen	Rate $\times$ Verweildauer	$0,63 \times 8 \approx 5$
8	KV-Bedarf	$\times$ Kontext $\times$ Bytes/Token	$5 \times 8\,192 \times 128\text{ KiB} \approx 5\text{ GiB}$
9	Passt es?	gegen KV-Budget	$5 < 14,6\text{ GiB}$ — ja
10	Beschaffung	Repliken + Reserve	2 GPUs

ACHTUNG Zwei Annahmen, die kippen können

Agentische Anwendungen erzeugen je Nutzeraktion zehn bis hundert Modellaufrufe statt einem. Schritt 2 ist dann um diesen Faktor zu erhöhen — und dieser Faktor ist meist unbekannt, weil die Anwendung noch nicht existiert.

Stapelverarbeitung hat keine Spitzen, sondern Dauerlast. Schritt 4 entfällt, dafür zählt der reine Durchsatz über die Laufzeit.

Beide Fälle gehören ausdrücklich abgefragt, bevor die Rechnung als Grundlage einer Beschaffung dient.

17.10 Drei Anwendungsfälle durchgerechnet

Abstrakte Architekturen helfen begrenzt. Drei konkrete Fälle, jeweils von der Anforderung zur Konfiguration.

17.10.1 Interner Chat-Assistent

Größe	Wert	Begründung
Nutzer	400 aktiv	–
Prompt	ca. 500 Token	Kurze Fragen, kleiner Systemprompt
Ausgabe	ca. 400 Token	Dialogantworten
Kontextgrenze	4 096	Reicht für mehrstufige Dialoge
Modell	7B, 4 Bit	Deckt Dialog ab — Kapitel 3
Gleichzeitigkeit	ca. 25	Aus KV-Budget: $14,6\text{ GiB} / (4\,096 \times 56\text{ KiB})$
Kritische Kennzahl	TTFT	Nutzer warten sichtbar
Besonderheit	Hohe Prefix-Trefferquote	Fester Systemprompt — Kapitel 7

Konfiguration: moderates Token-Budget je Schritt für gleichmäßige Ausgabe, Prefix Caching aktiv, zwei Repliken für Wartbarkeit.

17.10.2 RAG über die interne Dokumentation

Größe	Wert	Begründung
Nutzer	150 aktiv	Kleinerer Kreis

Größe	Wert	Begründung
Prompt	ca. 3 500 Token	Systemprompt plus fünf abgerufene Abschnitte
Ausgabe	ca. 300 Token	Antworten mit Belegen
Kontextgrenze	8 192	Muss den Abruf tragen
Gleichzeitigkeit	ca. 12	Halbiert gegenüber Chat – längerer Kontext
Kritische Kennzahl	TTFT	Prefill dominiert bei langen Prompts
Besonderheit	Head-of-Line-Risiko	Kapitel 2 und 7

MERKE

Dieser Fall zeigt, warum die Pool-Trennung aus Abschnitt 17.4 nötig ist: Bei siebenmal längeren Prompts als im Chat-Fall und halbiert Gleichzeitigkeit sind die richtigen Parameter völlig andere – und ein RAG-Prefill von 3 500 Token verzögert jede gleichzeitige Chat-Anfrage.

Auf einer gemeinsamen Instanz mit 150 RAG- und 400 Chat-Nutzern leidet die Chat-Latenz spürbar, obwohl die RAG-Nutzer in der Minderheit sind.

17.10.3 Nächtliche Klassifikation

Größe	Wert	Begründung
Volumen	200 000 Dokumente je Nacht	Stapelbetrieb
Prompt	ca. 800 Token	Dokumentauszug plus Anweisung
Ausgabe	ca. 10 Token	Nur eine Kategorie
Kontextgrenze	2 048	Knapp bemessen – maximiert Gleichzeitigkeit
Modell	1,5B, 4 Bit	Klassifikation braucht kein großes Modell – Kapitel 3
Kritische Kennzahl	Durchsatz	Keine Latenzzusage
Besonderheit	Scale-to-Zero	Läuft vier Stunden – Kapitel 10

MERKE

Der interessanteste Wert ist die Ausgabelänge: zehn Token. Damit ist dieser Fall **prefill-dominiert** – das Gegenteil des Chat-Falls. Kapitel 3 hat darauf hingewiesen, dass weight-only-Quantisierung im Prefill weniger bringt als im Decode; hier wirkt sie vor allem über den größeren KV-Cache.

Konfiguration entsprechend: hohes Token-Budget je Schritt für maximalen Durchsatz, große Batchgrenze, keine Rücksicht auf gleichmäßige Ausgabe. Genau die Einstellungen, die im Chat-Fall Latenzausreißer erzeugen würden.

17.10.4 Alle drei nebeneinander

	Chat	RAG	Stapel
Prompt	500	3 500	800
Ausgabe	400	300	10
Charakter	ausgewogen	prefill-lastig	stark prefill-lastig
Optimiert auf	TTFT und TPOT	TTFT	Durchsatz
Token-Budget	moderat	moderat	hoch
Priorität	hoch	hoch	niedrig
Scale-to-Zero	nein	nein	ja
Eigener Endpunkt	ja	ja	ja

MERKE

Die letzte Zeile ist das Fazit dieses Kapitels in einer Zeile: Drei Anwendungsfälle, drei Endpunkte. Nicht weil es schöner ist, sondern weil die richtigen Parameter für jeden andere sind – und sich gegenseitig ausschließen.

Wer diese Tabelle im Gespräch entwickeln kann, hat die Frage nach dem Lastprofil aus Kapitel 2 verstanden und ihre Konsequenz gezogen. Es ist derselbe Gedanke, der sich durch das ganze Buch zieht: Erst das Profil klären, dann konfigurieren.

17.11 Hybrid und mehrere Standorte

17.11.1 Wo was läuft

Ort	Wofür	Warum
Eigenes Rechenzentrum	Vertrauliche Klassen, Grundlast	Datensouveränität; bei guter Auslastung günstiger
Externe Anbieter	Unkritische Klassen, Spitzen, sehr große Modelle	Keine Fixkosten, sofort verfügbar
Cloud-GPUs	Zeitweiliger Bedarf: Ingestion, Versuche, Lastspitzen	Stundengenau abgerechnet – Kapitel 9 und 15

MERKE

Die dritte Zeile wird selten genutzt und lohnt oft. Der einmalige Aufbau eines Vektorbestands nach Kapitel 15 oder eine Quantisierung nach Kapitel 3 sind Aufgaben von wenigen Stunden mit hohem GPU-Bedarf – genau der Fall für gemietete Kapazität.

Wer dafür eigene Hardware beschafft, kauft für den Spitzenbedarf und zahlt ihn das ganze Jahr.

17.11.2 Mehrere Rechenzentren

Muster	Aufbau	Einordnung
Aktiv-Passiv	Zweiter Standort mit kalter Reserve	Günstig, aber der Wiederanlauf dauert – Kapitel 16
Aktiv-Aktiv	Beide Standorte bedienen Anfragen	Teuer: Modelle doppelt vorhalten. Für Inferenz aber einfach , weil zustandslos


Muster	Aufbau	Einordnung
Gateway verteilt	Gateway an beiden Standorten, gemeinsame Datenbank	Der kritische Punkt — die Datenbank muss standortübergreifend verfügbar sein

MERKE

Inferenz ist für Mehrstandortbetrieb ungewöhnlich freundlich: Ein Modell ist zustandslos, jede Replik kann jede Anfrage beantworten, und es gibt nichts zu synchronisieren außer den Modellartefakten — die sich selten ändern.

Der schwierige Teil ist nicht die GPU, sondern die **Gateway-Datenbank** aus Kapitel 11: Schlüssel, Budgets und Verbrauch müssen standortübergreifend konsistent sein. Wer Mehrstandortbetrieb plant, sollte dort ansetzen und nicht bei den Modellen.

17.12 Die vollständige Referenzarchitektur



Alle Bausteine mit Kapitelverweis

17.13 Die Senior-Aufgabe

Die Aufgabe, die in Interviews auf dieser Ebene gestellt wird – und eine Antwort, die sich in zwanzig Minuten am Whiteboard entwickeln lässt.

INTERVIEWFRAGE

5 000 Mitarbeiter. Entwickler nutzen derzeit direkt öffentliche Chat-Dienste. Sensible Anwendungen sollen lokale Modelle verwenden. Zwei Rechenzentren und eine Cloud-Umgebung sind vorhanden. Entwerfen Sie die Plattform.

Zuerst Rückfragen – wer sofort zu zeichnen beginnt, hat die Aufgabe verkleinert:

Welche Datenklassen gibt es und wer legt sie fest? Wie viele Anfragen je Nutzer und Tag, wie lang sind Prompts und Antworten? Gibt es agentische Anwendungen? Bestehen Verträge mit Anbietern? Wer betreibt das später, und wie groß ist das Team?

Dann die Stufen, mit Begründung der Reihenfolge – Kapitel 16:

Stufe 1 ist das Gateway vor den bestehenden Anbietern. Es braucht keine GPU, löst sofort das Kontrollproblem und liefert die Nutzungsdaten, mit denen sich alles Weitere begründen lässt. Parallel wandern die Anbieterschlüssel in den Secret-Speicher – erst danach lassen sich direkte Zugänge abschalten.

Stufe 2 sind Identität und Governance: OIDC, Ansprüche auf Teams und Datenklassen, Allowlists, grundsätzliches Egress-Verbot.

Stufe 3 sind die GPU-Knoten mit dem ersten eigenen Modell für die vertrauliche Klasse.

Dann die Architektur nach Abschnitt 17.4 mit getrennten Pools nach Lastprofil und der Kapazitätsrechnung aus Abschnitt 17.5 – bei 5 000 Nutzern grob acht bis zehn GPUs, wovon rund die Hälfte Reserve und Profiltrennung ist.

Zu den zwei Rechenzentren: Inferenz ist zustandslos und damit einfach zu verteilen. Der kritische Punkt ist die Gateway-Datenbank. Die Cloud dient für zeitweiligen Bedarf – Ingestion, Quantisierung, Lastspitzen –, nicht für Grundlast.

Was die Antwort abrundet: Die Aussage, dass die Kapazität rechnerisch mit deutlich weniger Karten auskäme und die Beschaffung von Verfügbarkeit, Modellgröße und Lastprofiltrennung bestimmt wird. Wer das begründet, zeigt, dass er die Rechnung geführt hat und nicht Erfahrungswerte wiedergibt.

17.13.1 Die Nachfragen

Frage	Kern der Antwort	Kap.
Warum ein Gateway?	Einzige Stelle mit Identität, Inhalt, Kosten und Ziel gleichzeitig	11
Was bei Anbietersausfall?	Fallback – aber innerhalb der Datenklasse; sonst ablehnen	11, 13
1 000 gleichzeitige Anfragen?	Warteschlange und Kontingente greifen; Skalierung über Wartende, nicht CPU	7, 10
Wie verhindern Sie, dass Finanzdaten nach außen gehen?	Klasse vor Zielwahl, Allowlist, plus Egress-Verbot als zweite Ebene	13
Was passiert, wenn die GPU voll ist?	Verdrängung – Alarm, nicht Normalzustand; KV-Cache zu klein	7

Frage	Kern der Antwort	Kap.
Wie skalieren Sie?	Repliken; verteiltes Serving nur bei zu großem Modell	9, 10
Wer darf welches Modell?	Datenklasse aus Anwendung oder Rolle, Allowlist je Team	12, 13
Wie messen Sie Kosten?	Kartenkosten durch erzeugte Token; Auslastung ist der Hebel	14
Was passiert mit Prompts im Log?	Nichts — Kennzahlen genügen; Inhalte nur mit eigener Grundlage	11, 13
Wie rotieren Sie Anbieter-schlüssel?	Überlappung, mit geprüftem Übergang vor dem Widerruf	12
Wiederanlauf?	Reihenfolge mit Secret-Speicher zuerst, Vektorbestände zuletzt	16

17.14 Was am häufigsten falsch gemacht wird

Eine Zusammenstellung aus dem gesamten Buch — die Fehler, die in Projekten wiederkehren.

Fehler	Warum er teuer ist	Kap.
GPUs vor der Messung beschaffen	Falsche Dimensionierung; meist zu viele Karten mit zu wenig VRAM	1
Nur eine GPU	Jede Wartung ist ein Ausfall	4, 10
Kontextlänge des Modells übernehmen	Der KV-Cache trägt sie nicht — der Server startet nicht	2, 3
Auf CPU-Auslastung skalieren	Das Signal trägt keine Information	10
Time-Slicing für Mandanten	Keine Speicherisolation — sporadische Ausfälle	6
Prompts im Log	Datenschutzvorfall in der Log-Pipeline	8, 11
Berechtigungen im RAG nachgelagert	Berechtigungsübergreif ohne Fehlermeldung	15
Modellverzeichnisse überschreiben	Rollback dauert Stunden statt Minuten	16
Startsonde vergessen	Endlose Neustarts, die wie ein Absturz aussehen	8
Egress nur teilweise verbieten	Das Gateway ist umgehbar — Governance wird zur Empfehlung	13

17.15 Was bleibt, wenn sich die Werkzeuge ändern

Das Vorwort hat zwei Ebenen unterschieden: veränderliche Werkzeuge und stabile Konzepte. Zum Abschluss die zweite Ebene — was auch dann gilt, wenn vLLM, KServe und LiteLLM anders heißen.

Konzept	Warum es bleibt
Prefill ist rechenbegrenzt, Decode bandbreitenbegrenzt	Folgt aus der Rechenstruktur, nicht aus einer Implementierung

Konzept	Warum es bleibt
Der KV-Cache ist der Kapazitätsengpass	Solange Sequenzen Zustand tragen, gilt das
Batching ist der größte Durchsatzhebel	Weil das Lesen der Gewichte je Schritt nur einmal anfällt
Auslastung schlägt Verfügbarkeit	Weil GPUs im Leerlauf ihren Preis verbrennen
Governance gehört an die Stelle mit allen Informationen	Eine Eigenschaft der Informationsverteilung, keine Produktwahl
Der Anfrageinhalt ist der Compliance-Gegenstand	Solange Modelle Text verarbeiten, den Menschen schreiben
Modelle sind große, langsame Artefakte	Auch wenn sie kleiner werden – relativ zu Anwendungen bleiben sie groß

MERKE

Wer diese sieben Aussagen begründen kann, kann eine KI-Plattform entwerfen – unabhängig davon, welche Werkzeuge gerade aktuell sind. Sie sind der Kern dessen, was dieses Buch vermitteln wollte.

Die Werkzeuge in den Referenzabschnitten werden veralten. Die Rechnungen und die Begründungen nicht.

17.16 Zusammenfassung

- Der rechnerische GPU-Bedarf ist überraschend klein: Eine Karte trägt einige hundert Nutzer. Die Beschaffung wird von Verfügbarkeit, Modellgröße und Lastprofiltrennung bestimmt.
- Unter hundert Nutzern ist die richtige Architektur ein Gateway **ohne** eigene GPUs – es sei denn, die Datenklassifikation erzwingt lokale Modelle.
- Die mittlere Architektur – Gateway, zwei GPU-Knoten, ein quantisiertes Modell der 7-bis-9B-Klasse, KServe, pgvector, Embedding auf CPU – deckt die Mehrheit der Organisationen ab.
- Ab einigen tausend Nutzern werden Pools nach Lastprofil getrennt. Das kostet Auslastung und verhindert, dass lange Prompts kurze Anfragen verzögern.
- Die Kapazitätsrechnung führt in zehn Schritten von der Nutzerzahl zur Beschaffung. Agentische Anwendungen und Stapelbetrieb brechen ihre Annahmen und gehören abgefragt.
- Inferenz ist für Mehrstandortbetrieb freundlich, weil zustandslos. Der schwierige Teil ist die Gateway-Datenbank.
- Cloud-GPUs lohnen für zeitweiligen Bedarf – Ingestion, Quantisierung, Spitzen – nicht für Grundlast.
- Bei der Systemdesign-Aufgabe kommen zuerst die Rückfragen, dann die Stufen mit Begründung der Reihenfolge, dann die Architektur.
- Sieben Konzepte überdauern die Werkzeuge. Wer sie begründen kann, kann eine Plattform entwerfen.

Quellen und Weiterlesen

- Dieses Buch, Kapitel 1 bis 16 – alle Zahlen und Begründungen dieses Kapitels sind dort hergeleitet.

- Die Referenzarchitekturen der Anbieter — NVIDIA, Kubernetes-Distributionen, Cloud-Anbieter — als Gegenprobe zur eigenen Rechnung, nicht als Vorlage.

Interview- und Whiteboard-Training

ZIEL	Die fünfzig Fragen, an denen sich Enterprise-AI-Infrastruktur-Wissen prüfen lässt — jeweils mit dem Unterschied zwischen einer richtigen und einer überzeugenden Antwort.
SETZT VORAUS	Die Kapitel des Buches. Jede Frage verweist auf die Stelle, an der die Herleitung steht.
DANACH KANNST DU	Auf Senior-Niveau über Enterprise-AI-Infrastruktur sprechen — und die eigenen Lücken kennen.

Dieser Anhang ist kein Auswendiglernstoff. Jede Antwort ist im Buch hergeleitet; hier steht die verdichtete Fassung mit dem, was eine Antwort von einer guten unterscheidet.

MERKE

So arbeiten Sie damit: Lesen Sie die Frage, formulieren Sie Ihre Antwort **laut** — nicht im Kopf — und lesen Sie erst dann weiter. Die Lücke zwischen dem, was man zu wissen glaubt, und dem, was man aussprechen kann, ist der eigentliche Prüfgegenstand.

Wo Sie ins Stocken geraten, gehen Sie in das genannte Kapitel zurück. Fünf Fragen je Sitzung genügen.

A.1 Phase 1: LLM- und Inferenz-Grundlagen

Diese zehn Fragen sind die Eintrittskarte. Wer sie nicht sicher beantwortet, wird nach den Kubernetes-Fragen gar nicht erst gefragt.

INTERVIEWFRAGE

1. Was passiert technisch, wenn ein Benutzer einen Prompt an ein LLM sendet?

Gut: Tokenisierung, Verarbeitung, Ausgabe Token für Token.

Senior: Fünf Abschnitte — Tokenisierung auf der CPU, Warteschlange im Scheduler, Prefill über alle Prompt-Token auf einmal, Decode Token für Token, Detokenisierung. Nur Prefill und Decode kosten GPU-Zeit, und sie sind grundverschieden: rechenbegrenzt gegen bandbreitenbegrenzt. **Kapitel 2.1**

INTERVIEWFRAGE

2. Was ist ein Token?

Gut: Eine Einheit aus dem Vokabular des Modells, meist ein Wortteil.

Senior: Ergänzt die betriebliche Konsequenz — Deutsch braucht rund die anderthalb- bis zweifache Tokenmenge gegenüber Englisch, Quellcode und JSON noch mehr. Wer Kostenschätzungen aus englischen Benchmarkzahlen ableitet, unterschätzt systematisch. **Kapitel 2.2**

INTERVIEWFRAGE

3. Was bedeutet Context Window?

Gut: Die maximale Zahl an Token aus Prompt und Ausgabe zusammen.

Senior: Die deklarierte Länge des Modells ist keine Betriebszusage. Was ein Server tatsächlich anbieten kann, ergibt sich aus dem KV-Cache — bei einem 8B-Modell auf 24 GiB oft ein Bruchteil des Deklarierten. Kontextlänge ist eine Kapazitätsentscheidung. **Kapitel 2.13**

INTERVIEWFRAGE

4. Unterschied zwischen Input- und Output-Token?

Gut: Eingabe wird gelesen, Ausgabe erzeugt; Ausgabe ist teurer.

Senior: Die Begründung — Input-Token werden im Prefill gemeinsam und hochparallel verarbeitet, Output-Token einzeln mit je einem vollständigen Durchlauf durch alle Gewichte. Daraus die Planungsregel: Input bestimmt den **Speicher** über den KV-Cache, Output die **Zeit**. **Kapitel 2.2**

INTERVIEWFRAGE

5. Was bedeutet TTFT?

Gut: Time to First Token — die Zeit bis zum ersten ausgegebenen Token.

Senior: Sie setzt sich aus Warteschlange und Prefill zusammen und wächst linear mit der Promptlänge. Sie ist die Kennzahl, die die Wahrnehmung prägt — und eine der beiden, auf die sich ein SLO sinnvoll formulieren lässt. **Kapitel 2.7 und 14.5**

INTERVIEWFRAGE

6. Was bedeutet Tokens per Second?

Gut: Wie viele Token je Sekunde erzeugt werden.

Senior: Die Unterscheidung zwischen der Rate **einer** Anfrage — begrenzt durch Bandbreite geteilt durch Modellgröße — und dem **Gesamtdurchsatz**, der über Batching ein Vielfaches erreicht. Wer beides verwechselt, dimensioniert falsch. **Kapitel 2.4 und 2.8**

INTERVIEWFRAGE

7. Was ist der KV Cache?

Gut: Zwischengespeicherte Key- und Value-Vektoren, damit nicht bei jedem Token die ganze Sequenz neu berechnet wird.

Senior: Die Formel $2LH_{kv} DB$ Bytes je Token, alle Werte aus der `config.json` – bei Llama 3.1 8B also 128 KiB je Token, ein Gigabyte je 8 192 Token. Und die Einordnung: Er ist der eigentliche Kapazitätsengpass, nicht die Gewichte. **Kapitel 2.5**

INTERVIEWFRAGE

8. Warum braucht ein LLM so viel GPU-RAM?

Gut: Gewichte und KV-Cache.

Senior: Die vollständige Bilanz – Gewichte, KV-Cache, Aktivierungen, CUDA-Kontext – mit der Feststellung, dass die Gewichte fix sind und der KV-Cache der variable Rest, der Gleichzeitigkeit und Kontextlänge bestimmt. Faustregel: Die Gewichte sollten höchstens zwei Drittel des nutzbaren Speichers belegen. **Kapitel 2.6 und 3.6**

INTERVIEWFRAGE

9. Unterschied zwischen Training und Inference?

Gut: Training passt Gewichte an, Inferenz nutzt sie.

Senior: Aus Betriebssicht: Training ist ein Stapelauftrag mit hohem Speicherbedarf für Gradienten und Optimiererzustände, planbar und unterbrechbar. Inferenz ist ein latenzkritischer Dauerdienst, dessen Speicherbedarf mit der Zahl gleichzeitiger Sequenzen wächst. Die Plattformen unterscheiden sich entsprechend. **Kapitel 1.2**

INTERVIEWFRAGE

10. Was bedeutet Quantisierung – FP16, FP8, INT8, INT4?

Gut: Reduzierte Genauigkeit, weniger Speicher.

Senior: Der Unterschied zwischen FP16 und BF16 – gleicher Speicher, anderer Wertebereich – die Hardwarevoraussetzung von FP8 ab Ada oder Hopper, und die Rechnung: 4 Bit spart nicht drei Viertel, sondern rund 60 Prozent, weil gruppenweise skaliert wird und Einbettung sowie Ausgabekopf unquantisiert bleiben. **Kapitel 3.2 und 3.4**

INTERVIEWFRAGE

Aufgabe: Ein Modell braucht 40 GB VRAM, Ihre Karte hat 24 GB.

Senior: Die geordnete Kette mit Begründung der Reihenfolge – Quantisierung zuerst, weil sie doppelt wirkt: weniger Speicher und schnellerer Decode, da die Modellgröße im Nenner der Bandbreitenformel steht. Dann Kontextlänge begrenzen, dann kleineres Modell, dann Tensor Parallelism, CPU-Offloading nur als Notlösung.

Die Rückfrage, die den Unterschied macht: **Sind mit den 40 GB die Gewichte allein gemeint oder inklusive KV-Cache?** Das ändert die Antwort vollständig. **Kapitel 3.6 und 9.1**

A.2 Phase 2: GPU-Infrastruktur

INTERVIEWFRAGE

11. Warum erkennt Kubernetes GPUs nicht automatisch wie CPU und RAM?

Gut: GPUs sind erweiterte Ressourcen und brauchen ein Device Plugin.

Senior: Die Begründung aus den Hardwareeigenschaften – CPU ist komprimierbar und drosselbar, Speicher überbuchbar und rückforderbar, eine GPU keines von beidem. Daraus folgen ganzzahlige, exklusive Vergabe, keine Überbuchung und die Regel, dass Request und Limit gleich sein müssen. **Kapitel 5.1**

INTERVIEWFRAGE

12. Was macht das NVIDIA Device Plugin?

Gut: Es meldet GPUs an das Kubelet.

Senior: Der vollständige Ablauf – Registrierung am Socket, fortlaufende Gerätemeldung, die im Knotenstatus als Kapazität erscheint, und bei der Zuteilung die Rückgabe der Angaben, mit denen der Container die Karte sieht. Entscheidend: Das Plugin **entscheidet**, das Container Toolkit **setzt um**. **Kapitel 5.1**

INTERVIEWFRAGE

13. Was macht der NVIDIA GPU Operator?

Gut: Er installiert und verwaltet den GPU-Stack.

Senior: Die Komponenten einzeln – NFD, GFD, Treiber, Toolkit, Device Plugin, DCGM, MIG Manager, Validator – mit dem Hinweis, dass Treiber und Toolkit abschaltbar sind und diese Entscheidung von der Knotenzahl abhängt. Bei vorhandenem Host-Treiber **müssen** sie abgeschaltet sein, sonst läuft der Treiber-Pod in eine Neustartschleife. **Kapitel 5.2**

INTERVIEWFRAGE

14. Welche Rolle spielen NVIDIA Driver, CUDA und Container Toolkit?

Senior: Treiber und Driver-API auf dem Host, CUDA-Laufzeit im Container, Toolkit als Bindeglied. Die Kompatibilitätsregel: Die Laufzeit im Container darf nicht neuer sein, als der Host-Treiber unterstützt – innerhalb einer Hauptversion mit Minor-Kompatibilität. Daraus die Betriebsregel: Host-Treiber neu halten, Images konservativ wählen. Ein Toolkit-Fehler ist nie durch Nachinstallation im Image zu beheben. **Kapitel 4.4**

INTERVIEWFRAGE

15. Was bedeutet `resources: limits: nvidia.com/gpu: 1`?

Gut: Der Pod bekommt eine GPU.

Senior: Es ist eine erweiterte Ressource, ganzzahlig und exklusiv. Der Request wird automatisch gleichgesetzt. Es bedeutet zugleich, dass ein Cluster mit einer Karte genau **einen** solchen Pod betreiben kann — ein zweiter bleibt in Pending, unabhängig davon, wie wenig der erste rechnet. **Kapitel 5.1**

INTERVIEWFRAGE

16. *Wie trennen Sie GPU-Nodes von normalen Worker Nodes?*

Senior: Zwei getrennte Probleme — `nodeSelector` führt GPU-Pods hin, ein Taint hält andere fern. Der zweite wird häufiger vergessen und ist teurer: Ohne ihn belegen beliebige Workloads CPU und Speicher der teuersten Maschine im Cluster.

Die Falle: Die DaemonSets des Operators müssen den Taint tolerieren, sonst verschwindet mit dem Device Plugin die GPU-Kapazität. **Kapitel 5.5**

INTERVIEWFRAGE

17. *Warum verwendet man Taints und Tolerations?*

Gut: Um zu steuern, welche Pods wo laufen.

Senior: Der Unterschied zur Affinität — ein Taint wirkt **abweisend** und ist die Voreinstellung, Affinität wirkt **anziehend** und muss je Workload gesetzt werden. Für teure Spezialhardware ist die abweisende Voreinstellung die richtige: Wer nichts sagt, landet nicht darauf. **Kapitel 5.5**

INTERVIEWFRAGE

18. *Was ist MIG?*

Gut: Aufteilung einer GPU in isolierte Instanzen.

Senior: Die Trennung erfolgt auf **Hardwareebene** — eigene Rechenwerke, Speicherbereiche, Speichercontroller, L2-Anteile. Damit ist MIG das einzige Verfahren mit echter Speicher- **und** Fehlerisolation. Voraussetzung ist eine Karte ab A100-Generation. Nachteile: Instanzen können nicht zusammenarbeiten, und eine Umkonfiguration erfordert eine leere GPU. **Kapitel 6.5**

INTERVIEWFRAGE

19. *Was ist GPU Time-Slicing?*

Gut: Der Treiber wechselt zwischen Prozessen; Kubernetes meldet die Karte mehrfach.

Senior: Der entscheidende Zusatz — es teilt **Rechenzeit**, nicht **Speicher**. Der VRAM bleibt gemeinsam und unbegrenzt. Zwei Pods können sich gegenseitig ins Out-of-Memory treiben, obwohl Kubernetes beide ordnungsgemäß geplant hat. **Kapitel 6.2**

INTERVIEWFRAGE

20. Wann MIG statt Time-Slicing?

Die Frage zielt auf genau einen Punkt.

Senior: Sobald **Speicherisolation** gebraucht wird — also bei jedem Mehrmandantenbetrieb mit Zusagen. Time-Slicing ist für Entwicklung und Test brauchbar und für Produktion mit Zusicherungen ungeeignet, weil der Ausfall sporadisch auftritt und der Anwendung zugeschrieben wird.

Der Zusatz, der Erfahrung zeigt: MIG braucht eine Karte ab A100 — auf Consumer-Hardware gibt es die Option gar nicht. **Kapitel 6.7**

A.3 Phase 3: vLLM

INTERVIEWFRAGE

21. Was ist vLLM?

Gut: Ein Inferenz-Server für Sprachmodelle mit OpenAI-kompatibler Schnittstelle.

Senior: Was ihn ausmacht — PagedAttention für blockweise KV-Cache-Verwaltung und Continuous Batching. Beides zusammen ergibt gegenüber einem einfachen Generierungsaufwurf eine Größenordnung mehr Durchsatz — nicht durch schnellere Kernel, sondern durch bessere Auslastung. **Kapitel 7.1**

INTERVIEWFRAGE

22. Warum nicht einfach Hugging Face Transformers als Produktionsserver?

Senior: Drei strukturelle Gründe, alle den KV-Cache betreffend: Reservierung auf die maximale Kontextlänge statt nach Bedarf — bei 500 genutzten von 4 096 reservierten Token ein Nutzungsgrad von 12 Prozent —, Zerstückelung des Speichers, und starre Batches, bei denen alle auf die längste Antwort warten.

Fair bleibt: Die Bibliothek ist für Forschung und Feinabstimmung gebaut und dort das richtige Werkzeug. **Kapitel 7.1**

INTERVIEWFRAGE

23. Was ist Continuous Batching?

Gut: Anfragen kommen und gehen einzeln statt als starrer Batch.

Senior: Die Entscheidung fällt **je Rechenschritt**, nicht je Batch. Die Rechnung dahinter: Bei statischem Batching bestimmt die längste Antwort die Belegung aller Plätze — erzeugt eine Anfrage 1 000 Token und neunzehn andere je 50, sind neunzehn Plätze über 95 Prozent der Zeit ungenutzt. **Kapitel 7.3**

INTERVIEWFRAGE

24. Was ist PagedAttention?

Gut: Blockweise Verwaltung des KV-Cache.

Senior: Die Analogie zur virtuellen Speicherverwaltung — Blocktabelle je Sequenz, physische Blöcke beliebig verteilt, Verschnitt nur im letzten Block. Der eigentliche Durchbruch ist aber, dass Blöcke **referenziert** statt kopiert werden können: Daraus folgen Prefix Caching und geteilte Blöcke bei mehreren Antwortvarianten. **Kapitel 7.2**

INTERVIEWFRAGE

25. Warum ist der KV Cache für vLLM wichtig?

Senior: Er ist der Engpass, den alles andere adressiert. Continuous Batching setzt voraus, dass Sequenzen jederzeit hinzukommen und wegfallen — das erfordert eine Speicherverwaltung ohne Zusammenhangserfordernis. PagedAttention ist deshalb nicht eine Optimierung neben anderen, sondern die Voraussetzung für alles Weitere. **Kapitel 7.1**

INTERVIEWFRAGE

26. Was bedeutet Tensor Parallelism?

Gut: Die Gewichtsmatrizen werden auf mehrere GPUs aufgeteilt.

Senior: Jede GPU rechnet an denselben Token mit, an einem Ausschnitt. Der Preis sind zwei Sammeloperationen je Schicht — bei 80 Schichten also 160 Synchronisationspunkte je Rechenschritt. Deshalb gehört TP in einen Server mit schneller Direktverbindung. Es senkt neben dem Speicherbedarf auch die Latenz, weil jede GPU nur ihren Anteil liest. **Kapitel 9.3**

INTERVIEWFRAGE

27. Was bedeutet Pipeline Parallelism?

Gut: Die Schichten werden auf GPUs aufgeteilt.

Senior: Nur eine Punkt-zu-Punkt-Übertragung je Stufengrenze statt Sammeloperationen — deshalb über Knotengrenzen brauchbar. Der Preis ist die Pipeline-Blase: Bei einer einzelnen Anfrage und vier Stufen liegt die Auslastung bei 25 Prozent. PP verbessert nur den Durchsatz unter Last, TP auch die Latenz. **Kapitel 9.4**

INTERVIEWFRAGE

28. Wann brauchen Sie mehrere GPUs?

Senior: Nur **ein** Grund erzwingt verteiltes Serving — das Modell passt nicht auf eine Karte. Durchsatz und Ausfallsicherheit werden durch mehr **Repliken** gelöst, und die skalieren besser: keine Kommunikation, kleinere Fehlerdomäne, einfacher Betrieb.

Und selbst dann erst nach der Leiter: quantisieren, Kontext begrenzen, kleineres Modell. **Kapitel 9.1**

INTERVIEWFRAGE

29. Wie stellen Sie mit vLLM eine OpenAI-kompatible API bereit?

Gut: Der Server bringt sie mit; vllm serve genügt.

Senior: Die betrieblich wichtigen Zusätze — `--served-model-name` für einen fachlichen Namen, der die Anwendung vom Modell entkoppelt, `--disable-log-requests` gegen Prompts im Log, ein Werkzeugauswerter für strukturierte Funktionsaufrufe, und die Feststellung, dass `/health` und `/metrics` absichtlich ungeschützt sind und über NetworkPolicies abgesichert werden müssen. **Kapitel 8.1**

INTERVIEWFRAGE

30. Wie würden Sie vLLM skalieren?

Senior: Horizontal über Repliken — mit dem Hinweis, dass Inferenz-Repliken **nicht** zustandslos sind: Jede hat ihren eigenen Prefix-Cache. Bei mehrstufigen Dialogen führt Reihum-Verteilung dazu, dass der Verlauf jedes Mal neu berechnet wird.

Skaliert wird auf die Warteschlangenlänge, nicht auf CPU. Und die Abkühlzeit muss ein Vielfaches der Ladezeit betragen, sonst pendelt der Dienst. **Kapitel 8.7 und 10.5**

A.4 Phase 4: Kubernetes und KServe

INTERVIEWFRAGE

31. Warum überhaupt Kubernetes für AI Inference?

Gut: Orchestrierung, Skalierung, Ausfallsicherheit.

Senior: Der eigentliche Grund ist ein anderer — die **Querschnittsthemen:** Identität, Secrets, Netzwerkregeln, Monitoring, GitOps existieren dort bereits. Zwei Drittel einer KI-Plattform sind klassisches Platform Engineering; Kubernetes ist die Umgebung, in der das schon gelöst ist. **Kapitel 1.6**

INTERVIEWFRAGE

32. Wann wäre Kubernetes unnötig?

Senior: Bei einem einzelnen Modell auf einem einzelnen Server ohne Mehrmandantenbetrieb — eine Systemd-Unit genügt und ist einfacher zu betreiben.

Die Grenze verläuft bei Anforderungen, nicht bei Größe: Sobald mehrere Modelle, mehrere Teams, Rollouts ohne Ausfall oder Kontingente gebraucht werden, kippt es. **Kapitel 10.1**

INTERVIEWFRAGE

33. Was ist ein KServe InferenceService?

Gut: Eine Ressourcenart, die ein Modell deklarativ bereitstellt.

Senior: Die Trennung – `ServingRuntime` beschreibt, **wie** ein Server startet, gepflegt vom Plattformteam; `InferenceService` beschreibt, **welches** Modell, geschrieben vom Anwendungsteam. Mit der ehrlichen Einordnung: Für einen einzelnen Dienst ist ein handgeschriebenes Deployment einfacher; der Nutzen entsteht ab dem fünften Modell.

Kapitel 10.2

INTERVIEWFRAGE

34. Wie deployen Sie ein Modell über `KServe`?

Senior: `InferenceService` mit Herkunftsangabe und Modellformat, das die Runtime auswählt. Die betrieblich wichtigen Punkte: `pvc://` ist der schnellste Bezugsweg, weil nichts kopiert wird; `hf://` gehört nicht in Produktion; die Startsonde muss die minutenlange Ladezeit abdecken. **Kapitel 10.3 und 10.4**

INTERVIEWFRAGE

35. Wie würden Sie Modelle versionieren?

Senior: Versionierte Verzeichnisse im Objektspeicher, niemals überschreiben, mit einem Beschreibungsdokument je Version – Herkunft, Revision, Prüfsummen, Quantisierung, Datenklasse, Freigabe. Im Git steht nur die Referenz.

Die Konsequenz: Ein Rollback ist eine Zeilenänderung, solange das alte Verzeichnis existiert. Wer aufräumt, macht daraus einen Stundenvorgang. **Kapitel 16.2**

INTERVIEWFRAGE

36. Wie führen Sie *Canary Deployments* durch?

Gut: Verkehrsanteil schrittweise erhöhen.

Senior: Die Reihenfolge – neue Version zuerst mit null Prozent Verkehr starten, dann den **fachlichen** Prüfsatz dagegen fahren, erst danach Verkehr geben. Ein Canary misst Fehler, Latenz und Durchsatz; er misst nicht, ob die Antworten schlechter geworden sind.

Und die Hardwarebedingung: Canary braucht doppelte GPU-Kapazität. Auf einem Einzel-Karten-Cluster ist es nicht möglich. **Kapitel 10.6**

INTERVIEWFRAGE

37. Wie funktioniert Autoscaling bei LLMs?

Senior: Auf die Warteschlangenlänge des Schedulers, mit der KV-Cache-Belegung als Frühindikator. Verdrängungen sind **kein** Skalierungssignal – dann ist es zu spät.

Der kritische Parameter ist die Abkühlzeit: Sie muss ein Vielfaches der Ladezeit betragen. Und eine neue Replik hilft erst nach Minuten – deshalb ist die Warteschlange ein Frühindikator und keine Notbremse. **Kapitel 10.5**

INTERVIEWFRAGE

38. Warum ist CPU-basierte Autoskalierung bei LLMs unzureichend?

Gut: Die Arbeit findet auf der GPU statt.

Senior: Jede Alternative mit ihrer Schwäche — Speicherauslastung ist konstant, weil der Server beim Start alles belegt; GPU-Auslastung zeigt nur, dass Kernel laufen; Anfragen je Sekunde ignorieren die Verarbeitungsdauer, denn zehn kurze und zehn sehr lange Anfragen bedeuten völlig verschiedene Last. **Kapitel 10.5**

A.5 Phase 5: AI Gateway

INTERVIEWFRAGE

39. Warum sollen Anwendungen nicht direkt OpenAI aufrufen?

Gut: Kostenkontrolle und Ausfallsicherheit.

Senior: Die Begründung aus der Informationsverteilung — nur an einer zentralen Stelle sind Identität, Inhalt, Kosten und erlaubtes Zielmodell **gleichzeitig** bekannt. Die Anwendung kennt ihren Nutzer, aber nicht die Budgets; der Inferenz-Server kennt die Last, aber nicht den Verursacher. Governance kann deshalb nur im Gateway stattfinden. **Kapitel 11.1**

INTERVIEWFRAGE

40. Warum verwendet man ein AI Gateway?

Senior: Sieben Dinge, die ohne es nicht gehen — Kosten je Team, Kontingente ohne eigene Hardware, Modellwechsel ohne Anwendungsänderung, Ausweichen bei Anbietersausfall, kontrollierte Protokollierung, Datenklassifikation im Anfragepfad, einheitliche Schnittstelle über Anbieter.

Der stärkste Einzelpunkt: Ein Kontingent ist die **bessere** Zusicherung als eine eigene GPU — feiner, sofort änderbar, nachweisbar, ohne Hardwareverschwendung. **Kapitel 11.1 und 11.4**

INTERVIEWFRAGE

41. Was macht LiteLLM?

Gut: Ein Proxy mit einheitlicher Schnittstelle über viele Anbieter.

Senior: Die Architektur — zustandsloser Proxy, Zustand in Datenbank und Cache. Zwei Einträge mit demselben Namen bilden eine Gruppe, über die verteilt und ausgewichen wird. Und die unbequeme Folge: Ohne Datenbank keine Schlüsselprüfung, also Totalausfall, obwohl alle Modelle laufen. **Kapitel 11.2 und 11.10**

INTERVIEWFRAGE

42. Wie implementieren Sie Rate Limiting?

Senior: Über Virtual Keys mit Anfragen und Token je Minute, hierarchisch von der Organisation bis zum Endnutzer. Mit dem Betriebshinweis: Bei mehreren Proxy-Repliken braucht es einen gemeinsamen Zähler – sonst begrenzt jede Replik für sich, und das wirksame Kontingent ist ein Vielfaches des konfigurierten. **Kapitel 11.3**

INTERVIEWFRAGE

43. *Wie ordnen Sie Kosten einzelnen Teams zu?*

Senior: Virtual Keys je Team, plus das Nutzerfeld für die Zuordnung bis auf die Person. Für **eigene** Modelle muss ein Preis hinterlegt werden – Kartenkosten geteilt durch erzeugte Token –, sonst erscheint Eigenbetrieb in jeder Auswertung kostenlos.

Der entscheidende Punkt: Dieser Preis hängt an der **Auslastung**, nicht am Anschaffungspreis. **Kapitel 11.7 und 14.8**

INTERVIEWFRAGE

44. *Was passiert, wenn OpenAI ausfällt?*

Gut: Fallback auf ein anderes Modell.

Senior: Die Grenze – Fallbacks müssen innerhalb derselben **Datenklasse** bleiben. Eine Kette, die von lokal nach extern ausweicht, verletzt im Störfall genau die Regel, wegen der lokal betrieben wird, und zwar unbemerkt. Für schützenswerte Anfragen lautet die richtige Reaktion: ablehnen. **Kapitel 11.4**

INTERVIEWFRAGE

45. *Wie bieten Sie Cloud- und lokale Modelle gemeinsam an?*

Senior: Über fachliche Modellnamen, die das Ziel verbergen, und eine Zuordnung nach Datenklasse. Die Anwendung fragt unternehmen-chat und weiß nicht, ob die Antwort aus dem eigenen Rechenzentrum oder von einem Anbieter kommt.

Damit wird ein Wechsel zur Plattformänderung statt zur Anwendungsänderung – was zusammen mit --served-model-name eine zweifache Entkopplung ergibt. **Kapitel 11.2**

A.6 Phase 6: Security

INTERVIEWFRAGE

46. *Wie authentifiziert sich ein Benutzer gegenüber der AI-Plattform?*

Senior: Über OIDC, mit Ansprüchen aus dem Verzeichnisdienst, die auf Team, Kontingent und Datenklasse abgebildet werden. Die Gruppenzugehörigkeit ist die Quelle der Wahrheit – eine Zuordnungstabelle im Gateway wäre eine zweite, die auseinanderläuft.

Das Gateway prüft lokal gegen zwischengespeicherte Schlüssel; ein Ausfall des Verzeichnisdienstes unterbricht nur die Ausgabe neuer Token. **Kapitel 12.2 und 12.3**

INTERVIEWFRAGE

47. *Wie authentifiziert sich eine Anwendung?*

Gut: Über einen Maschinenzugang mit Kennung und Geheimnis.

Senior: Der bessere Weg für Anwendungen **im Cluster** — ein projiziertes Dienstkonto-Token: kurzlebig, an eine Zielgruppe gebunden, automatisch erneuert, ohne abgelegtes Geheimnis. Damit entfällt die Rotationsfrage für diese Klasse vollständig.

Und die häufigste Fehlkonstruktion: ein persönlicher Zugang für eine Anwendung.

Kapitel 12.4

INTERVIEWFRAGE

48. *Wo liegen die OpenAI- oder Anthropic-API-Keys?*

Senior: In OpenBao, mit einer Richtlinie, die nur der Gateway-Rolle den Lesezugriff erlaubt, gebunden an Dienstkonto **und** Namensraum. Der Bezug erfolgt über einen Operator, der daraus ein Kubernetes-Secret erzeugt — im Repository steht nur der Verweis. **Kapitel 12.5 und 12.6**

INTERVIEWFRAGE

49. *Wie verhindern Sie, dass Entwickler Produktions-Keys sehen?*

Die Antwort ist keine Richtlinie, sondern die Architektur.

Senior: Der Schlüssel wird bei der Beschaffung **direkt** in den Speicher gelegt — eine Person sieht ihn, einmal. Danach kommen Anwendungen gar nicht an ihn heran, weil sie ausschließlich mit dem Gateway sprechen.

Der Nebeneffekt ist ebenso wertvoll: Weil kein Team einen eigenen Zugang hat, kann keines am Gateway vorbei arbeiten. **Kapitel 12.6**

INTERVIEWFRAGE

50. *Wie kontrollieren Sie, welche Daten externe Modelle erreichen dürfen?*

Senior: Zwei unabhängige Ebenen. Im Gateway die Modell-Allowlist je Team, gebunden an die Datenklasse — wobei die Klasse bestimmt wird, **bevor** das Ziel gewählt wird. Im Netzwerk ein grundsätzliches Egress-Verbot mit gezielten Ausnahmen, damit niemand am Gateway vorbeikommt.

Ohne die zweite Ebene ist die erste eine Empfehlung. Und der Inferenz-Server selbst braucht überhaupt keinen Internetzugang. **Kapitel 13.5 und 13.6**

A.7 Phase 7: Die Systemdesign-Aufgabe

INTERVIEWFRAGE

5 000 Mitarbeiter. Entwickler nutzen öffentliche Chat-Dienste direkt. Sensible Anwendungen sollen lokale Modelle nutzen. Zwei Rechenzentren und eine Cloud. Entwerfen Sie die Plattform.

Die vollständige Antwort steht in **Kapitel 17.10**. Der Aufbau in Kürze:

Erst Rückfragen — Datenklassen, Nutzungsvolumen, Prompt- und Ausgabelängen, agentische Anwendungen, bestehende Verträge, Teamgröße. Wer sofort zeichnet, hat die Aufgabe verkleinert.

Dann die Stufen — Gateway zuerst, weil es ohne GPU auskommt, sofort Kontrolle schafft und die Daten liefert, mit denen sich die Beschaffung begründen lässt. Dann Identität und Governance. Dann GPU-Knoten.

Dann die Architektur — getrennte Pools nach Lastprofil, Kapazitätsrechnung, rund acht bis zehn GPUs, davon etwa die Hälfte für Reserve und Profiltrennung.

Was die Antwort abrundet — die Feststellung, dass die Kapazität rechnerisch mit deutlich weniger Karten auskäme und die Beschaffung von Verfügbarkeit, Modellgröße und Lastprofiltrennung bestimmt wird.

A.7.1 Die dreizehn Nachfragen

Nach dem Entwurf kommen keine Wissensfragen mehr, sondern Belastungsproben. Jede lässt sich in zwei Sätzen beantworten, wenn die Herleitung sitzt.

Frage	Kern der Antwort	Kap.
Warum LiteLLM?	Nicht das Produkt ist die Antwort, sondern die Stelle: die einzige mit Identität, Inhalt, Kosten und Ziel gleichzeitig	11.1
Provider-Ausfall?	Fallback — aber innerhalb der Datenklasse; sonst ablehnen	11.5
1 000 gleichzeitige Prompts?	Warteschlange und Kontingente greifen; skaliert wird auf Wartende, nicht CPU. Eine neue Replik hilft erst nach Minuten	7.3, 10.5
Wie verhindern Sie, dass Finanzdaten OpenAI erreichen?	Klasse vor Zielwahl, Allowlist im Gateway, plus Egress-Verbot als zweite Ebene	13.5
Was, wenn die GPU voll ist?	Verdrängung — ein Alarm, kein Normalzustand. Bedeutet: KV-Cache zu klein	7.3
Wie skalieren Sie?	Repliken. Verteiltes Serving nur, wenn das Modell nicht auf eine Karte passt	9.1
Wer darf welches Modell?	Datenklasse aus Anwendung oder Rolle, Allowlist je Team, technisch durchgesetzt	13.5
Wer darf lokale Modelle nutzen?	Dieselbe Mechanik — die Klasse entscheidet, nicht die Person allein	13.3
Wie messen Sie Kosten?	Kartenkosten geteilt durch erzeugte Token; Auslastung ist der Hebel	14.8
Was passiert mit Prompts im Logging?	Nichts — Kennzahlen genügen für Abrechnung, Kapazität und Betrieb	11.6
Dürfen Sie Prompts überhaupt speichern?	Eigener Zweck, eigene Grundlage, eigene Frist. Nicht im Betriebsprotokoll	13.9

Frage	Kern der Antwort	Kap.
Wie rotieren Sie Provider-Secrets?	Überlappung, mit geprüftem Übergang vor dem Widerruf	12.7
Disaster Recovery?	Reihenfolge mit Secret-Speicher zuerst, Vektorbestände zuletzt	16.9

A.8 Zwei weitere Systemdesign-Aufgaben

Neben der großen Aufgabe gibt es zwei Varianten, die häufig gestellt werden – kleiner im Umfang, aber mit eigenen Fallstricken.

INTERVIEWFRAGE

Wir haben acht H100 in einem Kubernetes-Cluster. Wie stellen Sie die GPUs mehreren Teams zur Verfügung?

Der Fehler: sofort mit MIG antworten. Die Frage klingt nach GPU-Aufteilung und ist meistens keine.

Die Rückfrage: Nutzen die Teams **dasselbe** Modell oder verschiedene? Das entscheidet alles.

Bei demselben Modell – der häufigste Fall – ist die Antwort ein gemeinsamer Inferenz-Dienst mit Kontingenten im Gateway. Das nutzt die Hardware am besten, weil die Gewichte nur einmal im Speicher liegen und Continuous Batching über alle Teams hinweg greift. Eine GPU je Team wäre die teuerste und schlechteste Lösung: Sie vervielfacht die Hardware und verschlechtert gleichzeitig die Auslastung.

Bei verschiedenen Modellen wird aufgeteilt – und dann ist MIG richtig, weil es als einziges Verfahren Speicher- und Fehlerisolation bietet. Die Profile werden mit der VRAM-Bilanz gewählt, nicht nach Gefühl: Ein 1g. 10gb-Profil lässt nach Abzug eines 4-Bit-Modells und der Grundlast rund 3 GiB KV-Cache, also etwa 24 000 Token.

Die vollständige Antwort umfasst dann: Node-Pool-Trennung mit Taints, MIG-Profile passend zu den Modellgrößen, ResourceQuota je Namensraum, Kontingente im Gateway, DCGM-Monitoring mit Zuordnung zu Pod und Team, Kostenzuordnung über Token.

Was die Antwort abrundet: Zuerst die tatsächliche Auslastung messen, bevor man acht Karten in 56 Instanzen zerlegt. Und eine Karte als Reserve – ohne sie ist jedes Treiber-Update ein Ausfall. **Kapitel 6.7 und 6.14**

INTERVIEWFRAGE

Wir wollen für 500 Entwickler eine interne AI-Plattform betreiben. Einige Modelle laufen bei OpenAI und Azure, sensible Workloads sollen auf eigenen NVIDIA-GPUs laufen. Wie würden Sie die Plattform designen?

Diese Aufgabe entspricht der mittleren Architektur aus Kapitel 17.3. Die Antwort in der Reihenfolge, in der man sie entwickelt:

Kubernetes als Plattform – weil dort Identity, Secrets, Netzwerkregeln, Monitoring und GitOps bereits existieren. Zwei Drittel der Arbeit sind damit erledigt.

GPU-Worker-Knoten: NVIDIA GPU Operator für Treiber, Toolkit, Device Plugin und DCGM. Node-Pool-Trennung über Taints, damit gewöhnliche Workloads die teuren Knoten nicht belegen. MIG nur, wenn verschiedene Modelle isoliert laufen müssen.

Inferenz: vLLM als Server, KServe als Abstraktion darüber — sobald mehr als ein Modell im Spiel ist. Ein Modell der 7-bis-9B-Klasse in 4-Bit-Quantisierung deckt die Mehrheit der Fälle ab und lässt brauchbaren KV-Cache.

AI Gateway: LiteLLM davor. Es entscheidet anhand der Datenklasse, ob eine Anfrage zu einem externen Anbieter oder ins eigene Rechenzentrum geht — und die Anwendung merkt davon nichts, weil sie einen fachlichen Modellnamen anspricht.

Identity: Keycloak mit OIDC. Die Gruppenzugehörigkeit liefert Team und Datenklasse als Ansprüche im Token.

Secrets: OpenBao. Die Anbieterschlüssel liegen nur dort und werden nur vom Gateway gelesen — damit sieht sie kein Entwickler, und kein Team kann am Gateway vorbei arbeiten.

Netzwerk: NetworkPolicies mit grundsätzlichem Egress-Verbot und gezielten Ausnahmen. Der Inferenz-Server braucht überhaupt keinen Internetzugang.

Observability: Prometheus mit DCGM- und vLLM-Metriken, Grafana mit drei Dashboards für drei Zielgruppen, OpenTelemetry für Traces — ohne Prompt-Inhalte.

Delivery: Git, CI, Harbor, ArgoCD. Modelle liegen im Objektspeicher, im Git steht nur die Referenz.

Governance: Modell-Allowlist je Datenklasse, Kontingente je Team, Audit-Protokolle, Kostenzuordnung, festgelegte Prompt-Aufbewahrung.

Die Kapazitätsangabe, die überrascht: Bei 500 Entwicklern und realistischer Nutzung liegt der rechnerische Bedarf bei **einer** GPU. Beschafft werden zwei — für Wartung, Rollouts und Ausfallsicherheit, nicht für Durchsatz. Wer das begründen kann, hat die Rechnung geführt. **Kapitel 17.3 und 17.5**


A.9 Whiteboard-Skizzen

Auf Senior-Ebene wird nicht nur gefragt, sondern gezeichnet. Die folgenden acht Skizzen sollte man freihändig entwickeln können — nicht auswendig, sondern erklärend, Kasten für Kasten. Wer sie zeichnen **und** jede Box eine Minute lang verteidigen kann, besteht die meisten Architekturgespräche.

MERKE

So üben Sie: Decken Sie die Skizze ab, zeichnen Sie sie aus dem Gedächtnis und sprechen Sie dabei laut. Vergleichen Sie danach — nicht auf Vollständigkeit, sondern darauf, ob die **Reihenfolge** und die **Pfeilrichtungen** stimmen. Genau daran erkennt ein Gesprächspartner, ob jemand das System verstanden hat.


A.9.1 Skizze 1: Der Weg einer Anfrage



Was passiert zwischen Prompt und Antwort – Kapitel 2.1

Was dabei gesagt werden muss: Prefill und Decode sind verschiedene Workloads. Nur sie kosten GPU-Zeit. Der KV-Cache wächst mit jedem Token und ist der Kapazitätsengpass.

A.9.2 Skizze 2: Der GPU-Stack



Von der Karte bis zum Pod – Kapitel 4.4 und 5.1

Der Satz, der zählt: Der Treiber liegt auf dem Host, die CUDA-Laufzeit im Container – und die Laufzeit darf nicht neuer sein, als der Treiber unterstützt.


A.9.3 Skizze 3: GPU-Aufteilung

OHNE AUFTEILUNG	TIME-SLICING	MIG
GPU-Knoten ├ GPU 0 ├ GPU 1 ├ GPU 2 └ GPU 3	nvidia.com/gpu: 4 aber EINE Karte Speicher GEMEINSAM ohne Grenze	GPU 0 ├ Instanz A 10 GiB ├ Instanz B 10 GiB └ Instanz C 20 GiB
Eine GPU je Pod	Pods koennen sich gegenseitig ins OOM treiben	Speicher HART getrennt Ein Absturz betrifft nur die eigene Instanz

Time-Slicing gegen MIG – Kapitel 6


Die Pointe: Time-Slicing teilt Rechenzeit, nicht Speicher. MIG teilt die Hardware.

A.9.4 Skizze 4: Continuous Batching



Warum ein Inferenz-Server überlegen ist – Kapitel 7.3


A.9.5 Skizze 5: Das AI Gateway



Die Stelle mit allen Informationen – Kapitel 11.1


Was zu sagen ist: Nur hier sind alle vier Informationen gleichzeitig bekannt. Deshalb kann Governance nur hier stattfinden – nicht in der Anwendung, nicht im Server.

A.9.6 Skizze 6: Identität und Secrets



Wer darf was, und woher kommen die Schlüssel – Kapitel 12


A.9.7 Skizze 7: Die Sicherheitsschichten



Reihenfolge der Prüfungen – Kapitel 13

Der Punkt, der oft fehlt: Die Datenklasse wird bestimmt, **bevor** das Ziel gewählt wird. Und die Netzwerkebene ist unabhängig – ohne sie ist das Gateway umgehbar.

A.9.8 Skizze 8: Die vollständige Plattform



Was am Ende auf dem Whiteboard steht – Kapitel 17.12

MERKE

Diese letzte Skizze ist die, nach der am häufigsten gefragt wird. Zwei Ergänzungen machen den Unterschied zwischen einer auswendig gelernten und einer verstandenen Zeichnung:

Erstens der Hinweis, dass ungefähr zwei Drittel dieses Bildes klassisches Platform Engineering sind — Kubernetes, Identity, Secrets, Netzwerk, Monitoring, Registry, GitOps. Wirklich neu sind vier Kästen.

Zweitens die Frage nach der Reihenfolge des Aufbaus: von oben nach unten, weil das Gateway ohne GPU auskommt und die Daten liefert, mit denen sich die Beschaffung begründen lässt.

A.10 Vertiefungsfragen

Die fünfzig Fragen prüfen Wissen. Die folgenden prüfen, ob es sich zu etwas zusammensetzt — sie werden gestellt, wenn eine Antwort gut war und der Gesprächspartner nachfassen will.

A.10.1 Zu Inferenz und Speicher

INTERVIEWFRAGE

Ein Kollege sagt, eine schnellere GPU löse das Latenzproblem. Was antworten Sie?

Senior: Es kommt darauf an, welche Latenz. Ist die TTFT hoch, hilft Rechenleistung — der Prefill ist rechenbegrenzt. Ist die TPOT hoch, hilft sie **nicht**, weil der Decode an der Speicherbandbreite hängt. Eine Karte mit doppelter Rechenleistung und gleicher Bandbreite liefert praktisch dieselbe Token-Rate.

Die wirksamere Maßnahme wäre dann Quantisierung: Sie verkleinert den Divisor in der Bandbreitenformel und beschleunigt den Decode unmittelbar. **Kapitel 2.4 und 4.2**

INTERVIEWFRAGE

Warum wird Ihr Durchsatz bei mehr Nutzern nicht schlechter, die Latenz aber schon?

Senior: Weil Batching den Durchsatz fast linear mitwachsen lässt, solange KV-Cache und Rechenleistung reichen — die Bandbreitenkosten des Gewichtelesens fallen je Decode-Schritt nur einmal an. Die Einzellatenz steigt trotzdem leicht, weil mehr Sequenzen im Batch mehr Rechenlast je Schritt bedeuten.

Kippt es, dann abrupt: Sobald der KV-Cache voll ist, beginnt Verdrängung, und dann bricht beides ein. **Kapitel 2.8 und 7.4**

INTERVIEWFRAGE

Ein Modell hat 128k Kontext. Ihre Anwendung nutzt 4k. Was ändern Sie?

Senior: --max-model-len auf den tatsächlichen Bedarf setzen — mit Reserve, aber nicht auf den Modellwert. Das ist keine Sparmaßnahme, sondern eine Kapazitätsent-

scheidung: Der KV-Cache wird nach dieser Grenze aufgeteilt, und die mögliche Gleichzeitigkeit ist Token-Budget geteilt durch Kontextlänge.

Bei 4 096 statt 32 768 Token passen achtmal so viele Anfragen gleichzeitig. **Kapitel 2.13 und 8.4**

A.10.2 Zu GPU und Kubernetes

INTERVIEWFRAGE

Nach einem Knoten-Neustart schlagen Ihre Inferenz-Pods fehl. Woran liegt es?

Senior: Vermutlich an der Startreihenfolge. Das Kubelet meldet den Knoten nach etwa zwanzig Sekunden als bereit, aber Treiber, Toolkit und Device Plugin brauchen bis zu neunzig. In dieses Fenster geplante Pods finden eine nicht funktionsfähige GPU – oder scheitern erst beim ersten CUDA-Aufruf.

Die Absicherung ist ein Init-Container, der selbst eine GPU anfordert und auf ihre Verfügbarkeit wartet, statt sich auf den Knotenzustand zu verlassen. **Kapitel 5.8**

INTERVIEWFRAGE

Ihre GPU-Kapazität ist plötzlich verschwunden, die Hardware ist unverändert. Wo suchen Sie?

Senior: Drei Kandidaten in dieser Reihenfolge. Erstens: Wurde ein Taint gesetzt, den die Operator-DaemonSets nicht tolerieren? Dann verschwindet mit dem Device Plugin die Kapazität. Zweitens: Läuft das Device Plugin, findet aber keine Karte – dann Treiber prüfen. Drittens, unter RKE2: Wurde der Knoten neu gestartet, nachdem jemand `config.toml` statt der Vorlage angepasst hatte? Dann ist die Anpassung überschrieben. Der Validator des Operators sagt einem, welche Stufe bricht. **Kapitel 5.4 und 5.8**

INTERVIEWFRAGE

Zwei Teams beschwerten sich über sporadische Abstürze. Beide nutzen dieselbe GPU. Was ist los?

Senior: Mit hoher Wahrscheinlichkeit Time-Slicing ohne Speicherisolation. Kubernetes hat beide Pods korrekt geplant, das Device Plugin korrekt zugeteilt – und trotzdem stirbt einer an Out-of-Memory, weil der andere zuerst da war und mehr belegt hat.

Der Nachweis ist einfach: `nvidia-smi` auf dem Knoten zeigt eine physische Karte mit mehreren Prozessen, während Kubernetes mehrere Geräte meldet. Genau diese Diskrepanz ist das Verfahren. **Kapitel 6.3**

A.10.3 Zu Serving und Betrieb

INTERVIEWFRAGE

Ihr Dienst läuft seit Wochen stabil. Nach einem Update ist er langsamer. Was prüfen Sie zuerst?

Senior: Den Startlog – und zwar die KV-Cache-Größe. Ein Update des Inferenz-Servers kann Voreinstellungen ändern, etwa beim Token-Budget oder bei den Batchgrenzen, und damit den verfügbaren Cache verschieben. Die Konfiguration ist unverändert, die Kapazität nicht.

Zweitens die gewählte Kernel-Implementierung: Fällt der Server auf eine allgemeine Rückfallvariante zurück, zeigt sich das nur in der Latenz, nicht im Fehlerlog.

Deshalb gehört nach jedem Update die Rampenmessung wiederholt. **Kapitel 7.11 und 16.10**

INTERVIEWFRAGE

Ein Team meldet, dass Antworten manchmal Sekunden später beginnen. Die Metriken sehen gut aus.

Senior: Zwei Möglichkeiten. Erstens Head-of-Line-Blocking – ein einzelner langer Prompt hält die Decodes aller laufenden Anfragen an. Das bewegt keinen Mittelwert, nur das 99. Perzentil. Zweitens Pufferung im Ingress: Wenn die strömende Ausgabe gesammelt und am Ende auf einmal ausgeliefert wird, sieht die serverseitige TTFT hervorragend aus, und der Nutzer wartet trotzdem.

Der zweite Fall wird fast nie zuerst geprüft, weil er keine Metrik bewegt und keine Meldung erzeugt. Die Prüfung erfolgt aus Nutzersicht. **Kapitel 2.9, 11.9 und 14.13**

INTERVIEWFRAGE

Sie sollen Scale-to-Zero einführen, um Kosten zu sparen. Was sagen Sie?

Senior: Eine Rückfrage nach dem Anwendungsfall, dann eine Rechnung. Für interaktive Dienste ist es ungeeignet: Der Kaltstart kostet die volle Ladezeit von Minuten, und die trifft genau den Nutzer, der als Erster nach einer Ruhephase fragt.

Die bessere Antwort auf dasselbe Ziel ist Warmhaltung mit reduzierter Kapazität – nachts eine Replik statt drei spart zwei Drittel, ohne dass jemand drei Minuten wartet.

Geeignet ist Scale-to-Zero für Stapelbetrieb, Entwicklungsumgebungen und selten genutzte Fachmodelle. **Kapitel 10.5**

A.10.4 Zu Governance und Kosten

INTERVIEWFRAGE

Der Datenschutz verlangt, alle Prompts zu protokollieren. Wie gehen Sie damit um?

Senior: Nicht mit Widerspruch, sondern mit einer Rückfrage nach dem **Zweck**. Für Abrechnung, Kapazitätsplanung und Betrieb genügen Kennzahlen ohne Inhalte vollständig. Wenn Inhalte gebraucht werden, dann für Nachweispflichten oder Qualitätsuntersuchung – und das sind eigene Zwecke mit eigener Rechtsgrundlage, eigener Frist und eigenem Zugriffsschutz.

Der Punkt, den man vorbringen sollte: Vollständige Protokolle bedeuten, dass personenbezogene Daten und Geschäftsgeheimnisse in der Log-Pipeline landen, in deren

Aufbewahrung und in Backups. Das erzeugt genau das Risiko, das der Datenschutz eigentlich begrenzen will. **Kapitel 11.6 und 13.9**

INTERVIEWFRAGE

Die Leitung fragt, warum die KI-Plattform teurer ist als erwartet. Was zeigen Sie?

Senior: Die Kosten je Million Token im Zeitverlauf, nicht die Gesamtsumme. Steigt die Nutzung und sinkt dieser Wert, arbeitet die Plattform besser — das ist ein Argument für weitere Investitionen. Steigt er, ist die Auslastung gefallen, und dann ist die Konsequenz Kapazität zurückzubauen.

Der ehrliche Teil der Antwort: In allen Größenordnungen ist der **Betriebsaufwand** der größte Posten, deutlich vor der Hardware. Wer eine Plattform mit Hardwarekosten begründet hat, hat sie um den Faktor zwei bis drei unterschätzt. **Kapitel 14.12 und 17.6**

INTERVIEWFRAGE

Ein Fachbereich will ein Modell einsetzen, das Sie für ungeeignet halten. Wie argumentieren Sie?

Senior: Nicht mit einer Meinung, sondern mit dem Prüfsatz. Fünfzig bis hundert echte Prompts aus dem Anwendungsfall, gefahren gegen beide Kandidaten bei *temperature* 0, ausgewertet zuerst auf maschinell prüfbare Formattreue.

Das verlagert die Diskussion von „ich halte das für besser“ zu einer Zahl, die beide Seiten akzeptieren können. Und es kann sein, dass der Fachbereich recht hat — das ist ausdrücklich ein möglicher Ausgang. **Kapitel 3.6**

A.11 Fragen, die Sie selbst stellen sollten

Ein Gespräch verläuft in beide Richtungen. Die folgenden Fragen zeigen, dass man Plattformbetrieb kennt — und sie beantworten, ob die Stelle taugt.

Frage	Was die Antwort verrät
Wie viele GPUs betreiben Sie, und wie ausgelastet sind sie?	Ob überhaupt gemessen wird. Wer die Auslastung nicht kennt, hat kein Monitoring — oder keine Plattform
Gibt es bereits ein Gateway, oder rufen Anwendungen direkt auf?	Der Reifegrad aus Kapitel 1.5. Ohne Gateway ist die erste Aufgabe klar
Wer legt fest, welche Daten externe Modelle erreichen dürfen?	Ob Governance existiert oder improvisiert wird
Werden Prompts protokolliert — und auf welcher Grundlage?	Ob die Frage überhaupt gestellt wurde. Ein „das machen wir schon irgendwie“ ist ein Warnzeichen
Wie groß ist das Team, das die Plattform betreibt?	Ob der laufende Aufwand aus Kapitel 16.10 eingeplant ist
Was war der letzte Vorfall, und was haben Sie geändert?	Die aufschlussreichste Frage überhaupt — sie zeigt Betriebsreife und Fehlerkultur
Gibt es einen zweiten GPU-Knoten?	Ob Wartung ohne Ausfall möglich ist. Die Antwort sagt viel über den Reifegrad

MERKE

Die vorletzte Zeile ist die wertvollste. Eine Organisation, die konkret von einem Vorfall erzählen kann und was daraus folgte, betreibt tatsächlich etwas. Eine, die ausweicht, hat entweder nichts in Produktion – oder keine Kultur, in der Fehler besprochen werden.

A.12 Was nach dem Fachlichen kommt

Auf Senior-Ebene folgen Fragen, die keine technische Antwort haben – und deren Beantwortung mehr über die Eignung sagt als jede Wissensfrage.

Frage	Worauf sie zielt
Ein Fachbereich will ein Modell, das Sie für ungeeignet halten.	Können Sie mit Messwerten argumentieren statt mit Meinung? Der Prüfsatz aus Kapitel 3 ist die Antwort
Die Leitung will die zweite GPU streichen.	Können Sie erklären, dass sie für Wartbarkeit da ist, nicht für Durchsatz? Kapitel 4 und 17
Ein Team umgeht die Plattform.	Verstehen Sie, dass Umgehung ein Symptom ist? Der kontrollierte Weg muss bequemer sein – Kapitel 1 und 13
Der Datenschutz verlangt vollständige Prompt-Protokolle.	Können Sie den Zielkonflikt benennen, statt einfach zuzustimmen? Kapitel 11 und 13
Was würden Sie anders machen?	Haben Sie aus eigenen Entscheidungen gelernt – oder nur Anleitungen befolgt?

MERKE

Die letzte Zeile ist die, auf die man sich am schlechtesten vorbereiten kann und die am meisten aussagt. Eine gute Antwort nennt eine konkrete eigene Entscheidung, ihre Folgen und die Korrektur – nicht eine allgemeine Betrachtung.

Wer das Referenz-Lab aus dem Vorwort tatsächlich gebaut hat, hat dafür Material. Wer nur gelesen hat, nicht. Das ist der eigentliche Grund für die Labs in diesem Buch.

A.13 Selbsteinschätzung

Zum Abschluss eine Liste zum Abhaken. Sie ist nach Aufwand geordnet, nicht nach Wichtigkeit.

Ich kann...	sicher	ungefähr	nicht
die KV-Cache-Formel anwenden			
eine VRAM-Bilanz aufstellen			
Prefill und Decode unterscheiden und begründen			
den GPU-Stack von unten nach oben erklären			
die RKE2-Besonderheit benennen			
Time-Slicing gegen MIG abgrenzen			
PagedAttention erklären			
vLLM-Parameter begründet setzen			

Ich kann...	sicher	ungefähr	nicht
ein Deployment mit allen Sonden schreiben			
TP gegen PP einordnen			
einen InferenceService erklären			
Autoscaling-Signale begründen			
die Gateway-Begründung aus der Informationsverteilung führen			
den Weg eines Provider-Schlüssels beschreiben			
Datenklassifikation technisch durchsetzen			
die Auslastungsfälle erklären			
die Break-even-Rechnung führen			
RAG-Berechtigungen richtig verorten			
einen Modellwechsel über GitOps beschreiben			
die Systemdesign-Aufgabe frei entwickeln			

MERKE

Zwanzig Punkte. Wer bei mindestens fünfzehn „sicher“ ankreuzt und die Systemdesign-Aufgabe frei entwickeln kann, ist für Gespräche auf dieser Ebene gut aufgestellt.

Die letzten beiden Zeilen wiegen dabei schwerer als die ersten achtzehn: Sie prüfen nicht Wissen, sondern ob es sich zu etwas zusammensetzt.

Referenz-Repository

Die Struktur aus Kapitel 16, ausgeschrieben. Sie ist als Ausgangspunkt gedacht, nicht als Vorschrift — jede Organisation hat Konventionen, die Vorrang haben.

B.1 Vollständige Struktur

enterprise-ai-platform/			
├─ README.md			
├─ infrastruktur/			
│ └─ terraform/			
│ │ └─ knoten.tf			
│ │ └─ netzwerk.tf			
│ │ └─ objektspeicher.tf			
│ └─ ansible/			
│ │ └─ gpu-treiber.yml			
│ │ └─ container-toolkit.yml			
│ └─ rke2.yml			
├─ plattform/			
│ └─ gpu-operator/			
│ │ └─ application.yaml			
│ │ └─ values.yaml			
│ └─ kserve/			
│ │ └─ application.yaml			
│ │ └─ runtimes/			
│ │ │ └─ vllm.yaml			
│ │ │ └─ embedding.yaml			
│ └─ keycloak/			
│ │ └─ realm-plattform.yaml			
│ │ └─ gruppen.yaml			
│ └─ openbao/			
│ │ └─ policies/			
│ │ │ └─ auth-rollen.yaml			
│ └─ monitoring/			
│ │ └─ regeln/			
│ │ │ └─ alarme.yaml			
│ │ │ └─ verdichtung.yaml			
│ │ └─ dashboards/			
│ │ │ └─ hardware.json			
│ │ │ └─ dienste.json			
│ │ └─ kosten.json			
│ └─ netzwerk/			
│ │ └─ egress-grundregel.yaml			
│ └─ ausnahmen/			
├─ dienste/			
│ └─ gateway/			
│ │ └─ deployment.yaml			
│ │ └─ config.yaml			
│ │ └─ externalsecret.yaml			
│ └─ inferenz/			
│ │ └─ chat.yaml			
│ │ └─ rag.yaml			
│ │ └─ stapel.yaml			
│ └─ einbettung/			
│ └─ deployment.yaml			
│ └─ rag/			
│ │ └─ ingestion-cronjob.yaml			
│ └─ pgvector.yaml			
├─ katalog/			
│ └─ modelle.yaml			
│ └─ teams.yaml			
├─ umgebungen/			
│ └─ dev/			
│ │ └─ kustomization.yaml + werte.yaml			
│ └─ stage/			
│ │ └─ kustomization.yaml + werte.yaml			
│ └─ prod/			
│ │ └─ kustomization.yaml + werte.yaml			
├─ pruefsaetze/			
│ └─ formattreue/			
│ │ └─ faelle.jsonl			
│ │ └─ pruefen.py			
│ └─ abruf/			
│ │ └─ fragen.jsonl			
│ └─ pruefen.py			
├─ werkzeuge/			

B.2 Der Modellkatalog

Die Datei, aus der Gateway-Konfiguration und Nachweise erzeugt werden — Kapitel 13.

```
# katalog/modelle.yaml
modelle:
  - name: unternehmen-chat
    ziel: lokal
    pfad: qwen2.5-7b-instruct/awq-2026-03-15
    zweck: Assistent fuer Dialog und Zusammenfassung
    datenklasse: vertraulich
    kontext: 8192
    profil: chat
    freigabe:
      datum: 2026-03-18
      durch: [plattform, datenschutz]
    pruefsatz: formattreue/2026-03-17.json

  - name: unternehmen-rag
    ziel: lokal
    pfad: qwen2.5-7b-instruct/awq-2026-03-15
    zweck: Abrufgestuetzte Antworten
    datenklasse: vertraulich
    kontext: 16384
    profil: rag

  - name: extern-gross
    ziel: azure
    zweck: Komplexe Analysen ohne schutzwuerdige Daten
    datenklasse: intern
    vertrag: AVV-2025-114
    freigabe:
      datum: 2025-11-02
      durch: [plattform, datenschutz, einkauf]
```

MERKE

Die ersten beiden Einträge zeigen ein Muster aus Kapitel 17: **dasselbe Modell, zwei Endpunkte** — weil Chat und RAG verschiedene Kontextgrenzen und Parameter brauchen. Der Katalog macht das sichtbar, statt es in zwei ähnlichen Manifesten zu verstecken.

B.3 Die Teamdefinition

```
# katalog/teams.yaml
teams:
  - name: team-recht
    kostenstelle: KST-4711
    datenklasse: vertraulich
```

```
modelle: [unternehmen-chat, unternehmen-rag]
budget: {betrag: 500, zeitraum: 30d}
grenzen: {rpm: 120, tpm: 200000}

- name: team-marketing
  kostenstelle: KST-2200
  datenklasse: intern
  modelle: [unternehmen-chat, extern-gross]
  budget: {betrag: 300, zeitraum: 30d}
  grenzen: {rpm: 60, tpm: 100000}

- name: ingestion
  kostenstelle: KST-4711
  zweck: Stapelbetrieb -- eigenes Kontingent # Kapitel 15
  modelle: [einbettung]
  budget: {betrag: 200, zeitraum: 30d}
  grenzen: {rpm: 3000, tpm: 5000000}
```

B.4 Umgebungswerte

```
# umgebungen/prod/werte.yaml
modell:
  pfad: qwen2.5-7b-instruct/awq-2026-03-15
  revision: alb2c3d4
engine:
  kontext: 8192
  sequenzen: 24
  speicher: "0.90"
repliken:
  chat: 2
  rag: 2
gpu:
  knoten_label: node-role/gpu
```

Der dritte Eintrag ist der aus Kapitel 15: Ingestion bekommt ein eigenes Kontingent, damit sie den Abfragebetrieb des Teams nicht verdrängt.

Dieselbe Datei in dev unterscheidet sich in wenigen Zeilen – meist der Modellversion und der Replikatzahl. Die Struktur liegt einmal in basis/.

B.5 Was nicht ins Repository gehört

Nicht ins Git	Sondern
Modellgewichte	Objektspeicher; im Git nur die Referenz – Kapitel 16
Provider-Schlüssel	OpenBao; im Git nur der Verweis – Kapitel 12
Client-Geheimnisse	OpenBao
Vektorbestände	Datenbank; reproduzierbar aus den Quellen – Kapitel 15
Prompt-Inhalte	Nirgends – Kapitel 11 und 13
Erzeugte Konfiguration	Wird aus dem Katalog gebaut, nicht gepflegt

Kommando- und Konfigurationsreferenz

GESCHRIEBEN GEGEN

NVIDIA-Treiber 550+ · DCGM Exporter 3.3.x · Kubernetes 1.31 · vLLM 0.8.x · LiteLLM 1.6x
· Stand September 2026

Zum Nachschlagen. Verbindlich ist immer die Dokumentation der eingesetzten Version — diese Zusammenstellung ersetzt sie nicht, sondern erspart das Suchen im Alltag.

C.1 nvidia-smi

Aufruf	Zweck
nvidia-smi	Überblick: Treiber, CUDA-Obergrenze, Belegung, Prozesse
nvidia-smi -L	Karten mit UUID — die stabile Kennung
nvidia-smi -q	Vollständiger Zustandsbericht
nvidia-smi -q -d ECC,TEMPERATURE	Nur genannte Abschnitte
nvidia-smi topo -m	Verbindungstopologie — vor jedem TP-Einsatz
nvidia-smi dmon -s pucm	Kennzahlen im Sekundentakt
nvidia-smi pmon -s um	Kennzahlen je Prozess
nvidia-smi -pl <Watt>	Leistungsgrenze setzen
nvidia-smi -r -i <Index>	Karte zurücksetzen — nur ohne laufende Prozesse
nvidia-smi mig -lgip	Verfügbare MIG-Profile
nvidia-smi mig -lgi	Eingerichtete MIG-Instanzen

Maschinenlesbar für Skripte und Monitoring:

```
nvidia-smi --format=csv,noheader,nounits --query-gpu=\
index,name,uuid,memory.total,memory.used,utilization.gpu,\
temperature.gpu,power.draw,clocks.sm
```

C.1.1 Topologie-Kürzel

Kürzel	Bedeutung
NV#	NVLink mit Anzahl der Verbindungen — der beste Fall
PIX	Über einen PCIe-Switch — gut
PXB	Über mehrere PCIe-Switches — brauchbar
PHB	Über den Host-Bridge-Controller

nvidia-smi --help-query-gpu listet alle verfügbaren Felder. Die Liste ist lang und lohnt einen Blick vor dem eigenen Skript.

Kürzel	Bedeutung
NODE	Innerhalb eines NUMA-Knotens, über die CPU
SYS	Über die Verbindung zwischen CPU-Sockeln — der schlechteste Fall

C.2 Xid-Codes

Vollständigere Tabelle in Kapitel 4.9. Die Triage in Kurzform:

Codes	Ursprung	Reaktion
13, 31, 43, 45	Anwendung	Pod neu starten; Code oder Bibliotheksversion prüfen
48, 63, 64, 92, 94	Hardware	Beobachten; bei Häufung Austausch vormerken
74	Hardware	NVLink prüfen
79, 95	Hardware, schwer	Knoten aus dem Scheduling nehmen

C.3 Kubernetes für GPUs

Aufruf	Zweck
<code>kubectl describe node <n></code>	Kapazität und Zuteilung im Abschnitt Capacity
<code>kubectl get runtimeclass</code>	Ist die NVIDIA-Runtime registriert
<code>kubectl get clusterpolicy -o yaml</code>	Wirksame Operator-Konfiguration
<code>kubectl -n gpu-operator get pods</code>	Zustand der Operator-Komponenten
<code>kubectl get isvc -A</code>	Alle InferenceServices mit Bereitschaft
<code>kubectl get scaledobject,hpa</code>	Skalierungszustand

Kapazität und Zuteilung im Überblick:

```
kubectl get nodes -o json | jq -r '
.items[] | select(.status.capacity["nvidia.com/gpu"])
| [ .metadata.name,
    .status.capacity["nvidia.com/gpu"],
    (.metadata.labels["nvidia.com/gpu.product"] // "-") ]
| @tsv'
```

C.4 vLLM: Engine-Argumente

Vollständige Referenz in Kapitel 8.2. Die Argumente, die man täglich braucht:

Argument	Vorgabe	Wirkung
<code>--model</code>	–	Pfad oder Repository-Kennung
<code>--served-model-name</code>	Pfad	Fachlicher Name — entkoppelt die Anwendung
<code>--revision</code>	main	Version festnageln — in Produktion setzen
<code>--dtype</code>	auto	Folgt der <code>config.json</code>

Argument	Vorgabe	Wirkung
<code>--max-model-len</code>	Modell	Kapazitätsentscheidung , nicht Formatität
<code>--gpu-memory-utilization</code>	0.9	Anteil des VRAM
<code>--max-num-seqs</code>	versch.	Gleichzeitige Sequenzen
<code>--max-num-batched-tokens</code>	versch.	Token-Budget je Schritt
<code>--kv-cache-dtype</code>	auto	fp8 halbiert den KV-Bedarf
<code>--enable-prefix-caching</code>	meist an	Wiederverwendung von Präfixen
<code>--enable-chunked-prefill</code>	meist an	Gegen Head-of-Line-Blocking
<code>--enable-lora</code>	aus	Mehrere Adapter — Kapitel 8.4
<code>--tensor-parallel-size</code>	1	GPUs je Modellkopie
<code>--disable-log-requests</code>	aus	In Produktion setzen
<code>--enforce-eager</code>	aus	Kürzerer Start, höherer Aufwand je Schritt

C.4.1 Metriken

Metrik (Präfix <code>vllm:</code>)	Verwendung
<code>num_requests_running</code>	Auslastung
<code>num_requests_waiting</code>	Skalierung und Alarm
<code>gpu_cache_usage_perc</code>	Frühindikator
<code>num_preemptions_total</code>	Alarm — KV-Cache zu klein
<code>time_to_first_token_seconds</code>	SLO — als Perzentil
<code>time_per_output_token_seconds</code>	SLO — als Perzentil
<code>generation_tokens_total</code>	Durchsatz und Kosten
<code>prefix_cache_hits_total</code>	Wirksamkeit des Präfix-Caches

C.5 vLLM: Änderungen nach 0.8.x

Dieses Buch ist gegen vLLM 0.8.x geschrieben und geprüft. Wer eine deutlich neuere Fassung einsetzt, trifft auf vier Argumente, die es so nicht mehr gibt. Dieser Abschnitt nennt sie, damit sich ein Befehl aus diesem Buch übersetzen lässt, statt nur zu scheitern.

Argument im Buch	Status	Heutige Entsprechung
<code>--disable-log-requests</code>	entfernt	<code>--enable-log-requests</code> — mit umgekehrter Bedeutung, siehe unten
<code>--task embed</code>	ersetzt	<code>--runner pooling</code> ; umgewidmete Modelle: <code>--convert embed</code>
<code>--swap-space</code>	ersetzt	<code>--kv-offloading-size</code> in GiB, dazu <code>--kv-offloading-backend</code>
<code>--gpu-memory-utilization</code>	Vorgabe	vorhanden wie bisher; die Vorgabe ist von 0.9 auf 0.92 gestiegen

ACHTUNG

Bei `--disable-log-requests` hat sich nicht nur der Name geändert, sondern die Voreinstellung. In 0.8.x wurden Anfragen standardmäßig protokolliert, und das Flag schaltete das ab. Heute ist das Protokollieren standardmäßig aus, und `--enable-log-requests` schaltet es ein. Die Betriebsregel aus Kapitel 8.15 gilt unverändert – Prompts gehören nicht ins Containerlog. Sie verlangt heute nur keine Maßnahme mehr, sondern eine unterlassene.

Alle übrigen in diesem Buch verwendeten Engine-Argumente wurden gegen beide Fassungen geprüft und sind unverändert gültig, einschließlich der Vorgabewerte. Die Liste deckt nur ab, was hier tatsächlich vorkommt; eine vollständige Änderungsliste ist sie nicht. Für DCGM, KServe und LiteLLM steht eine entsprechende Prüfung aus.

C.6 DCGM-Metriken

Metrik	Einordnung
DCGM_FI_DEV_GPU_UTIL	Nur Anwesenheitsanzeige – Kapitel 14.2
DCGM_FI_PROF_DRAM_ACTIVE	Die aussagekräftige Zahl für Decode
DCGM_FI_PROF_PIPE_TENSOR_ACTIVE	Rechenauslastung – relevant im Prefill
DCGM_FI_DEV_FB_USED	Belegter Videospeicher
DCGM_FI_DEV_GPU_TEMP	Drosselung erkennen
DCGM_FI_DEV_POWER_USAGE	Kosten und Drosselung
DCGM_FI_DEV_SM_CLOCK	Fällt bei Drosselung ab
DCGM_FI_DEV_XID_ERRORS	Alarm, kein Dashboard

C.7 LiteLLM

Vollständige Behandlung in Kapitel 11. Der Aufbau der Konfiguration:

```
model_list:
  - model_name: <fachlicher Name>
    litellm_params:
      model: <anbieter>/<modell>
      api_base: <url>
      api_key: os.environ/<VARIABLE>
      input_cost_per_token: <preis> # eigene Modelle
      output_cost_per_token: <preis> # Kapitel 11.7

router_settings:
  routing_strategy: least-busy
  redis_host: os.environ/REDIS_HOST
  fallbacks: [{<modell>: [<ausweichziel>]}]
  context_window_fallbacks: [{<modell>: [<laengeres>]}]
  num_retries: 2
  allowed_fails: 3
  cooldown_time: 60

litellm_settings:
  turn_off_message_logging: true # Kapitel 11.6
```

```

success_callback: [prometheus, otel]
cache: true

general_settings:
  database_url: os.environ/DATABASE_URL
  master_key: os.environ/MASTER_KEY
  enable_jwt_auth: true # Kapitel 12.3

```

C.7.1 Verwaltung

Endpunkt	Zweck
POST /team/new	Team anlegen
POST /key/generate	Virtual Key mit Budget und Grenzen
GET /spend/logs	Verbrauch je Anfrage – Grundlage der Verrechnung
GET /v1/models	Gefilterter Katalog je Schlüssel
GET /health/readiness	Bereitschaft und erreichbare Ziele

C.8 Formeln

Die Rechnungen des Buches an einer Stelle.

Größe	Formel
KV-Cache je Token	$2 \cdot L \cdot H_{kv} \cdot D \cdot B$ Bytes – Kapitel 2.5
Decode-Rate	Speicherbandbreite ÷ Modellgröße – Kapitel 2.4
Prefill-Aufwand	$\approx 2 \cdot P \cdot T$ Operationen – Kapitel 2.3
Nutzbarer KV-Cache	VRAM × Nutzung – Gewichte – Aktivierungen – Kontext
Gleichzeitige Sequenzen	KV-Cache ÷ (Kontextlänge × Bytes je Token)
Anfragen im System	Rate × Verweildauer (Little) – Kapitel 2.14
Preis je Mio. Token	Kartenkosten ÷ erzeugte Token – Kapitel 11.7
4-Bit-Modellgröße	$P_{fix} \cdot 2 + (P_{ges} - P_{fix}) \cdot 4\{, \} \frac{25}{8}$ Bytes

C.9 Faustregeln

Regel	Herkunft
Gewichte höchstens zwei Drittel des nutzbaren Speichers	Kapitel 3.6
4-Bit spart rund 60 Prozent, nicht 75	Kapitel 3.4
Deutsch braucht 1,5- bis 2-fache Tokenmenge gegenüber Englisch	Kapitel 2.2
Ein Gigabyte VRAM entspricht rund 8 000 Token KV-Cache bei 8B	Kapitel 2.5
Break-even Eigenbetrieb bei rund 10 Prozent Auslastung	Kapitel 14.14

Regel	Herkunft
Abkühlzeit der Skalierung = Vielfaches der Ladezeit	Kapitel 10.5
Modellverzeichnisse zwei Wochen vorhalten	Kapitel 16.5
TP bis zur Knotengrenze, PP darüber	Kapitel 9.4
Eine Karte trägt einige hundert Nutzer — beschafft werden zwei	Kapitel 17.1

Glossar

Begriffe, wie sie in diesem Buch verwendet werden. Wo die englische Form üblich ist, steht sie voran – die Übersetzung folgt, wo eine sinnvolle existiert.

Aktivierungen Zwischenergebnisse eines Vorwärtsdurchlaufs. Belegen VRAM abhängig von der Batchgröße – Posten in der Bilanz aus Kapitel 3.6.

AWQ Quantisierungsverfahren, das anhand von Aktivierungsmustern entscheidet, welche Gewichte geschützt werden. Regelverfahren für 4 Bit – Kapitel 3.4.

BF16 16-Bit-Gleitkommaformat mit dem Wertebereich von FP32 bei geringerer Genauigkeit. Der Standard für Inferenz – Kapitel 3.2.

Chunked Prefill Zerlegung eines großen Prefills in Teilstücke, damit laufende Decodes nicht blockiert werden – Kapitel 7.4.

Continuous Batching Batching, bei dem die Zusammensetzung nach jedem Rechenschritt neu entschieden wird. Fertige Anfragen verlassen den Batch sofort – Kapitel 7.3.

DCGM Telemetriedienst für NVIDIA-GPUs. Liefert die Metriken, auf denen das Monitoring aufbaut – Kapitel 14.2.

Decode Phase, in der Token einzeln erzeugt werden. Bandbreitenbegrenzt, sequenziell, bestimmt TPOT – Kapitel 2.4.

Device Plugin Dienst, der Kubernetes Hardware meldet, die es nicht selbst erkennt. Meldet GPUs als `nvidia.com/gpu` – Kapitel 5.1.

Egress Ausgehender Netzwerkverkehr. Bei KI-Plattformen der Weg, auf dem Daten das Haus verlassen – Kapitel 13.6.

Einbettung (Embedding) Vektordarstellung eines Textes für Ähnlichkeitssuche. Grundlage von RAG – Kapitel 15.

Erweiterte Ressource Kubernetes-Mechanismus für Hardware außerhalb von CPU und Speicher. Ganzzahlig, exklusiv, nicht überbuchbar – Kapitel 5.1.

Fallback Ausweichziel, wenn das primäre Modell nicht antwortet. Muss innerhalb der Datenklasse bleiben – Kapitel 11.4.

FP8 8-Bit-Gleitkommaformat. Setzt Hardware ab Ada oder Hopper voraus – Kapitel 3.2.

Goodput Anteil der Anfragen, die alle Latenzzusagen einhalten. Die ehrlichste Leitkennzahl – Kapitel 14.5.

GQA (Grouped-Query Attention) Mehrere Query-Köpfe teilen sich ein Key-Value-Paar. Reduziert den KV-Cache erheblich – Kapitel 2.5.

Guardrail Prüfung im Anfrage- oder Antwortpfad – Kapitel 13.

- Head-of-Line-Blocking** Ein großer Prefill hält die Decodes aller laufenden Anfragen an – Kapitel 2.9.
- HNSW** Indexverfahren für Vektorsuche. Belegt 50 bis 100 Prozent zusätzlich zur Vektorgröße – Kapitel 15.4.
- InferenceService** KServe-Ressourcenart, die ein Modell deklarativ bereitstellt – Kapitel 10.3.
- Kontextlänge** Maximale Zahl an Token je Anfrage. Eine Kapazitätsentscheidung, keine Modelleigenschaft – Kapitel 2.13.
- KV-Cache** Zwischengespeicherte Key- und Value-Vektoren. Der zentrale Kapazitätsengpass – Kapitel 2.5.
- LoRA** Kleine Zusatzmatrizen, die ein Basismodell fachlich anpassen. Erlauben viele Varianten auf einer Karte – Kapitel 8.4.
- MIG** Aufteilung einer GPU auf Hardwareebene. Einziges Verfahren mit echter Speicher- und Fehlerisolation – Kapitel 6.5.
- MoE (Mixture of Experts)** Architektur, bei der je Token nur ein Teil der Parameter rechnet. Speicherbedarf nach Gesamtzahl, Rechenaufwand nach aktiven Parametern – Kapitel 3.9.
- MPS** Verfahren, mehrere Prozesse gleichzeitig auf einer GPU rechnen zu lassen. Bessere Auslastung, schwächere Fehlerisolation – Kapitel 6.4.
- NCCL** Bibliothek für Sammeloperationen zwischen GPUs. Bestimmt die Skalierung bei Tensor Parallelism – Kapitel 9.3.
- NVLink** Direktverbindung zwischen GPUs, um eine Größenordnung schneller als PCIe – Kapitel 4.3.
- PagedAttention** Blockweise Verwaltung des KV-Cache nach dem Vorbild virtueller Speicherverwaltung – Kapitel 7.2.
- Pipeline Parallelism** Aufteilung der Schichten auf mehrere GPUs. Über Knotengrenzen brauchbar, braucht Last – Kapitel 9.4.
- Prefill** Phase, in der alle Prompt-Token gemeinsam verarbeitet werden. Rechenbegrenzt, bestimmt TTFT – Kapitel 2.3.
- Prefix Caching** Wiederverwendung der KV-Blöcke gemeinsamer Prompt-Anfänge – Kapitel 7.5.
- Prompt Injection** Eingeschleuste Anweisungen, die das Verhalten verändern. Mit Infrastrukturmitteln nicht lösbar, nur eingrenzbar – Kapitel 13.2.
- Quantisierung** Darstellung der Gewichte mit weniger Bits. Wirkt doppelt: weniger Speicher und schnellerer Decode – Kapitel 3.4.
- RAG** Abrufgestützte Generierung – relevante Abschnitte werden gesucht und in den Prompt gestellt – Kapitel 15.
- safetensors** Format für Modellgewichte ohne ausführbaren Anteil. In Produktion verpflichtend – Kapitel 3.2.
- Scale-to-Zero** Herunterskalieren auf null Repliken. Bei LLMs durch die Ladezeit eingeschränkt – Kapitel 10.5.

- ServingRuntime** KServe-Ressourcenart, die beschreibt, wie ein Inferenz-Server gestartet wird – Kapitel 10.3.
- Speculative Decoding** Ein kleines Modell schlägt Token vor, das große bestätigt sie in einem Durchlauf – Kapitel 7.6.
- Tensor Parallelism** Aufteilung der Gewichtsmatrizen auf mehrere GPUs. Gehört in einen Server – Kapitel 9.2.
- Time-Slicing** Zeitgeteilte Nutzung einer GPU. Teilt Rechenzeit, **nicht** Speicher – Kapitel 6.2.
- Token** Verarbeitungseinheit eines Sprachmodells. Deutsch braucht mehr davon als Englisch – Kapitel 2.2.
- TPOT** Time per Output Token – Abstand zwischen zwei Ausgabetoken. Bestimmt, ob die Ausgabe flüssig wirkt – Kapitel 2.7.
- TTFT** Time to First Token – Zeit bis zum ersten ausgegebenen Token. Prägt die Wahrnehmung – Kapitel 2.7.
- Verdrängung (Preemption)** Zurückstellen laufender Anfragen bei vollem KV-Cache. Ein Alarmsignal, kein Normalzustand – Kapitel 7.3.
- vGPU** Aufteilung einer GPU auf Hypervisor-Ebene. Setzt Rechenzentrumskarte und Lizenz voraus – Kapitel 6.12.
- Virtual Key** Vom Gateway vergebener Schlüssel mit Budget, Kontingent und Allowlist – Kapitel 11.3.
- Xid** Fehlermeldung des NVIDIA-Treibers. Die Nummer trennt Anwendungs- von Hardwarefehlern – Kapitel 4.9.

Sachregister

Fette Seitenzahlen verweisen auf die Stelle, an der ein Begriff erklärt wird.

A

Aktivierungen 53, 174
AWQ 51

B

Batching 18, 35, 131
BF16 49, 70, 174

C

Chunked Prefill 37, 136
Container Toolkit 90

D

Datenklassifikation 16, 224
DCGM 16, 82, 101, 272
Decode 4, 29, 47, 70, 136, 173
Device Plugin 90, 110

E

Egress-Kontrolle 19, 257
Einbettungsmodell 39, 294
Erweiterte Ressource 89

F

FP8 49, 97

G

GitOps 1, 14, 259, 309
Goodput 34
GPU Operator 3, 78, 89, 113, 272
Grouped-Query Attention 31

H

Head-of-Line-Blocking 136

I

InferenceService 201
Ingestion 39, 203, 293

K

Kapazitätsplanung 80, 180
Kontextlänge 1, 40, 59, 132, 160, 218
Kontingent 16, 121, 213, 233
KServe 3, 191, 339
KV-Cache 1, 16, 30, 47, 131, 156, 178

L

LiteLLM 339
LoRA 155

M

MIG 17, 71, 114
Mixture-of-Experts 57, 180
MPS 17, 113

N

NetworkPolicy 161
NVLink 71, 103, 179

O

OpenBao 237

P

PagedAttention 132
Pipeline Parallelism 175
Prefill 4, 29, 55, 136, 183, 205
Prefix Caching 37, 162

Q

Quantisierung 47, 140

R

RAG 39, 164, 203, 258, 289
RKE2 89

S

safetensors 18, 48
Scale-to-Zero 18, 61, 80
Scheduler 1, 17, 102, 133, 196
ServingRuntime 194
SLO 274
Speculative Decoding 58, 137

T

Taint 96
Tensor Parallelism 72, 172
Time-Slicing 17, 110
Token 16, 28, 53, 70, 131, 172, 205, 213, 234, 296, 334
TPOT 34
TTFT 34, 297

V

Verdrängung 38
vGPU 121
Virtual Key 236
vLLM 3, 27, 139, 151, 181, 192, 339

X

Xid 80, 100

Zum Schluss

Dieses Buch ist aus einer Landkarte entstanden: einer Aufstellung von acht Wissensgebieten und fünfzig Fragen, die beschrieben, was ein Enterprise AI Platform Engineer beherrschen sollte. Was fehlte, waren die Antworten – und vor allem die Rechnungen, aus denen sie folgen.

Der Anspruch war deshalb von Anfang an nicht, Werkzeuge zu erklären. Werkzeuge veralten; die Referenzabschnitte dieses Buches werden es auch. Der Anspruch war, die **Herleitungen** verfügbar zu machen – so, dass man sie weitergeben kann.

MERKE

Was bleibt, wenn die Werkzeugnamen sich ändern, steht in Kapitel 17.15. Sieben Aussagen, die aus der Struktur des Problems folgen und nicht aus einer Implementierung: Prefill und Decode sind verschiedene Workloads. Der KV-Cache ist der Kapazitätsengpass. Batching ist der größte Durchsatzhebel. Auslastung schlägt Verfügbarkeit. Governance gehört an die Stelle mit allen Informationen. Der Anfrageinhalt ist der Compliance-Gegenstand. Modelle sind große, langsame Artefakte.

Wer diese sieben begründen kann – mit den Rechnungen, nicht mit Behauptungen – kann eine KI-Plattform entwerfen und die Entscheidungen gegenüber Menschen vertreten, die die Technik nicht kennen. Das war das Ziel.

Der zweite Teil des Ziels lässt sich nicht durch Lesen erreichen. Die Labs dieses Buches sind nicht Zierrat: Der Unterschied zwischen jemandem, der eine Plattform beschreiben kann, und jemandem, der eine gebaut hat, fällt in jedem ernsthaften Gespräch auf – und er zeigt sich genau bei der Frage, was man beim nächsten Mal anders machen würde.

Das Referenz-Lab aus dem Vorwort genügt dafür. Eine Karte, ein Cluster, ein Modell.